硕士学位论文

（专业学位论文）

基于图神经网络的多行为去噪推荐方法研究

RESEARCH ON MULTI-BEHAVIOR DENOISING RECOMMENDATION METHOD BASED ON GRAPH NEURAL NETWORKS

樊红雨

哈尔滨工业大学

2026 年 1 月

国内图书分类号：TM301.2　　学校代码：10213
国际图书分类号：62-5　　密级：公开

硕士学位论文

基于图神经网络的多行为去噪推荐方法研究

硕士研究生：樊红雨

导　　师：马江虹副教授

申请学位：专业硕士

类　　别：计算机技术

所在单位：哈尔滨工业大学（深圳）

答辩日期：2026 年 01 月

授予学位单位：哈尔滨工业大学

Classified Index: TM301.2
U.D.C: 62-5

Dissertation for the Master Degree

RESEARCH ON MULTI-BEHAVIOR DENOISING RECOMMENDATION METHOD BASED ON GRAPH NEURAL NETWORKS

Candidate: Hongyu Fan
Supervisor: Associate Prof. Jianghong Ma
Academic Degree Applied for: Master of Engineering
Specialty: Electronic and Information Engineering
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: January, 2026
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

随着用户交互行为类型的日益丰富，推荐系统在多行为场景下面临严重的噪声干扰与偏好混叠问题。用户在电商或内容平台上的点击、收藏、加购、购买等行为虽然能够反映潜在兴趣，但其中包含的随机、误触或弱相关交互会削弱模型对真实偏好的刻画能力。此外，传统多行为推荐多依赖协同信号，缺乏模态语义信息的辅助，难以在复杂语义环境下准确识别噪声行为。针对上述问题，本文围绕“多行为协同去噪”与“多模态语义引导去噪”两个方向展开研究，提出了两个具有互补性的去噪推荐模型。

首先，提出噪声识别与偏好提取的多行为去噪推荐方法，面向多行为推荐中的噪声干扰问题。该模型从行为间与行为内两个层面建模用户偏好关系，设计了行为加权机制与自监督约束，从多行为图结构中自动识别并抑制噪声交互的影响。同时，引入噪声感知的偏好提取模块，使模型在保留高质量辅助行为信号的同时，消除弱相关或不可靠的交互，从而获得更精确的偏好表示。

其次，为进一步扩展至多模态多行为场景，提出基于噪声识别与偏好提取的多模态多行为去噪推荐方法。该方法引入大型视觉语言模型提取物品的图像与文本语义表示，通过模态语义相似度实现硬去噪，去除语义不一致的辅助交互；在图神经网络框架中，设计语义感知注意力机制以实现软去噪，自适应调整邻居节点的信息权重，从而聚焦于语义一致的高质量交互。此外，提出跨图对比学习模块，在语义增强图与去噪图之间建立一致性约束，实现模态语义信息向结构空间的有效迁移。

本文的创新性体现在结合协同信号建模与多模态语义理解技术，提出两种创新方法以解决多行为推荐场景中的噪声干扰与真实偏好识别问题。一方面，从协同信息建模与去噪机制两方面入手，设计了基于行为内与行为间双层结构的噪声感知偏好提取模型，实现对真实偏好与噪声交互的有效区分，提升了多行为推荐的精确性与鲁棒性；另一方面，利用大型视觉语言模型的语义理解能力与多模态特征融合机制，构建多模态多行为去噪推荐框架，通过语义一致性约束实现软、硬去噪的协同优化，从视觉与文本模态中挖掘跨模态真实偏好信号，为复杂交互场景下的鲁棒推荐提供了新的思路与方法。

关键词：推荐系统；图神经网络；去噪推荐；多行为推荐

Abstract

With the increasing diversity of user interaction behaviors, recommender systems in multi-behavior scenarios face significant challenges of noise interference and preference entanglement. User actions on e-commerce or content platforms—such as clicks, favorites, add-to-cart, and purchases—can reflect potential interests, yet they often include random, accidental, or weakly related interactions that obscure true user preferences. Moreover, traditional multi-behavior recommendation methods primarily rely on collaborative signals, lacking semantic guidance from multimodal information, which limits their ability to identify noisy behaviors in complex semantic environments.

To address these issues, this thesis investigates two complementary directions: collaborative denoising and multimodal semantic-guided denoising, and proposes two novel denoising recommendation models.

First, a Noise-aware Inter- and Intra-behavior Preference Extraction model (NIPER) is proposed to address noise interference in multi-behavior recommendation. This model captures user preference relationships at both inter-behavior and intra-behavior levels, and introduces a behavior-weighted mechanism together with a self-supervised constraint to automatically identify and suppress noisy interactions in the multi-behavior graph. Furthermore, a noise-aware preference extraction module is designed to preserve high-quality auxiliary behavioral signals while filtering out weakly relevant or unreliable interactions, thus yielding more accurate user preference representations.

Second, to further extend the denoising framework to multimodal multi-behavior scenarios, a large-model semantic-guided multimodal denoising recommendation framework is proposed. This method leverages large vision-language models to extract semantic representations from both textual and visual modalities of items. Based on cross-modal semantic similarity, a hard-denoising mechanism removes inconsistent auxiliary interactions. Within the graph neural network (GNN) architecture, a semantic-aware attention mechanism is introduced to achieve soft denoising by adaptively adjusting neighbor weights, thereby emphasizing semantically consistent and informative interactions. In addition, a cross-graph contrastive learning module establishes consistency constraints between the denoised graph and the semantic-augmented graph, enabling effective transfer of semantic information into the structural representation space.

The main contributions of this thesis are as follows: (1) A collaborative denoising

method that distinguishes true preferences from noisy interactions through a dual-level (inter- and intra-behavior) preference extraction framework, enhancing the accuracy and robustness of multi-behavior recommendation; (2) A multimodal semantic-guided denoising framework that integrates large vision-language models and attention-based message passing, achieving synergistic optimization of hard and soft denoising via semantic consistency constraints. This design effectively captures cross-modal preference signals from textual and visual modalities, providing a new perspective and methodology for robust recommendation in complex multi-behavior and multimodal environments.

Keywords: recommender system, graph neural network, denoising recommendation, multi-behavior recommendation

目 录

摘 要 I
ABSTRACT II
第 1 章 绪论 1
1.1 本文研究背景 1
1.2 本文研究目的 2
1.3 国内外相关研究概述 2
1.3.1 基于图神经网络的推荐算法研究现状 2
1.3.2 基于图神经网络的多行为推荐研究现状 3
1.3.3 去噪推荐算法研究现状 4
1.3.4 多模态与大模型驱动的推荐研究现状 5
1.3.5 研究概述小结 7
1.4 本文的主要研究内容及章节安排 8
1.4.1 主要研究内容 8
1.4.2 噪声建模与去噪问题的统一视角 10
1.4.3 论文组织结构 11
1.4.4 论文整体研究框架 11
第 2 章 图神经网络与对比学习相关理论概述 13
2.1 引言 13
2.2 图神经网络相关原理及理论知识 13
2.2.1 图神经网络的基本流程 13
2.2.2 典型图神经网络模型 14
2.3 对比学习相关原理及理论知识 17
2.4 本章小结 18
第 3 章 噪声感知与偏好提取的多行为推荐方法 19
3.1 引言 19
3.2 问题定义及方法概述 19
3.2.1 问题定义 19
3.2.2 算法概述 20
3.3 行为间与行为内加权去噪模块 22
3.4 偏好感知的表征增强模块 25

3.5 模型训练 27
3.6 实验与讨论 28
3.6.1 评价指标 28
3.6.2 数据集信息 28
3.6.3 实验设置 29
3.6.4 总体实验效果 29
3.6.5 消融实验 31
3.6.6 参数实验 31
3.6.7 案例研究 32
3.7 本章小结 35
第 4 章 噪声感知与偏好提取的多模态多行为推荐方法 36
4.1 引言 36
4.2 问题定义及方法概述 36
4.2.1 问题定义 36
4.2.2 算法概述 37
4.3 多模态辅助偏好建模 39
4.4 语义感知注意力的软去噪消息传递 41
4.5 模态感知图增强与对比学习 42
4.6 模型训练 44
4.7 实验与讨论 45
4.7.1 评价指标 45
4.7.2 数据集信息 45
4.7.3 实验设置 46
4.7.4 总体实验效果 46
4.7.5 消融实验 48
4.7.6 参数实验 49
4.7.7 案例研究 49
4.8 本章小结 51
结 论 52
参考文献 54
攻读硕士学位期间取得创新性成果 59
哈尔滨工业大学学位论文原创性声明和使用权限 60
致 谢 61

第 1 章 绪论

1.1 本文研究背景

近年来，随着互联网的快速发展和数据规模的急剧膨胀，现实世界的信息量呈现出指数级增长的趋势。用户在享受信息便利的同时，也面临着“信息过载”的问题，即如何在海量数据中高效地筛选出符合个人兴趣和需求的内容，已成为当前研究和产业界的核心挑战之一。推荐系统（Recommender System, RS）正是在这一背景下应运而生，它通过分析用户与物品之间的历史交互关系来学习用户与物品的表示，从而为用户提供个性化内容推荐[1–3]。推荐系统如今已成为互联网产品的重要组成部分，被广泛应用于视频平台（如 YouTube、抖音）、音乐平台（如 QQ 音乐、网易云音乐）以及电商平台（如淘宝、拼多多、京东）等，为用户带来便利体验的同时也为企业创造了显著的商业价值。

推荐系统的发展大致经历了从基于相似度的协同过滤（Collaborative Filtering, CF)[4]，到基于深度学习的表示学习方法[3]，再到近年来基于图神经网络（Graph Neural Network, GNN)[2] 的阶段。协同过滤通过度量用户或物品间的相似性实现推荐，而深度学习方法利用神经网络提升了表示能力。近年来，GNN 被广泛应用于推荐系统中，能够在用户–物品二部图上建模高阶关系，通过消息传递机制捕捉潜在的交互模式，从而显著提升推荐性能。

在实际的电商场景中，不同平台的用户行为模式呈现显著差异。例如，淘宝具有多场景、多触点的推荐链路，用户浏览行为丰富但意图跨度较大；拼多多用户的交互频率较高，但弱意图点击占比更大、噪声比例更高；京东的行为密度相对较低，但购买类行为更能直接反映用户的明确偏好。这些平台在用户行为密度、意图强度与噪声比例方面的结构性差异，导致行为数据在语义和质量上存在显著不一致性，也使得推荐模型在不同平台上的行为建模面临更高挑战。

值得注意的是，现有的多数图神经网络推荐方法仍仅基于用户的单一目标行为（如购买）进行建模[5–7]。这一简化假设在真实平台的复杂交互场景下存在明显局限。事实上，用户往往会对同一物品产生多种行为[8,9]，如浏览、收藏、加购、购买等。这些行为反映了从浅层兴趣到深层意图的渐进过程，蕴含着更丰富的语义信息。为缓解数据稀疏问题并增强模型的表达能力，多行为推荐（Multi-Behavior Recommendation, MBR）通过引入辅助行为来扩充目标行为的有效信号。

但与此同时，引入辅助行为的同时也带来了大量噪声行为。由于弱意图行为（如浏览、随手点击）的语义更弱且不可控，这些行为容易偏离用户的真实兴趣。如

果直接将其纳入建模，将干扰模型的偏好学习过程，甚至导致推荐结果偏移。因此，如何有效识别并抑制多源行为中的噪声影响，成为当前多行为推荐研究面临的核心挑战之一。

1.2 本文研究目的

针对目前多行为推荐系统在去噪方面的研究不足，本文拟提出一种基于图神经网络的多行为去噪推荐模型。该模型通过在多行为图结构中引入噪声建模与关系加权机制，实现对多源行为的联合学习与鲁棒推荐。本文的研究目标在于提升推荐系统在复杂行为场景下的准确性与鲁棒性，同时为多行为数据的统一建模与泛化能力提供新的思路，从而推动推荐系统在真实环境中的稳定性与应用效果。

1.3 国内外相关研究概述

1.3.1 基于图神经网络的推荐算法研究现状

近年来，图神经网络凭借其在处理图结构化数据方面的强大建模能力，已成为推荐系统领域的重要研究方向。推荐系统的核心任务是基于用户的历史行为预测其未来的兴趣偏好，而用户与物品之间的交互关系可以自然地建模为图结构，这使得 GNN 在该场景中展现出独特优势。

GNN 能够在用户-物品二部图上建模高阶交互关系[10]。其中，用户和物品分别作为节点，交互行为作为边，通过消息传递与聚合机制，模型能够捕获潜在的关系模式，从而学习到更具表达力的用户与物品表示。此外，GNN 还可进一步融合外部信息，例如用户的社交关系[11] 和物品的知识图谱[12]，以构建统一的表示学习框架，更全面地刻画推荐系统中的异构数据特征。

图神经网络在推荐系统中的发展呈现出“结构简化”与“学习范式增强”双轨并进的趋势。早期工作 NGCF[7] 首次将协同过滤信号嵌入图神经网络的消息传递过程，通过多层邻居聚合捕获高阶交互关系，但其引入的非线性变换导致计算复杂度高且易引发过平滑问题。针对此局限，LightGCN[5] 通过移除非线性激活与特征变换层，仅保留邻居聚合与层间加权操作，在显著降低计算开销的同时保持了优异性能，验证了简洁图卷积结构在推荐任务中的有效性与鲁棒性。为进一步提升模型泛化能力，研究者将自监督对比学习引入图推荐框架：SGL[13] 基于图结构数据增强构建多视角表示，通过拉近同一节点在不同视角下的嵌入距离增强表征一致性；而 SimGCL[14] 则进一步简化流程，摒弃复杂的数据增强操作，转而通过在嵌入空间施加可控噪声扰动实现对比学习，以更轻量的结构取得相当甚至更优的

效果。这一系列工作表明，通过结构精简与自监督机制的协同设计，图神经网络推荐模型在效率、稳定性与泛化能力方面实现了系统性提升，为后续研究提供了清晰的技术路径与理论启示。

综上，基于图神经网络的推荐研究已取得显著进展，但在多行为建模方面仍存在不足。为进一步挖掘用户偏好的多层次特征，研究者开始探索基于图神经网络的多行为推荐方法，这将在下一节中详细介绍。

1.3.2 基于图神经网络的多行为推荐研究现状

传统的推荐模型通常仅利用单一类型的用户-物品交互行为进行建模，因此容易面临数据稀疏和冷启动等问题。多行为推荐通过引入多种用户-物品交互类型（例如浏览、收藏、加入购物车等），为缓解上述问题提供了有效的解决思路[15–18]。在多行为场景中，如何实现辅助行为（如浏览、收藏、加购）与目标行为（如购买）之间的有效信息融合，一直是学术界关注的研究重点。相关研究主要聚焦于探索不同行为之间的语义关联与交互机制，以提升目标行为的预测性能。图 1-1 展示了多行为推荐中典型的多种行为数据形式及其对应的推荐目标。

图 1-1: 多行为推荐的数据形式[2]

在多行为推荐研究中，如何有效融合异构行为信号、建模行为间复杂关系并提升模型鲁棒性，成为持续演进的核心议题。Jin 等人[19] 提出的 MBGCN 模型率先构建统一异构图结构，通过用户-物品二部图学习行为交互贡献，并在物品-物品共同交互图上建模行为语义相关性，实现多行为信号的互补融合，但其在噪声行为处理与行为依赖建模方面仍显不足。针对行为间依赖关系与用户行为模式差异性问题，Xia 等人[20] 引入元学习框架，将不同行为视为独立任务，通过动态调整图

神经网络参数实现跨行为知识迁移，显著增强了模型对多样化用户行为的适应能力，然而训练复杂度较高且对参数初始化较为敏感。为挖掘行为共性以缓解监督信号稀疏，Gu 等人[9] 设计 S-MBRec 模型，借助自监督学习最大化目标行为与辅助行为嵌入的一致性，在提升信号利用率的同时减少冗余，但对噪声行为的鲁棒性仍有提升空间。进一步地，Cheng 等人[21] 观察到多行为常呈现顺序性与因果依赖，提出 Cascading GCN 模型，通过级联结构将前序行为嵌入传递至后续行为的图卷积层，显式刻画用户兴趣的动态演化过程，但其对预设行为顺序的依赖限制了在非线性行为模式下的适用性。为突破多行为独立建模的局限，Zhang 等人[22] 提出 POGCN 模型，定义行为间的偏序关系并构建加权图结构，在保留层次差异的同时实现全局行为融合，然而该方法仍未充分区分不同行为的信噪差异。在此基础上，Zhang 等人[23] 进一步提出 DPT 模型，采用预训练策略对辅助行为交互进行质量评估与噪声过滤，在清洗后的数据上联合训练以提升表示质量，但其去噪机制与多行为关联结构解耦，且未能自适应建模各类行为的噪声比例差异。综上，多行为推荐研究正沿着“结构融合 → 依赖建模 → 自监督增强 → 顺序感知 → 偏序整合 → 噪声鲁棒”这一技术脉络持续深化，未来工作需进一步协同优化行为语义建模、动态依赖捕捉与噪声自适应处理能力，以构建更精准、稳健的用户兴趣表征框架。

虽然多行为推荐已取得显著进展，但现有研究大多关注于如何将多种行为信息进行融合，而较少考虑辅助行为中潜在的噪声问题。在实际场景中，诸如点击、浏览、收藏等辅助行为通常成本较低、随意性较强，往往不能准确反映用户的真实兴趣或购买意图，从而引入大量噪声。尽管 DPT 模型[23] 尝试对辅助行为进行去噪，但其仍沿用单行为推荐中的独立去噪思路，未能充分建模多种行为之间的关联差异。事实上，不同行为对用户偏好的反映程度并不相同，其噪声比例也应具有差异。因此，如何在多行为推荐中有效识别并抑制噪声行为，成为当前研究亟待解决的问题，也促使去噪推荐逐渐成为新的研究方向。

1.3.3 去噪推荐算法研究现状

推荐系统主要依赖于隐式反馈（Implicit Feedback）来学习用户偏好。隐式反馈指用户在与系统交互过程中无需明确表达意图，系统根据用户的行为（如点击、浏览、收藏等）推断其兴趣偏好。与显式反馈（如评分或评论）相比，隐式反馈更易获取且更符合用户的真实行为特征。然而，在实际场景中，隐式反馈往往包含大量噪声样本，如误点击、随机浏览或非兴趣驱动的交互，这些噪声会干扰模型对用户真实偏好的学习，导致推荐性能下降。因此，如何识别并抑制噪声反馈，成为推荐系统研究中的重要问题[24]。

在推荐系统的噪声鲁棒性研究中，去噪策略的设计逐步从单点优化走向结构感知与多粒度协同。Wang 等人[25] 首次提出基于训练动态的自适应去噪框架（ADT），通过监测隐式交互的损失值分布，采用截断或加权策略动态抑制高损失样本的干扰，奠定了“训练信号驱动去噪”的基础范式。然而，该方法未考虑图结构中噪声通过邻域聚合的传播效应。针对此局限，Tian 等人[26] 引入图去噪模块与多样性保持模块：前者优化图拓扑以筛选可靠交互关系，后者联合去噪数据与多样性增强样本进行训练，在抑制全局噪声扩散的同时缓解了过度去噪引发的数据稀疏问题。进一步地，Fan 等人[6] 指出交互频次异质性带来的双重挑战——稀疏节点信息不足与密集节点噪声冗余，提出 GraphDA 模型：通过预训练获取节点嵌入，并采用 Top-K 双向增强策略，对稀疏节点进行语义扩充、对高频节点实施精准去噪，有效平衡数据不平衡与噪声干扰。然而，基于瞬时损失的噪声判别易受困难样本干扰，评估稳定性不足。He 等人[27] 提出 DCF 模型，通过聚合多轮训练迭代的损失轨迹提升样本评估鲁棒性，并创新性地将标记噪声样本重新标注后参与训练，在增强模型抗噪能力的同时避免了有效信息的浪费。近期，Zhang 等人[28] 将去噪机制拓展至多行为推荐场景，设计 DeMBR 双层框架：硬去噪层依据多行为嵌入相似度剔除低质量交互；软去噪层则引入语义引导机制，以强表达行为（如购买）的语义信号校准弱表达行为（如点击）的噪声分布。该方法虽显著提升多行为推荐性能，但仍依赖预设行为强度假设，缺乏对噪声比例的动态感知能力。综上，去噪研究已从“单点损失筛选”演进至“图结构优化—频次感知增强—多轮评估稳定—多行为语义协同”的系统化框架，未来需进一步融合自适应噪声建模、行为强度动态校准与图结构演化感知，以构建更具鲁棒性与解释性的推荐系统。

综上所述，现有去噪推荐研究主要聚焦于单行为隐式反馈场景下的噪声识别与抑制，通过损失监测、自适应加权或图结构重构等手段提升模型鲁棒性。然而，在多行为推荐系统中，辅助行为（如浏览、收藏、加购）普遍存在噪声，而相关研究仍较为匮乏。当前方法往往假设所有辅助行为的噪声分布一致，忽略了不同行为在用户偏好反映上的差异性。针对这一问题，本文将从“多行为去噪”的角度出发，探索在图神经网络框架下识别并抑制辅助行为噪声的新方法，以更准确地刻画用户真实兴趣并提升多行为推荐性能。

1.3.4 多模态与大模型驱动的推荐研究现状

(1) 多模态推荐研究现状

近年来，研究者开始探索在推荐系统中融合多模态信息，以更全面地理解用户兴趣与物品语义。多模态推荐通过结合文本、图像、音频等内容特征，能够在冷

启动与稀疏交互场景下显著提升模型性能。然而，现有多模态推荐方法普遍存在两个主要不足：一是多数模型仅在特征层面进行模态信息的简单融合，未能充分建模不同模态之间的交互与互补关系；二是模态特征中常存在噪声（如图像背景干扰或文本冗余描述），若未加以抑制，可能会削弱模型对用户真实偏好的刻画精度。

在多模态推荐研究中，如何有效挖掘模态内容蕴含的物品关联结构，并协同处理模态噪声与特征冗余，成为提升推荐质量的关键挑战。Zhang 等人提出的 LATTICE 模型[29] 首次系统构建了多模态隐式关联图谱，为图像、文本等各模态分别建立物品-物品图，并聚合为统一的潜在结构图进行图卷积传播，实现了模态语义与协同信号的有效融合。然而，该模型未显式建模模态间的互补关系，亦缺乏对模态特征中噪声干扰的鲁棒性处理机制。针对图结构效率与交互噪声问题，Zhou 等人[30] 提出 FREEDOM 模型，在保留 LATTICE 多模态图框架的基础上，通过冻结物品-物品图降低训练开销，并对用户-物品交互图实施剪枝与去噪策略，显著提升了模型稳定性与计算效率；但其仍未深入挖掘模态间的语义互补性，也未对模态内部噪声进行显式建模。为进一步解决多模态图神经网络中的特征冗余与模态噪声耦合问题，Mo 等人[31] 提出 MGNM 模型，构建局部-全局协同优化框架：在局部交互层面，引入动态去冗余损失，通过约束特征矩阵与系数矩阵的乘积关系，有效抑制多层传播引发的特征冗余；在全局交互层面，设计模态引导的特征去噪模块，针对性滤除与用户偏好无关的模态噪声，并显式建模模态内部的复杂语义关联。这一技术演进脉络清晰呈现了多模态推荐研究从“多模态图构建”到“结构效率优化”，再到“精细化噪声抑制与冗余控制”的深化过程，为后续融合模态互补性建模与自适应去噪机制的研究提供了重要思路。

总体而言，现有多模态推荐研究在提升模型表达能力和缓解数据稀疏方面取得了显著进展。然而，大多数方法仍主要关注模态内部特征的融合，而缺乏对不同模态间交互与语义互补关系的系统建模。同时，模态特征本身往往存在噪声与冗余信息，若未有效抑制，可能导致推荐结果偏离用户真实偏好。这些局限性为后续将大模型（LLMs）引入推荐系统以实现跨模态语义理解与知识增强提供了新的研究方向。

(2) 大模型结合推荐研究现状

近年来，大语言模型（Large Language Models, LLMs）在自然语言处理领域展现出强大的语义理解与推理能力，推动了推荐系统研究的新方向。LLM 在推荐系统中的应用主要集中于特征工程阶段，利用其开放世界知识与逻辑推理能力对原始数据进行后加工与数据增强，以生成语义更丰富的特征或样本，缓解数据稀疏

与冷启动问题。然而，现有多模态推荐方法往往忽视模态之间的关联性与模态内部的噪声特征，导致特征融合效果受限。为此，本文引入大语言模型作为语义引导模块，通过深层语义建模与关系补全来显式建模模态间关联，并削弱模态内部噪声，从而实现跨模态信息的语义对齐与高质量特征融合，提升推荐系统的鲁棒性与语义表达能力。

为应对推荐系统中数据稀疏、语义理解不足及噪声干扰等核心挑战，研究者积极探索将预训练语言模型与多模态技术深度融入推荐框架。Wei 等人提出的 LLM-Rec 模型[32] 首次系统性地利用大型语言模型（LLM）的通用知识与推理能力，从自然语言视角对推荐图进行三重增强：强化用户－物品交互边以丰富隐式反馈信号、深化物品节点的语义表征、构建细粒度自然语言用户画像，显著提升了稀疏场景下的语义理解与个性化建模能力。在多模态语义融合方向，Xu 等人[33] 针对兴趣点推荐中的模态异构问题，设计统一语义对齐框架：借助 BLIP2[34] 将图像内容转化为结构化文本描述，并通过 Sentence-BERT[35] 统一提取多模态语义表示，有效消解视觉与文本模态间的语义鸿沟，增强内容表达的完整性与一致性。进一步地，Wang 等人[36] 提出的 LLaRD 模型将 LLM 的能力延伸至噪声鲁棒性优化，突破传统去噪方法对外部知识或固定假设的依赖，创新性地引入语言先验与链式思维（CoT）推理机制：首先由 LLM 从交互数据中提炼用户偏好语义知识，继而通过逻辑推理显式识别并过滤无关或错误交互，在保留有效信息的同时显著提升模型抗噪能力。上述工作共同勾勒出预训练模型赋能推荐系统的技术演进路径——从图结构语义增强、多模态语义对齐，到基于语言推理的噪声感知与净化，标志着推荐系统正逐步迈向“语义驱动、认知增强”的新阶段，为构建更智能、可解释且鲁棒的下一代推荐框架提供了关键思路。总体来看，近年来大语言模型（LLMs）在推荐系统中的引入，为缓解数据稀疏、语义不一致及噪声干扰等长期难题提供了新的思路。相关研究表明，LLM 不仅能够利用其开放世界知识和推理能力丰富用户与物品的语义表示，还能在多模态融合与交互建模中发挥语义引导作用。

1.3.5 研究概述小结

在多行为推荐系统中，现有研究主要聚焦于利用多种用户交互行为（如点击、加购、收藏和购买）来缓解数据稀疏问题并提升推荐精度。然而，尽管多行为建模显著改善了用户偏好的捕获能力，现有方法在噪声识别与偏好提取方面仍存在若干不足与挑战：

辅助行为噪声问题：辅助行为虽能提供额外的用户偏好线索，但其中包含大量与真实兴趣无关的交互，例如偶然点击或临时操作。这类偶然点击通常表现为：

与用户长期兴趣模式不一致的短期行为、在相似用户交互中缺乏支持，以及未触发后续高价值行为。在多行为推荐建模中，这类噪声可能在图传播过程中被放大，导致模型学习到的用户偏好偏离真实分布。目前大多方法仍将不同辅助行为视为等价信号，缺乏对行为强度差异与行为内相关性的细粒度建模。为缓解其干扰，本文在后续方法中主要从两个维度识别辅助行为噪声：一是依据不同行为类型的强度差异赋予行为权重，反映其对目标偏好的可信度；二是基于相似用户的局部一致性，通过用户间共同交互模式评估单条行为的可靠性，从而有效过滤低可信度的噪声交互。

行为间依赖关系建模不足：多行为推荐往往将辅助行为直接与目标行为进行融合，却忽略了行为间的层次与依赖结构。例如，加购行为对购买的促进作用远强于点击行为，若未能显式区分不同行为的影响强度，容易引入跨行为噪声并造成信息混淆。

模态特征噪声与异构性问题：随着多模态推荐的兴起，视觉、文本等模态特征被广泛用于丰富物品表示。然而，不同模态间存在显著的语义空间差异，而单一模态内部也常含有噪声或冗余信息。若缺乏有效的模态对齐与噪声抑制机制，模态融合反而可能削弱推荐的语义一致性。

语义层面真实偏好提取不足：当前大多数方法仅依赖结构化交互数据进行建模，忽视了从语义层面理解与提炼用户真实偏好的可能性。由于交互行为背后潜藏着复杂的语义意图，单纯依赖协同信号难以全面刻画用户兴趣。

综上，现有研究在多行为推荐的去噪建模中仍存在结构层与语义层的双重瓶颈。为此，本文分别从**协同信号层面与语义层面**提出系统性改进：第一，设计基于协同信号的**跨行为与行为内加权去噪机制**，结合对比学习以区分真实偏好与辅助噪声；第二，引入**大语言模型（LLM）生成的模态语义信息**，通过模态引导的**硬去噪与软去噪策略**实现跨模态语义对齐与噪声抑制，并进一步通过模态驱动的对比学习增强语义一致性，从而实现多层次、可解释的多行为去噪推荐。

1.4 本文的主要研究内容及章节安排

1.4.1 主要研究内容

在信息过载与用户交互行为日益多样化的背景下，推荐系统正逐步从单一行为建模迈向多行为融合的深度语义理解阶段。多行为推荐系统通过联合建模点击、收藏、加购、购买等多种用户交互行为，在一定程度上缓解了数据稀疏问题。然而，辅助行为中普遍存在的噪声以及行为之间复杂的依赖关系，使得模型难以准

确刻画用户的真实偏好。在本文中，噪声被定义为：在多行为交互日志中被观测到、但与用户针对目标行为的真实偏好弱相关或在语义层面存在不一致的交互信号。这类噪声主要来源于用户的偶然点击、浏览试探以及界面诱导等行为，其在数据层面客观存在，但在偏好建模过程中对目标推荐任务具有潜在的误导性。需要指出的是，本文关注的并非由曝光机制或样本选择所导致的整体分布偏差，而是实例级、交互级的偏好不一致噪声。此外，随着多模态内容的引入，模态内部噪声以及模态间语义差异的叠加进一步加剧了推荐过程的不稳定性。针对上述挑战，本文以“基于图神经网络的多行为去噪推荐方法”为核心研究目标，从协同信号建模与语义建模两个层面展开系统研究，提出两种创新性框架，实现多源信息融合场景下的多层次去噪推荐。

首先，针对辅助行为中广泛存在的噪声问题，需要强调的是，本文并不试图消除所有辅助行为，而是在保持其整体信息价值的前提下，识别并抑制其中与目标偏好关联度较低的噪声交互，从而提升多行为信号对目标任务的有效性与稳定性。为此，本文设计了**噪声感知与偏好提取的多行为推荐方法**。该方法以用户—物品多行为交互图为基础，通过行为间与行为内的加权机制，分别从全局行为强度与局部相似交互两个层面识别潜在噪声交互。其中，跨行为加权模块利用因果推断方法估计不同行为对目标行为的影响强度，从而为各类行为分配合理权重；行为内加权模块则依据相似用户的共同交互模式动态调整交互权重，以保留高可信度的偏好信号。需要区分的是，上述权重建模与交互过滤过程旨在识别不可靠或具有误导性的个体交互信号，属于实例级去噪范畴，而非对用户或物品交互分布进行整体重加权或重采样。因此，本文的方法不同于以缓解曝光偏差或流行度偏差为目标的去偏（debias）方法，其核心在于提升偏好信号的纯净度，而非重塑数据分布。在此基础上，本文提出了权重引导的去噪机制，通过设定噪声阈值自适应地过滤低权重交互，构建高质量的多行为交互图。随后，引入偏好感知的对比学习策略，在跨行为与行为内两个层面构造正负样本对，以增强用户表示在多行为空间中的一致性，从而实现对用户真实偏好的精准建模与表达。

其次，考虑到多模态信息在刻画用户偏好与物品语义中的关键作用，本文进一步提出了**噪声感知与偏好提取的多模态多行为推荐方法**。该方法利用大语言模型在知识理解与语义推理方面的优势，通过生成用户与物品的模态描述文本，实现跨模态特征的语义对齐与表达扩展。在多模态场景下，噪声不仅体现在行为层面，还表现为行为信号与物品语义之间的不一致性。例如，用户可能由于标题党或视觉吸引等因素产生点击行为，但对应内容在语义层面并不符合其长期兴趣偏好，这类“语义不一致交互”为多模态推荐引入了额外的噪声来源。针对该问题，本

文在模型层面引入两种互补的去噪机制：在硬去噪阶段，基于模态相似度计算直接删除显著偏离真实语义的交互；在软去噪阶段，则在图神经网络的消息传播过程中引入模态引导的注意力机制，动态抑制语义噪声的传播。为进一步提升语义一致性，本文利用模态生成的嵌入构造正负样本对，开展模态对比学习，从特征层面强化用户与物品之间的语义匹配关系，实现语义驱动的去噪与偏好增强。

综上所述，本文从“协同信号建模”与“语义建模”两个层面出发，构建了一个层次化的多行为去噪推荐体系。前者通过行为强度建模与对比学习实现结构级噪声抑制，后者依托大语言模型实现模态语义层面的噪声识别与语义补全。两者相辅相成，不仅有效提升了推荐系统的鲁棒性与泛化能力，也为多行为、多模态场景下的去噪推荐提供了新的研究视角与方法支撑。

1.4.2 噪声建模与去噪问题的统一视角

在推荐系统，尤其是多行为推荐场景中，用户—物品交互数据并不完全等价于用户的真实偏好表达。受用户误操作、系统引导策略、曝光机制以及行为语义差异等因素影响，原始交互数据中普遍存在不同形式的噪声。这类噪声并非随机扰动，而往往表现为与目标偏好不一致或弱相关的交互行为，若直接用于模型训练，可能导致偏好建模失真甚至性能退化。

从问题本质上看，噪声并不局限于图神经网络建模场景。在矩阵分解、序列建模、表示学习等非图方法中，同样隐含着对“交互可靠性”的假设，即默认所有观测行为均可作为等价监督信号。然而在真实数据中，这一假设往往难以成立。因此，去噪并非图模型特有的问题，而是推荐系统中具有普适意义的数据质量建模问题。已有研究从交互重加权、样本筛选、置信度建模等角度对噪声进行缓解，其核心思想在于区分“高可信交互”与“潜在噪声交互”，这一思路同样可被借鉴至图结构或多行为建模中。

需要指出的是，去噪与去偏在目标和侧重点上存在差异。去偏通常关注由曝光、采样或系统策略引入的分布层面偏差，而本文所讨论的去噪更侧重于单条交互层面的语义一致性与有效性问题，即某一行为是否真实反映了用户对目标物品的偏好。因此，本文的研究重点并非修正整体数据分布，而是识别并削弱与目标偏好不一致的噪声交互对模型学习过程的干扰。

基于上述统一视角，本文从不同层面探讨多行为推荐中的噪声问题，并提出两种互补的解决思路。第三章与第四章分别从不同建模角度出发，对噪声进行刻画与缓解，旨在系统性地验证：通过显式建模交互可靠性与一致性，可以有效提升多行为推荐模型的偏好建模能力与泛化性能。

1.4.3 论文组织结构

本论文的整体结构安排如下：

第一章为绪论。首先介绍多行为推荐系统的研究背景与现实意义，阐述推荐系统在多样化用户交互场景下所面临的核心问题，如噪声交互、数据稀疏及模态差异等。随后，对国内外在多行为推荐、去噪推荐、多模态推荐以及大语言模型辅助推荐等领域的研究现状进行系统梳理，分析现有方法的优势与不足，并明确本文的研究目标与创新点。最后，对论文的总体结构进行概述，为后续章节的展开奠定理论与逻辑基础。

第二章为相关技术概述。主要介绍支撑本文研究的基础理论与关键技术，包括图神经网络在推荐系统中的建模原理、消息传递机制及其在多行为场景下的应用。同时，对多行为推荐的基本框架与噪声建模思路进行阐述，并简要介绍大语言模型在语义理解与知识生成方面的核心机制，为后续模型设计及语义引导去噪方法提供必要的技术支撑。

第三章提出噪声感知与偏好提取的多行为推荐方法。针对辅助行为中普遍存在的噪声问题，构建了跨行为与行为内加权去噪模块，通过因果推断建模行为强度与相似交互关系，从多层次识别并过滤异常交互。同时，引入偏好感知的跨行为与行为内对比学习机制，以多视角强化用户与物品的嵌入一致性与语义表达能力，从而有效缓解噪声干扰与数据稀疏问题，提升推荐结果的准确性与稳定性。

第四章提出噪声感知与偏好提取的多模态多行为推荐方法。该方法充分利用 LLM 的语义理解与逻辑推理能力，为用户与物品生成文本化的模态描述，实现跨模态语义空间的对齐。在此基础上，通过模态相似度计算实现硬去噪，并在图神经网络中引入注意力机制以实现软去噪，从而削弱模态噪声并保留关键偏好特征。进一步地，结合模态对比学习策略，增强不同模态间的语义一致性与特征互补性，实现高质量特征融合与鲁棒推荐效果。

1.4.4 论文整体研究框架

本研究针对多行为推荐系统在多样化用户交互场景中普遍面临的噪声干扰、数据稀疏及模态差异等问题，构建了以图神经网络为核心的多层次去噪与语义增强推荐框架。研究主要聚焦以下三个核心问题：首先，针对多行为数据中存在的大量噪声交互，提出跨行为与行为内加权去噪算法，通过因果推断估计行为强度，结合用户间相似性建模生成加权交互图，以有效区分真实偏好与噪声交互，从而提升推荐的准确性与稳定性；其次，为解决辅助行为与目标行为之间的偏好差异问题，构建偏好感知的自监督对比学习机制，在行为内与行为间两个层面进行表

征增强，强化用户与物品嵌入的一致性；最后，引入大语言模型生成的语义特征，通过文本化模态描述与语义对齐机制，建模多模态信息间的关系。基于模态相似性实现硬去噪，并在图神经网络中通过注意力机制完成软去噪，进一步提升模型的鲁棒性与语义表达能力。论文通过理论创新与语义融合，形成从多行为噪声识别、偏好表征增强到多模态语义引导去噪的系统性研究框架，为多行为推荐系统中的噪声建模与语义增强提供了新的范式，并在多个公开数据集上验证了其有效性与可扩展性。

在本研究中，第三章提出的**噪声感知与偏好提取的多行为推荐方法**，以及第四章提出的**噪声感知与偏好提取的多模态多行为推荐方法**，从不同层面为多行为推荐系统中的噪声抑制与偏好建模提供了解决方案。

第三章聚焦于多行为数据的结构与信号建模，通过构建跨行为与行为内加权去噪模块，结合因果推断与自监督对比学习，识别辅助行为中的噪声并提取真实偏好信号，形成纯净且高质量的交互表示。第四章则在此基础上引入大语言模型，通过语义生成与关系推理，扩展推荐系统的模态维度。该方法利用 LLM 生成的语义描述实现跨模态特征对齐，并在图神经网络中融合模态注意力机制，实现多模态层面的硬、软联合去噪，从而进一步提升推荐的语义解释性与泛化能力。

需要指出的是，第四章的研究在方法设计上继承并扩展了第三章的成果。第三章为多行为去噪奠定了结构性与因果性基础，而第四章则在此框架上通过引入语言语义与多模态信息实现更高层次的语义增强。两章在研究目标上相互独立、在技术逻辑上相互衔接，分别从行为信号与语义特征两个维度推进多行为推荐的去噪与增强研究。

从推荐流程的视角来看，第三章与第四章可视为并行互补的两条路径：前者侧重于基于交互结构的信号净化与偏好提取，后者则着眼于语义层面的知识建模与特征融合。两者共同构成完整的多行为去噪与语义引导推荐框架，为实现高精度、高鲁棒性的推荐提供了系统性解决思路与技术支撑。

第 2 章 图神经网络与对比学习相关理论概述

2.1 引言

随着互联网平台的快速发展，用户与内容之间的交互数据呈指数级增长，如何在海量信息中为用户提供个性化推荐已成为智能信息系统的重要研究方向。传统的推荐算法（如协同过滤与矩阵分解）在建模用户—物品关系方面取得了良好效果，但由于忽略了交互数据的复杂结构与高阶关联，其表达能力和泛化性能仍存在不足。近年来，图神经网络凭借其在非欧几里得结构化数据上的建模优势[2]，被广泛引入推荐系统中，用于捕获用户与物品之间的高阶连接与潜在语义关系，从而显著提升了推荐的准确性与表示能力。

然而，仅依靠监督信号进行训练的推荐模型在实际应用中仍面临诸多挑战。首先，用户行为数据往往存在噪声、稀疏和偏置等问题[37,38]，导致模型学习到的用户表示与真实偏好存在偏差。其次，推荐系统中的多行为交互和多模态内容信息进一步增加了建模难度，使得模型难以充分利用潜在的结构信号与语义信息。为此，对比学习（Contrastive Learning, CL）被引入推荐系统，作为一种自监督学习范式，通过构造正负样本对在无标签条件下优化表示分布，从而提升模型在噪声环境下的鲁棒性与泛化能力。

综上所述，图神经网络与对比学习的结合为推荐系统的研究提供了新的发展方向：前者关注用户—物品关系的结构化建模，后者强调表示空间的一致性约束与自监督优化。二者相辅相成，不仅能够增强推荐模型的表示能力，还能有效缓解数据噪声与稀疏问题。本章将系统梳理与本研究密切相关的理论基础，包括图神经网络的核心原理及其在推荐系统中的典型应用，以及对比学习的基本思想与在推荐场景下的改进策略，为后续章节的模型设计与算法实现奠定理论支撑。

2.2 图神经网络相关原理及理论知识

2.2.1 图神经网络的基本流程

图神经网络是一类能够在图结构数据上直接进行学习的深度模型。其核心思想是通过消息传递（Message Passing）机制，使节点在嵌入空间中综合自身特征与邻居节点的信息，从而生成具有结构感知与关系表达能力的节点表示。

在一个典型的 GNN 层中，节点特征的更新通常包含两个阶段：

1. **消息传递**：每个节点从其邻居节点接收并聚合信息。对于节点 v，其邻居集合记为 $\mathcal{N}(v)$。在第 l 层中，消息传递过程可表示为：

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v)} M^{(l)} \left(\mathbf{h}_v^{(l-1)}, \mathbf{h}_u^{(l-1)}, \mathbf{e}_{uv} \right), \tag{2-1}$$

其中，$M^{(l)}(\cdot)$ 为消息函数，用于根据节点与边特征计算邻居信息的加权表示，并完成消息的聚合。

2. **节点更新**：节点结合自身上一层的表示与聚合后的消息向量，更新当前层的表示：

$$\mathbf{h}_v^{(l)} = U^{(l)} \left(\mathbf{h}_v^{(l-1)}, \mathbf{m}_v^{(l)} \right), \tag{2-2}$$

其中，$U^{(l)}(\cdot)$ 为更新函数，可采用非线性变换（如 MLP、GRU 或残差结构）以捕获复杂的邻域依赖关系。

通过堆叠多层消息传递与更新操作，GNN 能够逐步捕获高阶邻居的结构信息，实现节点间的深层语义关联建模。在此框架下，众多具有代表性的模型相继被提出，其中部分方法已被广泛应用于推荐系统场景。接下来，本文将介绍几种在推荐算法领域中具有代表性的图神经网络模型及其核心思想。

2.2.2 典型图神经网络模型

（1）图卷积网络

图卷积网络（Graph Convolutional Network, GCN）[39] 是最早提出的基于谱域卷积思想的图神经网络之一，其核心目标是将传统卷积神经网络（CNN）的局部特征提取能力扩展至非欧式的图结构数据中。GCN 的关键思想在于：每个节点不仅依赖自身特征进行表征学习，还通过邻接关系接收邻居节点的信息，实现跨节点的特征传播与全局平滑。其计算过程可归纳为典型的两步形式：**消息传递**与 **节点更新**。

- **消息传递**：节点通过邻接矩阵实现特征的聚合与传播。对于节点 v，其邻居集合为 $\mathcal{N}(v)$，消息传递过程可形式化为：

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v) \cup \{v\}} \frac{1}{\sqrt{d_u d_v}} \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)}, \tag{2-3}$$

其中，$\mathbf{W}^{(l)}$ 为第 l 层的可学习线性变换参数，d_u 与 d_v 分别为节点 u 与 v 的度。该式中的对称归一化因子 $\frac{1}{\sqrt{d_u d_v}}$ 可有效抑制高连接度节点在聚合过程中的主导效应，从而实现稳定的信息传播。

• **节点更新**：节点将聚合后的邻域信息 $\mathbf{m}_v^{(l)}$ 经过非线性变换，更新为新的特征表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\mathbf{m}_v^{(l)}\right), \tag{2-4}$$

其中 $\sigma(\cdot)$ 表示非线性激活函数（如 ReLU）。通过多层堆叠，GCN 能够递归地传播信息，使每个节点在高层表征中融入高阶邻居的结构语义特征。

在矩阵形式下，GCN 的整体更新规则可写为：

$$\mathbf{H}^{(l+1)} = \sigma\left(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}}\mathbf{H}^{(l)}\mathbf{W}^{(l)}\right), \tag{2-5}$$

其中，$\widetilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ 表示加入自连接的邻接矩阵，$\widetilde{\mathbf{D}}$ 为其对应的度矩阵。该更新过程等价于在图拉普拉斯谱域上进行卷积操作，因此 GCN 可视为对图信号进行低通滤波的平滑算子。GCN 以其参数高效、结构简洁的特点成为后续多种图神经网络（如 GraphSAGE、GAT、LightGCN 等）的理论基础。

（2）图采样聚合网络

GraphSAGE（Graph Sample and Aggregate）[40] 是一种支持大规模图上归纳式学习的图神经网络模型。与 GCN 依赖全图邻接矩阵计算不同，GraphSAGE 通过采样机制与可学习聚合函数实现了高效的局部邻域特征传播，能够在动态变化或未见过的新节点上进行推理。其核心流程可概括为两步：消息传递与节点更新。

• **消息传递**：对于每个节点 v，GraphSAGE 首先从其邻居集合 $\mathcal{N}(v)$ 中随机采样固定数量的邻居，以控制计算复杂度。然后，通过可学习的聚合函数（如均值聚合、LSTM 聚合或池化聚合）将邻居节点的特征表示汇总：

$$\mathbf{m}_v^{(l)} = \mathrm{AGGREGATE}\left(\{\mathbf{h}_u^{(l-1)} \mid u \in \mathrm{Sample}(\mathcal{N}(v))\}\right), \tag{2-6}$$

其中，Sample$(\cdot)$ 表示随机采样操作。该聚合机制使得模型能够在保持表达能力的同时显著降低计算与存储开销，从而适应大规模工业级图数据。

• **节点更新**：节点将自身特征与聚合后的邻居信息进行拼接，通过线性变换与非线性激活生成新的节点表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\mathbf{W}^{(l)} \cdot \mathrm{CONCAT}\left(\mathbf{h}_v^{(l-1)}, \mathbf{m}_v^{(l)}\right)\right), \tag{2-7}$$

其中，$\mathbf{W}^{(l)}$ 为可学习参数矩阵，$\sigma(\cdot)$ 为激活函数。这种更新方式既保留了节点自身的语义信息，又融合了邻域特征，使得 GraphSAGE 在异质节点和稀疏场景中具备更强的泛化能力。

通过分层采样与聚合，GraphSAGE 支持在训练阶段仅访问部分图结构，并在推理阶段对新增节点进行嵌入生成（inductive inference），因而广泛应用于推荐系统、社交网络与知识图谱等大规模动态图场景。

（3）图注意力网络

图注意力网络（Graph Attention Network, GAT）[41] 在消息传递框架中引入了注意力机制，以自适应地分配邻居节点的重要性权重，从而克服了传统 GCN 中均匀聚合的局限性。GAT 不再依赖预定义的归一化矩阵，而是通过可学习的注意力参数在局部邻域内动态调整信息流强度。其核心流程同样可分为两步：**消息传递**与**节点更新**。

- **消息传递**：对于每个节点 v，首先通过线性变换矩阵 $\mathbf{W}$ 将节点特征映射到新的表示空间：

$$\mathbf{h}'_v = \mathbf{W}\mathbf{h}_v. \tag{2-8}$$

然后，通过注意力机制计算节点 v 与邻居节点 $u \in \mathcal{N}(v)$ 之间的关联强度：

$$e_{uv} = \mathrm{LeakyReLU}\left(\mathbf{a}^\top [\mathbf{h}'_u \| \mathbf{h}'_v]\right), \tag{2-9}$$

并使用 softmax 函数对所有邻居的注意力得分进行归一化：

$$\alpha_{uv} = \frac{\exp(e_{uv})}{\sum_{k \in \mathcal{N}(v)} \exp(e_{kv})}, \tag{2-10}$$

其中，$\mathbf{a}$ 为可学习的注意力向量，$\|$ 表示向量拼接操作。该机制允许节点对语义上更相关的邻居分配更高权重，从而提升消息传播的针对性。

- **节点更新**：节点基于注意力权重对邻居特征进行加权聚合，形成更新后的表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\sum_{u \in \mathcal{N}(v)} \alpha_{uv} \mathbf{h}'_u\right), \tag{2-11}$$

其中，$\sigma(\cdot)$ 表示非线性激活函数。为了增强模型的表达能力，GAT 通常采用多头注意力机制（Multi-Head Attention），即并行计算多个注意力通道并对其结果进行拼接或平均，从而捕获不同语义视角下的邻域特征相关性。

通过注意力机制的引入，GAT 实现了节点间关系的自适应建模，不再依赖图结构的固定拓扑权重，在异质图、社交网络及多模态推荐任务中展现出优越的特征选择与语义过滤能力。

（4）LightGCN 模型

LightGCN（Light Graph Convolution Network）[5] 是一种专为推荐系统设计的轻量级图神经网络模型，其核心思想是对传统 GCN 结构进行简化，仅保留最关键的

邻居特征聚合过程，去除了非线性激活与特征变换等操作，从而在保持模型表达能力的同时显著提升训练与推理效率。其整体流程可分为两个阶段：消息传递与节点更新。

• **消息传递**：LightGCN 不再引入额外的线性变换矩阵或激活函数，而是直接基于对称归一化的邻接矩阵传播节点特征。对于第 l 层传播，节点特征的更新公式为：

$$\mathbf{E}^{(l+1)} = \mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}}\mathbf{E}^{(l)}, \tag{2-12}$$

其中，$\mathbf{A}$ 为用户-物品二部图的邻接矩阵，$\mathbf{D}$ 为其度矩阵。该归一化传播机制确保了不同度节点之间的平衡，使得每个节点能够稳定地吸收邻居的嵌入信息，从而实现高效的信息扩散与结构平滑。

• **节点更新**：为充分利用多层传播过程中不同阶邻居所包含的协同信息，LightGCN 将所有层的节点表示进行加权融合，形成最终的节点嵌入：

$$\mathbf{e}_u = \sum_{l=0}^{L} \alpha_l \mathbf{e}_u^{(l)}, \quad \mathbf{e}_i = \sum_{l=0}^{L} \alpha_l \mathbf{e}_i^{(l)}, \tag{2-13}$$

其中，α_l 为第 l 层的权重系数，通常设为均值或按经验衰减分配。这种跨层融合方式有效整合了不同阶邻居的结构特征，使模型在保持轻量化的同时依然具备捕获高阶协同信号的能力。

通过去除非必要的非线性变换与参数矩阵，LightGCN 显著减少了计算与存储开销，同时在多行为推荐、社交推荐等任务中仍能保持强大的表示能力，因此成为近年来推荐系统研究中的核心基线模型。

2.3 对比学习相关原理及理论知识

对比学习（Contrastive Learning）是一种基于相似性约束的自监督表示学习方法，其核心思想是通过构建正负样本对（Positive/Negative Pairs）来学习高质量的特征表示，使语义相似的样本在嵌入空间中靠近，而语义无关的样本彼此远离。相比传统的监督学习依赖人工标签的方式，对比学习能够从无标注数据中挖掘潜在结构信息，显著提升模型的泛化能力和鲁棒性。

早期的对比学习思想可追溯至互信息最大化（Mutual Information Maximization）方法，其目标在于通过最大化不同视图之间的互信息来捕获共享语义特征。此类方法包括 Deep InfoMax[42] 和 CPC（Contrastive Predictive Coding）[43] 等。随着大规模无监督表示学习的发展，SimCLR[44]、MoCo[45] 和 BYOL[46] 等方法进一步推动了对比学习在计算机视觉和推荐系统中的广泛应用。

对比学习的一般流程可分为三个阶段：样本构建、相似度度量与目标优化。

1. **样本构建**：模型首先需要从原始样本中生成具有语义关联的多视图表示。对于给定样本 x，通过两种不同的数据增强或视角变换（如裁剪、遮挡、掩码或行为扰动）生成两个相关视图 (x_i, x_j)，称为正样本对。来自其他样本的数据 (x_i, x_k) 被视为负样本对。这种设计使得模型在无监督条件下能够自动学习到“语义一致性”，即同一实体的不同观测在嵌入空间中应保持接近。

2. **相似度度量**：为量化样本对在表示空间中的关系，常用的相似度度量为余弦相似度：

$$\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i^\top \mathbf{z}_j}{\|\mathbf{z}_i\| \, \|\mathbf{z}_j\|}, \tag{2-14}$$

其中，$\mathbf{z}_i$ 与 $\mathbf{z}_j$ 分别表示样本经过编码器 $f_\theta(\cdot)$ 后的特征表示。余弦相似度通过角度关系刻画样本间的相对语义距离，保证了尺度不变性和数值稳定性。

3. **目标优化**：对比学习的核心目标是最大化正样本对的相似度并最小化负样本对的相似度。最常用的优化目标是 InfoNCE 损失函数[43]：

$$\mathcal{L}_{\mathrm{InfoNCE}} = -\log \frac{\exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{N} \exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}, \tag{2-15}$$

其中，τ 为温度系数，用于调整相似度分布的平滑程度，N 表示候选样本数量。该损失通过软最大化机制强化正样本对的区分性，并在嵌入空间中形成自然的簇结构（Cluster Structure）。

从信息论角度来看，InfoNCE 可被视为互信息的下界估计，其优化过程等价于最大化样本视图间共享信息的期望。这种思想被称为互信息最大化原理（Mutual Information Maximization Principle），能够有效减少特征冗余并提升表达能力。此外，Wang 与 Isola[47] 提出了对比学习的两个关键理论目标：（1）**对齐性（Alignment）**——正样本对在嵌入空间中的距离应尽可能接近；（2）**均匀性（Uniformity）**——所有样本在单位超球面上应均匀分布，以避免塌陷（Collapse）问题。对比学习的目标可视为在这两种约束之间取得平衡，从而在保持判别性的同时维持表示多样性。

2.4 本章小结

本章主要介绍了图神经网络与对比学习的相关理论基础。在图神经网络部分，首先阐述了 GNN 的一般工作流程，包括消息构造与聚合机制，并重点介绍了若干具有代表性的模型（如 GCN、GraphSAGE、GAT 与 LightGCN），以说明不同结构在特征传播与表示学习上的差异与优势。在对比学习部分，本章系统总结了其核心思想、基本流程与典型优化目标（如 InfoNCE 损失），并分析了其在特征对齐与表示均匀性方面的理论依据。

第 3 章 噪声感知与偏好提取的多行为推荐方法

3.1 引言

随着互联网平台中用户行为的多样化，**多行为推荐系统**逐渐成为解决推荐系统中**数据稀疏**和**冷启动**问题的有效工具。传统推荐算法通常依赖单一类型的用户行为（如购买行为）来推测用户偏好，在数据稀疏或冷启动场景下会面临显著挑战。为解决这些问题，多行为推荐系统通过引入辅助行为（例如点击、浏览、收藏等）增强对用户兴趣的理解，从而提高推荐精度。然而，辅助行为往往含有大量噪声信息，例如误点击、无意浏览或无效收藏，这些噪声交互可能干扰对用户真实偏好的识别。

尽管近年来针对多行为推荐的研究不断深入，已有方法主要集中在**行为信息融合**和**行为关系建模**上，但大多数忽视了辅助行为中的噪声问题。现有方法通常假设所有辅助行为均为有效信息，未能有效区分低质量的噪声行为与真实兴趣。此外，传统去噪方法多集中在单一行为场景，忽略了多行为场景下**行为间的关联性**以及如何利用高质量辅助行为增强目标行为的表达能力。

针对上述问题，本章主要研究以下关键问题：如何在多行为推荐系统中识别并抑制辅助行为中的噪声? 如何利用辅助行为中的有效信息增强目标行为的表示能力，从而提升推荐的准确性与鲁棒性? 为了回答这些问题，本章提出了一种系统化的多行为去噪方法，并在后续小节中详细介绍其模型设计、去噪机制以及行为间信息融合策略。

3.2 问题定义及方法概述

3.2.1 问题定义

在本研究中，定义用户集合为 $U = \{u_1, u_2, ..., u_{|U|}\}$，物品集合为 $I = \{i_1, i_2, ..., i_{|I|}\}$，其中 $|U|$ 和 $|I|$ 分别表示用户和物品的数量。符号 B 表示行为类型的集合。

首先，将用户-物品交互数据表示为**交互矩阵集合** $R = \{R_1, R_2, ..., R_K\}$，其中 $R_k \in \mathbb{R}^{|U|\times|I|}$ 表示第 k 种行为下的用户-物品交互矩阵。若 $R^k_{ui} = 1$，则表示用户 u 在行为 k 下与物品 i 发生过交互；若 $R^k_{ui} = 0$，则表示未发生交互。在数据集中，将购买行为设定为**目标行为**，其他行为（如浏览、加购、收藏等）设定为**辅助行为**。

在此基础上，可将每种行为的交互矩阵映射为对应的行为子图 $G^R_k =$

$(V, E_k^R), k = 1, 2, ..., K$，其中 $V = U \cup I$ 表示图中所有用户与物品节点的集合，边集 E_k^R 表示第 k 种行为下观测到的交互关系。若 $R_{ui}^k = 1$，则在 G_k^R 中存在一条连接用户 u 与物品 i 的边；若 $R_{ui}^k = 0$，则不存在该边。由此可构建整体交互图 $G^R = (V, E^R)$，其中 $E^R = \bigcup_{k=1}^K E_k^R$，用于描述多行为交互场景下的完整用户-物品关系。

为了进一步挖掘用户与物品之间潜在的相似偏好信息，构建了**用户同构图** G^U 和**物品同构图** G^I，以捕捉用户-用户及物品-物品之间的共享交互关系。具体地，遍历各行为下的用户-物品交互记录；若一对用户 (u, v) 或一对物品 (i, j) 在目标行为（购买行为）下存在共同交互，则在图 G^U 中连接 u 与 v，并在图 G^I 中连接 i 与 j。

多行为推荐任务的形式化定义如下：

- **输入**：用户在 K 种行为下的交互图集合 $\{G_1^R, G_2^R, ..., G_K^R\}$；
- **输出**：一个推荐模型，用于预测用户 u 在第 K 种行为（目标行为）下与物品 i 发生交互的概率。

3.2.2 算法概述

为有效解决多行为推荐算法中的噪声干扰问题，本文提出了**噪声感知与偏好提取的多行为推荐方法**（NIPER: Noise Identification and Preference Extraction in Multi-Behavior Recommender System）。图 3-1 展示了 NIPER 的整体结构，该模型主要由两个关键模块组成：**(i) 行为间与行为内加权去噪模块（Inter- and Intra-Behavior Weighted Denoising Module）**与 **(ii) 偏好感知的表征增强模块（Preference-informed Representation Enhancement Module）**。

行为间与行为内加权去噪模块旨在识别并减轻辅助行为中的噪声交互，通过跨行为与行为内加权机制提升多行为信号的可靠性。该模块包含三个子模块：**基于行为强度的行为间加权模块**、**基于共同交互的行为内加权模块**以及**去噪模块**。其中，基于行为强度的行为间加权模块用于刻画不同行为类型在用户偏好表达中的固有强度差异。例如，在电商场景中，购买行为通常较加购行为更能体现真实兴趣，而加购行为的偏好强度又高于单纯的浏览行为。基于共同交互的行为内加权模块则用于建模具有相似兴趣的用户之间的交互影响。若多个用户在某些物品上表现出一致的交互行为，则这些行为更可能反映其真实偏好，从而获得更高的权重。通过上述两类加权机制的协同作用，可构建出带有权重的多行为交互图。随后，去噪模块根据权重分布剔除低置信度的辅助行为交互，从而生成经过降噪处理且保留关键信息的高质量多行为图，有效减弱噪声对推荐结果的负面影响。

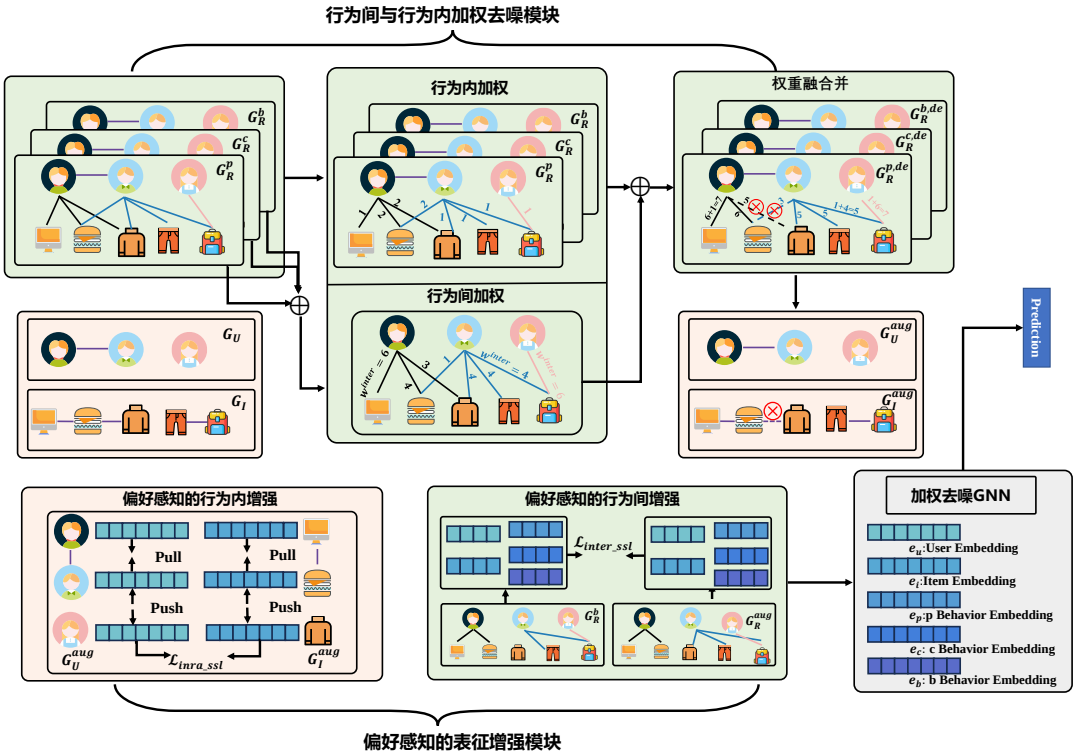

图 3-1: NIPER 整体框架示意图如图所示：图的上半部分为行为间与行为内加权去噪模块，该模块用于识别辅助行为中的噪声交互，并进行有效过滤；图的下半部分为偏好感知表征增强模块，通过构造正负样本，强化真实偏好信息在用户与物品嵌入中的传递，从而提升偏好表示的准确性和鲁棒性。

偏好感知的表征增强模块旨在从辅助行为中提取高置信度的真实偏好，以缓解目标行为数据的稀疏性。该模块包括两部分：**偏好感知的行为间对比学习**与**偏好感知的行为内对比学习**。前者利用在去噪阶段保留的高权重辅助交互，对目标行为交互图进行增强与补充。通过对比增强前后目标行为的嵌入表示，挖掘用户在多行为数据中的潜在偏好，从而提升整体推荐性能。后者依据用户与用户、物品与物品之间的相似交互偏好，对其嵌入进行区分与优化，强化具有相似兴趣实体间的表示一致性，进一步提升模型的表达能力与泛化性。

3.2.2.1 复杂度分析

本章所提出的噪声感知与偏好提取的多行为推荐方法主要针对用户—物品多行为交互图进行加权计算与噪声识别。跨行为加权阶段，对每个用户的各类行为计算对目标行为的影响强度，时间复杂度为 $O(|E|)$，其中 $|E|$ 为多行为图中的交互边数。行为内加权阶段基于相似用户的局部一致性计算权重，复杂度为 $O(|U|\cdot k\cdot d)$，其中 $|U|$ 为用户数量，k 为邻居数量，d 为嵌入维度。权重引导的去噪操作可在

$O(|E|)$ 时间内完成。空间复杂度主要由用户与物品嵌入以及加权图存储构成，总体为 $O((|U|+|I|)\cdot d+|E|)$，其中 $|I|$ 为物品数量。整体复杂度随用户数、物品数及交互边数线性增长，适合大规模稀疏交互数据处理。

3.3 行为间与行为内加权去噪模块

在多行为推荐系统中，传统方法通常将用户行为划分为辅助行为与目标行为[8,9,19,20,23,37]。然而，这种二元划分忽略了不同辅助行为在表达用户兴趣偏好方面的重要性差异。例如，加入购物车行为相较于浏览页面更能反映用户的潜在购买意图。若不加区分地处理所有辅助行为，可能导致关键行为信号被削弱，从而降低推荐精度。

为定量刻画不同行为类型在购买转化中的作用，本文将点击与加购行为的影响建模为一个因果推断问题[48]，并采用潜在结果框架进行建模。对于每个用户 i，设 $T\in\{1,2\}$ 表示行为类型，其中 $T=1$ 表示点击行为，$T=2$ 表示加购行为；$Y\in\{0,1\}$ 表示用户是否完成购买；X 表示用户的行为特征，包括点击次数、加购次数及总交互次数。

个体化处理效应（Individual Treatment Effect, ITE）定义为：

$$\tau_i=\mathbb{E}[Y_i(2)-Y_i(1)\mid X_i], \tag{3-1}$$

其中 $Y_i(t)$ 表示用户 i 在行为类型 $T=t$ 下的潜在购买结果。由于实际数据中每个样本仅能观测到一个处理结果，因此需通过因果推断方法进行估计。

本文采用因果森林模型[49] 对 τ_i 进行估计。该模型是一种基于随机森林的非参数方法，能够在高维协变量空间中捕捉异质性处理效应。训练完成后，模型根据用户特征 X_i 计算估计的处理效应：

$$\tau_i=\hat{\mathbb{E}}[Y_i\mid T=2,X_i]-\hat{\mathbb{E}}[Y_i\mid T=1,X_i]. \tag{3-2}$$

若 $\tau_i>0$，说明对用户 i 而言，加购行为相较点击行为更能促进购买转化；反之则表示点击行为更具影响力。该效应可用于刻画不同行为的相对重要性。

在本研究中，估计得到的 τ_i 用于计算不同行为的个体化权重，从而区分不同辅助行为对用户的实际影响。对于用户 i 的某类辅助行为 T，若 $\tau_i>0$，则说明该行为相较其他行为更能促进购买转化，对应的行为权重将被赋予较高值；反之则赋予较低权重。通过这种方式，模型能够根据每个用户的特征自适应地调整辅助行为的贡献，刻画行为间的重要性差异，从而更精准地反映用户真实偏好。这一策略在本质上类似于以用户为中心的个体化加权机制，但不同于传统图结构调整方法，本方法侧重于行为权重而非直接改变邻接关系。

为进一步量化各行为的强度，本文依据用户级处理效应 τ_i 构建行为权重。将其映射为点击与加购行为的响应权重如下：

$$w_{\text{cart},i} = \frac{\exp(\tau_i)}{\exp(\tau_i) + 1}, \tag{3-3}$$

相应地，点击行为的权重被定义为加购权重的补集，从而将两种行为视为互斥且完备的概率事件。

$$w_{\text{click},i} = 1 - w_{\text{cart},i}, \tag{3-4}$$

上述形式保证了权重的平滑性与归一性，能够有效反映用户在两种行为间的相对偏好强度。

基于用户级权重，定义加购行为的全局强度指标为：

$$\rho^{\text{cart}} = \frac{1}{N}\sum_{i=1}^{N} w_{\text{cart},i}, \tag{3-5}$$

相应地，点击行为的全局强度可表示为 $\rho^{\text{click}} = 1 - \rho^{\text{cart}}$。上述强度值用于衡量不同行为在全局范围内对购买转化的平均促进作用。作为最终目标行为，购买行为直接反映用户的真实转化，因此其强度设为常数：

$$\rho^{\text{buy}} = 1. \tag{3-6}$$

基于计算得到的各行为强度值，本文构建了全局加权的跨行为交互图 $\boldsymbol{G}_{inter}$，其邻接矩阵 $\boldsymbol{w}^{inter} \in \mathbb{R}^{|U|\times|I|}$ 定义为：

$$w_{ui}^{inter} = \sum_{k=1}^{K} \rho^k \cdot R_{ui}^k. \tag{3-7}$$

该公式将多种行为的贡献进行加权融合，从而更全面地刻画用户的真实偏好与意图。如图 3-2 所示，若用户 u_1 在浏览、加购与购买三种行为中均与物品 i_1 发生交互，则其全局权重为：

$$w_{u_1 i_1}^{inter} = w^{pv} \times 1 + w^{cart} \times 1 + w^{buy} \times 1 = 6. \tag{3-8}$$

若用户 u_1 仅在浏览与购买行为中与物品 i_2 交互，则权重计算为：

$$w_{u_1 i_2}^{inter} = w^{pv} \times 1 + w^{cart} \times 0 + w^{buy} \times 1 = 4. \tag{3-9}$$

通过上述建模过程，跨行为加权机制能够有效捕捉不同行为类型对用户偏好的贡献，为后续去噪与特征学习奠定基础。

基于共现交互的行为内加权：除了考虑不同行为类型在偏好表达中的强度差

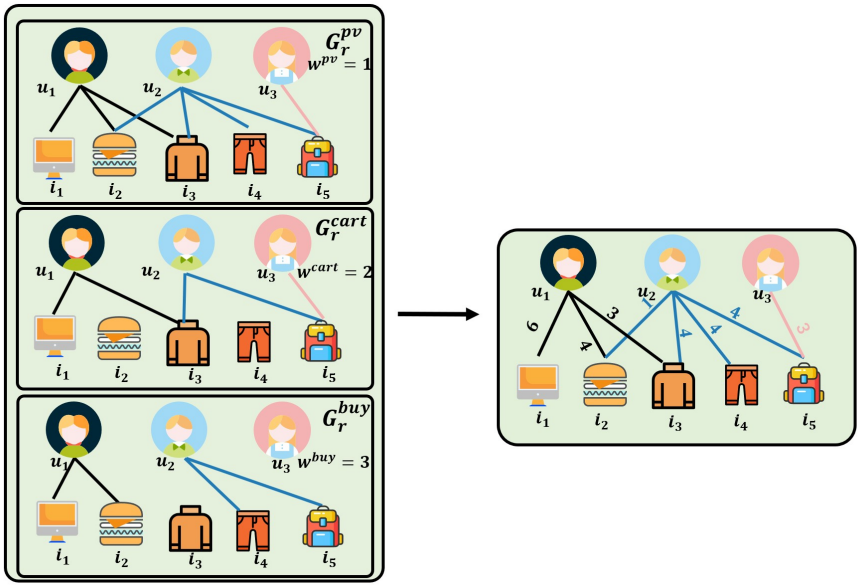

图 3-2: 一个生成带有权重的行为间全局交互图的例子

异外，用户在同一行为下的交互偏好同样蕴含着重要信息。这些偏好能够反映交互行为的相对重要性，并在相似用户之间体现出一定的一致性。基于此，本文引入**共现交互机制**，以量化具有相似兴趣的用户在同一行为下的共同交互强度。

具体而言，若相似用户在相同行为下频繁与同一物品交互，则该交互更可能代表真实偏好。为刻画这一关系，结合用户相似性交互图 $\boldsymbol{G}_U$ 与用户–物品交互图 $\boldsymbol{G}_R$，定义用户 u 在行为 k 下与物品 i 的行为内权重如下：

$$w_{ui}^{\text{intra},k} = \left(1 + \sum_{v \in V_u} R_{vi}^k\right) \cdot R_{ui}^k, \tag{3-10}$$

其中，V_u 表示与用户 u 相似的用户集合。该定义综合了用户相似性与共同交互频率，从而能够更全面地量化行为内交互的重要性。

为统一不同层次的权重信息，本文提出一种**行为内与行为间权重融合框架**。其中，行为内权重用于刻画单一行为下用户–物品交互的重要性，而跨行为权重用于建模不同行为类型间的关联性。两者的融合能够在全局层面上平衡行为差异与局部特征，从而更准确地反映用户的真实偏好。

在融合过程中，为避免权重尺度差异导致偏移，首先采用最小–最大归一化对行为内权重进行标准化。最终得到的融合权重矩阵 $\boldsymbol{w}^{com,k} \in \mathbb{R}^{|\mathcal{U}|\times|\mathcal{I}|}$ 定义如下：

$$w_{ui}^{com,k} = \alpha w_{ui}^{\text{intra},k} + (1-\alpha) w_{ui}^{\text{inter}}, \tag{3-11}$$

其中，k 表示行为类型，α 为平衡系数，用于控制行为内权重与跨行为权重的贡献比例。

权重引导的去噪模块：该模块旨在进一步去除辅助行为中噪声交互的影响。具体而言，仅对辅助行为中权重较低的交互进行过滤，而目标行为保持不变。设每个辅助行为的融合权重为 $w_{ui}^{\mathrm{com},k}$，并根据超参数 β_{low} 及行为强度 ρ^k 自适应确定去噪阈值，则去噪后的交互矩阵定义为：

$$R_{ui}^{\mathrm{de},k} = w_{ui}^{\mathrm{com},k} \cdot \mathbb{I}\left(\frac{w_{ui}^{\mathrm{com},k}}{\max(\mathbf{w}^{\mathrm{com},\mathbf{k}})} < \frac{\beta_{\mathrm{low}}}{\rho^k}\right), \tag{3-12}$$

其中，$\mathbb{I}(\cdot)$ 表示指示函数。该机制确保仅去除低权重的辅助行为交互，而目标行为矩阵 $\boldsymbol{R}^{de,K}$ 保持不变，直接令 $\boldsymbol{R}^{de,K} = \boldsymbol{w}^{com,K}$。最终，对于每个辅助行为 k，去噪后的矩阵 $\boldsymbol{R}^{de,k}$ 保留了高置信度的交互信息，并作为相应去噪多行为图的邻接矩阵。该过程使得用户-物品交互关系能够被更准确、鲁棒地建模。

在得到多行为去噪加权交互矩阵 $\boldsymbol{R}^{de,k}$ 后，采用带有消息传递机制的图神经网络（GNN）对用户和物品进行表示学习。具体而言，本文以 GHCF（Graph-based Hybrid Collaborative Filtering）[8] 作为主干网络。GHCF 是一种针对多行为推荐任务设计的图神经网络结构，能够联合嵌入图中节点（用户与物品）及多种行为关系的表示，并显式捕获跨行为的高阶协同信号。

与原始 GHCF 在节点表示学习中对同一行为下的邻居进行等权聚合不同，本文在消息传播过程中引入了基于去噪权重的加权机制，使模型能够根据交互置信度动态调整邻居节点的重要性。其消息传播公式定义如下：

$$\mathbf{e}_{u,k}^{(l+1)} = \mathrm{LeakyReLU}\left(\mathbf{W}^{(l)} \cdot \mathrm{mean}\left\{\mathbf{e}_{i,k}^{(l)} \odot \mathbf{e}_k^{(l)} : i \in N_{u,k}\right\}\right), \tag{3-13}$$

其中，$\mathbf{e}_{u,k}^{(l+1)}$ 表示在第 $(l+1)$ 层传播后，用户 u 在行为类型 k 下的嵌入表示；$N_{u,k}$ 为用户 u 在行为 k 下的邻居物品集合；$\mathbf{W}^{(l)}$ 为第 l 层的特征变换矩阵；$\odot$ 表示逐元素乘积操作；$\mathbf{e}_k^{(l)}$ 为第 l 层行为类型 k 的全局嵌入向量，用于调节不同行为语义间的表示差异。

行为类型嵌入 $\mathbf{e}_k^{(l)}$ 在各层间通过以下线性变换进行更新：

$$\mathbf{e}_k^{(l+1)} = \mathbf{W}_b^{(l)} \mathbf{e}_k^{(l)}, \tag{3-14}$$

其中，$\mathbf{W}_b^{(l)}$ 为层特定的行为类型转换矩阵，用于捕获多行为之间的语义迁移关系。

经过多层消息传播后，模型最终得到用户嵌入 $\mathbf{E_u}$、物品嵌入 $\mathbf{E_i}$ 以及行为类型嵌入 $\mathbf{E_k}$（其中 $k \in \mathcal{B}$），为后续的偏好建模与预测提供高质量的表示基础。

3.4 偏好感知的表征增强模块

偏好感知的行为间对比学习：为缓解目标行为中的数据稀疏问题，本文利用

辅助行为中高权重的交互信息对目标行为进行增强，从而构建更具代表性的交互视图。该方法通过将辅助行为中反映用户真实偏好的交互迁移至目标行为的表示空间，有效提升了目标行为的表达能力与鲁棒性。

具体而言，首先将所有辅助行为的去噪加权交互矩阵进行融合，定义如下：

$$\boldsymbol{R}^{all} = \sum_{k=1}^{K-1} \boldsymbol{R}^{de,k}, \tag{3-15}$$

其中，$\boldsymbol{R}^{all}$ 表示合并后的多行为交互矩阵。为控制注入目标行为的辅助数据规模，引入阈值超参数 β_{high}，从辅助行为中筛选出高置信度的交互样本，得到高权重交互矩阵：

$$R_{ui}^{\text{high}} = R_{ui}^{\text{all}} \cdot \mathbb{I}\left(\frac{R_{ui}^{\text{all}}}{\max(\mathbf{R}^{\text{all}})} \geq 1 - \beta_{\text{high}}\right), \tag{3-16}$$

其中，$\mathbb{I}(\cdot)$ 为指示函数。将高权重矩阵 $\boldsymbol{R}^{high}$ 与目标行为的去噪矩阵 $\boldsymbol{R}^{de,K}$ 合并后，得到增强后的目标行为视图：

$$\boldsymbol{R}^{aug} = \boldsymbol{R}^{high} + \boldsymbol{R}^{de,K}. \tag{3-17}$$

该矩阵 $\boldsymbol{R}^{aug}$ 作为增强图 $\boldsymbol{G}_R^{aug}$ 的邻接矩阵，用于刻画用户与物品之间的强化交互关系。

上述过程生成了目标行为的两个视图：原始视图与增强视图。分别对两者进行编码后，得到节点表示 $\boldsymbol{e}_u^{\text{ori}}$ 与 $\boldsymbol{e}_u^{\text{aug}}$。节点级的正样本对定义为：

$$\left\{(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_u^{\text{aug}}) \mid u \in \mathcal{U}\right\},$$

而负样本对为：

$$\left\{(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_v^{\text{aug}}) \mid u, v \in \mathcal{U}, u \neq v\right\}.$$

在用户侧，优化目标采用 InfoNCE 损失定义如下：

$$\mathcal{L}_{\text{inter,user}} = -\sum_{u \in \mathcal{U}} \log\left(\frac{\exp\left(\phi(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_u^{\text{aug}})/\tau\right)}{\sum_{v \in \mathcal{U}} \exp\left(\phi(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_v^{\text{aug}})/\tau\right)}\right), \tag{3-18}$$

其中，τ 为温度系数，$\phi(\cdot)$ 表示内积运算。物品侧的损失函数可按相同方式计算，最终跨行为对比学习的总体损失为：

$$\mathcal{L}_{\text{inter}} = \mathcal{L}_{\text{inter,user}} + \mathcal{L}_{\text{inter,item}}. \tag{3-19}$$

偏好感知的行为内对比学习：在多行为推荐中，具有相似交互模式的用户往往在偏好特征上表现出一致性，因此其嵌入表示也应保持高度相似。为此，本文

引入了行为内对比学习机制，通过最大化相似用户嵌入之间的一致性，强化同偏好用户在表示空间中的聚合性，从而提升模型对用户真实偏好的刻画能力。

具体而言，基于增强后的交互矩阵 $\boldsymbol{R}^{aug}$，重新定义用户真实偏好相似性图 $\boldsymbol{G}_U^{aug}$ 与物品真实偏好相似性图 $\boldsymbol{G}_I^{aug}$。若用户 u 与 v（或物品 i 与 j）在 $\boldsymbol{R}^{aug}$ 中存在相同交互，则在用户图 $\boldsymbol{G}_U^{aug}$ 中建立 u 与 v 的连接，在物品图 $\boldsymbol{G}_I^{aug}$ 中建立 i 与 j 的连接。由此可以刻画用户（或物品）间的交互一致性关系。

基于上述图结构，将具有相似交互模式的用户视为正样本对 (u, u^+)，行为差异较大的用户视为负样本对 (u, u^-)。通过最大化正样本对之间的嵌入一致性并最小化负样本对之间的相似度，实现对用户嵌入空间的对比优化。设 $\boldsymbol{e}_u$ 表示用户 u 的嵌入向量，行为内对比学习的目标函数定义如下：

$$\mathcal{L}_{\text{intra,user}} = -\sum_{u \in \mathcal{U}} \log \left(\frac{\exp\left(\phi(\boldsymbol{e}_u, \boldsymbol{e}_{u^+})/\tau\right)}{\sum_{u^- \in \mathcal{U}} \exp\left(\phi(\boldsymbol{e}_u, \boldsymbol{e}_{u^-})/\tau\right)} \right), \tag{3-20}$$

其中，u^+ 表示与用户 u 在图 $\boldsymbol{G}_U^{aug}$ 中相连的节点，u^- 表示未与 u 相连的节点；τ 为温度超参数，$\phi(\cdot)$ 表示内积相似度函数。物品侧的损失函数定义方式与用户侧相同，行为内对比学习的总目标为：

$$\mathcal{L}_{\text{intra}} = \mathcal{L}_{\text{intra,user}} + \mathcal{L}_{\text{intra,item}}. \tag{3-21}$$

3.5 模型训练

为实现稳定高效的模型训练，本文采用一种非采样推荐目标函数[50]，其在准确性与效率上均优于传统的贝叶斯个性化排序（Bayesian Personalized Ranking, BPR）损失。对于给定的用户批次 B 和物品集合 $\mathcal{I}$，在行为 k 下的非采样推荐损失定义为：

$$\mathcal{L}_{\text{rec}}^k = \sum_{u \in B} \sum_{i \in I_u^{k+}} \left[\left(c_i^{k+} - c_i^{k-}\right) \left(\hat{x}_{u,i}^k\right)^2 - 2c_i^{k+} \hat{x}_{u,i}^k \right], \tag{3-22}$$

其中，$\hat{x}_{u,i}^k$ 表示用户 u 在行为 k 下对物品 i 的预测交互概率；I_u^{k+} 表示用户 u 在行为 k 下已发生交互的物品集合；c_i^{k+} 和 c_i^{k-} 为超参数，用于控制正负样本权重。

整体推荐任务的优化目标为各行为损失的加权和，其中 λ_k 为各行为的平衡系数：

$$\mathcal{L}_{\text{rec}} = \sum_{k=1}^{K} \lambda_k \mathcal{L}_{\text{rec}}^k. \tag{3-23}$$

此外，本文在训练中引入自监督对比学习损失，以进一步提升嵌入表示的判别性与鲁棒性。最终的联合优化目标定义为：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \mu(\mathcal{L}_{\text{inter}} + \mathcal{L}_{\text{intra}}), \tag{3-24}$$

其中，μ 为控制自监督学习强度的超参数。

训练完成后，目标行为下用户 u 对未交互物品 v 的交互概率计算如下：

$$\hat{y}_{uv}^{(k)} = \boldsymbol{e}_u^\top \cdot \text{diag}(\boldsymbol{e}_K) \cdot \boldsymbol{e}_v, \tag{3-25}$$

其中，$\boldsymbol{e}_u$ 与 $\boldsymbol{e}_v$ 分别表示用户与物品的嵌入，K 表示目标行为类型，$\text{diag}(\boldsymbol{e}_K)$ 为由目标行为嵌入构成的对角矩阵。

3.6 实验与讨论

3.6.1 评价指标

为了全面评估各模型在 Top-K 推荐任务下的性能，本文选取了两个常用指标：召回率（Recall）和归一化折损累计增益（Normalized Discounted Cumulative Gain, NDCG）。对于测试集中的每个用户，模型首先对所有候选物品进行排序，并根据排序结果计算以下指标。

$$\text{Recall@K} = \frac{|R^K(u) \cap T(u)|}{|T(u)|}, \tag{3-26}$$

$$\text{NDCG@K} = \frac{1}{|U|} \sum_{u \in U} \frac{\sum_{k=1}^{K} \frac{\mathbb{I}\left(R_k^K(u) \in T(u)\right)}{\log_2(k+1)}}{\sum_{k=1}^{K} \frac{1}{\log_2(k+1)}}, \tag{3-27}$$

其中，$R^K(u)$ 表示模型为用户 u 推荐的 Top-K 个物品集合，$T(u)$ 表示测试集中用户 u 实际交互（或点击）的物品集合，$R_k^K(u)$ 表示推荐列表中第 k 个物品。$\mathbb{I}(\cdot)$ 为指示函数，当 $R_k^K(u) \in T(u)$ 时取 1，否则为 0。

Recall@K 反映模型能否成功推荐出用户真实感兴趣的物品，而 NDCG@K 则进一步关注这些物品在推荐列表中的排序位置。前者强调**推荐覆盖率**，后者衡量**推荐排序质量**。二者结合使用，可综合评估模型在多行为去噪推荐任务中的整体表现。

3.6.2 数据集信息

本研究选用了学术界广泛使用的三个多行为推荐数据集——Beibei、Taobao 和 Tmall，以评估所提出算法在不同场景下的有效性。这些数据集均包含用户与物品之间的多种交互行为（如浏览、收藏、加购与购买），能够充分反映用户在不同阶

表 3-1: 数据集的统计信息

数据集	#User	#Item	#View	#Cart	#Favorite	#Buy
Beibei	21,716	7,977	2,412,586	642,622	–	282,860
Taobao	48,749	39,493	1,548,162	193,747	–	211,022
Tmall	31,882	31,232	1,223,372	293,544	253,619	135,980

段的兴趣变化。所有数据集中均不包含显式反馈信息，仅记录用户的交互行为，因此非常适合用于基于隐式反馈的多行为去噪推荐研究。各数据集的详细统计信息见表 3-1。

3.6.3 实验设置

实验在 PyTorch 框架下实现，优化器采用 Adam，学习率设为 0.001，批量大小为 256，嵌入维度为 64。为防止模型过拟合，在训练过程中设置嵌入丢弃率（embedding dropout rate）为 0.3，边丢弃率（edge dropout rate）为 0.1。非采样损失（non-sampling loss）中的负样本权重在 $\{0.1, 0.01\}$ 中选择；对比学习的温度系数 τ 从 $\{0.2, 0.4\}$ 中选取。

3.6.4 总体实验效果

为验证所提出模型的有效性，本文选取了三类具有代表性的先进推荐模型作为对比基线。

首先，单行为推荐模型部分包含 NGCF[7] 与 LightGCN[5]，它们仅基于目标行为进行训练。为评估将多种行为简单融合为单一行为的影响，进一步构建了扩展版本 NGCF_{all} 与 $\text{LightGCN}_{\text{all}}$，其中所有行为均被统一视为购买行为并共同用于训练。

其次，本文引入具有去噪能力的推荐方法，以考察模型在噪声行为存在时的鲁棒性。单行为去噪模型采用 GraphDA[6]，而多行为场景下则选用 DPT[23] 与 DeMBR[28] 作为代表性方法，用于验证多源行为噪声处理机制的有效性。

最后，为全面比较多行为推荐技术的整体性能，本文选取了多种典型的多行为推荐模型，包括 S-MBRec[9]、GHCF[8]、MBSSL[37] 与 POGCN[22]。这些方法覆盖了跨行为关系建模、图结构学习以及多任务优化等不同技术路线，为本文提出模型的优势验证提供了多角度的参考。

表 3-2 展示了 NIPER 与各类基线模型的实验结果，其中最佳与次优结果分别以加粗和下划线标注。综合结果显示，NIPER 在所有数据集与评价指标上均表现出显著优势。

首先，NIPER 在 Recall 与 NDCG 等核心指标上均取得最优性能，其整体效果明显优于所有基线方法。其性能提升主要得益于两方面：一是跨行为与行为内的加权去噪机制能够有效识别并抑制辅助行为中的噪声干扰；二是偏好感知的表示增强模块提升了用户与物品嵌入的表达能力，使辅助行为中蕴含的真实偏好能够更准确地迁移至目标行为表示中。

其次，多行为建模在三种数据集上均明显优于单行为模型，表明显式建模行为之间的关联有助于更准确地刻画用户的潜在偏好。尽管将所有行为简单合并为单一行为（如 NGCF_{all} 与 $\text{LightGCN}_{\text{all}}$）能够带来一定收益，但这一策略忽略了行为差异性，因此整体效果仍显著落后于多行为推荐方法。

进一步观察各数据集的实验结果可发现，辅助行为通常包含有价值的偏好信息，但也可能带来噪声。在 Beibei 和 Taobao 数据集中，引入辅助行为能够显著提升性能，说明这些行为中蕴含的偏好信号对推荐是有益的。然而在 Tmall 数据集中，直接引入辅助行为反而导致性能下降，表明该数据集中的辅助行为噪声比例较高，未经处理的行为融合会放大噪声影响。

最后，与现有的去噪方法相比，NIPER 展现出更强的去噪能力。相较于 GraphDA（单行为去噪）与 DPT（独立行为去噪），NIPER 在建模行为间依赖关系的同时实现了多行为联合去噪，并结合自监督信号增强嵌入表示的鲁棒性，从而在多行为场景下取得更加优越的表现。

表 3-2: NIPER 在三个数据集上的实验结果 (Beibei, Taobao, Tmall)

Model	Beibei				Taobao				Tmall			
	R@5	R@10	N@5	N@10	R@5	R@10	N@5	N@10	R@5	R@10	N@5	N@10
NGCF[7]	0.0185	0.0348	0.0108	0.0161	0.0203	0.0291	0.0141	0.0169	0.0219	0.0329	0.0146	0.0182
NGCF_{all}[7]	0.0316	0.0487	0.0194	0.0261	0.0254	0.0348	0.0193	0.0205	0.0024	0.0053	0.0021	0.0029
LightGCN[5]	0.0230	0.0419	0.0141	0.0202	0.0300	0.0412	0.0211	0.0247	0.0363	0.0524	0.0251	0.0303
LightGCN_{all}[5]	0.0349	0.0583	0.0222	0.0297	0.0377	0.0433	0.0284	0.0284	0.0036	0.0060	0.0023	0.0030
GraphDA[6]	0.0384	0.0603	0.0253	0.0312	0.0318	0.0468	0.0214	0.0253	0.0153	0.0204	0.0098	0.0143
DPT[23]	0.1009	0.1621	0.0545	0.0793	0.0484	0.1025	0.0375	0.0571	0.0573	0.0934	0.0353	0.0448
S-MBRec[9]	0.0981	0.1697	0.0613	0.0872	0.0673	0.0814	0.0348	0.0446	0.0503	0.0639	0.0301	0.0397
GHCF[8]	0.1227	0.1897	0.0783	0.1000	0.0534	0.0807	0.0361	0.0449	0.0462	0.0763	0.0287	0.0384
MBSSL[37]	0.1034	0.1734	0.0652	0.0899	0.0688	0.1022	0.0465	0.0567	0.0507	0.0838	0.0313	0.0419
DeMBR[28]	0.1357	0.2028	0.0805	0.1207	0.0722	0.0987	0.0457	0.0593	0.0712	0.1123	0.0428	0.0597
POGCN[22]	0.0854	0.1548	0.0621	0.0801	0.0519	0.0841	0.0351	0.0423	0.0458	0.0741	0.0214	0.0386
NIPER	**0.1679**	**0.2394**	**0.1092**	**0.1322**	**0.0829**	**0.1103**	**0.0590**	**0.0678**	**0.0884**	**0.1216**	**0.0585**	**0.0693**

为确保实验结果的可靠性，本研究中的所有实验均重复执行 5 次，每次实验仅改变随机种子（seed），其余超参数和训练设置保持一致。对于每次实验，我们记录关键评价指标，并计算其均值与标准差。结果显示，不同随机种子对模型性能的波动较小，标准差约为指标均值的 1.3% 左右，表明方法具有较高的稳定性。

针对主要指标，本文采用 Wilcoxon 符号秩检验（Wilcoxon signed-rank test）进行显著性分析，以验证本文方法相较于基线方法的性能提升是否具有统计意义。实验结果显示，关键指标的 p 值远小于 0.05，表明性能提升具有统计显著性。通过重复实验、方差分析及显著性检验，本研究能够有效排除偶然因素的影响，为多行为推荐方法的性能评估提供可靠依据。

3.6.5 消融实验

为验证所提出模型中各个设计模块的有效性与必要性，本节进行了系统的消融实验。具体地，设计了以下六个模型变体：

1. **w/o Inter-Weighting**：移除跨行为加权机制，仅保留行为内权重进行去噪；
2. **w/o Causal Inference**：去除基于因果推断的行为强度估计，采用人工设定的固定值作为行为强度，其中 $\rho^{click} = 1$，$\rho^{cart} = \rho^{collect} = 2$，$\rho^{buy} = 3$；
3. **w/o Intra-Weighting**：移除行为内加权机制，仅依赖跨行为权重进行去噪；
4. **w/o Denoising**：完全取消去噪模块，直接利用原始多行为交互图进行建模；
5. **w/o $\mathbf{SSL_{inter}}$**：移除偏好增强模块中的跨行为自监督学习部分；
6. **w/o $\mathbf{SSL_{intra}}$**：移除偏好增强模块中的行为内自监督学习部分。

消融实验结果如表 3-3 所示。由于篇幅限制，本文重点报告 Beibei 与 Taobao 数据集上的 Recall@5 结果，其他数据集上亦观察到相似趋势。结果分析如下：

加权机制的重要性。跨行为与行为内加权机制的结合能够有效整合多视角信息，对不同交互的重要性进行精细区分。当任意一项加权机制被移除时（如 w/o Inter-Weighting 或 w/o Intra-Weighting），模型性能均出现明显下降，说明该双层加权策略对于识别噪声交互与保持有效信号均至关重要。

去噪模块的必要性。将完整模型与 w/o Denoising 变体对比可发现，去噪模块在显著提升模型精度方面发挥关键作用。如果直接使用未经筛选的原始交互，辅助行为中的噪声信号会误导用户偏好建模，导致推荐结果偏差。因此，去噪阶段对于提升推荐系统的鲁棒性和准确性具有重要意义。

自监督学习增强的有效性。移除自监督学习组件（w/o $\mathrm{SSL_{inter}}$ 或 w/o $\mathrm{SSL_{intra}}$）都会造成显著性能退化。这表明跨行为自监督学习（inter-SSL）通过高权重辅助行为增强目标行为表示，而行为内自监督学习（intra-SSL）强化了相似用户与物品之间的嵌入一致性。二者协同作用显著提升了模型的表征能力与泛化性能。

3.6.6 参数实验

为探究模型关键超参数对整体性能的影响，本文从噪声移除比例 β_{low}、目标行

表 3-3: 消融实验结果

DataSet	Beibei		Taobao		Tmall	
Metric	Recall@5	NDCG@5	Recall@5	NDCG@5	Recall@5	NDCG@5
w/o Inter-Weighting	0.1243	0.0783	0.0704	0.0487	0.0611	0.0397
w/o Casual Inference	0.1325	0.0.0835	0.0806	0.0524	0.0691	0.0429
w/o Intra-Weighting	0.1232	0.0746	0.0720	0.0472	0.0601	0.0383
w/o Denoising	0.1198	0.0758	0.0603	0.0406	0.0493	0.0318
w/o SSL_{inter}	0.1154	0.0775	0.0618	0.0454	0.0576	0.0381
w/o SSL_{intra}	0.1163	0.0769	0.0605	0.0438	0.0549	0.0375
NIPER	**0.1632**	**0.1053**	**0.0812**	**0.0576**	**0.0884**	**0.0585**

为增强比例 β_{high} 以及行为权重平衡系数 α 三个方面进行了系统实验分析。图 3-3 展示了各参数变化对模型性能的影响趋势与差异。

去噪比例 β_{low} 的影响。如图 3-3(a) 所示，不同数据集在最优去噪比例上的差异反映了其噪声水平的不同。随着去噪比例的提高，模型性能呈现“先升后降”的趋势。这一现象可归因于以下两点：（i）在较低去噪比例下，适度去除噪声交互有助于减少无关信息干扰；（ii）当比例过高时，部分有效交互被误删，导致模型无法充分学习用户真实偏好，从而造成性能下降。

辅助行为增强比例 β_{high} 的影响。增强比例 β_{high} 控制辅助行为对目标行为的补充程度。如图 3-3(b) 所示，随着 β_{high} 的增大，模型性能初期逐步提升，但在超过最优值后出现下降。适量引入辅助行为能够有效传递真实偏好信息，而过高的增强比例则可能带来噪声或无效信号，从而削弱推荐效果。因此，合理设定 β_{high} 对充分利用辅助行为、提升模型准确性至关重要。

平衡系数 α 的影响。参数 α 用于平衡行为间权重与行为内权重的重要性。如图 3-3(c) 所示，当 α 取值过小或过大时，模型分别会过度依赖跨行为或行为内权重，从而导致性能下降。尽管不同数据集的最优 α 略有差异，但整体结果表明，在两类权重之间保持适当平衡能够获得最佳模型表现。

3.6.7 案例研究

(1) 去噪模块通用性分析

为进一步验证所提出去噪模块的通用性与可迁移性，本节将 NIPER 的跨行为与行为内加权去噪模块集成至三种当前最先进的多行为推荐模型中——GHCF[8]、MBSSL[37] 和 POGCN[22]，以评估其对不同框架的性能提升效果。实验采用 Recall@10 与 NDCG@10 两项指标，对集成去噪模块前后的性能差异进行对比分析，从而量化该模块在提升推荐精度方面的贡献。

如图 3-4 所示，在 Beibei、Taobao 和 Tmall 数据集上，三种基线模型在 Recall@10

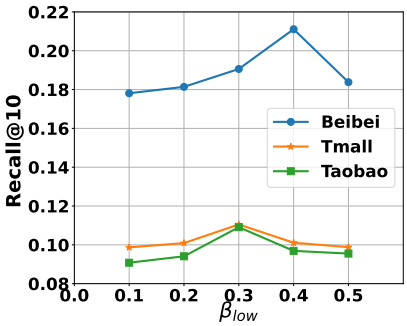

(a) 去噪比例 β_{low}

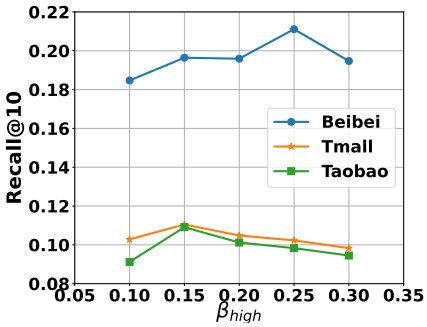

(b) 辅助行为增强比例 β_{high}

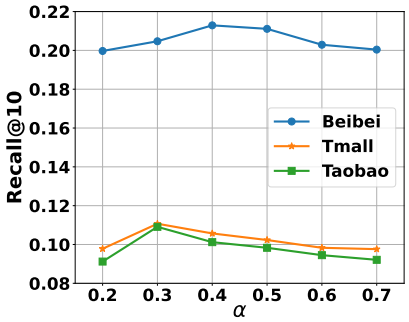

(c) 平衡系数 α

图 3-3: 超参数实验

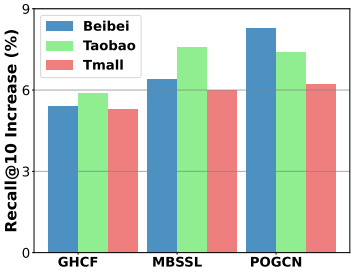

(a) Recall@10 提升效果

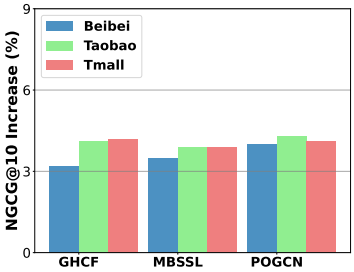

(b) NDCG@10 提升效果

图 3-4: 在不同模型中集成 NIPER 去噪模块后的性能增益

与 NDCG@10 指标上均取得显著提升。该结果表明，NIPER 的去噪机制能够有效降低多行为交互中的噪声干扰，同时具备良好的通用性与可扩展性，可作为提升现有多行为推荐框架性能的独立模块。

(2) 去噪模块有效性分析为验证 NPIER 去噪模块的有效性，本实验在 Beibei 数据集的辅助行为中人工注入 0%–30% 梯度的噪声，并对比 NPIER 与 GHCF、MBSSL 在 Recall@10 指标上的表现。如图 3-5 所示，无论是否添加人工噪声，NPIER 的 Recall@10 绝对值在所有噪声水平下均显著高于两个基线模型：无噪声时达 0.2394，30% 噪声下仍保持 0.1857，而 GHCF 与 MBSSL 在相同条件下分别仅为 0.1530 与

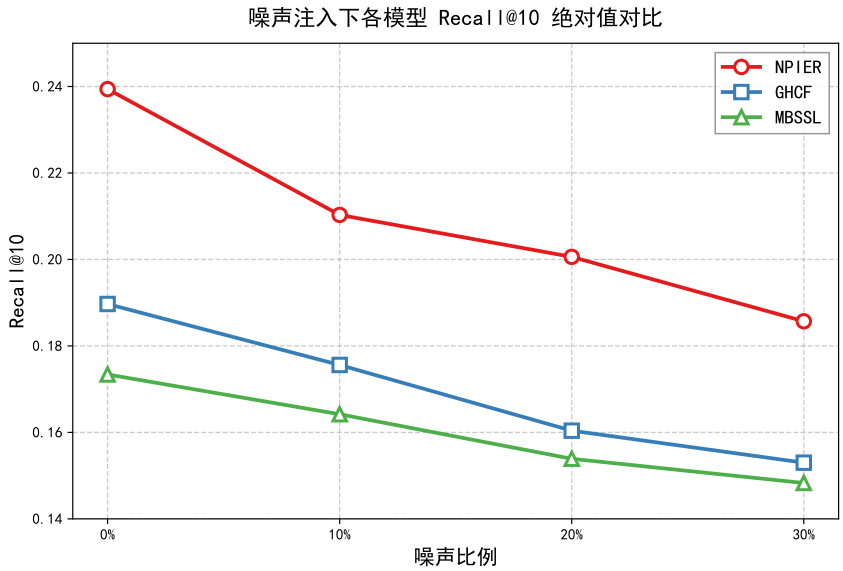

图 3-5: 不同噪声比例下各模型的 Recall@10 性能对比

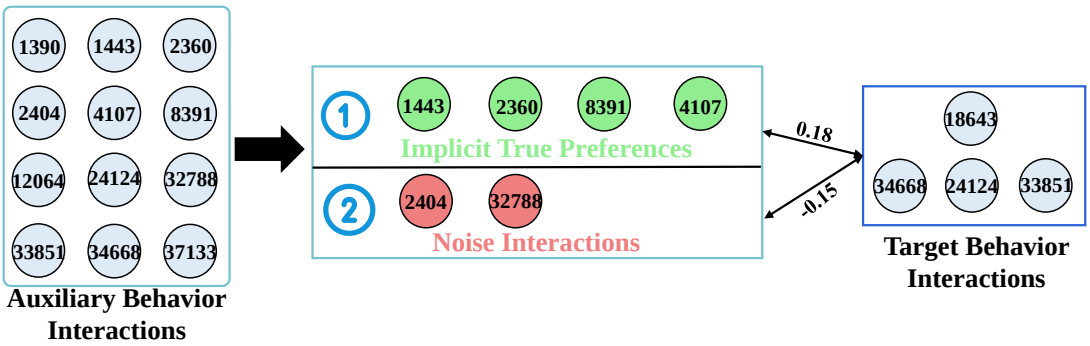

图 3-6: 辅助行为与目标行为相似性案例分析

0.1483。该结果清晰表明，NPIER 的去噪机制不仅有效抑制噪声干扰，同时在无噪声场景下亦能优化用户偏好建模，从而在各类条件下均稳定输出更优的推荐性能，充分验证了该模块的普适性与实用价值。

(3) 去噪模块的局部效果分析为进一步验证 NIPER 在辅助行为分类中的有效性，本节从局部视角对其进行分析。我们选取 Taobao 数据集中的一位典型用户作为研究对象，该用户在辅助行为下与 12 个物品发生过交互。依据模型在最优参数设置下的权重分布，我们根据去噪阈值 β_{low} 和增强阈值 β_{high} 对该用户的辅助行为进行了分类。其中，权重低于 β_{low} 的交互被视为噪声样本，而权重高于 $(1-\beta_{high})$ 的交互则被认为更能反映用户的真实偏好。随后，我们计算辅助行为交互与用户实际购买物品之间的余弦相似度，以验证分类结果的合理性。

分析：如图 3-6 所示，辅助行为中被识别为真实偏好的高权重交互，其与目标行为（购买行为）物品的相似度显著高于被识别为噪声的交互。这表明，NIPER 能

够精准地区分噪声与真实偏好，在去除无效交互的同时，有效保留对用户真实兴趣具有代表性的交互信息，从而提升模型的整体推荐性能。

3.7 本章小结

本章针对多行为推荐系统中存在的噪声交互问题，提出了一种新颖的多行为推荐框架——NIPER（Noise Identification and Preference Extraction in Multi-Behavior Recommender System）。该框架旨在解决多行为推荐系统中噪声交互与真实偏好提取的核心问题，与以往将所有辅助行为直接融合到目标行为模型的方法不同，NIPER 能够有效区分辅助行为中的噪声与真实偏好。

具体而言，**跨行为与行为内加权去噪模块**通过为多行为交互分配不同权重，削弱噪声交互的影响，确保无关或偶然行为被过滤；**基于偏好的表征增强模块**则利用自监督学习机制，从辅助行为中提取真实偏好信息，增强模型对目标行为的表达能力。通过这两个模块的协同作用，NIPER 能够在多源行为融合的同时抑制噪声影响，从而提升推荐系统的准确性与鲁棒性。

在多个公开数据集上的实验结果表明，NIPER 在推荐精度和模型稳定性方面均显著优于现有最先进方法，验证了该框架在提升多行为推荐系统性能方面的有效性，同时为多行为推荐系统中的噪声处理提供了新的思路。

第 4 章 噪声感知与偏好提取的多模态多行为推荐方法

4.1 引言

随着推荐系统在电商、短视频与内容分发等场景中的广泛应用，用户行为数据呈现出多样化和复杂化的特征。不同类型的用户行为（如点击、收藏、购买等）蕴含了用户多层次的兴趣线索，为建模个性化偏好提供了丰富的信息来源。然而，当前推荐系统在建模用户偏好时仍面临两大核心挑战：其一，多行为交互数据中普遍存在噪声，例如误点击、无效浏览等行为可能不能准确反映用户的真实兴趣；其二，现有方法主要依赖用户-物品的协同信号，忽视了物品本身的多模态语义内容（如文本描述和图像特征），从而限制了模型在兴趣表达不充分或行为多样性较高场景下的建模能力。

近年来，针对多行为推荐问题的研究逐渐深入，已有工作主要集中在行为关系建模和行为融合策略上，通过在不同层次捕获多行为间的关联性来提升推荐效果。然而，这些方法普遍存在两方面不足：一方面，它们通常假设辅助行为均为有效信号，未能充分考虑行为数据中的噪声问题，导致模型可能受到误导性交互干扰；另一方面，尽管多模态信息（如图像和文本）能够为用户偏好提供语义补充，但现有研究往往将其作为静态特征使用，缺乏与多行为信号的深度融合，难以实现语义层面的偏好理解与去噪。

针对上述问题，本章主要研究以下关键问题：如何在多行为推荐系统中识别并抑制噪声交互？如何将多模态内容特征与多行为信号进行有效融合，从而提升用户偏好表示的准确性与稳健性？本章提出的方法将多模态信息（文本、图像）与多行为交互信号协同建模，并通过图神经网络和对比学习机制实现语义增强和噪声抑制，为解决上述问题提供技术方案。

4.2 问题定义及方法概述

4.2.1 问题定义

在本研究中，设用户集合为 $\mathcal{U} = \{u_1, u_2, \ldots, u_{|\mathcal{U}|}\}$，物品集合为 $\mathcal{I} = \{i_1, i_2, \ldots, i_{|\mathcal{I}|}\}$。定义用户-物品交互图为

$$G^R = (V, E^R), \tag{4-1}$$

其中，节点集合 $V = \mathcal{U} \cup \mathcal{I}$ 表示所有用户与物品节点，边集合 E^R 表示观测到的

用户–物品交互关系。在多行为场景下，用户可能与同一物品发生多种类型的交互（如浏览、加购、购买等）。因此，整体交互图 G^R 可以划分为 K 个行为子图：

$$G^R = \{G_1^R, G_2^R, \ldots, G_K^R\}, \tag{4-2}$$

其中，G_k^R 表示第 k 种行为对应的子图。

为便于建模，定义交互矩阵集合 $\{R_1, R_2, \ldots, R_K\}$，其中

$$R_k \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|} \tag{4-3}$$

表示行为 k 下的用户–物品交互矩阵。若

$$R_{ui}^k = 1, \tag{4-4}$$

则表示用户 u 在行为 k 下与物品 i 发生过交互，对应地，在行为图 G_k^R 中存在一条连接用户 u 与物品 i 的边；若

$$R_{ui}^k = 0, \tag{4-5}$$

则表示该交互未发生。

在推荐任务中，模型旨在学习一个预测函数 $\widehat{y}_{ui}$，用于刻画用户 u 对物品 i 的偏好强度：

$$\widehat{y}_{ui} = f(u, i \mid \Theta), \tag{4-6}$$

其中 $f(\cdot)$ 表示推荐模型，Θ 为模型参数。根据预测得分对物品集合 $\mathcal{I}$ 进行排序，可为用户 u 生成推荐列表 R_u，即排名最高的 Top-K 个物品：

$$R_u = \text{Top-}K(\widehat{y}_{ui}, i \in \mathcal{I}). \tag{4-7}$$

综上，多行为推荐任务的形式化定义如下：

- **输入**：用户在 K 种行为下的交互图集合 $\{G_1^R, G_2^R, \ldots, G_K^R\}$；
- **输出**：一个推荐模型，用于预测用户 u 在第 K 种行为（即目标行为）下与物品 i 发生交互的概率 $\widehat{y}_{ui}$。

4.2.2 算法概述

本研究聚焦于多模态多行为推荐系统中的噪声干扰与鲁棒表示建模问题，提出了一种统一的多模态多行为去噪推荐框架。该方法融合了大语言模型的语义生成能力、多模态内容理解、图神经网络的结构建模优势以及对比学习的判别特性，以实现高质量、可解释且鲁棒的用户–物品表示学习。整体框架由以下三个核心模块组成：

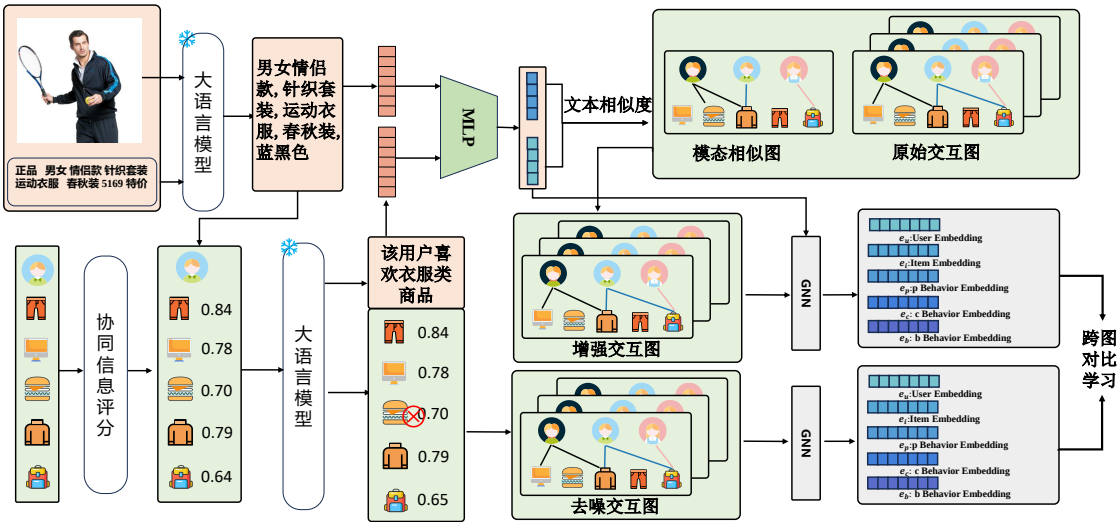

图 4-1: 噪声感知与偏好提取的多模态多行为推荐方法整体框架示意图

多模态辅助偏好建模模块。为获得语义丰富且具备判别力的特征表示，本文首先利用 LLM 对多模态内容进行语义对齐。具体而言，物品侧基于图像与文本模态信息，通过 LLM 生成内容一致的语义文本描述，并将不同模态特征映射至共享语义空间，实现模态间的对齐与融合。随后，利用生成的模态嵌入计算用户-物品交互的语义相似度，并根据相似度阈值执行**硬去噪**，以剔除显著偏离用户真实兴趣的异常交互行为。针对多模态推荐中的文本特征提取问题，现有方法通常直接使用原始文本或独立编码各模态特征，存在不同模态间语义偏差较大的问题。本文提出的方法的特殊之处在于：在文本提取之前，首先利用大语言模型引入其世界知识，将原始文本与图像信息进行融合，生成语义一致的文本描述。通过这一预处理步骤，不同模态的信息被统一映射到共享语义空间，从而显著减少了多模态推荐中常见的模态间语义偏差问题。相较于传统方法，本方法能够更准确地捕获用户偏好与物品语义之间的真实关联，提高下游推荐任务的效果与鲁棒性。

语义感知的图消息传递模块。为联合建模交互结构与模态语义信息，本文设计了一种语义感知的消息传递机制。在邻居聚合过程中，引入基于模态相似度的注意力加权策略，使图神经网络在传播阶段重点聚合语义一致性更高的邻居节点；在特征更新阶段，融合交互嵌入、行为类型嵌入与模态语义嵌入，从而捕获多源特征间的互补关系，提升用户与物品表示的表达能力。

模态感知图增强与对比学习模块。为弥补原始交互图中潜在的偏好缺失，本文基于多模态语义关系构建语义增强图 $\mathcal{G}_{\text{aug}}$，并将其与去噪后的协同交互图共同用于表示学习。通过引入图级对比学习策略，对两种视角下的节点表示进行对齐，使模型能够在结构空间与语义空间之间实现一致性约束与知识迁移，从而有效提升推荐的鲁棒性与泛化性能。

4.2.2.1 复杂度分析

本章所提出的多模态多行为去噪推荐方法主要包含三个核心模块：多模态辅助偏好建模模块、语义感知的图消息传递模块以及模态感知图增强与对比学习模块。

在多模态辅助偏好建模阶段，利用 LLM 生成物品模态嵌入并进行语义对齐，其时间复杂度取决于文本/图像长度 L 与嵌入维度 d_m，可表示为 $O(L \cdot d_m^2)$。硬去噪操作基于用户-物品相似度筛选异常交互，复杂度为 $O(|E|)$。

在语义感知的图消息传递阶段，引入模态注意力加权的邻居聚合操作，其复杂度为 $O(|U| \cdot k \cdot d_{\text{total}})$，其中 d_{total} 为融合后的总嵌入维度。

在模态感知图增强与对比学习阶段，对节点进行图级对比学习，其复杂度为 $O(|U| \cdot S \cdot d_{\text{total}})$，$S$ 为每个用户采样的正负样本数。空间复杂度主要包括用户与物品嵌入、正负样本缓存及模态嵌入，总体为 $O((|U| + |I|) \cdot (d + d_m) + |U| \cdot S + |E|)$。整体设计保证方法在处理大规模多行为与多模态交互数据时仍具有良好的可扩展性。

4.3 多模态辅助偏好建模

多模态输入与文本摘要生成：本研究的输入数据包括物品侧的图像与标题文本，以及用户侧的多行为交互记录。物品侧数据通常存在语义噪声：图像中可能包含广告、水印或背景干扰元素，而文本标题多由商家编写，常含有营销性修辞或冗余关键词，难以准确反映商品的核心属性。为实现多模态内容的统一理解与语义浓缩表达，物品的图像与文本标题被共同输入至多模态大语言模型（LLM），通过设计提示词（prompt），在视觉与文本的协同语义空间中生成高质量的物品摘要文本。

如图4-2所示，在提示设计中，输入由“任务指令部分”和“数据输入部分”组成。

多模态大语言模型在接收上述输入后，将联合理解图像与文本两种模态的信息，并输出一段高语义浓度的商品摘要。例如：“轻质透气的男士跑步鞋，适合日常通勤与运动。”该摘要被记作物品的语义描述 s_i，用于后续的用户偏好建模与图结构构建。

用户偏好摘要生成机制：在获得所有物品的模态摘要后，结合用户的多行为交互记录生成用户的偏好摘要文本。对于每个用户，将其交互过的物品摘要文本、行为类型（如点击、加购、收藏、购买）以及交互评分一并输入 LLM。交互评分来源于前一工作 NIPER 所提出的基于因果推断的协同加权机制，该机制通过跨行

任务说明(Instruction):
你是一名电商领域的专家，请根据以下商品的图像和文本信息，生成一句简洁的摘要，用以准确描述该商品的核心功能、用途或适用人群。

数据输入(Input):
图像：< 上传的商品主图 >
文本：这是一款夏季新款男士运动鞋，轻便透气，适合跑步及日常出行。

图 4-2: 物品摘要生成的 Prompt 模板示意图。

为与行为内的加权计算，为每条用户-物品交互分配一个反映交互可靠性与强度的权重分值，从而量化不同交互行为的重要性。

为了引导 LLM 理解行为强度与语义内容之间的关系，从而生成能够反映稳定兴趣偏好的文本摘要，我们将设计的 Prompt 模板具体内容可视化如图 4-3 所示。

任务说明(Instruction):
你是一位推荐系统助手。用户与物品之间的交互行为具有不同强度，例如"购买"通常表示较强兴趣，而"点击"可能仅代表短暂关注。请根据用户的历史交互记录，总结其主要兴趣偏好。

数据输入(Input):
包括交互行为类型、物品摘要文本以及协同评分，例如：用户 ID：u1234 交互物品列表：
[1] 行为：购买；摘要：轻质透气的跑步鞋；评分：0.92
[2] 行为：点击；摘要：女士时尚手提包；评分：0.23
[3] 行为：加购；摘要：运动功能手表，适合日常锻炼；评分：0.87
……

图 4-3: 用户偏好摘要生成的 Prompt 模板示意图。

LLM 在理解交互强度、协同评分与模态语义的关系后，生成概括性的用户偏好摘要文本 s_u，如"偏好运动休闲类商品，特别关注轻便跑鞋与户外装备"。在此基础上，利用生成的用户偏好文本与物品模态摘要文本构建统一的语义表示空间，以支持后续基于模态相似度的硬去噪机制。

语义嵌入与基于相似度的硬去噪：为获得用户与物品的语义表示，首先将用

户偏好摘要文本 s_u 与物品模态摘要文本 s_i 输入预训练语言模型 BERT，得到高维原始模态语义向量：

$$\mathbf{h}_u = \mathrm{BERT}(s_u), \qquad \mathbf{h}_i = \mathrm{BERT}(s_i). \tag{4-8}$$

由于原始 BERT 表征 $\mathbf{h}$ 能完整保留语义细节，因此在识别辅助行为中的噪声交互时，直接使用 $\mathbf{h}_u$ 与 $\mathbf{h}_i$ 计算用户与其交互物品之间的语义相似度：

$$s_{ui} = \frac{\mathbf{h}_u^\top \mathbf{h}_i}{\|\mathbf{h}_u\| \, \|\mathbf{h}_i\|}. \tag{4-9}$$

随后对每位用户的相似度得分进行 softmax 归一化：

$$\tilde{s}_{ui} = \frac{\exp(s_{ui}/\tau)}{\sum_{j \in \mathcal{I}_u} \exp(s_{uj}/\tau)}, \tag{4-10}$$

并根据阈值 δ 删除语义相关性较低的辅助行为交互（购买行为始终保留）：

$$\mathcal{G}_{\text{denoised}} = \mathcal{G}^R \setminus \{(u, i, b) \mid b \in \mathcal{B}_{\text{aux}},\ \tilde{s}_{ui} < \delta\}. \tag{4-11}$$

该步骤基于未经投影的原始语义空间进行判断，从而避免降维带来的语义偏差影响噪声识别质量。

在得到去噪后的多行为交互图后，将用户与物品的模态表示输入多层感知机（MLP）进行投影与降维，使其与图神经网络得到的行为嵌入处于一致的向量尺度：

$$\widetilde{\mathbf{e}}_u = \mathrm{MLP}(\mathbf{h}_u), \qquad \widetilde{\mathbf{e}}_i = \mathrm{MLP}(\mathbf{h}_i). \tag{4-12}$$

为增强降维后的模态语义嵌入与 GNN 行为嵌入 $\mathbf{g}_u, \mathbf{g}_i$ 的表示一致性，引入基于余弦相似度的对齐正则项：

$$\mathcal{L}_{\text{align}} = 1 - \frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} \frac{\mathbf{g}_x^\top \widetilde{\mathbf{e}}_x}{\|\mathbf{g}_x\| \, \|\widetilde{\mathbf{e}}_x\|}, \tag{4-13}$$

其中 $\mathcal{X}$ 表示用户与物品节点集合。该正则项最大化结构表示与模态表示的方向一致性，从而实现语义空间与行为空间的有效融合，同时避免了 KL 散度等分布对齐方法的数值不稳定性。

4.4 语义感知注意力的软去噪消息传递

在获得去噪后的加权交互图 $\boldsymbol{G}_{\mathbf{denoised},k}$ 后，为进一步缓解残余噪声干扰并提升表示的语义一致性，本文引入带有语义引导的消息传递机制，实现基于注意力的软去噪（soft denoising）。该过程以图神经网络为核心，在 GHCF[8] 框架基础上，通

过引入 Query–Key–Value（QKV）注意力机制，动态调整邻居节点在信息聚合中的权重，从而抑制低语义相关的邻居贡献，强化与用户兴趣一致的高相关邻居信号。

不同于原始 GHCF 在各行为子图中对同类邻居进行等权聚合的方式，本研究根据用户与邻居物品在语义空间中的相似度自适应地分配聚合权重，使消息传递过程具备噪声感知能力。在第 l 层传播中，首先将用户与物品的模态语义嵌入 $\widetilde{\mathbf{e}}_u$ 与 $\widetilde{\mathbf{e}}_v$ 分别映射为 Query 与 Key 表示，而 Value 向量来自邻居节点的交互嵌入 $\mathbf{e}_v^{(l)}$：

$$\mathbf{q}_u = \mathbf{W}_Q^{(l)}\widetilde{\mathbf{e}}_u, \quad \mathbf{k}_v = \mathbf{W}_K^{(l)}\widetilde{\mathbf{e}}_v, \quad \mathbf{v}_v^{(l)} = \mathbf{W}_V^{(l)}\mathbf{e}_v^{(l)}, \tag{4-14}$$

其中，$\mathbf{W}_Q^{(l)}$、$\mathbf{W}_K^{(l)}$ 和 $\mathbf{W}_V^{(l)}$ 为第 l 层的可学习参数矩阵。

随后，用户 u 与其邻居物品 $v \in N_{u,k}$ 的注意力权重基于语义相关性计算得到：

$$\alpha_{uv,k}^{(l)} = \mathrm{softmax}\left(\frac{\mathbf{q}_u^\top \mathbf{k}_v}{\sqrt{d}}\right)_{v \in N_{u,k}}, \tag{4-15}$$

其中 d 为嵌入维度。该权重反映了邻居节点在语义空间中与用户兴趣的一致程度，高相似度邻居在聚合中获得更大权重，而语义不一致的噪声邻居则被自然削弱，从而实现了隐式的软去噪。

基于注意力权重，对邻居节点的特征进行加权聚合，得到用户 u 在行为 k 下的更新表示：

$$\mathbf{e}_{u,k}^{(l+1)} = \mathrm{LeakyReLU}\left(\mathbf{W}^{(l)} \sum_{v \in N_{u,k}} \alpha_{uv,k}^{(l)} \left(\mathbf{v}_v^{(l)} \odot \mathbf{e}_k^{(l+1)}\right)\right), \tag{4-16}$$

其中，$\odot$ 表示逐元素乘，$\mathbf{e}_k^{(l+1)}$ 为行为类型的嵌入，$\mathbf{W}^{(l)}$ 为特征变换矩阵。

为了进一步建模行为类型间的差异性，对每种行为类型嵌入进行线性变换：

$$\mathbf{e}_k^{(l+1)} = \mathbf{W}_b^{(l)}\mathbf{e}_k, \tag{4-17}$$

其中 $\mathbf{W}_b^{(l)}$ 为行为特征映射矩阵。最终，经过多层传播后，可分别得到用户嵌入 E_u、物品嵌入 E_v 和行为类型嵌入 E_k，其中 $k \in \mathcal{B}$ 为行为集合。

该语义感知注意力机制通过在消息传递过程中显式建模用户与邻居间的语义相关性，实现了对残余噪声的软抑制（soft denoising），使模型能够在多模态多行为场景下学习到更加鲁棒且语义一致的用户与物品表示。

4.5 模态感知图增强与对比学习

语义增强图构建：为缓解原始交互图中真实偏好边的缺失问题，并进一步发挥模态语义在推荐任务中的补充作用，构建了基于模态一致性的语义增强图 $\mathcal{G}_{\text{aug}}$。

该图以辅助行为图（即 G_k^R，$k = 1, \ldots, K-1$）为基础，通过筛选语义一致性较高的用户-物品交互对来补充目标行为图 G_K^R，从而在保持协同结构的同时引入内容层面的关联信息。

具体而言，基于用户与物品的模态语义嵌入 $\widetilde{\mathbf{e}}_u$ 与 $\widetilde{\mathbf{e}}_v$，采用余弦相似度衡量二者的语义相关性：

$$\mathrm{sim}(u, v) = \frac{\widetilde{\mathbf{e}}_u^\top \widetilde{\mathbf{e}}_v}{\|\widetilde{\mathbf{e}}_u\| \, \|\widetilde{\mathbf{e}}_v\|}. \tag{4-18}$$

当 $\mathrm{sim}(u, v)$ 超过设定阈值 β 时，认为该辅助行为交互在语义上可能反映了用户的真实兴趣意图，因此将其纳入语义增强图：

$$\mathcal{G}_{\mathrm{sim}} = \left\{(u, v) \mid \exists k \in \{1, \ldots, K-1\},\ (u, v) \in G_k^R,\ \mathrm{sim}(u, v) > \beta\right\}. \tag{4-19}$$

最终，语义增强图 $\mathcal{G}_{\mathrm{sim}}$ 被并入目标行为图，形成增强后的目标行为图：

$$\widetilde{G}_K^R = G_K^R \cup \mathcal{G}_{\mathrm{sim}}, \tag{4-20}$$

并将其与原始辅助行为图集合共同记为 $\mathcal{G}_{\mathrm{aug}}$。该增强策略通过引入高置信度的模态语义边补充协同图的结构信息，有效提升了目标行为图对用户真实兴趣的刻画能力。

跨图表示对比学习：为进一步实现语义增强图 $\mathcal{G}_{\mathrm{aug}}$ 与去噪图 $\mathcal{G}_{\mathrm{denoised}}$ 之间的知识迁移与偏好一致性建模，引入了跨图对比学习（cross-graph contrastive learning）策略。该机制利用模态信息生成正负样本对，从语义视角对齐两图中的节点表示，促进语义信息的高效传递。

具体而言，将两张图分别输入图神经网络（GNN），得到用户与物品在两种图结构下的嵌入表示：

$$\mathbf{e}_u, \mathbf{e}_v = \mathrm{GNN}(\mathcal{G}_{\mathrm{denoised}}), \quad \mathbf{e}_u^{\mathrm{aug}}, \mathbf{e}_v^{\mathrm{aug}} = \mathrm{GNN}(\mathcal{G}_{\mathrm{aug}}). \tag{4-21}$$

其中，$\mathbf{e}_u$ 与 $\mathbf{e}_v$ 分别为去噪图中用户与物品的嵌入，$\mathbf{e}_u^{\mathrm{aug}}$ 与 $\mathbf{e}_v^{\mathrm{aug}}$ 则来自语义增强图。

为强化两种图视角下的语义一致性，对同一节点在两图中的嵌入施加对比学习约束。以用户为例，对比学习损失定义为：

$$\mathcal{L}_{\mathrm{contrast}}^{(u)} = -\log \frac{\exp\left(\cos(\mathbf{e}_u, \mathbf{e}_u^{\mathrm{aug}})/\tau\right)}{\sum_{u' \in \mathcal{U}} \exp\left(\cos(\mathbf{e}_u, \mathbf{e}_{u'}^{\mathrm{aug}})/\tau\right)}, \tag{4-22}$$

其中 τ 为温度系数，$\cos(\cdot)$ 表示余弦相似度。同理，物品端的对比损失为：

$$\mathcal{L}_{\mathrm{contrast}}^{(v)} = -\log \frac{\exp\left(\cos(\mathbf{e}_v, \mathbf{e}_v^{\mathrm{aug}})/\tau\right)}{\sum_{v' \in \mathcal{I}} \exp\left(\cos(\mathbf{e}_v, \mathbf{e}_{v'}^{\mathrm{aug}})/\tau\right)}. \tag{4-23}$$

最终的跨图对比学习目标定义为：

$$\mathcal{L}_{\text{contrast}} = \mathcal{L}_{\text{contrast}}^{(u)} + \mathcal{L}_{\text{contrast}}^{(v)}. \tag{4-24}$$

该模块利用模态信息构建正负样本对，将语义增强图中的高质量语义关系显式传递至去噪图的节点表示中，从而在结构空间与语义空间间实现信息对齐，显著提升用户与物品嵌入的鲁棒性与泛化能力。

4.6 模型训练

为实现多模态多行为场景下的稳定训练与鲁棒优化，模型的最终目标函数综合考虑了推荐精度、语义一致性与跨图表示对齐三方面因素。

首先，推荐损失仍采用与第一部分 NIPER 相同的非采样优化形式，用于直接回归用户-物品交互概率，避免负采样引入的噪声误差。对于特定用户批次 B 与整个物品集合 $\mathcal{I}$，行为 k 下的非采样推荐损失定义为：

$$\mathcal{L}_{\text{rec}}^{k} = \sum_{u \in B} \sum_{i \in I_u^{k+}} \left[\left(c_i^{k+} - c_i^{k-}\right) \left(\hat{x}_{u,i}^{k}\right)^2 - 2c_i^{k+} \hat{x}_{u,i}^{k} \right], \tag{4-25}$$

其中，$\hat{x}_{u,i}^{k}$ 表示用户 u 在行为 k 下对物品 i 的预测偏好值，I_u^{k+} 为正交互集合，c_i^{k+} 与 c_i^{k-} 为经验超参数。

整体推荐损失为各行为损失的加权和：

$$\mathcal{L}_{\text{rec}} = \sum_{k=1}^{K} \lambda_k \mathcal{L}_{\text{rec}}^{k}, \tag{4-26}$$

其中 λ_k 表示第 k 种行为的权重。

其次，为实现语义增强图与去噪图之间的信息传递与偏好一致性，引入跨图对比学习损失：

$$\mathcal{L}_{\text{contrast}} = \mathcal{L}_{\text{contrast}}^{(u)} + \mathcal{L}_{\text{contrast}}^{(v)}, \tag{4-27}$$

其中用户端与物品端的对比损失定义为：

$$\mathcal{L}_{\text{contrast}}^{(u)} = -\log \frac{\exp\left(\cos(\mathbf{e}_u, \mathbf{e}_u^{\text{aug}})/\tau\right)}{\sum_{u' \in \mathcal{U}} \exp\left(\cos(\mathbf{e}_u, \mathbf{e}_{u'}^{\text{aug}})/\tau\right)}, \quad \mathcal{L}_{\text{contrast}}^{(v)} = -\log \frac{\exp\left(\cos(\mathbf{e}_v, \mathbf{e}_v^{\text{aug}})/\tau\right)}{\sum_{v' \in \mathcal{I}} \exp\left(\cos(\mathbf{e}_v, \mathbf{e}_{v'}^{\text{aug}})/\tau\right)}. \tag{4-28}$$

此外，为防止 MLP 降维造成的语义漂移，引入余弦一致性正则项，用以保持投影后嵌入与 GNN 学习的协同侧嵌入的语义方向一致：

$$\mathcal{L}_{\text{align}} = 1 - \frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} \frac{\mathbf{h}_x^{\top} \widetilde{\mathbf{e}}_x}{\|\mathbf{h}_x\| \, \|\widetilde{\mathbf{e}}_x\|}, \tag{4-29}$$

其中 $\mathcal{X}$ 为用户与物品节点的集合。

最终的联合优化目标定义为:

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \mu\,\mathcal{L}_{\text{contrast}} + \gamma\,\mathcal{L}_{\text{align}}, \tag{4-30}$$

其中，μ 与 γ 分别为对比学习与语义一致性正则项的权重系数。

在优化完成后，用户 u 对物品 v 的目标行为预测概率为:

$$\hat{y}_{uv}^{(k)} = \mathbf{e}_u^{\top} \cdot \text{diag}(\mathbf{e}_k) \cdot \mathbf{e}_v, \tag{4-31}$$

其中 $\mathbf{e}_u$、$\mathbf{e}_v$ 分别为用户与物品嵌入，$\mathbf{e}_k$ 为目标行为类型的嵌入向量，$\text{diag}(\mathbf{e}_k)$ 表示以 $\mathbf{e}_k$ 为对角元素的对角矩阵。

该联合目标在优化过程中同时约束了结构信号、模态语义与跨图一致性，从而实现了鲁棒、稳健的多模态多行为去噪推荐建模。

4.7 实验与讨论

4.7.1 评价指标

为全面评估模型的推荐性能，本文采用命中率（Hit Ratio，HR）与归一化折损累计增益（Normalized Discounted Cumulative Gain，NDCG）作为主要评价指标，其计算方式与第三章相同。其中，HR 用于衡量模型在前 K 个推荐结果中命中目标物品的比例，反映模型的召回能力；NDCG 则综合考虑目标物品在推荐列表中的排名位置，更能体现推荐结果的排序合理性与相关性。

4.7.2 数据集信息

由于第三章所使用的数据集仅包含用户与物品在多种行为下的交互信息（如点击、加购、购买等），缺乏文本与图像等模态特征，无法支撑多模态场景下的去噪与偏好建模研究。为进一步扩展模型至多模态多行为推荐任务，本章基于 Tmall 平台的原始数据重新构建了一个多模态多行为推荐数据集——**Tmall-Rec**①。该数据集在保留用户-物品多行为交互关系的基础上，补充了物品侧的文本描述与图像信息，使得模型能够同时利用协同交互信号与多模态内容特征进行联合建模，从而更深入地探索用户真实偏好识别与噪声过滤机制。表 4-1 展示了该数据集的统计信息。

① https://tianchi.aliyun.com/dataset/140281

表 4-1: Tmall-Rec 数据集的统计信息

数据集	#User	#Item	#View	#Cart	#Buy
Tmall-Rec	8,302	30,316	496,615	60,798	43,172

4.7.3 实验设置

实验基于 PyTorch 实现，优化器采用 Adam，学习率设为 0.001，批量大小为 256。图神经网络（GNN）的嵌入维度为 64；为缓解过拟合，训练中使用嵌入丢弃率 0.3 与边丢弃率 0.1。非采样推荐目标的负样本权重固定为 0.01。对比学习的温度系数 τ 在区间 $[0.1, 0.5]$ 内网格搜索。文本语义编码器采用 Sentence-BERT，其输出维度为 768；随后通过一个 MLP 投影到 64 维以与 GNN 表示空间对齐并降低计算开销。多模态摘要与语义对齐由 Qwen-2.5-VL-72B 完成，输入为物品图像与标题以及用户的多行为交互信息。

4.7.4 总体实验效果

表 4-2: Tmall-Rec 数据集上各模型的性能比较结果

Model	Tmall-Rec			
	Recall@5	Recall@10	NDCG@5	NDCG@10
LightGCN[5]	0.0823	0.2049	0.0742	0.1598
FREEDOM[30]	0.1874	0.3412	0.1438	0.2487
GHCF[8]	0.3117	0.4079	0.2274	0.2585
DPT[23]	0.3571	0.4762	0.2745	0.3017
MBSSL[37]	0.3934	0.5063	0.2932	0.3298
Ours	**0.5064**	**0.5925**	**0.3973**	**0.4253**

为验证所提多模态多行为去噪推荐算法的有效性，本章与三类具有代表性的推荐模型进行了系统对比，具体如下：**单行为推荐模型（Single-Behavior Recommendation Models）**。该类方法仅基于目标行为进行建模，用于评估多行为协同建模带来的性能提升。代表模型包括经典协同过滤方法 LightGCN[5]。

多模态推荐模型（Multi-Modal Recommendation Models）。以及融合模态特征的单行为多模态推荐模型 FREEDOM[30]。

去噪推荐模型（Denoising Recommendation Models）。此类方法通过识别和抑制噪声交互以提升推荐结果的鲁棒性。本文选取多行为场景下具有代表性的去噪方法 DPT[23] 作为对比模型。

多行为推荐模型（Multi-Behavior Recommendation Models）。该类方法显式建模多种用户行为间的相关性，以增强目标行为的预测能力。本文选取 GHCF[8] 与基于自监督机制的 MBSSL[37] 作为代表性多行为推荐模型进行对比。

表 4-2 展示了多模态多行为去噪推荐算法与三类基线模型在 Tmall-Rec 数据集上的综合性能比较结果。所有模型均采用在验证集上表现最优的超参数配置进行评估，以确保结果的公平性。

从整体结果来看，所提算法在 Recall@K 与 NDCG@K 等主要指标上均取得了显著提升，表现出更优的推荐准确性与排序能力。其中，在 Recall@10 和 NDCG@10 上，较当前表现最优的多行为模型 MBSSL 分别提升约 12% 与 10%，在各评价指标上均保持领先。

从模型结构角度分析，传统单行为模型（如 LightGCN）由于未考虑多行为信号之间的关联，仅能学习目标行为层面的偏好模式，整体性能较低。加入模态特征的 FREEDOM 在一定程度上提升了内容表达能力，但其缺乏对多行为协同关系与噪声交互的建模，仍存在语义偏差与过拟合问题。多行为推荐方法 GHCF 与 MBSSL 能够捕获行为间的关联性，从而在多源交互数据上获得更优表现，但其对多模态内容的利用较为有限，且在存在噪声干扰的场景中表现下降。

相比之下，所提算法在两方面实现了显著优势：（1）通过引入大模型生成的模态语义摘要，有效弥补了协同信号中缺失的内容信息，使模型能够在语义空间中对齐用户与物品的真实偏好关系；（2）结合基于模态相似度的硬去噪机制与语义感知的软去噪聚合策略，显著降低了辅助行为中随机性与非兴趣驱动交互的干扰，确保图结构中保留的信息更加纯净。

综合来看，该算法在多模态融合与噪声抑制两方面均展现出较高的鲁棒性与表达能力，验证了在复杂交互场景下引入模态语义信息与分层去噪机制的必要性与有效性。

为确保实验结果的可靠性，本研究中的所有实验均重复执行 5 次，每次实验仅改变随机种子（seed），其余超参数和训练设置保持一致。对于每次实验，我们记录关键评价指标，并计算其均值与标准差。结果显示，不同随机种子对模型性能的波动较小，标准差约为指标均值的 1.4% 左右，表明方法具有较高的稳定性。

针对主要指标，本文采用 Wilcoxon 符号秩检验（Wilcoxon signed-rank test）进行显著性分析，以验证本文方法相较于基线方法的性能提升是否具有统计意义。实验结果显示，关键指标的 p 值远小于 0.05，表明性能提升具有统计显著性。通过重复实验、方差分析及显著性检验，本研究能够有效排除偶然因素的影响，为多行为推荐方法的性能评估提供可靠依据。

4.7.5 消融实验

为验证所提出模型中各个设计模块的有效性与必要性，本节进行了系统的消融实验。具体地，设计了以下四个模型变体：

1. **GNN only**：仅保留基础的 GHCF 网络结构，对多行为交互进行建模，不引入任何模态或去噪模块；

2. **w/o 硬去噪**：移除基于多模态信息的硬去噪模块，保留语义感知消息传递与对比学习；

3. **w/o 软去噪**：移除语义感知注意力机制，使用与 GHCF 相同的均值聚合方式进行消息传递；

4. **w/o 硬打分**：移除基于多模态信息的硬去噪模块中的用户-物品交互打分，在大模型的输入中将同等行为视为同等权重；

5. **w/o SSL**：移除模态感知图增强与跨图对比学习模块，仅保留去噪与基本 GNN 表示学习；

消融实验结果如表 4-3 所示。结果分析如下：

基础 GNN 的性能对比。与完整模型相比，仅使用 GHCF 结构（**GNN only**）的性能显著较低，说明单纯依赖协同信号难以充分建模用户的真实偏好。这验证了引入多模态语义与去噪机制对于提升表示质量与缓解交互噪声具有重要意义。

硬去噪机制的重要性。移除硬去噪模块后，模型性能显著下降，表明多模态信息在识别和剔除非真实交互方面发挥了关键作用。硬去噪模块通过计算用户与物品在语义空间中的模态相似度，有效过滤了语义不一致或低相关的辅助行为交互，从而降低了噪声干扰。当该机制被移除时，噪声交互被直接用于训练，导致表示学习受污染，用户偏好建模的准确性显著下降。

软去噪模块的必要性。替换语义感知注意力为均值聚合后，模型在所有评估指标上均出现明显退化，表明软去噪机制在信息传播过程中的自适应调节能力至关重要。基于语义相似度的注意力权重能够动态调整邻居节点的影响力，使模型在特征聚合时更关注语义一致性高的交互关系，从而提升用户与物品表示的判别性与稳定性。

硬打分模块的有效性。移除硬打分模块后，模型将所有用户-物品交互行为赋予同等权重，导致噪声干扰下推荐性能显著下降。该结果不仅验证了该模块在交互质量量化中的关键作用，更凸显其跨工作的强泛化能力：作为本论文第一项工作 NIPER 的核心组件，该机制在第二项工作中仍发挥关键作用。性能退化表明，该模块并非面向单一任务的定制设计，而是具备普适性的噪声感知基础单元，为多行为推荐系统提供了可迁移、可复用的交互质量评估范式。

对比学习的有效性。移除跨图对比学习模块后，模型泛化性能明显下降，验证了该模块在语义增强图与去噪图之间建立一致性约束的作用。对比学习通过在两个视角下对齐节点表示，促进了语义信息向结构空间的有效迁移，从而在保持表达一致性的同时增强了模型的鲁棒性。

表 4-3: 消融实验结果（Tmall-Rec 数据集）

Model	Tmall-Rec			
	Recall@5	Recall@10	NDCG@5	NDCG@10
GNN only	0.2902	0.3857	0.2098	0.2405
w/o 硬去噪	0.4386	0.5337	0.3157	0.3444
w/o 软去噪	0.4628	0.5835	0.3321	0.3695
w/o 硬打分	0.4823	0.5599	0.3171	0.3489
w/o SSL	0.4409	0.5748	0.3279	0.3528
Ours	**0.5064**	**0.5925**	**0.3973**	**0.4253**

4.7.6 参数实验

为系统分析模型关键超参数对整体性能的影响，本节从三个方面展开实验研究：硬噪声阈值 δ、语义增强阈值 β 以及对比学习温度系数 τ。图 4-4 展示了不同参数取值下模型在主要指标上的性能变化趋势。

硬噪声阈值 δ 的影响：该参数用于控制硬去噪阶段中交互样本的过滤强度。当阈值较低时，模型可能保留部分噪声样本，导致表示学习受到干扰；而当阈值过高时，真实但罕见的偏好交互可能被误删，造成信息损失。实验结果表明，适中的阈值能在噪声抑制与信息保留之间取得良好平衡，从而实现最优性能。

语义增强阈值 β 的影响：语义增强阈值决定了辅助行为交互是否可被纳入语义增强图中。较低的阈值会引入更多低相关的辅助样本，降低图结构的纯度；较高的阈值则导致增强边数量不足，语义补充效果减弱。实验结果显示，适当提升 β 能有效强化语义一致性，提升模型在高阶兴趣建模中的表现。

对比学习温度系数 τ 的影响：温度系数调节了对比学习中正负样本分布的平滑程度。当 τ 过大时，样本差异被弱化，导致对比约束不足；当 τ 过小时，梯度过于尖锐，模型训练不稳定。结果表明，适中的温度系数能兼顾表示区分性与优化稳定性，从而提升跨图对齐效果。

4.7.7 案例研究

为验证本文提出的大模型模态增强方法在区分视觉相似但语义不同商品时的

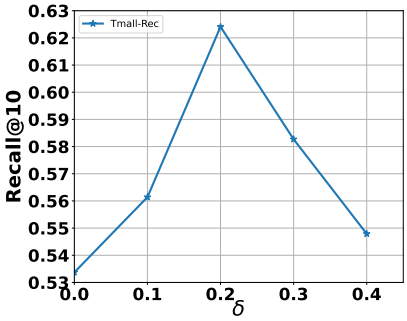

(a) 硬噪声阈值 δ

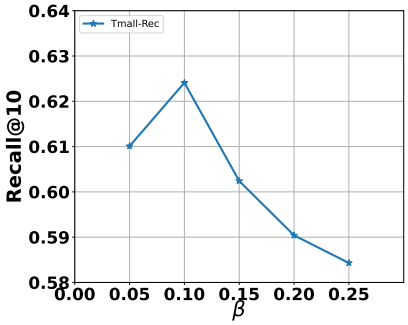

(b) 语义增强阈值 β

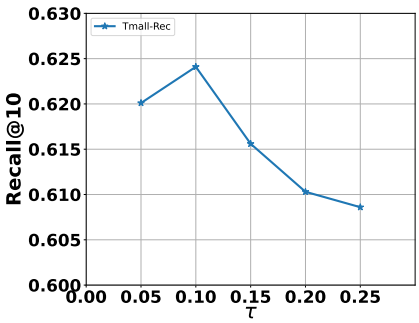

(c) 对比学习温度系数 τ

图 4-4: 超参数实验

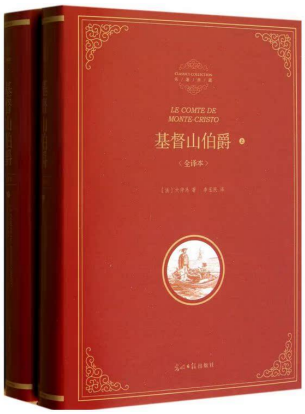

特征类型	相似度
视觉特征（Vision-only）	0.57
原始文本特征（Original Text）	0.41
LLM 增强文本特征（LLM-Enhanced Text）	**0.32**

图 4-5: 红色豆浆机与红色图书样本对在不同特征表征下的语义相似度。

有效性，本节选取两张在视觉上高度相似、背景一致的商品图片（红色豆浆机与红色图书）构建案例对。两张图片在颜色、光照与构图上几乎一致，低层视觉特征高度相似，难以通过视觉表征区分。

实验对比了三种不同表征方式的相似度。如图 4-5 所示，视觉特征的相似度最高（0.57），表明传统视觉模型主要受颜色与外观影响；原始文本表征的相似度下降至 0.41，反映了文本语义对类别差异的初步区分；而本文提出的 LLM 增强文本方法进一步将相似度降低至 0.32，说明通过大语言模型生成的结构化语义描述（包含品类、功能、品牌等关键槽位信息），能够显著强化语义可分性，减少视觉共性带来的混淆。

4.8 本章小结

本章针对多模态多行为推荐场景中存在的噪声干扰与鲁棒表示建模问题，提出了一种融合大语言模型语义理解能力与图神经网络结构建模优势的统一去噪推荐框架。与传统多行为推荐方法仅依赖协同信号不同，本方法充分利用多模态内容与语义信息，实现多源信号下对用户真实偏好的精准建模。

具体而言，**多模态辅助偏好建模模块**利用大语言模型生成物品语义摘要及相似度分布，并通过硬去噪机制有效过滤低相关交互；**语义感知的图消息传递模块**引入软去噪策略，自适应聚合语义一致性更高的邻居节点，提升表示的稳定性与鲁棒性；**模态感知图增强与对比学习模块**通过跨图一致性约束，实现结构空间与语义空间的协同优化，进一步增强模型的泛化能力。

在多个公开多模态多行为数据集上的实验结果表明，所提出框架在 Recall、NDCG 等指标上均显著优于现有主流方法。同时，消融实验验证了硬去噪、软去噪与对比学习模块的有效性，表明该方法在融合多源模态信息、抑制交互噪声以及提升推荐性能方面具有显著优势，为多模态多行为推荐系统提供了一种鲁棒且可解释的解决思路。

结 论

随着推荐系统在各类互联网平台中的广泛应用，用户交互数据的多样化与复杂性不断提升，传统的单行为建模方式已难以充分刻画用户的真实偏好特征。多行为与多模态信息的引入为推荐系统带来了新的机遇，也带来了噪声干扰、语义偏移及鲁棒建模等新的挑战。本文围绕多行为与多模态推荐场景下的噪声抑制与偏好建模问题展开研究，提出了两种创新性的去噪推荐框架。

首先，提出了一种新颖的多行为推荐框架——NIPER，用于解决多行为推荐系统中噪声交互与真实偏好提取的核心问题。与以往方法普遍将所有辅助行为数据直接融合到目标行为模型中不同，NIPER 能够区分辅助行为中的噪声与真实偏好。其中，行为间与行为内加权去噪模块通过为多行为交互分配权重，有效削弱了噪声交互的影响，确保无关或偶然的行为被过滤；基于偏好的表征增强模块则利用自监督学习机制，从辅助行为中提取真实偏好信息，从而增强模型的表达能力。广泛的实验结果表明，NIPER 在推荐精度与鲁棒性方面均显著优于现有最先进方法，验证了该框架在多行为推荐任务中的有效性。

接着，本文针对多模态多行为推荐场景中的噪声干扰与鲁棒表示建模问题，提出了一种融合大语言模型（LLM）语义理解能力与图神经网络（GNN）结构建模优势的统一去噪推荐框架。该方法通过多模态内容辅助、语义引导消息传递与跨图对比学习三方面的设计，实现了多源信号下用户真实偏好的精准建模。首先，在多模态辅助偏好建模阶段，引入多模态大语言模型生成物品的语义摘要文本，并结合多行为交互生成用户偏好摘要，从而在语义层面实现跨模态对齐；随后，通过模态语义嵌入计算用户与物品相似度分布，设计硬去噪机制以识别并剔除低相关交互，显著提升交互图的纯净度。其次，在软去噪模块中，构建语义感知注意力机制，引导 GNN 在消息传递过程中自适应地聚合语义相关性更高的邻居节点，从而降低噪声扩散并增强表示的鲁棒性。最后，通过模态感知图增强与跨图对比学习模块，引入语义增强图以补充协同图中的偏好缺失信息，并在跨图约束下实现多视角表示一致性。实验结果表明，该模型在多个指标上均显著优于主流基线模型，验证了所提框架在融合多源模态信息、抑制交互噪声与提升推荐精度方面的优势。

研究仍然存在一些不足。本文提出的多行为与多模态去噪推荐方法在泛化性与可扩展性方面仍有进一步提升空间。首先，模型整体结构较为复杂，包含多层去噪与语义对齐模块，虽然能够有效提升推荐性能，但也带来了较高的计算开销与参数规模，在大规模推荐场景下的训练效率与推理速度仍需优化。最后，本文

的实验主要基于公开数据集，缺乏在真实工业环境中的在线验证与用户反馈分析。未来的研究将探索基于因果推理的噪声建模与多模态语义对齐机制，结合任务自适应与轻量化建模策略，进一步提升模型的泛化性、可扩展性与稳健性，为多行为多模态推荐系统的发展提供更加通用且高效的解决方案。

参考文献

[1] 刘建国，周涛，汪秉宏. 个性化推荐系统的研究进展 [J]. 自然科学进展，2009，19（01）：1-15.

[2] GAO C，WANG X，HE X，et al. Graph neural networks for recommender system [C] //Proceedings of the fifteenth ACM international conference on web search and data mining，2022：1623-1625.

[3] ZHOU H, XIONG F, CHEN H. A comprehensive survey of recommender systems based on deep learning [J]. Applied Sciences，2023，13（20）：11378.

[4] ALJUNID M F，MANJAIAH D，HOOSHMAND M K，et al. A collaborative filtering recommender systems: Survey [J]. Neurocomputing，2025，617：128718.

[5] HE X，DENG K，WANG X，et al. Lightgcn: Simplifying and powering graph convolution network for recommendation [C] //Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval，2020：639-648.

[6] FAN Z, XU K, DONG Z, et al. Graph collaborative signals denoising and augmentation for recommendation [C] //Proceedings of the 46th international ACM SIGIR conference on research and development in information retrieval，2023：2037-2041.

[7] WANG X，HE X，WANG M，et al. Neural graph collaborative filtering [C] //Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval，2019：165-174.

[8] CHEN C, MA W, ZHANG M, et al. Graph heterogeneous multi-relational recommendation [C] //Proceedings of the AAAI conference on artificial intelligence：Vol 35，2021：3958-3966.

[9] GU S, WANG X, SHI C, et al. Self-supervised Graph Neural Networks for Multi-behavior Recommendation. [C] //IJCAI，2022：2052-2058.

[10] YING R，HE R，CHEN K，et al. Graph convolutional neural networks for web-scale recommender systems [C] //Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining，2018：974-983.

[11] WU L, SUN P, FU Y, et al. A neural influence diffusion model for social recommendation [C] // Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval, 2019: 235-244.

[12] WANG H, ZHANG F, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation [C] // The world wide web conference, 2019: 2000-2010.

[13] WU J, WANG X, FENG F, et al. Self-supervised graph learning for recommendation [C] // Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval, 2021: 726-735.

[14] LIU C, YU C, GUI N, et al. SimGCL: graph contrastive learning by finding homophily in heterophily [J]. Knowledge and Information Systems, 2024, 66 (3): 2089-2114.

[15] 严明时，程志勇，孙静，et al. 基于两阶段学习的多行为推荐 [J/OL]. 软件学报，2024，35（05）：2446-2465. http://dx.doi.org/10.13328/j.cnki.jos.006897.

[16] 党伟超，宋楚君，高改梅，et al. 基于级联残差图卷积网络的多行为推荐 [J]. 计算机应用，2024：1-13.

[17] 李建国，马文杰，程俊伟，et al. 基于图注意力网络的多行为推荐算法 [J]. 华南师范大学学报 (自然科学版)，2023，55（04）：72-80.

[18] 陆佳炜，李端倪，王策策，et al. 基于超图卷积神经网络的多行为感知服务推荐方法 [J]. 浙江大学学报 (工学版)，2023，57（10）：1977-1986.

[19] JIN B, GAO C, HE X, et al. Multi-behavior recommendation with graph convolutional networks [C] // Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval, 2020: 659-668.

[20] XIA L, XU Y, HUANG C, et al. Graph meta network for multi-behavior recommendation [C] // Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval, 2021: 757-766.

[21] CHENG Z, HAN S, LIU F, et al. Multi-behavior recommendation with cascading graph convolution networks [C] // Proceedings of the ACM Web Conference 2023, 2023: 1181-1189.

[22] ZHANG Y, BEI Y, CHEN H, et al. Multi-Behavior Collaborative Filtering with Partial Order Graph Convolutional Networks [C] // Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2024: 6257-6268.

[23] ZHANG C，CHEN R，ZHAO X，et al. Denoising and prompt-tuning for multi-behavior recommendation [C] //Proceedings of the ACM Web Conference 2023，2023：1355-1363.

[24] 王魁，姚迅，杨捷. 基于样本选择的自学习去噪鲁棒模型 [J]. 计算机应用，2024，44（S1）：77-82.

[25] WANG W，FENG F，HE X，et al. Denoising implicit feedback for recommendation [C] //Proceedings of the 14th ACM international conference on web search and data mining，2021：373-381.

[26] TIAN C，XIE Y，LI Y，et al. Learning to denoise unreliable interactions for graph collaborative filtering [C] //Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval，2022：122-132.

[27] HE Z，WANG Y，YANG Y，et al. Double Correction Framework for Denoising Recommendation [C] //Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining，2024：1062-1072.

[28] ZHANG S，CHU H，LI J，et al. DeMBR: Denoising Model with Memory Pruning and Semantic Guidance for Multi-Behavior Recommendation [C] //Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining，2025：521-529.

[29] ZHANG J，ZHU Y，LIU Q，et al. Mining latent structures for multimedia recommendation [C] //Proceedings of the 29th ACM international conference on multimedia，2021：3872-3880.

[30] ZHOU X，SHEN Z. A tale of two graphs: Freezing and denoising graph structures for multimodal recommendation [C] //Proceedings of the 31st ACM international conference on multimedia，2023：935-943.

[31] MO F，XIAO L，SONG Q，et al. Multimodal graph neural network for recommendation with dynamic de-redundancy and modality-guided feature de-noisy [J]. arXiv preprint arXiv:2411.01561，2024.

[32] WEI W，REN X，TANG J，et al. Llmrec: Large language models with graph augmentation for recommendation [C] //Proceedings of the 17th ACM international conference on web search and data mining，2024：806-815.

[33] XU Y，CONG G，ZHU L，et al. MMPOI: A Multi-Modal Content-Aware Framework for POI Recommendations [C] //Proceedings of the ACM on Web Conference，Singapore，2024：3454-3463.

[34] LI J，LI D，SAVARESE S，et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models [C/OL] // KRAUSE A，BRUNSKILL E，CHO K，et al. Proceedings of Machine Learning Research，Vol 202：Proceedings of the 40th International Conference on Machine Learning. PMLR，2023：19730-19742. https://proceedings.mlr.press/v202/li23q.html.

[35] REIMERS N，GUREVYCH I. Sentence-bert: Sentence embeddings using siamese bert-networks [J]. arXiv preprint arXiv:1908.10084，2019.

[36] WANG S，ZHENG Z，SUI Y，et al. Unleashing the Power of Large Language Model for Denoising Recommendation [C] // Proceedings of the ACM on Web Conference 2025，2025： 252-263.

[37] XU J，WANG C，WU C，et al. Multi-behavior self-supervised learning for recommendation [C] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval，2023： 496-505.

[38] WEI W，HUANG C，XIA L，et al. Contrastive meta learning with behavior multiplicity for recommendation [C] // Proceedings of the fifteenth ACM international conference on web search and data mining，2022： 1120-1128.

[39] KIPF T. Semi-supervised classification with graph convolutional networks [J]. arXiv preprint arXiv:1609.02907，2016.

[40] HAMILTON W，YING Z，LESKOVEC J. Inductive representation learning on large graphs [J]. Advances in neural information processing systems，2017，30.

[41] VELICKOVIC P，CUCURULL G，CASANOVA A，et al. Graph Attention Networks [C] // 6th International Conference on Learning Representations，Vancouver, BC, Canada，2018： 1024-1045.

[42] BACHMAN P，HJELM R D，BUCHWALTER W. Learning representations by maximizing mutual information across views [J]. Advances in neural information processing systems，2019，32.

[43] OORD A V D，LI Y，VINYALS O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748，2018.

[44] CHEN T，KORNBLITH S，NOROUZI M，et al. A simple framework for contrastive learning of visual representations [C] // International conference on machine learning，2020： 1597-1607.

[45] HE K，FAN H，WU Y，et al. Momentum contrast for unsupervised visual representation learning [C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition，2020：9729-9738.

[46] GRILL J-B，STRUB F，ALTCHÉ F，et al. Bootstrap your own latent-a new approach to self-supervised learning [J]. Advances in neural information processing systems，2020，33：21271-21284.

[47] WANG T，ISOLA P. Understanding contrastive representation learning through alignment and uniformity on the hypersphere [C] // International conference on machine learning，2020：9929-9939.

[48] YAO L，CHU Z，LI S，et al. A survey on causal inference [J]. ACM Transactions on Knowledge Discovery from Data (TKDD)，2021，15（5）：1-46.

[49] CHERNOZHUKOV V，CHETVERIKOV D，DEMIRER M，et al. Double/debiased machine learning for treatment and causal parameters [J]. arXiv preprint arXiv:1608.00060，2016.

[50] CHEN C，ZHANG M，ZHANG Y，et al. Efficient heterogeneous collaborative filtering without negative sampling for recommendation [C] // Proceedings of the AAAI conference on artificial intelligence：Vol 34，2020：19-26.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

”NIPER: Noise Identification and Preference Extraction in Multi-Behavior Recommender System” 期刊 TKDD(Transactions on Knowledge Discovery from Data) 在投。

（二）申请及已获得的专利

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于图神经网络的多行为去噪推荐方法研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

时光荏苒，转眼间两年半的硕士研究生生涯已近尾声。在完成毕业论文之际，百感交集。回望来路，深知今日之成果绝非一人之力所能及——正是众多师长、亲友的无私支持与倾心相助，才让我得以坚定前行、顺利完成学业。在此，谨以最诚挚的心意，向所有曾给予我关怀与帮助的人致以深深的谢意。

在此，谨向我的导师马江虹老师致以最诚挚的感谢。在攻读硕士学位期间，您不仅在学术研究上给予我系统而深入的指导，更在写作与学术汇报方面耐心地培养了我的逻辑思维能力。在论文撰写与修改过程中，您始终认真细致，提出了大量富有针对性的批注与修改建议，使我能够清晰地认识到论文中存在的不足，并不断加以完善。您的严谨治学态度与无私付出令我受益匪浅。此外，在日常学习与生活中，您也给予我们充分的关怀与支持，为我顺利完成学业提供了重要保障。

其次，我要感谢我的同门。在科研探索的过程中，我们相互交流、共同进步，面对研究中的困难与挑战，彼此分享思路与经验。与同门们共同讨论课题，使我在学术视野与研究能力上均受益良多，每一次交流都对我的研究工作产生了积极而深远的影响。

随后，我要特别感谢我的家人。在攻读硕士学位的这几年中，面对学业与科研带来的压力，是你们始终如一的理解、包容与鼓励，给予我坚持前行的力量。每一次电话中的关怀、每一次回家时温暖的陪伴，都让我深切感受到无言却深厚的爱与支持。正是你们在背后的默默付出，成为我顺利完成学业的重要支撑。

同时，我也衷心感谢我的朋友们。在求学与科研的过程中，你们的陪伴、理解与鼓励，为这段紧张而充实的时光增添了温度。无论是低谷时的倾听，还是前行中的相互支持，你们都让我在忙碌与压力之中保持信心与动力。

最后，我要衷心感谢哈尔滨工业大学。四年在哈尔滨本部、两年在深圳校区的学习经历，使我在学术视野与专业能力上都得到了系统而全面的培养。从专业课程的科学设置，使我得以扎实而深入地掌握相关理论与方法。学院的每一位老师都治学严谨、认真负责，其言传身教不仅传授了专业知识与研究方法，也深刻塑造了我严谨求实的学术态度。感谢学校和学院多年来的悉心培养，未来我将秉持在此形成的治学精神，继续努力，在各自岗位上践行哈工大的校训与精神。

衷心感谢老师的悉心教诲、同学的并肩前行、朋友的温暖陪伴以及家人的坚定支持，使我得以顺利走过这段研究生时光。未来，我将带着这份感激与收获，继续前行。