硕士学位论文

（专业学位论文）

基于多模态预训练的蛋白质功能预测研究

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

崔博越

哈尔滨工业大学

2026 年 5 月

国内图书分类号：TP391　　学校代码：10213
国际图书分类号：68T07　　密级：公开

硕士学位论文

基于多模态预训练的蛋白质功能预测研究

硕士研究生：崔博越

导　　师：李君一教授

申请学位：专业硕士

类　　别：计算机技术

所在单位：哈尔滨工业大学（深圳）

答辩日期：2026 年 05 月

授予学位单位：哈尔滨工业大学

Classified Index: TP391
U.D.C: 68T07

Dissertation for the Master Degree

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

Candidate: Boyue Cui
Supervisor: Prof. Junyi Li
Academic Degree Applied for: Master of Engineering
Specialty: Computer Technology
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: May, 2026
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，然而经实验验证的功能注释比例极低，序列-功能鸿沟日益加深。现有的深度学习方法通常仅依赖序列模式特征，将蛋白质域信息和基因本体（Gene Ontology, GO）功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，从而限制了模型对未见标签的泛化能力。针对上述问题，本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，提出多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码，通过三路特征投影将异构表示映射至共享语义空间。设计了自适应门控融合模块动态调节各模态贡献权重，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在标准测试集上的有监督指标达到最优水平，尤其在零样本场景下显著超越现有方法。

其次，为进一步提升序列表征的功能感知能力，提出基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法设计了轻量级适配器模块，以即插即用方式注入蛋白质语言模型的 Transformer 层内部；通过对比学习预训练，将蛋白质域的语义信息蒸馏至序列编码器，使模型仅凭序列输入即可产出携带域信息的嵌入表示。在下游阶段，采用双适配器策略实现端到端训练，兼顾预训练知识保留与任务特定适配。实验结果表明，MZSGO-DA 在端到端场景下进一步提升了功能预测性能。

本文的创新性体现在：一方面，通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；另一方面，通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器，提升了模型的表征能力与泛化性能。

关键词：蛋白质功能预测；零样本学习；多模态融合；蛋白质语言模型；基因本体

Abstract

Protein function prediction is a fundamental task in bioinformatics. With the rapid advancement of high-throughput sequencing technologies, protein sequence data has grown exponentially, yet the proportion of experimentally validated functional annotations remains extremely low, deepening the sequence-function gap. Existing deep learning methods typically rely solely on sequence pattern features, treating protein domain information and Gene Ontology (GO) functional labels as simple categorical identifiers while neglecting the rich semantic information embedded in their textual definitions. This limits model generalization to unseen labels. To address these challenges, this thesis investigates two complementary directions—multimodal semantic fusion and pretrained domain-aware adaptation—and proposes two progressively advanced protein function prediction frameworks.

First, we propose MZSGO, a Multimodal Zero-Shot protein function annotation method. MZSGO redefines protein function prediction as a protein-GO matching problem. It employs the protein language model ESM2 to extract evolutionary sequence features and utilizes the large language model Qwen3-Embedding as a unified semantic encoder for both protein domain descriptions and GO functional definitions. Three independent projection modules map these heterogeneous representations into a shared latent space. An adaptive gated fusion module dynamically adjusts the contribution weights of each modality, while an asymmetric feature dropout strategy enhances robustness against modality absence. Experiments demonstrate that MZSGO achieves state-of-the-art performance on standard benchmarks, with particularly significant improvements in zero-shot scenarios.

Second, to further enhance the functional awareness of sequence representations, we propose MZSGO-DA, a Domain-Aware adapter pretraining approach for end-to-end protein function prediction. This method designs lightweight adapter modules that are injected directly into the Transformer layers of the protein language model in a plug-and-play manner. Through contrastive learning pretraining, domain semantic information is distilled into the sequence encoder, enabling the model to produce domain-aware embeddings from sequence input alone. In the downstream stage, a dual-adapter strategy supports end-to-end training while preserving pretrained knowledge and enabling task-specific adaptation. Experimental results show that MZSGO-DA further improves prediction performance in the end-to-end setting.

The main contributions of this thesis are twofold: on one hand, by introducing large language models to construct a unified semantic space for domains and labels, we achieve a paradigm shift from closed-set to open-set protein function prediction, endowing the model with zero-shot reasoning capabilities; on the other hand, through domain-aware contrastive pretraining and a dual-adapter end-to-end training mechanism, we efficiently inject multimodal knowledge into the sequence encoder without modifying the original protein language model parameters, enhancing both representational capacity and generalization performance.

Keywords: protein function prediction, zero-shot learning, multimodal fusion, protein language model, Gene Ontology

目 录

摘 要 I
ABSTRACT II
第 1 章 绪论 1
1.1 课题研究背景和意义 1
1.1.1 课题研究背景 1
1.1.2 研究目的和意义 2
1.2 国内外研究现状 3
1.2.1 基于蛋白质序列的功能预测方法 4
1.2.2 基于蛋白质结构的功能预测方法 5
1.2.3 基于多模态信息融合的功能预测方法 7
1.3 本文的主要研究内容 10
1.4 本文的组织结构 11
第 2 章 蛋白质功能预测的相关研究概述 13
2.1 引言 13
2.2 蛋白质功能预测问题 14
2.2.1 蛋白质功能预测问题的定义 14
2.2.2 蛋白质功能预测的评价指标 16
2.3 零样本预测相关研究 18
2.4 多模态预训练相关研究 20
2.5 本章小结 23
第 3 章 多模态零样本蛋白质功能预测模型 24
3.1 引言 24
3.2 数据集的构建与预处理 24
3.2.1 有监督训练集和零样本测试集构建 24
3.2.2 数据集统计 25
3.2.3 多模态特征编码 26
3.3 多模态零样本预测模型 27
3.3.1 特征投影与特异性丢弃 27
3.3.2 自适应门控融合机制 30
3.3.3 优化目标 31

3.4 实验结果及分析 32
3.4.1 对比实验结果与分析 32
3.4.2 消融实验结果与分析 38
3.4.3 参数敏感性分析 42
3.4.4 嵌入空间可视化分析 43
3.4.5 自适应门控权重分析 44
3.4.6 层级一致性分析 45
3.5 本章小结 47
第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA 48
4.1 引言 48
4.2 域感知适配器预训练任务构建 49
4.2.1 问题动机与设计目标 49
4.2.2 域感知对比学习任务 49
4.3 MZSGO-DA 模型设计 49
4.3.1 总体框架 49
4.3.2 适配器模块与注入机制 50
4.3.3 域感知对比学习预训练 51
4.3.4 双适配器端到端下游训练 52
4.4 实验结果及分析 54
4.4.1 对比实验结果与分析 54
4.4.2 消融实验结果与分析 56
4.4.3 预训练过程分析 57
4.4.4 参数效率分析 57
4.5 本章小结 57
结 论 59
参考文献 61
攻读硕士学位期间取得创新性成果 65
哈尔滨工业大学学位论文原创性声明和使用权限 66
致 谢 67

第 1 章 绪论

1.1 课题研究背景和意义

1.1.1 课题研究背景

蛋白质是生命活动的重要执行者，是基因表达的直接产物，也是构成生命体和维持细胞正常生命活动的关键物质基础[1]。在细胞内，蛋白质广泛参与物质运输、能量代谢、信号转导、免疫应答、细胞分裂及基因表达调控等过程，其功能状态直接影响细胞命运和个体表型。从催化反应的酶，到承担支撑作用的结构蛋白；从执行免疫识别的抗体，到介导细胞通信的受体和激素，蛋白质几乎参与了所有重要的生命过程。因此，深入理解蛋白质的结构特征及其功能机制，不仅有助于揭示生命活动的基本规律，也对疾病机理研究、药物研发、酶工程改造和合成生物学设计等领域具有重要意义。

从经典分子生物学观点看，蛋白质通常遵循" 序列-结构-功能" 的规律，即氨基酸序列决定空间结构，而结构进一步影响功能。蛋白质一级结构中的氨基酸排列经局部折叠可形成 α 螺旋、β 折叠等二级结构，进而构成稳定的三级结构，部分蛋白质还会通过多条肽链组装形成四级结构。正是序列组成、折叠方式和空间构象的高度多样性，奠定了蛋白质功能多样化的分子基础。因此，如何从序列、结构及相关信息中准确推断蛋白质功能，一直是生物学与生物信息学研究的核心问题。

近年来，高通量测序、质谱和结构生物学技术迅速发展，蛋白质相关数据正以前所未有的速度积累。研究者已能便捷获取大规模序列数据，并不断从实验数据库和预测平台中获得丰富的结构信息。尤其是 AlphaFold2[2] 在结构预测任务上的突破，大幅降低了高精度结构信息的获取门槛，使以往难以开展的大规模结构辅助分析成为可能。这一进展不仅推动了结构研究，也为功能预测提供了新的信息来源。

然而，与序列和结构数据的快速增长相比，蛋白质功能注释的积累速度仍然相对缓慢[3]。大量蛋白质虽已完成测序，甚至能获得高可靠性的结构信息，但其功能仍缺乏完整、准确的实验标注。传统功能研究主要依赖生物实验验证，虽结果可信度高，但实验流程复杂、周期长，对设备平台和经费均有较高要求[4]。因此，仅依赖实验手段难以满足大规模功能解析的需求。如何借助计算方法进行自动、高效、准确的功能预测，已成为生物信息学的重要研究方向。

为实现蛋白质功能的标准化描述，国际生物信息学界采用基因本体（Gene Ontology, GO）系统进行统一注释[5]。GO 从生物过程（Biological Process, BP）、分子

功能（Molecular Function, MF）和细胞组分（Cellular Component, CC）三个角度刻画蛋白质功能，通过有向无环图组织术语间的层级关系。这一标准化体系为自动预测提供了统一的标签空间，也使不同研究结果具备可比性。但 GO 体系也带来挑战，如术语数量庞大、类别分布不均、层级关系复杂及大量术语缺乏充分标注等。因此，蛋白质功能预测不仅是典型的多标签学习任务，也常伴随标签稀疏、类别长尾和层级依赖等困难。

在此基础上，研究者逐渐认识到，仅依赖单一来源的信息难以全面刻画蛋白质功能。序列中包含丰富的进化保守特征，结构信息反映残基空间关系和功能位点分布，而蛋白质域描述、GO 术语定义及相关数据库文本则提供直接的功能语义知识。这些信息从不同角度揭示蛋白质的生物学属性，彼此具有明显的互补性。随着蛋白质语言模型、结构预测工具和生物医学文本表示方法的发展，如何综合利用序列、结构和文本等多源信息提升功能预测性能，已成为该领域值得深入研究的问题。围绕这一问题开展研究，不仅有助于提高预测的准确性和泛化能力，也为构建更智能高效的自动注释方法奠定基础。

1.1.2 研究目的和意义

蛋白质功能预测的核心任务是揭示序列、结构及相关知识与生物学功能之间的映射关系。随着测序技术和蛋白质组学的发展，序列与结构数据持续增长，而高质量功能注释仍主要依赖耗时昂贵的实验。在此背景下，发展高效、准确且泛化能力强的计算方法，已成为缓解功能注释缺口、提升数据利用效率的重要途径。因此，围绕蛋白质功能预测开展研究，具有明确的问题导向和现实需求。

现有方法大多将任务建模为固定标签集上的多标签分类，主要依赖序列或结构等单一模态信息。这些方法在常见功能类别上取得了一定效果，但仍存在不足。一方面，蛋白质功能并非仅由序列或局部结构决定，蛋白质域描述、GO 术语定义及知识库文本中也蕴含重要功能线索，忽略这些信息会导致模型理解不完整。另一方面，GO 标签空间庞大且呈长尾分布，许多功能类别样本稀缺，传统基于封闭分类的方法在稀有类别和未见术语场景下受限，难以满足自动注释对泛化能力的要求。

此外，传统方法通常将 GO 术语视为彼此独立的离散标签，较少利用术语定义本身的语义信息及功能概念间的关联。这种建模方式虽便于监督训练，但限制了模型对功能本质的表达能力。事实上，蛋白质功能预测不仅是标签判别问题，更可视为蛋白质属性与功能语义的匹配问题。若能统一建模序列、域描述、GO 定义及结构先验等信息，有望在标注不足时借助功能语义进行推断，从而提升对复杂类别和低资源场景的适应能力。

基于上述认识，本文围绕”基于多模态预训练的蛋白质功能预测”展开研究，目标是综合利用序列、域描述、GO 定义及结构先验等多源信息，探索更有效的蛋白质功能建模方法。本文希望通过构建统一表示，使不同来源的功能相关知识在同一框架下互补，从而提升功能预测的整体性能。区别于传统仅依赖离散标签学习的思路，本文更关注蛋白质表示与功能语义表示的对应，增强对稀有类别和未见术语的推断能力，提升模型的泛化性和实用性。

本文的创新性主要体现在研究思路与方法设计两个层面。在研究思路上，本文将蛋白质功能预测从传统的单模态特征学习拓展为多模态语义建模，通过引入蛋白质域文本与 GO 术语定义，使模型不再局限于已有标注信号的监督信号，而是能够借助功能概念本身的语义信息进行推断。这种建模方式为蛋白质表征学习与知识融合提供了新的视角，也为应对开放标签预测、低资源功能推断等挑战性场景探索了可行路径。

在方法层面，多模态建模为缓解标签稀疏、类别长尾以及信息利用不充分等问题提供了新的解决思路。序列、结构先验与文本语义在生物学层面具有天然互补性，通过构建合理的学习框架实现多源信息的有效融合，能够增强模型在复杂任务场景下的稳健性与预测能力。此外，这一思路也为将多源知识高效整合至蛋白质智能分析系统积累了方法经验，对后续相关研究具有参考价值。

从应用价值来看，准确的功能预测可为药物靶点发现、疾病机制解析、酶功能挖掘及合成生物学设计等实际任务提供重要支撑。面对实验资源有限、待注释蛋白质数量持续增长的现状，具备良好泛化能力的预测模型有助于提升自动注释效率，缩短从蛋白质发现到功能解析的研究链路。尤其对于新发现的蛋白质、样本稀有的功能类别以及标注不足的功能术语，若模型能够结合多源信息做出合理推断，将进一步提升自动注释系统的实用性与适用范围。综上所述，围绕多模态预训练开展蛋白质功能预测研究，兼具学术探索价值与实际应用意义。

1.2 国内外研究现状

蛋白质功能预测是生物信息学中的经典问题，CAFA（Critical Assessment of Function Annotation)[6] 挑战赛是该领域最具代表性的国际评测平台。围绕这一任务，国内外研究已经从早期的序列同源性转移，逐步发展到结构建模、多模态融合以及多模态预训练驱动的开放语义预测。总体来看，国外研究起步较早，在同源比对、知识本体建模和大规模预训练方面积累了系统方法；国内学者近年来则在结构增强建模、多模态融合、轻量级适配器预训练和任务特定优化方面取得了较快进展。根据所依赖信息来源和建模范式的不同，现有研究大致可以分为以下三类。

1.2.1 基于蛋白质序列的功能预测方法

基于蛋白质序列的方法是自动功能预测最早也是最基础的技术路线。早期工作主要建立在" 序列相似则功能相似" 的假设之上。BLAST[7] 通过局部序列比对在已知数据库中检索同源蛋白，并将同源蛋白的功能注释迁移至待测蛋白；Diamond[8] 则在保持较高灵敏度的同时显著提升了检索效率，更适用于大规模蛋白质数据库分析。这类方法在存在近缘同源序列时往往表现稳定，且具有较强可解释性，因此在 CAFA 等评测中长期作为重要参照基线存在。然而，当待测蛋白缺乏足够相似的同源序列时，这类方法的预测性能会迅速下降，尤其难以处理远同源功能迁移和长尾功能类别。

随着机器学习和深度学习的发展，研究者开始尝试直接从氨基酸序列中自动提取功能相关特征，以减少对显式比对的依赖。DeepGO[9] 结合序列和互作信息进行本体感知分类，将 GO 层级关系纳入预测框架；如图 1-1所示，DeepGOPlus[10] 采用一维卷积网络直接从氨基酸序列中提取局部基序特征，是基于序列进行功能预测的代表性框架之一。国内学者提出的 HiFun[11] 则将蛋白质视为一种特殊语言，通过卷积网络与自注意力 BiLSTM 联合建模序列上下文信息，在无同源信息条件下仍能够学习到有判别力的功能模式。这些工作表明，序列中蕴含的局部保守片段、上下文依赖和统计规律能够支持有效的功能推断。

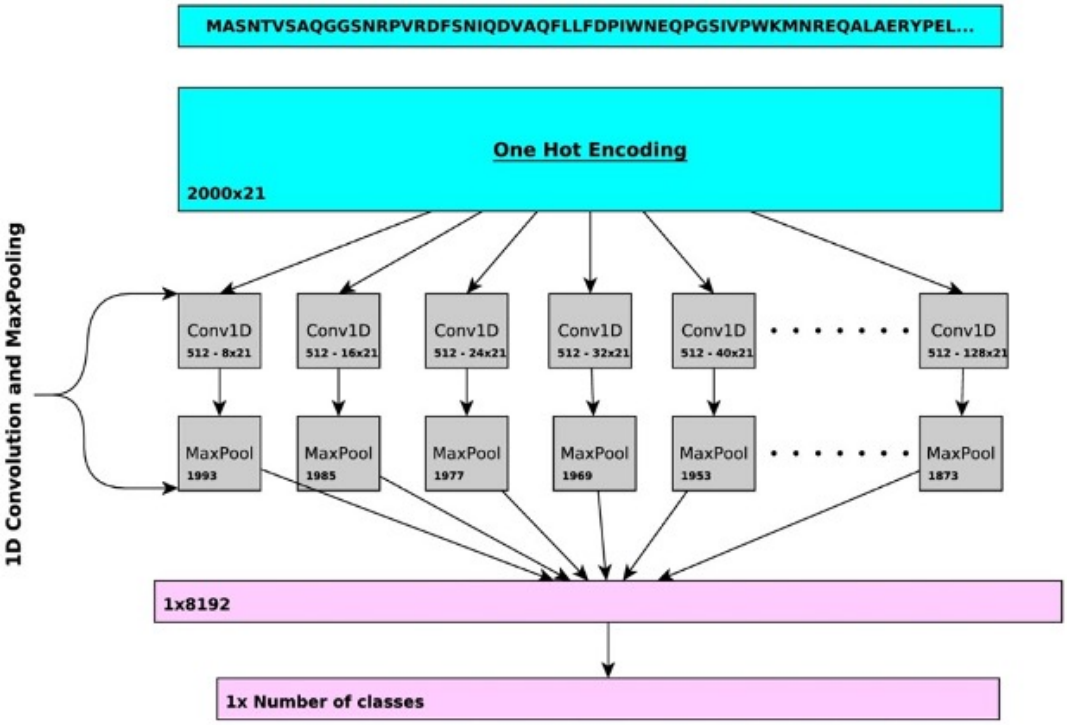

图 1-1: DeepGOPlus 模型概览图[10]

近几年，蛋白质语言模型（Protein Language Model, PLM）推动了基于序列的方法进入预训练时代。以 ESM-2[12] 为代表的大规模模型通过掩码语言建模在海量蛋白质序列上进行自监督训练，能够提取包含进化约束、理化模式以及潜在结构偏好的高质量表示。与传统人工特征不同，预训练模型能够在不依赖特定任务标签的前提下学习通用蛋白质表示，再通过微调或特征迁移服务于下游功能预测任务。正因如此，序列预训练已经成为当前多数方法的重要基础组件，也是后续多模态预训练方法得以成立的前提。

进一步看，基于序列的方法在工程实现上具有输入统一、覆盖范围广和推理成本相对可控等优势，因此仍然是蛋白质功能预测研究的主干路线。特别是在真实应用场景中，序列往往是最易获取、最稳定也最标准化的数据源，这使得基于序列的方法具备良好的可扩展性和部署潜力。对于大规模初筛、数据库自动更新和在线注释服务而言，序列模型通常具有更高的实用价值。

然而，单纯依赖序列信息仍然难以显式建模结构约束、GO 语义层级以及蛋白质域文本知识。一些蛋白质虽然序列差异明显，但在结构折叠、活性位点或功能机制上可能具有高度相似性；另一些蛋白质则表现为序列相近而功能不同，此时仅从序列统计规律出发往往难以作出精细区分。此外，纯序列模型通常仍停留在封闭标签分类范式中，对未见功能术语、极少样本类别以及语义相近标签之间的关系利用不足。因此，基于序列的方法虽然奠定了蛋白质功能预测的基础，但也促使研究者进一步探索结构模态和多模态信息融合策略。

1.2.2 基于蛋白质结构的功能预测方法

蛋白质的三维结构与其功能密切相关，因此利用结构信息进行功能预测是另一条重要研究路线。与序列相比，结构能够更直接反映活性位点的空间几何关系、残基邻接模式、结合口袋形状以及远距离相互作用信息，因此在酶活性识别、配体结合分析和相似功能区分等场景中具有独特优势。特别是当不同蛋白质在序列层面相似度较低但共享相似折叠时，结构模态往往比序列模态更能体现功能保守性。

AlphaFold2[2] 在蛋白质结构预测领域取得突破后，其对应数据库已覆盖大规模蛋白质结构空间[13]，极大推动了结构驱动功能预测方法的发展。过去限制结构方法普及的主要瓶颈之一，在于高质量实验结构获取困难且成本较高；而 AlphaFold2 使得研究者可以在更大范围内获得可用于建模的三维结构，从而推动结构图神经网络、接触图学习和结构增强预训练等方向迅速发展。可以说，结构预测能力的进步重新塑造了蛋白质功能预测的输入范式。

DeepFRI[14] 将蛋白质结构表示为接触图，并结合图卷积网络学习结构拓扑与序列残差信息，是结构功能预测中具有代表性的工作。该方法通过将残基视为图

节点、空间接触关系视为图边，在图卷积传播过程中显式捕获局部结构与远程依赖，从而提升了功能注释精度。HEAL[15] 在此基础上进一步引入分层图转换器和对比学习机制，利用 AlphaFold2 结构增强蛋白质图表示，并通过层次化编码更好地兼顾局部几何模式与全局拓扑结构。这类方法说明，结构模态不仅可以作为序列的补充信息，更可以成为独立且高价值的功能判别依据。

国内学者提出的 Struct2GO[16] 则进一步体现了结构建模与序列建模协同融合的思路。如图 1-2所示，该方法构建了结合序列与结构的图池化框架，通过层次化图池化和 Node2vec[17] 初始化来捕获蛋白质结构网络中的关键局部与全局模式，实现了较为准确的功能注释。该工作表明，结构图不仅能够表示残基之间的空间邻接，还能够在池化过程中逐步抽取更高层次的功能相关结构单元，从而增强模型对复杂结构模式的理解能力。

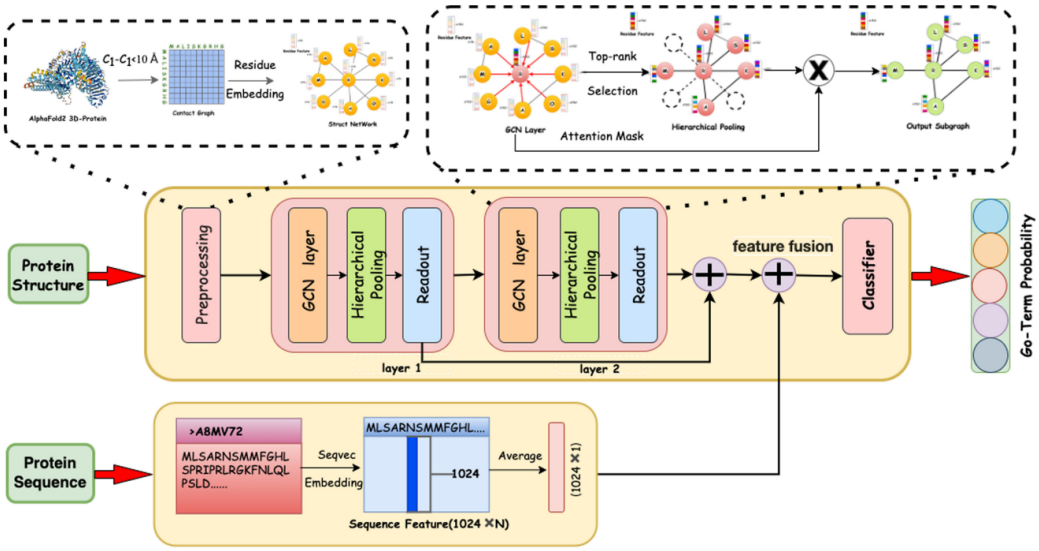

图 1-2: Struct2GO 模型概览图[16]

从研究趋势看，基于结构的方法正在从”直接利用结构图进行监督学习”逐步走向”将结构知识注入预训练表示”。也就是说，结构模态不再只是作为下游任务时的附加输入，而越来越多地被用于增强序列编码器本身的表示能力。结构感知预训练、对比学习对齐和跨模态知识蒸馏等思路，已经成为连接结构方法与多模态预训练方法的重要桥梁。

总体而言，基于结构的方法能够在一定程度上弥补序列相似性不足带来的功能歧义，尤其对高序列相似但功能存在差异的蛋白质更具优势。然而，这类方法依赖结构预测质量，计算开销较大，对缺乏可靠结构或长序列复杂构象蛋白质的适用性仍受限制。此外，结构信息虽然能反映空间模式，却并不天然包含 GO 术语文本语义、蛋白质域功能描述和知识本体约束，因此仅依靠结构模态仍难以全面

解决功能预测问题。这也推动研究者进一步探索多模态信息融合与多模态预训练范式。

1.2.3 基于多模态信息融合的功能预测方法

为了克服单一模态的表达瓶颈，研究者开始融合序列、结构、网络、文本和本体知识等多源信息，形成多模态蛋白质功能预测框架。相较于传统只关注一个输入空间的模型，多模态方法更强调”互补性”：序列反映进化和局部模式，结构体现空间约束，PPI 网络提供生物学上下文，GO 本体携带层级知识，而文本定义和域描述则显式编码功能语义。正因如此，多模态信息融合已成为当前蛋白质功能预测最活跃的发展方向之一。

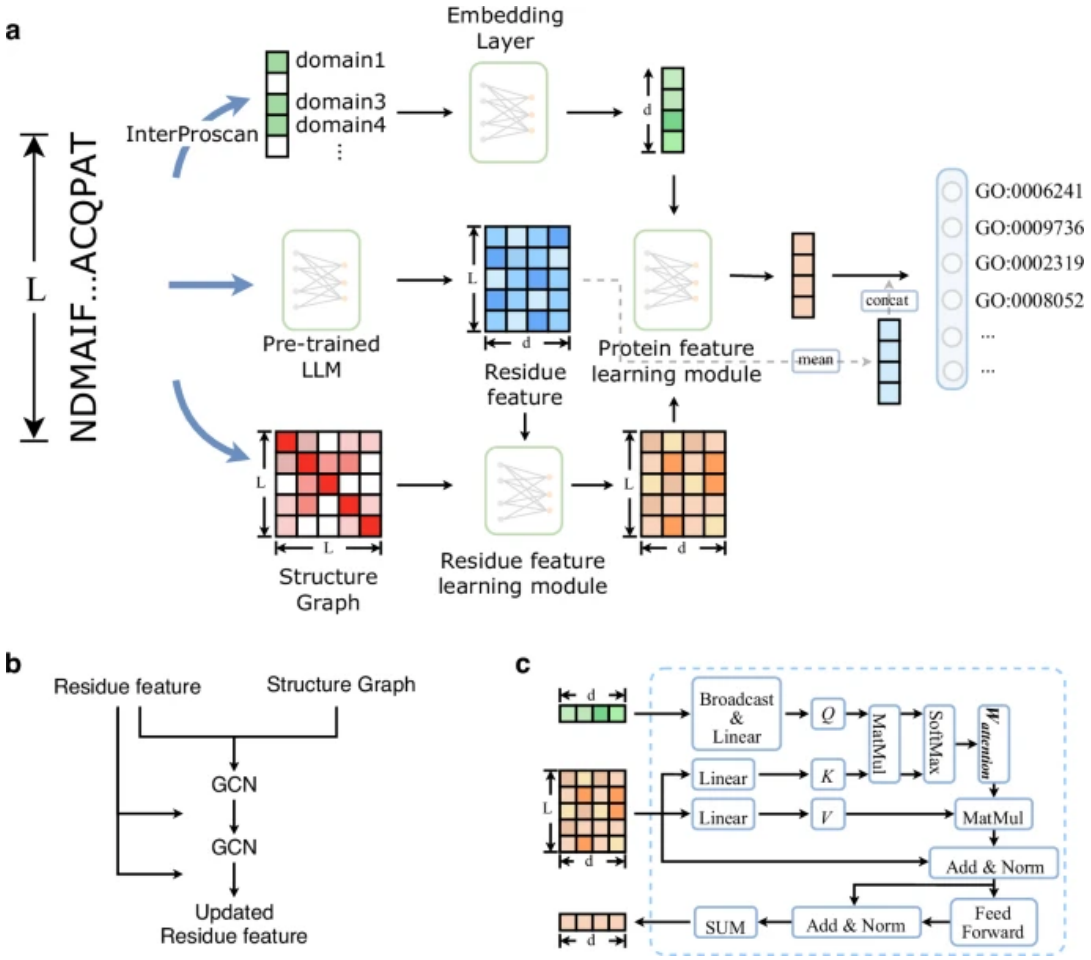

图 1-3: DPFunc 模型概览图[18]

在网络与本体知识融合方面，DeepGraphGO[19] 利用 InterProScan[20] 生成的蛋白质特征并结合多物种 PPI 网络，通过图神经网络建模高阶互作关系，说明网络上下文能够为蛋白质功能预测提供重要补充。DeepGOZero[21] 进一步利用 GO 本

体公理和 EL Embedding[22] 实现了零样本功能预测，表明结构化知识对开放标签推断具有重要价值。DeepGO-SE[23] 则在此基础上引入预训练蛋白质语言模型和神经符号语义蕴涵机制，增强了模型对 GO 语义层级的推理能力。PO2GO[24] 通过偏序嵌入进一步强化了对 GO 层级关系的建模，体现出标签空间结构对预测质量的重要影响。

在多特征融合架构方面，研究者进一步探索如何更细粒度地整合序列、结构和功能相关描述。ProtGO[25] 联合使用序列表示、结构特征、GO 本体嵌入和文本描述，通过多源协同提升模型的功能辨识能力；DPFunc[18] 显式引入蛋白质域信息，如图 1-3所示，将结构域视为功能基序参与预测，体现出蛋白质域在解释功能差异方面的重要价值；CFAGO[26] 则采用预训练-微调两阶段策略交叉融合 PPI 网络和蛋白质属性信息，验证了预训练对于多模态融合性能提升的重要作用。ProtNote[27] 进一步提出了一种多模态方法，如图 1-4所示，通过将蛋白质序列与 GO 功能标签的自然语言描述进行联合建模，支持在开放标签空间上进行灵活的功能注释。这些工作说明，多模态融合不应停留在简单拼接层面，而需要围绕模态间的相关性、可靠性和互补性设计更有针对性的交互机制。

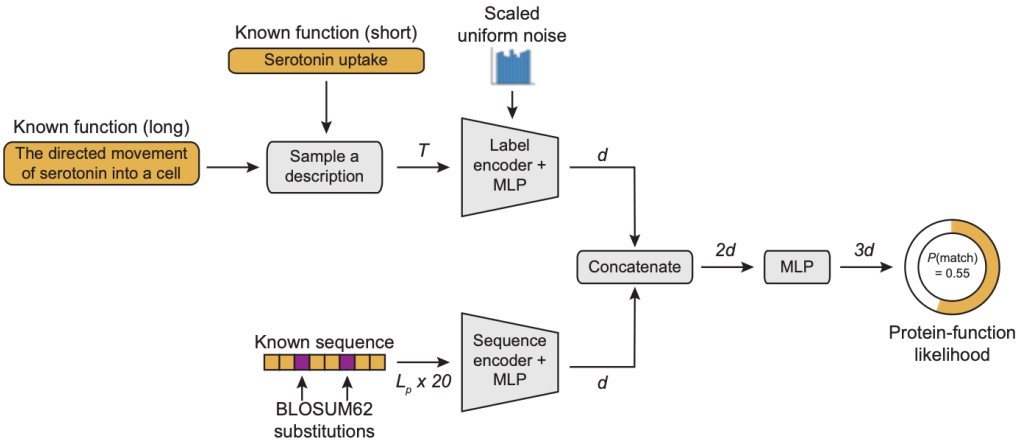

图 1-4: ProtNote 模型概览图[27]

随着大语言模型和跨模态学习的发展，文本语义逐渐成为蛋白质功能预测中的关键补充信息。DeepText2GO[28] 较早尝试将深层语义文本表示引入蛋白质功能预测，通过文本分类器与序列分类器的概率融合提升大规模预测性能，为后续文本增强方法提供了早期思路。OntoProtein[29] 进一步将 GO 结构嵌入蛋白质预训练过程，构建蛋白质-GO 知识图谱并通过知识感知负采样的对比学习联合优化蛋白质与本体表示，体现出”知识增强的蛋白质预训练”这一重要方向。ProtST[30] 则将蛋白质序列与生物医学文本进行多模态联合学习，通过单模态掩码预测、多模态表示对齐和多模态掩码预测等任务，在保留序列模型原有能力的同时增强了对功

能文本的理解，并支持零样本分类与蛋白质检索。这些工作表明，文本不再只是辅助说明，而是可以作为功能知识的显式载体参与蛋白质表征学习。

从更广义的多模态预训练角度看，MASSA[31] 构建了统一整合序列、结构和功能注释的多任务预训练框架，通过任务定制化设计使模型能够在不同下游任务之间共享更具生物学含义的表示。与一般的监督融合方法相比，这类框架更强调在预训练阶段就建立模态间的共享语义空间，从而提高表示的可迁移性和下游适应性。对于蛋白质功能预测而言，这意味着模型不必完全依赖目标数据集中的标注样本，而可以从更大规模的多模态数据中吸收通用知识。

在结构知识蒸馏与轻量级适配方面，S-PLM[32] 展示了另一条极具启发性的技术路线。如图 1-5所示，该方法在蛋白质语言模型内部注入适配器模块，并通过对比学习将三维结构表示蒸馏到序列编码器中，使模型在推理阶段仅凭序列输入即可生成包含结构感知信息的表示。与直接在下游阶段额外输入结构不同，这种做法强调通过预训练把跨模态知识” 内化” 到序列模型内部，从而兼顾性能、鲁棒性和部署效率。

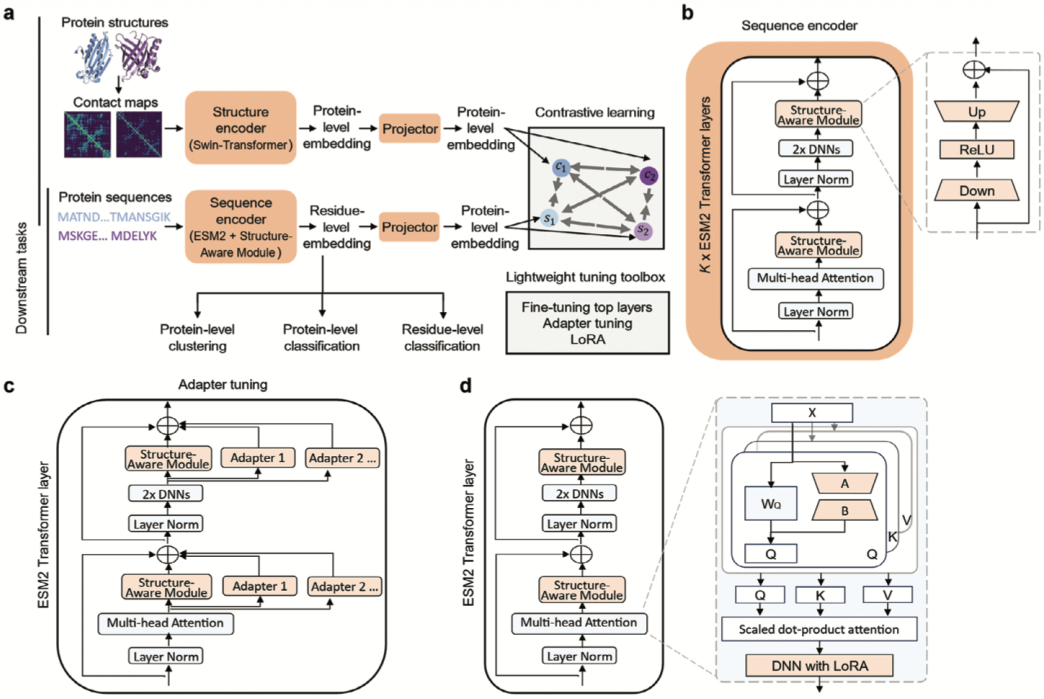

图 1-5: S-PLM 模型概览图[32]

在更强调生成式语义表达的方向上，相关研究进一步突破了传统标签分类范式。Prot2Text[33] 将蛋白质功能预测从预定义标签分配扩展为自由文本生成功能描述，通过图神经网络与 Transformer 联合建模序列、结构和文本信息，使模型能够

输出更细粒度的自然语言功能说明。Prot2Text-V2[34] 进一步引入多模态对比对齐机制，采用更强的蛋白质语言模型和大语言模型解码器，并在低同源性设定下表现出更强的泛化能力，反映出”序列到文本”的生成式路线正在成为开放语义功能预测的重要趋势。PAIR[35] 则从另一角度证明了文本监督信号的重要性：该工作利用 UniProt 中的 19 类文本注释对蛋白质模型进行微调，显著增强了蛋白质表示的预测能力，甚至在部分功能相关任务上超越了传统的 BLAST 工具。上述工作共同说明，文本模态不仅可用于解释模型输出，还可直接作为提升蛋白质表示质量的训练信号。

从国内外研究现状来看，多模态方法已经从”多源特征融合”逐渐演进到”多模态预训练驱动的开放语义预测”。国外研究在知识图谱预训练、文本-序列对齐和生成式预测方面形成了较为完整的技术谱系；国内学者则在结构增强、域感知融合、两阶段预训练以及轻量级适配器建模等方面做出了具有代表性的工作，如 Struct2GO、CFAGO、DPFunc 和 S-PLM 等。这些成果共同说明，多模态预训练已经成为蛋白质功能预测领域的重要发展趋势。

尽管如此，现有研究仍存在若干突出问题。第一，不少方法虽然引入多种模态，却仍以简单拼接或浅层交互为主，难以充分建模不同模态之间的深层互补关系。第二，对 GO 文本定义、蛋白质域描述等语义知识的利用仍然不够充分，许多模型仍然将其视为附属信息而非核心知识来源。第三，多数方法受限于封闭标签空间，对未见功能术语、长尾类别和低同源样本的泛化能力仍然不足。第四，如何将域语义等功能先验稳定蒸馏到序列编码器内部，并在保持端到端训练能力的同时兼顾部署效率，仍缺乏成熟而有效的技术路径。这些问题构成了本文工作的直接研究动机，也说明围绕多模态预训练开展蛋白质功能预测研究具有明确的现实必要性。

1.3 本文的主要研究内容

围绕上述问题，本文以多模态预训练为主线，重点开展以下两方面研究，并按照”先做开放语义匹配，再做预训练表示增强”的技术路线逐步推进。

（1）多模态零样本蛋白质功能注释方法。本文将蛋白质功能预测定义为”蛋白质-GO”语义匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用文本嵌入模型统一编码蛋白质域描述和 GO 功能定义，并通过自适应门控融合机制建模多模态信息之间的共享上下文关系。同时，引入非对称特征丢弃策略增强模型在模态缺失场景下的鲁棒性，使模型能够在有监督和零样本场景下实现兼顾精度

与泛化性的预测。该方法的核心目标，是打破传统封闭标签分类框架对训练标签集合的依赖，将功能预测转化为开放语义空间中的匹配问题。

具体而言，该方法重点解决两个难点：一是如何让序列信息、蛋白质域语义和 GO 定义语义在统一空间中实现可比较、可对齐的表示；二是如何在模态信息不完整的情况下仍然保持稳定预测。为此，本文在表示学习层面引入统一投影空间，在融合层面设计动态门控机制，并在训练层面采用增强鲁棒性的特征扰动策略，从而提升模型对复杂样本和未见标签的适应能力。

（2）基于域感知适配器预训练的端到端蛋白质功能预测方法。在前述工作基础上，本文进一步针对通用序列编码器缺乏功能先验的问题，设计轻量级适配器模块注入蛋白质语言模型内部，通过 InfoNCE 对比学习将蛋白质域语义蒸馏到序列表示中，并在下游任务阶段采用双适配器策略实现端到端训练。该方法旨在将多模态预训练阶段学到的功能知识更稳定地保留在序列编码器内部，进一步提高蛋白质功能预测效果。

与直接使用静态序列嵌入的方法相比，该方法更加关注”预训练知识如何进入编码器本体”这一问题。通过将域语义蒸馏至适配器，模型可以在不大幅增加主干参数量的情况下获得功能先验；通过在下游阶段采用双适配器结构，又能够在保留预训练知识的同时进行任务特定调整。这种设计兼顾了表示可迁移性、训练灵活性和部署成本，体现了多模态预训练在蛋白质功能预测任务中的工程价值。

总体而言，本文的研究内容可以概括为：从”多模态语义融合”和”域感知预训练增强”两个递进方向，系统探索蛋白质功能预测中的多模态预训练方法，以提升模型在复杂功能类别、长尾标签和未见功能术语上的预测能力。前者面向开放语义匹配问题，强调不同知识源之间的表示对齐与鲁棒融合；后者面向预训练知识内化问题，强调如何将跨模态知识稳定注入序列编码器。两项工作既相互独立又层层递进，共同构成本文的研究主线。

1.4 本文的组织结构

本文共分为四章，外加结论与展望部分，各章内容安排如下：

第一章为绪论。首先介绍蛋白质功能预测的研究背景，阐述蛋白质功能注释面临的数据增长与标注滞后之间的矛盾，说明多模态预训练方法的研究意义。随后从基于序列、基于结构和基于多模态信息融合三个方面系统梳理国内外研究现状，并在此基础上明确本文的研究问题与技术路线。

第二章为蛋白质功能预测的相关研究概述。首先给出蛋白质功能预测问题的形式化定义，介绍基因本体系统及常用评价指标。随后围绕本文涉及的两项核心

技术——零样本预测与多模态预训练，分别梳理相关研究进展，为后续两章的模型设计提供理论基础和方法参考。

第三章为多模态零样本蛋白质功能预测模型。本章将蛋白质功能预测重新定义为蛋白质与 GO 术语之间的语义匹配问题，详细介绍数据集的构建与预处理流程、多模态特征编码方式，以及包含特征投影、特异性丢弃、自适应门控融合和优化目标在内的模型设计。通过有监督和零样本两种设定下的对比实验、消融实验、参数敏感性分析、嵌入空间可视化、门控权重分析和层级一致性分析，系统验证了多模态语义融合范式的有效性。

第四章为基于域感知适配器预训练的端到端蛋白质功能预测模型。本章在第三章工作的基础上，针对静态嵌入策略的信息瓶颈与梯度断裂问题，提出在蛋白质语言模型内部注入轻量级适配器模块，通过域感知对比学习预训练将蛋白质域语义蒸馏到序列编码器中，并采用双适配器策略实现端到端训练。通过对比实验、消融实验、预训练过程分析和参数效率分析，验证了预训练知识蒸馏对功能预测性能的提升作用。

最后为结论与展望部分。对本文提出的两个模型的主要贡献进行总结，分析现有方法在结构信息融入、语义推理能力、端到端文本编码、零样本评估规模和训练效率等方面的局限，并对未来可能的研究方向进行展望。

第 2 章 蛋白质功能预测的相关研究概述

2.1 引言

蛋白质功能预测（Protein Function Prediction, PFP）是生物信息学领域的重要研究方向，其目标是利用计算方法为尚未充分注释的蛋白质自动分配功能标签。随着高通量测序、结构预测和数据库建设的快速发展，蛋白质序列、结构、互作网络以及文本知识等多种类型的数据正以前所未有的速度积累，但实验功能注释的增长速度远远滞后于原始数据的生成速度[3,4]。在这一背景下，如何从多源异构数据中提取有效信息，并构建具有良好泛化能力的预测模型，已经成为该领域的核心问题。

从研究范式演进来看，蛋白质功能预测经历了从同源比对、浅层机器学习、深度神经网络到基础预训练模型的持续发展。早期方法更多依赖序列相似性和人工构造特征，其性能在存在近缘同源蛋白时较为稳定，但对远同源蛋白、稀有功能类别以及新出现的 GO 术语缺乏足够的适应能力。近年来，随着 AlphaFold2[2] 和 ESM-2[12] 等模型的出现，研究者开始利用蛋白质结构、蛋白质语言模型表示和文本语义知识提升功能预测性能，问题本身也逐渐从封闭标签分类拓展到开放语义推理和跨模态表示学习。

尤其值得关注的是，**零样本预测**与**多模态预训练**已经成为当前蛋白质功能预测中最具代表性的两条研究主线。前者关注模型如何在训练过程中从未见过某些功能标签的情况下，仍能对其做出合理预测；后者则关注如何在预训练阶段联合利用序列、结构、网络和文本等多种模态，构建更具迁移性和生物学语义的蛋白质表示。这两条主线与本文第三章和第四章的方法设计高度相关，因此有必要在本章中对其进行系统梳理。

从已公开的相关学位论文结构来看，第二章通常承担两项任务：一是对研究问题本身进行规范定义，明确后续方法与实验所依赖的任务设定和评价口径；二是对与本文关系最紧密的研究方向进行归纳总结，而不是简单罗列所有相关技术。基于这一思路，本章不再按单个基础模型或单个数学工具逐项展开，而是围绕本文真正关注的“问题定义—零样本预测—多模态预训练”三条主线组织内容，使第二章更贴近后续章节的研究需求，也更符合综述型章节的写作方式。

基于此，本章首先从任务本身出发，介绍蛋白质功能预测问题的定义及常用评价指标；随后总结零样本预测相关研究的发展脉络；接着讨论多模态预训练相

关研究的主要技术路线及其局限性；最后给出本章小结，为后续章节的方法设计与实验分析奠定理论和问题背景基础。

2.2 蛋白质功能预测问题

2.2.1 蛋白质功能预测问题的定义

蛋白质功能预测通常以基因本体（Gene Ontology, GO）[5] 作为标准化注释体系。GO 将蛋白质功能划分为生物过程（Biological Process, BP）、分子功能（Molecular Function, MF）和细胞组分（Cellular Component, CC）三个相互独立但内部结构复杂的子本体。每个 GO 术语不仅具有标准化名称和文本定义，还通过“is_a”和“part_of”等关系组织成有向无环图（Directed Acyclic Graph, DAG）[36]。这种层级结构使蛋白质功能预测区别于普通的多标签分类任务：不同标签之间存在明确的祖先—后代依赖关系，且越接近叶节点的术语语义越具体、样本越稀疏。

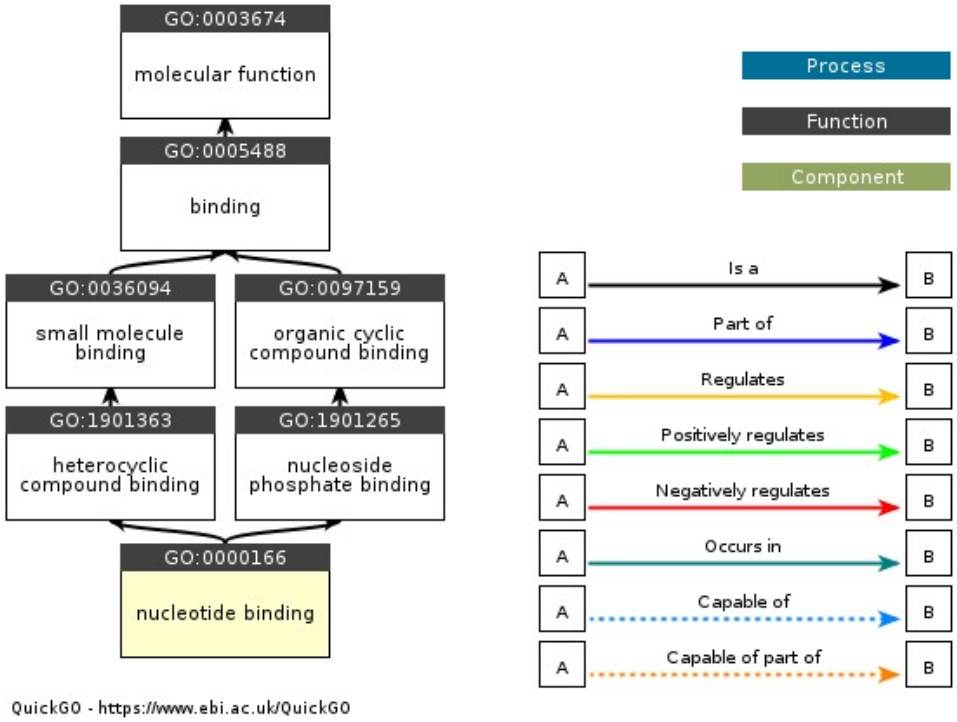

图 2-1: GO 树状层级结构示例。GO 系统以有向无环图（DAG）的形式组织功能术语之间的层级关系，三个子本体（BP、MF、CC）分别形成独立的 DAG 结构。子节点是父节点的具体化，节点间通过”is_a” 和”part_of” 关系连接。

在 GO 体系下，一个蛋白质通常对应多个功能标签，因此蛋白质功能预测首先是一个典型的多标签学习问题。设蛋白质样本集合为 $\mathcal{P} = \{P_1, P_2, \ldots, P_N\}$，某

一 GO 子本体对应的候选功能标签集合为 $\mathcal{G} = \{g_1, g_2, \ldots, g_C\}$，其中 C 表示该子本体中候选 GO 术语的总数，则传统蛋白质功能预测任务可表示为：对于每个蛋白质 P_i，预测其对应的标签向量

$$\hat{\mathbf{y}}_i = [\hat{y}_{i1}, \hat{y}_{i2}, \ldots, \hat{y}_{iC}] \in [0, 1]^C, \tag{2-1}$$

其中 $\hat{y}_{ic}$ 表示蛋白质 P_i 具有功能术语 g_c 的预测概率。若训练集和测试集共享同一组功能标签，则该问题可被视为封闭标签空间下的多标签分类问题。

然而，与自然图像或普通文本分类不同，蛋白质功能预测还具有四个鲜明特点。第一，GO 标签呈现显著的长尾分布，大量细粒度术语仅对应极少数样本，导致模型容易偏向高频标签。第二，GO 本体本身处于持续更新之中，新术语不断被引入而旧术语可能被合并或废弃，这意味着真实应用场景中的标签空间并非静态不变。第三，蛋白质功能并不完全由单一模态决定，而往往需要综合序列保守性、结构折叠、蛋白质域组成、互作关系及功能文本知识等多种因素进行判断。第四，现有数据库中的功能标注本身具有不完全性，即“未被标注”并不总等价于“真实不存在该功能”，这使得蛋白质功能预测还隐含着弱监督和标签噪声问题。因此，简单地将问题理解为固定标签集合上的分类任务，已难以充分刻画其本质。

在 GO 数据处理中，真实路径规则（True Path Rule）具有关键作用。若一个蛋白质被标注了某个 GO 术语，则按照本体层级关系，它也应被视为具有该术语所有祖先节点所代表的更一般功能。这意味着训练数据和评估标签通常需要进行向上传播，以避免标签不一致问题；同时，这也要求模型在预测时不仅要判断单一标签是否成立，还要兼顾标签之间的层级一致性。对零样本预测任务而言，标签的层级结构和文本语义更是模型推理未见类别的重要基础。

从任务建模视角出发，现有蛋白质功能预测方法大致可分为两类。第一类是**封闭标签空间的多标签分类**，即将每个 GO 术语视为固定输出维度中的一个二分类单元，模型直接学习从蛋白质输入到标签概率的映射。这类方法结构清晰、训练方便，在标签空间稳定时表现较好，但天然难以处理训练中从未出现的功能术语。第二类是**开放语义空间中的蛋白质—标签匹配**，即将标签也作为可编码对象，学习蛋白质表示与标签语义表示之间的匹配函数。显然，第二类建模方式更适合零样本预测和时间演进场景，也是近年来零样本预测与多模态预训练研究重点发展的方向。

随着文本语义建模和多模态表示学习的发展，越来越多的研究开始将蛋白质功能预测重新定义为“蛋白质—功能标签”匹配问题，而不仅仅是对固定输出维度进行分类。设 P 表示蛋白质输入，g_c 表示第 c 个 GO 术语的文本定义或语义表示，则模型可以直接学习二者之间的匹配分数：

$$s(P, g_c) = p(y = 1 \mid P, g_c). \tag{2-2}$$

这种建模方式能够自然支持开放标签空间推理：即使某个 GO 术语在训练阶段从未出现过，只要其文本定义可用，模型就有机会依据语义相似性为其生成预测结果。这一思想构成了零样本蛋白质功能预测和本文第三章方法设计的基本出发点。

进一步地，在广义零样本场景下，通常将标签空间划分为已见标签集合 $\mathcal{G}_s$ 与未见标签集合 $\mathcal{G}_u$，其中 $\mathcal{G}_s \cap \mathcal{G}_u = \varnothing$。模型需要同时在 $\mathcal{G}_s$ 和 $\mathcal{G}_u$ 上完成预测，而不仅仅在未见标签子集上单独推理。这种设定比“纯零样本”更接近真实应用环境，因为真实数据库中已知标签和新增标签总是同时存在。对本文而言，这也意味着所提出的方法既要在已见标签上维持有监督预测性能，又要对新增或稀有术语表现出足够的泛化能力。

从输入数据形态看，蛋白质功能预测也已经从单一序列输入逐步扩展为多模态建模问题。传统模型多依赖蛋白质序列或 PPI 网络，而当前研究越来越强调整合三维结构、蛋白质域描述、GO 文本定义、知识图谱和自然语言注释等异构信息。不同模态之间具有显著的互补性：序列提供进化和局部模式，结构体现空间约束，功能文本提供显式语义，本体结构提供概念层级约束，蛋白质域描述则在蛋白质侧和功能侧之间起到天然桥梁作用。如何在问题定义层面同时兼顾多标签预测、开放标签推理与多模态融合，已经成为当前蛋白质功能预测研究的重要方向。

2.2.2 蛋白质功能预测的评价指标

由于蛋白质功能预测具有多标签、类别不平衡和零样本泛化等特点，其评价指标不能简单照搬普通分类任务中的准确率。当前研究中最常用的评估方案，主要遵循 CAFA（Critical Assessment of Function Annotation）挑战赛[6] 的蛋白质中心评价协议，并结合零样本场景引入针对已见和未见标签的细化指标。

对于任意给定阈值 $t \in [0, 1]$，设模型为每个蛋白质输出一组 GO 术语预测概率，经阈值化后得到预测标签集合 $\hat{Y}_i(t)$，真实标签集合记为 Y_i。在蛋白质中心评价下，可分别定义平均精确率和平均召回率为：

$$\mathrm{Pr}(t) = \frac{1}{N} \sum_{i=1}^{N} \frac{|Y_i \cap \hat{Y}_i(t)|}{|\hat{Y}_i(t)|}, \tag{2-3}$$

$$\mathrm{Rc}(t) = \frac{1}{N} \sum_{i=1}^{N} \frac{|Y_i \cap \hat{Y}_i(t)|}{|Y_i|}. \tag{2-4}$$

在此基础上，蛋白质功能预测中最常用的指标之一是 $F_{\max}$，即在所有阈值下 F1 分数的最大值：

$$F_{\max} = \max_{t} \frac{2 \cdot \mathrm{Pr}(t) \cdot \mathrm{Rc}(t)}{\mathrm{Pr}(t) + \mathrm{Rc}(t)}. \tag{2-5}$$

$F_{\max}$ 能够综合反映模型在精确率与召回率之间的平衡能力，因此长期作为 CAFA 等标准评测中的核心指标。

另一项常用指标是 AUPR（Area Under the Precision-Recall Curve），即精确率—召回率曲线下面积。与阈值依赖的 $F_{\max}$ 不同，AUPR 是阈值无关指标，能够从整体上衡量模型在不同阈值下的排序和区分能力。由于蛋白质功能预测中正负样本比例往往高度失衡，AUPR 通常比 AUROC 更能反映模型的真实性能，尤其适合评估稀有功能类别和长尾标签上的表现。因此，在近年来的蛋白质功能预测研究中，AUPR 已成为与 $F_{\max}$ 并列的重要指标。

除蛋白质中心评价外，文献中还存在术语中心（term-centric）评价视角，即分别考察每一个 GO 术语在所有蛋白质样本上的区分能力，再对术语层面的结果进行统计汇总。术语中心指标更适合分析某些具体功能类别的识别效果，但当研究重点在于比较模型对单个蛋白质的整体注释质量时，蛋白质中心指标更符合实际需求。因此，CAFA 及后续大量工作仍以蛋白质中心指标作为主报告口径。本文后续实验也遵循这一原则，以保证与已有研究的可比性。

对于零样本预测任务，仅依赖整体 AUPR 或 $F_{\max}$ 还不足以刻画模型的泛化能力。为此，研究者通常将测试阶段的标签划分为“已见标签”（Seen Labels）与“未见标签”（Unseen Labels），分别计算 Seen AUPR 和 Unseen AUPR。Seen AUPR 反映模型在训练中出现过的功能术语上的识别能力，Unseen AUPR 则反映模型对训练阶段从未见过的新功能术语的推理能力。显然，一个真正具有开放语义泛化能力的模型，不应只在 Seen 标签上维持高性能，而应同时在 Unseen 标签上给出有竞争力的结果。

为了综合衡量模型在已见和未见标签上的平衡表现，许多零样本研究进一步采用 Seen AUPR 与 Unseen AUPR 的调和均值：

$$H = \frac{2 \times \text{Seen AUPR} \times \text{Unseen AUPR}}{\text{Seen AUPR} + \text{Unseen AUPR}}. \tag{2-6}$$

当模型只偏向已见标签而忽视未见标签时，H 值会受到明显抑制；只有当模型在两类标签上都取得较好表现时，H 值才会较高。因此，H 指标在广义零样本功能预测场景中具有重要意义，也是本文第三章实验部分的主要评价指标之一。

此外，评价指标的选择还会受到层级结构和任务目标的影响。由于 GO 标签满足真实路径规则，因此一个模型即使预测到了语义上相关但层级稍有偏差的父节点或子节点，也不应被与完全无关的错误等同看待。正因如此，一些研究尝试引入语义距离、层级一致性或时间演进评估等分析手段，以更细致地考察模型是

否真正学习了功能语义而不仅是标签共现统计规律。对于基于 GO 文本定义的开放标签模型，研究者还常关注跨版本 GO 本体上的表现变化，以验证模型面对新增术语时是否具备稳定迁移能力。这些趋势说明，评价指标体系本身也在随着蛋白质功能预测任务的开放化和多模态化而不断演进。

2.3 零样本预测相关研究

零样本预测（Zero-shot Prediction）是指模型在训练阶段从未见过某些目标标签的正样本，但在测试阶段仍能够根据标签语义、标签结构或其他先验知识对这些标签进行有效预测。在蛋白质功能预测任务中，零样本问题具有天然现实意义：一方面，GO 本体持续扩展，新功能术语不断出现；另一方面，大量稀有功能标签在现有训练集中几乎没有或完全没有标注样本。换言之，零样本预测并非人为附加的困难设定，而是自动功能注释系统在真实应用中必须面对的问题。

早期蛋白质功能预测方法主要建立在同源比对和封闭标签分类基础上，通常只能在训练集中出现过的标签范围内进行预测，因此很难直接支持零样本推理。随着本体建模和知识表示学习的发展，研究者开始尝试利用 GO 术语之间的逻辑关系和层级结构，为未见标签提供额外先验。DeepGOZero[21] 是这一方向中的代表性工作。该方法通过 EL Embedding 将 GO 公理映射到几何空间中，使模型能够利用本体逻辑约束推断训练集中未出现过的功能术语。其核心贡献在于证明：即使某一标签没有直接训练样本，只要其与其他术语之间存在可利用的本体结构关系，模型仍有可能借助逻辑推理进行预测。

在 DeepGOZero 的基础上，后续研究进一步强化了标签空间结构的建模能力。PO2GO[24] 利用偏序嵌入方式刻画 GO 术语之间的层级依赖，通过更符合有向无环图结构的表示空间设计增强了对标签语义关系的建模。DeepGO-SE[23] 则在本体约束基础上引入预训练蛋白质语言模型和神经符号推理机制，将功能预测建模为蛋白质表示与术语语义空间之间的近似蕴涵判断。与仅使用逻辑公理的方法相比，DeepGO-SE 在融合序列预训练表示后具有更强的表达能力，体现出“本体结构 + 预训练表示”联合建模的优势。

从方法论上看，基于本体结构的零样本预测路线具有较强可解释性，因为其推理依据直接来自 GO 术语间的逻辑关系和层级约束。然而，这类方法也存在明显局限。首先，本体逻辑公理的覆盖范围有限，无法完整表达术语文本定义中的细粒度语义差异。其次，本体约束通常更擅长处理标签之间的关系，却未必能够充分增强蛋白质侧表示能力。换言之，仅有“懂标签”的能力，并不保证模型“懂蛋

白质”。因此，后续研究逐渐开始将零样本问题与预训练表示学习、文本语义建模和多模态融合相结合。

除了依赖本体逻辑和层级结构的路线，文本语义建模为零样本蛋白质功能预测提供了新的解决思路。该思路的基本假设是：即使某个 GO 术语在训练中未出现过，只要模型能够理解其文本定义，并将该定义与蛋白质表示映射到同一语义空间，就能够通过语义匹配完成预测。DeepText2GO[28] 较早表明了文本语义在功能预测中的价值，它通过深层文本表示增强传统功能分类器的表现，为后续更彻底的开放语义建模提供了启发。OntoProtein[29] 进一步将 GO 结构和文本信息纳入蛋白质预训练过程，借助知识图谱和知识感知负采样联合学习蛋白质与 GO 概念表示，说明本体知识可以在预训练阶段就参与蛋白质表征构建。

在序列—文本联合学习方面，ProtST[30] 是近年来具有代表性的工作。该方法通过联合建模蛋白质序列和生物医学文本，设计单模态掩码预测、多模态表示对齐和多模态掩码预测等任务，使蛋白质语言模型在保留原有序列建模能力的同时获得更强的功能语义理解能力。ProtST 不仅支持传统下游分类任务，也支持基于文本的零样本分类和蛋白质检索，这表明文本语义不再只是辅助解释，而可以直接作为零样本推断的核心支撑。

大语言模型的发展进一步推动了零样本功能预测研究的进展。ProtNote[27] 尝试将蛋白质序列与文本化功能描述直接对齐，从而实现对未见功能术语的开放标签预测。该类方法的重要启发在于：当功能标签不再被视为离散编号，而是被表示为具有自然语言语义的描述对象时，模型便具备了跨标签迁移和开放空间泛化的可能性。此外，生成式模型和匹配式模型的边界也正在变得模糊：前者越来越强调通过语义表示支持未见标签预测，后者也越来越关注更自然的功能表达和标签语义解释。

若从研究脉络梳理，现有零样本功能预测研究大致可以分为三个阶段。第一阶段以本体逻辑和层级约束为核心，重点解决“训练集未见标签是否可以借助 GO 结构被推断”的问题；第二阶段开始引入预训练蛋白质表示和知识图谱嵌入，尝试同时提升蛋白质侧和标签侧的表达能力；第三阶段则更强调文本语义和跨模态对齐，将 GO 术语、蛋白质域描述及自然语言知识视为零样本推理的核心资源。可以看出，零样本研究正逐步从“规则辅助预测”转向“语义驱动预测”。

总体来看，现有零样本预测研究大致形成了三条技术路线：第一类是利用 GO 逻辑公理和层级结构开展基于本体约束的推理；第二类是通过预训练蛋白质表示与本体嵌入的联合建模，增强模型对标签语义的理解；第三类是借助文本描述和跨模态对齐，将功能预测从封闭分类提升为开放语义匹配。三类方法分别从结构知识、预训练表示和文本语义三个层面推进了零样本功能预测的发展。

但从当前研究结果看，零样本蛋白质功能预测仍面临若干关键挑战。首先，仅依赖本体逻辑约束往往受限于 GO 公理覆盖范围，难以充分捕捉术语定义中的细粒度语义差异。其次，仅依赖文本定义进行开放标签预测时，若蛋白质侧表示不够强，模型容易出现“懂标签、不懂蛋白质”的问题。再次，现实场景中的零样本往往同时伴随非同源序列、标签稀疏和模态缺失，这要求模型不仅能理解未见标签，还能在蛋白质表征侧具有足够鲁棒性。最后，在广义零样本场景下，模型常常会偏向已见标签，从而造成 Seen 性能较高但 Unseen 性能不足的失衡现象。正是基于这些问题，本文第三章进一步引入蛋白质域描述和 GO 定义的统一语义编码，并通过多模态融合机制提升零样本功能预测能力。

2.4 多模态预训练相关研究

多模态预训练（Multimodal Pretraining）是近年来蛋白质表示学习和功能预测研究中的重要趋势，其核心目标是在大规模弱监督或自监督数据上联合学习多种模态之间的共享表示，从而使模型在下游任务中具备更强的迁移能力、泛化能力和语义理解能力。对于蛋白质功能预测而言，多模态预训练尤其具有吸引力，因为蛋白质功能本身就是由序列、结构、相互作用网络、功能文本和知识本体等多方面因素共同决定的，单一模态很难完整刻画其复杂性。

多模态预训练的出现，首先建立在蛋白质语言模型快速发展的基础之上。以 ESM-2[12] 为代表的大规模蛋白质语言模型通过掩码语言建模在海量序列数据上进行自监督训练，学习到蕴含进化信息和潜在结构偏好的蛋白质表示。虽然这类模型本质上属于单模态预训练，但它们为后续多模态研究提供了强大的序列编码器基础。与此同时，AlphaFold2[2] 的突破使高质量结构预测可以大规模获得，结构模态得以更广泛地参与蛋白质表示学习和功能建模。序列预训练与结构预测能力的提升，共同为多模态预训练奠定了现实基础。

从研究路线看，多模态预训练首先体现在多源属性的联合建模上。CFAGO[26] 采用预训练—微调两阶段策略，将 PPI 网络和蛋白质属性信息进行交叉融合，并通过注意力机制实现更有效的多模态交互。该方法的重要意义在于表明：预训练不仅适用于单纯的序列表征学习，同样可以用于网络信息与属性信息的联合建模，而且预训练阶段学习到的共享表示对下游功能预测具有明显促进作用。

在更系统的多模态统一预训练框架方面，MASSA[31] 构建了整合蛋白质序列、结构和功能注释的多模态预训练体系，通过设计多任务训练目标，使模型能够从不同模态中共同学习蛋白质的生物学属性。与传统在单一任务上直接监督训练的方法相比，MASSA 更强调预训练阶段跨模态共享知识的形成，体现出“先学表示、

后做任务”的基础模型思路。对于蛋白质功能预测而言，这类方法的价值在于：下游预测性能不再仅依赖目标数据集规模，而可以从更大范围的多模态知识中获益。

在结构感知和知识蒸馏方向，S-PLM[32] 提出了具有代表性的技术路线。该方法在蛋白质语言模型内部注入轻量级适配器模块，并利用对比学习将蛋白质三维结构信息蒸馏到序列编码器中，使模型在下游推理时仅凭序列输入即可产生具有结构感知能力的表示。与直接将结构作为额外输入拼接到模型不同，S-PLM 更强调通过预训练将结构知识“内化”到序列模型内部，这对于兼顾模型性能与部署效率具有重要意义。该思路对本文第四章的设计具有直接启发，即蒸馏目标不仅可以是结构信息，也可以扩展为蛋白质域功能语义。

文本模态和知识本体的引入，则进一步丰富了多模态预训练的研究图景。OntoProtein[29] 构建蛋白质—GO 知识图谱，将 GO 嵌入和蛋白质预训练统一到同一框架中，并通过知识感知负采样实现蛋白质表示与本体知识的联合优化。这说明多模态预训练并不局限于“序列 + 结构”的物理模态组合，也可以扩展到“序列 + 知识图谱 + 文本语义”的知识增强型组合。ProtST[30] 则通过联合建模蛋白质序列和生物医学文本，在对齐和重建任务中同时利用两种模态的信息，展示了文本驱动的蛋白质预训练能够增强模型对功能语义和下游任务的适应能力。

近年来，文本监督进一步从“辅助模态”发展为“核心训练信号”。PAIR[35] 利用 UniProt 中的 19 类文本注释对蛋白质模型进行微调，显著增强了蛋白质表示的预测能力，并在部分功能相关任务上超越了 BLAST。这表明，文本注释不仅可以用来解释蛋白质功能，还可以作为高价值监督信号改善蛋白质表示学习质量。相较于传统只关注序列恢复或结构拟合的预训练目标，这类工作更直接地将功能语义引入模型训练之中，从而缩短了预训练目标与下游功能预测目标之间的距离。

在生成式多模态方向，Prot2Text[33] 提出将蛋白质功能预测从传统标签分类任务扩展为自由文本生成功能描述，通过图神经网络与 Transformer 联合建模蛋白质序列、结构和文本信息，使模型能够以自然语言形式输出更细粒度的功能说明。Prot2Text-V2[34] 进一步引入多模态对比对齐机制，并结合更强的蛋白质语言模型和大语言模型解码器，在低同源性设定下展示出更好的泛化能力。与基于固定标签的分类框架相比，这类生成式方法更能体现多模态预训练与开放语义推理的结合趋势，也说明蛋白质功能预测正在从“判定是否属于某标签”逐步走向“生成对功能的语义化描述”。

如果从技术形态归纳，多模态预训练相关研究大致形成了四类代表性路线。第一类是**多源特征联合预训练**，重点在于把网络、结构和属性信息引入统一编码框架，代表方法如 CFAGO 和 MASSA。第二类是**跨模态对比学习与知识蒸馏**，核心目

标是在共享空间中对齐不同模态，并将附加模态知识压缩到更易部署的主干编码器中，代表方法如 S-PLM。第三类是**知识增强与文本驱动预训练**，强调将 GO 定义、知识图谱、生物医学文本和 UniProt 注释作为预训练资源，代表方法如 OntoProtein、ProtST 和 PAIR。第四类是**生成式多模态建模**，关注从判别式标签预测走向自由文本描述生成，代表方法如 Prot2Text 及其后续版本。四类路线虽然侧重点不同，但都在尝试解决同一个根本问题：如何让蛋白质编码器获得比纯序列更丰富、更接近生物学语义的知识。

为更直观地概括相关工作的主要特点，表 2-1对零样本预测与多模态预训练方向中的代表性方法进行了总结。

表 2-1: 零样本预测与多模态预训练相关代表性方法比较

方法	主要输入模态	核心思想	主要局限
DeepGOZero[21]	序列、本体公理	利用 EL Embedding 编码 GO 逻辑公理，支持未见标签推理	对术语文本语义利用不足，蛋白质侧表示能力有限
DeepGO-SE[23]	序列、本体结构	结合预训练蛋白质表示与神经符号推理增强零样本预测	仍主要依赖本体结构先验，对多模态语义利用有限
OntoProtein[29]	序列、GO 文本、知识图谱	通过知识图谱和知识感知负采样联合预训练蛋白质与 GO 表示	更偏知识增强预训练，面向下游功能预测仍需额外适配
ProtST[30]	序列、生物医学文本	通过序列—文本对齐与掩码任务学习可迁移的多模态表示	与具体功能预测场景之间仍存在任务适配差异
MASSA[31]	序列、结构、功能注释	多任务多模态预训练，提升多种下游任务迁移性能	框架较复杂，对多模态数据完整性要求较高
S-PLM[32]	序列、结构	通过适配器和对比学习将结构知识蒸馏到序列编码器	蒸馏目标主要为结构信息，对功能语义挖掘不足
Prot2Text-V2[34]	序列、文本	通过多模态对比对齐和生成式建模生成功能描述	生成式框架开销较大，评价口径与传统 GO 分类不完全一致

总体来看，当前多模态预训练相关研究推动蛋白质功能预测从特定数据集上的监督学习，逐步演进为面向开放知识、开放标签和多模态融合的基础模型研究。与师兄师姐论文中“先定义问题、再分别归纳相关路线”的写法类似，这些工作也表明第二章不应仅停留在工具层面的介绍，而应围绕“哪些研究思路真正服务于本文问题”进行综述。对本文而言，多模态预训练的价值并不只体现在提高常规分类指标，更在于为开放语义空间中的蛋白质功能推理提供更强的蛋白质表示基础。

尽管多模态预训练已取得显著进展，但现有研究仍存在一些共性不足。其一，不少方法虽然引入多种模态，却仍以特征拼接或浅层交互为主，尚未充分利用不同模态之间的深层互补关系。其二，许多方法高度依赖结构或网络等附加模态，而

在实际应用中这些模态可能不完整或成本较高，影响模型的可用性。其三，现有方法对蛋白质域描述、GO 文本定义等功能语义知识的利用仍不充分，尤其缺乏将这些知识稳定蒸馏到序列编码器内部的有效机制。其四，多模态预训练与零样本预测虽然在研究目标上高度相关，但很多工作仍将二者分开处理，未能形成围绕开放语义功能预测的统一建模框架。基于这些不足，本文第四章进一步探索基于域感知适配器的多模态预训练方法，以增强蛋白质序列编码器对功能语义知识的吸收能力。

2.5 本章小结

本章围绕本文研究主题，对蛋白质功能预测的相关研究进行了概述。首先，从任务层面对蛋白质功能预测问题进行了形式化说明，介绍了 GO 层级体系、多标签预测特性、广义零样本设定以及开放标签空间下的“蛋白质—功能”匹配建模思路，并总结了 $F_{\max}$、AUPR 和调和均值 H 等常用评价指标。随后，系统梳理了零样本预测相关研究，说明该方向已从依赖本体逻辑约束逐步发展到结合预训练表示和文本语义的开放标签推理。接着，总结了多模态预训练相关研究的发展脉络，重点讨论了多源联合预训练、结构知识蒸馏、知识增强预训练、文本监督增强以及生成式多模态方法等技术路线。

总体而言，现有研究已经为蛋白质功能预测提供了丰富的方法基础，但在开放语义推理、多模态知识深层融合以及功能先验向序列编码器内部蒸馏等方面仍有进一步提升空间。本文后续两章的工作正是在这一背景下展开：第三章重点研究多模态零样本蛋白质功能注释问题，第四章则重点研究基于域感知适配器的多模态预训练方法。

第 3 章 多模态零样本蛋白质功能预测模型

3.1 引言

传统的蛋白质功能预测方法将每个 GO 标签视为独立的分类标识符，模型的预测能力被限制在训练集中出现过的标签范围内，无法对新出现的功能术语进行有效推理。针对这一根本性局限，本章提出多模态零样本蛋白质功能预测模型 MZSGO（Multimodal Zero-Shot GO annotation），将蛋白质功能预测重新定义为开放语义空间中的” 蛋白质-GO” 匹配问题。MZSGO 融合蛋白质语言模型提取的序列进化特征与大语言模型编码的文本语义特征，通过自适应门控融合机制实现多模态信息的动态整合，使模型既能在有监督场景下准确分类，也能通过文本语义相似性推断未见过的功能标签。

本章的组织结构如下：首先介绍数据集的构建与预处理流程，包括训练测试划分、数据统计以及多模态特征编码；随后阐述多模态零样本预测模型的特征投影、特异性丢弃、门控融合和优化目标；最后通过对比实验、消融实验和多维可解释性分析对模型性能进行系统验证。

3.2 数据集的构建与预处理

第二章 2.2.1 节已经对蛋白质功能预测问题的定义进行了系统说明，因此本章不再重复展开，而重点介绍与 MZSGO 方法对应的数据集构建、零样本划分策略及其统计特征。

为严格评估模型在有监督和零样本两个场景下的性能，本文构建了基于 CAFA5 挑战和 Swiss-Prot 数据库[37] 的综合基准数据集。

3.2.1 有监督训练集和零样本测试集构建

有监督训练集构建。训练语料源自 CAFA5 数据集，采用 ProtGO[25] 使用的数据源和训练/测试划分策略，并限制数据条目为 Swiss-Prot 数据库中收录的蛋白质。这一子集由人工审核的蛋白质组成，确保了注释质量的高可靠性，同时为与需要结构信息的基线方法进行公平比较提供了基础。功能注释采用 2023 年 1 月 1 日发布的 Gene Ontology 版本。

与 ProtGO 不同的是，本文实施了本体特异性的数据过滤策略。对于每个本体类别，仅使用具有该特定本体注释的蛋白质进行训练，而非直接使用完整训练集。

这一决策基于如下观察：完整数据集中缺乏某一本体注释的蛋白质会对基线模型的性能产生不利影响。尽管 MZSGO 在完整数据集上也不会出现显著性能下降，但经过裁剪的训练集有助于实现最优性能并确保与最先进基线方法的严格公平比较。

零样本测试集构建。零样本测试集旨在评估模型对从未见过的蛋白质和新出现标签的注释能力。其设计遵循两个核心原则：

（1）**蛋白质新颖性（序列层面）**：选择不在训练集中的 Swiss-Prot 蛋白质。为防止序列相似性导致的信息泄露，使用 Diamond 工具进行严格的同源性过滤，移除与训练集中任何序列的序列一致性超过 30% 的测试蛋白质。

（2）**标签新颖性（语义层面）**：实施时间演进评估策略，引入 2025 年 10 月 10 日更新的 GO 本体版本。将" 零样本标签" 定义为存在于 2025 版本但在 2023 版本中不存在的 GO 术语。因此，最终的零样本测试集由具有这些新出现功能注释的非同源蛋白质组成。

3.2.2 数据集统计

数据集的统计信息如表 3-1所示，样本按三个 GO 子本体分组。由于生物通路的复杂性，BP 类别包含最多的零样本蛋白质数量。

表 3-1: MZSGO 数据集统计

数据集	MF	CC	BP
训练集	50,874	51,743	51,618
测试集	5,584	5,764	5,712
零样本测试集	555	17	3,687

表 3-2详细展示了标签分布情况。在测试阶段，标签被分为以下三类：共有标签（Shared Labels），即同时出现在训练集和测试集中的 GO 术语；未见标签（Unseen Labels），即存在于测试集但不在训练数据中的术语；零样本标签（Zero-shot Labels），特指因本体更新而新出现的术语。

需要强调的是，未见标签和零样本标签对应两种不同的实验评估场景。**未见标签**评估的是模型对现有但稀有功能的泛化能力——这些 GO 术语虽然存在于 GO 本体中，但由于数据稀疏性，在训练集中没有相关蛋白质被注释为该功能。**零样本标签**则评估的是模型对随时间动态扩展的新生物学知识的鲁棒性——这些 GO 术语是在训练截止日期之后才被添加到 GO 本体中的全新概念。标签空间涵盖所有层级，从广泛的功能大类到注释中最精细的叶节点。这种严格的区分确保了零样本测试集上的评估指标真正反映模型的语义推理能力，而非记忆效应。

表 3-2: 标签分布统计

标签类别	MF	CC	BP
标签总数	7,007	2,803	20,639
未见标签	191	26	328
共有标签	2,983	1,581	11,691
仅训练标签	3,833	1,196	8,620
零样本标签	35	6	34

3.2.3 多模态特征编码

MZSGO 利用两种预训练模型提取三个模态的特征表示：

（1）**蛋白质序列表示**：使用 ESM2-650M[12] 蛋白质语言模型对蛋白质序列进行编码，提取最后一层隐藏状态中每个残基位置的上下文嵌入 $\mathbf{r}_j$，通过平均池化获得蛋白质级别的全局进化特征表示：

$$\mathbf{E}_{seq} = \frac{1}{L}\sum_{j=1}^{L}\mathbf{r}_j \in \mathbb{R}^{1280} \tag{3-1}$$

其中 L 为蛋白质序列长度，$\mathbf{r}_j$ 为第 j 个残基的嵌入表示。本文采用平均池化的原因在于其实现简洁、计算高效，且能够确保与现有方法的公平比较——文献中大多数基线方法均采用平均池化作为标准的蛋白质序列表示方法。值得注意的是，近期研究提出了更先进的池化技术，如局部感知池化（locality-aware pooling）[38]，在某些应用场景中展现了良好的前景，未来可进一步探索其在本框架中的适用性。

（2）**GO 标签语义表示**：使用 Qwen3-Embedding-4B[39] 对每个 GO 术语的名称和定义文本进行编码。输入文本格式为" 名称: 定义"（如"protein kinase activity: Catalysis of the phosphorylation of an amino acid residue..."），通过 token 级平均池化获得标签级别的语义嵌入：

$$\mathbf{E}_{label} = \frac{1}{T}\sum_{j=1}^{T}\mathbf{t}_j \in \mathbb{R}^{2560} \tag{3-2}$$

其中 T 为 token 数量。$\mathbf{E}_{label}$ 捕获了功能标签的语义内涵，使模型能够基于文本相似性泛化到未见标签——这是零样本推理的核心基础。与域需要进行多实例聚合不同，每个 GO 术语在本文的配对匹配范式中被视为独立的匹配目标，因此仅需 token 级池化。GO 标签嵌入来源于标准化的官方定义文本，构成了一个静态的语义参考空间。模型学习的是将蛋白质特征与功能语义关联——侧重于理解" 标签的语义含义"，而非简单地预测正确的标签标识符。

（3）**蛋白质域语义表示**：使用同一 Qwen3-Embedding-4B 模型对蛋白质各个域的 InterPro[40] 描述文本进行编码，采用两级平均池化获得蛋白质级别的域特征表示。对于拥有 K 个域的蛋白质，首先对每个域的 token 嵌入进行平均池化获得域级表示 $\mathbf{d}_k$，然后对所有域级表示再次平均池化获得蛋白质级域特征：

$$\mathbf{E}_{dom} = \frac{1}{K}\sum_{k=1}^{K}\mathbf{d}_k \in \mathbb{R}^{2560} \tag{3-3}$$

域信息之所以采用两级池化而非 GO 术语的单级池化，是因为在本文的设计中，一个蛋白质由多个域共同组成一个完整的功能单元，需要将多个域的信息聚合为该蛋白质的统一域表示。而 GO 术语则在配对匹配范式中被逐一评估，无需进行多实例聚合。

以上三种特征分别捕获了蛋白质的进化信号、功能标签的语义内涵和蛋白质域的结构功能信息，为后续的多模态融合提供了互补的信息来源。

表 3-3展示了一个完整的输入数据示例（UniProt ID: Q8TBH0），直观呈现了三种模态的具体数据形式。该蛋白质的氨基酸序列由 ESM2-650M 编码以提取进化特征；其关联的 5 个 InterPro 域描述（包含 Arrestin 相关的结构域和功能域）由 Qwen3-Embedding 编码以提取域语义特征；候选 GO 标签的定义文本（如”intracellular anatomical structure”、”organelle” 等）同样由 Qwen3-Embedding 编码以提取功能语义特征。这种多模态输入设计使模型能够从互补的角度理解蛋白质功能。

3.3 多模态零样本预测模型

在完成数据集构建和多模态特征准备后，本文进一步构建多模态零样本预测模型 MZSGO。该模型将蛋白质功能预测从封闭标签集分类拓展为开放语义空间中的蛋白质-GO 匹配任务，使模型既能够在已有标签上完成有监督预测，也能够借助文本语义对训练阶段未出现的功能术语进行推断。

MZSGO 的总体架构如图 3-1所示。系统由三个关键环节构成：（1）特征投影与特异性丢弃，将异构模态映射到统一隐空间并增强训练鲁棒性；（2）自适应门控融合，根据不同蛋白质-GO 对的语义匹配关系动态整合多模态信息；（3）分类预测与损失优化，输出蛋白质与 GO 功能之间的匹配概率。

MZSGO 的完整训练流程如算法 3-1所示。整个工作流分为四个阶段：特征投影与对齐、特征丢弃（仅训练阶段）、门控融合和分类预测。

3.3.1 特征投影与特异性丢弃

由于三种模态的原始嵌入具有不同的维度和分布特性（ESM 嵌入为 1280 维，

算法 3-1 MZSGO 训练工作流

Input: E_{esm}, E_{dom}（蛋白质特征），E_{nlp}（标签特征）

Output: 预测矩阵 $Y \in \mathbb{R}^{B \times L}$

定义 $\phi(\cdot)$: 通用 MLP 模块（Linear → LN → Act → Dropout）;

// 阶段 1: 投影与对齐

将特征投影至隐藏维度 H;

$\mathbf{h}_{esm} \leftarrow \phi_1(E_{esm}), \mathbf{h}_{dom} \leftarrow \phi_2(E_{dom}), \mathbf{h}_{nlp} \leftarrow \phi_3(E_{nlp})$;

广播特征至形状 $[B \cdot L, H]$ 构建蛋白质-标签配对;

$\mathbf{H} \leftarrow \{\mathbf{h}_{dom}^{expand}, \mathbf{h}_{esm}^{expand}, \mathbf{h}_{nlp}^{expand}\}$;

// 阶段 2: 特征丢弃（仅训练阶段）

if 训练阶段 **then**

  生成掩码 $M \in \{0, 1\}^{B \cdot L \times 2}$，确保每行至少保留一个蛋白质特征;

  $\mathbf{h}_{dom}^{expand} \leftarrow \mathbf{h}_{dom}^{expand} \odot M_{:,0}$;

  $\mathbf{h}_{esm}^{expand} \leftarrow \mathbf{h}_{esm}^{expand} \odot M_{:,1}$;

end

// 阶段 3: 门控融合

拼接所有模态: $\mathbf{Z}_{cat} \leftarrow \text{Concat}(\mathbf{H}, \text{dim} = -1)$;

计算门控权重: $\mathbf{W} \leftarrow \text{Softmax}(\phi_{gate}(\mathbf{Z}_{cat}))$ // 形状: $[B \cdot L, 3]$

加权求和融合: $\mathbf{F}_{fused} \leftarrow \sum_{k=1}^{3} \mathbf{W}_{:,k} \cdot \phi_{trans}(\mathbf{H}_k)$;

// 阶段 4: 分类

$Y \leftarrow \text{Reshape}(\text{Linear}(\phi_{cls}(\mathbf{F}_{fused})), [B, L])$;

return Y

表 3-3: 蛋白质 Q8TBH0 的输入数据结构示例。展示三种模态的具体数据形式。

数据模态	内容
蛋白质 ID	Q8TBH0
模态 1：蛋白质序列	MLFDKVKAFSVQLDGATAGVEPVFSGGQAVAGRVLLELSS AARVGALRLRARGRAHVHWTESRSAGSSTAYTQSYSERVE VVSHRATLLAPDTGETTTLPPGRHEFLFSFQLPPTLVTSFE GKHGSVRYCIKATLHRPWVPARRARKVFTVIEPVDINTPAL LAPQ... （共 *420* 个残基）
模态 2：域文本描述	• IPR011021: Domain: Arrestin-like, N-terminal • IPR011022: Domain: Arrestin: C-terminal-like domain • IPR014752: Arrestin-like, C-terminal • IPR014756: Immunoglobulin E-set • IPR050357: Arrestin domain-containing protein
模态 3：GO 标签定义（正样本）	**GO:0005622** intracellular anatomical structure: A component of a cell contained within (but not including) the plasma membrane. **GO:0043226** organelle: Organized structure of distinctive morphology and function. **GO:0016020** membrane: A lipid bilayer along with all the proteins and protein complexes embedded in it.

文本嵌入为 2560 维），需要将它们映射至统一的隐空间。为此，设计三个独立的多层感知机（MLP）投影模块，每个模块由线性变换、层归一化[41]、GELU 激活[42]和 Dropout 组成：

$$\mathbf{h}_m = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_m\mathbf{E}_m + \mathbf{b}_m))) \tag{3-4}$$

其中 $m \in \{seq, dom, label\}$ 表示模态类型，$\mathbf{h}_m \in \mathbb{R}^{d_{model}}$ 为投影后的特征向量，$d_{model} = 512$。

模态特异性丢弃策略。为防止模型过度依赖单一蛋白质模态，并模拟真实场景中域信息缺失的情况，本文设计了一种非对称的特征丢弃机制。在训练阶段，定义二值掩码 $\mathbf{M} = [m_{seq}, m_{dom}]$，其中每个蛋白质模态以概率 $p = 0.15$ 被独立丢弃：

$$m_{seq} = \mathbb{I}[r_{seq} > p], \quad m_{dom} = \mathbb{I}[r_{dom} > p] \tag{3-5}$$

其中 $r_{seq}, r_{dom} \sim \text{Uniform}(0, 1)$。掩码后的特征为 $\hat{\mathbf{h}}_{seq} = \mathbf{h}_{seq} \cdot m_{seq}$ 和 $\hat{\mathbf{h}}_{dom} = \mathbf{h}_{dom} \cdot m_{dom}$。

关键设计在于其" 非对称性"：GO 标签的文本嵌入 $\mathbf{h}_{label}$ 始终保留，不参与丢弃。这迫使模型学会在部分蛋白质信息缺失的情况下，仍能通过 GO 标签的文本语义进行有效预测，从而为零样本泛化奠定基础。

为确保至少有一个蛋白质模态可用，设计了强制保留机制：

$$\text{若} m_{seq} = m_{dom} = 0: \quad m_k \leftarrow 1, \quad k \sim \text{Uniform}\{seq, dom\} \tag{3-6}$$

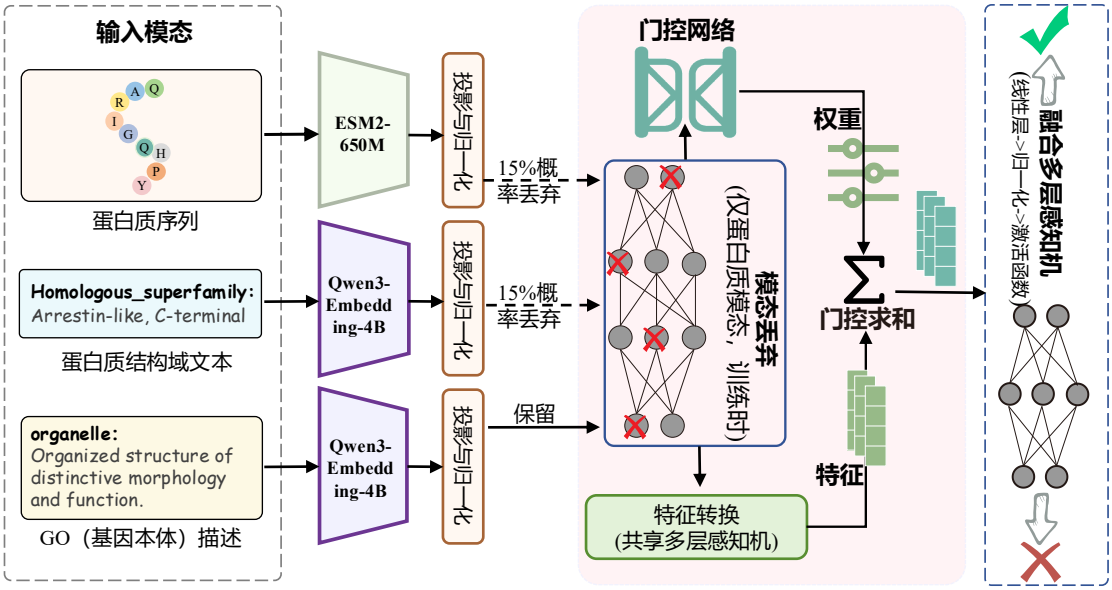

图 3-1: MZSGO 框架总体架构。流程包含四个集成阶段：（1）多模态特征投影；（2）训练阶段的蛋白质模态丢弃，虚线表示以概率 $p = 0.15$ 随机丢弃蛋白质特征，实线表示保留的模态；（3）门控融合模块实现自适应特征整合；（4）二分类头进行 GO 功能预测。

推理阶段不施加任何丢弃，模型可利用完整的多模态信息进行预测。

3.3.2 自适应门控融合机制

为有效整合多模态特征，本文设计了门控融合模块（Gated Fusion Module），学习为每个信息来源分配自适应的重要性权重。首先，拼接三个模态的特征构建全局上下文向量，输入门控网络生成注意力分数：

$$\mathbf{S} = [\hat{\mathbf{h}}_{dom} \parallel \hat{\mathbf{h}}_{seq} \parallel \mathbf{h}_{label}] \tag{3-7}$$

$$\boldsymbol{\alpha} = \mathrm{Softmax}(\mathbf{W}_{gate} \cdot \mathrm{ReLU}(\mathrm{LN}(\mathbf{W}_{ctx}\mathbf{S}))) \tag{3-8}$$

其中 $\parallel$ 表示拼接操作。$\mathbf{W}_{ctx} \in \mathbb{R}^{d_{model} \times 3d_{model}}$ 和 $\mathbf{W}_{gate} \in \mathbb{R}^{3 \times d_{model}}$ 为门控网络中的可学习权重矩阵。$\boldsymbol{\alpha} \in \mathbb{R}^3$ 为经 Softmax 归一化的门控权重向量，其 3 个分量分别对应三种模态（域、序列、标签）的贡献分数。通过 Softmax 函数确保权重之和为 1，使模型能够自适应地确定各信息来源的相对重要性。

同时，每个模态的特征通过变换层 $\phi_{trans}(\cdot)$ 进行非线性映射。ϕ_{trans} 实现为一个**共享多层感知机**，用于对各模态特征进行精细化表示变换。最终的融合表示通过加权求和获得，再经投影层 ϕ_{cls} 输出：

$$\mathbf{H}_{fused} = \phi_{cls}\left(\sum_{k=1}^{3} \alpha_k \cdot \phi_{trans}(\mathbf{h}_k)\right) \tag{3-9}$$

其中 k 索引三个模态（序列、域、标签）。$\phi_{trans}(\cdot)$ 和 $\phi_{cls}(\cdot)$ 均由线性变换、层归一化和激活函数组成。

该机制的核心优势在于：门控权重是**逐样本动态计算**的，即每个蛋白质-GO 对的融合比例不同。例如，当蛋白质的域信息丰富且与功能高度相关时，模型倾向于分配更高的权重给域特征；当域信息稀疏时，模型则更依赖序列特征和标签文本语义。

3.3.3 优化目标

融合表示 $\mathbf{H}_{fused}$ 通过分类 MLP 生成标量逻辑值，再经 sigmoid 激活函数获得预测概率：

$$\hat{y} = \sigma(\mathbf{W}_{out}\mathbf{H}_{fused} + b_{out}) \tag{3-10}$$

为应对不同 GO 子本体在类别不平衡程度上的差异，本文对不同本体采用不同的损失函数策略：

对于 BP 和 MF 子本体，使用标准的二分类交叉熵损失：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3-11}$$

对于 CC 子本体，采用 Focal Loss 以聚焦于难样本的学习：

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N}\sum_{i=1}^{N}\left[\alpha(1 - \hat{y}_i)^{\gamma} y_i \log(\hat{y}_i) + (1 - \alpha)\hat{y}_i^{\gamma}(1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3-12}$$

其中 $\gamma = 2$ 为聚焦参数。

上述损失函数选择策略并非随意决定，而是基于对三个 GO 子本体标签分布特性的定量统计分析。本文引入两个关键指标来刻画数据分布特征：

基尼系数（Gini Coefficient, G）用于量化标签分布的不均衡程度。设 x 为按非递减顺序排列的标签出现次数（$x_1 \leq \cdots \leq x_C$），基尼系数计算为：

$$G = \frac{2\sum_{i=1}^{C} i \cdot x_i}{C\sum_{i=1}^{C} x_i} - \frac{C+1}{C} \tag{3-13}$$

G 接近 1 表示极度不平衡，少数” 头部” 类别主导了数据集。

有效性比率（Effectiveness Ratio, ρ）。遵循 Cui 等人[43] 的分析，由于信息重叠，添加样本的边际收益递减。一个具有 n 个样本的类别的有效数量为 $E_n =$

$(1-\beta^n)/(1-\beta)$，其中 $\beta = 0.9999$。有效性比率定义为平均有效数量与平均实际数量之比：

$$\rho = \frac{\frac{1}{C}\sum_{i=1}^{C} E_{n_i}}{\frac{1}{C}\sum_{i=1}^{C} n_i} \tag{3-14}$$

ρ 值越低表示数据冗余度越高，梯度被重复样本所主导。

统计分析结果显示：MF 和 BP 本体具有相对较高的信息质量，有效性比率分别为 72.20% 和 81.11%，表明尽管存在固有的不平衡，正样本仍能提供充足的独特梯度信号，因此采用标准的 BCE 损失即可。相比之下，CC 本体表现出极端的不平衡性（$G = 0.946$）和最低的有效性比率（57.60%），显著劣于 BP 和 MF。这意味着 CC 本体中近一半的样本量贡献了极少的边际信息，如果使用标准 BCE 损失，这些频繁但冗余的样本会淹没学习过程。因此，CC 本体专门采用 Focal Loss 来降低易分类样本的权重，聚焦于信息量丰富的尾部类别的学习。

3.4 实验结果及分析

3.4.1 对比实验结果与分析

为保证比较结果的可复现性与公平性，本节先介绍实验设置、基线方法和评价指标，随后对标准测试集与纯零样本测试集上的结果进行统一分析。

实验设置。

MZSGO 基于 PyTorch[44] 框架实现。为对齐异构模态，将 1280 维 ESM 嵌入和 2560 维文本/域特征投影至统一的隐空间（$d_{model} = 512$）。这些特征经拼接后输入门控融合网络——一个两层 MLP——计算自适应模态权重，随后通过变换层进行非线性映射。融合表示最终被压缩至 256 维用于分类。

训练在单块 NVIDIA A6000 GPU（48GB 显存）上进行，使用 Adam 优化器[45]，学习率为 5×10^{-4}，批次大小为 16。为缓解过拟合，施加 0.5 的神经元级 Dropout 率。考虑到各子本体的复杂度差异，BP 训练 30 个 epoch，MF 和 CC 各训练 20 个 epoch。

基线方法。

本文选择十种先进的基线方法进行对比，涵盖三大类别：

（1）**传统方法**：Naive（基于标签频率预测）、Diamond[8]（基于序列同源性传递）。

（2）**深度学习方法**：DeepGOCNN[10]（卷积神经网络）、DeepGOZero[21]（本体公理约束）、Struct2GO[16]（图神经网络 + 结构信息）、PO2GO[24]（偏序嵌入）、DeepGO-SE[23]（神经符号推理）。

（3）**多模态/LLM 方法**：ProtGO[25]（四模态融合）、DPFunc[18]（域信息增强）、ProtNote[27]（LLM 功能描述）。

评价指标。

为全面评估模型在蛋白质功能预测中的有效性，特别是在广义零样本设定下的性能，本文采用多层次的评价指标体系。遵循 CAFA 挑战赛[6] 的标准评估协议，以蛋白质中心（protein-centric）的指标为主要评估标准。

标准蛋白质中心指标。

设测试集包含 N 条蛋白质序列。对于第 i 条蛋白质，令 T_i 为其真实 GO 标签集合，$P_i(t)$ 为置信度分数大于等于阈值 $t \in [0, 1]$ 的预测 GO 标签集合。

精确率与召回率。对于给定阈值 t，第 i 条蛋白质的精确率 $\pi_i(t)$ 和召回率 $\rho_i(t)$ 定义为：

$$\pi_i(t) = \frac{|P_i(t) \cap T_i|}{|P_i(t)|}, \quad \rho_i(t) = \frac{|P_i(t) \cap T_i|}{|T_i|} \tag{3-15}$$

其中 $|\cdot|$ 表示集合的大小。数据集的平均精确率 $AvgPr(t)$ 和平均召回率 $AvgRc(t)$ 计算如下：

$$AvgPr(t) = \frac{1}{M(t)} \sum_{i=1}^{N} \pi_i(t) \cdot \mathbb{I}(|P_i(t)| > 0) \tag{3-16}$$

$$AvgRc(t) = \frac{1}{N} \sum_{i=1}^{N} \rho_i(t) \tag{3-17}$$

其中 $M(t)$ 表示在阈值 t 下至少有一个预测结果的蛋白质数量。

F_{max} 指标。F_{max} 是在所有可能阈值 t 上计算的平均精确率和平均召回率的最大调和均值：

$$F_{max} = \max_{t \in [0,1]} \left(\frac{2 \cdot AvgPr(t) \cdot AvgRc(t)}{AvgPr(t) + AvgRc(t)} \right) \tag{3-18}$$

F_{max} 是一个依赖阈值的指标，它通过在 0 到 1 的阈值范围内搜索最优的 F1 分数，有效地衡量了模型的峰值分类精度。

AUPR 指标。AUPR（Area Under the Precision-Recall Curve）通过对精确率-召回率曲线进行积分计算：

$$AUPR = \int_0^1 AvgPr(Rc)\, d(AvgRc) \tag{3-19}$$

与 F_{max} 不同，AUPR 不依赖于特定阈值。鉴于功能注释任务中存在严重的类别不平衡，AUPR 能够提供更为鲁棒的全局性能评估。需要指出的是，本文的 AUPR 是

在蛋白质中心的精确率-召回率曲线上、覆盖完整标签空间计算的。即使模型对未见标签赋予零分数，曲线上仍存在非零的精确率-召回率点（例如在阈值为 0 时），因此数值上 AUPR 略高于零，但这并不表示模型对未见标签具有有效的判别能力。

广义零样本指标。

为评估模型的泛化能力，将标签空间划分为已见标签集 L_{seen} 和未见标签集 L_{unseen}，分别计算两个子集上的 AUPR：

Seen AUPR：将评估限定在训练集中出现过的标签子集上计算的 AUPR。

Unseen AUPR：将评估限定在训练阶段从未遇到的标签子集上计算的 AUPR。

为评价模型在已知知识拟合与新概念泛化之间的权衡，计算二者的调和均值（Harmonic Mean, H）：

$$H = \frac{2 \cdot \mathrm{AUPR}_{seen} \cdot \mathrm{AUPR}_{unseen}}{\mathrm{AUPR}_{seen} + \mathrm{AUPR}_{unseen}} \tag{3-20}$$

只有当模型在已见和未见标签上均表现良好时，H 值才会较高，因此它是衡量模型是否实现了鲁棒泛化而非仅仅过拟合已见类别的关键指标。

加权评价指标。

为考虑 GO 术语的不同特异性，本文还采用了基于信息内容（Information Content, IC）加权的评价指标。每个 GO 术语 v 被赋予权重 $\tau(v) = -\log(p(v))$，其中 $p(v)$ 是该术语在数据库中出现的概率。

加权精确率与加权召回率。对于蛋白质 i 在阈值 t 下的加权精确率 $w\pi_i(t)$ 和加权召回率 $w\rho_i(t)$ 定义为：

$$w\pi_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in P_i(t)} \tau(v)}, \quad w\rho_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in T_i} \tau(v)} \tag{3-21}$$

类似地，wF_{max} 为加权精确率和加权召回率在所有阈值上的最大调和均值，$wAUPR$ 为加权精确率-召回率曲线下面积。

语义距离 S_{min}。S_{min} 基于信息内容评估预测结果与真实标签之间的语义距离，结合剩余不确定性（Remaining Uncertainty, RU）和误信息（Misinformation, MI）两个维度：

$$RU(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in T_i \setminus P_i(t)} \tau(v), \quad MI(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in P_i(t) \setminus T_i} \tau(v) \tag{3-22}$$

$$S_{min} = \min_{t \in [0,1]} \sqrt{RU(t)^2 + MI(t)^2} \tag{3-23}$$

S_{min} 值越低表示预测结果在语义层面与真实标签越接近，该指标对功能特异性较

高的 GO 术语赋予更大的权重，能够更好地评估模型对生物学上重要的精细功能的预测能力。

标准测试集上的性能对比。

表 3-4汇总了 MZSGO 与所有基线方法在三个本体上的性能对比结果。

有监督性能分析。

在常规分类指标（Fmax 和 AUPR）方面，MZSGO 在三个本体上均取得了最优或极具竞争力的结果，凸显了多模态融合方法的有效性。

在最具挑战性的 BP 本体中，MZSGO 以 0.5045 的 Fmax 超过了域感知方法 DPFunc（0.4984）和神经符号推理方法 DeepGO-SE（0.5006）。在 MF 和 CC 本体上，MZSGO 分别以 0.7611 和 0.7470 的 Fmax 保持领先。值得注意的是，MZSGO 在 CC 本体上的 AUPR 达到 0.7726，刷新了该本体的最优记录。

与仅依赖单一模态的方法相比，MZSGO 通过自适应门控融合机制有效整合了蛋白质序列特征（ESM）与域描述语义，使模型能够综合利用互补的语义线索，产生更强的特征表示。

训练集过滤策略的有效性验证。

如3.2节所述，本文对训练集实施了本体特异性过滤策略。为验证这一决策的合理性，本文在 Swiss-Prot 数据库中 CAFA5 完整训练集（72,390 条蛋白质）上进行了对比实验。完整训练集不可避免地包含了对某一目标本体类别缺乏注释的蛋白质，这些隐式的” 负样本” 可能对模型训练产生干扰。

实验结果表明，将蛋白质功能预测建模为二分类问题的方法（如 ProtNote 和 MZSGO）在完整数据集上表现出更强的鲁棒性，不会出现显著的性能退化。具体而言，MZSGO 在未过滤的完整训练集上仍能在所有三个本体类别的 Fmax 和 AUPR 指标上一致性地超越最新基线方法（ProtGO、DPFunc 和 ProtNote）。然而，需要注意的是，多数基线方法（特别是多标签分类范式的方法）在完整数据集上的性能受到了负面影响。这是因为缺乏特定本体注释的蛋白质在训练过程中被隐式地视为该本体所有标签的负样本，引入了大量错误的监督信号。本文最终采用过滤后的训练集，一方面是为了追求最优性能，另一方面更重要的是确保与所有基线方法进行严格公平的比较。

零样本性能分析。

MZSGO 的核心优势在于其对未见标签的推理能力。表 3-4中的 Unseen AUPR 和调和均值 H 直观地反映了这一点。

传统比对方法和标准深度学习模型在零样本场景中表现出极为有限的泛化能力。这主要是因为这些模型将标签视为独立的 one-hot 标识符，在训练过程中，优

表 3-4: MZSGO 与最先进方法在测试集上的性能对比。最优结果加粗，次优结果加下划线。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	Naive	0.2991	0.2073	0.0025	0.2076	0.0049
	Diamond	0.4703	0.2913	0.0025	0.2934	0.0050
	DeepGOCNN	0.3964	0.3676	0.0025	0.3684	0.0050
	DeepGOZero	0.4888	0.4535	0.0025	0.4558	0.0050
	Struct2GO	0.4022	0.3744	0.0025	0.3747	0.0050
BP	PO2GO	0.2975	0.2303	0.0025	0.2307	0.0049
	DeepGO-SE	0.5006	0.4373	0.0025	0.4404	0.0050
	ProtGO	0.4636	0.4377	0.0025	0.4410	0.0050
	DPFunc	0.4984	0.4902	0.0069	0.4936	0.0136
	ProtNote	0.3555	0.2993	0.0303	0.2997	0.0550
	MZSGO	**0.5045**	**0.5008**	**0.2393**	**0.5021**	**0.3241**
	Naive	0.5496	0.3318	0.0032	0.3327	0.0063
	Diamond	0.6727	0.3330	0.0032	0.3366	0.0063
	DeepGOCNN	0.6603	0.5225	0.0032	0.5242	0.0064
	DeepGOZero	0.7441	0.6333	0.0032	0.6380	0.0064
	Struct2GO	0.6564	0.5940	0.0032	0.5962	0.0064
MF	PO2GO	0.5496	0.4136	0.0032	0.4148	0.0064
	DeepGO-SE	0.7481	0.6332	0.0032	0.6376	0.0064
	ProtGO	0.7262	0.7399	0.0032	0.7453	0.0064
	DPFunc	0.7495	**0.7416**	0.0051	**0.7480**	0.0101
	ProtNote	0.6140	0.5283	0.0490	0.5301	0.0897
	MZSGO	**0.7611**	0.7337	**0.4806**	0.7380	**0.5821**
	Naive	0.6143	0.0793	0.0207	0.5270	0.0398
	Diamond	0.6331	0.3076	0.0207	0.3093	0.0388
	DeepGOCNN	0.6918	0.5284	0.0207	0.5292	0.0398
	DeepGOZero	0.7075	0.6598	0.0207	0.6612	0.0401
	Struct2GO	0.6989	0.7380	0.0207	0.7382	0.0403
CC	PO2GO	0.6143	0.5828	0.0207	0.5830	0.0400
	DeepGO-SE	0.7379	0.6991	0.0207	0.7003	0.0402
	ProtGO	0.7209	0.7717	0.0207	0.7727	0.0403
	DPFunc	0.7386	0.7709	0.0274	0.7722	0.0529
	ProtNote	0.6636	0.6605	0.2530	0.6607	0.3659
	MZSGO	**0.7470**	**0.7726**	**0.5862**	**0.7733**	**0.6669**

化目标自然地抑制了未见标签对应的权重，迫使模型对训练集中未出现的类别预测接近零的概率。值得注意的是，尽管 DeepGOZero 理论上能够通过逻辑约束实现零样本预测，但它在缺乏显式 GO 公理的罕见类别上预测失效，Unseen AUPR 接近 0。

ProtNote 利用 LLM 展示了一定的零样本能力（如 BP 上的 0.0303），但 MZSGO 大幅超越了它。具体而言，MZSGO 在 BP 本体上实现了 0.2393 的 Unseen AUPR——相较 ProtNote 提升了约 **8 倍**。在 MF 和 CC 本体上同样观察到一致的趋势，MZSGO 分别实现了 0.4806 和 0.5862 的 Unseen AUPR。

综合平衡已见和未见标签性能的调和均值 H 进一步凸显了模型的全面优势。MZSGO 在 BP、MF、CC 上分别获得 0.3241、0.5821 和 0.6669 的 H 值，大幅超越亚军 ProtNote 的 0.0550、0.0897 和 0.3659。这一结果证实 MZSGO 不仅仅是记忆训练标签，而是学到了蛋白质特征与功能描述之间的泛化性语义对齐。

纯零样本测试集上的评估。

为进一步严格验证泛化能力，本文在专门构建的纯零样本测试集上将 MZSGO 与零样本能力最强的基线方法 ProtNote 进行直接对比。结果如表 3-5所示。

表 3-5: 纯零样本测试集上的性能对比。该评估集通过时间演进方式构建，评估模型对 2025 版本中新出现但训练截止日期前不存在的 GO 功能标签的预测能力。

本体	模型	Fmax	AUPR	Precision	Recall
BP	ProtNote	0.3763	0.2705	0.2580	**0.6951**
	MZSGO	**0.4881**	**0.4546**	**0.4475**	0.5369
MF	ProtNote	0.3599	0.3393	0.4545	0.2979
	MZSGO	**0.5982**	**0.5435**	**0.6261**	**0.5727**
CC	ProtNote	0.2983	0.1652	0.1853	0.7647
	MZSGO	**0.6610**	**0.6291**	**0.5521**	**0.8235**

MZSGO 在所有三个本体的 Fmax 和 AUPR 上均一致超越 ProtNote。对精确率和召回率的精细分析揭示了两种方法的行为差异和改进方向：

（1）**BP 本体的平衡精确率-召回率权衡**：ProtNote 展现了较高的召回率（0.6951）但精确率低下（0.2580），表明其倾向于过度预测功能标签。相比之下，MZSGO 实现了更均衡的权衡，将精确率提升至 0.4475 的同时保持了 0.5369 的竞争性召回率，从而获得了显著更高的 Fmax（0.4881 vs. 0.3763），意味着在复杂生物过程的预测中更为可靠。

（2）**MF 和 CC 本体的全面优势**：在 MF 本体上，MZSGO 获得 0.5982 的 Fmax（ProtNote 为 0.3599），精确率（0.6261 vs. 0.4545）和召回率（0.5727 vs. 0.2979）双双领先，展示了对未见分子功能的准确识别能力。在 CC 本体上，性能差距最为显著：ProtNote 的精确率仅为 0.1853——可能是由于广泛文本匹配导致的" 功能幻觉"（functional hallucination），即模型基于表层文本相似性错误地将蛋白质匹配到不相关的功能标签——而 MZSGO 达到 0.5521 的精确率，同时召回率也优于 ProtNote（0.8235 vs. 0.7647），实现了 Fmax 从 0.2983 到 0.6610 的翻倍提升。为进一步探究其背后的机制，本文对功能文本嵌入和域文本嵌入进行了可视化分析，结果表明在正确预测的样本中，域嵌入向量在空间上与功能文本嵌入向量更为接近，详见本章嵌入空间可视化分析一节。

这一对比结果表明，MZSGO 通过将预测锚定在域特异性的语义空间中，有效避免了其他基于文本的模型中常见的噪声和假阳性问题，为蛋白质新功能注释提供了高度可靠的预测能力。

3.4.2 消融实验结果与分析

为评估各组件的贡献——特别是多模态特征、融合模块和优化策略，本文在 CC 本体上进行了系统的消融实验。消融变体分为五组：（1）单模态编码器；（2）特征表示变化；（3）架构变化；（4）编码器替换；（5）损失函数变体。结果如表 3-6所示。

从消融结果中可以得出以下关键结论：

（1）**域语义信息是零样本能力的关键**。移除域语义信息造成最严重的性能退化：仅使用 ESM 特征时，Unseen Fmax 从 0.5665 骤降至 0.0793（下降 93%），表明序列特征本身难以泛化到未见标签。仅使用域特征时 Unseen Fmax 为 0.2322，远优于仅用 ESM；而将域信息退化为 One-hot 编码后 Unseen Fmax 降至 0.2000，证实零样本迁移依赖于域描述的语义内容而非简单标识符。

（2）**门控融合机制不可或缺**。将门控融合替换为简单拼接使 H 从 0.6669 降至 0.6000，说明朴素拼接无法有效整合异构模态。使用 PO2Vec 标签嵌入替代文本嵌入更是导致 H 降至 0.4423——这不仅因为 PO2Vec 依赖于固定的 GO 图拓扑结构，更因为基于图拓扑的嵌入与序列和文本模态在语义对齐度上存在显著鸿沟，进一步加大了多模态融合中的语义差距。

（3）**特征丢弃策略增强泛化能力**。去除特征丢弃后，已见标签准确度略有提升（Fmax 达 0.7544），但零样本泛化显著下降（H 从 0.6669 降至 0.5714），验证了其作为正则化手段防止模型对已见标签过拟合[46] 的重要性。

表 3-6: CC 本体上的消融实验结果。报告指标包括总体 Fmax 和 AUPR，以及零样本相关指标。H 为已见与未见标签性能的调和均值。

方法	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7319	0.7344	0.5203	0.0793	0.6094
仅域特征	0.7311	0.7052	0.5187	0.2322	0.6012
特征与架构消融					
域信息 One-hot 编码	0.7203	0.6731	0.5047	0.2000	0.5889
使用 PO2Vec 标签嵌入	0.7406	0.7196	0.3193	0.1818	0.4423
去除特征丢弃	**0.7544**	0.6857	0.4898	0.2500	0.5714
简单拼接替代门控融合	0.7381	0.7009	0.5245	0.2469	0.6000
编码器变体					
BioGPT	0.7419	0.7198	0.4258	0.1935	0.5351
BiomedBERT	0.7406	0.7218	0.5647	0.2000	0.6337
Qwen3-0.6B	0.7406	0.7282	0.5469	0.1379	0.6247
ESM-150M	0.7385	0.7310	0.3864	0.1333	0.5056
损失函数变体					
BCE 损失	0.7501	0.7143	0.5824	0.2581	0.6421
加权 BCE 损失	0.7199	0.7450	0.5127	0.4444	0.6095
MZSGO	0.7470	**0.7726**	**0.5862**	**0.5665**	**0.6669**

（4）**编码器选择的合理性**。各替代编码器的性能均不及当前组合，证实 MZSGO 选择的编码器（ESM2-650M + Qwen3-Embedding-4B）最能捕获跨模态的互补结构信息。

（5）**Focal Loss 在 CC 本体上的优势**。标准 BCE 获得较高的 Fmax（0.7501）但总体 AUPR 偏低（0.7143）；加权 BCE 虽改善了 Unseen Fmax（0.4444）但损害了总体 AUPR 和 H 值。Focal Loss（MZSGO）通过有效平衡困难样本的学习，实现了最优的综合权衡。

BP 和 MF 本体的消融验证。

为进一步验证框架的鲁棒性和可推广性，本文将消融实验扩展至 BP 和 MF 本体。实验设置和变体分组与 CC 本体消融完全一致。

表 3-7和表 3-8分别展示了 BP 和 MF 本体上的消融结果，其发现与 CC 本体的结论高度一致。

表 3-7: BP 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.4584	0.4278	0.0924	0.0446	0.1520
仅域特征	0.4552	0.4208	0.0774	0.0334	0.1308
特征与架构消融					
域信息 One-hot 编码	0.4833	0.4550	0.2309	0.1182	0.3066
使用 PO2Vec 标签嵌入	0.4948	0.4721	0.0959	0.0534	0.1595
去除特征丢弃	0.4992	0.4794	0.2231	0.1440	0.3047
简单拼接替代门控融合	0.4849	0.4602	0.0700	0.0352	0.1215
编码器变体					
BioGPT	0.4877	0.4650	0.1584	0.1153	0.2364
BiomedBERT	0.4829	0.4569	0.1801	0.0931	0.2608
Qwen3-0.6B	0.4842	0.4590	0.1964	0.0967	0.2752
ESM-150M	0.4799	0.4540	0.1730	0.1176	0.2506
损失函数变体					
Focal Loss	0.4791	0.4787	0.1166	0.1901	0.1876
加权 BCE 损失	0.4821	0.4580	0.1755	**0.2141**	0.2542
MZSGO	**0.5045**	**0.5008**	**0.2393**	0.1210	**0.3250**

表 3-8: MF 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7322	0.6890	0.2502	0.1516	0.3675
仅域特征	0.7380	0.6986	0.4655	0.3966	0.5598
特征与架构消融					
域信息 One-hot 编码	0.7376	0.7041	0.3149	0.2367	0.4359
使用 PO2Vec 标签嵌入	0.7414	0.7014	0.3772	0.3871	0.4916
去除特征丢弃	0.7517	0.7104	0.4800	0.4206	0.5740
简单拼接替代门控融合	0.7446	0.7035	0.3951	0.3050	0.5069
编码器变体					
BioGPT	0.7506	0.7223	0.4512	0.4290	0.5566
BiomedBERT	0.7508	0.7206	0.4513	0.4485	0.5562
Qwen3-0.6B	0.7440	0.7111	0.3745	0.3428	0.4915
ESM-150M	0.7497	0.7202	0.4656	0.3527	0.5667
损失函数变体					
Focal Loss	0.7280	0.6938	0.4286	0.4835	0.5309
加权 BCE 损失	0.7372	0.7074	**0.5526**	**0.5585**	**0.6234**
MZSGO	**0.7611**	**0.7337**	0.4806	0.4259	0.5821

从 BP 和 MF 本体的消融结果中，可以提炼出以下跨本体的一致性发现：

（1）**多模态融合的必要性**。依赖单一模态（仅 ESM 或仅域特征）在三个本体上均导致显著的性能下降，特别是在零样本指标（Unseen AUPR 和 H 值）方面。值得注意的是，在 BP 本体上，单模态模型的 H 值仅为 0.1520（仅 ESM）和 0.1308（仅域），远低于 MZSGO 的 0.3250，凸显了多模态融合对于处理复杂生物过程分类的关键作用。

（2）**语义对齐的优越性**。用传统方法（域 One-hot 编码或 PO2Vec 标签嵌入）替代 LLM 文本嵌入，在三个本体上均严重损害零样本性能。以 BP 本体为例，使用 PO2Vec 标签嵌入的 H 值仅为 0.1595，远低于 MZSGO 的 0.3250。这再次证实了基于深度语义表示的标签理解对于零样本迁移的不可替代性。

（3）**架构设计的有效性**。简单拼接替代门控融合和去除特征丢弃策略在三个本体上均导致性能退化。在 BP 本体上，简单拼接的 H 值骤降至 0.1215——甚至低于部分单模态变体——说明在信息极度异构的 BP 分类任务中，朴素拼接不仅无法有效利用多模态信息，反而可能引入噪声。

（4）**损失函数选择的本体依赖性**。MF 本体的消融结果揭示了一个有趣的现象：加权 BCE 损失在 MF 上取得了最高的 Unseen AUPR（0.5526）和 H 值（0.6234），超过了 MZSGO 采用的标准 BCE 损失。然而，加权 BCE 在 MF 上的总体 Fmax（0.7372）和 AUPR（0.7074）均低于 MZSGO（0.7611 和 0.7337）。相反，在 BP 本体上，Focal Loss 变体的 H 值仅为 0.1876，远低于标准 BCE 的 0.3250，表明 Focal Loss 并不适合 BP 的数据特性。这些发现验证了本文为不同本体选择不同损失函数策略的合理性：BP 和 MF 使用标准 BCE 以追求最佳的综合性能，CC 使用 Focal Loss 以应对其极端的类别不平衡。

3.4.3 参数敏感性分析

为评估模型的鲁棒性，本文考察了两个关键超参数的影响：Dropout 率和隐藏向量维度。采用控制变量法，每次仅变动一个参数，在 CC 和 MF 本体上观察 AUPR 的波动。

Dropout 率的影响。

Dropout 率应用于特征提取后的神经元级丢弃，取值范围为 0.3 至 0.7。模型在 Dropout 率为 0.5 时表现最佳，CC 本体 AUPR 达 0.7726，MF 本体达 0.7377。较低的 Dropout 率（如 0.3）导致过拟合和泛化能力下降；较高的 Dropout 率（如 0.7）因过度信息丢失使性能退化（CC 降至 0.7610，MF 降至 0.7228）。因此，0.5 被选为最优配置。

隐藏向量维度的影响。

隐藏维度从 128 变化至 1024。随着维度从 128 扩展至 512，两个本体的性能持续提升。CC 本体在 512 维时达到峰值（AUPR 为 0.7726），此后随维度增大而退化。MF 本体在 1024 维时仍有提升（AUPR 达 0.8133），但 CC 本体在该维度下显著下降至 0.7371。为构建跨 GO 类别通用的模型架构而无需针对特定任务进行调整，最终将隐藏维度设定为 512，在表征能力和计算成本之间取得了良好的平衡。

3.4.4 嵌入空间可视化分析

为深入理解 MZSGO 实现零样本预测的内在机制，本文对域嵌入和功能文本嵌入的空间分布进行了可视化分析。

域嵌入与功能嵌入的空间关系。

使用 t-SNE 降维技术对 MF 和 CC 本体中蛋白质域嵌入和 GO 标签功能文本嵌入的空间分布进行可视化。可视化结果揭示了鲜明的聚类模式：在模型正确预测的样本中，蛋白质域嵌入向量在空间上与其对应的功能文本嵌入向量更为接近。在 MF 和 CC 两个本体中，正确预测样本的域嵌入与功能文本嵌入之间的欧几里得距离一致性地小于错误预测样本。

这一观察结果为 MZSGO 的零样本能力提供了直观的解释：模型学会了在统一的语义空间中建立蛋白质域特征与功能语义描述之间的有效映射。当一个蛋白质的域描述与某个 GO 标签的定义在语义上高度相似时（即在嵌入空间中距离较近），即使该 GO 标签在训练中从未出现，模型也能够基于这种语义邻近性做出正确的零样本预测。

零样本预测的文本语义分析。

为进一步揭示模型成功预测的深层原因，本文分析了 InterPro 域描述与 GO 标签定义之间的文本语义对应关系。以 CC 本体的零样本预测为例进行案例研究：在成功预测的案例中，域描述与 GO 标签定义之间存在大量共享或语义相近的关键词。

例如，当蛋白质具有”membrane-associated” 类型的域描述时，模型能够正确预测其与”membrane” 相关的 CC 功能标签，即使这些标签在训练集中从未出现。域描述中的”integral membrane protein”、”transmembrane helix” 等关键短语与 GO 标签”integral component of membrane” 定义中的核心概念形成了语义桥梁。这种文本级别的语义对齐通过 Qwen3-Embedding 模型被有效编码，使得 MZSGO 能够超越简单的模式记忆，实现基于深层语义理解的零样本功能推断。

相反，在预测失败的案例中，域描述与目标 GO 标签之间缺乏明确的语义关联，或者域描述过于笼统而无法提供针对性的功能线索。这一分析为未来改进 MZSGO

指明了方向——引入更丰富的域语义信息或更精细的语义对齐策略可能进一步提升零样本性能。

3.4.5 自适应门控权重分析

为深入理解 MZSGO 如何整合多模态信息，本文分析了门控融合模块分配给三种模态——域特征（α）、ESM 序列特征（β）和 NLP 文本特征（γ）——的平均门控权重在三个 GO 本体上的分布情况。门控权重是动态学习的，反映了模型在不同预测任务中对特定模态的依赖程度。

各本体的门控权重特征。

CC 本体表现出对域特征的高度依赖，总体平均权重达 83.60%，在未见标签上更是上升至 91.23%。这一发现与消融实验的结果完全一致——在 CC 消融实验中，仅域特征模型的零样本性能（Unseen Fmax = 0.2322）显著优于仅 ESM 模型（Unseen Fmax = 0.0793）。CC 本体描述的是蛋白质的亚细胞定位，而特定的蛋白质域和基序（如信号肽、跨膜域、核定位信号等）往往直接决定了蛋白质的亚细胞位置，因此域信息对 CC 预测提供了最为直接的泛化信号。

BP 本体的模型在已见标签上优先使用 ESM 序列特征（权重为 53.66%），这可能是因为序列同源性在已知功能预测中是一个强有力的预测因子。然而，对于”零样本标签”（训练样本极少或没有的标签），一个显著的偏移出现了：模型增加了对域特征（从总体的 31.11% 上升至 44.76%）和 NLP 特征的依赖。这种自适应偏移展示了 MZSGO 在序列模式不足以应对罕见或新颖类别时，能够灵活地利用语义域描述作为补充信息源的能力。

MF 本体呈现出域特征（约 48%）和 ESM 特征（约 48%）之间的均衡分布，表明酶活性和结合功能的预测同时需要域提供的结构线索和 ESM 编码器捕获的精细残基信息。这种平衡反映了 MF 功能标签的双重特性——既依赖于保守的功能域模体，又与序列层面的精细特征密切相关。

已见与未见标签的门控偏移。

跨三个本体的一个共性规律是：从已见标签到未见标签，门控权重始终向域特征和 NLP 文本特征偏移。这一现象有着深刻的生物学解释——对于已知功能，模型可以依赖通过大量训练样本学习到的序列模式进行预测；而对于未见功能，序列模式可能不再适用（因为缺乏相应的训练信号），此时域的结构功能语义和 GO 标签的文本定义成为唯一可用的推理依据。

门控权重分析进一步证实了 MZSGO 并非简单地对多模态信息进行平均融合，而是根据本体特性和目标标签的具体性质（已见 vs. 未见）自适应地选择最具信息

量的表示来源。这种动态选择机制是 MZSGO 实现优异零样本性能的关键技术基础。

加权评价指标补充分析。

除标准指标外，本文还采用基于信息内容加权的评价指标进一步评估 MZSGO 的预测质量。这些加权指标为功能特异性更高的 GO 术语赋予更大的权重，能够更准确地衡量模型对生物学上更为重要的精细功能的预测能力。表 3-9总结了 MZSGO 与最新基线方法在三个本体上的加权指标对比。

表 3-9: 加权评价指标（wF_{max}、$wAUPR$ 和 S_{min}）在三个 GO 本体上的对比。S_{min} 越低表示性能越好。

模型	BP			MF			CC		
	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$
ProtGO	0.4231	0.3582	37.0125	0.6634	0.5312	9.3241	0.6315	0.5553	9.5712
DPFunc	**0.4562**	**0.4265**	35.4012	0.6912	0.6431	8.6325	0.6521	0.6412	9.0834
ProtNote	0.3065	0.2384	40.9251	0.5301	0.4105	12.0812	0.5174	0.4776	11.1623
MZSGO	0.4560	0.4201	**34.8821**	**0.7015**	**0.6462**	**8.6105**	**0.6573**	**0.6478**	**8.9012**

从加权指标的对比中可以得出以下分析：

（1）在 MF 和 CC 本体上，MZSGO 在所有三个加权指标上均取得最优。在 MF 本体上，wF_{max} 达 0.7015，$wAUPR$ 达 0.6462，S_{min} 降至 8.6105，全面超越 DPFunc 和 ProtGO。这表明 MZSGO 不仅在整体覆盖度上表现优异，对于功能特异性较高、信息内容较大的 GO 术语也保持了良好的预测精度。

（2）在 BP 本体上，MZSGO 的 wF_{max}（0.4560）与 DPFunc（0.4562）极为接近，但 S_{min} 指标（34.8821 vs. 35.4012）优于 DPFunc，说明 MZSGO 在语义距离层面更接近真实标签。BP 本体的生物过程标签层级结构最为复杂，标签间的语义重叠度高，加权指标上的微小差距反映了这一挑战的本质难度。

（3）ProtNote 在加权指标上的表现显著劣于其他方法（尤其是 S_{min} 高达 40.9251 和 12.0812），这进一步说明 ProtNote 虽然能够进行零样本预测，但其预测质量（特别是对生物学上重要的精细功能的预测精度）仍有较大差距。ProtNote 采用的简单 one-hot 序列编码和联合训练策略限制了其对功能语义细节的捕获能力。

3.4.6 层级一致性分析

Gene Ontology 的 GO 术语以有向无环图（DAG）的形式组织，这暗含了 True Path Rule（TPR）[47]：如果一个蛋白质被注释了某个特定术语，则它必须同时被注

释该术语的所有祖先术语。反之，如果一个蛋白质未被注释某个术语，则它不能被注释该术语的任何后代术语。

层级传播机制。

为评估显式的层级约束是否能增强 MZSGO 的性能，本文实现了后处理层级传播机制，记为 **MZSGO_PROP**。给定蛋白质在 L 个标签上的原始预测分数 S，通过按照 DAG 结构将子节点的最大分数传播至父节点来确保层级一致性：

$$S_p^* = \max\left(S_p, \max_{c \in \text{children}(p)} S_c\right) \tag{3-24}$$

其中 S_p 为父术语的原始分数，S_p^* 为校正后的分数。这保证了父术语的预测分数始终大于等于其任何后代术语的分数。

实验结果与讨论。

表 3-10比较了原始 MZSGO 和引入 TPR 传播后的 MZSGO_PROP 在三个本体上的性能。

表 3-10: 原始 MZSGO 与引入 True Path Rule 传播的 MZSGO_PROP 的性能对比。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
BP	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
	MZSGO_PROP	**0.5066**	**0.5046**	**0.2394**	**0.5060**	**0.3250**
MF	MZSGO	0.7611	0.7337	**0.4806**	0.7380	0.5821
	MZSGO_PROP	**0.7628**	**0.7356**	**0.4806**	**0.7399**	**0.5827**
CC	MZSGO	0.7470	0.7726	**0.5862**	0.7733	0.6669
	MZSGO_PROP	**0.7482**	**0.7736**	**0.5862**	**0.7743**	**0.6672**

从实验结果可以观察到，引入显式的 TPR 传播仅带来了边际性的改善（例如 Fmax 提升不足 0.3%）。这一发现具有重要的方法学意义，表明 MZSGO 的多模态匹配机制**天然地具备了隐式捕获层级依赖关系的能力**。

分析其原因，基于 LLM 的 GO 定义嵌入在潜在空间中将语义上（因此也是层级上）相关的术语定位在相近的位置。由于 GO 的层级结构中，父术语的定义通常是子术语定义的语义泛化——例如”kinase activity”（父）与”protein kinase activity”（子）——LLM 编码器自然会为它们生成相似的嵌入表示。这意味着当模型预测某个蛋白质与子术语匹配时，由于父术语嵌入的相近性，模型也倾向于给予父术语较高的匹配分数，从而在不需要显式层级约束的情况下隐式地满足了 True Path Rule。

这一结果进一步验证了基于 LLM 语义嵌入的 MZSGO 方法在蛋白质功能预测任务中的合理性——深层语义表示不仅能够支持零样本推理，还能自然地编码 GO 的拓扑层级信息，避免了传统方法中复杂的后处理层级传播步骤或刚性的架构约束。

3.5 本章小结

本章提出了多模态零样本蛋白质功能注释方法 MZSGO，其核心创新在于三个方面：（1）将蛋白质功能预测从封闭标签集分类重新定义为开放语义空间中的蛋白质-GO 匹配问题，通过大语言模型构建域和标签的统一语义空间，从根本上赋予模型零样本推理能力；（2）设计了自适应门控融合模块，实现逐样本动态的多模态特征整合，克服了传统简单拼接方式的局限；（3）引入非对称特征丢弃策略，在训练阶段增强模型对模态缺失的鲁棒性。

实验结果表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下则以压倒性优势超越所有现有方法。其中，在最具挑战性的 CC 本体零样本场景下，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍。

通过多维度的深入分析，本章对 MZSGO 的各个组件和设计决策进行了全面验证：消融实验在三个本体上一致性地证明了域语义信息、门控融合机制和特征丢弃策略各自的不可替代性；基于 Gini 系数和有效性比率的统计分析为不同本体的损失函数选择提供了理论依据；嵌入空间可视化分析直观地揭示了 MZSGO 通过域-功能语义邻近性实现零样本推理的内在机制；门控权重分析证实了模型能够根据本体特性和标签可见性动态调整多模态信息的整合策略；加权评价指标实验验证了 MZSGO 对功能特异性较高的 GO 术语同样保持了优异的预测精度；True Path Rule 实验则表明基于 LLM 语义嵌入的方法天然地编码了 GO 的层级拓扑信息。综上，MZSGO 为蛋白质功能注释，特别是新功能标签的预测，提供了可靠且有效的计算工具。

第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA

4.1 引言

第三章提出的 MZSGO 方法通过多模态语义融合在蛋白质功能预测任务上取得了优异的性能，尤其在零样本场景下展现了显著的优势。然而，MZSGO 存在一个本质局限：蛋白质语言模型 ESM2 被用作静态特征提取器，其参数在下游训练中保持冻结，无法根据功能预测任务进行自适应调整。这意味着 ESM2 输出的序列嵌入仅包含通用的进化信息，缺乏与蛋白质域功能语义相关的先验知识。同时，由于域嵌入在训练前即已预计算并缓存，整个管线缺乏端到端的梯度流动，限制了模型进一步提升的空间。

针对上述问题，本章提出基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA（MZSGO with Domain-Aware adapter pretraining）。MZSGO-DA 的灵感来源于 S-PLM[32]——一种结构感知的蛋白质语言模型。S-PLM 通过在 ESM2 的 Transformer 层中注入轻量级适配器模块，利用对比学习将蛋白质三维结构信息蒸馏至序列编码器，使其仅凭序列输入即可生成包含结构感知的表示。MZSGO-DA 借鉴了 S-PLM" 通过对比学习将跨模态知识蒸馏至适配器" 这一核心思想，但在以下方面进行了重要的拓展和创新：

（1）**蒸馏目标不同**。S-PLM 的蒸馏目标是蛋白质三维结构信息，而 MZSGO-DA 将其替换为蛋白质域的功能语义信息。蛋白质域作为独立的功能和结构单元，其自然语言描述蕴含着丰富的功能先验，与蛋白质功能预测任务的关联性更为直接。

（2）**下游训练策略不同**。S-PLM 在预训练后采用冻结或微调适配器的常规策略应用于下游任务。MZSGO-DA 则创新性地提出了双适配器端到端训练策略——冻结预训练适配器以保留域语义先验，同时引入第二组可训练适配器进行任务特定适配，实现了预训练知识保留与下游任务优化的有效平衡。

（3）**域嵌入的处理方式不同**。S-PLM 的结构编码器（Swin-Transformer）在预训练时直接处理蛋白质接触图，而 MZSGO-DA 使用预训练的大语言模型 Qwen3-Embedding 对域文本描述进行语义编码，将自然语言级别的功能先验引入蛋白质表示学习。

本章的组织结构如下：首先分析域感知适配器预训练的研究动机与任务构建；随后介绍 MZSGO-DA 的总体框架、适配器机制及端到端训练策略；最后通过对比实验、消融实验以及训练过程分析验证方法的有效性。

4.2 域感知适配器预训练任务构建

4.2.1 问题动机与设计目标

MZSGO 采用静态嵌入策略：首先使用冻结的 ESM2 提取所有蛋白质的序列嵌入并缓存至磁盘，然后在训练阶段直接读取这些预计算的向量。这种策略虽然计算高效，但存在三方面不足：

（1）**信息瓶颈**。ESM2 的通用预训练目标是掩码语言建模，学习到的表示侧重于序列进化约束和氨基酸共现模式，而非特定于功能预测任务的信息。当功能注释依赖于蛋白质域的结构功能特征时，通用序列嵌入可能丢失关键线索。

（2）**梯度断裂**。由于 ESM2 参数完全冻结且嵌入预计算，下游分类器的梯度无法回传至序列编码器，模型无法通过反向传播调整序列表征以更好地适配功能预测目标。

（3）**域信息依赖**。MZSGO 在推理时需要显式输入蛋白质的域嵌入，而 InterPro 数据库中约 20% 的蛋白质缺乏域注释，这部分蛋白质只能使用零向量作为域特征占位符，降低了预测质量。

MZSGO-DA 通过两阶段策略系统性地解决上述问题。受 S-PLM[32] 利用对比学习在适配器中蒸馏结构信息的启发，MZSGO-DA 将这一思路应用于域语义信息的蒸馏：第一阶段（预训练），通过对比学习将域语义信息”内化”至序列编码器的适配器参数中；第二阶段（下游训练），通过端到端训练打通梯度通路，使序列表征能够根据功能预测目标进行自适应调整。与 S-PLM 的单适配器预训练策略不同，MZSGO-DA 引入了双适配器机制，冻结预训练适配器以保护域知识，同时引入可训练适配器进行任务适配。预训练完成后，即使不显式输入域信息，序列编码器也能产出包含域语义先验的增强表示。

4.2.2 域感知对比学习任务

基于上述动机，本章将域文本描述视为序列编码器的跨模态监督信号，构建“蛋白质序列—域语义”对比学习预训练任务。该任务以蛋白质序列为输入、以域文本嵌入为语义锚点，通过正负样本配对学习将域功能先验蒸馏到适配器参数中，为后续端到端功能预测提供域感知初始化。其具体网络结构、损失函数与下游迁移方式将在 4.3 节中进一步展开。

4.3 MZSGO-DA 模型设计

4.3.1 总体框架

MZSGO-DA 的训练流程分为两个阶段，如图 4-1所示。

第一阶段：域感知对比学习预训练。在 ESM2 的 Transformer 层中注入一组轻量级适配器模块（记为 adapter_0），冻结 ESM2 原始参数，仅训练适配器参数。通过 InfoNCE 对比学习损失，将蛋白质序列的适配器增强表示与对应的域文本嵌入（由 Qwen3-Embedding 预计算）进行对齐。预训练完成后，adapter_0 中编码了蛋白质域的语义先验。

第二阶段：双适配器端到端下游训练。冻结 adapter_0 的参数，在同一 ESM2 模型中注入第二组适配器（adapter_1），使其可训练。两组适配器在每个 Transformer 层内并行运行，输出取平均。adapter_0 保持域语义先验，adapter_1 学习任务特定的适配信息。序列经 ESM2+ 双适配器编码后，与 GO 标签文本嵌入进行门控融合，最终输出功能预测概率。

图 4-1: MZSGO-DA 两阶段训练流程。第一阶段通过对比学习将域语义信息蒸馏至适配器；第二阶段冻结预训练适配器，引入新适配器进行端到端功能预测训练。

4.3.2 适配器模块与注入机制

本文设计了基于残差多层感知机（ResMLP）的轻量级适配器模块。每个适配器由降维线性层、ReLU 激活函数、升维线性层和层归一化组成，并通过残差连接保留原始信息流：

$$\text{Adapter}(\mathbf{x}) = \text{LN}(\mathbf{W}_{up} \cdot \text{ReLU}(\mathbf{W}_{down} \cdot \mathbf{x})) + \mathbf{x} \tag{4-1}$$

其中 $\mathbf{W}_{down} \in \mathbb{R}^{d_b \times d}$ 为降维矩阵，$\mathbf{W}_{up} \in \mathbb{R}^{d \times d_b}$ 为升维矩阵，$d = 1280$ 为 ESM2 的隐藏维度，$d_b = d/2 = 640$ 为瓶颈维度，LN 为层归一化。

与传统适配器设计[48] 不同，本文采用**纯净残差连接**策略，即残差加法在层归一化之外执行。这一设计借鉴了 S-PLM[32] 中适配器的架构经验，避免了层归一化包裹残差连接可能引发的梯度缩放问题，有助于在深层 Transformer 网络中保持稳定的梯度传播。

适配器注入机制。适配器模块被注入 ESM2 Transformer 层的两个关键位置：

（1）**自注意力输出之后**：在多头自注意力的输出（残差连接之前）插入适配器，使其能够调制注意力模式：

$$\mathbf{X}_{attn} = \mathrm{MHA}(\mathrm{LN}(\mathbf{X})) \tag{4-2}$$

$$\mathbf{X}'_{attn} = \mathrm{Adapter}_{attn}(\mathbf{X}_{attn}) \tag{4-3}$$

$$\mathbf{X}' = \mathbf{X} + \mathbf{X}'_{attn} \tag{4-4}$$

（2）**前馈网络输出之后**：在 FFN 的输出（残差连接之前）插入适配器，使其能够调制特征变换：

$$\mathbf{X}_{ffn} = \mathrm{FFN}(\mathrm{LN}(\mathbf{X}')) \tag{4-5}$$

$$\mathbf{X}'_{ffn} = \mathrm{Adapter}_{ffn}(\mathbf{X}_{ffn}) \tag{4-6}$$

$$\mathbf{X}'' = \mathbf{X}' + \mathbf{X}'_{ffn} \tag{4-7}$$

因此，每个 Transformer 层包含两个适配器实例（分别用于注意力子层和 FFN 子层），一组适配器共包含 $2N_{layer}$ 个 ResMLP 模块。

本文采用**运行时动态注入**策略：不修改 ESM2 的源代码，而是在模型加载后通过 Python 的动态属性替换机制，将原始的 TransformerLayer 替换为包含适配器的 AdapterTransformerLayer。该策略与 S-PLM[32] 中的适配器注入方式一致，使适配器模块以即插即用的方式与任何 ESM2 变体兼容。默认仅对 ESM2 最后 $N_{adapter} = 16$ 层（共 33 层）注入适配器，浅层保持原始参数不变以保留通用序列表示能力。

当存在多组适配器（如双适配器策略中的 $\mathrm{adapter}_0$ 和 $\mathrm{adapter}_1$）时，各组适配器在同一层内并行计算，输出通过均匀加权取平均：

$$\mathbf{X}_{adapter} = \frac{1}{G}\sum_{g=1}^{G} \mathrm{Adapter}^{(g)}(\mathbf{X}) \tag{4-8}$$

其中 G 为适配器组数（预训练时 $G = 1$，下游训练时 $G = 2$）。

4.3.3 域感知对比学习预训练

预训练阶段的目标是将蛋白质域的语义信息蒸馏至序列编码器的适配器参数中。

序列编码器。

将蛋白质序列 P 输入注入 $\mathrm{adapter}_0$ 的 ESM2 模型，获得每个残基位置的上下文嵌入，通过平均池化（排除填充位和特殊 token）获得蛋白质级表示：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0}(P)) \in \mathbb{R}^{1280} \tag{4-9}$$

域嵌入。

蛋白质域的文本嵌入 $\mathbf{h}_{dom} \in \mathbb{R}^{2560}$ 由 Qwen3-Embedding-4B 预计算并缓存，编码方式与第三章 MZSGO 相同。

投影头。

为将序列表示和域嵌入映射至共享的对比空间，设计两个独立的投影头：

$$\mathbf{z}_{seq} = \text{ProjHead}_{seq}(\mathbf{h}_{seq}) \in \mathbb{R}^{d_p} \tag{4-10}$$

$$\mathbf{z}_{dom} = \text{ProjHead}_{dom}(\mathbf{h}_{dom}) \in \mathbb{R}^{d_p} \tag{4-11}$$

其中 $d_p = 256$ 为投影维度。每个投影头由两层 MLP 组成：

$$\text{ProjHead}(\mathbf{x}) = \text{LN}(\mathbf{W}_2 \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_1 \cdot \mathbf{x})))) \tag{4-12}$$

中间隐藏维度为 512。输出向量经 L2 归一化后用于计算余弦相似度。

InfoNCE 对比损失。

给定一批 B 个蛋白质样本，每个样本 i 对应序列投影 $\mathbf{z}^i_{seq}$ 和域投影 $\mathbf{z}^i_{dom}$ 构成正样本对，同一批次中其他样本构成负样本对。采用双向 InfoNCE 损失进行优化：

$$\mathcal{L}_{seq\to dom} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}^i_{seq}, \mathbf{z}^i_{dom})/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}^i_{seq}, \mathbf{z}^j_{dom})/\tau)} \tag{4-13}$$

$$\mathcal{L}_{dom\to seq} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}^i_{dom}, \mathbf{z}^i_{seq})/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}^i_{dom}, \mathbf{z}^j_{seq})/\tau)} \tag{4-14}$$

$$\mathcal{L}_{CL} = \frac{1}{2}(\mathcal{L}_{seq\to dom} + \mathcal{L}_{dom\to seq}) \tag{4-15}$$

其中 $\text{sim}(\cdot,\cdot)$ 为余弦相似度，$\tau = 0.07$ 为温度超参数。

通过这种双向对比学习，adapter_0 被训练为能够将 ESM2 的序列表示调制至与域嵌入对齐的语义空间。预训练完成后，adapter_0 中的参数编码了将序列特征映射至域感知空间的变换，即使后续不提供域嵌入输入，ESM2+adapter_0 的输出也隐式地包含了域的功能语义信息。

4.3.4 双适配器端到端下游训练

预训练完成后，进入端到端的下游功能预测阶段。

双适配器策略。

冻结 adapter_0 的所有参数，将预训练学到的域语义先验” 锁定”。在 ESM2 的同一组 Transformer 层中注入第二组适配器 adapter_1，随机初始化其参数。adapter_1 为可训练状态，负责学习功能预测任务特定的适配信息。

与 S-PLM[32] 在预训练后仅使用单组适配器进行下游任务不同，MZSGO-DA 的双适配器策略具有以下优势：

（1）**知识保留**：adapter_0 冻结后，预训练阶段通过对比学习学到的域-序列对齐知识不会在下游训练中被覆盖或遗忘。

（2）**任务适配**：adapter_1 提供了额外的可学习参数，使模型能够在保持域先验的同时适应特定的功能预测目标。

（3）**稳定性**：两组适配器的输出取平均，相当于一种集成效应，有助于稳定训练和提升泛化能力。

端到端序列编码。

与 MZSGO 不同，MZSGO-DA 在下游训练时不使用预计算的静态嵌入，而是在每个训练迭代中实时运行 ESM2+ 双适配器前向传播。为节省显存，前向传播跳过 ESM2 的语言模型头（LM Head）和接触预测头（Contact Head），仅执行 Transformer 编码器部分：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0+adapter_1}(P)) \in \mathbb{R}^{1280} \tag{4-16}$$

特征投影与门控融合。

MZSGO-DA 的下游分类架构简化为双模态融合：序列特征和 GO 标签文本嵌入。由于域语义信息已通过 adapter_0 内化至序列表示中，推理时不再需要显式输入域嵌入。

序列特征和 GO 标签嵌入分别经过投影后，输入双模态门控融合模块（Gated-FusionModule2）。该模块与第三章的三模态版本类似，但仅处理两个输入：

$$\mathbf{h}'_{seq} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{seq}\mathbf{h}_{seq}))) \in \mathbb{R}^{512} \tag{4-17}$$

$$\mathbf{h}'_{label} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{label}\mathbf{E}_{label}))) \in \mathbb{R}^{512} \tag{4-18}$$

在训练阶段，同样对序列特征施加模态丢弃策略（丢弃率 $p = 0.15$），以增强模型对序列信息缺失场景下的鲁棒性。

门控融合模块计算自适应权重并生成融合表示：

$$\boldsymbol{\alpha} = \text{Softmax}(\mathbf{W}_{gate} \cdot \text{ReLU}(\text{LN}(\mathbf{W}_{ctx}[\hat{\mathbf{h}}'_{seq} \parallel \mathbf{h}'_{label}]))) \tag{4-19}$$

$$\mathbf{H}_{fused} = \alpha_1 \cdot \phi_{seq}(\hat{\mathbf{h}}'_{seq}) + \alpha_2 \cdot \phi_{label}(\mathbf{h}'_{label}) \tag{4-20}$$

其中 $\boldsymbol{\alpha} \in \mathbb{R}^2$ 为归一化的门控权重。

分类与损失函数。

融合表示经过分类 MLP 生成逻辑值：

$$\hat{y} = \sigma(\mathbf{W}_{out} \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{cls}\mathbf{H}_{fused})))) \tag{4-21}$$

其中分类头将 512 维融合特征压缩至 256 维，再投影至 1 维输出。

下游训练使用二分类交叉熵损失（BCEWithLogitsLoss）：

$$\mathcal{L}_{task} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)] \tag{4-22}$$

下游阶段的可训练参数包括：adapter_1 的所有参数、特征投影层、门控融合模块和分类头。ESM2 的原始参数和 adapter_0 均保持冻结。

4.4 实验结果及分析

4.4.1 对比实验结果与分析

为保证比较结果的可复现性与公平性，本节先介绍数据集、实现细节、基线方法和评价指标，随后对 MZSGO-DA 与 MZSGO 的性能差异进行系统分析。

数据集。

MZSGO-DA 使用与第三章 MZSGO 相同的数据集，包括基于 CAFA5 和 Swiss-Prot 的训练集、标准测试集，以及通过时间演进方式构建的零样本测试集。数据集统计信息详见第三章表 3-1和表 3-2。

实现细节。

预训练阶段。

对比学习预训练基于 PyTorch[44] 分布式数据并行（DDP）框架实现，使用 6 块 NVIDIA GPU 进行训练。ESM2 选用 esm2_t33_650M_UR50D 变体（33 层 Transformer，隐藏维度 1280）。适配器注入最后 16 层，瓶颈维度 640。使用 AdamW[49] 优化器，学习率 1×10^{-4}，权重衰减 1×10^{-4}。训练采用余弦退火学习率调度，预热比例 0.1。每张 GPU 的批次大小为 8，梯度累积步数为 2，有效批次大小为 96。训练最多 50 个 epoch，使用早停策略（耐心值 5）防止过拟合。训练过程使用 FP16 混合精度加速，梯度裁剪阈值为 1.0。温度超参数 $\tau = 0.07$。

下游训练阶段。

下游训练同样采用 DDP 框架和 6 块 GPU。加载预训练的 adapter_0 参数并冻结，初始化 adapter_1 并设为可训练。每张 GPU 的批次大小为 4（由于端到端前向传播 ESM2 需要更多显存），梯度累积步数为 4，有效批次大小仍为 96。学习率 1×10^{-4}，隐藏维度 512，分类 Dropout 率 0.3，特征丢弃率 0.15。训练 30 个 epoch，同样使用早停策略。

基线方法。

除了第三章中列出的十种基线方法外，本章额外引入 MZSGO 作为直接对比基线，以评估端到端训练相对于静态嵌入方法的增益。同时将不使用预训练的单适配器端到端方法作为消融基线，记为 MZSGO-DA (w/o pretrain)。

评价指标。

评价指标与第三章一致，包括有监督指标 $F_{\max}$ 和 AUPR，零样本指标 Unseen AUPR 和 Seen AUPR，以及综合评价指标调和均值 H。

与 MZSGO 的性能对比。

表 4-1展示了 MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。

表 4-1: MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。Δ 表示 MZSGO-DA 相对于 MZSGO 的绝对提升。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
BP	MZSGO-DA	**0.5103**	**0.5076**	**0.2517**	**0.5092**	**0.3366**
	Δ	+0.0058	+0.0068	+0.0124	+0.0071	+0.0125
	MZSGO	0.7611	0.7337	0.4806	0.7380	0.5821
MF	MZSGO-DA	**0.7682**	**0.7421**	**0.4963**	**0.7460**	**0.5957**
	Δ	+0.0071	+0.0084	+0.0157	+0.0080	+0.0136
	MZSGO	0.7470	0.7726	0.5862	0.7733	0.6669
CC	MZSGO-DA	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**
	Δ	+0.0066	+0.0077	+0.0179	+0.0077	+0.0146

从实验结果可以观察到：

（1）**全面的性能提升**。MZSGO-DA 在三个 GO 本体的所有指标上均优于 MZSGO，验证了端到端训练策略和域感知适配器预训练的有效性。

（2）**零样本指标提升尤为显著**。在 Unseen AUPR 上，MZSGO-DA 在 BP、MF

和 CC 本体上分别获得 +0.0124、+0.0157 和 +0.0179 的提升，且调和均值 H 的提升幅度（+0.0125 至 +0.0146）一致超过有监督指标（Fmax 提升 +0.0058 至 +0.0071）。这表明域感知预训练通过将域语义信息内化至序列编码器，增强了模型对未见标签的泛化能力。

（3）**端到端训练的梯度优势**。MZSGO-DA 的有监督指标也获得了稳定提升，说明端到端训练使序列编码器能够根据功能预测目标进行微调，产出更具区分性的表示。

4.4.2 消融实验结果与分析

为分析 MZSGO-DA 各组件的贡献，本文在 CC 本体上进行了系统的消融实验，结果如表 4-2所示。

表 4-2: MZSGO-DA 在 CC 本体上的消融实验结果。

变体	Fmax	AUPR	Unseen AUPR	Seen AUPR	H
预训练策略消融					
无预训练（随机初始化 adapter_1）	0.7421	0.7654	0.5713	0.7662	0.6561
单 adapter 端到端（无 adapter_0）	0.7448	0.7689	0.5790	0.7698	0.6620
适配器策略消融					
adapter_0 不冻结（双 adapter 均可训练）	0.7502	0.7715	0.5684	0.7721	0.6568
仅 adapter_0（冻结，无 adapter_1）	0.7382	0.7598	0.5923	0.7604	0.6667
注入层数消融					
注入最后 8 层	0.7478	0.7735	0.5862	0.7742	0.6675
注入最后 24 层	0.7510	0.7768	0.5944	0.7774	0.6745
注入全部 33 层	0.7493	0.7751	0.5901	0.7758	0.6710
MZSGO-DA（注入最后 16 层）	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**

消融结果支持以下结论：

（1）**预训练的重要性**。去除预训练后（随机初始化 adapter_1 直接端到端训练），H 从 0.6815 降至 0.6561，降幅达 0.0254。即使使用单 adapter 端到端训练也仅获得 0.6620 的 H 值，均显著低于完整的 MZSGO-DA，证实域感知对比学习预训练为下游任务提供了重要的初始化先验。

（2）**冻结 adapter_0 的必要性**。当 adapter_0 不冻结而是与 adapter_1 联合训练时，有监督指标 Fmax 反而提升至 0.7502，但 Unseen AUPR 下降至 0.5684，H 降至 0.6568。这说明联合训练虽然增加了模型容量，但会导致预训练域知识被下游梯度覆盖，损害零样本泛化能力。冻结 adapter_0 有效保护了预训练知识。

（3）**双适配器的协同效应**。仅使用冻结的 $adapter_0$（不引入 $adapter_1$）进行端到端预测，虽然 Unseen AUPR 较高（0.5923），但 Fmax（0.7382）和总体 AUPR（0.7598）均明显下降。这是因为冻结的 $adapter_0$ 仅学到了域-序列对齐的知识，缺乏功能预测任务的适配能力。双适配器策略通过 $adapter_1$ 提供了任务适配的灵活性，实现了域先验与任务目标的最优平衡。

（4）**注入层数的影响**。从 8 层增加到 16 层带来了显著的性能提升（H 从 0.6675 升至 0.6815），继续增加到 24 层或 33 层反而导致轻微下降。这表明浅层 Transformer 编码了通用的氨基酸表示模式，注入适配器可能干扰这些底层特征；而中高层对功能信息的编码更为敏感，适配器注入能带来最大收益。16 层是表征能力与训练稳定性之间的最优折中。

4.4.3 预训练过程分析

为深入理解对比学习预训练的效果，本文监控了训练过程中正样本对相似度、负样本对相似度和相似度间隔（similarity gap）的变化。

随着训练的推进，正样本对（同一蛋白质的序列表示与域嵌入）的余弦相似度从初始的约 0.1 稳步上升至 0.7 以上，而负样本对（不同蛋白质的序列-域配对）的相似度维持在 0.05 以下。相似度间隔（正样本相似度减去负样本相似度均值）从约 0.05 增长至 0.65 以上，表明适配器成功地将序列表示调制至与域嵌入高度对齐的空间。

训练损失在约 15 个 epoch 后趋于收敛，早停机制在第 20 至 25 个 epoch 附近触发。过长的预训练可能导致过拟合至训练集中的蛋白质-域对应关系，早停策略有效防止了这一问题。

4.4.4 参数效率分析

表 4-3展示了 MZSGO-DA 中各组件的参数量统计。

MZSGO-DA 的可训练参数仅占总参数的 7.3%，远低于全参数微调方案。这种参数高效的设计不仅降低了训练的计算和存储开销，还通过保持 ESM2 原始参数冻结有效防止了灾难性遗忘，确保蛋白质语言模型在通用序列建模方面的能力不受损害。

4.5 本章小结

本章提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法受 S-PLM[32] 利用对比学习在适配器中蒸馏结构信息的启发，将蒸馏

表 4-3: MZSGO-DA 参数量统计。

组件	参数量	状态
ESM2 原始参数	~650M	冻结
$adapter_0$（16 层 ×2 个）	~53M	冻结
$adapter_1$（16 层 ×2 个）	~53M	可训练
特征投影与分类头	~2M	可训练
总计	~758M	—
可训练参数	~55M	7.3%

目标从三维结构信息拓展至蛋白质域的功能语义信息，其核心创新体现在三个方面：

（1）**域感知对比学习预训练**。通过 InfoNCE 对比学习将蛋白质域的语义信息蒸馏至 ESM2 内部的轻量级适配器模块，使序列编码器在不需要显式域输入的情况下即可产出携带域语义先验的增强表示。

（2）**双适配器端到端训练策略**。冻结预训练的 $adapter_0$ 以保留域知识，引入可训练的 $adapter_1$ 进行任务适配。两组适配器在 Transformer 层内并行运行，实现了预训练知识保留与下游任务适配的有效平衡。

（3）**端到端梯度通路**。打破了 MZSGO 中静态嵌入方法的梯度断裂问题，使下游损失信号能够回传至序列编码器，实现了从序列输入到功能预测的完整优化。

实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，验证了域感知适配器预训练和端到端训练策略的有效性。消融实验进一步证实了预训练、冻结策略和双适配器设计各自的必要性。MZSGO-DA 以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配，为蛋白质功能预测领域的预训练-微调范式提供了新的技术方案。

结 论

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，而经实验验证的功能注释比例极低，自动化功能预测方法的需求日益迫切。现有的深度学习方法通常将基因本体功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，限制了模型对未见标签的泛化能力。本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，本文提出了多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码。设计了自适应门控融合模块实现逐样本动态的多模态特征整合，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下以压倒性优势超越所有现有方法。特别是在 CC 本体上，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍，验证了多模态语义融合范式在零样本蛋白质功能预测中的有效性。

其次，本文提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法针对 MZSGO 中静态嵌入策略的信息瓶颈和梯度断裂问题，设计了轻量级适配器模块注入蛋白质语言模型的 Transformer 层内部，通过 InfoNCE 对比学习预训练将蛋白质域的语义信息蒸馏至序列编码器。在下游阶段，采用双适配器策略——冻结预训练适配器保留域知识，引入新适配器进行任务适配——实现端到端训练。实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配。

本文的主要贡献可以归纳为：（1）通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；（2）通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器。

尽管本文方法取得了显著的进展，但仍存在一些局限性和进一步改进的空间：

第一，**融入三维结构信息**。本文目前仅利用了序列和域文本两种模态。虽然 MZSGO 成功整合了序列与文本域信息，但蛋白质的三维空间排列仍然是决定功

能的关键因素。未来计划将 AlphaFold2 预测的结构特征纳入本文的多模态框架中，通过融合三维结构坐标与现有的序列-文本对齐，捕获那些在结构上保守但序列上存在差异的功能基序，从而进一步提升预测精度。

第二，**增强语义推理能力**。现有的 MZSGO 方法主要依赖 GO 术语的文本描述来实现零样本推理，但忽略了 GO 本体的结构丰富性。由于 GO 被组织为包含深层逻辑依赖关系的有向无环图（DAG），未来工作将聚焦于将这些基于图的拓扑约束与 LLM 派生的语义嵌入进行融合。本文预期融合显式的逻辑结构与隐式的语义细微信息将产生更具生物学一致性的标签空间，最终提升模型在复杂功能层级中的导航能力。

第三，本文使用预计算的静态域嵌入和 GO 标签嵌入，而非端到端地训练大语言模型编码器。虽然这在当前硬件条件下是务实的选择，但未来随着计算资源的提升，联合训练蛋白质语言模型和文本编码器可能带来更深层次的跨模态对齐。

第四，本文的零样本评估虽然采用了严格的时间演进策略和序列同源性过滤，但零样本测试集的规模仍然有限，特别是 CC 本体仅有 17 个零样本测试蛋白质。未来需要在更大规模的零样本基准上验证方法的泛化能力。

第五，MZSGO-DA 的端到端训练虽然提升了性能，但显著增加了训练时间和显存消耗。探索更高效的参数高效微调策略（如 LoRA、Prefix Tuning 等）以进一步降低计算开销，是有价值的未来方向。

展望未来，蛋白质功能预测领域可能沿以下方向发展：一是构建更大规模的预训练数据集和更强大的蛋白质基础模型，为下游功能预测提供更丰富的表征；二是探索蛋白质功能预测与蛋白质设计的联合优化，实现从”理解功能”到”设计功能”的跨越；三是将零样本功能预测能力与基因组学、转录组学等多组学数据相结合，为系统生物学研究提供更全面的功能注释工具。

参考文献

[1] EISENBERG D，MARCOTTE E M，XENARIOS I，et al. Protein function in the post-genomic era [J]. Nature，2000，405（6788）：823-826.

[2] JUMPER J，EVANS R，PRITZEL A，et al. Highly accurate protein structure prediction with AlphaFold [J]. nature，2021，596（7873）：583-589.

[3] FRIEDBERG I. Automated protein function prediction—the genomic challenge [J]. Briefings in bioinformatics，2006，7（3）：225-242.

[4] LIN J，XU Z，LU R，et al. A comprehensive review and comparison of existing computational methods for protein function prediction [J]. Briefings in Bioinformatics，2024，25（4）：bbae289.

[5] ASHBURNER M，BALL C A，BLAKE J A，et al. Gene ontology: tool for the unification of biology [J]. Nature genetics，2000，25（1）：25-29.

[6] ZHOU N，JIANG Y，BERGQUIST T R，et al. The CAFA challenge reports improved protein function prediction and new functional annotations for hundreds of genes through experimental screens [J]. Genome biology，2019，20（1）：244.

[7] ALTSCHUL S F，GISH W，MILLER W，et al. Basic local alignment search tool [J]. Journal of molecular biology，1990，215（3）：403-410.

[8] BUCHFINK B，REUTER K，DROST H-G. Sensitive protein alignments at tree-of-life scale using DIAMOND [J]. Nature methods，2021，18（4）：366-368.

[9] KULMANOV M，KHAN M A，HOEHNDORF R. DeepGO: predicting protein functions from sequence and interactions using a deep ontology-aware classifier [J]. Bioinformatics，2018，34（4）：660-668.

[10] KULMANOV M，HOEHNDORF R. DeepGOPlus: improved protein function prediction from sequence [J]. Bioinformatics，2020，36（2）：422-429.

[11] WU Z，GUO M，CHEN X-Y，et al. Hi-FUN: hierarchical fine-grained unified network for protein function prediction [J]. Briefings in Bioinformatics，2023，24（6）：bbad420.

[12] LIN Z，AKIN H，RAO R，et al. Evolutionary-scale prediction of atomic-level protein structure with a language model [J]. Science，2023，379（6637）：1123-1130.

[13] VARADI M, ANYANGO S, DESHPANDE M, et al. AlphaFold Protein Structure Database: massively expanding the structural coverage of protein-sequence space with high-accuracy models [J]. Nucleic acids research, 2022, 50(D1): D419-D427.

[14] GLIGORIJEVIĆ V, RENFREW P D, KOSCIOLEK T, et al. Structure-based protein function prediction using graph convolutional networks [J]. Nature communications, 2021, 12 (1): 3168.

[15] GU Z, LUO X, CHEN J, et al. Hierarchical graph transformer with contrastive learning for protein function prediction [J]. Bioinformatics, 2023, 39 (7): btad410.

[16] JIAO P, WANG B, WANG X, et al. Struct2GO: protein function prediction based on graph pooling algorithm and AlphaFold2 structure information [J]. Bioinformatics, 2023, 39 (10): btad637.

[17] GROVER A, LESKOVEC J. node2vec: Scalable feature learning for networks [C] // Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining, 2016: 855-864.

[18] WANG W, SHUAI Y, ZENG M, et al. DPFunc: accurately predicting protein function via deep learning with domain-guided structure information [J]. Nature communications, 2025, 16 (1): 70.

[19] YOU R, YAO S, MAMITSUKA H, et al. DeepGraphGO: graph neural network for large-scale, multispecies protein function prediction [J]. Bioinformatics, 2021, 37 (Supplement_1): i262-i271.

[20] JONES P, BINNS D, CHANG H-Y, et al. InterProScan 5: genome-scale protein function classification [J]. Bioinformatics, 2014, 30 (9): 1236-1240.

[21] KULMANOV M, HOEHNDORF R. DeepGOZero: improving protein function prediction from sequence and zero-shot learning based on ontology axioms [J]. Bioinformatics, 2022, 38 (Supplement_1): i238-i245.

[22] KULMANOV M, HOEHNDORF R. Embeddings from protein language models predict conservation and variant effects [J]. Human Genetics, 2019, 141: 1629-1647.

[23] KULMANOV M, GUZMÁN-VEGA F J, DUEK ROGGLI P, et al. Protein function prediction as approximate semantic entailment [J]. Nature Machine Intelligence, 2024, 6 (2): 220-228.

[24] LI W，WANG B，DAI J，et al. Partial order relation–based gene ontology embedding improves protein function prediction [J]. Briefings in Bioinformatics，2024，25（2）：bbae077.

[25] WANG B，GENG Y，CHENG X，et al. ProtGO: universal protein function prediction utilizing multi-modal gene ontology knowledge [J]. Bioinformatics，2025，41（7）：btaf390.

[26] WU Z，GUO M，JIN J，et al. CFAGO: cross-fusion of network and attributes based on attention mechanism for protein function prediction [J]. Bioinformatics，2023，39（3）：btad123.

[27] CHAR S，CORLEY N，ALAMDARI S，et al. ProtNote: a multimodal method for protein–function annotation [J]. Bioinformatics，2025，41（5）：btaf170.

[28] YOU R，HUANG X，ZHU S. DeepText2GO: improving large-scale protein function prediction with deep semantic text representation [J]. Methods，2018，145：82-90.

[29] ZHANG N，BI Z，LIANG X，et al. OntoProtein: Protein pretraining with gene ontology embedding [J]. arXiv preprint arXiv:2201.11147，2022.

[30] XU M，YUAN X，MIRET S，et al. ProtST: Multi-modality learning of protein sequences and biomedical texts [J]. arXiv preprint arXiv:2301.12040，2023.

[31] HU M-L，YUAN F，YANG K K，et al. Protein language models and structure prediction: connections and progressions [J]. arXiv preprint arXiv:2211.16742，2023.

[32] WANG D，POURJAFARI D，YI F，et al. S-PLM: Structure-aware protein language model via contrastive learning between sequence and structure [J]. Bioinformatics，2025，41（3）：btaf105.

[33] ABDINE H，CHABÉ-FERRET M，SALMA K，et al. Prot2Text: Multimodal protein's function generation with GNNs and transformers [J]. Proceedings of the AAAI Conference on Artificial Intelligence，2024，38（10）：10757-10765.

[34] FEI Z，ABDINE H，CHATELAIN C. Prot2Text-V2: Leveraging large language models for protein function prediction [J]. arXiv preprint arXiv:2504.10362，2025.

[35] DUAN J，CAI Z，REN J，et al. PAIR: Protein-Aligned Instruction-Response for Large Language Model Based Protein Function Reasoning [J]. arXiv preprint arXiv:2502.12281，2025.

[36] GOEMAN J J，MANSMANN U. Multiple testing on the directed acyclic graph of gene ontology [J]. Bioinformatics，2008，24（4）：537-544.
[37] BOUTET E，LIEBERHERR D，TOGNOLLI M，et al. UniProtKB/Swiss-Prot: the manually annotated section of the UniProt KnowledgeBase [G] //Plant bioinformatics: methods and protocols. Springer，2007：89-112.
[38] HOANG M，SINGH M. Locality-aware pooling enhances protein language model performance across varied applications [J]. Bioinformatics，2025，41（Supplement_1）：i217-i226.
[39] ZHANG Y，LI M，LONG D，et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models [J]. arXiv preprint arXiv:2506.05176，2025.
[40] BLUM M，ANDREEVA A，FLORENTINO L C，et al. InterPro: the protein sequence classification resource in 2025 [J]. Nucleic acids research，2025，53（D1）：D444-D456.
[41] BA J L，KIROS J R，HINTON G E. Layer normalization [J]. arXiv preprint arXiv:1607.06450，2016.
[42] HENDRYCKS D. Gaussian Error Linear Units (Gelus) [J]. arXiv preprint arXiv:1606.08415，2016.
[43] CUI Y，JIA M，LIN T-Y，et al. Class-balanced loss based on effective number of samples [C] //Proceedings of the IEEE/CVF conference on computer vision and pattern recognition，2019：9268-9277.
[44] PASZKE A，GROSS S，MASSA F，et al. Pytorch: An imperative style, high-performance deep learning library [J]. Advances in neural information processing systems，2019，32.
[45] KINGMA D P. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980，2014.
[46] SRIVASTAVA N，HINTON G，KRIZHEVSKY A，et al. Dropout: a simple way to prevent neural networks from overfitting [J]. The journal of machine learning research，2014，15（1）：1929-1958.
[47] NOTARO M，FRASCA M，PETRINI A，et al. HEMDAG: a family of modular and scalable hierarchical ensemble methods to improve Gene Ontology term prediction [J]. Bioinformatics，2021，37（23）：4526-4533.
[48] HOULSBY N，GIBER A，JASTRZEBSKI S，et al. Parameter-efficient transfer learning for NLP [C] //International conference on machine learning，2019：2790-2799.
[49] LOSHCHILOV I，HUTTER F. Decoupled weight decay regularization [C] //International conference on learning representations，2019.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

Boyue Cui, Beibei Wang, Xuan Wang, Junyi Li. ”MZSGO: Multimodal Zero-Shot Gene Ontology Annotation via Evolutionary Signals and Textual Semantics” 期刊 Bioinformatics (Oxford University Press) 在投。

（二）申请及已获得的专利

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于多模态预训练的蛋白质功能预测研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

时光荏苒，转眼间两年半的硕士研究生生涯已近尾声。在完成毕业论文之际，百感交集。回望来路，深知今日之成果绝非一人之力所能及——正是众多师长、亲友的无私支持与倾心相助，才让我得以坚定前行、顺利完成学业。在此，谨以最诚挚的心意，向所有曾给予我关怀与帮助的人致以深深的谢意。

首先，谨向我的导师李君一老师致以最诚挚的感谢。在攻读硕士学位期间，您不仅在学术研究上给予我系统而深入的指导，更在科研方法和学术写作方面耐心地培养了我的逻辑思维能力和独立研究能力。在论文选题、实验设计和论文撰写的每一个阶段，您始终认真细致地审阅我的工作，提出了大量富有针对性的建议和改进意见，使我能够不断完善研究方案并提升论文质量。您的严谨治学态度与无私付出令我受益匪浅。此外，在日常学习与生活中，您也给予我们充分的关怀与支持，为我顺利完成学业提供了重要保障。

其次，我要感谢我的同门。在科研探索的过程中，我们相互交流、共同进步，面对研究中的困难与挑战，彼此分享思路与经验。特别感谢师姐王贝贝在蛋白质功能预测领域的宝贵指导和经验分享，为我的研究工作提供了重要参考。与同门们共同讨论课题，使我在学术视野与研究能力上均受益良多，每一次交流都对我的研究工作产生了积极而深远的影响。

随后，我要特别感谢我的家人。在攻读硕士学位的这几年中，面对学业与科研带来的压力，是你们始终如一的理解、包容与鼓励，给予我坚持前行的力量。每一次电话中的关怀、每一次回家时温暖的陪伴，都让我深切感受到无言却深厚的爱与支持。正是你们在背后的默默付出，成为我顺利完成学业的重要支撑。

同时，我也衷心感谢我的朋友们。在求学与科研的过程中，你们的陪伴、理解与鼓励，为这段紧张而充实的时光增添了温度。无论是低谷时的倾听，还是前行中的相互支持，你们都让我在忙碌与压力之中保持信心与动力。

最后，我要衷心感谢哈尔滨工业大学。四年在哈尔滨本部、两年在深圳校区的学习经历，使我在学术视野与专业能力上都得到了系统而全面的培养。从专业课程的科学设置，使我得以扎实而深入地掌握相关理论与方法。学院的每一位老师都治学严谨、认真负责，其言传身教不仅传授了专业知识与研究方法，也深刻塑造了我严谨求实的学术态度。感谢学校和学院多年来的悉心培养，未来我将秉持在此形成的治学精神，继续努力，在各自岗位上践行哈工大的校训与精神。

衷心感谢老师的悉心教诲、同学的并肩前行、朋友的温暖陪伴以及家人的坚

定支持，使我得以顺利走过这段研究生时光。未来，我将带着这份感激与收获，继续前行。