硕士学位论文

（专业学位论文）

基于多模态预训练的蛋白质功能预测研究

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

崔博越

哈尔滨工业大学

2026 年 5 月

国内图书分类号：TP391　　学校代码：10213
国际图书分类号：68T07　　密级：公开

硕士学位论文

基于多模态预训练的蛋白质功能预测研究

硕士研究生：崔博越

导　　师：李君一教授

申请学位：专业硕士

类　　别：计算机技术

所在单位：哈尔滨工业大学（深圳）

答辩日期：2026 年 05 月

授予学位单位：哈尔滨工业大学

Classified Index: TP391
U.D.C: 68T07

Dissertation for the Master Degree

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

Candidate: Boyue Cui
Supervisor: Prof. Junyi Li
Academic Degree Applied for: Master of Engineering
Specialty: Computer Technology
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: May, 2026
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，然而经实验验证的功能注释比例极低，序列-功能鸿沟日益加深。现有的深度学习方法通常仅依赖序列模式特征，将蛋白质域信息和基因本体（Gene Ontology, GO）功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，从而限制了模型对未见标签的泛化能力。针对上述问题，本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，提出多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码，通过三路特征投影将异构表示映射至共享语义空间。设计了自适应门控融合模块动态调节各模态贡献权重，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在标准测试集上的有监督指标达到最优水平，尤其在零样本场景下显著超越现有方法。

其次，为进一步提升序列表征的功能感知能力，提出基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法设计了轻量级适配器模块，以即插即用方式注入蛋白质语言模型的 Transformer 层内部；通过对比学习预训练，将蛋白质域的语义信息蒸馏至序列编码器，使模型仅凭序列输入即可产出携带域信息的嵌入表示。在下游阶段，采用双适配器策略实现端到端训练，兼顾预训练知识保留与任务特定适配。实验结果表明，MZSGO-DA 在端到端场景下进一步提升了功能预测性能。

本文的创新性体现在：一方面，通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；另一方面，通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器，提升了模型的表征能力与泛化性能。

关键词：蛋白质功能预测；零样本学习；多模态融合；蛋白质语言模型；基因本体

Abstract

Protein function prediction is a fundamental task in bioinformatics. With the rapid advancement of high-throughput sequencing technologies, protein sequence data has grown exponentially, yet the proportion of experimentally validated functional annotations remains extremely low, deepening the sequence-function gap. Existing deep learning methods typically rely solely on sequence pattern features, treating protein domain information and Gene Ontology (GO) functional labels as simple categorical identifiers while neglecting the rich semantic information embedded in their textual definitions. This limits model generalization to unseen labels. To address these challenges, this thesis investigates two complementary directions—multimodal semantic fusion and pretrained domain-aware adaptation—and proposes two progressively advanced protein function prediction frameworks.

First, we propose MZSGO, a Multimodal Zero-Shot protein function annotation method. MZSGO redefines protein function prediction as a protein-GO matching problem. It employs the protein language model ESM2 to extract evolutionary sequence features and utilizes the large language model Qwen3-Embedding as a unified semantic encoder for both protein domain descriptions and GO functional definitions. Three independent projection modules map these heterogeneous representations into a shared latent space. An adaptive gated fusion module dynamically adjusts the contribution weights of each modality, while an asymmetric feature dropout strategy enhances robustness against modality absence. Experiments demonstrate that MZSGO achieves state-of-the-art performance on standard benchmarks, with particularly significant improvements in zero-shot scenarios.

Second, to further enhance the functional awareness of sequence representations, we propose MZSGO-DA, a Domain-Aware adapter pretraining approach for end-to-end protein function prediction. This method designs lightweight adapter modules that are injected directly into the Transformer layers of the protein language model in a plug-and-play manner. Through contrastive learning pretraining, domain semantic information is distilled into the sequence encoder, enabling the model to produce domain-aware embeddings from sequence input alone. In the downstream stage, a dual-adapter strategy supports end-to-end training while preserving pretrained knowledge and enabling task-specific adaptation. Experimental results show that MZSGO-DA further improves prediction performance in the end-to-end setting.

The main contributions of this thesis are twofold: on one hand, by introducing large language models to construct a unified semantic space for domains and labels, we achieve a paradigm shift from closed-set to open-set protein function prediction, endowing the model with zero-shot reasoning capabilities; on the other hand, through domain-aware contrastive pretraining and a dual-adapter end-to-end training mechanism, we efficiently inject multimodal knowledge into the sequence encoder without modifying the original protein language model parameters, enhancing both representational capacity and generalization performance.

Keywords: protein function prediction, zero-shot learning, multimodal fusion, protein language model, Gene Ontology

目 录

摘 要 I
ABSTRACT II
第 1 章 绪论 1
1.1 课题研究背景和意义 1
1.1.1 课题研究背景 1
1.1.2 研究目的和意义 2
1.2 国内外研究现状 3
1.2.1 基于多模态信息融合的功能预测方法 4
1.2.2 基于零样本预测的功能预测方法 6
1.2.3 基于预训练的功能预测方法 7
1.3 本文的主要研究内容 10
1.4 本文的组织结构 11
第 2 章 蛋白质功能预测的相关研究概述 12
2.1 引言 12
2.2 蛋白质功能预测问题 12
2.2.1 蛋白质功能预测问题的定义 12
2.2.2 蛋白质功能预测的评价指标 14
2.3 表征学习基础技术 15
2.3.1 Transformer 架构 15
2.3.2 ESM-2 蛋白质语言模型 16
2.3.3 文本语义嵌入 17
2.4 对比学习、知识蒸馏与参数高效微调 18
2.4.1 对比学习 18
2.4.2 知识蒸馏 19
2.4.3 适配器与参数高效微调 20
2.5 本章小结 21

第 3 章 多模态零样本蛋白质功能预测模型 22
3.1 引言 22
3.2 数据集的构建与预处理 22
3.2.1 有监督训练集和零样本测试集构建 22
3.2.2 数据集统计 23
3.2.3 多模态特征编码 24
3.3 多模态零样本预测模型 25
3.3.1 特征投影与特异性丢弃 25
3.3.2 自适应门控融合机制 28
3.3.3 优化目标 29
3.4 实验结果及分析 30
3.4.1 对比实验结果与分析 30
3.4.2 消融实验结果与分析 36
3.4.3 参数敏感性分析 40
3.4.4 嵌入空间可视化分析 41
3.4.5 自适应门控权重分析 42
3.4.6 层级一致性分析 43
3.5 本章小结 45
第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA 46
4.1 引言 46
4.2 域感知适配器预训练任务构建 47
4.2.1 问题动机与设计目标 47
4.2.2 域感知对比学习任务 47
4.3 MZSGO-DA 模型设计 47
4.3.1 总体框架 47
4.3.2 适配器模块与注入机制 48
4.3.3 域感知对比学习预训练 49
4.3.4 双适配器端到端下游训练 50
4.4 实验结果及分析 52
4.4.1 对比实验结果与分析 52
4.4.2 消融实验结果与分析 54
4.4.3 预训练过程分析 55
4.4.4 参数效率分析 55
4.5 本章小结 55

结　论 57
参考文献 59
攻读硕士学位期间取得创新性成果 64
哈尔滨工业大学学位论文原创性声明和使用权限 65
致　谢 66

第 1 章 绪论

1.1 课题研究背景和意义

1.1.1 课题研究背景

蛋白质是生命活动的重要执行者，是基因表达的直接产物，也是构成生命体和维持细胞正常生命活动的关键物质基础[1]。在细胞内，蛋白质广泛参与物质运输、能量代谢、信号转导、免疫应答、细胞分裂及基因表达调控等过程，其功能状态直接影响细胞命运和个体表型。从催化反应的酶，到承担支撑作用的结构蛋白；从执行免疫识别的抗体，到介导细胞通信的受体和激素，蛋白质几乎参与了所有重要的生命过程。因此，深入理解蛋白质的结构特征及其功能机制，不仅有助于揭示生命活动的基本规律，也对疾病机理研究、药物研发、酶工程改造和合成生物学设计等领域具有重要意义。

从经典分子生物学观点看，蛋白质通常遵循" 序列-结构-功能" 的规律，即氨基酸序列决定空间结构，而结构进一步影响功能。蛋白质一级结构中的氨基酸排列经局部折叠可形成 α 螺旋、β 折叠等二级结构，进而构成稳定的三级结构，部分蛋白质还会通过多条肽链组装形成四级结构。正是序列组成、折叠方式和空间构象的高度多样性，奠定了蛋白质功能多样化的分子基础。因此，如何从序列、结构及相关信息中准确推断蛋白质功能，一直是生物学与生物信息学研究的核心问题。

近年来，高通量测序、质谱和结构生物学技术迅速发展，蛋白质相关数据正以前所未有的速度积累。研究者已能便捷获取大规模序列数据，并不断从实验数据库和预测平台中获得丰富的结构信息。尤其是 AlphaFold2[2] 在结构预测任务上的突破，大幅降低了高精度结构信息的获取门槛，使以往难以开展的大规模结构辅助分析成为可能。这一进展不仅推动了结构研究，也为功能预测提供了新的信息来源。

然而，与序列和结构数据的快速增长相比，蛋白质功能注释的积累速度仍然相对缓慢[3]。大量蛋白质虽已完成测序，甚至能获得高可靠性的结构信息，但其功能仍缺乏完整、准确的实验标注。传统功能研究主要依赖生物实验验证，虽结果可信度高，但实验流程复杂、周期长，对设备平台和经费均有较高要求[4]。因此，仅依赖实验手段难以满足大规模功能解析的需求。如何借助计算方法进行自动、高效、准确的功能预测，已成为生物信息学的重要研究方向。

为实现蛋白质功能的标准化描述，国际生物信息学界采用基因本体（Gene Ontology, GO）系统进行统一注释[5]。GO 从生物过程（Biological Process, BP）、分子

功能（Molecular Function, MF）和细胞组分（Cellular Component, CC）三个角度刻画蛋白质功能，通过有向无环图组织术语间的层级关系。这一标准化体系为自动预测提供了统一的标签空间，也使不同研究结果具备可比性。但 GO 体系也带来挑战，如术语数量庞大、类别分布不均、层级关系复杂及大量术语缺乏充分标注等。因此，蛋白质功能预测不仅是典型的多标签学习任务，也常伴随标签稀疏、类别长尾和层级依赖等困难。

在此基础上，研究者逐渐认识到，仅依赖单一来源的信息难以全面刻画蛋白质功能。序列中包含丰富的进化保守特征，结构信息反映残基空间关系和功能位点分布，而蛋白质域描述、GO 术语定义及相关数据库文本则提供直接的功能语义知识。这些信息从不同角度揭示蛋白质的生物学属性，彼此具有明显的互补性。随着蛋白质语言模型、结构预测工具和生物医学文本表示方法的发展，如何综合利用序列、结构和文本等多源信息提升功能预测性能，已成为该领域值得深入研究的问题。围绕这一问题开展研究，不仅有助于提高预测的准确性和泛化能力，也为构建更智能高效的自动注释方法奠定基础。

1.1.2 研究目的和意义

蛋白质功能预测的核心任务是揭示序列、结构及相关知识与生物学功能之间的映射关系。随着测序技术和蛋白质组学的发展，序列与结构数据持续增长，而高质量功能注释仍主要依赖耗时昂贵的实验。在此背景下，发展高效、准确且泛化能力强的计算方法，已成为缓解功能注释缺口、提升数据利用效率的重要途径。因此，围绕蛋白质功能预测开展研究，具有明确的问题导向和现实需求。

现有方法大多将任务建模为固定标签集上的多标签分类，主要依赖序列或结构等单一模态信息。这些方法在常见功能类别上取得了一定效果，但仍存在不足。一方面，蛋白质功能并非仅由序列或局部结构决定，蛋白质域描述、GO 术语定义及知识库文本中也蕴含重要功能线索，忽略这些信息会导致模型理解不完整。另一方面，GO 标签空间庞大且呈长尾分布，许多功能类别样本稀缺，传统基于封闭分类的方法在稀有类别和未见术语场景下受限，难以满足自动注释对泛化能力的要求。

此外，传统方法通常将 GO 术语视为彼此独立的离散标签，较少利用术语定义本身的语义信息及功能概念间的关联。这种建模方式虽便于监督训练，但限制了模型对功能本质的表达能力。事实上，蛋白质功能预测不仅是标签判别问题，更可视为蛋白质属性与功能语义的匹配问题。若能统一建模序列、域描述、GO 定义及结构先验等信息，有望在标注不足时借助功能语义进行推断，从而提升对复杂类别和低资源场景的适应能力。

基于上述认识，本文围绕”基于多模态预训练的蛋白质功能预测”展开研究，目标是综合利用序列、域描述、GO 定义及结构先验等多源信息，探索更有效的蛋白质功能建模方法。本文希望通过构建统一表示，使不同来源的功能相关知识在同一框架下互补，从而提升功能预测的整体性能。区别于传统仅依赖离散标签学习的思路，本文更关注蛋白质表示与功能语义表示的对应，增强对稀有类别和未见术语的推断能力，提升模型的泛化性和实用性。

本文的创新性主要体现在研究思路与方法设计两个层面。在研究思路上，本文将蛋白质功能预测从传统的单模态特征学习拓展为多模态语义建模，通过引入蛋白质域文本与 GO 术语定义，使模型不再局限于已有标注信号的监督信号，而是能够借助功能概念本身的语义信息进行推断。这种建模方式为蛋白质表征学习与知识融合提供了新的视角，也为应对开放标签预测、低资源功能推断等挑战性场景探索了可行路径。

在方法层面，多模态建模为缓解标签稀疏、类别长尾以及信息利用不充分等问题提供了新的解决思路。序列、结构先验与文本语义在生物学层面具有天然互补性，通过构建合理的学习框架实现多源信息的有效融合，能够增强模型在复杂任务场景下的稳健性与预测能力。此外，这一思路也为将多源知识高效整合至蛋白质智能分析系统积累了方法经验，对后续相关研究具有参考价值。

从应用价值来看，准确的功能预测可为药物靶点发现、疾病机制解析、酶功能挖掘及合成生物学设计等实际任务提供重要支撑。面对实验资源有限、待注释蛋白质数量持续增长的现状，具备良好泛化能力的预测模型有助于提升自动注释效率，缩短从蛋白质发现到功能解析的研究链路。尤其对于新发现的蛋白质、样本稀有的功能类别以及标注不足的功能术语，若模型能够结合多源信息做出合理推断，将进一步提升自动注释系统的实用性与适用范围。综上所述，围绕多模态预训练开展蛋白质功能预测研究，兼具学术探索价值与实际应用意义。

1.2 国内外研究现状

蛋白质功能预测是生物信息学中的经典问题，CAFA（Critical Assessment of Function Annotation)[6] 挑战赛是该领域最具代表性的国际评测平台。围绕这一任务，国内外研究已经从早期的序列同源性转移和单模态监督学习，逐步发展到多模态信息融合、零样本开放标签预测以及大规模预训练驱动的表示学习。总体来看，国外研究起步较早，在同源比对、知识本体建模和大规模预训练方面积累了系统方法；国内学者近年来则在结构增强建模、多模态融合、轻量级适配器预训

练和任务特定优化方面取得了较快进展。根据建模范式和技术路线的不同，以下分别从多模态信息融合、零样本预测和预训练三个方面梳理现有研究进展。

1.2.1 基于多模态信息融合的功能预测方法

早期蛋白质功能预测方法主要建立在”序列相似则功能相似”的假设之上。BLAST[7] 通过局部序列比对在已知数据库中检索同源蛋白，并将同源蛋白的功能注释迁移至待测蛋白。然而，单纯依赖序列信息难以显式建模结构约束和 GO 语义层级，一些序列差异明显的蛋白质可能在结构和功能上高度相似，另一些序列相近的蛋白质功能却截然不同。随着深度学习的发展，研究者逐步认识到仅依赖单一模态信息难以全面刻画蛋白质功能，开始融合序列、结构、网络、文本和本体知识等多源信息，形成多模态蛋白质功能预测框架。

在早期基于深度学习的方法中，DeepGO[8] 结合序列和蛋白质互作信息进行本体感知分类，将 GO 层级关系纳入预测框架。DeepText2GO[9] 较早尝试将深层语义文本表示引入蛋白质功能预测，通过文本分类器与序列分类器的概率融合提升大规模预测性能，为后续文本增强方法提供了早期思路。DeepGOPlus[10] 采用一维卷积网络直接从氨基酸序列中提取局部基序特征，是基于序列进行功能预测的代表性框架之一。

在结构信息融入方面，AlphaFold2[2] 在蛋白质结构预测领域的突破，使其对应数据库已覆盖大规模蛋白质结构空间[11]，极大推动了结构驱动功能预测方法的发展。DeepFRI[12] 将蛋白质结构表示为接触图，并结合图卷积网络学习结构拓扑与序列残差信息，是结构功能预测中具有代表性的工作。Diamond[13] 则在保持较高灵敏度的同时显著提升了检索效率，更适用于大规模蛋白质数据库分析。在网络信息融合方面，DeepGraphGO[14] 利用 InterProScan[15] 生成的蛋白质特征并结合多物种 PPI 网络，通过图神经网络建模高阶互作关系，说明网络上下文能够为蛋白质功能预测提供重要补充。

随后，结构信息的利用进一步深化。HEAL[16] 引入分层图转换器和对比学习机制，利用 AlphaFold2 结构增强蛋白质图表示，并通过层次化编码更好地兼顾局部几何模式与全局拓扑结构。国内学者提出的 Struct2GO[17] 则体现了结构建模与序列建模协同融合的思路。如图 1-1所示，该方法构建了结合序列与结构的图池化框架，通过层次化图池化和 Node2vec[18] 初始化来捕获蛋白质结构网络中的关键局部与全局模式，实现了较为准确的功能注释。国内学者提出的 HiFun[19] 则将蛋白质视为一种特殊语言，通过卷积网络与自注意力 BiLSTM 联合建模序列上下文信息，在无同源信息条件下仍能够学习到有判别力的功能模式。

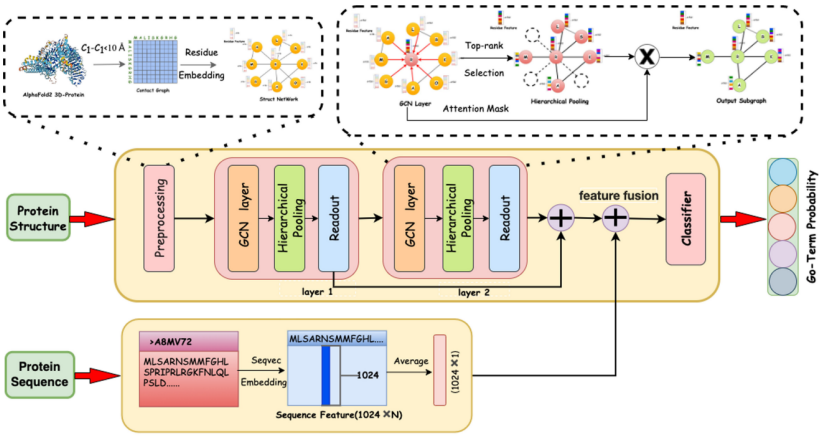

图 1-1: Struct2GO 模型概览图[17]

在本体与多特征融合方面，PO2GO[20] 通过偏序嵌入强化了对 GO 层级关系的建模，体现出标签空间结构对预测质量的重要影响。ProtGO[21] 联合使用序列表示、结构特征、GO 本体嵌入和文本描述，通过多源协同提升模型的功能辨识能力。DPFunc[22] 显式引入蛋白质域信息，如图 1-2所示，将结构域视为功能基序参与预测，体现出蛋白质域在解释功能差异方面的重要价值。这些工作说明，多模态融合不应停留在简单拼接层面，而需要围绕模态间的相关性、可靠性和互补性设计更有针对性的交互机制。

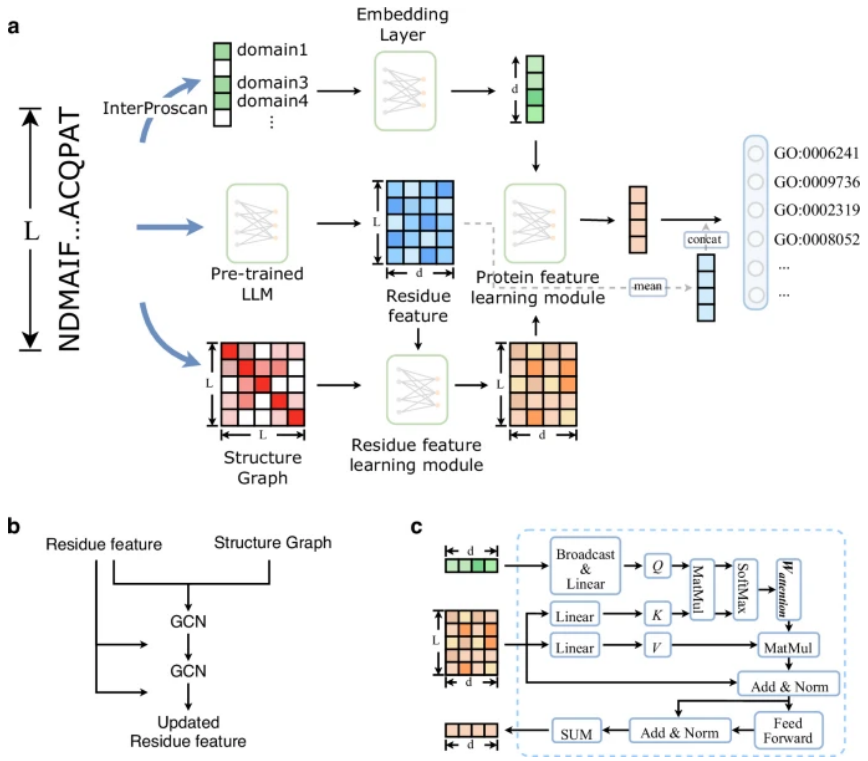

图 1-2: DPFunc 模型概览图[22]

为更清晰地展示各方法在模态利用方面的差异，表 1-1汇总了本节所述代表性工作所采用的输入模态信息。

表 1-1: 多模态信息融合方法使用的模态信息汇总

方法	序列	结构	PPI 网络	GO 本体	文本	蛋白质域
BLAST(1990)[7]	✓					
DeepGO(2018)[8]	✓		✓	✓		
DeepText2GO(2018)[9]	✓				✓	
DeepGOPlus(2020)[10]	✓					
DeepFRI(2021)[12]	✓	✓				
Diamond(2021)[13]	✓					
DeepGraphGO(2021)[14]	✓		✓			
HEAL(2023)[16]	✓	✓				
Struct2GO(2023)[17]	✓	✓				
HiFun(2023)[19]	✓					
PO2GO(2024)[20]	✓			✓		
ProtGO(2025)[21]	✓	✓		✓	✓	
DPFunc(2025)[22]	✓	✓				✓

然而，尽管多模态融合方法有效整合了不同来源的信息，但多数方法仍受限于封闭标签空间，难以处理训练阶段未见的 GO 术语、长尾功能类别以及低同源样本，对泛化能力的提升仍然不足。这促使研究者进一步探索零样本预测与预训练范式。

1.2.2 基于零样本预测的功能预测方法

传统蛋白质功能预测方法通常将 GO 术语视为固定标签集上的多标签分类问题，模型只能预测训练阶段见过的功能类别。然而，GO 标签空间庞大且持续扩展，许多功能类别样本极度稀缺甚至在训练集中完全缺失。为应对这一挑战，零样本预测方法应运而生，其核心思想是利用功能标签本身携带的语义信息，使模型具备对训练阶段未见功能术语的推断能力。

DeepGOZero[23] 是零样本蛋白质功能预测方向的代表性工作，该方法利用 GO 本体公理和 EL Embedding[24] 将功能术语嵌入到几何空间中，使模型能够基于本体结构关系对训练阶段未见的 GO 术语进行推断，表明结构化知识对开放标签预测具有重要价值。DeepGO-SE[25] 在此基础上引入预训练蛋白质语言模型和神经符

号语义蕴涵机制，增强了模型对 GO 语义层级的推理能力，进一步提升了零样本场景下的预测精度。

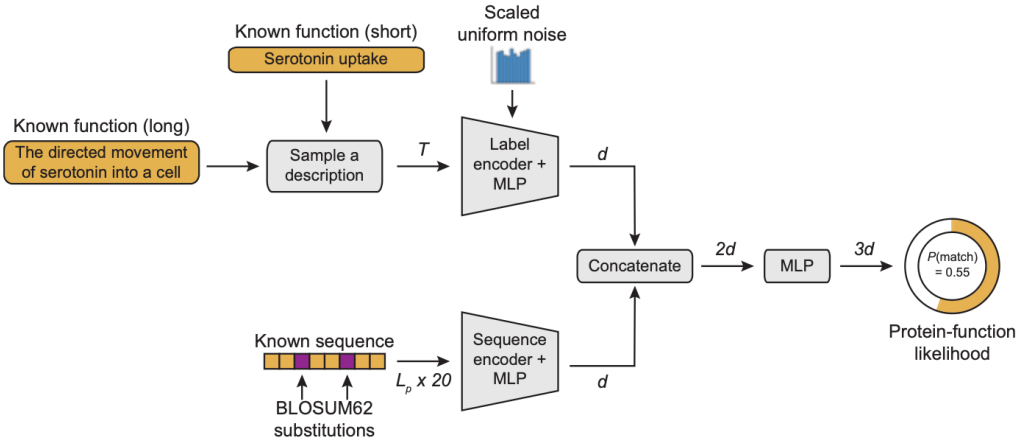

图 1-3: ProtNote 模型概览图[26]

ProtNote[26] 提出了另一种面向开放标签预测的多模态方法。如图 1-3所示，该方法通过将蛋白质序列与 GO 功能标签的自然语言描述进行联合建模，将功能预测转化为蛋白质表示与标签文本语义之间的匹配问题，从而支持在开放标签空间上进行灵活的功能注释。这种将标签语义纳入预测框架的思路，打破了传统封闭分类的限制，为处理未见标签和稀有类别提供了有效手段。

FunBind[27] 则从统一多模态对齐的角度进一步拓展了零样本预测的能力。该方法整合蛋白质序列、结构、文本描述、InterPro 域注释和 GO 术语五种模态，以序列模态为中心通过对比学习将其余模态对齐到统一的潜在空间中，从而在无监督条件下直接通过嵌入相似度实现对训练阶段未见 GO 术语的零样本预测。此外，FunBind 还支持在对齐后的多模态表示上进行有监督微调，实现对已知功能类别更精确的多标签分类，体现了零样本预测与有监督预测在统一框架下的有效结合。

总体来看，零样本预测方法通过引入 GO 本体语义、标签文本描述或多模态对齐，使模型不再局限于训练阶段的固定标签集，在功能类别快速扩展和标注不足的场景下展现出显著优势。然而，这些方法对标签语义表示的质量和蛋白质特征的泛化能力有较高要求，如何获取更具判别力的蛋白质表示以支撑零样本推断，进一步指向了预训练方法的发展。

1.2.3 基于预训练的功能预测方法

随着深度学习技术的发展，预训练范式在蛋白质功能预测中发挥着越来越重要的作用。预训练方法通过在大规模无标注数据上进行自监督学习，使模型获得通用的蛋白质表示能力，再通过微调或特征迁移服务于下游功能预测任务。这种

范式有效缓解了蛋白质功能注释中标注数据不足的问题，已成为当前多数方法的重要基础组件。

在序列预训练方面，以 ESM-2[28] 为代表的蛋白质语言模型（Protein Language Model, PLM）通过掩码语言建模在海量蛋白质序列上进行自监督训练，能够提取包含进化约束、理化模式以及潜在结构偏好的高质量表示。与传统人工特征不同，预训练模型能够在不依赖特定任务标签的前提下学习通用蛋白质表示，再通过微调或特征迁移服务于下游功能预测任务。正因如此，序列预训练已经成为当前多数方法的重要基础组件，也是后续多模态预训练方法得以成立的前提。

在知识增强预训练方面，OntoProtein[29] 将 GO 结构嵌入蛋白质预训练过程，构建蛋白质-GO 知识图谱并通过知识感知负采样的对比学习联合优化蛋白质与本体表示，体现出”知识增强的蛋白质预训练”这一重要方向。ProtST[30] 则将蛋白质序列与生物医学文本进行多模态联合学习，通过单模态掩码预测、多模态表示对齐和多模态掩码预测等任务，在保留序列模型原有能力的同时增强了对功能文本的理解，并支持零样本分类与蛋白质检索。CFAGO[31] 采用预训练-微调两阶段策略，首先通过交叉融合对 PPI 网络和蛋白质属性信息进行预训练学习，再在下游任务上微调，验证了预训练对于多模态融合性能提升的重要作用。从更广义的多模态预训练角度看，MASSA[32] 构建了统一整合序列、结构和功能注释的多任务预训练框架，通过任务定制化设计使模型能够在不同下游任务之间共享更具生物学含义的表示，更强调在预训练阶段就建立模态间的共享语义空间，从而提高表示的可迁移性和下游适应性。PAIR[33] 则从另一角度证明了文本监督信号的重要性：该工作利用 UniProt 中的 19 类文本注释对蛋白质模型进行微调，显著增强了蛋白质表示的预测能力，甚至在部分功能相关任务上超越了传统的 BLAST 工具。这些工作共同表明，文本和知识图谱等外部知识不再只是辅助说明，而是可以作为功能知识的显式载体参与蛋白质表征的预训练过程。

在生成式预训练方面，研究者将蛋白质功能预测从预定义标签分配拓展为自由文本生成。Prot2Text[34] 通过图神经网络与 Transformer 联合建模序列、结构和文本信息，使模型能够以自然语言形式输出蛋白质功能描述。FAPM[35] 借鉴视觉-语言预训练中的 BLIP2 框架，将预训练蛋白质语言模型与大语言模型 Mistral-7B 相结合，通过蛋白质-文本对比学习、蛋白质-文本匹配和语言建模三个预训练目标联合优化，使模型能够以自然语言形式生成 GO 功能术语和催化活性描述。FAPM 还引入了分类信息等额外文本提示，增强了模型的交互性和可解释性，在公开基准和低同源噬菌体蛋白上均取得了优越的性能。Prot2Text-V2[36] 进一步引入多模态对比对齐机制，采用更强的蛋白质语言模型和大语言模型解码器，并在低同源性

设定下表现出更强的泛化能力，反映出”序列到文本”的生成式预训练路线正在成为蛋白质功能预测的重要趋势。这些工作表明，基于预训练大语言模型的生成式范式为蛋白质功能预测开辟了新的方向。

在结构知识蒸馏与轻量级适配方面，S-PLM[37] 展示了另一条极具启发性的技术路线。如图 1-4所示，该方法在蛋白质语言模型内部注入适配器模块，并通过对比学习将三维结构表示蒸馏到序列编码器中，使模型在推理阶段仅凭序列输入即可生成包含结构感知信息的表示。与直接在下游阶段额外输入结构不同，这种做法强调通过预训练把跨模态知识”内化”到序列模型内部，从而兼顾性能、鲁棒性和部署效率。对于本文第四章研究而言，S-PLM 提供了重要启发，即蒸馏目标并不一定局限于结构，也可以拓展为蛋白质域的功能语义信息。

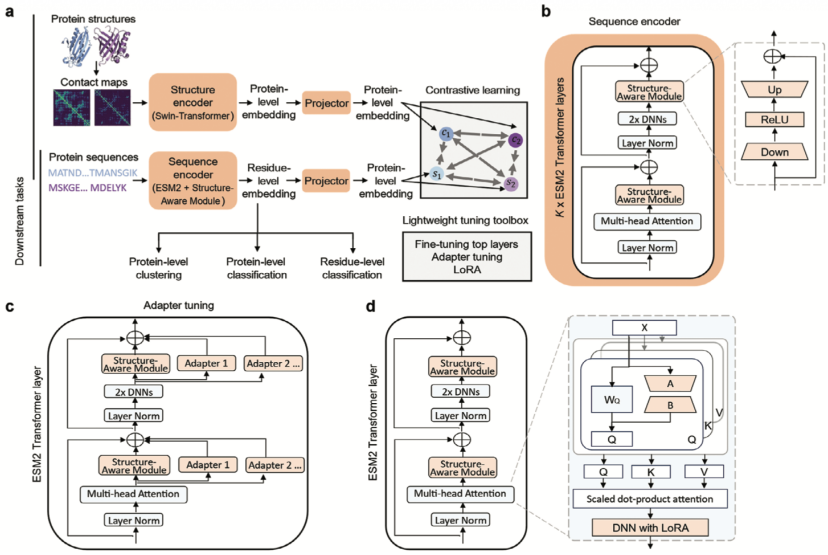

图 1-4: S-PLM 模型概览图[37]

从国内外研究现状来看，预训练方法已经从单模态序列预训练发展到多模态联合预训练，从通用表示学习走向功能导向的知识增强预训练和生成式预训练。国外研究在知识图谱预训练、文本-序列对齐、生成式预测和多模态对比学习方面形成了较为完整的技术谱系；国内学者则在结构增强、域感知融合、两阶段预训练以及轻量级适配器建模等方面做出了具有代表性的工作，如 Struct2GO、CFAGO、DPFunc、FAPM 和 S-PLM 等。这些成果共同说明，多模态预训练已经成为蛋白质功能预测领域的重要发展趋势。

尽管如此，现有研究仍存在若干突出问题。第一，不少方法虽然引入多种模态，却仍以简单拼接或浅层交互为主，难以充分建模不同模态之间的深层互补关系。第二，对 GO 文本定义、蛋白质域描述等语义知识的利用仍然不够充分，许多

模型仍然将其视为附属信息而非核心知识来源。第三，多数方法受限于封闭标签空间，对未见功能术语、长尾类别和低同源样本的泛化能力仍然不足。第四，如何将域语义等功能先验稳定蒸馏到序列编码器内部，并在保持端到端训练能力的同时兼顾部署效率，仍缺乏成熟而有效的技术路径。这些问题构成了本文工作的直接研究动机，也说明围绕多模态预训练开展蛋白质功能预测研究具有明确的现实必要性。

1.3 本文的主要研究内容

围绕上述问题，本文以多模态预训练为主线，重点开展以下两方面研究，并按照”先做开放语义匹配，再做预训练表示增强”的技术路线逐步推进。

（1）多模态零样本蛋白质功能注释方法。本文将蛋白质功能预测定义为”蛋白质-GO”语义匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用文本嵌入模型统一编码蛋白质域描述和 GO 功能定义，并通过自适应门控融合机制建模多模态信息之间的共享上下文关系。同时，引入非对称特征丢弃策略增强模型在模态缺失场景下的鲁棒性，使模型能够在有监督和零样本场景下实现兼顾精度与泛化性的预测。该方法的核心目标，是打破传统封闭标签分类框架对训练标签集合的依赖，将功能预测转化为开放语义空间中的匹配问题。

具体而言，该方法重点解决两个难点：一是如何让序列信息、蛋白质域语义和 GO 定义语义在统一空间中实现可比较、可对齐的表示；二是如何在模态信息不完整的情况下仍然保持稳定预测。为此，本文在表示学习层面引入统一投影空间，在融合层面设计动态门控机制，并在训练层面采用增强鲁棒性的特征扰动策略，从而提升模型对复杂样本和未见标签的适应能力。

（2）基于域感知适配器预训练的端到端蛋白质功能预测方法。在前述工作基础上，本文进一步针对通用序列编码器缺乏功能先验的问题，设计轻量级适配器模块注入蛋白质语言模型内部，通过 InfoNCE 对比学习将蛋白质域语义蒸馏到序列表示中，并在下游任务阶段采用双适配器策略实现端到端训练。该方法旨在将多模态预训练阶段学到的功能知识更稳定地保留在序列编码器内部，进一步提高蛋白质功能预测效果。

与直接使用静态序列嵌入的方法相比，该方法更加关注”预训练知识如何进入编码器本体”这一问题。通过将域语义蒸馏至适配器，模型可以在不大幅增加主干参数量的情况下获得功能先验；通过在下游阶段采用双适配器结构，又能够在保留预训练知识的同时进行任务特定调整。这种设计兼顾了表示可迁移性、训练灵活性和部署成本，体现了多模态预训练在蛋白质功能预测任务中的工程价值。

总体而言，本文的研究内容可以概括为：从”多模态语义融合”和”域感知预训练增强”两个递进方向，系统探索蛋白质功能预测中的多模态预训练方法，以提升模型在复杂功能类别、长尾标签和未见功能术语上的预测能力。前者面向开放语义匹配问题，强调不同知识源之间的表示对齐与鲁棒融合；后者面向预训练知识内化问题，强调如何将跨模态知识稳定注入序列编码器。两项工作既相互独立又层层递进，共同构成本文的研究主线。

1.4 本文的组织结构

本文共分为四章，外加结论与展望部分，各章内容安排如下：

第一章为绪论。首先介绍蛋白质功能预测的研究背景，阐述蛋白质功能注释面临的数据增长与标注滞后之间的矛盾，说明多模态预训练方法的研究意义。随后从多模态信息融合、零样本预测和预训练三个方面系统梳理国内外研究现状，并在此基础上明确本文的研究问题与技术路线。

第二章为蛋白质功能预测的相关研究概述。首先给出蛋白质功能预测问题的形式化定义，介绍基因本体系统及常用评价指标。随后围绕本文涉及的两项核心技术——零样本预测与多模态预训练，分别梳理相关研究进展，为后续两章的模型设计提供理论基础和方法参考。

第三章为多模态零样本蛋白质功能预测模型。本章将蛋白质功能预测重新定义为蛋白质与 GO 术语之间的语义匹配问题，详细介绍数据集的构建与预处理流程、多模态特征编码方式，以及包含特征投影、特异性丢弃、自适应门控融合和优化目标在内的模型设计。通过有监督和零样本两种设定下的对比实验、消融实验、参数敏感性分析、嵌入空间可视化、门控权重分析和层级一致性分析，系统验证了多模态语义融合范式的有效性。

第四章为基于域感知适配器预训练的端到端蛋白质功能预测模型。本章在第三章工作的基础上，针对静态嵌入策略的信息瓶颈与梯度断裂问题，提出在蛋白质语言模型内部注入轻量级适配器模块，通过域感知对比学习预训练将蛋白质域语义蒸馏到序列编码器中，并采用双适配器策略实现端到端训练。通过对比实验、消融实验、预训练过程分析和参数效率分析，验证了预训练知识蒸馏对功能预测性能的提升作用。

最后为结论与展望部分。对本文提出的两个模型的主要贡献进行总结，分析现有方法在结构信息融入、语义推理能力、端到端文本编码、零样本评估规模和训练效率等方面的局限，并对未来可能的研究方向进行展望。

第 2 章 蛋白质功能预测的相关研究概述

2.1 引言

蛋白质功能预测是生物信息学领域的一项重要研究任务，其核心目标是利用计算方法为尚未充分注释的蛋白质自动分配功能标签。完成这一目标不仅需要计算模型相关理论的支持，还需要来自生物学上的可靠分析。本文的实验主要围绕蛋白质语言模型、文本语义嵌入、对比学习与知识蒸馏以及参数高效微调等技术展开，因此本章在定义蛋白质功能预测问题的基础上，分别介绍上述基础技术的研究内容与原理，为之后的工作做铺垫。

本章的组织结构为：2.2 节介绍蛋白质功能预测问题的定义和常用评价指标；2.3 节介绍表征学习的基础技术，包括 Transformer 架构、ESM-2 蛋白质语言模型和文本语义嵌入；2.4 节介绍对比学习、知识蒸馏与参数高效微调方法；2.5 节对本章内容进行总结。

2.2 蛋白质功能预测问题

2.2.1 蛋白质功能预测问题的定义

蛋白质功能预测通常以基因本体（Gene Ontology, GO）[5] 作为标准化注释体系。GO 将蛋白质功能划分为生物过程（Biological Process, BP）、分子功能（Molecular Function, MF）和细胞组分（Cellular Component, CC）三个相互独立但内部结构复杂的子本体。每个 GO 术语不仅具有标准化名称和文本定义，还通过”is_a” 和”part_of” 等关系组织成有向无环图（Directed Acyclic Graph, DAG）[38]。如图 2-1所示，GO 系统以有向无环图的形式组织功能术语之间的层级关系，子节点是父节点的具体化。这种层级结构使蛋白质功能预测区别于普通的多标签分类任务：不同标签之间存在明确的祖先—后代依赖关系，且越接近叶节点的术语语义越具体、样本越稀疏。

在 GO 体系下，蛋白质功能预测可以形式化为多标签分类问题。设蛋白质集合 $\mathcal{P} = \{P_1, P_2, \ldots, P_N\}$ 包含 N 个蛋白质，$\mathcal{X} = \{X_1, X_2, \ldots, X_N\}$ 表示蛋白质的特征向量，特征可以是单一数据源提取的，也可以是多数据源提取的。某一 GO 子本体对应的候选功能术语集合为 $\mathcal{G} = \{g_1, g_2, \ldots, g_C\}$，其中 C 表示该子本体中候选 GO 术语的总数。蛋白质 P_i 的功能注释用二元向量表示：

$$\mathbf{y}_i \in \{0,1\}^C, \quad y_{ic} = \begin{cases} 1 & \text{当蛋白质} P_i \text{具有功能} g_c \\ 0 & \text{否则} \end{cases} \tag{2-1}$$

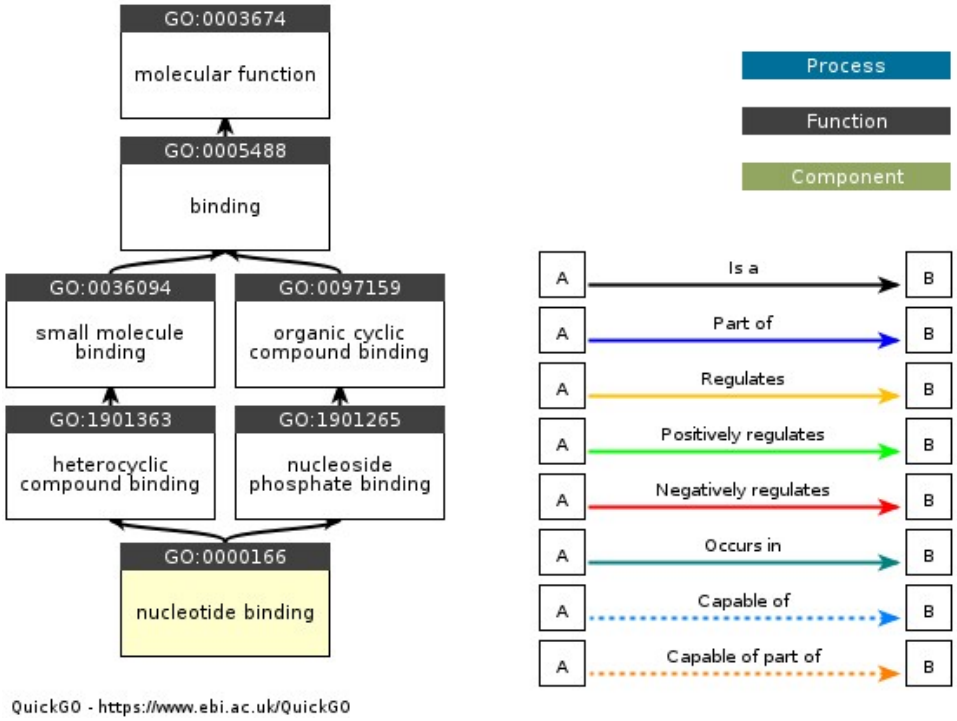

图 2-1: GO 树状层级结构示例。GO 系统以有向无环图（DAG）的形式组织功能术语之间的层级关系，三个子本体（BP、MF、CC）分别形成独立的 DAG 结构。子节点是父节点的具体化，节点间通过"is_a" 和"part_of" 关系连接。

给定训练集 $\mathcal{D} = \{(P_i, \mathbf{y}_i)\}_{i=1}^{N}$，学习映射函数 $f_\theta : \mathcal{X} \to [0,1]^C$，通过最小化多标签损失函数优化参数：

$$\mathcal{L}(\theta) = -\sum_{i=1}^{N}\sum_{c=1}^{C}\left[y_{ic}\log f_\theta(P_i)_c + (1-y_{ic})\log(1-f_\theta(P_i)_c)\right] \tag{2-2}$$

值得注意的是，GO 标签满足真实路径规则（True Path Rule）：若一个蛋白质被标注了某个 GO 术语，则按照本体层级关系，它也应被视为具有该术语所有祖先节点所代表的更一般功能。这意味着训练数据和评估标签通常需要进行向上传播，以避免标签不一致问题。同时，这也要求模型在预测时不仅要判断单一标签是否成立，还要兼顾标签之间的层级一致性。

除封闭标签空间下的多标签分类建模外，近年来越来越多的研究将蛋白质功能预测重新定义为" 蛋白质—功能标签" 匹配问题。设 P 表示蛋白质输入，g_c 表示第 c 个 GO 术语的文本定义或语义表示，则模型可以直接学习二者之间的匹配分数：

$$s(P, g_c) = p(y = 1 \mid P, g_c) \tag{2-3}$$

这种建模方式能够自然支持开放标签空间推理：即使某个 GO 术语在训练阶段从

未出现过，只要其文本定义可用，模型就有机会依据语义相似性为其生成预测结果。在广义零样本场景下，标签空间被划分为已见标签集合 $\mathcal{G}_s$ 与未见标签集合 $\mathcal{G}_u$，其中 $\mathcal{G}_s \cap \mathcal{G}_u = \varnothing$，模型需要同时在 $\mathcal{G}_s$ 和 $\mathcal{G}_u$ 上完成预测。这一思想构成了本文第三章方法设计的基本出发点。

2.2.2 蛋白质功能预测的评价指标

由于蛋白质功能预测具有多标签、类别不平衡和零样本泛化等特点，其评价指标不能简单照搬普通分类任务中的准确率。当前研究中最常用的评估方案，主要遵循 CAFA（Critical Assessment of Function Annotation）挑战赛[6] 的蛋白质中心评价协议。

对于任意给定阈值 $t \in [0, 1]$，设模型为每个蛋白质输出一组 GO 术语预测概率，经阈值化后得到预测标签集合 $\hat{Y}_i(t)$，真实标签集合记为 Y_i。在蛋白质中心评价下，可分别定义平均精确率和平均召回率为：

$$\mathrm{Pr}(t) = \frac{1}{N} \sum_{i=1}^{N} \frac{|Y_i \cap \hat{Y}_i(t)|}{|\hat{Y}_i(t)|} \tag{2-4}$$

$$\mathrm{Rc}(t) = \frac{1}{N} \sum_{i=1}^{N} \frac{|Y_i \cap \hat{Y}_i(t)|}{|Y_i|} \tag{2-5}$$

在此基础上，蛋白质功能预测中最常用的指标之一是 $F_{\max}$，即在所有阈值下 F1 分数的最大值：

$$F_{\max} = \max_{t} \frac{2 \cdot \mathrm{Pr}(t) \cdot \mathrm{Rc}(t)}{\mathrm{Pr}(t) + \mathrm{Rc}(t)} \tag{2-6}$$

$F_{\max}$ 能够综合反映模型在精确率与召回率之间的平衡能力，因此长期作为 CAFA 等标准评测中的核心指标。

另一项常用指标是 AUPR（Area Under the Precision-Recall Curve），即精确率—召回率曲线下面积。与阈值依赖的 $F_{\max}$ 不同，AUPR 是阈值无关指标，能够从整体上衡量模型在不同阈值下的排序和区分能力。由于蛋白质功能预测中正负样本比例往往高度失衡，AUPR 通常比 AUROC 更能反映模型的真实性能，尤其适合评估稀有功能类别和长尾标签上的表现。

对于零样本预测任务，仅依赖整体 AUPR 或 $F_{\max}$ 还不足以刻画模型的泛化能力。为此，研究者通常将测试阶段的标签划分为”已见标签”（Seen Labels）与”未见标签”（Unseen Labels），分别计算 Seen AUPR 和 Unseen AUPR。为综合衡量模型在已见和未见标签上的平衡表现，许多零样本研究进一步采用调和均值：

$$H = \frac{2 \times \text{Seen AUPR} \times \text{Unseen AUPR}}{\text{Seen AUPR} + \text{Unseen AUPR}} \tag{2-7}$$

当模型只偏向已见标签而忽视未见标签时，H 值会受到明显抑制；只有当模型在两类标签上都取得较好表现时，H 值才会较高。因此，H 指标在广义零样本功能预测场景中具有重要意义，也是本文第三章实验部分的主要评价指标之一。

2.3 表征学习基础技术

表征学习旨在从原始数据中自动学习有效的特征表示，是本文方法的核心技术基础。本节首先介绍作为深度序列建模基础的 Transformer 架构，随后介绍基于该架构的 ESM-2 蛋白质语言模型和文本语义嵌入技术。

2.3.1 Transformer 架构

Transformer[39] 是一种完全基于注意力机制的序列建模架构，自提出以来已成为自然语言处理和蛋白质表示学习领域的核心基础。与传统的循环神经网络（RNN）不同，Transformer 通过自注意力机制实现了对序列中任意位置之间依赖关系的直接建模，有效解决了长距离依赖问题，其整体架构如图 2-2所示。

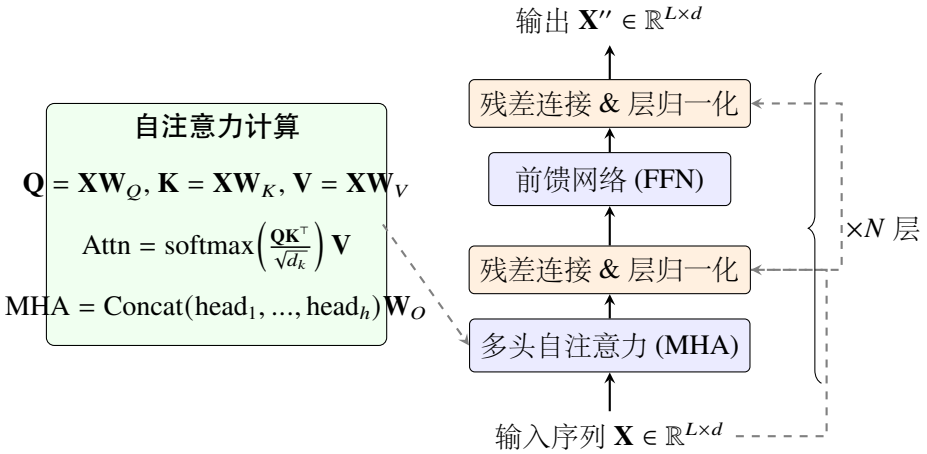

图 2-2: Transformer 编码器单层结构示意图。每一层由多头自注意力子层和前馈网络子层组成，每个子层后均采用残差连接和层归一化。左侧展示了自注意力的核心计算过程。N 层 Transformer 层堆叠构成完整的编码器。

Transformer 的核心是多头自注意力（Multi-Head Self-Attention, MHA）机制。给定输入序列 $\mathbf{X} \in \mathbb{R}^{L\times d}$（$L$ 为序列长度，d 为隐藏维度），自注意力首先通过三个线性变换生成查询矩阵 $\mathbf{Q}$、键矩阵 $\mathbf{K}$ 和值矩阵 $\mathbf{V}$：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V \tag{2-8}$$

其中 $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d\times d_k}$，$\mathbf{W}_V \in \mathbb{R}^{d\times d_v}$ 为可学习参数。自注意力通过缩放点积计算序列中各位置之间的相关性：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V} \tag{2-9}$$

其中 $\sqrt{d_k}$ 为缩放因子，用于防止点积过大导致梯度消失。

多头注意力机制将输入投影到 h 个不同的子空间中并行计算注意力，然后拼接各头的输出：

$$\text{MHA}(\mathbf{X}) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)\mathbf{W}_O \tag{2-10}$$

其中每个注意力头 $\text{head}_i = \text{Attention}(\mathbf{Q}_i, \mathbf{K}_i, \mathbf{V}_i)$，$\mathbf{W}_O \in \mathbb{R}^{hd_v\times d}$ 为输出投影矩阵。多头机制使模型能够同时关注不同位置的不同表示子空间，增强了模型对复杂依赖关系的捕获能力。

Transformer 的每一层由多头自注意力子层和前馈网络（Feed-Forward Network, FFN）子层组成，每个子层后均采用残差连接[40] 和层归一化（Layer Normalization, LN）：

$$\mathbf{X}' = \text{LN}(\mathbf{X} + \text{MHA}(\mathbf{X})) \tag{2-11}$$

$$\mathbf{X}'' = \text{LN}(\mathbf{X}' + \text{FFN}(\mathbf{X}')) \tag{2-12}$$

其中前馈网络由两层线性变换和激活函数组成：

$$\text{FFN}(\mathbf{x}) = \mathbf{W}_2 \cdot \sigma(\mathbf{W}_1 \cdot \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2 \tag{2-13}$$

σ 为激活函数（如 GELU[41]）。Transformer 通过堆叠多个这样的层构成深层网络，能够有效建模长距离依赖关系。

2.3.2 ESM-2 蛋白质语言模型

蛋白质序列可以类比于自然语言中的句子：20 种标准氨基酸构成” 词汇表”，氨基酸序列构成” 语句”。基于这一类比，蛋白质语言模型借鉴自然语言处理中的预训练范式，在海量蛋白质序列上进行自监督训练，学习蕴含进化信息和潜在结构偏好的蛋白质表示。

ESM-2[28] 是目前最具代表性的蛋白质语言模型之一，其预训练流程如图 2-3所示。ESM-2 的核心训练目标为掩码语言建模（Masked Language Modeling, MLM）：在输入序列中随机遮掩一定比例的氨基酸位置，模型通过上下文信息预测被遮掩的氨基酸。设蛋白质序列为 $\mathbf{s} = (s_1, s_2, \ldots, s_L)$，遮掩位置集合为 $\mathcal{M}$，则 MLM 的训练目标为：

$$\mathcal{L}_{\text{MLM}} = -\sum_{j \in \mathcal{M}} \log p(s_j \mid \mathbf{s}_{\setminus \mathcal{M}}) \tag{2-14}$$

其中 $\mathbf{s}_{\setminus \mathcal{M}}$ 表示未被遮掩的序列部分。通过在 UniRef 数据库中约 2.5 亿条蛋白质序列上训练，ESM-2 学习到的表示能够隐式编码氨基酸的共进化模式、接触关系和保守性特征。

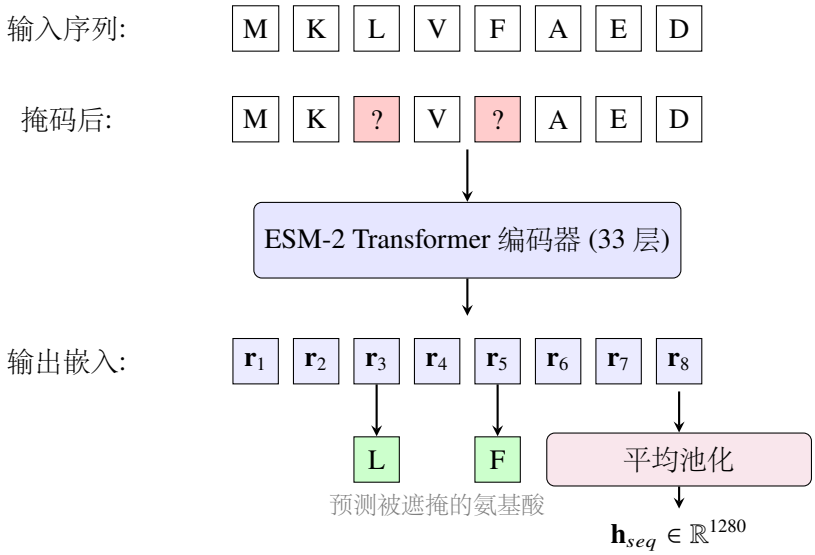

图 2-3: ESM-2 蛋白质语言模型预训练与特征提取示意图。模型通过掩码语言建模（MLM）在大规模蛋白质序列数据上进行预训练，学习氨基酸上下文的共进化模式。预训练完成后，通过平均池化可以获得蛋白质级别的全局表示 $\mathbf{h}_{seq}$。

ESM-2 采用标准的 Transformer 编码器架构，具有多个规模变体，其中 ESM2-650M 包含 33 层 Transformer 层、隐藏维度为 1280。给定蛋白质序列 P，ESM-2 输出每个残基位置的上下文嵌入 $\mathbf{r}_j$，通过平均池化可获得蛋白质级别的全局表示：

$$\mathbf{h}_{seq} = \frac{1}{L} \sum_{j=1}^{L} \mathbf{r}_j \in \mathbb{R}^{1280} \tag{2-15}$$

ESM-2 为后续蛋白质功能预测提供了强大的序列编码器基础。在本文中，第三章使用 ESM2-650M 作为静态特征提取器提取蛋白质序列的进化特征，第四章则在 ESM-2 的 Transformer 层中注入适配器模块实现端到端训练。

2.3.3 文本语义嵌入

在蛋白质功能预测中，GO 术语的名称和文本定义、蛋白质域的功能描述等文本信息蕴含丰富的语义知识。将这些文本信息编码为稠密向量表示，是实现零样本功能预测和多模态融合的关键环节。

文本嵌入（Text Embedding）旨在将自然语言文本映射为固定长度的稠密向量，使得语义相近的文本在向量空间中距离较近。现代文本嵌入模型通常基于 Transformer 编码器架构，通过大规模文本语料的预训练获得通用的语义表示能力。给定输入文本序列 $(w_1, w_2, \ldots, w_T)$，Transformer 编码器输出每个 token 位置的上下文表示 $(\mathbf{t}_1, \mathbf{t}_2, \ldots, \mathbf{t}_T)$。常用的句子级表示获取方式包括：使用特殊标记 [CLS] 的输出作为全局表示，或对所有 token 的输出进行平均池化：

$$\mathbf{e}_{text} = \frac{1}{T}\sum_{j=1}^{T}\mathbf{t}_j \tag{2-16}$$

输出的文本嵌入向量可用于语义相似度计算、文本检索和跨模态对齐等下游任务。

本文使用 Qwen3-Embedding-4B[42] 作为文本编码器。Qwen3-Embedding 是一种基于大语言模型的文本嵌入模型，具有 40 亿参数规模，在多种文本嵌入基准上表现优异。相比传统的 BERT 规模编码器，Qwen3-Embedding 具有更强的语义理解能力，能够更准确地捕捉生物医学领域专业术语的细粒度语义差异。

在本文的应用中，Qwen3-Embedding 承担两种文本的编码任务。其一是 GO 标签语义编码：将每个 GO 术语的名称和定义文本（如"protein kinase activity: Catalysis of the phosphorylation of an amino acid residue..."）编码为标签语义嵌入 $\mathbf{E}_{label} \in \mathbb{R}^{2560}$，使模型能够基于文本相似性泛化到未见标签，这是零样本推理的核心基础。其二是蛋白质域语义编码：将蛋白质各个域的 InterPro[43] 描述文本编码为域语义嵌入 $\mathbf{E}_{dom} \in \mathbb{R}^{2560}$，蛋白质域作为独立的功能和结构单元，其自然语言描述蕴含丰富的功能先验知识。

2.4 对比学习、知识蒸馏与参数高效微调

本节介绍对比学习、知识蒸馏和适配器等技术的基本原理，这些技术构成了本文第四章域感知适配器预训练和端到端功能预测的核心方法基础。

2.4.1 对比学习

对比学习（Contrastive Learning）是一种通过构造正负样本对来学习数据表示的自监督学习范式[44]。其核心思想是：在表示空间中拉近语义相似的正样本对，同时推远语义不相关的负样本对。图 2-4展示了对比学习的基本原理。

对比学习中最具代表性的损失函数是 InfoNCE[45] 损失。给定一批 B 个样本，每个样本 i 对应两种模态的表示 $\mathbf{z}_i^a$ 和 $\mathbf{z}_i^b$，同一样本的两种模态表示构成正样本对，不同样本的表示构成负样本对。InfoNCE 损失定义为：

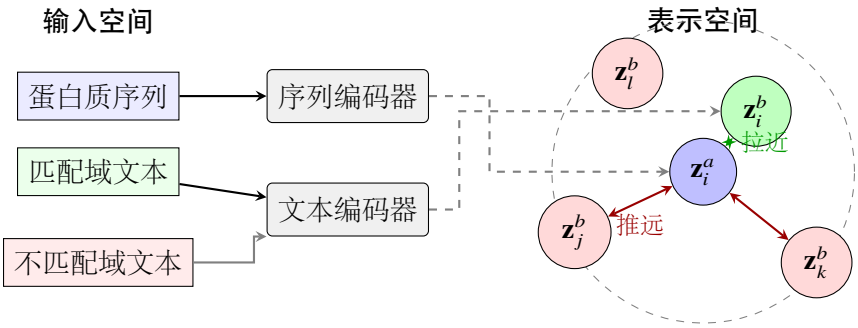

图 2-4: 对比学习原理示意图。在表示空间中，对比学习通过 InfoNCE 损失拉近语义匹配的正样本对（如蛋白质序列与其匹配的域文本描述），同时推远不匹配的负样本对，从而实现跨模态语义对齐。

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}_i^a, \mathbf{z}_i^b)/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}_i^a, \mathbf{z}_j^b)/\tau)} \tag{2-17}$$

其中 $\text{sim}(\cdot,\cdot)$ 为余弦相似度，τ 为温度超参数。温度参数控制分布的集中程度：较小的 τ 使模型更关注困难负样本，较大的 τ 则使分布更加平滑。

在跨模态学习中，对比学习可以有效地将不同模态的表示对齐到共享语义空间中。对于蛋白质功能预测任务，这种对齐机制使得蛋白质序列表示能够与功能文本描述在同一空间中进行语义匹配。本文第四章利用双向 InfoNCE 对比损失，将蛋白质序列表示与域文本嵌入进行对齐，实现域语义信息向序列编码器的蒸馏。

2.4.2 知识蒸馏

知识蒸馏（Knowledge Distillation）[46] 最初被提出用于模型压缩，即将大型教师模型中的知识转移到小型学生模型中。其基本思想是：让学生模型不仅学习真实标签，还学习教师模型输出的软标签分布，从而获得教师模型中蕴含的更丰富的知识。图 2-5（左）展示了知识蒸馏的基本框架。

在经典的知识蒸馏框架中，设教师模型的输出 logits 为 $\mathbf{z}_T$，学生模型的输出 logits 为 $\mathbf{z}_S$，则蒸馏损失通过 KL 散度衡量软标签分布之间的差异：

$$\mathcal{L}_{\text{KD}} = T^2 \cdot \text{KL}\left(\text{softmax}\left(\frac{\mathbf{z}_T}{T}\right)\middle\|\text{softmax}\left(\frac{\mathbf{z}_S}{T}\right)\right) \tag{2-18}$$

其中 T 为蒸馏温度，较高的温度使输出分布更加平滑，有助于传递更多类间关系信息。

在更广义的框架下，知识蒸馏可以理解为一种跨模态或跨表示的知识转移机制：将某种信息源中蕴含的知识” 内化” 到目标模型的参数中，使目标模型在推理时无需显式访问原始信息源，仍能从其参数中恢复相关知识。这种思想在蛋白质表示学习领域已有成功应用，如 S-PLM[37] 通过对比学习将蛋白质三维结构信息蒸

馏到序列编码器的适配器参数中，使模型仅凭序列输入即可产生包含结构感知的表示。

在本文第四章中，知识蒸馏的思想被进一步拓展：蒸馏目标从三维结构信息替换为蛋白质域的功能语义信息。通过对比学习预训练，域文本描述中蕴含的功能先验知识被蒸馏至 ESM-2 适配器的参数中。预训练完成后，序列编码器即使不显式输入域信息，也能在其输出表示中隐式包含域的功能语义先验。

2.4.3 适配器与参数高效微调

大规模预训练模型（如 ESM-2）通常包含数亿甚至数十亿参数。在将其应用于特定下游任务时，全参数微调不仅计算成本高昂，还容易导致灾难性遗忘。参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）通过仅训练少量额外参数来适配下游任务，在保持预训练知识的同时实现高效迁移。

适配器（Adapter）[47] 是参数高效微调中最具代表性的方法之一。其基本思想是在预训练模型的每一层中插入轻量级的瓶颈结构模块，冻结预训练模型的原始参数，仅训练新插入的适配器参数。如图 2-5（右）所示，标准的适配器模块采用瓶颈结构，由降维线性层、非线性激活函数和升维线性层组成，并通过残差连接保留原始信息流：

$$\text{Adapter}(\mathbf{x}) = \mathbf{W}_{up} \cdot \sigma(\mathbf{W}_{down} \cdot \mathbf{x}) + \mathbf{x} \tag{2-19}$$

其中 $\mathbf{W}_{down} \in \mathbb{R}^{d_b \times d}$ 为降维矩阵，$\mathbf{W}_{up} \in \mathbb{R}^{d \times d_b}$ 为升维矩阵，d 为隐藏维度，$d_b \ll d$ 为瓶颈维度，σ 为激活函数。适配器模块通常被注入 Transformer 层的自注意力输出之后和前馈网络输出之后两个位置。

适配器的参数量远小于原始模型。以 ESM2-650M 为例，其隐藏维度 $d = 1280$，若设瓶颈维度 $d_b = 640$，则每个适配器模块的参数量约为 $2 \times d \times d_b \approx 1.6 \times 10^6$，仅占原始模型参数量的极小比例。通过这种设计，适配器能够在保留预训练模型通用表示能力的同时，以较低的计算和存储成本实现任务特定的适配。

在蛋白质功能预测领域，适配器技术已经开始被用于增强蛋白质语言模型的下游迁移能力。S-PLM[37] 在 ESM-2 的 Transformer 层中注入基于残差多层感知机的适配器模块，通过对比学习将蛋白质三维结构信息蒸馏到适配器参数中，使序列编码器仅凭序列输入即可产生包含结构感知的表示。这一工作证明了适配器不仅可以用于任务适配，还可以作为跨模态知识蒸馏的载体。

在本文第四章中，适配器技术被进一步拓展为双适配器策略：第一组适配器通过对比学习预训练编码域语义先验，预训练后冻结其参数；第二组适配器在端

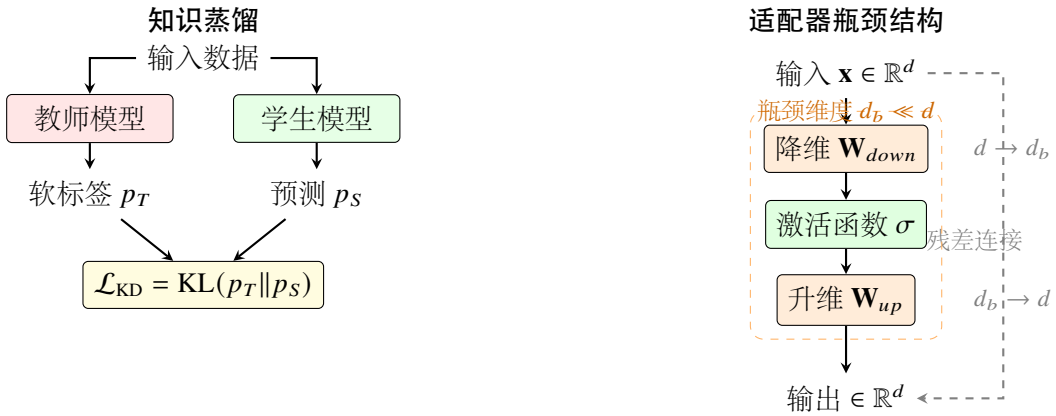

图 2-5: 知识蒸馏与适配器结构示意图。左：知识蒸馏框架，教师模型的软标签通过 KL 散度指导学生模型学习。右：适配器瓶颈结构，通过降维—激活—升维和残差连接实现轻量级的参数高效微调。

到端训练中学习任务特定的适配信息。两组适配器并行运行、输出取平均，实现了预训练知识保留与下游任务优化的有效平衡。

2.5 本章小结

本章围绕蛋白质功能预测的相关研究进行了概述。首先，从任务层面对蛋白质功能预测问题进行了形式化定义，介绍了 GO 层级体系、多标签预测特性、广义零样本设定以及开放标签空间下的”蛋白质—功能”匹配建模思路，并总结了 $F_{\max}$、AUPR 和调和均值 H 等常用评价指标。随后，在表征学习基础技术方面，介绍了 Transformer 架构的自注意力机制、ESM-2 蛋白质语言模型的掩码语言建模训练范式，以及文本语义嵌入技术和 Qwen3-Embedding 模型。之后，阐述了对比学习的 InfoNCE 损失、知识蒸馏的基本框架及其在蛋白质功能预测中的拓展应用，以及适配器与参数高效微调方法的瓶颈结构设计。

本章介绍的各项技术构成了后续研究的理论基础：第三章利用 ESM-2 提取蛋白质序列特征、Qwen3-Embedding 编码文本语义，通过多模态融合实现零样本功能预测；第四章在此基础上进一步利用对比学习、知识蒸馏和适配器技术，将域功能语义先验蒸馏至蛋白质语言模型中，实现端到端的功能预测。

第 3 章 多模态零样本蛋白质功能预测模型

3.1 引言

传统的蛋白质功能预测方法将每个 GO 标签视为独立的分类标识符，模型的预测能力被限制在训练集中出现过的标签范围内，无法对新出现的功能术语进行有效推理。针对这一根本性局限，本章提出多模态零样本蛋白质功能预测模型 MZSGO（Multimodal Zero-Shot GO annotation），将蛋白质功能预测重新定义为开放语义空间中的” 蛋白质-GO” 匹配问题。MZSGO 融合蛋白质语言模型提取的序列进化特征与大语言模型编码的文本语义特征，通过自适应门控融合机制实现多模态信息的动态整合，使模型既能在有监督场景下准确分类，也能通过文本语义相似性推断未见过的功能标签。

本章的组织结构如下：首先介绍数据集的构建与预处理流程，包括训练测试划分、数据统计以及多模态特征编码；随后阐述多模态零样本预测模型的特征投影、特异性丢弃、门控融合和优化目标；最后通过对比实验、消融实验和多维可解释性分析对模型性能进行系统验证。

3.2 数据集的构建与预处理

第二章 2.2.1 节已经对蛋白质功能预测问题的定义进行了系统说明，因此本章不再重复展开，而重点介绍与 MZSGO 方法对应的数据集构建、零样本划分策略及其统计特征。

为严格评估模型在有监督和零样本两个场景下的性能，本文构建了基于 CAFA5 挑战和 Swiss-Prot 数据库[48] 的综合基准数据集。

3.2.1 有监督训练集和零样本测试集构建

有监督训练集构建。训练语料源自 CAFA5 数据集，采用 ProtGO[21] 使用的数据源和训练/测试划分策略，并限制数据条目为 Swiss-Prot 数据库中收录的蛋白质。这一子集由人工审核的蛋白质组成，确保了注释质量的高可靠性，同时为与需要结构信息的基线方法进行公平比较提供了基础。功能注释采用 2023 年 1 月 1 日发布的 Gene Ontology 版本。

与 ProtGO 不同的是，本文实施了本体特异性的数据过滤策略。对于每个本体类别，仅使用具有该特定本体注释的蛋白质进行训练，而非直接使用完整训练集。

这一决策基于如下观察：完整数据集中缺乏某一本体注释的蛋白质会对基线模型的性能产生不利影响。尽管 MZSGO 在完整数据集上也不会出现显著性能下降，但经过裁剪的训练集有助于实现最优性能并确保与最先进基线方法的严格公平比较。

零样本测试集构建。零样本测试集旨在评估模型对从未见过的蛋白质和新出现标签的注释能力。其设计遵循两个核心原则：

（1）**蛋白质新颖性（序列层面）**：选择不在训练集中的 Swiss-Prot 蛋白质。为防止序列相似性导致的信息泄露，使用 Diamond 工具进行严格的同源性过滤，移除与训练集中任何序列的序列一致性超过 30% 的测试蛋白质。

（2）**标签新颖性（语义层面）**：实施时间演进评估策略，引入 2025 年 10 月 10 日更新的 GO 本体版本。将" 零样本标签" 定义为存在于 2025 版本但在 2023 版本中不存在的 GO 术语。因此，最终的零样本测试集由具有这些新出现功能注释的非同源蛋白质组成。

3.2.2 数据集统计

数据集的统计信息如表 3-1所示，样本按三个 GO 子本体分组。由于生物通路的复杂性，BP 类别包含最多的零样本蛋白质数量。

表 3-1: MZSGO 数据集统计

数据集	MF	CC	BP
训练集	50,874	51,743	51,618
测试集	5,584	5,764	5,712
零样本测试集	555	17	3,687

表 3-2详细展示了标签分布情况。在测试阶段，标签被分为以下三类：共有标签（Shared Labels），即同时出现在训练集和测试集中的 GO 术语；未见标签（Unseen Labels），即存在于测试集但不在训练数据中的术语；零样本标签（Zero-shot Labels），特指因本体更新而新出现的术语。

需要强调的是，未见标签和零样本标签对应两种不同的实验评估场景。**未见标签**评估的是模型对现有但稀有功能的泛化能力——这些 GO 术语虽然存在于 GO 本体中，但由于数据稀疏性，在训练集中没有相关蛋白质被注释为该功能。**零样本标签**则评估的是模型对随时间动态扩展的新生物学知识的鲁棒性——这些 GO 术语是在训练截止日期之后才被添加到 GO 本体中的全新概念。标签空间涵盖所有层级，从广泛的功能大类到注释中最精细的叶节点。这种严格的区分确保了零样本测试集上的评估指标真正反映模型的语义推理能力，而非记忆效应。

表 3-2: 标签分布统计

标签类别	MF	CC	BP
标签总数	7,007	2,803	20,639
未见标签	191	26	328
共有标签	2,983	1,581	11,691
仅训练标签	3,833	1,196	8,620
零样本标签	35	6	34

3.2.3 多模态特征编码

MZSGO 利用两种预训练模型提取三个模态的特征表示：

（1）**蛋白质序列表示**：使用 ESM2-650M[28] 蛋白质语言模型对蛋白质序列进行编码，提取最后一层隐藏状态中每个残基位置的上下文嵌入 $\mathbf{r}_j$，通过平均池化获得蛋白质级别的全局进化特征表示：

$$\mathbf{E}_{seq} = \frac{1}{L}\sum_{j=1}^{L}\mathbf{r}_j \in \mathbb{R}^{1280} \tag{3-1}$$

其中 L 为蛋白质序列长度，$\mathbf{r}_j$ 为第 j 个残基的嵌入表示。本文采用平均池化的原因在于其实现简洁、计算高效，且能够确保与现有方法的公平比较——文献中大多数基线方法均采用平均池化作为标准的蛋白质序列表示方法。值得注意的是，近期研究提出了更先进的池化技术，如局部感知池化（locality-aware pooling）[49]，在某些应用场景中展现了良好的前景，未来可进一步探索其在本框架中的适用性。

（2）**GO 标签语义表示**：使用 Qwen3-Embedding-4B[42] 对每个 GO 术语的名称和定义文本进行编码。输入文本格式为" 名称: 定义"（如"protein kinase activity: Catalysis of the phosphorylation of an amino acid residue..."），通过 token 级平均池化获得标签级别的语义嵌入：

$$\mathbf{E}_{label} = \frac{1}{T}\sum_{j=1}^{T}\mathbf{t}_j \in \mathbb{R}^{2560} \tag{3-2}$$

其中 T 为 token 数量。$\mathbf{E}_{label}$ 捕获了功能标签的语义内涵，使模型能够基于文本相似性泛化到未见标签——这是零样本推理的核心基础。与域需要进行多实例聚合不同，每个 GO 术语在本文的配对匹配范式中被视为独立的匹配目标，因此仅需 token 级池化。GO 标签嵌入来源于标准化的官方定义文本，构成了一个静态的语义参考空间。模型学习的是将蛋白质特征与功能语义关联——侧重于理解" 标签的语义含义"，而非简单地预测正确的标签标识符。

（3）**蛋白质域语义表示**：使用同一 Qwen3-Embedding-4B 模型对蛋白质各个域的 InterPro[43] 描述文本进行编码，采用两级平均池化获得蛋白质级别的域特征表示。对于拥有 K 个域的蛋白质，首先对每个域的 token 嵌入进行平均池化获得域级表示 $\mathbf{d}_k$，然后对所有域级表示再次平均池化获得蛋白质级域特征：

$$\mathbf{E}_{dom} = \frac{1}{K}\sum_{k=1}^{K}\mathbf{d}_k \in \mathbb{R}^{2560} \tag{3-3}$$

域信息之所以采用两级池化而非 GO 术语的单级池化，是因为在本文的设计中，一个蛋白质由多个域共同组成一个完整的功能单元，需要将多个域的信息聚合为该蛋白质的统一域表示。而 GO 术语则在配对匹配范式中被逐一评估，无需进行多实例聚合。

以上三种特征分别捕获了蛋白质的进化信号、功能标签的语义内涵和蛋白质域的结构功能信息，为后续的多模态融合提供了互补的信息来源。

表 3-3展示了一个完整的输入数据示例（UniProt ID: Q8TBH0），直观呈现了三种模态的具体数据形式。该蛋白质的氨基酸序列由 ESM2-650M 编码以提取进化特征；其关联的 5 个 InterPro 域描述（包含 Arrestin 相关的结构域和功能域）由 Qwen3-Embedding 编码以提取域语义特征；候选 GO 标签的定义文本（如”intracellular anatomical structure”、”organelle” 等）同样由 Qwen3-Embedding 编码以提取功能语义特征。这种多模态输入设计使模型能够从互补的角度理解蛋白质功能。

3.3 多模态零样本预测模型

在完成数据集构建和多模态特征准备后，本文进一步构建多模态零样本预测模型 MZSGO。该模型将蛋白质功能预测从封闭标签集分类拓展为开放语义空间中的蛋白质-GO 匹配任务，使模型既能够在已有标签上完成有监督预测，也能够借助文本语义对训练阶段未出现的功能术语进行推断。

MZSGO 的总体架构如图 3-1所示。系统由三个关键环节构成：（1）特征投影与特异性丢弃，将异构模态映射到统一隐空间并增强训练鲁棒性；（2）自适应门控融合，根据不同蛋白质-GO 对的语义匹配关系动态整合多模态信息；（3）分类预测与损失优化，输出蛋白质与 GO 功能之间的匹配概率。

MZSGO 的完整训练流程如算法 3-1所示。整个工作流分为四个阶段：特征投影与对齐、特征丢弃（仅训练阶段）、门控融合和分类预测。

3.3.1 特征投影与特异性丢弃

由于三种模态的原始嵌入具有不同的维度和分布特性（ESM 嵌入为 1280 维，

算法 3-1 MZSGO 训练工作流

Input: E_{esm}, E_{dom}（蛋白质特征），E_{nlp}（标签特征）

Output: 预测矩阵 $Y \in \mathbb{R}^{B \times L}$

定义 $\phi(\cdot)$: 通用 MLP 模块（Linear → LN → Act → Dropout）;

// 阶段 1: 投影与对齐

将特征投影至隐藏维度 H;

$\mathbf{h}_{esm} \leftarrow \phi_1(E_{esm}), \mathbf{h}_{dom} \leftarrow \phi_2(E_{dom}), \mathbf{h}_{nlp} \leftarrow \phi_3(E_{nlp})$;

广播特征至形状 $[B \cdot L, H]$ 构建蛋白质-标签配对;

$\mathbf{H} \leftarrow \{\mathbf{h}_{dom}^{expand}, \mathbf{h}_{esm}^{expand}, \mathbf{h}_{nlp}^{expand}\}$;

// 阶段 2: 特征丢弃（仅训练阶段）

if 训练阶段 **then**

  生成掩码 $M \in \{0,1\}^{B \cdot L \times 2}$，确保每行至少保留一个蛋白质特征;

  $\mathbf{h}_{dom}^{expand} \leftarrow \mathbf{h}_{dom}^{expand} \odot M_{:,0}$;

  $\mathbf{h}_{esm}^{expand} \leftarrow \mathbf{h}_{esm}^{expand} \odot M_{:,1}$;

end

// 阶段 3: 门控融合

拼接所有模态: $\mathbf{Z}_{cat} \leftarrow \mathrm{Concat}(\mathbf{H}, \mathrm{dim} = -1)$;

计算门控权重: $\mathbf{W} \leftarrow \mathrm{Softmax}(\phi_{gate}(\mathbf{Z}_{cat}))$ // 形状: $[B \cdot L, 3]$

加权求和融合: $\mathbf{F}_{fused} \leftarrow \sum_{k=1}^{3} \mathbf{W}_{:,k} \cdot \phi_{trans}(\mathbf{H}_k)$;

// 阶段 4: 分类

$Y \leftarrow \mathrm{Reshape}(\mathrm{Linear}(\phi_{cls}(\mathbf{F}_{fused})), [B, L])$;

return Y

表 3-3: 蛋白质 Q8TBH0 的输入数据结构示例。展示三种模态的具体数据形式。

数据模态	内容
蛋白质 ID	Q8TBH0
模态 1：蛋白质序列	MLFDKVKAFSVQLDGATAGVEPVFSGGQAVAGRVLLELSS AARVGALRLRARGRAHVHWTESRSAGSSTAYTQSYSERVE VVSHRATLLAPDTGETTTLPPGRHEFLFSFQLPPTLVTSFE GKHGSVRYCIKATLHRPWVPARRARKVFTVIEPVDINTPAL LAPQ... （共 *420* 个残基）
模态 2：域文本描述	• IPR011021: Domain: Arrestin-like, N-terminal • IPR011022: Domain: Arrestin: C-terminal-like domain • IPR014752: Arrestin-like, C-terminal • IPR014756: Immunoglobulin E-set • IPR050357: Arrestin domain-containing protein
模态 3：GO 标签定义（正样本）	**GO:0005622** intracellular anatomical structure: A component of a cell contained within (but not including) the plasma membrane. **GO:0043226** organelle: Organized structure of distinctive morphology and function. **GO:0016020** membrane: A lipid bilayer along with all the proteins and protein complexes embedded in it.

文本嵌入为 2560 维），需要将它们映射至统一的隐空间。为此，设计三个独立的多层感知机（MLP）投影模块，每个模块由线性变换、层归一化[40]、GELU 激活[41]和 Dropout 组成：

$$\mathbf{h}_m = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_m\mathbf{E}_m + \mathbf{b}_m))) \tag{3-4}$$

其中 $m \in \{seq, dom, label\}$ 表示模态类型，$\mathbf{h}_m \in \mathbb{R}^{d_{model}}$ 为投影后的特征向量，$d_{model} = 512$。

模态特异性丢弃策略。为防止模型过度依赖单一蛋白质模态，并模拟真实场景中域信息缺失的情况，本文设计了一种非对称的特征丢弃机制。在训练阶段，定义二值掩码 $\mathbf{M} = [m_{seq}, m_{dom}]$，其中每个蛋白质模态以概率 $p = 0.15$ 被独立丢弃：

$$m_{seq} = \mathbb{I}[r_{seq} > p], \quad m_{dom} = \mathbb{I}[r_{dom} > p] \tag{3-5}$$

其中 $r_{seq}, r_{dom} \sim \text{Uniform}(0, 1)$。掩码后的特征为 $\hat{\mathbf{h}}_{seq} = \mathbf{h}_{seq} \cdot m_{seq}$ 和 $\hat{\mathbf{h}}_{dom} = \mathbf{h}_{dom} \cdot m_{dom}$。

关键设计在于其" 非对称性"：GO 标签的文本嵌入 $\mathbf{h}_{label}$ 始终保留，不参与丢弃。这迫使模型学会在部分蛋白质信息缺失的情况下，仍能通过 GO 标签的文本语义进行有效预测，从而为零样本泛化奠定基础。

为确保至少有一个蛋白质模态可用，设计了强制保留机制：

$$\text{若} m_{seq} = m_{dom} = 0: \quad m_k \leftarrow 1, \quad k \sim \text{Uniform}\{seq, dom\} \tag{3-6}$$

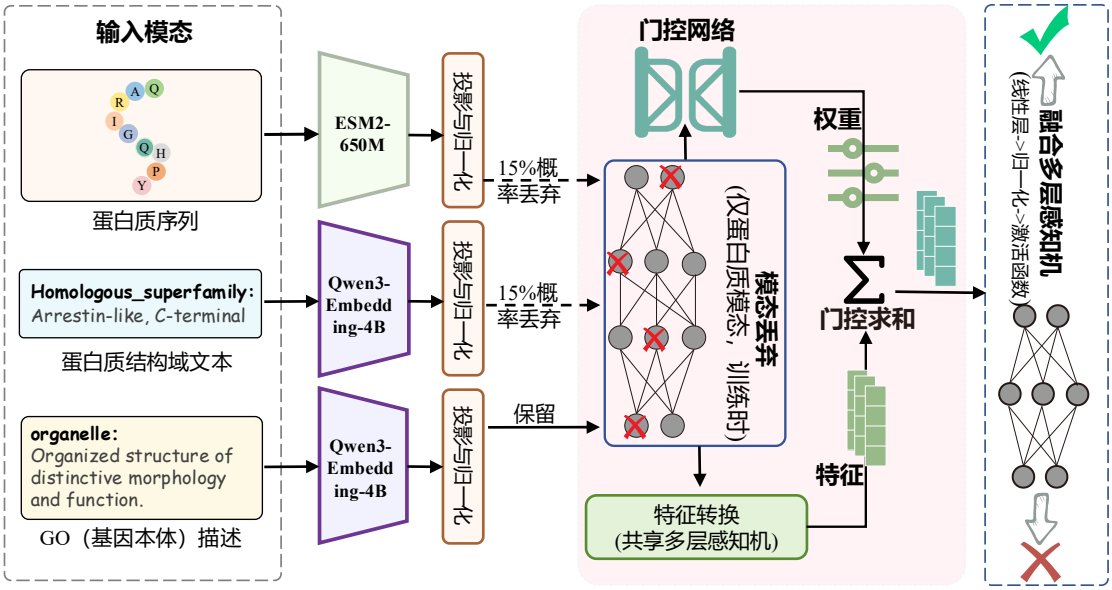

图 3-1: MZSGO 框架总体架构。流程包含四个集成阶段：（1）多模态特征投影；（2）训练阶段的蛋白质模态丢弃，虚线表示以概率 $p = 0.15$ 随机丢弃蛋白质特征，实线表示保留的模态；（3）门控融合模块实现自适应特征整合；（4）二分类头进行 GO 功能预测。

推理阶段不施加任何丢弃，模型可利用完整的多模态信息进行预测。

3.3.2 自适应门控融合机制

为有效整合多模态特征，本文设计了门控融合模块（Gated Fusion Module），学习为每个信息来源分配自适应的重要性权重。首先，拼接三个模态的特征构建全局上下文向量，输入门控网络生成注意力分数：

$$\mathbf{S} = [\hat{\mathbf{h}}_{dom} \parallel \hat{\mathbf{h}}_{seq} \parallel \mathbf{h}_{label}] \tag{3-7}$$

$$\boldsymbol{\alpha} = \mathrm{Softmax}(\mathbf{W}_{gate} \cdot \mathrm{ReLU}(\mathrm{LN}(\mathbf{W}_{ctx}\mathbf{S}))) \tag{3-8}$$

其中 $\parallel$ 表示拼接操作。$\mathbf{W}_{ctx} \in \mathbb{R}^{d_{model} \times 3d_{model}}$ 和 $\mathbf{W}_{gate} \in \mathbb{R}^{3 \times d_{model}}$ 为门控网络中的可学习权重矩阵。$\boldsymbol{\alpha} \in \mathbb{R}^3$ 为经 Softmax 归一化的门控权重向量，其 3 个分量分别对应三种模态（域、序列、标签）的贡献分数。通过 Softmax 函数确保权重之和为 1，使模型能够自适应地确定各信息来源的相对重要性。

同时，每个模态的特征通过变换层 $\phi_{trans}(\cdot)$ 进行非线性映射。ϕ_{trans} 实现为一个**共享多层感知机**，用于对各模态特征进行精细化表示变换。最终的融合表示通过加权求和获得，再经投影层 ϕ_{cls} 输出：

$$\mathbf{H}_{fused} = \phi_{cls}\left(\sum_{k=1}^{3} \alpha_k \cdot \phi_{trans}(\mathbf{h}_k)\right) \tag{3-9}$$

其中 k 索引三个模态（序列、域、标签）。$\phi_{trans}(\cdot)$ 和 $\phi_{cls}(\cdot)$ 均由线性变换、层归一化和激活函数组成。

该机制的核心优势在于：门控权重是**逐样本动态计算**的，即每个蛋白质-GO 对的融合比例不同。例如，当蛋白质的域信息丰富且与功能高度相关时，模型倾向于分配更高的权重给域特征；当域信息稀疏时，模型则更依赖序列特征和标签文本语义。

3.3.3 优化目标

融合表示 $\mathbf{H}_{fused}$ 通过分类 MLP 生成标量逻辑值，再经 sigmoid 激活函数获得预测概率：

$$\hat{y} = \sigma(\mathbf{W}_{out}\mathbf{H}_{fused} + b_{out}) \tag{3-10}$$

为应对不同 GO 子本体在类别不平衡程度上的差异，本文对不同本体采用不同的损失函数策略：

对于 BP 和 MF 子本体，使用标准的二分类交叉熵损失：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3-11}$$

对于 CC 子本体，采用 Focal Loss 以聚焦于难样本的学习：

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N}\sum_{i=1}^{N}\left[\alpha(1 - \hat{y}_i)^{\gamma} y_i \log(\hat{y}_i) + (1 - \alpha)\hat{y}_i^{\gamma}(1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3-12}$$

其中 $\gamma = 2$ 为聚焦参数。

上述损失函数选择策略并非随意决定，而是基于对三个 GO 子本体标签分布特性的定量统计分析。本文引入两个关键指标来刻画数据分布特征：

基尼系数（Gini Coefficient, G）用于量化标签分布的不均衡程度。设 x 为按非递减顺序排列的标签出现次数（$x_1 \leq \cdots \leq x_C$），基尼系数计算为：

$$G = \frac{2\sum_{i=1}^{C} i \cdot x_i}{C\sum_{i=1}^{C} x_i} - \frac{C+1}{C} \tag{3-13}$$

G 接近 1 表示极度不平衡，少数” 头部” 类别主导了数据集。

有效性比率（Effectiveness Ratio, ρ）。遵循 Cui 等人[50] 的分析，由于信息重叠，添加样本的边际收益递减。一个具有 n 个样本的类别的有效数量为 $E_n =$

$(1-\beta^n)/(1-\beta)$，其中 $\beta = 0.9999$。有效性比率定义为平均有效数量与平均实际数量之比：

$$\rho = \frac{\frac{1}{C}\sum_{i=1}^{C} E_{n_i}}{\frac{1}{C}\sum_{i=1}^{C} n_i} \tag{3-14}$$

ρ 值越低表示数据冗余度越高，梯度被重复样本所主导。

统计分析结果显示：MF 和 BP 本体具有相对较高的信息质量，有效性比率分别为 72.20% 和 81.11%，表明尽管存在固有的不平衡，正样本仍能提供充足的独特梯度信号，因此采用标准的 BCE 损失即可。相比之下，CC 本体表现出极端的不平衡性（$G = 0.946$）和最低的有效性比率（57.60%），显著劣于 BP 和 MF。这意味着 CC 本体中近一半的样本量贡献了极少的边际信息，如果使用标准 BCE 损失，这些频繁但冗余的样本会淹没学习过程。因此，CC 本体专门采用 Focal Loss 来降低易分类样本的权重，聚焦于信息量丰富的尾部类别的学习。

3.4 实验结果及分析

3.4.1 对比实验结果与分析

为保证比较结果的可复现性与公平性，本节先介绍实验设置、基线方法和评价指标，随后对标准测试集与纯零样本测试集上的结果进行统一分析。

实验设置。

MZSGO 基于 PyTorch[51] 框架实现。为对齐异构模态，将 1280 维 ESM 嵌入和 2560 维文本/域特征投影至统一的隐空间（$d_{model} = 512$）。这些特征经拼接后输入门控融合网络——一个两层 MLP——计算自适应模态权重，随后通过变换层进行非线性映射。融合表示最终被压缩至 256 维用于分类。

训练在单块 NVIDIA A6000 GPU（48GB 显存）上进行，使用 Adam 优化器[52]，学习率为 5×10^{-4}，批次大小为 16。为缓解过拟合，施加 0.5 的神经元级 Dropout 率。考虑到各子本体的复杂度差异，BP 训练 30 个 epoch，MF 和 CC 各训练 20 个 epoch。

基线方法。

本文选择十种先进的基线方法进行对比，涵盖三大类别：

（1）**传统方法**：Naive（基于标签频率预测）、Diamond[13]（基于序列同源性传递）。

（2）**深度学习方法**：DeepGOCNN[10]（卷积神经网络）、DeepGOZero[23]（本体公理约束）、Struct2GO[17]（图神经网络 + 结构信息）、PO2GO[20]（偏序嵌入）、DeepGO-SE[25]（神经符号推理）。

（3）**多模态/LLM 方法**：ProtGO[21]（四模态融合）、DPFunc[22]（域信息增强）、ProtNote[26]（LLM 功能描述）。

评价指标。

为全面评估模型在蛋白质功能预测中的有效性，特别是在广义零样本设定下的性能，本文采用多层次的评价指标体系。遵循 CAFA 挑战赛[6] 的标准评估协议，以蛋白质中心（protein-centric）的指标为主要评估标准。

标准蛋白质中心指标。

设测试集包含 N 条蛋白质序列。对于第 i 条蛋白质，令 T_i 为其真实 GO 标签集合，$P_i(t)$ 为置信度分数大于等于阈值 $t \in [0, 1]$ 的预测 GO 标签集合。

精确率与召回率。对于给定阈值 t，第 i 条蛋白质的精确率 $\pi_i(t)$ 和召回率 $\rho_i(t)$ 定义为：

$$\pi_i(t) = \frac{|P_i(t) \cap T_i|}{|P_i(t)|}, \quad \rho_i(t) = \frac{|P_i(t) \cap T_i|}{|T_i|} \tag{3-15}$$

其中 $|\cdot|$ 表示集合的大小。数据集的平均精确率 $AvgPr(t)$ 和平均召回率 $AvgRc(t)$ 计算如下：

$$AvgPr(t) = \frac{1}{M(t)} \sum_{i=1}^{N} \pi_i(t) \cdot \mathbb{I}(|P_i(t)| > 0) \tag{3-16}$$

$$AvgRc(t) = \frac{1}{N} \sum_{i=1}^{N} \rho_i(t) \tag{3-17}$$

其中 $M(t)$ 表示在阈值 t 下至少有一个预测结果的蛋白质数量。

F_{max} 指标。F_{max} 是在所有可能阈值 t 上计算的平均精确率和平均召回率的最大调和均值：

$$F_{max} = \max_{t \in [0,1]} \left(\frac{2 \cdot AvgPr(t) \cdot AvgRc(t)}{AvgPr(t) + AvgRc(t)} \right) \tag{3-18}$$

F_{max} 是一个依赖阈值的指标，它通过在 0 到 1 的阈值范围内搜索最优的 F1 分数，有效地衡量了模型的峰值分类精度。

AUPR 指标。AUPR（Area Under the Precision-Recall Curve）通过对精确率-召回率曲线进行积分计算：

$$AUPR = \int_0^1 AvgPr(Rc)\, d(AvgRc) \tag{3-19}$$

与 F_{max} 不同，AUPR 不依赖于特定阈值。鉴于功能注释任务中存在严重的类别不平衡，AUPR 能够提供更为鲁棒的全局性能评估。需要指出的是，本文的 AUPR 是

在蛋白质中心的精确率-召回率曲线上、覆盖完整标签空间计算的。即使模型对未见标签赋予零分数，曲线上仍存在非零的精确率-召回率点（例如在阈值为 0 时），因此数值上 AUPR 略高于零，但这并不表示模型对未见标签具有有效的判别能力。

广义零样本指标。

为评估模型的泛化能力，将标签空间划分为已见标签集 L_{seen} 和未见标签集 L_{unseen}，分别计算两个子集上的 AUPR：

Seen AUPR：将评估限定在训练集中出现过的标签子集上计算的 AUPR。

Unseen AUPR：将评估限定在训练阶段从未遇到的标签子集上计算的 AUPR。

为评价模型在已知知识拟合与新概念泛化之间的权衡，计算二者的调和均值（Harmonic Mean, H）：

$$H = \frac{2 \cdot \mathrm{AUPR}_{seen} \cdot \mathrm{AUPR}_{unseen}}{\mathrm{AUPR}_{seen} + \mathrm{AUPR}_{unseen}} \tag{3-20}$$

只有当模型在已见和未见标签上均表现良好时，H 值才会较高，因此它是衡量模型是否实现了鲁棒泛化而非仅仅过拟合已见类别的关键指标。

加权评价指标。

为考虑 GO 术语的不同特异性，本文还采用了基于信息内容（Information Content, IC）加权的评价指标。每个 GO 术语 v 被赋予权重 $\tau(v) = -\log(p(v))$，其中 $p(v)$ 是该术语在数据库中出现的概率。

加权精确率与加权召回率。对于蛋白质 i 在阈值 t 下的加权精确率 $w\pi_i(t)$ 和加权召回率 $w\rho_i(t)$ 定义为：

$$w\pi_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in P_i(t)} \tau(v)}, \quad w\rho_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in T_i} \tau(v)} \tag{3-21}$$

类似地，wF_{max} 为加权精确率和加权召回率在所有阈值上的最大调和均值，$wAUPR$ 为加权精确率-召回率曲线下面积。

语义距离 S_{min}。S_{min} 基于信息内容评估预测结果与真实标签之间的语义距离，结合剩余不确定性（Remaining Uncertainty, RU）和误信息（Misinformation, MI）两个维度：

$$RU(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in T_i \setminus P_i(t)} \tau(v), \quad MI(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in P_i(t) \setminus T_i} \tau(v) \tag{3-22}$$

$$S_{min} = \min_{t \in [0,1]} \sqrt{RU(t)^2 + MI(t)^2} \tag{3-23}$$

S_{min} 值越低表示预测结果在语义层面与真实标签越接近，该指标对功能特异性较

高的 GO 术语赋予更大的权重，能够更好地评估模型对生物学上重要的精细功能的预测能力。

标准测试集上的性能对比。

表 3-4汇总了 MZSGO 与所有基线方法在三个本体上的性能对比结果。

有监督性能分析。

在常规分类指标（Fmax 和 AUPR）方面，MZSGO 在三个本体上均取得了最优或极具竞争力的结果，凸显了多模态融合方法的有效性。

在最具挑战性的 BP 本体中，MZSGO 以 0.5045 的 Fmax 超过了域感知方法 DPFunc（0.4984）和神经符号推理方法 DeepGO-SE（0.5006）。在 MF 和 CC 本体上，MZSGO 分别以 0.7611 和 0.7470 的 Fmax 保持领先。值得注意的是，MZSGO 在 CC 本体上的 AUPR 达到 0.7726，刷新了该本体的最优记录。

与仅依赖单一模态的方法相比，MZSGO 通过自适应门控融合机制有效整合了蛋白质序列特征（ESM）与域描述语义，使模型能够综合利用互补的语义线索，产生更强的特征表示。

训练集过滤策略的有效性验证。

如3.2节所述，本文对训练集实施了本体特异性过滤策略。为验证这一决策的合理性，本文在 Swiss-Prot 数据库中 CAFA5 完整训练集（72,390 条蛋白质）上进行了对比实验。完整训练集不可避免地包含了对某一目标本体类别缺乏注释的蛋白质，这些隐式的” 负样本” 可能对模型训练产生干扰。

实验结果表明，将蛋白质功能预测建模为二分类问题的方法（如 ProtNote 和 MZSGO）在完整数据集上表现出更强的鲁棒性，不会出现显著的性能退化。具体而言，MZSGO 在未过滤的完整训练集上仍能在所有三个本体类别的 Fmax 和 AUPR 指标上一致性地超越最新基线方法（ProtGO、DPFunc 和 ProtNote）。然而，需要注意的是，多数基线方法（特别是多标签分类范式的方法）在完整数据集上的性能受到了负面影响。这是因为缺乏特定本体注释的蛋白质在训练过程中被隐式地视为该本体所有标签的负样本，引入了大量错误的监督信号。本文最终采用过滤后的训练集，一方面是为了追求最优性能，另一方面更重要的是确保与所有基线方法进行严格公平的比较。

零样本性能分析。

MZSGO 的核心优势在于其对未见标签的推理能力。表 3-4中的 Unseen AUPR 和调和均值 H 直观地反映了这一点。

传统比对方法和标准深度学习模型在零样本场景中表现出极为有限的泛化能力。这主要是因为这些模型将标签视为独立的 one-hot 标识符，在训练过程中，优

表 3-4: MZSGO 与最先进方法在测试集上的性能对比。最优结果加粗，次优结果加下划线。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	Naive	0.2991	0.2073	0.0025	0.2076	0.0049
	Diamond	0.4703	0.2913	0.0025	0.2934	0.0050
	DeepGOCNN	0.3964	0.3676	0.0025	0.3684	0.0050
	DeepGOZero	0.4888	0.4535	0.0025	0.4558	0.0050
	Struct2GO	0.4022	0.3744	0.0025	0.3747	0.0050
BP	PO2GO	0.2975	0.2303	0.0025	0.2307	0.0049
	DeepGO-SE	0.5006	0.4373	0.0025	0.4404	0.0050
	ProtGO	0.4636	0.4377	0.0025	0.4410	0.0050
	DPFunc	0.4984	0.4902	0.0069	0.4936	0.0136
	ProtNote	0.3555	0.2993	0.0303	0.2997	0.0550
	MZSGO	**0.5045**	**0.5008**	**0.2393**	**0.5021**	**0.3241**
	Naive	0.5496	0.3318	0.0032	0.3327	0.0063
	Diamond	0.6727	0.3330	0.0032	0.3366	0.0063
	DeepGOCNN	0.6603	0.5225	0.0032	0.5242	0.0064
	DeepGOZero	0.7441	0.6333	0.0032	0.6380	0.0064
	Struct2GO	0.6564	0.5940	0.0032	0.5962	0.0064
MF	PO2GO	0.5496	0.4136	0.0032	0.4148	0.0064
	DeepGO-SE	0.7481	0.6332	0.0032	0.6376	0.0064
	ProtGO	0.7262	0.7399	0.0032	0.7453	0.0064
	DPFunc	0.7495	**0.7416**	0.0051	**0.7480**	0.0101
	ProtNote	0.6140	0.5283	0.0490	0.5301	0.0897
	MZSGO	**0.7611**	0.7337	**0.4806**	0.7380	**0.5821**
	Naive	0.6143	0.0793	0.0207	0.5270	0.0398
	Diamond	0.6331	0.3076	0.0207	0.3093	0.0388
	DeepGOCNN	0.6918	0.5284	0.0207	0.5292	0.0398
	DeepGOZero	0.7075	0.6598	0.0207	0.6612	0.0401
	Struct2GO	0.6989	0.7380	0.0207	0.7382	0.0403
CC	PO2GO	0.6143	0.5828	0.0207	0.5830	0.0400
	DeepGO-SE	0.7379	0.6991	0.0207	0.7003	0.0402
	ProtGO	0.7209	0.7717	0.0207	0.7727	0.0403
	DPFunc	0.7386	0.7709	0.0274	0.7722	0.0529
	ProtNote	0.6636	0.6605	0.2530	0.6607	0.3659
	MZSGO	**0.7470**	**0.7726**	**0.5862**	**0.7733**	**0.6669**

化目标自然地抑制了未见标签对应的权重，迫使模型对训练集中未出现的类别预测接近零的概率。值得注意的是，尽管 DeepGOZero 理论上能够通过逻辑约束实现零样本预测，但它在缺乏显式 GO 公理的罕见类别上预测失效，Unseen AUPR 接近 0。

ProtNote 利用 LLM 展示了一定的零样本能力（如 BP 上的 0.0303），但 MZSGO 大幅超越了它。具体而言，MZSGO 在 BP 本体上实现了 0.2393 的 Unseen AUPR——相较 ProtNote 提升了约 **8 倍**。在 MF 和 CC 本体上同样观察到一致的趋势，MZSGO 分别实现了 0.4806 和 0.5862 的 Unseen AUPR。

综合平衡已见和未见标签性能的调和均值 H 进一步凸显了模型的全面优势。MZSGO 在 BP、MF、CC 上分别获得 0.3241、0.5821 和 0.6669 的 H 值，大幅超越亚军 ProtNote 的 0.0550、0.0897 和 0.3659。这一结果证实 MZSGO 不仅仅是记忆训练标签，而是学到了蛋白质特征与功能描述之间的泛化性语义对齐。

纯零样本测试集上的评估。

为进一步严格验证泛化能力，本文在专门构建的纯零样本测试集上将 MZSGO 与零样本能力最强的基线方法 ProtNote 进行直接对比。结果如表 3-5所示。

表 3-5: 纯零样本测试集上的性能对比。该评估集通过时间演进方式构建，评估模型对 2025 版本中新出现但训练截止日期前不存在的 GO 功能标签的预测能力。

本体	模型	Fmax	AUPR	Precision	Recall
BP	ProtNote	0.3763	0.2705	0.2580	**0.6951**
	MZSGO	**0.4881**	**0.4546**	**0.4475**	0.5369
MF	ProtNote	0.3599	0.3393	0.4545	0.2979
	MZSGO	**0.5982**	**0.5435**	**0.6261**	**0.5727**
CC	ProtNote	0.2983	0.1652	0.1853	0.7647
	MZSGO	**0.6610**	**0.6291**	**0.5521**	**0.8235**

MZSGO 在所有三个本体的 Fmax 和 AUPR 上均一致超越 ProtNote。对精确率和召回率的精细分析揭示了两种方法的行为差异和改进方向：

（1）**BP 本体的平衡精确率-召回率权衡**：ProtNote 展现了较高的召回率（0.6951）但精确率低下（0.2580），表明其倾向于过度预测功能标签。相比之下，MZSGO 实现了更均衡的权衡，将精确率提升至 0.4475 的同时保持了 0.5369 的竞争性召回率，从而获得了显著更高的 Fmax（0.4881 vs. 0.3763），意味着在复杂生物过程的预测中更为可靠。

（2）**MF 和 CC 本体的全面优势**：在 MF 本体上，MZSGO 获得 0.5982 的 Fmax（ProtNote 为 0.3599），精确率（0.6261 vs. 0.4545）和召回率（0.5727 vs. 0.2979）双双领先，展示了对未见分子功能的准确识别能力。在 CC 本体上，性能差距最为显著：ProtNote 的精确率仅为 0.1853——可能是由于广泛文本匹配导致的" 功能幻觉"（functional hallucination），即模型基于表层文本相似性错误地将蛋白质匹配到不相关的功能标签——而 MZSGO 达到 0.5521 的精确率，同时召回率也优于 ProtNote（0.8235 vs. 0.7647），实现了 Fmax 从 0.2983 到 0.6610 的翻倍提升。为进一步探究其背后的机制，本文对功能文本嵌入和域文本嵌入进行了可视化分析，结果表明在正确预测的样本中，域嵌入向量在空间上与功能文本嵌入向量更为接近，详见本章嵌入空间可视化分析一节。

这一对比结果表明，MZSGO 通过将预测锚定在域特异性的语义空间中，有效避免了其他基于文本的模型中常见的噪声和假阳性问题，为蛋白质新功能注释提供了高度可靠的预测能力。

3.4.2 消融实验结果与分析

为评估各组件的贡献——特别是多模态特征、融合模块和优化策略，本文在 CC 本体上进行了系统的消融实验。消融变体分为五组：（1）单模态编码器；（2）特征表示变化；（3）架构变化；（4）编码器替换；（5）损失函数变体。结果如表 3-6所示。

从消融结果中可以得出以下关键结论：

（1）**域语义信息是零样本能力的关键**。移除域语义信息造成最严重的性能退化：仅使用 ESM 特征时，Unseen Fmax 从 0.5665 骤降至 0.0793（下降 93%），表明序列特征本身难以泛化到未见标签。仅使用域特征时 Unseen Fmax 为 0.2322，远优于仅用 ESM；而将域信息退化为 One-hot 编码后 Unseen Fmax 降至 0.2000，证实零样本迁移依赖于域描述的语义内容而非简单标识符。

（2）**门控融合机制不可或缺**。将门控融合替换为简单拼接使 H 从 0.6669 降至 0.6000，说明朴素拼接无法有效整合异构模态。使用 PO2Vec 标签嵌入替代文本嵌入更是导致 H 降至 0.4423——这不仅因为 PO2Vec 依赖于固定的 GO 图拓扑结构，更因为基于图拓扑的嵌入与序列和文本模态在语义对齐度上存在显著鸿沟，进一步加大了多模态融合中的语义差距。

（3）**特征丢弃策略增强泛化能力**。去除特征丢弃后，已见标签准确度略有提升（Fmax 达 0.7544），但零样本泛化显著下降（H 从 0.6669 降至 0.5714），验证了其作为正则化手段防止模型对已见标签过拟合[53] 的重要性。

表 3-6: CC 本体上的消融实验结果。报告指标包括总体 Fmax 和 AUPR，以及零样本相关指标。H 为已见与未见标签性能的调和均值。

方法	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7319	0.7344	0.5203	0.0793	0.6094
仅域特征	0.7311	0.7052	0.5187	0.2322	0.6012
特征与架构消融					
域信息 One-hot 编码	0.7203	0.6731	0.5047	0.2000	0.5889
使用 PO2Vec 标签嵌入	0.7406	0.7196	0.3193	0.1818	0.4423
去除特征丢弃	**0.7544**	0.6857	0.4898	0.2500	0.5714
简单拼接替代门控融合	0.7381	0.7009	0.5245	0.2469	0.6000
编码器变体					
BioGPT	0.7419	0.7198	0.4258	0.1935	0.5351
BiomedBERT	0.7406	0.7218	0.5647	0.2000	0.6337
Qwen3-0.6B	0.7406	0.7282	0.5469	0.1379	0.6247
ESM-150M	0.7385	0.7310	0.3864	0.1333	0.5056
损失函数变体					
BCE 损失	0.7501	0.7143	0.5824	0.2581	0.6421
加权 BCE 损失	0.7199	0.7450	0.5127	0.4444	0.6095
MZSGO	0.7470	**0.7726**	**0.5862**	**0.5665**	**0.6669**

（4）**编码器选择的合理性**。各替代编码器的性能均不及当前组合，证实 MZSGO 选择的编码器（ESM2-650M + Qwen3-Embedding-4B）最能捕获跨模态的互补结构信息。

（5）**Focal Loss 在 CC 本体上的优势**。标准 BCE 获得较高的 Fmax（0.7501）但总体 AUPR 偏低（0.7143）；加权 BCE 虽改善了 Unseen Fmax（0.4444）但损害了总体 AUPR 和 H 值。Focal Loss（MZSGO）通过有效平衡困难样本的学习，实现了最优的综合权衡。

BP 和 MF 本体的消融验证。

为进一步验证框架的鲁棒性和可推广性，本文将消融实验扩展至 BP 和 MF 本体。实验设置和变体分组与 CC 本体消融完全一致。

表 3-7和表 3-8分别展示了 BP 和 MF 本体上的消融结果，其发现与 CC 本体的结论高度一致。

表 3-7: BP 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.4584	0.4278	0.0924	0.0446	0.1520
仅域特征	0.4552	0.4208	0.0774	0.0334	0.1308
特征与架构消融					
域信息 One-hot 编码	0.4833	0.4550	0.2309	0.1182	0.3066
使用 PO2Vec 标签嵌入	0.4948	0.4721	0.0959	0.0534	0.1595
去除特征丢弃	0.4992	0.4794	0.2231	0.1440	0.3047
简单拼接替代门控融合	0.4849	0.4602	0.0700	0.0352	0.1215
编码器变体					
BioGPT	0.4877	0.4650	0.1584	0.1153	0.2364
BiomedBERT	0.4829	0.4569	0.1801	0.0931	0.2608
Qwen3-0.6B	0.4842	0.4590	0.1964	0.0967	0.2752
ESM-150M	0.4799	0.4540	0.1730	0.1176	0.2506
损失函数变体					
Focal Loss	0.4791	0.4787	0.1166	0.1901	0.1876
加权 BCE 损失	0.4821	0.4580	0.1755	**0.2141**	0.2542
MZSGO	**0.5045**	**0.5008**	**0.2393**	0.1210	**0.3250**

表 3-8: MF 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7322	0.6890	0.2502	0.1516	0.3675
仅域特征	0.7380	0.6986	0.4655	0.3966	0.5598
特征与架构消融					
域信息 One-hot 编码	0.7376	0.7041	0.3149	0.2367	0.4359
使用 PO2Vec 标签嵌入	0.7414	0.7014	0.3772	0.3871	0.4916
去除特征丢弃	0.7517	0.7104	0.4800	0.4206	0.5740
简单拼接替代门控融合	0.7446	0.7035	0.3951	0.3050	0.5069
编码器变体					
BioGPT	0.7506	0.7223	0.4512	0.4290	0.5566
BiomedBERT	0.7508	0.7206	0.4513	0.4485	0.5562
Qwen3-0.6B	0.7440	0.7111	0.3745	0.3428	0.4915
ESM-150M	0.7497	0.7202	0.4656	0.3527	0.5667
损失函数变体					
Focal Loss	0.7280	0.6938	0.4286	0.4835	0.5309
加权 BCE 损失	0.7372	0.7074	**0.5526**	**0.5585**	**0.6234**
MZSGO	**0.7611**	**0.7337**	0.4806	0.4259	0.5821

从 BP 和 MF 本体的消融结果中，可以提炼出以下跨本体的一致性发现：

（1）**多模态融合的必要性**。依赖单一模态（仅 ESM 或仅域特征）在三个本体上均导致显著的性能下降，特别是在零样本指标（Unseen AUPR 和 H 值）方面。值得注意的是，在 BP 本体上，单模态模型的 H 值仅为 0.1520（仅 ESM）和 0.1308（仅域），远低于 MZSGO 的 0.3250，凸显了多模态融合对于处理复杂生物过程分类的关键作用。

（2）**语义对齐的优越性**。用传统方法（域 One-hot 编码或 PO2Vec 标签嵌入）替代 LLM 文本嵌入，在三个本体上均严重损害零样本性能。以 BP 本体为例，使用 PO2Vec 标签嵌入的 H 值仅为 0.1595，远低于 MZSGO 的 0.3250。这再次证实了基于深度语义表示的标签理解对于零样本迁移的不可替代性。

（3）**架构设计的有效性**。简单拼接替代门控融合和去除特征丢弃策略在三个本体上均导致性能退化。在 BP 本体上，简单拼接的 H 值骤降至 0.1215——甚至低于部分单模态变体——说明在信息极度异构的 BP 分类任务中，朴素拼接不仅无法有效利用多模态信息，反而可能引入噪声。

（4）**损失函数选择的本体依赖性**。MF 本体的消融结果揭示了一个有趣的现象：加权 BCE 损失在 MF 上取得了最高的 Unseen AUPR（0.5526）和 H 值（0.6234），超过了 MZSGO 采用的标准 BCE 损失。然而，加权 BCE 在 MF 上的总体 Fmax（0.7372）和 AUPR（0.7074）均低于 MZSGO（0.7611 和 0.7337）。相反，在 BP 本体上，Focal Loss 变体的 H 值仅为 0.1876，远低于标准 BCE 的 0.3250，表明 Focal Loss 并不适合 BP 的数据特性。这些发现验证了本文为不同本体选择不同损失函数策略的合理性：BP 和 MF 使用标准 BCE 以追求最佳的综合性能，CC 使用 Focal Loss 以应对其极端的类别不平衡。

3.4.3 参数敏感性分析

为评估模型的鲁棒性，本文考察了两个关键超参数的影响：Dropout 率和隐藏向量维度。采用控制变量法，每次仅变动一个参数，在 CC 和 MF 本体上观察 AUPR 的波动。

Dropout 率的影响。

Dropout 率应用于特征提取后的神经元级丢弃，取值范围为 0.3 至 0.7。模型在 Dropout 率为 0.5 时表现最佳，CC 本体 AUPR 达 0.7726，MF 本体达 0.7377。较低的 Dropout 率（如 0.3）导致过拟合和泛化能力下降；较高的 Dropout 率（如 0.7）因过度信息丢失使性能退化（CC 降至 0.7610，MF 降至 0.7228）。因此，0.5 被选为最优配置。

隐藏向量维度的影响。

隐藏维度从 128 变化至 1024。随着维度从 128 扩展至 512，两个本体的性能持续提升。CC 本体在 512 维时达到峰值（AUPR 为 0.7726），此后随维度增大而退化。MF 本体在 1024 维时仍有提升（AUPR 达 0.8133），但 CC 本体在该维度下显著下降至 0.7371。为构建跨 GO 类别通用的模型架构而无需针对特定任务进行调整，最终将隐藏维度设定为 512，在表征能力和计算成本之间取得了良好的平衡。

3.4.4 嵌入空间可视化分析

为深入理解 MZSGO 实现零样本预测的内在机制，本文对域嵌入和功能文本嵌入的空间分布进行了可视化分析。

域嵌入与功能嵌入的空间关系。

使用 t-SNE 降维技术对 MF 和 CC 本体中蛋白质域嵌入和 GO 标签功能文本嵌入的空间分布进行可视化。可视化结果揭示了鲜明的聚类模式：在模型正确预测的样本中，蛋白质域嵌入向量在空间上与其对应的功能文本嵌入向量更为接近。在 MF 和 CC 两个本体中，正确预测样本的域嵌入与功能文本嵌入之间的欧几里得距离一致性地小于错误预测样本。

这一观察结果为 MZSGO 的零样本能力提供了直观的解释：模型学会了在统一的语义空间中建立蛋白质域特征与功能语义描述之间的有效映射。当一个蛋白质的域描述与某个 GO 标签的定义在语义上高度相似时（即在嵌入空间中距离较近），即使该 GO 标签在训练中从未出现，模型也能够基于这种语义邻近性做出正确的零样本预测。

零样本预测的文本语义分析。

为进一步揭示模型成功预测的深层原因，本文分析了 InterPro 域描述与 GO 标签定义之间的文本语义对应关系。以 CC 本体的零样本预测为例进行案例研究：在成功预测的案例中，域描述与 GO 标签定义之间存在大量共享或语义相近的关键词。

例如，当蛋白质具有”membrane-associated” 类型的域描述时，模型能够正确预测其与”membrane” 相关的 CC 功能标签，即使这些标签在训练集中从未出现。域描述中的”integral membrane protein”、”transmembrane helix” 等关键短语与 GO 标签”integral component of membrane” 定义中的核心概念形成了语义桥梁。这种文本级别的语义对齐通过 Qwen3-Embedding 模型被有效编码，使得 MZSGO 能够超越简单的模式记忆，实现基于深层语义理解的零样本功能推断。

相反，在预测失败的案例中，域描述与目标 GO 标签之间缺乏明确的语义关联，或者域描述过于笼统而无法提供针对性的功能线索。这一分析为未来改进 MZSGO

指明了方向——引入更丰富的域语义信息或更精细的语义对齐策略可能进一步提升零样本性能。

3.4.5 自适应门控权重分析

为深入理解 MZSGO 如何整合多模态信息，本文分析了门控融合模块分配给三种模态——域特征（α）、ESM 序列特征（β）和 NLP 文本特征（γ）——的平均门控权重在三个 GO 本体上的分布情况。门控权重是动态学习的，反映了模型在不同预测任务中对特定模态的依赖程度。

各本体的门控权重特征。

CC 本体表现出对域特征的高度依赖，总体平均权重达 83.60%，在未见标签上更是上升至 91.23%。这一发现与消融实验的结果完全一致——在 CC 消融实验中，仅域特征模型的零样本性能（Unseen Fmax = 0.2322）显著优于仅 ESM 模型（Unseen Fmax = 0.0793）。CC 本体描述的是蛋白质的亚细胞定位，而特定的蛋白质域和基序（如信号肽、跨膜域、核定位信号等）往往直接决定了蛋白质的亚细胞位置，因此域信息对 CC 预测提供了最为直接的泛化信号。

BP 本体的模型在已见标签上优先使用 ESM 序列特征（权重为 53.66%），这可能是因为序列同源性在已知功能预测中是一个强有力的预测因子。然而，对于”零样本标签”（训练样本极少或没有的标签），一个显著的偏移出现了：模型增加了对域特征（从总体的 31.11% 上升至 44.76%）和 NLP 特征的依赖。这种自适应偏移展示了 MZSGO 在序列模式不足以应对罕见或新颖类别时，能够灵活地利用语义域描述作为补充信息源的能力。

MF 本体呈现出域特征（约 48%）和 ESM 特征（约 48%）之间的均衡分布，表明酶活性和结合功能的预测同时需要域提供的结构线索和 ESM 编码器捕获的精细残基信息。这种平衡反映了 MF 功能标签的双重特性——既依赖于保守的功能域模体，又与序列层面的精细特征密切相关。

已见与未见标签的门控偏移。

跨三个本体的一个共性规律是：从已见标签到未见标签，门控权重始终向域特征和 NLP 文本特征偏移。这一现象有着深刻的生物学解释——对于已知功能，模型可以依赖通过大量训练样本学习到的序列模式进行预测；而对于未见功能，序列模式可能不再适用（因为缺乏相应的训练信号），此时域的结构功能语义和 GO 标签的文本定义成为唯一可用的推理依据。

门控权重分析进一步证实了 MZSGO 并非简单地对多模态信息进行平均融合，而是根据本体特性和目标标签的具体性质（已见 vs. 未见）自适应地选择最具信息

量的表示来源。这种动态选择机制是 MZSGO 实现优异零样本性能的关键技术基础。

加权评价指标补充分析。

除标准指标外，本文还采用基于信息内容加权的评价指标进一步评估 MZSGO 的预测质量。这些加权指标为功能特异性更高的 GO 术语赋予更大的权重，能够更准确地衡量模型对生物学上更为重要的精细功能的预测能力。表 3-9总结了 MZSGO 与最新基线方法在三个本体上的加权指标对比。

表 3-9: 加权评价指标（wF_{max}、$wAUPR$ 和 S_{min}）在三个 GO 本体上的对比。S_{min} 越低表示性能越好。

模型	BP			MF			CC		
	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$
ProtGO	0.4231	0.3582	37.0125	0.6634	0.5312	9.3241	0.6315	0.5553	9.5712
DPFunc	**0.4562**	**0.4265**	35.4012	0.6912	0.6431	8.6325	0.6521	0.6412	9.0834
ProtNote	0.3065	0.2384	40.9251	0.5301	0.4105	12.0812	0.5174	0.4776	11.1623
MZSGO	0.4560	0.4201	**34.8821**	**0.7015**	**0.6462**	**8.6105**	**0.6573**	**0.6478**	**8.9012**

从加权指标的对比中可以得出以下分析：

（1）在 MF 和 CC 本体上，MZSGO 在所有三个加权指标上均取得最优。在 MF 本体上，wF_{max} 达 0.7015，$wAUPR$ 达 0.6462，S_{min} 降至 8.6105，全面超越 DPFunc 和 ProtGO。这表明 MZSGO 不仅在整体覆盖度上表现优异，对于功能特异性较高、信息内容较大的 GO 术语也保持了良好的预测精度。

（2）在 BP 本体上，MZSGO 的 wF_{max}（0.4560）与 DPFunc（0.4562）极为接近，但 S_{min} 指标（34.8821 vs. 35.4012）优于 DPFunc，说明 MZSGO 在语义距离层面更接近真实标签。BP 本体的生物过程标签层级结构最为复杂，标签间的语义重叠度高，加权指标上的微小差距反映了这一挑战的本质难度。

（3）ProtNote 在加权指标上的表现显著劣于其他方法（尤其是 S_{min} 高达 40.9251 和 12.0812），这进一步说明 ProtNote 虽然能够进行零样本预测，但其预测质量（特别是对生物学上重要的精细功能的预测精度）仍有较大差距。ProtNote 采用的简单 one-hot 序列编码和联合训练策略限制了其对功能语义细节的捕获能力。

3.4.6 层级一致性分析

Gene Ontology 的 GO 术语以有向无环图（DAG）的形式组织，这暗含了 True Path Rule（TPR）[54]：如果一个蛋白质被注释了某个特定术语，则它必须同时被注

释该术语的所有祖先术语。反之，如果一个蛋白质未被注释某个术语，则它不能被注释该术语的任何后代术语。

层级传播机制。

为评估显式的层级约束是否能增强 MZSGO 的性能，本文实现了后处理层级传播机制，记为 **MZSGO_PROP**。给定蛋白质在 L 个标签上的原始预测分数 S，通过按照 DAG 结构将子节点的最大分数传播至父节点来确保层级一致性：

$$S_p^* = \max\left(S_p, \max_{c \in \text{children}(p)} S_c\right) \tag{3-24}$$

其中 S_p 为父术语的原始分数，S_p^* 为校正后的分数。这保证了父术语的预测分数始终大于等于其任何后代术语的分数。

实验结果与讨论。

表 3-10比较了原始 MZSGO 和引入 TPR 传播后的 MZSGO_PROP 在三个本体上的性能。

表 3-10: 原始 MZSGO 与引入 True Path Rule 传播的 MZSGO_PROP 的性能对比。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
BP	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
	MZSGO_PROP	**0.5066**	**0.5046**	**0.2394**	**0.5060**	**0.3250**
MF	MZSGO	0.7611	0.7337	**0.4806**	0.7380	0.5821
	MZSGO_PROP	**0.7628**	**0.7356**	**0.4806**	**0.7399**	**0.5827**
CC	MZSGO	0.7470	0.7726	**0.5862**	0.7733	0.6669
	MZSGO_PROP	**0.7482**	**0.7736**	**0.5862**	**0.7743**	**0.6672**

从实验结果可以观察到，引入显式的 TPR 传播仅带来了边际性的改善（例如 Fmax 提升不足 0.3%）。这一发现具有重要的方法学意义，表明 MZSGO 的多模态匹配机制**天然地具备了隐式捕获层级依赖关系的能力**。

分析其原因，基于 LLM 的 GO 定义嵌入在潜在空间中将语义上（因此也是层级上）相关的术语定位在相近的位置。由于 GO 的层级结构中，父术语的定义通常是子术语定义的语义泛化——例如”kinase activity”（父）与”protein kinase activity”（子）——LLM 编码器自然会为它们生成相似的嵌入表示。这意味着当模型预测某个蛋白质与子术语匹配时，由于父术语嵌入的相近性，模型也倾向于给予父术语较高的匹配分数，从而在不需要显式层级约束的情况下隐式地满足了 True Path Rule。

这一结果进一步验证了基于 LLM 语义嵌入的 MZSGO 方法在蛋白质功能预测任务中的合理性——深层语义表示不仅能够支持零样本推理，还能自然地编码 GO 的拓扑层级信息，避免了传统方法中复杂的后处理层级传播步骤或刚性的架构约束。

3.5 本章小结

本章提出了多模态零样本蛋白质功能注释方法 MZSGO，其核心创新在于三个方面：（1）将蛋白质功能预测从封闭标签集分类重新定义为开放语义空间中的蛋白质-GO 匹配问题，通过大语言模型构建域和标签的统一语义空间，从根本上赋予模型零样本推理能力；（2）设计了自适应门控融合模块，实现逐样本动态的多模态特征整合，克服了传统简单拼接方式的局限；（3）引入非对称特征丢弃策略，在训练阶段增强模型对模态缺失的鲁棒性。

实验结果表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下则以压倒性优势超越所有现有方法。其中，在最具挑战性的 CC 本体零样本场景下，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍。

通过多维度的深入分析，本章对 MZSGO 的各个组件和设计决策进行了全面验证：消融实验在三个本体上一致性地证明了域语义信息、门控融合机制和特征丢弃策略各自的不可替代性；基于 Gini 系数和有效性比率的统计分析为不同本体的损失函数选择提供了理论依据；嵌入空间可视化分析直观地揭示了 MZSGO 通过域-功能语义邻近性实现零样本推理的内在机制；门控权重分析证实了模型能够根据本体特性和标签可见性动态调整多模态信息的整合策略；加权评价指标实验验证了 MZSGO 对功能特异性较高的 GO 术语同样保持了优异的预测精度；True Path Rule 实验则表明基于 LLM 语义嵌入的方法天然地编码了 GO 的层级拓扑信息。综上，MZSGO 为蛋白质功能注释，特别是新功能标签的预测，提供了可靠且有效的计算工具。

第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA

4.1 引言

第三章提出的 MZSGO 方法通过多模态语义融合在蛋白质功能预测任务上取得了优异的性能，尤其在零样本场景下展现了显著的优势。然而，MZSGO 存在一个本质局限：蛋白质语言模型 ESM2 被用作静态特征提取器，其参数在下游训练中保持冻结，无法根据功能预测任务进行自适应调整。这意味着 ESM2 输出的序列嵌入仅包含通用的进化信息，缺乏与蛋白质域功能语义相关的先验知识。同时，由于域嵌入在训练前即已预计算并缓存，整个管线缺乏端到端的梯度流动，限制了模型进一步提升的空间。

针对上述问题，本章提出基于域感知适配器预训练的端到端蛋白质功能预测模型 MZSGO-DA（MZSGO with Domain-Aware adapter pretraining）。MZSGO-DA 的灵感来源于 S-PLM[37]——一种结构感知的蛋白质语言模型。S-PLM 通过在 ESM2 的 Transformer 层中注入轻量级适配器模块，利用对比学习将蛋白质三维结构信息蒸馏至序列编码器，使其仅凭序列输入即可生成包含结构感知的表示。MZSGO-DA 借鉴了 S-PLM" 通过对比学习将跨模态知识蒸馏至适配器" 这一核心思想，但在以下方面进行了重要的拓展和创新：

（1）**蒸馏目标不同**。S-PLM 的蒸馏目标是蛋白质三维结构信息，而 MZSGO-DA 将其替换为蛋白质域的功能语义信息。蛋白质域作为独立的功能和结构单元，其自然语言描述蕴含着丰富的功能先验，与蛋白质功能预测任务的关联性更为直接。

（2）**下游训练策略不同**。S-PLM 在预训练后采用冻结或微调适配器的常规策略应用于下游任务。MZSGO-DA 则创新性地提出了双适配器端到端训练策略——冻结预训练适配器以保留域语义先验，同时引入第二组可训练适配器进行任务特定适配，实现了预训练知识保留与下游任务优化的有效平衡。

（3）**域嵌入的处理方式不同**。S-PLM 的结构编码器（Swin-Transformer）在预训练时直接处理蛋白质接触图，而 MZSGO-DA 使用预训练的大语言模型 Qwen3-Embedding 对域文本描述进行语义编码，将自然语言级别的功能先验引入蛋白质表示学习。

本章的组织结构如下：首先分析域感知适配器预训练的研究动机与任务构建；随后介绍 MZSGO-DA 的总体框架、适配器机制及端到端训练策略；最后通过对比实验、消融实验以及训练过程分析验证方法的有效性。

4.2 域感知适配器预训练任务构建

4.2.1 问题动机与设计目标

MZSGO 采用静态嵌入策略：首先使用冻结的 ESM2 提取所有蛋白质的序列嵌入并缓存至磁盘，然后在训练阶段直接读取这些预计算的向量。这种策略虽然计算高效，但存在三方面不足：

（1）**信息瓶颈**。ESM2 的通用预训练目标是掩码语言建模，学习到的表示侧重于序列进化约束和氨基酸共现模式，而非特定于功能预测任务的信息。当功能注释依赖于蛋白质域的结构功能特征时，通用序列嵌入可能丢失关键线索。

（2）**梯度断裂**。由于 ESM2 参数完全冻结且嵌入预计算，下游分类器的梯度无法回传至序列编码器，模型无法通过反向传播调整序列表征以更好地适配功能预测目标。

（3）**域信息依赖**。MZSGO 在推理时需要显式输入蛋白质的域嵌入，而 InterPro 数据库中约 20% 的蛋白质缺乏域注释，这部分蛋白质只能使用零向量作为域特征占位符，降低了预测质量。

MZSGO-DA 通过两阶段策略系统性地解决上述问题。受 S-PLM[37] 利用对比学习在适配器中蒸馏结构信息的启发，MZSGO-DA 将这一思路应用于域语义信息的蒸馏：第一阶段（预训练），通过对比学习将域语义信息”内化”至序列编码器的适配器参数中；第二阶段（下游训练），通过端到端训练打通梯度通路，使序列表征能够根据功能预测目标进行自适应调整。与 S-PLM 的单适配器预训练策略不同，MZSGO-DA 引入了双适配器机制，冻结预训练适配器以保护域知识，同时引入可训练适配器进行任务适配。预训练完成后，即使不显式输入域信息，序列编码器也能产出包含域语义先验的增强表示。

4.2.2 域感知对比学习任务

基于上述动机，本章将域文本描述视为序列编码器的跨模态监督信号，构建“蛋白质序列—域语义”对比学习预训练任务。该任务以蛋白质序列为输入、以域文本嵌入为语义锚点，通过正负样本配对学习将域功能先验蒸馏到适配器参数中，为后续端到端功能预测提供域感知初始化。其具体网络结构、损失函数与下游迁移方式将在 4.3 节中进一步展开。

4.3 MZSGO-DA 模型设计

4.3.1 总体框架

MZSGO-DA 的训练流程分为两个阶段，如图 4-1所示。

第一阶段：域感知对比学习预训练。在 ESM2 的 Transformer 层中注入一组轻量级适配器模块（记为 adapter_0），冻结 ESM2 原始参数，仅训练适配器参数。通过 InfoNCE 对比学习损失，将蛋白质序列的适配器增强表示与对应的域文本嵌入（由 Qwen3-Embedding 预计算）进行对齐。预训练完成后，adapter_0 中编码了蛋白质域的语义先验。

第二阶段：双适配器端到端下游训练。冻结 adapter_0 的参数，在同一 ESM2 模型中注入第二组适配器（adapter_1），使其可训练。两组适配器在每个 Transformer 层内并行运行，输出取平均。adapter_0 保持域语义先验，adapter_1 学习任务特定的适配信息。序列经 ESM2+ 双适配器编码后，与 GO 标签文本嵌入进行门控融合，最终输出功能预测概率。

图 4-1: MZSGO-DA 两阶段训练流程。第一阶段通过对比学习将域语义信息蒸馏至适配器；第二阶段冻结预训练适配器，引入新适配器进行端到端功能预测训练。

4.3.2 适配器模块与注入机制

本文设计了基于残差多层感知机（ResMLP）的轻量级适配器模块。每个适配器由降维线性层、ReLU 激活函数、升维线性层和层归一化组成，并通过残差连接保留原始信息流：

$$\text{Adapter}(\mathbf{x}) = \text{LN}(\mathbf{W}_{up} \cdot \text{ReLU}(\mathbf{W}_{down} \cdot \mathbf{x})) + \mathbf{x} \tag{4-1}$$

其中 $\mathbf{W}_{down} \in \mathbb{R}^{d_b \times d}$ 为降维矩阵，$\mathbf{W}_{up} \in \mathbb{R}^{d \times d_b}$ 为升维矩阵，$d = 1280$ 为 ESM2 的隐藏维度，$d_b = d/2 = 640$ 为瓶颈维度，LN 为层归一化。

与传统适配器设计[47] 不同，本文采用**纯净残差连接**策略，即残差加法在层归一化之外执行。这一设计借鉴了 S-PLM[37] 中适配器的架构经验，避免了层归一化包裹残差连接可能引发的梯度缩放问题，有助于在深层 Transformer 网络中保持稳定的梯度传播。

适配器注入机制。适配器模块被注入 ESM2 Transformer 层的两个关键位置：

（1）**自注意力输出之后**：在多头自注意力的输出（残差连接之前）插入适配器，使其能够调制注意力模式：

$$\mathbf{X}_{attn} = \mathrm{MHA}(\mathrm{LN}(\mathbf{X})) \tag{4-2}$$

$$\mathbf{X}'_{attn} = \mathrm{Adapter}_{attn}(\mathbf{X}_{attn}) \tag{4-3}$$

$$\mathbf{X}' = \mathbf{X} + \mathbf{X}'_{attn} \tag{4-4}$$

（2）**前馈网络输出之后**：在 FFN 的输出（残差连接之前）插入适配器，使其能够调制特征变换：

$$\mathbf{X}_{ffn} = \mathrm{FFN}(\mathrm{LN}(\mathbf{X}')) \tag{4-5}$$

$$\mathbf{X}'_{ffn} = \mathrm{Adapter}_{ffn}(\mathbf{X}_{ffn}) \tag{4-6}$$

$$\mathbf{X}'' = \mathbf{X}' + \mathbf{X}'_{ffn} \tag{4-7}$$

因此，每个 Transformer 层包含两个适配器实例（分别用于注意力子层和 FFN 子层），一组适配器共包含 $2N_{layer}$ 个 ResMLP 模块。

本文采用**运行时动态注入**策略：不修改 ESM2 的源代码，而是在模型加载后通过 Python 的动态属性替换机制，将原始的 TransformerLayer 替换为包含适配器的 AdapterTransformerLayer。该策略与 S-PLM[37] 中的适配器注入方式一致，使适配器模块以即插即用的方式与任何 ESM2 变体兼容。默认仅对 ESM2 最后 $N_{adapter} = 16$ 层（共 33 层）注入适配器，浅层保持原始参数不变以保留通用序列表示能力。

当存在多组适配器（如双适配器策略中的 $\mathrm{adapter}_0$ 和 $\mathrm{adapter}_1$）时，各组适配器在同一层内并行计算，输出通过均匀加权取平均：

$$\mathbf{X}_{adapter} = \frac{1}{G}\sum_{g=1}^{G} \mathrm{Adapter}^{(g)}(\mathbf{X}) \tag{4-8}$$

其中 G 为适配器组数（预训练时 $G = 1$，下游训练时 $G = 2$）。

4.3.3 域感知对比学习预训练

预训练阶段的目标是将蛋白质域的语义信息蒸馏至序列编码器的适配器参数中。

序列编码器。

将蛋白质序列 P 输入注入 $\mathrm{adapter}_0$ 的 ESM2 模型，获得每个残基位置的上下文嵌入，通过平均池化（排除填充位和特殊 token）获得蛋白质级表示：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0}(P)) \in \mathbb{R}^{1280} \tag{4-9}$$

域嵌入。

蛋白质域的文本嵌入 $\mathbf{h}_{dom} \in \mathbb{R}^{2560}$ 由 Qwen3-Embedding-4B 预计算并缓存，编码方式与第三章 MZSGO 相同。

投影头。

为将序列表示和域嵌入映射至共享的对比空间，设计两个独立的投影头：

$$\mathbf{z}_{seq} = \text{ProjHead}_{seq}(\mathbf{h}_{seq}) \in \mathbb{R}^{d_p} \tag{4-10}$$

$$\mathbf{z}_{dom} = \text{ProjHead}_{dom}(\mathbf{h}_{dom}) \in \mathbb{R}^{d_p} \tag{4-11}$$

其中 $d_p = 256$ 为投影维度。每个投影头由两层 MLP 组成：

$$\text{ProjHead}(\mathbf{x}) = \text{LN}(\mathbf{W}_2 \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_1 \cdot \mathbf{x})))) \tag{4-12}$$

中间隐藏维度为 512。输出向量经 L2 归一化后用于计算余弦相似度。

InfoNCE 对比损失。

给定一批 B 个蛋白质样本，每个样本 i 对应序列投影 $\mathbf{z}^i_{seq}$ 和域投影 $\mathbf{z}^i_{dom}$ 构成正样本对，同一批次中其他样本构成负样本对。采用双向 InfoNCE 损失进行优化：

$$\mathcal{L}_{seq\to dom} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}^i_{seq}, \mathbf{z}^i_{dom})/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}^i_{seq}, \mathbf{z}^j_{dom})/\tau)} \tag{4-13}$$

$$\mathcal{L}_{dom\to seq} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}^i_{dom}, \mathbf{z}^i_{seq})/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}^i_{dom}, \mathbf{z}^j_{seq})/\tau)} \tag{4-14}$$

$$\mathcal{L}_{CL} = \frac{1}{2}(\mathcal{L}_{seq\to dom} + \mathcal{L}_{dom\to seq}) \tag{4-15}$$

其中 $\text{sim}(\cdot,\cdot)$ 为余弦相似度，$\tau = 0.07$ 为温度超参数。

通过这种双向对比学习，adapter_0 被训练为能够将 ESM2 的序列表示调制至与域嵌入对齐的语义空间。预训练完成后，adapter_0 中的参数编码了将序列特征映射至域感知空间的变换，即使后续不提供域嵌入输入，ESM2+adapter_0 的输出也隐式地包含了域的功能语义信息。

4.3.4 双适配器端到端下游训练

预训练完成后，进入端到端的下游功能预测阶段。

双适配器策略。

冻结 adapter_0 的所有参数，将预训练学到的域语义先验” 锁定”。在 ESM2 的同一组 Transformer 层中注入第二组适配器 adapter_1，随机初始化其参数。adapter_1 为可训练状态，负责学习功能预测任务特定的适配信息。

与 S-PLM[37] 在预训练后仅使用单组适配器进行下游任务不同，MZSGO-DA 的双适配器策略具有以下优势：

（1）**知识保留**：adapter_0 冻结后，预训练阶段通过对比学习学到的域-序列对齐知识不会在下游训练中被覆盖或遗忘。

（2）**任务适配**：adapter_1 提供了额外的可学习参数，使模型能够在保持域先验的同时适应特定的功能预测目标。

（3）**稳定性**：两组适配器的输出取平均，相当于一种集成效应，有助于稳定训练和提升泛化能力。

端到端序列编码。

与 MZSGO 不同，MZSGO-DA 在下游训练时不使用预计算的静态嵌入，而是在每个训练迭代中实时运行 ESM2+ 双适配器前向传播。为节省显存，前向传播跳过 ESM2 的语言模型头（LM Head）和接触预测头（Contact Head），仅执行 Transformer 编码器部分：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0+adapter_1}(P)) \in \mathbb{R}^{1280} \tag{4-16}$$

特征投影与门控融合。

MZSGO-DA 的下游分类架构简化为双模态融合：序列特征和 GO 标签文本嵌入。由于域语义信息已通过 adapter_0 内化至序列表示中，推理时不再需要显式输入域嵌入。

序列特征和 GO 标签嵌入分别经过投影后，输入双模态门控融合模块（Gated-FusionModule2）。该模块与第三章的三模态版本类似，但仅处理两个输入：

$$\mathbf{h}'_{seq} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{seq}\mathbf{h}_{seq}))) \in \mathbb{R}^{512} \tag{4-17}$$

$$\mathbf{h}'_{label} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{label}\mathbf{E}_{label}))) \in \mathbb{R}^{512} \tag{4-18}$$

在训练阶段，同样对序列特征施加模态丢弃策略（丢弃率 $p = 0.15$），以增强模型对序列信息缺失场景下的鲁棒性。

门控融合模块计算自适应权重并生成融合表示：

$$\boldsymbol{\alpha} = \text{Softmax}(\mathbf{W}_{gate} \cdot \text{ReLU}(\text{LN}(\mathbf{W}_{ctx}[\hat{\mathbf{h}}'_{seq} \parallel \mathbf{h}'_{label}]))) \tag{4-19}$$

$$\mathbf{H}_{fused} = \alpha_1 \cdot \phi_{seq}(\hat{\mathbf{h}}'_{seq}) + \alpha_2 \cdot \phi_{label}(\mathbf{h}'_{label}) \tag{4-20}$$

其中 $\boldsymbol{\alpha} \in \mathbb{R}^2$ 为归一化的门控权重。

分类与损失函数。

融合表示经过分类 MLP 生成逻辑值：

$$\hat{y} = \sigma(\mathbf{W}_{out} \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{cls}\mathbf{H}_{fused})))) \tag{4-21}$$

其中分类头将 512 维融合特征压缩至 256 维，再投影至 1 维输出。

下游训练使用二分类交叉熵损失（BCEWithLogitsLoss）：

$$\mathcal{L}_{task} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)] \tag{4-22}$$

下游阶段的可训练参数包括：adapter_1 的所有参数、特征投影层、门控融合模块和分类头。ESM2 的原始参数和 adapter_0 均保持冻结。

4.4 实验结果及分析

4.4.1 对比实验结果与分析

为保证比较结果的可复现性与公平性，本节先介绍数据集、实现细节、基线方法和评价指标，随后对 MZSGO-DA 与 MZSGO 的性能差异进行系统分析。

数据集。

MZSGO-DA 使用与第三章 MZSGO 相同的数据集，包括基于 CAFA5 和 Swiss-Prot 的训练集、标准测试集，以及通过时间演进方式构建的零样本测试集。数据集统计信息详见第三章表 3-1和表 3-2。

实现细节。

预训练阶段。

对比学习预训练基于 PyTorch[51] 分布式数据并行（DDP）框架实现，使用 6 块 NVIDIA GPU 进行训练。ESM2 选用 esm2_t33_650M_UR50D 变体（33 层 Transformer，隐藏维度 1280）。适配器注入最后 16 层，瓶颈维度 640。使用 AdamW[55] 优化器，学习率 1×10^{-4}，权重衰减 1×10^{-4}。训练采用余弦退火学习率调度，预热比例 0.1。每张 GPU 的批次大小为 8，梯度累积步数为 2，有效批次大小为 96。训练最多 50 个 epoch，使用早停策略（耐心值 5）防止过拟合。训练过程使用 FP16 混合精度加速，梯度裁剪阈值为 1.0。温度超参数 $\tau = 0.07$。

下游训练阶段。

下游训练同样采用 DDP 框架和 6 块 GPU。加载预训练的 adapter_0 参数并冻结，初始化 adapter_1 并设为可训练。每张 GPU 的批次大小为 4（由于端到端前向传播 ESM2 需要更多显存），梯度累积步数为 4，有效批次大小仍为 96。学习率 1×10^{-4}，隐藏维度 512，分类 Dropout 率 0.3，特征丢弃率 0.15。训练 30 个 epoch，同样使用早停策略。

基线方法。

除了第三章中列出的十种基线方法外，本章额外引入 MZSGO 作为直接对比基线，以评估端到端训练相对于静态嵌入方法的增益。同时将不使用预训练的单适配器端到端方法作为消融基线，记为 MZSGO-DA (w/o pretrain)。

评价指标。

评价指标与第三章一致，包括有监督指标 $F_{\max}$ 和 AUPR，零样本指标 Unseen AUPR 和 Seen AUPR，以及综合评价指标调和均值 H。

与 MZSGO 的性能对比。

表 4-1展示了 MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。

表 4-1: MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。Δ 表示 MZSGO-DA 相对于 MZSGO 的绝对提升。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
BP	MZSGO-DA	**0.5103**	**0.5076**	**0.2517**	**0.5092**	**0.3366**
	Δ	+0.0058	+0.0068	+0.0124	+0.0071	+0.0125
	MZSGO	0.7611	0.7337	0.4806	0.7380	0.5821
MF	MZSGO-DA	**0.7682**	**0.7421**	**0.4963**	**0.7460**	**0.5957**
	Δ	+0.0071	+0.0084	+0.0157	+0.0080	+0.0136
	MZSGO	0.7470	0.7726	0.5862	0.7733	0.6669
CC	MZSGO-DA	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**
	Δ	+0.0066	+0.0077	+0.0179	+0.0077	+0.0146

从实验结果可以观察到：

（1）**全面的性能提升**。MZSGO-DA 在三个 GO 本体的所有指标上均优于 MZSGO，验证了端到端训练策略和域感知适配器预训练的有效性。

（2）**零样本指标提升尤为显著**。在 Unseen AUPR 上，MZSGO-DA 在 BP、MF

和 CC 本体上分别获得 +0.0124、+0.0157 和 +0.0179 的提升，且调和均值 H 的提升幅度（+0.0125 至 +0.0146）一致超过有监督指标（Fmax 提升 +0.0058 至 +0.0071）。这表明域感知预训练通过将域语义信息内化至序列编码器，增强了模型对未见标签的泛化能力。

（3）**端到端训练的梯度优势**。MZSGO-DA 的有监督指标也获得了稳定提升，说明端到端训练使序列编码器能够根据功能预测目标进行微调，产出更具区分性的表示。

4.4.2 消融实验结果与分析

为分析 MZSGO-DA 各组件的贡献，本文在 CC 本体上进行了系统的消融实验，结果如表 4-2所示。

表 4-2: MZSGO-DA 在 CC 本体上的消融实验结果。

变体	Fmax	AUPR	Unseen AUPR	Seen AUPR	H
预训练策略消融					
无预训练（随机初始化 adapter_1）	0.7421	0.7654	0.5713	0.7662	0.6561
单 adapter 端到端（无 adapter_0）	0.7448	0.7689	0.5790	0.7698	0.6620
适配器策略消融					
adapter_0 不冻结（双 adapter 均可训练）	0.7502	0.7715	0.5684	0.7721	0.6568
仅 adapter_0（冻结，无 adapter_1）	0.7382	0.7598	0.5923	0.7604	0.6667
注入层数消融					
注入最后 8 层	0.7478	0.7735	0.5862	0.7742	0.6675
注入最后 24 层	0.7510	0.7768	0.5944	0.7774	0.6745
注入全部 33 层	0.7493	0.7751	0.5901	0.7758	0.6710
MZSGO-DA（注入最后 16 层）	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**

消融结果支持以下结论：

（1）**预训练的重要性**。去除预训练后（随机初始化 adapter_1 直接端到端训练），H 从 0.6815 降至 0.6561，降幅达 0.0254。即使使用单 adapter 端到端训练也仅获得 0.6620 的 H 值，均显著低于完整的 MZSGO-DA，证实域感知对比学习预训练为下游任务提供了重要的初始化先验。

（2）**冻结 adapter_0 的必要性**。当 adapter_0 不冻结而是与 adapter_1 联合训练时，有监督指标 Fmax 反而提升至 0.7502，但 Unseen AUPR 下降至 0.5684，H 降至 0.6568。这说明联合训练虽然增加了模型容量，但会导致预训练域知识被下游梯度覆盖，损害零样本泛化能力。冻结 adapter_0 有效保护了预训练知识。

（3）**双适配器的协同效应**。仅使用冻结的 $adapter_0$（不引入 $adapter_1$）进行端到端预测，虽然 Unseen AUPR 较高（0.5923），但 Fmax（0.7382）和总体 AUPR（0.7598）均明显下降。这是因为冻结的 $adapter_0$ 仅学到了域-序列对齐的知识，缺乏功能预测任务的适配能力。双适配器策略通过 $adapter_1$ 提供了任务适配的灵活性，实现了域先验与任务目标的最优平衡。

（4）**注入层数的影响**。从 8 层增加到 16 层带来了显著的性能提升（H 从 0.6675 升至 0.6815），继续增加到 24 层或 33 层反而导致轻微下降。这表明浅层 Transformer 编码了通用的氨基酸表示模式，注入适配器可能干扰这些底层特征；而中高层对功能信息的编码更为敏感，适配器注入能带来最大收益。16 层是表征能力与训练稳定性之间的最优折中。

4.4.3 预训练过程分析

为深入理解对比学习预训练的效果，本文监控了训练过程中正样本对相似度、负样本对相似度和相似度间隔（similarity gap）的变化。

随着训练的推进，正样本对（同一蛋白质的序列表示与域嵌入）的余弦相似度从初始的约 0.1 稳步上升至 0.7 以上，而负样本对（不同蛋白质的序列-域配对）的相似度维持在 0.05 以下。相似度间隔（正样本相似度减去负样本相似度均值）从约 0.05 增长至 0.65 以上，表明适配器成功地将序列表示调制至与域嵌入高度对齐的空间。

训练损失在约 15 个 epoch 后趋于收敛，早停机制在第 20 至 25 个 epoch 附近触发。过长的预训练可能导致过拟合至训练集中的蛋白质-域对应关系，早停策略有效防止了这一问题。

4.4.4 参数效率分析

表 4-3展示了 MZSGO-DA 中各组件的参数量统计。

MZSGO-DA 的可训练参数仅占总参数的 7.3%，远低于全参数微调方案。这种参数高效的设计不仅降低了训练的计算和存储开销，还通过保持 ESM2 原始参数冻结有效防止了灾难性遗忘，确保蛋白质语言模型在通用序列建模方面的能力不受损害。

4.5 本章小结

本章提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法受 S-PLM[37] 利用对比学习在适配器中蒸馏结构信息的启发，将蒸馏

表 4-3: MZSGO-DA 参数量统计。

组件	参数量	状态
ESM2 原始参数	~650M	冻结
adapter_0（16 层 ×2 个）	~53M	冻结
adapter_1（16 层 ×2 个）	~53M	可训练
特征投影与分类头	~2M	可训练
总计	~758M	—
可训练参数	~55M	7.3%

目标从三维结构信息拓展至蛋白质域的功能语义信息，其核心创新体现在三个方面：

（1）**域感知对比学习预训练**。通过 InfoNCE 对比学习将蛋白质域的语义信息蒸馏至 ESM2 内部的轻量级适配器模块，使序列编码器在不需要显式域输入的情况下即可产出携带域语义先验的增强表示。

（2）**双适配器端到端训练策略**。冻结预训练的 adapter_0 以保留域知识，引入可训练的 adapter_1 进行任务适配。两组适配器在 Transformer 层内并行运行，实现了预训练知识保留与下游任务适配的有效平衡。

（3）**端到端梯度通路**。打破了 MZSGO 中静态嵌入方法的梯度断裂问题，使下游损失信号能够回传至序列编码器，实现了从序列输入到功能预测的完整优化。

实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，验证了域感知适配器预训练和端到端训练策略的有效性。消融实验进一步证实了预训练、冻结策略和双适配器设计各自的必要性。MZSGO-DA 以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配，为蛋白质功能预测领域的预训练-微调范式提供了新的技术方案。

结 论

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，而经实验验证的功能注释比例极低，自动化功能预测方法的需求日益迫切。现有的深度学习方法通常将基因本体功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，限制了模型对未见标签的泛化能力。本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，本文提出了多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码。设计了自适应门控融合模块实现逐样本动态的多模态特征整合，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下以压倒性优势超越所有现有方法。特别是在 CC 本体上，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍，验证了多模态语义融合范式在零样本蛋白质功能预测中的有效性。

其次，本文提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法针对 MZSGO 中静态嵌入策略的信息瓶颈和梯度断裂问题，设计了轻量级适配器模块注入蛋白质语言模型的 Transformer 层内部，通过 InfoNCE 对比学习预训练将蛋白质域的语义信息蒸馏至序列编码器。在下游阶段，采用双适配器策略——冻结预训练适配器保留域知识，引入新适配器进行任务适配——实现端到端训练。实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配。

本文的主要贡献可以归纳为：（1）通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；（2）通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器。

尽管本文方法取得了显著的进展，但仍存在一些局限性和进一步改进的空间：

第一，**融入三维结构信息**。本文目前仅利用了序列和域文本两种模态。虽然 MZSGO 成功整合了序列与文本域信息，但蛋白质的三维空间排列仍然是决定功

能的关键因素。未来计划将 AlphaFold2 预测的结构特征纳入本文的多模态框架中，通过融合三维结构坐标与现有的序列-文本对齐，捕获那些在结构上保守但序列上存在差异的功能基序，从而进一步提升预测精度。

第二，**增强语义推理能力**。现有的 MZSGO 方法主要依赖 GO 术语的文本描述来实现零样本推理，但忽略了 GO 本体的结构丰富性。由于 GO 被组织为包含深层逻辑依赖关系的有向无环图（DAG），未来工作将聚焦于将这些基于图的拓扑约束与 LLM 派生的语义嵌入进行融合。本文预期融合显式的逻辑结构与隐式的语义细微信息将产生更具生物学一致性的标签空间，最终提升模型在复杂功能层级中的导航能力。

第三，本文使用预计算的静态域嵌入和 GO 标签嵌入，而非端到端地训练大语言模型编码器。虽然这在当前硬件条件下是务实的选择，但未来随着计算资源的提升，联合训练蛋白质语言模型和文本编码器可能带来更深层次的跨模态对齐。

第四，本文的零样本评估虽然采用了严格的时间演进策略和序列同源性过滤，但零样本测试集的规模仍然有限，特别是 CC 本体仅有 17 个零样本测试蛋白质。未来需要在更大规模的零样本基准上验证方法的泛化能力。

第五，MZSGO-DA 的端到端训练虽然提升了性能，但显著增加了训练时间和显存消耗。探索更高效的参数高效微调策略（如 LoRA、Prefix Tuning 等）以进一步降低计算开销，是有价值的未来方向。

展望未来，蛋白质功能预测领域可能沿以下方向发展：一是构建更大规模的预训练数据集和更强大的蛋白质基础模型，为下游功能预测提供更丰富的表征；二是探索蛋白质功能预测与蛋白质设计的联合优化，实现从”理解功能”到”设计功能”的跨越；三是将零样本功能预测能力与基因组学、转录组学等多组学数据相结合，为系统生物学研究提供更全面的功能注释工具。

参考文献

[1] EISENBERG D，MARCOTTE E M，XENARIOS I，et al. Protein function in the post-genomic era [J]. Nature，2000，405（6788）：823-826.

[2] JUMPER J，EVANS R，PRITZEL A，et al. Highly accurate protein structure prediction with AlphaFold [J]. nature，2021，596（7873）：583-589.

[3] FRIEDBERG I. Automated protein function prediction—the genomic challenge [J]. Briefings in bioinformatics，2006，7（3）：225-242.

[4] LIN J，XU Z，LU R，et al. A comprehensive review and comparison of existing computational methods for protein function prediction [J]. Briefings in Bioinformatics，2024，25（4）：bbae289.

[5] ASHBURNER M，BALL C A，BLAKE J A，et al. Gene ontology: tool for the unification of biology [J]. Nature genetics，2000，25（1）：25-29.

[6] ZHOU N，JIANG Y，BERGQUIST T R，et al. The CAFA challenge reports improved protein function prediction and new functional annotations for hundreds of genes through experimental screens [J]. Genome biology，2019，20（1）：244.

[7] ALTSCHUL S F，GISH W，MILLER W，et al. Basic local alignment search tool [J]. Journal of molecular biology，1990，215（3）：403-410.

[8] KULMANOV M，KHAN M A，HOEHNDORF R. DeepGO: predicting protein functions from sequence and interactions using a deep ontology-aware classifier [J]. Bioinformatics，2018，34（4）：660-668.

[9] YOU R，HUANG X，ZHU S. DeepText2GO: improving large-scale protein function prediction with deep semantic text representation [J]. Methods，2018，145：82-90.

[10] KULMANOV M，HOEHNDORF R. DeepGOPlus: improved protein function prediction from sequence [J]. Bioinformatics，2020，36（2）：422-429.

[11] VARADI M，ANYANGO S，DESHPANDE M，et al. AlphaFold Protein Structure Database: massively expanding the structural coverage of protein-sequence space with high-accuracy models [J]. Nucleic acids research，2022，50（D1）：D419-D427.

[12] GLIGORIJEVIĆ V, RENFREW P D, KOSCIOLEK T, et al. Structure-based protein function prediction using graph convolutional networks [J]. Nature communications, 2021, 12 (1): 3168.

[13] BUCHFINK B, REUTER K, DROST H-G. Sensitive protein alignments at tree-of-life scale using DIAMOND [J]. Nature methods, 2021, 18 (4): 366-368.

[14] YOU R, YAO S, MAMITSUKA H, et al. DeepGraphGO: graph neural network for large-scale, multispecies protein function prediction [J]. Bioinformatics, 2021, 37 (Supplement_1): i262-i271.

[15] JONES P, BINNS D, CHANG H-Y, et al. InterProScan 5: genome-scale protein function classification [J]. Bioinformatics, 2014, 30 (9): 1236-1240.

[16] GU Z, LUO X, CHEN J, et al. Hierarchical graph transformer with contrastive learning for protein function prediction [J]. Bioinformatics, 2023, 39 (7): btad410.

[17] JIAO P, WANG B, WANG X, et al. Struct2GO: protein function prediction based on graph pooling algorithm and AlphaFold2 structure information [J]. Bioinformatics, 2023, 39 (10): btad637.

[18] GROVER A, LESKOVEC J. node2vec: Scalable feature learning for networks [C] // Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining, 2016: 855-864.

[19] WU Z, GUO M, CHEN X-Y, et al. Hi-FUN: hierarchical fine-grained unified network for protein function prediction [J]. Briefings in Bioinformatics, 2023, 24 (6): bbad420.

[20] LI W, WANG B, DAI J, et al. Partial order relation–based gene ontology embedding improves protein function prediction [J]. Briefings in Bioinformatics, 2024, 25 (2): bbae077.

[21] WANG B, GENG Y, CHENG X, et al. ProtGO: universal protein function prediction utilizing multi-modal gene ontology knowledge [J]. Bioinformatics, 2025, 41 (7): btaf390.

[22] WANG W, SHUAI Y, ZENG M, et al. DPFunc: accurately predicting protein function via deep learning with domain-guided structure information [J]. Nature communications, 2025, 16 (1): 70.

[23] KULMANOV M, HOEHNDORF R. DeepGOZero: improving protein function prediction from sequence and zero-shot learning based on ontology axioms [J]. Bioinformatics, 2022, 38 (Supplement_1): i238-i245.

[24] KULMANOV M，HOEHNDORF R. Embeddings from protein language models predict conservation and variant effects [J]. Human Genetics，2019，141：1629-1647.

[25] KULMANOV M，GUZMÁN-VEGA F J，DUEK ROGGLI P，et al. Protein function prediction as approximate semantic entailment [J]. Nature Machine Intelligence，2024，6（2）：220-228.

[26] CHAR S，CORLEY N，ALAMDARI S，et al. ProtNote: a multimodal method for protein–function annotation [J]. Bioinformatics，2025，41（5）：btaf170.

[27] BOADU F，WANG Y，CHENG J. A unified multimodal model for generalizable zero-shot and supervised protein function prediction [J]. bioRxiv，2025：2025-05.

[28] LIN Z，AKIN H，RAO R，et al. Evolutionary-scale prediction of atomic-level protein structure with a language model [J]. Science，2023，379（6637）：1123-1130.

[29] ZHANG N，BI Z，LIANG X，et al. OntoProtein: Protein pretraining with gene ontology embedding [J]. arXiv preprint arXiv:2201.11147，2022.

[30] XU M，YUAN X，MIRET S，et al. ProtST: Multi-modality learning of protein sequences and biomedical texts [J]. arXiv preprint arXiv:2301.12040，2023.

[31] WU Z，GUO M，JIN J，et al. CFAGO: cross-fusion of network and attributes based on attention mechanism for protein function prediction [J]. Bioinformatics，2023，39（3）：btad123.

[32] HU M-L，YUAN F，YANG K K，et al. Protein language models and structure prediction: connections and progressions [J]. arXiv preprint arXiv:2211.16742，2023.

[33] DUAN J，CAI Z，REN J，et al. PAIR: Protein-Aligned Instruction-Response for Large Language Model Based Protein Function Reasoning [J]. arXiv preprint arXiv:2502.12281，2025.

[34] ABDINE H，CHABÉ-FERRET M，SALMA K，et al. Prot2Text: Multimodal protein's function generation with GNNs and transformers [J]. Proceedings of the AAAI Conference on Artificial Intelligence，2024，38（10）：10757-10765.

[35] XIANG W，XIONG Z，CHEN H，et al. FAPM: Functional Annotation of Proteins using Multi-Modal Models Beyond Structural Modeling [J]. bioRxiv，2024：2024-05.

[36] FEI Z，ABDINE H，CHATELAIN C. Prot2Text-V2: Leveraging large language models for protein function prediction [J]. arXiv preprint arXiv:2504.10362，2025.

[37] WANG D，POURJAFARI D，YI F，et al. S-PLM: Structure-aware protein language model via contrastive learning between sequence and structure [J]. Bioinformatics，2025，41（3）：btaf105.

[38] GOEMAN J J，MANSMANN U. Multiple testing on the directed acyclic graph of gene ontology [J]. Bioinformatics，2008，24（4）：537-544.

[39] VASWANI A，SHAZEER N，PARMAR N，et al. Attention is all you need [J]. Advances in neural information processing systems，2017，30.

[40] BA J L，KIROS J R，HINTON G E. Layer normalization [J]. arXiv preprint arXiv:1607.06450，2016.

[41] HENDRYCKS D. Gaussian Error Linear Units (Gelus) [J]. arXiv preprint arXiv:1606.08415，2016.

[42] ZHANG Y，LI M，LONG D，et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models [J]. arXiv preprint arXiv:2506.05176，2025.

[43] BLUM M，ANDREEVA A，FLORENTINO L C，et al. InterPro: the protein sequence classification resource in 2025 [J]. Nucleic acids research，2025，53（D1）：D444-D456.

[44] CHEN T，KORNBLITH S，NOROUZI M，et al. A simple framework for contrastive learning of visual representations [C] //International conference on machine learning，2020：1597-1607.

[45] OORD A V D，LI Y，VINYALS O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748，2018.

[46] HINTON G，VINYALS O，DEAN J. Distilling the knowledge in a neural network [J]. arXiv preprint arXiv:1503.02531，2015.

[47] HOULSBY N，GIBER A，JASTRZEBSKI S，et al. Parameter-efficient transfer learning for NLP [C] //International conference on machine learning，2019：2790-2799.

[48] BOUTET E，LIEBERHERR D，TOGNOLLI M，et al. UniProtKB/Swiss-Prot: the manually annotated section of the UniProt KnowledgeBase [G] //Plant bioinformatics: methods and protocols. Springer，2007：89-112.

[49] HOANG M, SINGH M. Locality-aware pooling enhances protein language model performance across varied applications [J]. Bioinformatics, 2025, 41 (Supplement_1): i217-i226.

[50] CUI Y, JIA M, LIN T-Y, et al. Class-balanced loss based on effective number of samples [C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 9268-9277.

[51] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library [J]. Advances in neural information processing systems, 2019, 32.

[52] KINGMA D P. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980, 2014.

[53] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting [J]. The journal of machine learning research, 2014, 15 (1): 1929-1958.

[54] NOTARO M, FRASCA M, PETRINI A, et al. HEMDAG: a family of modular and scalable hierarchical ensemble methods to improve Gene Ontology term prediction [J]. Bioinformatics, 2021, 37 (23): 4526-4533.

[55] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization [C] // International conference on learning representations, 2019.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

Boyue Cui, Beibei Wang, Xuan Wang, Junyi Li. ”MZSGO: Multimodal Zero-Shot Gene Ontology Annotation via Evolutionary Signals and Textual Semantics” 期刊 Bioinformatics (Oxford University Press) 在投。

（二）申请及已获得的专利

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于多模态预训练的蛋白质功能预测研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

时光荏苒，转眼间两年半的硕士研究生生涯已近尾声。在完成毕业论文之际，百感交集。回望来路，深知今日之成果绝非一人之力所能及——正是众多师长、亲友的无私支持与倾心相助，才让我得以坚定前行、顺利完成学业。在此，谨以最诚挚的心意，向所有曾给予我关怀与帮助的人致以深深的谢意。

首先，谨向我的导师李君一老师致以最诚挚的感谢。在攻读硕士学位期间，您不仅在学术研究上给予我系统而深入的指导，更在科研方法和学术写作方面耐心地培养了我的逻辑思维能力和独立研究能力。在论文选题、实验设计和论文撰写的每一个阶段，您始终认真细致地审阅我的工作，提出了大量富有针对性的建议和改进意见，使我能够不断完善研究方案并提升论文质量。您的严谨治学态度与无私付出令我受益匪浅。此外，在日常学习与生活中，您也给予我们充分的关怀与支持，为我顺利完成学业提供了重要保障。

其次，我要感谢我的同门。在科研探索的过程中，我们相互交流、共同进步，面对研究中的困难与挑战，彼此分享思路与经验。特别感谢师姐王贝贝在蛋白质功能预测领域的宝贵指导和经验分享，为我的研究工作提供了重要参考。与同门们共同讨论课题，使我在学术视野与研究能力上均受益良多，每一次交流都对我的研究工作产生了积极而深远的影响。

随后，我要特别感谢我的家人。在攻读硕士学位的这几年中，面对学业与科研带来的压力，是你们始终如一的理解、包容与鼓励，给予我坚持前行的力量。每一次电话中的关怀、每一次回家时温暖的陪伴，都让我深切感受到无言却深厚的爱与支持。正是你们在背后的默默付出，成为我顺利完成学业的重要支撑。

同时，我也衷心感谢我的朋友们。在求学与科研的过程中，你们的陪伴、理解与鼓励，为这段紧张而充实的时光增添了温度。无论是低谷时的倾听，还是前行中的相互支持，你们都让我在忙碌与压力之中保持信心与动力。

最后，我要衷心感谢哈尔滨工业大学。四年在哈尔滨本部、两年在深圳校区的学习经历，使我在学术视野与专业能力上都得到了系统而全面的培养。从专业课程的科学设置，使我得以扎实而深入地掌握相关理论与方法。学院的每一位老师都治学严谨、认真负责，其言传身教不仅传授了专业知识与研究方法，也深刻塑造了我严谨求实的学术态度。感谢学校和学院多年来的悉心培养，未来我将秉持在此形成的治学精神，继续努力，在各自岗位上践行哈工大的校训与精神。

衷心感谢老师的悉心教诲、同学的并肩前行、朋友的温暖陪伴以及家人的坚

定支持，使我得以顺利走过这段研究生时光。未来，我将带着这份感激与收获，继续前行。