硕士学位论文

（专业学位论文）

基于多模态预训练的蛋白质功能预测研究

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

崔博越

哈尔滨工业大学

2026 年 5 月

国内图书分类号：TP391　　学校代码：10213
国际图书分类号：68T07　　密级：公开

硕士学位论文

基于多模态预训练的蛋白质功能预测研究

硕士研究生：崔博越

导　　师：李君一教授

申请学位：专业硕士

类　　别：计算机技术

所在单位：哈尔滨工业大学（深圳）

答辩日期：2026 年 05 月

授予学位单位：哈尔滨工业大学

Classified Index: TP391
U.D.C: 68T07

Dissertation for the Master Degree

RESEARCH ON PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL PRETRAINING

Candidate: Boyue Cui
Supervisor: Prof. Junyi Li
Academic Degree Applied for: Master of Engineering
Specialty: Computer Technology
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: May, 2026
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，然而经实验验证的功能注释比例极低，序列-功能鸿沟日益加深。现有的深度学习方法通常仅依赖序列模式特征，将蛋白质域信息和基因本体（Gene Ontology, GO）功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，从而限制了模型对未见标签的泛化能力。针对上述问题，本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，提出多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码，通过三路特征投影将异构表示映射至共享语义空间。设计了自适应门控融合模块动态调节各模态贡献权重，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在标准测试集上的有监督指标达到最优水平，尤其在零样本场景下显著超越现有方法。

其次，为进一步提升序列表征的功能感知能力，提出基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法设计了轻量级适配器模块，以即插即用方式注入蛋白质语言模型的 Transformer 层内部；通过对比学习预训练，将蛋白质域的语义信息蒸馏至序列编码器，使模型仅凭序列输入即可产出携带域信息的嵌入表示。在下游阶段，采用双适配器策略实现端到端训练，兼顾预训练知识保留与任务特定适配。实验结果表明，MZSGO-DA 在端到端场景下进一步提升了功能预测性能。

本文的创新性体现在：一方面，通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；另一方面，通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器，提升了模型的表征能力与泛化性能。

关键词：蛋白质功能预测；零样本学习；多模态融合；蛋白质语言模型；基因本体

Abstract

Protein function prediction is a fundamental task in bioinformatics. With the rapid advancement of high-throughput sequencing technologies, protein sequence data has grown exponentially, yet the proportion of experimentally validated functional annotations remains extremely low, deepening the sequence-function gap. Existing deep learning methods typically rely solely on sequence pattern features, treating protein domain information and Gene Ontology (GO) functional labels as simple categorical identifiers while neglecting the rich semantic information embedded in their textual definitions. This limits model generalization to unseen labels. To address these challenges, this thesis investigates two complementary directions—multimodal semantic fusion and pretrained domain-aware adaptation—and proposes two progressively advanced protein function prediction frameworks.

First, we propose MZSGO, a Multimodal Zero-Shot protein function annotation method. MZSGO redefines protein function prediction as a protein-GO matching problem. It employs the protein language model ESM2 to extract evolutionary sequence features and utilizes the large language model Qwen3-Embedding as a unified semantic encoder for both protein domain descriptions and GO functional definitions. Three independent projection modules map these heterogeneous representations into a shared latent space. An adaptive gated fusion module dynamically adjusts the contribution weights of each modality, while an asymmetric feature dropout strategy enhances robustness against modality absence. Experiments demonstrate that MZSGO achieves state-of-the-art performance on standard benchmarks, with particularly significant improvements in zero-shot scenarios.

Second, to further enhance the functional awareness of sequence representations, we propose MZSGO-DA, a Domain-Aware adapter pretraining approach for end-to-end protein function prediction. This method designs lightweight adapter modules that are injected directly into the Transformer layers of the protein language model in a plug-and-play manner. Through contrastive learning pretraining, domain semantic information is distilled into the sequence encoder, enabling the model to produce domain-aware embeddings from sequence input alone. In the downstream stage, a dual-adapter strategy supports end-to-end training while preserving pretrained knowledge and enabling task-specific adaptation. Experimental results show that MZSGO-DA further improves prediction performance in the end-to-end setting.

The main contributions of this thesis are twofold: on one hand, by introducing large language models to construct a unified semantic space for domains and labels, we achieve a paradigm shift from closed-set to open-set protein function prediction, endowing the model with zero-shot reasoning capabilities; on the other hand, through domain-aware contrastive pretraining and a dual-adapter end-to-end training mechanism, we efficiently inject multimodal knowledge into the sequence encoder without modifying the original protein language model parameters, enhancing both representational capacity and generalization performance.

Keywords: protein function prediction, zero-shot learning, multimodal fusion, protein language model, Gene Ontology

目 录

摘 要 I
ABSTRACT II
第 1 章 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 基于蛋白质序列的功能预测方法 2
1.2.2 基于蛋白质结构的功能预测方法 3
1.2.3 基于多模态信息融合的功能预测方法 3
1.2.4 蛋白质表示学习中的预训练方法 3
1.2.5 现有研究的不足与本文的出发点 4
1.3 论文主要工作与创新点 5
1.4 论文组织结构 5
第 2 章 相关工作与技术基础 7
2.1 基因本体系统 7
2.2 蛋白质语言模型 8
2.2.1 ESM-2 模型 8
2.2.2 适配器技术 8
2.3 大语言模型文本嵌入 9
2.3.1 Qwen3-Embedding 模型 9
2.3.2 蛋白质域的语义编码 10
2.4 多标签分类与损失函数 10
2.4.1 二分类交叉熵损失 10
2.4.2 Focal Loss 10
2.5 Transformer 架构与注意力机制 11
2.5.1 自注意力机制 11
2.5.2 多头注意力机制 11
2.5.3 Transformer 层结构 12
2.6 对比学习 12
2.6.1 InfoNCE 损失函数 12
2.6.2 投影头设计 12

2.7 评价指标 13
2.7.1 蛋白质中心评价指标 13
2.7.2 零样本评价指标 13
2.8 本章小结 14
第 3 章 多模态零样本蛋白质功能注释方法 MZSGO 15
3.1 问题定义 15
3.2 数据集构建 15
3.2.1 有监督训练集构建 15
3.2.2 零样本测试集构建 16
3.2.3 数据集统计 16
3.3 MZSGO 方法设计 17
3.3.1 总体框架 17
3.3.2 多模态特征编码 17
3.3.3 特征投影与模态特异性丢弃 19
3.3.4 自适应门控融合机制 21
3.3.5 优化目标 21
3.4 实验设置 22
3.4.1 实现细节 22
3.4.2 基线方法 23
3.4.3 评价指标 23
3.5 实验结果与分析 25
3.5.1 标准测试集上的性能对比 25
3.5.2 纯零样本测试集上的评估 27
3.5.3 消融实验 28
3.5.4 参数敏感性分析 33
3.5.5 嵌入空间可视化分析 33
3.5.6 自适应门控权重分析 34
3.5.7 加权评价指标实验 35
3.5.8 层级一致性与 True Path Rule 分析 36
3.6 本章小结 37

第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA 39
4.1 动机分析 39
4.2 MZSGO-DA 方法设计 40
4.2.1 总体框架 40
4.2.2 适配器模块设计 41
4.2.3 适配器注入机制 41
4.2.4 域感知对比学习预训练 42
4.2.5 双适配器端到端下游训练 43
4.3 实验设置 45
4.3.1 数据集 45
4.3.2 实现细节 45
4.3.3 基线方法 45
4.3.4 评价指标 46
4.4 实验结果与分析 46
4.4.1 与 MZSGO 的性能对比 46
4.4.2 消融实验 47
4.4.3 预训练过程分析 48
4.4.4 参数效率分析 48
4.5 本章小结 48
结 论 50
参考文献 52
攻读硕士学位期间取得创新性成果 55
哈尔滨工业大学学位论文原创性声明和使用权限 56
致 谢 57

第 1 章 绪论

1.1 研究背景与意义

蛋白质是生命活动的主要承担者，在信号传导、物质运输、免疫防御、基因表达调控等几乎所有生物学过程中发挥着核心作用[1]。要深入理解生物系统在分子尺度上的行为机制，就必须阐明蛋白质的功能。蛋白质功能预测不仅对基础生物学研究具有重要的科学价值，也在药物靶点发现、酶工程、合成生物学等应用领域具有广阔的前景。

国际生物信息学界通常采用基因本体（Gene Ontology, GO）系统[2]对蛋白质功能进行标准化描述。GO 系统将蛋白质功能划分为三大本体论：生物过程（Biological Process, BP）、分子功能（Molecular Function, MF）和细胞组分（Cellular Component, CC），并以有向无环图（Directed Acyclic Graph, DAG）的形式组织数千个功能术语之间的层级关系[3]。在这种结构中，子节点功能是父节点功能的具体化，使得功能描述既具有高度的规范性，也蕴含着丰富的语义层级信息。

然而，随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，序列数据与功能注释之间的鸿沟日益加深。截至目前，UniProt/Swiss-Prot 数据库[4]中收录的蛋白质中，经过实验验证获得功能注释的比例不到 1%。这一巨大的缺口促使研究者开发自动化蛋白质功能预测（Automated Function Prediction, AFP）方法[5]，以计算手段大规模地为未注释蛋白质分配 GO 功能标签。

早期的自动功能预测方法主要基于”功能关联”原则，即序列相似的蛋白质通常具有相似的功能。BLAST[6]和 Diamond[7]等序列比对工具通过在已知功能蛋白质中寻找同源序列来传递功能注释。这类方法在处理具有高度序列相似性的蛋白质时表现良好，但对于缺乏近缘同源序列的蛋白质，预测准确度急剧下降。近年来，深度学习技术的兴起为蛋白质功能预测带来了新的突破。基于卷积神经网络的 DeepGOPlus[8]能够直接从序列中提取局部模式特征。随着 AlphaFold2[9]在蛋白质结构预测方面取得里程碑式的成功，Struct2GO[10]等方法进一步利用三维结构信息来增强功能预测的精度。

尽管取得了显著的进步，现有方法仍面临两大核心挑战：

第一，**模态融合不充分**。多数方法仅利用蛋白质序列或结构的单一模态，或者仅将多种模态进行简单拼接，未能充分挖掘蛋白质序列进化信号、蛋白质域功能描述、GO 标签语义定义等不同模态之间的深层互补关系。蛋白质域（domain）是蛋白质中独立折叠和行使功能的结构单元，InterPro 数据库[11]中超过 80% 的蛋白

质具有域注释信息，其文本描述蕴含着丰富的功能线索，但现有方法大多将其视为简单的分类标签，忽略了其文本语义。

第二，**零样本泛化能力不足**。传统的功能预测方法将每个 GO 标签视为独立的分类标识符（即 one-hot 编码），模型的预测能力被限制在训练集中出现过的标签范围内。然而，GO 本体处于持续更新之中，每年都有新的功能术语被添加。对于训练集中从未出现的新功能标签，传统模型无法给出有效预测。虽然 DeepGOZero[12] 尝试利用 GO 本体的逻辑公理实现零样本预测，但其效果受限于本体公理的覆盖范围。

针对上述两大挑战，本文的核心思路是：利用大语言模型（Large Language Model, LLM）对蛋白质域描述和 GO 功能定义进行统一的语义编码，将蛋白质功能预测从传统的封闭标签集多标签分类问题，重新定义为开放语义空间中的”蛋白质-功能”匹配问题。这一范式转换使得模型能够通过文本语义相似性推断未见过的功能标签，从根本上赋予模型零样本推理的能力。在此基础上，本文围绕多模态语义融合与预训练域感知适配两个方向展开研究，提出了两个递进式的蛋白质功能预测框架，旨在推进蛋白质功能注释的自动化水平。

1.2 国内外研究现状

蛋白质功能预测是生物信息学领域的经典问题，CAFA（Critical Assessment of Function Annotation)[13] 挑战赛是该领域最具影响力的国际评测平台，推动了大量方法的发展。本节从四个方面系统梳理国内外研究现状。

1.2.1 基于蛋白质序列的功能预测方法

基于蛋白质序列的方法是功能预测的基础范式。早期工作主要依赖序列比对技术，遵循”序列相似则功能相似”的假设。BLAST[6] 通过局部序列比对在已知蛋白质数据库中搜索同源序列，将同源蛋白质的功能注释传递给查询蛋白质。Diamond[7] 在保持比对灵敏度的同时大幅提升了搜索速度，适用于大规模蛋白质数据库的功能注释。然而，这类方法的根本局限在于：当查询蛋白质缺乏近缘同源序列时，预测精度将急剧下降。

深度学习的兴起为序列特征的自动提取提供了强大的工具。DeepGOPlus[8] 采用卷积神经网络（CNN)[14] 直接从蛋白质氨基酸序列中捕获局部序列基序，结合序列比对分数实现功能预测。蛋白质语言模型（Protein Language Model, PLM）的出现更是带来了范式性的变革。ESM-2[15] 是一种基于 Transformer[16] 架构的大规模蛋白质语言模型，在数百万条蛋白质序列上进行自监督预训练，能够提取蕴含

进化信息和理化性质的高质量序列嵌入表示。以 ESM-2 为代表的蛋白质语言模型已成为蛋白质功能预测领域的标准特征提取器。

1.2.2 基于蛋白质结构的功能预测方法

蛋白质的三维结构是理解其功能的关键。基于" 结构决定功能" 的原则，利用蛋白质结构信息可以显著提升功能预测的准确性。AlphaFold2[9] 在蛋白质结构预测领域取得了革命性的突破，使得大规模获取蛋白质三维结构成为可能，极大地推动了基于结构的功能预测方法的发展。

DeepFRI 利用图卷积网络（GCN）在蛋白质残基接触图上进行消息传递，提取结构拓扑特征用于功能预测。Struct2GO[10] 进一步提出了基于图池化算法的框架，结合 AlphaFold2 预测的结构信息，通过多层次的图表征学习实现了更精确的功能注释。这些方法证明了结构信息在功能预测中的重要价值，但其性能受限于结构预测的准确性，且难以对缺乏可靠结构信息的蛋白质进行有效预测。

1.2.3 基于多模态信息融合的功能预测方法

为克服单一模态的局限性，研究者开始探索融合序列、结构、文本等多种信息来源的多模态方法。

DeepGO-SE[17] 提出了一种神经符号方法，将蛋白质语言模型与基于 GO 本体公理的形式化推理相结合，以近似语义蕴涵的方式进行功能预测。PO2GO[18] 利用偏序嵌入方法 PO2Vec 捕获 GO 有向无环图中的拓扑关系，增强了标签空间的表示能力。ProtGO[19] 建立了一个融合四种模态的框架，包括 PLM 序列表示、结构特征、GO 本体嵌入和可解释的文本描述。DPFunc[20] 将蛋白质域信息与序列数据互补融合，利用域作为功能基序来增强预测精度。

在大语言模型（LLM）驱动的方向上，ProtNote[21] 开创性地将 LLM 应用于蛋白质功能注释，将氨基酸序列与文本化的功能描述进行直接对齐。然而，ProtNote 依赖简单的 one-hot 编码表示序列信息，忽略了蛋白质语言模型能够提供的丰富进化特征，导致其在有监督场景下性能不佳。此外，ProtNote 对所有三个本体联合训练的策略限制了模型学习各本体特有特征的能力。

1.2.4 蛋白质表示学习中的预训练方法

预训练技术在蛋白质表示学习中发挥着越来越重要的作用。蛋白质语言模型如 ESM-2[15] 通过在大规模蛋白质序列语料上进行掩码语言建模预训练，学习到的表示蕴含了丰富的进化和功能信息。然而，这些通用预训练表示未必能充分捕获特定下游任务所需的信息。

参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）技术为解决这一问题提供了优雅的方案。适配器（Adapter)[22] 是一类轻量级的可学习模块，以即插即用的方式嵌入预训练模型的 Transformer 层中，在保持原始参数冻结的同时学习任务特定的适配信息。这种策略不仅避免了全参数微调的高昂计算开销，还能有效防止灾难性遗忘。

对比学习[23] 作为一种自监督学习范式，通过拉近正样本对的表示、推远负样本对的表示来学习有意义的特征表示。InfoNCE 损失[24] 是对比学习中最常用的目标函数。在蛋白质领域，S-PLM[25] 开创性地将适配器技术与对比学习相结合，通过在 ESM2 的 Transformer 层中注入适配器模块，利用序列-结构对比学习将蛋白质三维结构信息蒸馏至序列编码器中，使其仅凭序列输入即可生成包含结构感知的表示。S-PLM 的成功证明了”通过对比学习将跨模态知识蒸馏至适配器”这一技术路径的有效性，为本文第四章提出的 MZSGO-DA 方法提供了重要的灵感来源——将蒸馏目标从结构信息拓展至蛋白质域的功能语义信息，从而增强序列编码器的功能感知能力。

1.2.5 现有研究的不足与本文的出发点

综合上述研究现状，本文识别出现有方法的主要不足：

（1）**语义信息利用不充分**：大多数方法将 GO 功能标签和蛋白质域信息视为离散的分类标识符，忽略了其文本定义中蕴含的丰富语义信息。这种做法不仅限制了多模态融合的深度，更从根本上阻碍了模型对未见标签的推理能力。

（2）**多模态融合机制粗糙**：现有多模态方法大多采用简单拼接的方式整合不同模态的特征，缺乏动态适应不同样本特点的融合机制，难以有效应对不同模态信息质量参差不齐的现实情况。

（3）**零样本场景表现不佳**：受限于封闭标签集的分类范式，大多数方法无法预测训练集中未出现过的新功能标签。即使是声称支持零样本的方法，如 DeepGOZero 和 ProtNote，也存在预测精度低或有监督性能受损等问题。

（4）**序列编码器缺乏功能先验**：通用的蛋白质语言模型通过序列自监督预训练获得表示，但这些表示不一定包含特定于功能预测任务的知识，如蛋白质域的功能信息。

本文正是针对上述不足展开研究，力图通过多模态语义融合与预训练域感知适配两条技术路径，系统性地提升蛋白质功能预测在有监督和零样本两个场景下的性能。

1.3 论文主要工作与创新点

本文围绕蛋白质功能预测这一核心任务，提出了两个递进式的方法框架。论文的主要工作和创新点如下：

（1）**提出多模态零样本蛋白质功能注释方法 MZSGO**。将蛋白质功能预测重新定义为”蛋白质-GO”匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码。设计了自适应门控融合模块，根据各模态特征的共享上下文动态分配融合权重，克服了传统简单拼接方式的局限；同时引入非对称特征丢弃策略，在训练阶段随机遮蔽蛋白质侧特征以增强模型鲁棒性。MZSGO 在三个 GO 本体的有监督与零样本评测中均达到了最优或接近最优的水平，尤其在零样本指标上大幅超越现有方法。

（2）**提出基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA**。在 MZSGO 的基础上，进一步针对序列编码器缺乏功能先验的问题，设计了轻量级适配器模块，以即插即用方式注入蛋白质语言模型的 Transformer 层内部（注意力层后和前馈网络层后），通过 InfoNCE 对比学习预训练将蛋白质域的语义信息蒸馏至序列编码器。在下游阶段，冻结预训练适配器并引入第二组可训练适配器，以双适配器策略实现端到端训练，有效兼顾了预训练知识保留与任务特定适配。MZSGO-DA 通过端到端训练避免了静态嵌入提取的信息损失，进一步提升了功能预测性能。

1.4 论文组织结构

本文共分为四章，各章内容安排如下：

第一章为绪论。介绍蛋白质功能预测的研究背景与意义，系统梳理国内外研究现状，分析现有方法的不足，阐述本文的主要工作与创新点。

第二章为相关工作与技术基础。系统介绍蛋白质功能预测相关的基础概念和核心技术，包括基因本体系统、蛋白质语言模型、大语言模型文本嵌入、多标签分类、Transformer 架构与注意力机制、对比学习等，为后续章节奠定理论基础。

第三章为多模态零样本蛋白质功能注释方法 MZSGO。详细介绍 MZSGO 的方法设计，包括多模态特征提取、特征投影与非对称丢弃、自适应门控融合机制和优化目标。在标准测试集和纯零样本测试集上与十种基线方法进行全面对比实验，并通过消融实验和参数敏感性分析验证各模块的有效性。

第四章为基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。受 S-PLM 利用对比学习蒸馏结构信息至适配器的启发，本章将蒸馏目标拓展

至蛋白质域的功能语义信息。介绍适配器注入机制、对比学习预训练策略和双适配器端到端下游训练流程。通过实验验证端到端训练相对于静态嵌入方法的优势，并分析不同预训练策略对下游性能的影响。

最后为总结与展望，对全文工作进行总结，分析现有方法的局限性，并展望未来的研究方向。

第 2 章 相关工作与技术基础

本章系统介绍与本文工作密切相关的基础概念和核心技术，为后续章节的方法设计奠定理论基础。首先介绍蛋白质功能注释的标准体系——基因本体，然后依次阐述蛋白质语言模型、大语言模型文本嵌入技术、多标签分类与损失函数设计、Transformer 架构与注意力机制、以及对比学习方法。

2.1 基因本体系统

基因本体（Gene Ontology, GO）[2] 是生物信息学领域中最广泛使用的标准化功能注释体系，旨在为基因和蛋白质产物提供统一、规范的功能描述。GO 系统由三个相互独立的本体论组成：

（1）**分子功能（Molecular Function, MF）**：描述蛋白质在分子层面执行的活动，例如” 蛋白激酶活性”（protein kinase activity）、”DNA 结合”（DNA binding）等。

（2）**生物过程（Biological Process, BP）**：描述蛋白质参与的更高层次的生物学事件，例如” 信号转导”（signal transduction）、” 细胞凋亡”（apoptosis）等。BP 本体具有最多的 GO 术语数量和最复杂的层级结构，因此也是功能预测中最具挑战性的分支。

（3）**细胞组分（Cellular Component, CC）**：描述蛋白质在细胞中执行功能的位置，例如” 细胞核”（nucleus）、” 线粒体”（mitochondrion）等。

GO 术语之间以有向无环图（DAG）的形式组织[3]，主要包含”is_a”（是一种）和”part_of”（是... 的一部分）两种关系类型。在这种层级结构中，越靠近根节点的术语越抽象、越通用，越靠近叶节点的术语越具体、越细化。根据” 真实路径规则”（True Path Rule），如果一个蛋白质被注释了某个 GO 术语，那么它自动被认为具有该术语所有祖先节点的功能。这一规则在数据预处理和预测评估中具有重要意义。

每个 GO 术语都有标准化的文本定义，包括名称（name）和详细的功能描述（definition）。例如，GO:0004672 的名称为”protein kinase activity”，其定义为”Catalysis of the phosphorylation of an amino acid residue in a protein”。这些文本定义蕴含着丰富的语义信息，是本文方法利用大语言模型进行语义编码的基础。

值得注意的是，GO 本体处于持续的更新演化之中。新的功能术语不断被添加，旧的术语可能被废弃或合并。这种动态特性意味着功能预测模型需要具备对新术语的泛化能力，即零样本预测能力。本文第三章中构建的零样本测试集正是基于 GO 版本的时间演进来模拟真实的新功能发现场景。

2.2 蛋白质语言模型

蛋白质语言模型（Protein Language Model, PLM）是近年来生物信息学领域最具变革性的技术之一。其核心思想是将蛋白质序列类比为自然语言中的”句子”，将氨基酸类比为”词汇”，利用自然语言处理（NLP）领域成熟的自监督预训练范式来学习蛋白质序列的表示。

2.2.1 ESM-2 模型

ESM-2（Evolutionary Scale Modeling 2）[15] 是 Meta AI 研究院开发的蛋白质语言模型系列，包含从 800 万到 150 亿参数的多种规模。本文主要使用 ESM2-650M 变体（6.5 亿参数，33 层 Transformer），在数百万条蛋白质序列上通过掩码语言建模（Masked Language Modeling, MLM）预训练。

ESM-2 的工作原理是：对输入序列中随机选定的氨基酸位置进行掩码，然后利用双向 Transformer 上下文信息预测被掩码的氨基酸。通过在进化上多样化的序列集合上训练，模型隐式地学习到了蛋白质的进化约束、结构偏好和功能模式。

给定一条长度为 L 的蛋白质序列 $P = \{a_1, a_2, \ldots, a_L\}$，其中 a_i 表示第 i 个位置的氨基酸，ESM-2 输出每个位置的上下文嵌入表示 $\mathrm{ESM}(a_i) \in \mathbb{R}^{d_{seq}}$。通过对所有位置的嵌入进行平均池化（Mean Pooling），可以获得蛋白质级别的全局表示：

$$\mathbf{E}_{seq} = \frac{1}{L}\sum_{i=1}^{L} \mathrm{ESM}(a_i) \in \mathbb{R}^{d_{seq}} \tag{2-1}$$

其中，$d_{seq} = 1280$（对于 ESM2-650M 变体）。该嵌入向量蕴含了蛋白质的进化信号和理化性质，是本文方法中序列模态的基础特征表示。

2.2.2 适配器技术

蛋白质语言模型通常包含数亿乃至数十亿的参数，对其进行全参数微调不仅计算开销巨大，还容易导致灾难性遗忘——即微调过程中丢失预训练阶段学到的通用知识。适配器（Adapter）[22] 技术提供了一种参数高效的替代方案。

适配器是一种轻量级的瓶颈结构模块，通常由降维线性层、非线性激活函数和升维线性层组成，并通过残差连接与原始模型相加。设输入为 $\mathbf{x} \in \mathbb{R}^d$，适配器的计算过程为：

$$\mathrm{Adapter}(\mathbf{x}) = \mathrm{LN}(\mathbf{W}_{\mathrm{up}} \cdot \mathrm{ReLU}(\mathbf{W}_{\mathrm{down}} \cdot \mathbf{x}) + \mathbf{x}) \tag{2-2}$$

其中，$\mathbf{W}_{\mathrm{down}} \in \mathbb{R}^{d_b \times d}$ 将输入降维至瓶颈维度 d_b（通常 $d_b = d/2$），$\mathbf{W}_{\mathrm{up}} \in \mathbb{R}^{d \times d_b}$ 将其恢复至原始维度，LN 表示层归一化。由于适配器的参数量远小于原始模型，在

训练时只需更新适配器参数而冻结原始模型参数，即可高效地将外部知识注入预训练模型。

在蛋白质表示学习领域，S-PLM[25] 率先将适配器技术与对比学习相结合应用于蛋白质语言模型的增强。S-PLM 在 ESM2 的 Transformer 层中注入适配器模块构建序列编码器，同时使用 Swin-Transformer 作为结构编码器处理蛋白质 Cα 骨架接触图。通过对比学习，S-PLM 将来自同一蛋白质的序列表示与其三维结构表示在潜在空间中对齐，使得序列编码器在预训练后仅凭氨基酸序列输入即可生成包含结构感知的嵌入表示。S-PLM 的成功验证了通过对比学习将跨模态知识蒸馏至适配器这一技术路径的有效性。

本文第四章提出的 MZSGO-DA 方法借鉴了 S-PLM 的技术思路，在蛋白质语言模型的 Transformer 层中注入轻量级适配器模块，但将蒸馏目标从三维结构信息替换为蛋白质域的功能语义信息，通过对比学习预训练将域语义信息蒸馏至序列编码器。

2.3 大语言模型文本嵌入

大语言模型文本嵌入（LLM-based Text Embedding）技术旨在利用大规模预训练语言模型将任意自然语言文本映射为稠密的向量表示，使得语义相似的文本在向量空间中距离更近。

2.3.1 Qwen3-Embedding 模型

Qwen3-Embedding[26] 是通义千问系列推出的文本嵌入模型，具有强大的语义理解和表示能力。本文采用 Qwen3-Embedding-4B（40 亿参数）作为统一的语义编码器，对蛋白质域描述文本和 GO 功能定义文本进行编码。

对于一段包含 N 个 token 的输入文本 T，Qwen3-Embedding 输出每个 token 的嵌入 $\{h_1, h_2, \ldots, h_N\}$，通过平均池化获得文本的全局语义表示：

$$\mathbf{E}_{text} = \frac{1}{N}\sum_{n=1}^{N} h_n \in \mathbb{R}^{d_{text}} \tag{2-3}$$

其中，$d_{text} = 2560$（对于 Qwen3-Embedding-4B）。

选择 Qwen3-Embedding 而非生物医学专用语言模型（如 BioGPT[27]）的原因在于：文本嵌入模型专门针对句子级语义表示进行了优化训练，能够生成高质量的句向量；而像 BioGPT 这样的生成式模型需要通过平均 token 级嵌入来近似句子表示，其句子级语义捕获能力不如专用嵌入模型。本文第三章的消融实验也验证了这一选择的合理性。

2.3.2 蛋白质域的语义编码

蛋白质域（domain）是蛋白质中独立折叠并行使特定功能的结构和功能单元。InterPro 数据库[11] 提供了全面的蛋白质域注释信息，包括每个域的标识符及其自然语言描述。例如，某蛋白质可能包含”Protein kinase domain”（蛋白激酶结构域）和”SH2 domain”（SH2 结构域）等多个功能域。

对于拥有 K 个域注释 $\mathcal{D} = \{d_1, d_2, \ldots, d_K\}$ 的蛋白质，域编码采用两级平均池化策略：

第一级（token 级池化）：对每个域描述 d_k（含 M_k 个 token）内部进行池化：

$$\mathbf{e}_k = \frac{1}{M_k} \sum_{m=1}^{M_k} h_{k,m} \tag{2-4}$$

第二级（域级池化）：对该蛋白质所有域的嵌入进行聚合：

$$\mathbf{E}_{dom} = \frac{1}{K} \sum_{k=1}^{K} \mathbf{e}_k \in \mathbb{R}^{d_{text}} \tag{2-5}$$

若蛋白质无域注释，则使用零向量作为占位符。根据 InterPro 数据库的统计，UniProtKB 中超过 80% 的蛋白质具有匹配的域信息，表明域特征具有广泛的适用性。

2.4 多标签分类与损失函数

蛋白质功能预测本质上是一个多标签分类问题——一个蛋白质通常同时具有多个 GO 功能注释。在本文的框架中，我们进一步将其转化为多个独立的二分类问题：对每个” 蛋白质-GO” 对，模型判断该蛋白质是否具有该 GO 功能。

2.4.1 二分类交叉熵损失

对于给定的” 蛋白质-GO” 对，设真实标签为 $y \in \{0, 1\}$，模型预测概率为 $\hat{y} \in (0, 1)$，二分类交叉熵（Binary Cross-Entropy, BCE）损失定义为：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \tag{2-6}$$

其中 N 为样本数。BCE 损失在正负样本分布相对均衡的本体分支（如 BP 和 MF）上表现良好。

2.4.2 Focal Loss

GO 功能标签通常呈现极度的长尾分布——少量高频标签覆盖大部分蛋白质，

而大量低频标签仅注释少量蛋白质。这种类别不平衡问题在 CC 本体中尤为严重。为此，本文在 CC 本体上采用 Focal Loss[28] 来缓解类别不平衡问题：

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N}\sum_{i=1}^{N}\left[\alpha(1-\hat{y}_i)^{\gamma} y_i \log(\hat{y}_i) + (1-\alpha)\hat{y}_i^{\gamma}(1-y_i)\log(1-\hat{y}_i)\right] \tag{2-7}$$

其中，α 用于平衡正负样本的权重，γ 为聚焦参数（实验中设为 2），用于降低易分类样本的损失权重。当 $\gamma > 0$ 时，对于模型已经能够正确且高置信度分类的样本（$\hat{y}_i$ 接近真实标签），其损失被大幅衰减；而对于模型难以正确分类的” 困难样本”，损失保持较大值，使模型训练更加聚焦于困难样本的学习。

2.5 Transformer 架构与注意力机制

Transformer[16] 是一种完全基于注意力机制的神经网络架构，最初用于自然语言处理的序列到序列任务，现已成为深度学习领域最广泛使用的基础架构之一。本文使用的蛋白质语言模型 ESM-2 和大语言模型 Qwen3-Embedding 均基于 Transformer 架构构建。

2.5.1 自注意力机制

自注意力（Self-Attention）机制是 Transformer 的核心组件，允许序列中的每个位置与其他所有位置进行信息交互。给定输入表示 $\mathbf{X} \in \mathbb{R}^{L\times d}$，自注意力机制首先通过三个可学习的线性映射将输入分别投影为查询（Query）、键（Key）和值（Value）：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V \tag{2-8}$$

其中 $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d\times d_k}$，$\mathbf{W}_V \in \mathbb{R}^{d\times d_v}$ 为参数矩阵。注意力输出通过缩放点积计算：

$$\text{Attention}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}}\right)\mathbf{V} \tag{2-9}$$

其中 $\sqrt{d_k}$ 为缩放因子，防止点积值过大导致梯度消失。

2.5.2 多头注意力机制

为了使模型能够从不同的子空间中捕获多种类型的注意力模式，Transformer 采用多头注意力（Multi-Head Attention, MHA）机制。设有 H 个注意力头，每个头独立计算注意力后将结果拼接：

$$\text{MHA}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \text{Concat}(\text{head}_1,\ldots,\text{head}_H)\mathbf{W}_O \tag{2-10}$$

其中 $\text{head}_h = \text{Attention}(\mathbf{QW}_Q^h, \mathbf{KW}_K^h, \mathbf{VW}_V^h)$，$\mathbf{W}_O$ 为输出投影矩阵。

2.5.3 Transformer 层结构

标准的 Transformer 编码器层由两个子层组成：多头自注意力子层和前馈网络（Feed-Forward Network, FFN）子层，每个子层都包含残差连接和层归一化：

$$\mathbf{X}' = \text{LN}(\mathbf{X} + \text{MHA}(\mathbf{X})) \tag{2-11}$$

$$\mathbf{X}'' = \text{LN}(\mathbf{X}' + \text{FFN}(\mathbf{X}')) \tag{2-12}$$

其中 FFN 通常由两个线性变换和一个非线性激活函数组成。本文第四章中的适配器模块正是分别嵌入在注意力子层和 FFN 子层之后。

2.6 对比学习

对比学习[23] 是一种自监督表示学习方法，其核心思想是在特征空间中拉近语义相似的样本对（正样本对），同时推远语义不相似的样本对（负样本对），从而学习到具有区分性的特征表示。

2.6.1 InfoNCE 损失函数

InfoNCE[24] 是对比学习中最常用的目标函数。给定一批 B 个样本，其中每个样本 i 具有两个视图的表示 $\mathbf{z}_i^A$ 和 $\mathbf{z}_i^B$（正样本对），InfoNCE 损失定义为：

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\text{sim}(\mathbf{z}_i^A, \mathbf{z}_i^B)/\tau)}{\sum_{j=1}^{B}\exp(\text{sim}(\mathbf{z}_i^A, \mathbf{z}_j^B)/\tau)} \tag{2-13}$$

其中 $\text{sim}(\cdot,\cdot)$ 为相似度函数（通常采用余弦相似度），τ 为温度超参数，控制分布的平滑程度。

在本文第四章的预训练阶段，我们使用双向 InfoNCE 对比损失来对齐蛋白质序列表示与域嵌入表示：

$$\mathcal{L}_{\text{CL}} = \frac{1}{2}\left(\mathcal{L}_{\text{InfoNCE}}(\mathbf{Z}_{seq} \to \mathbf{Z}_{dom}) + \mathcal{L}_{\text{InfoNCE}}(\mathbf{Z}_{dom} \to \mathbf{Z}_{seq})\right) \tag{2-14}$$

通过这种双向对比学习，同一蛋白质的序列表示和域描述嵌入被拉近，不同蛋白质的表示被推远。预训练完成后，序列编码器无需显式输入域信息，即可生成携带域语义信息的蛋白质表示。

2.6.2 投影头设计

在对比学习中，通常在编码器输出之后附加一个投影头（Projection Head），将

高维特征映射至低维对比空间[23]。这是因为投影头能够过滤掉与对比目标无关的高层特征变化，使对比损失更聚焦于语义层面的对齐。

本文采用的投影头结构为：

$$\text{ProjHead}(\mathbf{x}) = \text{LN}(\mathbf{W}_2 \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_1 \cdot \mathbf{x})))) \tag{2-15}$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{d_p \times d}$、$\mathbf{W}_2 \in \mathbb{R}^{d_p \times d_p}$ 为线性变换参数，d_p 为投影维度（设为 256），GELU 为激活函数[29]。输出向量经过 L2 归一化后用于计算余弦相似度。

2.7 评价指标

为全面评估蛋白质功能预测的性能，尤其是在零样本场景下的泛化能力，本文采用以下评价指标体系。

2.7.1 蛋白质中心评价指标

遵循 CAFA 挑战[13] 的标准协议，本文主要报告以下蛋白质中心指标：

（1）$F_{\max}$：是一个阈值依赖的指标。对于每个决策阈值 $t \in [0, 1]$，计算所有蛋白质上的平均精确率 $\text{Pr}(t)$ 和平均召回率 $\text{Rc}(t)$，然后取所有阈值下 F1 分数的最大值：

$$F_{\max} = \max_t \frac{2 \cdot \text{Pr}(t) \cdot \text{Rc}(t)}{\text{Pr}(t) + \text{Rc}(t)} \tag{2-16}$$

（2）**AUPR**（Area Under the Precision-Recall Curve）：精确率-召回率曲线下面积，是一个阈值无关的指标。在功能注释任务固有的严重类别不平衡情况下，AUPR 比 AUROC 更能反映模型的真实性能。

2.7.2 零样本评价指标

为评估模型对未见标签的推理能力，本文将标签空间划分为”已见标签集”（Seen Labels，训练集中出现过的 GO 术语）和”未见标签集”（Unseen Labels，训练集中未出现的 GO 术语），分别计算 Seen AUPR 和 Unseen AUPR。

（3）**调和均值 H**：为综合评估模型在已见和未见标签上的平衡性能，采用 Seen AUPR 和 Unseen AUPR 的调和均值：

$$H = \frac{2 \times \text{Seen AUPR} \times \text{Unseen AUPR}}{\text{Seen AUPR} + \text{Unseen AUPR}} \tag{2-17}$$

只有当模型在两类标签上均表现良好时，H 值才会较高。该指标是零样本场景下最重要的综合评价指标。

2.8 本章小结

本章系统介绍了本文工作所涉及的核心技术基础。基因本体系统提供了功能注释的标准框架，蛋白质语言模型和大语言模型文本嵌入分别为蛋白质序列和功能文本提供了强大的特征提取能力，多标签分类损失函数和 Focal Loss 为应对类别不平衡提供了优化工具，Transformer 和注意力机制构成了本文模型的基础架构，对比学习为跨模态知识蒸馏提供了有效的训练范式，评价指标体系为模型性能的全面评估提供了可靠的依据。上述技术基础将在后续两章的具体方法设计中得到综合运用。

第 3 章 多模态零样本蛋白质功能注释方法 MZSGO

传统的蛋白质功能预测方法将每个 GO 标签视为独立的分类标识符，模型的预测能力被限制在训练集中出现过的标签范围内，无法对新出现的功能术语进行有效推理。针对这一根本性局限，本章提出多模态零样本蛋白质功能注释方法 MZSGO（Multimodal Zero-Shot GO annotation），将蛋白质功能预测重新定义为开放语义空间中的” 蛋白质-GO” 匹配问题。MZSGO 融合蛋白质语言模型提取的序列进化特征与大语言模型编码的文本语义特征，通过自适应门控融合机制实现多模态信息的动态整合，使模型既能在有监督场景下准确分类，也能通过文本语义相似性推断未见过的功能标签。

3.1 问题定义

蛋白质功能预测任务的目标是：给定一个蛋白质 P 和一组 GO 功能标签 $\mathcal{G} = \{g_1, g_2, \ldots, g_C\}$，预测该蛋白质与每个功能标签之间的关联概率 $p(y = 1|P, g_c)$，其中 $y = 1$ 表示蛋白质 P 具有功能 g_c。

与传统方法不同，本文不将其建模为固定标签集的多标签分类问题，而是重新定义为” 蛋白质-GO” 匹配问题。具体而言，每个蛋白质的特征表示与每个 GO 标签的文本语义嵌入配对，由模型计算二者的匹配分数。这种范式设计意味着：对于训练集中未出现过的新 GO 标签，只需提供其文本定义即可生成语义嵌入并参与预测，从而天然支持零样本推理。

考虑到 GO 的三个本体（BP、MF、CC）在标签规模、语义粒度和数据分布上存在显著差异，本文对每个本体独立训练一个模型。这一策略基于如下实验观察：联合训练所有本体会导致模型难以学习各本体特有的特征模式，独立训练能够获得更好的性能。

3.2 数据集构建

为严格评估模型在有监督和零样本两个场景下的性能，本文构建了基于 CAFA5 挑战和 Swiss-Prot 数据库[30] 的综合基准数据集。

3.2.1 有监督训练集构建

训练语料源自 CAFA5 数据集，采用 ProtGO[19] 使用的数据源和训练/测试划分策略，并限制数据条目为 Swiss-Prot 数据库中收录的蛋白质。这一子集由人工审核

的蛋白质组成，确保了注释质量的高可靠性，同时为与需要结构信息的基线方法进行公平比较提供了基础。功能注释采用 2023 年 1 月 1 日发布的 Gene Ontology 版本。

与 ProtGO 不同的是，本文实施了本体特异性的数据过滤策略。对于每个本体类别，仅使用具有该特定本体注释的蛋白质进行训练，而非直接使用完整训练集。这一决策基于如下观察：完整数据集中缺乏某一本体注释的蛋白质会对基线模型的性能产生不利影响。尽管 MZSGO 在完整数据集上也不会出现显著性能下降，但经过裁剪的训练集有助于实现最优性能并确保与最先进基线方法的严格公平比较。

3.2.2 零样本测试集构建

零样本测试集旨在评估模型对从未见过的蛋白质和新出现标签的注释能力。其设计遵循两个核心原则：

（1）**蛋白质新颖性（序列层面）**：选择不在训练集中的 Swiss-Prot 蛋白质。为防止序列相似性导致的信息泄露，使用 Diamond 工具进行严格的同源性过滤，移除与训练集中任何序列的序列一致性超过 30% 的测试蛋白质。

（2）**标签新颖性（语义层面）**：实施时间演进评估策略，引入 2025 年 10 月 10 日更新的 GO 本体版本。将” 零样本标签” 定义为存在于 2025 版本但在 2023 版本中不存在的 GO 术语。因此，最终的零样本测试集由具有这些新出现功能注释的非同源蛋白质组成。

3.2.3 数据集统计

数据集的统计信息如表 3-1所示，样本按三个 GO 子本体分组。由于生物通路的复杂性，BP 类别包含最多的零样本蛋白质数量。

表 3-1: MZSGO 数据集统计

数据集	MF	CC	BP
训练集	50,874	51,743	51,618
测试集	5,584	5,764	5,712
零样本测试集	555	17	3,687

表 3-2详细展示了标签分布情况。在测试阶段，标签被分为以下三类：共有标签（Shared Labels），即同时出现在训练集和测试集中的 GO 术语；未见标签（Unseen Labels），即存在于测试集但不在训练数据中的术语；零样本标签（Zero-shot Labels），特指因本体更新而新出现的术语。

表 3-2: 标签分布统计

标签类别	MF	CC	BP
标签总数	7,007	2,803	20,639
未见标签	191	26	328
共有标签	2,983	1,581	11,691
仅训练标签	3,833	1,196	8,620
零样本标签	35	6	34

这种严格的区分确保了零样本测试集上的评估指标真正反映模型的推理能力，而非记忆效应。

3.3 MZSGO 方法设计

3.3.1 总体框架

MZSGO 的总体架构如图 3-1所示。系统由四个紧密联结的组件构成：（1）多模态特征编码，提取蛋白质序列、域描述和 GO 标签定义的嵌入表示；（2）特征投影与非对称特征丢弃，将异构表示映射至共享语义空间并增强训练鲁棒性；（3）自适应门控融合，动态整合多模态特征；（4）分类预测，输出蛋白质与 GO 功能的匹配概率。

MZSGO 的完整训练流程如算法 3-1所示。整个工作流分为四个阶段：特征投影与对齐、特征丢弃（仅训练阶段）、门控融合和分类预测。

3.3.2 多模态特征编码

MZSGO 利用两种预训练模型提取三个模态的特征表示：

（1）**蛋白质序列表示**：使用 ESM2-650M[15] 蛋白质语言模型对蛋白质序列进行编码，提取最后一层隐藏状态，通过平均池化获得蛋白质级别的全局进化特征表示 $\mathbf{E}_{seq} \in \mathbb{R}^{1280}$。

（2）**GO 标签语义表示**：使用 Qwen3-Embedding-4B[26] 对每个 GO 术语的名称和定义文本进行编码。输入文本格式为” 名称: 定义”（如”protein kinase activity: Catalysis of the phosphorylation of an amino acid residue...”），通过平均池化获得标签级别的语义嵌入 $\mathbf{E}_{label} \in \mathbb{R}^{2560}$。

（3）**蛋白质域语义表示**：使用同一 Qwen3-Embedding-4B 模型对蛋白质各个域的 InterPro[11] 描述文本进行编码，采用两级平均池化（token 级和域级）获得蛋白质级别的域特征表示 $\mathbf{E}_{dom} \in \mathbb{R}^{2560}$。

算法 3-1 MZSGO 训练工作流

Input: E_{esm}, E_{dom}（蛋白质特征），E_{nlp}（标签特征）

Output: 预测矩阵 $Y \in \mathbb{R}^{B \times L}$

定义 $\phi(\cdot)$: 通用 MLP 模块（Linear → LN → Act → Dropout）;

// 阶段 1: 投影与对齐

将特征投影至隐藏维度 H;

$\mathbf{h}_{esm} \leftarrow \phi_1(E_{esm}), \mathbf{h}_{dom} \leftarrow \phi_2(E_{dom}), \mathbf{h}_{nlp} \leftarrow \phi_3(E_{nlp})$;

广播特征至形状 $[B \cdot L, H]$ 构建蛋白质-标签配对;

$\mathbf{H} \leftarrow \{\mathbf{h}_{dom}^{expand}, \mathbf{h}_{esm}^{expand}, \mathbf{h}_{nlp}^{expand}\}$;

// 阶段 2: 特征丢弃（仅训练阶段）

if 训练阶段 **then**

  生成掩码 $M \in \{0, 1\}^{B \cdot L \times 2}$，确保每行至少保留一个蛋白质特征;

  $\mathbf{h}_{dom}^{expand} \leftarrow \mathbf{h}_{dom}^{expand} \odot M_{:,0}$;

  $\mathbf{h}_{esm}^{expand} \leftarrow \mathbf{h}_{esm}^{expand} \odot M_{:,1}$;

end

// 阶段 3: 门控融合

拼接所有模态: $\mathbf{Z}_{cat} \leftarrow \text{Concat}(\mathbf{H}, \text{dim} = -1)$;

计算门控权重: $\mathbf{W} \leftarrow \text{Softmax}(\phi_{gate}(\mathbf{Z}_{cat}))$ // 形状: $[B \cdot L, 3]$

加权求和融合: $\mathbf{F}_{fused} \leftarrow \sum_{k=1}^{3} \mathbf{W}_{:,k} \cdot \phi_{trans}(\mathbf{H}_k)$;

// 阶段 4: 分类

$Y \leftarrow \text{Reshape}(\text{Linear}(\phi_{cls}(\mathbf{F}_{fused})), [B, L])$;

return Y

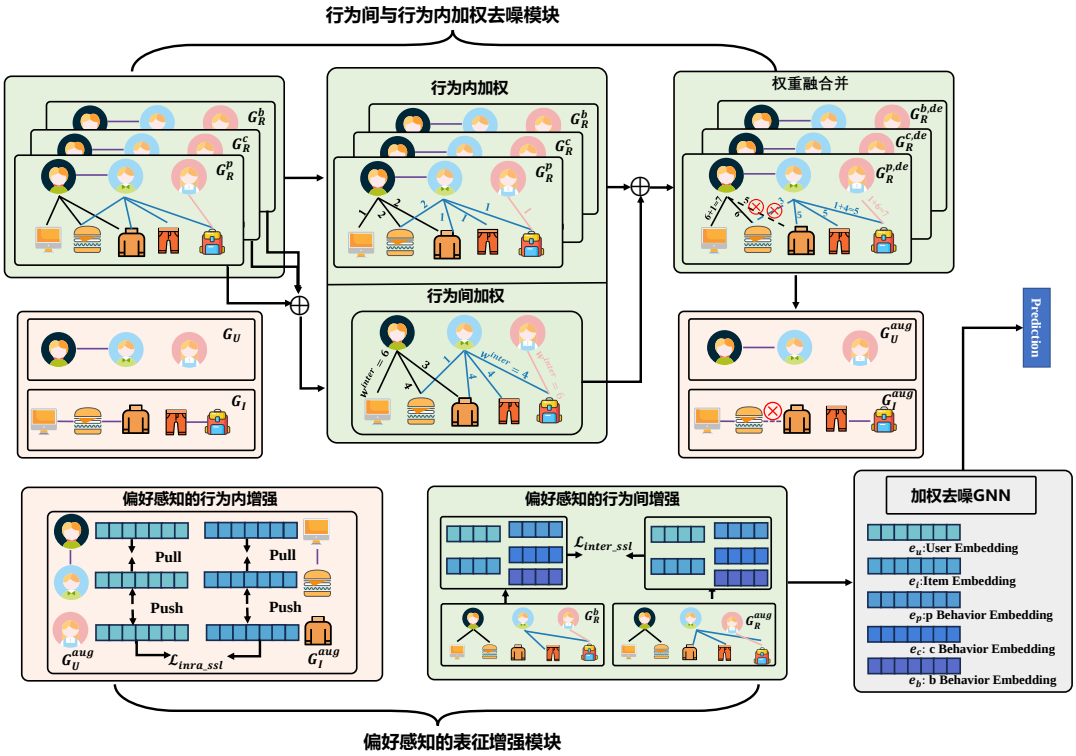

图 3-1: MZSGO 框架总体架构。流程包含四个集成阶段:（1）多模态特征投影;（2）训练阶段的蛋白质模态丢弃，虚线表示以概率 $p = 0.15$ 随机丢弃蛋白质特征，实线表示保留的模态;（3）门控融合模块实现自适应特征整合;（4）二分类头进行 GO 功能预测。

以上三种特征分别捕获了蛋白质的进化信号、功能标签的语义内涵和蛋白质域的结构功能信息，为后续的多模态融合提供了互补的信息来源。

表 3-3展示了一个完整的输入数据示例（UniProt ID: Q8TBH0），直观呈现了三种模态的具体数据形式。该蛋白质的氨基酸序列由 ESM2-650M 编码以提取进化特征;其关联的 5 个 InterPro 域描述（包含 Arrestin 相关的结构域和功能域）由 Qwen3-Embedding 编码以提取域语义特征；候选 GO 标签的定义文本（如”intracellular anatomical structure”、”organelle” 等）同样由 Qwen3-Embedding 编码以提取功能语义特征。这种多模态输入设计使模型能够从互补的角度理解蛋白质功能。

3.3.3 特征投影与模态特异性丢弃

由于三种模态的原始嵌入具有不同的维度和分布特性（ESM 嵌入为 1280 维，文本嵌入为 2560 维），需要将它们映射至统一的隐空间。为此，设计三个独立的多层感知机（MLP）投影模块，每个模块由线性变换、层归一化[31]、GELU 激活[29]和 Dropout 组成:

表 3-3: 蛋白质 Q8TBH0 的输入数据结构示例。展示三种模态的具体数据形式。

数据模态	内容
蛋白质 ID	Q8TBH0
模态 1：蛋白质序列	MLFDKVKAFSVQLDGATAGVEPVFSGGQAVAGRVLLELSS AARVGALRLRARGRAHVHWTESRSAGSSTAYTQSYSERVE VVSHRATLLAPDTGETTTLPPGRHEFLFSFQLPPTLVTSFE GKHGSVRYCIKATLHRPWVPARRARKVFTVIEPVDINTPAL LAPQ... （共 *420* 个残基）
模态 2：域文本描述	• IPR011021: Domain: Arrestin-like, N-terminal • IPR011022: Domain: Arrestin: C-terminal-like domain • IPR014752: Arrestin-like, C-terminal • IPR014756: Immunoglobulin E-set • IPR050357: Arrestin domain-containing protein
模态 3：GO 标签定义（正样本）	**GO:0005622** intracellular anatomical structure: A component of a cell contained within (but not including) the plasma membrane. **GO:0043226** organelle: Organized structure of distinctive morphology and function. **GO:0016020** membrane: A lipid bilayer along with all the proteins and protein complexes embedded in it.

$$\mathbf{h}_m = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_m\mathbf{E}_m + \mathbf{b}_m))) \tag{3-1}$$

其中 $m \in \{seq, dom, label\}$ 表示模态类型，$\mathbf{h}_m \in \mathbb{R}^{d_{model}}$ 为投影后的特征向量，$d_{model} = 512$。

模态特异性丢弃策略。为防止模型过度依赖单一蛋白质模态，并模拟真实场景中域信息缺失的情况，本文设计了一种非对称的特征丢弃机制。在训练阶段，定义二值掩码 $\mathbf{M} = [m_{seq}, m_{dom}]$，其中每个蛋白质模态以概率 $p = 0.15$ 被独立丢弃：

$$m_{seq} = \mathbb{I}[r_{seq} > p], \quad m_{dom} = \mathbb{I}[r_{dom} > p] \tag{3-2}$$

其中 $r_{seq}, r_{dom} \sim \text{Uniform}(0, 1)$。掩码后的特征为 $\hat{\mathbf{h}}_{seq} = \mathbf{h}_{seq} \cdot m_{seq}$ 和 $\hat{\mathbf{h}}_{dom} = \mathbf{h}_{dom} \cdot m_{dom}$。

关键设计在于其”非对称性”：GO 标签的文本嵌入 $\mathbf{h}_{label}$ 始终保留，不参与丢弃。这迫使模型学会在部分蛋白质信息缺失的情况下，仍能通过 GO 标签的文本语义进行有效预测，从而为零样本泛化奠定基础。

为确保至少有一个蛋白质模态可用，设计了强制保留机制：

$$\text{若} m_{seq} = m_{dom} = 0: \quad m_k \leftarrow 1, \quad k \sim \text{Uniform}\{seq, dom\} \tag{3-3}$$

推理阶段不施加任何丢弃，模型可利用完整的多模态信息进行预测。

3.3.4 自适应门控融合机制

为有效整合多模态特征，本文设计了门控融合模块（Gated Fusion Module），学习为每个信息来源分配自适应的重要性权重。首先，拼接三个模态的特征构建全局上下文向量，输入门控网络生成注意力分数：

$$\mathbf{S} = [\hat{\mathbf{h}}_{dom} \parallel \hat{\mathbf{h}}_{seq} \parallel \mathbf{h}_{label}] \tag{3-4}$$

$$\boldsymbol{\alpha} = \text{Softmax}(\mathbf{W}_{gate} \cdot \text{ReLU}(\text{LN}(\mathbf{W}_{ctx}\mathbf{S}))) \tag{3-5}$$

其中 $\parallel$ 表示拼接操作，$\boldsymbol{\alpha} \in \mathbb{R}^3$ 为归一化的门控权重，$\mathbf{W}_{ctx} \in \mathbb{R}^{d_{model} \times 3d_{model}}$ 和 $\mathbf{W}_{gate} \in \mathbb{R}^{3 \times d_{model}}$ 为可学习参数。

同时，每个模态的特征通过各自的变换层 $\phi(\cdot)$ 进行非线性映射。最终的融合表示通过加权求和获得：

$$\mathbf{H}_{fused} = \sum_{k=1}^{3} \alpha_k \cdot \phi(\mathbf{h}_k) \tag{3-6}$$

其中 k 索引三个模态（序列、域、标签），$\phi(\cdot)$ 包含线性变换、层归一化、ReLU 激活和 Dropout。

该机制的核心优势在于：门控权重是**逐样本动态计算**的，即每个蛋白质-GO 对的融合比例不同。例如，当蛋白质的域信息丰富且与功能高度相关时，模型倾向于分配更高的权重给域特征；当域信息稀疏时，模型则更依赖序列特征和标签文本语义。

3.3.5 优化目标

融合表示 $\mathbf{H}_{fused}$ 通过分类 MLP 生成标量逻辑值，再经 sigmoid 激活函数获得预测概率：

$$\hat{y} = \sigma(\mathbf{W}_{out}\mathbf{H}_{fused} + b_{out}) \tag{3-7}$$

为应对不同 GO 子本体在类别不平衡程度上的差异，本文对不同本体采用不同的损失函数策略：

对于 BP 和 MF 子本体，使用标准的二分类交叉熵损失：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)] \tag{3-8}$$

对于 CC 子本体，采用 Focal Loss 以聚焦于难样本的学习：

$$\mathcal{L}_{\text{Focal}} = -\frac{1}{N}\sum_{i=1}^{N}\left[\alpha(1-\hat{y}_i)^{\gamma} y_i \log(\hat{y}_i) + (1-\alpha)\hat{y}_i^{\gamma}(1-y_i)\log(1-\hat{y}_i)\right] \tag{3-9}$$

其中 $\gamma = 2$ 为聚焦参数。

上述损失函数选择策略并非随意决定，而是基于对三个 GO 子本体标签分布特性的定量统计分析。本文引入两个关键指标来刻画数据分布特征：

基尼系数（Gini Coefficient, G）用于量化标签分布的不均衡程度。设 x 为按非递减顺序排列的标签出现次数（$x_1 \leq \cdots \leq x_C$），基尼系数计算为：

$$G = \frac{2\sum_{i=1}^{C} i \cdot x_i}{C\sum_{i=1}^{C} x_i} - \frac{C+1}{C} \tag{3-10}$$

G 接近 1 表示极度不平衡，少数” 头部” 类别主导了数据集。

有效性比率（Effectiveness Ratio, ρ）。遵循 Cui 等人[28] 的分析，由于信息重叠，添加样本的边际收益递减。一个具有 n 个样本的类别的有效数量为 $E_n = (1-\beta^n)/(1-\beta)$，其中 $\beta = 0.9999$。有效性比率定义为平均有效数量与平均实际数量之比：

$$\rho = \frac{\frac{1}{C}\sum_{i=1}^{C} E_{n_i}}{\frac{1}{C}\sum_{i=1}^{C} n_i} \tag{3-11}$$

ρ 值越低表示数据冗余度越高，梯度被重复样本所主导。

统计分析结果显示：MF 和 BP 本体具有相对较高的信息质量，有效性比率分别为 72.20% 和 81.11%，表明尽管存在固有的不平衡，正样本仍能提供充足的独特梯度信号，因此采用标准的 BCE 损失即可。相比之下，CC 本体表现出极端的不平衡性（$G = 0.946$）和最低的有效性比率（57.60%），显著劣于 BP 和 MF。这意味着 CC 本体中近一半的样本量贡献了极少的边际信息，如果使用标准 BCE 损失，这些频繁但冗余的样本会淹没学习过程。因此，CC 本体专门采用 Focal Loss 来降低易分类样本的权重，聚焦于信息量丰富的尾部类别的学习。

3.4 实验设置

3.4.1 实现细节

MZSGO 基于 PyTorch[32] 框架实现。为对齐异构模态，将 1280 维 ESM 嵌入和 2560 维文本/域特征投影至统一的隐空间（$d_{model} = 512$）。这些特征经拼接后输入门控融合网络——一个两层 MLP——计算自适应模态权重，随后通过变换层进行非线性映射。融合表示最终被压缩至 256 维用于分类。

训练在单块 NVIDIA A6000 GPU（48GB 显存）上进行，使用 Adam 优化器[33]，

学习率为 5×10^{-4}，批次大小为 16。为缓解过拟合，施加 0.5 的神经元级 Dropout 率。考虑到各子本体的复杂度差异，BP 训练 30 个 epoch，MF 和 CC 各训练 20 个 epoch。

3.4.2 基线方法

本文选择十种先进的基线方法进行对比，涵盖三大类别：

（1）**传统方法**：Naive（基于标签频率预测）、Diamond[7]（基于序列同源性传递）。

（2）**深度学习方法**：DeepGOCNN[8]（卷积神经网络）、DeepGOZero[12]（本体公理约束）、Struct2GO[10]（图神经网络 + 结构信息）、PO2GO[18]（偏序嵌入）、DeepGO-SE[17]（神经符号推理）。

（3）**多模态/LLM 方法**：ProtGO[19]（四模态融合）、DPFunc[20]（域信息增强）、ProtNote[21]（LLM 功能描述）。

3.4.3 评价指标

为全面评估模型在蛋白质功能预测中的有效性，特别是在广义零样本设定下的性能，本文采用多层次的评价指标体系。遵循 CAFA 挑战赛[13] 的标准评估协议，以蛋白质中心（protein-centric）的指标为主要评估标准。

3.4.3.1 标准蛋白质中心指标

设测试集包含 N 条蛋白质序列。对于第 i 条蛋白质，令 T_i 为其真实 GO 标签集合，$P_i(t)$ 为置信度分数大于等于阈值 $t \in [0, 1]$ 的预测 GO 标签集合。

精确率与召回率。对于给定阈值 t，第 i 条蛋白质的精确率 $\pi_i(t)$ 和召回率 $\rho_i(t)$ 定义为：

$$\pi_i(t) = \frac{|P_i(t) \cap T_i|}{|P_i(t)|}, \quad \rho_i(t) = \frac{|P_i(t) \cap T_i|}{|T_i|} \tag{3-12}$$

其中 $|\cdot|$ 表示集合的大小。数据集的平均精确率 $AvgPr(t)$ 和平均召回率 $AvgRc(t)$ 计算如下：

$$AvgPr(t) = \frac{1}{M(t)} \sum_{i=1}^{N} \pi_i(t) \cdot \mathbb{I}(|P_i(t)| > 0) \tag{3-13}$$

$$AvgRc(t) = \frac{1}{N} \sum_{i=1}^{N} \rho_i(t) \tag{3-14}$$

其中 $M(t)$ 表示在阈值 t 下至少有一个预测结果的蛋白质数量。

F_{max} 指标。F_{max} 是在所有可能阈值 t 上计算的平均精确率和平均召回率的最大调和均值：

$$F_{max} = \max_{t \in [0,1]} \left(\frac{2 \cdot AvgPr(t) \cdot AvgRc(t)}{AvgPr(t) + AvgRc(t)} \right) \tag{3-15}$$

F_{max} 是一个依赖阈值的指标，它通过在 0 到 1 的阈值范围内搜索最优的 F1 分数，有效地衡量了模型的峰值分类精度。

AUPR 指标。AUPR（Area Under the Precision-Recall Curve）通过对精确率-召回率曲线进行积分计算：

$$AUPR = \int_0^1 AvgPr(Rc)\, d(AvgRc) \tag{3-16}$$

与 F_{max} 不同，AUPR 不依赖于特定阈值。鉴于功能注释任务中存在严重的类别不平衡，AUPR 能够提供更为鲁棒的全局性能评估。需要指出的是，本文的 AUPR 是在蛋白质中心的精确率-召回率曲线上、覆盖完整标签空间计算的。即使模型对未见标签赋予零分数，曲线上仍存在非零的精确率-召回率点（例如在阈值为 0 时），因此数值上 AUPR 略高于零，但这并不表示模型对未见标签具有有效的判别能力。

3.4.3.2 广义零样本指标

为评估模型的泛化能力，将标签空间划分为已见标签集 L_{seen} 和未见标签集 L_{unseen}，分别计算两个子集上的 AUPR：

Seen AUPR：将评估限定在训练集中出现过的标签子集上计算的 AUPR。

Unseen AUPR：将评估限定在训练阶段从未遇到的标签子集上计算的 AUPR。

为评价模型在已知知识拟合与新概念泛化之间的权衡，计算二者的调和均值（Harmonic Mean, H）：

$$H = \frac{2 \cdot \mathrm{AUPR}_{seen} \cdot \mathrm{AUPR}_{unseen}}{\mathrm{AUPR}_{seen} + \mathrm{AUPR}_{unseen}} \tag{3-17}$$

只有当模型在已见和未见标签上均表现良好时，H 值才会较高，因此它是衡量模型是否实现了鲁棒泛化而非仅仅过拟合已见类别的关键指标。

3.4.3.3 加权评价指标

为考虑 GO 术语的不同特异性，本文还采用了基于信息内容（Information Content, IC）加权的评价指标。每个 GO 术语 v 被赋予权重 $\tau(v) = -\log(p(v))$，其中 $p(v)$ 是该术语在数据库中出现的概率。

加权精确率与加权召回率。对于蛋白质 i 在阈值 t 下的加权精确率 $w\pi_i(t)$ 和加权召回率 $w\rho_i(t)$ 定义为：

$$w\pi_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in P_i(t)} \tau(v)}, \quad w\rho_i(t) = \frac{\sum_{v \in P_i(t) \cap T_i} \tau(v)}{\sum_{v \in T_i} \tau(v)} \tag{3-18}$$

类似地，wF_{max} 为加权精确率和加权召回率在所有阈值上的最大调和均值，$wAUPR$ 为加权精确率-召回率曲线下面积。

语义距离 S_{min}。S_{min} 基于信息内容评估预测结果与真实标签之间的语义距离，结合剩余不确定性（Remaining Uncertainty, RU）和误信息（Misinformation, MI）两个维度：

$$RU(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in T_i \setminus P_i(t)} \tau(v), \quad MI(t) = \frac{1}{N} \sum_{i=1}^{N} \sum_{v \in P_i(t) \setminus T_i} \tau(v) \tag{3-19}$$

$$S_{min} = \min_{t \in [0,1]} \sqrt{RU(t)^2 + MI(t)^2} \tag{3-20}$$

S_{min} 值越低表示预测结果在语义层面与真实标签越接近，该指标对功能特异性较高的 GO 术语赋予更大的权重，能够更好地评估模型对生物学上重要的精细功能的预测能力。

3.5 实验结果与分析

3.5.1 标准测试集上的性能对比

表 3-4汇总了 MZSGO 与所有基线方法在三个本体上的性能对比结果。

3.5.1.1 有监督性能分析

在常规分类指标（Fmax 和 AUPR）方面，MZSGO 在三个本体上均取得了最优或极具竞争力的结果，凸显了多模态融合方法的有效性。

在最具挑战性的 BP 本体中，MZSGO 以 0.5045 的 Fmax 超过了域感知方法 DPFunc（0.4984）和神经符号推理方法 DeepGO-SE（0.5006）。在 MF 和 CC 本体上，MZSGO 分别以 0.7611 和 0.7470 的 Fmax 保持领先。值得注意的是，MZSGO 在 CC 本体上的 AUPR 达到 0.7726，刷新了该本体的最优记录。

与仅依赖单一模态的方法相比，MZSGO 通过自适应门控融合机制有效整合了蛋白质序列特征（ESM）与域描述语义，使模型能够综合利用互补的语义线索，产生更强的特征表示。

3.5.1.2 训练集过滤策略的有效性验证

如3.2节所述，本文对训练集实施了本体特异性过滤策略。为验证这一决策的

表 3-4: MZSGO 与最先进方法在测试集上的性能对比。最优结果加粗，次优结果加下划线。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	Naive	0.2991	0.2073	0.0025	0.2076	0.0049
	Diamond	0.4703	0.2913	0.0025	0.2934	0.0050
	DeepGOCNN	0.3964	0.3676	0.0025	0.3684	0.0050
	DeepGOZero	0.4888	0.4535	0.0025	0.4558	0.0050
	Struct2GO	0.4022	0.3744	0.0025	0.3747	0.0050
BP	PO2GO	0.2975	0.2303	0.0025	0.2307	0.0049
	DeepGO-SE	0.5006	0.4373	0.0025	0.4404	0.0050
	ProtGO	0.4636	0.4377	0.0025	0.4410	0.0050
	DPFunc	0.4984	0.4902	0.0069	0.4936	0.0136
	ProtNote	0.3555	0.2993	0.0303	0.2997	0.0550
	MZSGO	**0.5045**	**0.5008**	**0.2393**	**0.5021**	**0.3241**
	Naive	0.5496	0.3318	0.0032	0.3327	0.0063
	Diamond	0.6727	0.3330	0.0032	0.3366	0.0063
	DeepGOCNN	0.6603	0.5225	0.0032	0.5242	0.0064
	DeepGOZero	0.7441	0.6333	0.0032	0.6380	0.0064
	Struct2GO	0.6564	0.5940	0.0032	0.5962	0.0064
MF	PO2GO	0.5496	0.4136	0.0032	0.4148	0.0064
	DeepGO-SE	0.7481	0.6332	0.0032	0.6376	0.0064
	ProtGO	0.7262	0.7399	0.0032	0.7453	0.0064
	DPFunc	0.7495	**0.7416**	0.0051	**0.7480**	0.0101
	ProtNote	0.6140	0.5283	0.0490	0.5301	0.0897
	MZSGO	**0.7611**	0.7337	**0.4806**	0.7380	**0.5821**
	Naive	0.6143	0.0793	0.0207	0.5270	0.0398
	Diamond	0.6331	0.3076	0.0207	0.3093	0.0388
	DeepGOCNN	0.6918	0.5284	0.0207	0.5292	0.0398
	DeepGOZero	0.7075	0.6598	0.0207	0.6612	0.0401
	Struct2GO	0.6989	0.7380	0.0207	0.7382	0.0403
CC	PO2GO	0.6143	0.5828	0.0207	0.5830	0.0400
	DeepGO-SE	0.7379	0.6991	0.0207	0.7003	0.0402
	ProtGO	0.7209	0.7717	0.0207	0.7727	0.0403
	DPFunc	0.7386	0.7709	0.0274	0.7722	0.0529
	ProtNote	0.6636	0.6605	0.2530	0.6607	0.3659
	MZSGO	**0.7470**	**0.7726**	**0.5862**	**0.7733**	**0.6669**

合理性，本文在 Swiss-Prot 数据库中 CAFA5 完整训练集（72,390 条蛋白质）上进行了对比实验。完整训练集不可避免地包含了对某一目标本体类别缺乏注释的蛋白质，这些隐式的" 负样本" 可能对模型训练产生干扰。

实验结果表明，将蛋白质功能预测建模为二分类问题的方法（如 ProtNote 和 MZSGO）在完整数据集上表现出更强的鲁棒性，不会出现显著的性能退化。具体而言，MZSGO 在未过滤的完整训练集上仍能在所有三个本体类别的 Fmax 和 AUPR 指标上一致性地超越最新基线方法（ProtGO、DPFunc 和 ProtNote）。然而，需要注意的是，多数基线方法（特别是多标签分类范式的方法）在完整数据集上的性能受到了负面影响。这是因为缺乏特定本体注释的蛋白质在训练过程中被隐式地视为该本体所有标签的负样本，引入了大量错误的监督信号。本文最终采用过滤后的训练集，一方面是为了追求最优性能，另一方面更重要的是确保与所有基线方法进行严格公平的比较。

3.5.1.3 零样本性能分析

MZSGO 的核心优势在于其对未见标签的推理能力。表 3-4中的 Unseen AUPR 和调和均值 H 直观地反映了这一点。

传统比对方法和标准深度学习模型在零样本场景中表现出极为有限的泛化能力。这主要是因为这些模型将标签视为独立的 one-hot 标识符，在训练过程中，优化目标自然地抑制了未见标签对应的权重，迫使模型对训练集中未出现的类别预测接近零的概率。值得注意的是，尽管 DeepGOZero 理论上能够通过逻辑约束实现零样本预测，但它在缺乏显式 GO 公理的罕见类别上预测失效，Unseen AUPR 接近 0。

ProtNote 利用 LLM 展示了一定的零样本能力（如 BP 上的 0.0303），但 MZSGO 大幅超越了它。具体而言，MZSGO 在 BP 本体上实现了 0.2393 的 Unseen AUPR——相较 ProtNote 提升了约 **8 倍**。在 MF 和 CC 本体上同样观察到一致的趋势，MZSGO 分别实现了 0.4806 和 0.5862 的 Unseen AUPR。

综合平衡已见和未见标签性能的调和均值 H 进一步凸显了模型的全面优势。MZSGO 在 BP、MF、CC 上分别获得 0.3241、0.5821 和 0.6669 的 H 值，大幅超越亚军 ProtNote 的 0.0550、0.0897 和 0.3659。这一结果证实 MZSGO 不仅仅是记忆训练标签，而是学到了蛋白质特征与功能描述之间的泛化性语义对齐。

3.5.2 纯零样本测试集上的评估

为进一步严格验证泛化能力，本文在专门构建的纯零样本测试集上将 MZSGO 与零样本能力最强的基线方法 ProtNote 进行直接对比。结果如表 3-5所示。

表 3-5: 纯零样本测试集上的性能对比。该评估集通过时间演进方式构建，评估模型对 2025 版本中新出现但训练截止日期前不存在的 GO 功能标签的预测能力。

本体	模型	Fmax	AUPR	Precision	Recall
BP	ProtNote	0.3763	0.2705	0.2580	**0.6951**
	MZSGO	**0.4881**	**0.4546**	**0.4475**	0.5369
MF	ProtNote	0.3599	0.3393	0.4545	0.2979
	MZSGO	**0.5982**	**0.5435**	**0.6261**	**0.5727**
CC	ProtNote	0.2983	0.1652	0.1853	0.7647
	MZSGO	**0.6610**	**0.6291**	**0.5521**	**0.8235**

MZSGO 在所有三个本体的 Fmax 和 AUPR 上均一致超越 ProtNote。对精确率和召回率的精细分析揭示了两种方法的行为差异和改进方向：

（1）**BP 本体的平衡精确率-召回率权衡**：ProtNote 展现了较高的召回率（0.6951）但精确率低下（0.2580），表明其倾向于过度预测功能标签。相比之下，MZSGO 实现了更均衡的权衡，将精确率提升至 0.4475 的同时保持了 0.5369 的竞争性召回率，从而获得了显著更高的 Fmax（0.4881 vs. 0.3763）。

（2）**MF 和 CC 本体的全面优势**：在 MF 本体上，MZSGO 获得 0.5982 的 Fmax（ProtNote 为 0.3599），精确率（0.6261 vs. 0.4545）和召回率（0.5727 vs. 0.2979）双双领先。在 CC 本体上，性能差距最为显著：ProtNote 的精确率仅为 0.1853，可能是由于广泛文本匹配导致的” 功能幻觉”；而 MZSGO 达到 0.5521 的精确率，同时召回率也优于 ProtNote（0.8235 vs. 0.7647），实现了 Fmax 从 0.2983 到 0.6610 的翻倍提升。

这一对比结果表明，MZSGO 通过将预测锚定在域特异性的语义空间中，有效避免了其他基于文本的模型中常见的噪声和假阳性问题，为蛋白质新功能注释提供了高度可靠的预测能力。

3.5.3 消融实验

为评估各组件的贡献——特别是多模态特征、融合模块和优化策略，本文在 CC 本体上进行了系统的消融实验。消融变体分为五组：（1）单模态编码器；（2）特征表示变化；（3）架构变化；（4）编码器替换；（5）损失函数变体。结果如表 3-6所示。

从消融结果中可以得出以下关键结论：

（1）**域语义信息是零样本能力的关键**。移除域语义信息造成最严重的性能退

表 3-6: CC 本体上的消融实验结果。报告指标包括总体 Fmax 和 AUPR，以及零样本相关指标。H 为已见与未见标签性能的调和均值。

方法	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7319	0.7344	0.5203	0.0793	0.6094
仅域特征	0.7311	0.7052	0.5187	0.2322	0.6012
特征与架构消融					
域信息 One-hot 编码	0.7203	0.6731	0.5047	0.2000	0.5889
使用 PO2Vec 标签嵌入	0.7406	0.7196	0.3193	0.1818	0.4423
去除特征丢弃	**0.7544**	0.6857	0.4898	0.2500	0.5714
简单拼接替代门控融合	0.7381	0.7009	0.5245	0.2469	0.6000
编码器变体					
BioGPT	0.7419	0.7198	0.4258	0.1935	0.5351
BiomedBERT	0.7406	0.7218	0.5647	0.2000	0.6337
Qwen3-0.6B	0.7406	0.7282	0.5469	0.1379	0.6247
ESM-150M	0.7385	0.7310	0.3864	0.1333	0.5056
损失函数变体					
BCE 损失	0.7501	0.7143	0.5824	0.2581	0.6421
加权 BCE 损失	0.7199	0.7450	0.5127	0.4444	0.6095
MZSGO	0.7470	**0.7726**	**0.5862**	**0.5665**	**0.6669**

化：仅使用 ESM 特征时，Unseen Fmax 从 0.5665 骤降至 0.0793，表明序列特征本身难以泛化到未见标签。仅使用域特征时 Unseen Fmax 为 0.2322，远优于仅用 ESM；而将域信息退化为 One-hot 编码后 Unseen Fmax 降至 0.2000，证实零样本迁移依赖于域描述的语义内容而非简单标识符。

（2）**门控融合机制不可或缺**。将门控融合替换为简单拼接使 H 从 0.6669 降至 0.6000，说明朴素拼接无法有效整合异构模态。使用 PO2Vec 标签嵌入替代文本嵌入更是导致 H 降至 0.4423，这是因为基于图拓扑的 PO2Vec 嵌入与序列和文本模态的语义对齐度较低。

（3）**特征丢弃策略增强泛化能力**。去除特征丢弃后，已见标签准确度略有提升（Fmax 达 0.7544），但零样本泛化显著下降（H 从 0.6669 降至 0.5714），验证了其作为正则化手段的重要性。

（4）**编码器选择的合理性**。各替代编码器的性能均不及当前组合，证实 MZSGO 选择的编码器（ESM2-650M + Qwen3-Embedding-4B）最能捕获跨模态的互补结构信息。

（5）**Focal Loss 在 CC 本体上的优势**。标准 BCE 获得较高的 Fmax（0.7501）但总体 AUPR 偏低（0.7143）；加权 BCE 虽改善了 Unseen Fmax（0.4444）但损害了总体 AUPR 和 H 值。Focal Loss（MZSGO）通过有效平衡困难样本的学习，实现了最优的综合权衡。

3.5.3.1 BP 和 MF 本体的消融验证

为进一步验证框架的鲁棒性和可推广性，本文将消融实验扩展至 BP 和 MF 本体。实验设置和变体分组与 CC 本体消融完全一致。

表 3-7和表 3-8分别展示了 BP 和 MF 本体上的消融结果，其发现与 CC 本体的结论高度一致。

从 BP 和 MF 本体的消融结果中，可以提炼出以下跨本体的一致性发现：

（1）**多模态融合的必要性**。依赖单一模态（仅 ESM 或仅域特征）在三个本体上均导致显著的性能下降，特别是在零样本指标（Unseen AUPR 和 H 值）方面。值得注意的是，在 BP 本体上，单模态模型的 H 值仅为 0.1520（仅 ESM）和 0.1308（仅域），远低于 MZSGO 的 0.3250，凸显了多模态融合对于处理复杂生物过程分类的关键作用。

（2）**语义对齐的优越性**。用传统方法（域 One-hot 编码或 PO2Vec 标签嵌入）替代 LLM 文本嵌入，在三个本体上均严重损害零样本性能。以 BP 本体为例，使用 PO2Vec 标签嵌入的 H 值仅为 0.1595，远低于 MZSGO 的 0.3250。这再次证实了基于深度语义表示的标签理解对于零样本迁移的不可替代性。

表 3-7: BP 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.4584	0.4278	0.0924	0.0446	0.1520
仅域特征	0.4552	0.4208	0.0774	0.0334	0.1308
特征与架构消融					
域信息 One-hot 编码	0.4833	0.4550	0.2309	0.1182	0.3066
使用 PO2Vec 标签嵌入	0.4948	0.4721	0.0959	0.0534	0.1595
去除特征丢弃	0.4992	0.4794	0.2231	0.1440	0.3047
简单拼接替代门控融合	0.4849	0.4602	0.0700	0.0352	0.1215
编码器变体					
BioGPT	0.4877	0.4650	0.1584	0.1153	0.2364
BiomedBERT	0.4829	0.4569	0.1801	0.0931	0.2608
Qwen3-0.6B	0.4842	0.4590	0.1964	0.0967	0.2752
ESM-150M	0.4799	0.4540	0.1730	0.1176	0.2506
损失函数变体					
Focal Loss	0.4791	0.4787	0.1166	0.1901	0.1876
加权 BCE 损失	0.4821	0.4580	0.1755	**0.2141**	0.2542
MZSGO	**0.5045**	**0.5008**	**0.2393**	0.1210	**0.3250**

表 3-8: MF 本体上的消融实验结果。

模型变体	Fmax	AUPR	Unseen AUPR	Unseen Fmax	H
模态消融					
仅 ESM 特征	0.7322	0.6890	0.2502	0.1516	0.3675
仅域特征	0.7380	0.6986	0.4655	0.3966	0.5598
特征与架构消融					
域信息 One-hot 编码	0.7376	0.7041	0.3149	0.2367	0.4359
使用 PO2Vec 标签嵌入	0.7414	0.7014	0.3772	0.3871	0.4916
去除特征丢弃	0.7517	0.7104	0.4800	0.4206	0.5740
简单拼接替代门控融合	0.7446	0.7035	0.3951	0.3050	0.5069
编码器变体					
BioGPT	0.7506	0.7223	0.4512	0.4290	0.5566
BiomedBERT	0.7508	0.7206	0.4513	0.4485	0.5562
Qwen3-0.6B	0.7440	0.7111	0.3745	0.3428	0.4915
ESM-150M	0.7497	0.7202	0.4656	0.3527	0.5667
损失函数变体					
Focal Loss	0.7280	0.6938	0.4286	0.4835	0.5309
加权 BCE 损失	0.7372	0.7074	**0.5526**	**0.5585**	**0.6234**
MZSGO	**0.7611**	**0.7337**	0.4806	0.4259	0.5821

（3）**架构设计的有效性**。简单拼接替代门控融合和去除特征丢弃策略在三个本体上均导致性能退化。在 BP 本体上，简单拼接的 H 值骤降至 0.1215——甚至低于部分单模态变体——说明在信息极度异构的 BP 分类任务中，朴素拼接不仅无法有效利用多模态信息，反而可能引入噪声。

（4）**损失函数选择的本体依赖性**。MF 本体的消融结果揭示了一个有趣的现象：加权 BCE 损失在 MF 上取得了最高的 Unseen AUPR（0.5526）和 H 值（0.6234），超过了 MZSGO 采用的标准 BCE 损失。然而，加权 BCE 在 MF 上的总体 Fmax（0.7372）和 AUPR（0.7074）均低于 MZSGO（0.7611 和 0.7337）。相反，在 BP 本体上，Focal Loss 变体的 H 值仅为 0.1876，远低于标准 BCE 的 0.3250，表明 Focal Loss 并不适合 BP 的数据特性。这些发现验证了本文为不同本体选择不同损失函数策略的合理性：BP 和 MF 使用标准 BCE 以追求最佳的综合性能，CC 使用 Focal Loss 以应对其极端的类别不平衡。

3.5.4 参数敏感性分析

为评估模型的鲁棒性，本文考察了两个关键超参数的影响：Dropout 率和隐藏向量维度。采用控制变量法，每次仅变动一个参数，在 CC 和 MF 本体上观察 AUPR 的波动。

3.5.4.1 Dropout 率的影响

Dropout 率应用于特征提取后的神经元级丢弃，取值范围为 0.3 至 0.7。模型在 Dropout 率为 0.5 时表现最佳，CC 本体 AUPR 达 0.7726，MF 本体达 0.7377。较低的 Dropout 率（如 0.3）导致过拟合和泛化能力下降；较高的 Dropout 率（如 0.7）因过度信息丢失使性能退化（CC 降至 0.7610，MF 降至 0.7228）。因此，0.5 被选为最优配置。

3.5.4.2 隐藏向量维度的影响

隐藏维度从 128 变化至 1024。随着维度从 128 扩展至 512，两个本体的性能持续提升。CC 本体在 512 维时达到峰值（AUPR 为 0.7726），此后随维度增大而退化。MF 本体在 1024 维时仍有提升（AUPR 达 0.8133），但 CC 本体在该维度下显著下降至 0.7371。为构建跨 GO 类别通用的模型架构而无需针对特定任务进行调整，最终将隐藏维度设定为 512，在表征能力和计算成本之间取得了良好的平衡。

3.5.5 嵌入空间可视化分析

为深入理解 MZSGO 实现零样本预测的内在机制，本文对域嵌入和功能文本嵌入的空间分布进行了可视化分析。

3.5.5.1 域嵌入与功能嵌入的空间关系

使用 t-SNE 降维技术对 MF 和 CC 本体中蛋白质域嵌入和 GO 标签功能文本嵌入的空间分布进行可视化。可视化结果揭示了鲜明的聚类模式：在模型正确预测的样本中，蛋白质域嵌入向量在空间上与其对应的功能文本嵌入向量更为接近。在 MF 和 CC 两个本体中，正确预测样本的域嵌入与功能文本嵌入之间的欧几里得距离一致性地小于错误预测样本。

这一观察结果为 MZSGO 的零样本能力提供了直观的解释：模型学会了在统一的语义空间中建立蛋白质域特征与功能语义描述之间的有效映射。当一个蛋白质的域描述与某个 GO 标签的定义在语义上高度相似时（即在嵌入空间中距离较近），即使该 GO 标签在训练中从未出现，模型也能够基于这种语义邻近性做出正确的零样本预测。

3.5.5.2 零样本预测的文本语义分析

为进一步揭示模型成功预测的深层原因，本文分析了 InterPro 域描述与 GO 标签定义之间的文本语义对应关系。以 CC 本体的零样本预测为例进行案例研究：在成功预测的案例中，域描述与 GO 标签定义之间存在大量共享或语义相近的关键词。

例如，当蛋白质具有”membrane-associated” 类型的域描述时，模型能够正确预测其与”membrane” 相关的 CC 功能标签，即使这些标签在训练集中从未出现。域描述中的”integral membrane protein”、”transmembrane helix” 等关键短语与 GO 标签”integral component of membrane” 定义中的核心概念形成了语义桥梁。这种文本级别的语义对齐通过 Qwen3-Embedding 模型被有效编码，使得 MZSGO 能够超越简单的模式记忆，实现基于深层语义理解的零样本功能推断。

相反，在预测失败的案例中，域描述与目标 GO 标签之间缺乏明确的语义关联，或者域描述过于笼统而无法提供针对性的功能线索。这一分析为未来改进 MZSGO 指明了方向——引入更丰富的域语义信息或更精细的语义对齐策略可能进一步提升零样本性能。

3.5.6 自适应门控权重分析

为深入理解 MZSGO 如何整合多模态信息，本文分析了门控融合模块分配给三种模态——域特征（α）、ESM 序列特征（β）和 NLP 文本特征（γ）——的平均门控权重在三个 GO 本体上的分布情况。门控权重是动态学习的，反映了模型在不同预测任务中对特定模态的依赖程度。

3.5.6.1 各本体的门控权重特征

CC 本体表现出对域特征的高度依赖，总体平均权重达 83.60%，在未见标签上更是上升至 91.23%。这一发现与消融实验的结果完全一致——在 CC 消融实验中，仅域特征模型的零样本性能（Unseen Fmax = 0.2322）显著优于仅 ESM 模型（Unseen Fmax = 0.0793）。CC 本体描述的是蛋白质的亚细胞定位，而特定的蛋白质域和基序（如信号肽、跨膜域、核定位信号等）往往直接决定了蛋白质的亚细胞位置，因此域信息对 CC 预测提供了最为直接的泛化信号。

BP 本体的模型在已见标签上优先使用 ESM 序列特征（权重为 53.66%），这可能是因为序列同源性在已知功能预测中是一个强有力的预测因子。然而，对于”零样本标签”（训练样本极少或没有的标签），一个显著的偏移出现了：模型增加了对域特征（从总体的 31.11% 上升至 44.76%）和 NLP 特征的依赖。这种自适应偏移展示了 MZSGO 在序列模式不足以应对罕见或新颖类别时，能够灵活地利用语义域描述作为补充信息源的能力。

MF 本体呈现出域特征（约 48%）和 ESM 特征（约 48%）之间的均衡分布，表明酶活性和结合功能的预测同时需要域提供的结构线索和 ESM 编码器捕获的精细残基信息。这种平衡反映了 MF 功能标签的双重特性——既依赖于保守的功能域模体，又与序列层面的精细特征密切相关。

3.5.6.2 已见与未见标签的门控偏移

跨三个本体的一个共性规律是：从已见标签到未见标签，门控权重始终向域特征和 NLP 文本特征偏移。这一现象有着深刻的生物学解释——对于已知功能，模型可以依赖通过大量训练样本学习到的序列模式进行预测；而对于未见功能，序列模式可能不再适用（因为缺乏相应的训练信号），此时域的结构功能语义和 GO 标签的文本定义成为唯一可用的推理依据。

门控权重分析进一步证实了 MZSGO 并非简单地对多模态信息进行平均融合，而是根据本体特性和目标标签的具体性质（已见 vs. 未见）自适应地选择最具信息量的表示来源。这种动态选择机制是 MZSGO 实现优异零样本性能的关键技术基础。

3.5.7 加权评价指标实验

除标准指标外，本文还采用基于信息内容加权的评价指标进一步评估 MZSGO 的预测质量。这些加权指标为功能特异性更高的 GO 术语赋予更大的权重，能够更准确地衡量模型对生物学上更为重要的精细功能的预测能力。表 3-9总结了 MZSGO 与最新基线方法在三个本体上的加权指标对比。

表 3-9: 加权评价指标（wF_{max}、$wAUPR$ 和 S_{min}）在三个 GO 本体上的对比。S_{min} 越低表示性能越好。

模型	BP			MF			CC		
	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$	wF_{max}	$wAUPR$	$S_{min}\downarrow$
ProtGO	0.4231	0.3582	37.0125	0.6634	0.5312	9.3241	0.6315	0.5553	9.5712
DPFunc	**0.4562**	**0.4265**	35.4012	0.6912	0.6431	8.6325	0.6521	0.6412	9.0834
ProtNote	0.3065	0.2384	40.9251	0.5301	0.4105	12.0812	0.5174	0.4776	11.1623
MZSGO	0.4560	0.4201	**34.8821**	**0.7015**	**0.6462**	**8.6105**	**0.6573**	**0.6478**	**8.9012**

从加权指标的对比中可以得出以下分析：

（1）在 MF 和 CC 本体上，MZSGO 在所有三个加权指标上均取得最优。在 MF 本体上，wF_{max} 达 0.7015，$wAUPR$ 达 0.6462，S_{min} 降至 8.6105，全面超越 DPFunc 和 ProtGO。这表明 MZSGO 不仅在整体覆盖度上表现优异，对于功能特异性较高、信息内容较大的 GO 术语也保持了良好的预测精度。

（2）在 BP 本体上，MZSGO 的 wF_{max}（0.4560）与 DPFunc（0.4562）极为接近，但 S_{min} 指标（34.8821 vs. 35.4012）优于 DPFunc，说明 MZSGO 在语义距离层面更接近真实标签。BP 本体的生物过程标签层级结构最为复杂，标签间的语义重叠度高，加权指标上的微小差距反映了这一挑战的本质难度。

（3）ProtNote 在加权指标上的表现显著劣于其他方法（尤其是 S_{min} 高达 40.9251 和 12.0812），这进一步说明 ProtNote 虽然能够进行零样本预测，但其预测质量（特别是对生物学上重要的精细功能的预测精度）仍有较大差距。ProtNote 采用的简单 one-hot 序列编码和联合训练策略限制了其对功能语义细节的捕获能力。

3.5.8 层级一致性与 True Path Rule 分析

Gene Ontology 的 GO 术语以有向无环图（DAG）的形式组织，这暗含了 True Path Rule（TPR）[34]：如果一个蛋白质被注释了某个特定术语，则它必须同时被注释该术语的所有祖先术语。反之，如果一个蛋白质未被注释某个术语，则它不能被注释该术语的任何后代术语。

3.5.8.1 层级传播机制

为评估显式的层级约束是否能增强 MZSGO 的性能，本文实现了后处理层级传播机制，记为 **MZSGO_PROP**。给定蛋白质在 L 个标签上的原始预测分数 S，通过按照 DAG 结构将子节点的最大分数传播至父节点来确保层级一致性：

$$S_p^* = \max\left(S_p, \max_{c\in\text{children}(p)} S_c\right) \tag{3-21}$$

其中 S_p 为父术语的原始分数，S_p^* 为校正后的分数。这保证了父术语的预测分数始终大于等于其任何后代术语的分数。

3.5.8.2 实验结果与讨论

表 3-10比较了原始 MZSGO 和引入 TPR 传播后的 MZSGO_PROP 在三个本体上的性能。

表 3-10: 原始 MZSGO 与引入 True Path Rule 传播的 MZSGO_PROP 的性能对比。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
BP	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
	MZSGO_PROP	**0.5066**	**0.5046**	**0.2394**	**0.5060**	**0.3250**
MF	MZSGO	0.7611	0.7337	**0.4806**	0.7380	0.5821
	MZSGO_PROP	**0.7628**	**0.7356**	**0.4806**	**0.7399**	**0.5827**
CC	MZSGO	0.7470	0.7726	**0.5862**	0.7733	0.6669
	MZSGO_PROP	**0.7482**	**0.7736**	**0.5862**	**0.7743**	**0.6672**

从实验结果可以观察到，引入显式的 TPR 传播仅带来了边际性的改善（例如 Fmax 提升不足 0.3%）。这一发现具有重要的方法学意义，表明 MZSGO 的多模态匹配机制**天然地具备了隐式捕获层级依赖关系的能力**。

分析其原因，基于 LLM 的 GO 定义嵌入在潜在空间中将语义上（因此也是层级上）相关的术语定位在相近的位置。由于 GO 的层级结构中，父术语的定义通常是子术语定义的语义泛化——例如”kinase activity”（父）与”protein kinase activity”（子）——LLM 编码器自然会为它们生成相似的嵌入表示。这意味着当模型预测某个蛋白质与子术语匹配时，由于父术语嵌入的相近性，模型也倾向于给予父术语较高的匹配分数，从而在不需要显式层级约束的情况下隐式地满足了 True Path Rule。

这一结果进一步验证了基于 LLM 语义嵌入的 MZSGO 方法在蛋白质功能预测任务中的合理性——深层语义表示不仅能够支持零样本推理，还能自然地编码 GO 的拓扑层级信息，避免了传统方法中复杂的后处理层级传播步骤或刚性的架构约束。

3.6 本章小结

本章提出了多模态零样本蛋白质功能注释方法 MZSGO，其核心创新在于三个方面：（1）将蛋白质功能预测从封闭标签集分类重新定义为开放语义空间中的蛋白质-GO 匹配问题，通过大语言模型构建域和标签的统一语义空间，从根本上赋予模型零样本推理能力；（2）设计了自适应门控融合模块，实现逐样本动态的

多模态特征整合，克服了传统简单拼接方式的局限；（3）引入非对称特征丢弃策略，在训练阶段增强模型对模态缺失的鲁棒性。

实验结果表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下则以压倒性优势超越所有现有方法。其中，在最具挑战性的 CC 本体零样本场景下，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍。

通过多维度的深入分析，本章对 MZSGO 的各个组件和设计决策进行了全面验证：消融实验在三个本体上一致性地证明了域语义信息、门控融合机制和特征丢弃策略各自的不可替代性；基于 Gini 系数和有效性比率的统计分析为不同本体的损失函数选择提供了理论依据；嵌入空间可视化分析直观地揭示了 MZSGO 通过域-功能语义邻近性实现零样本推理的内在机制；门控权重分析证实了模型能够根据本体特性和标签可见性动态调整多模态信息的整合策略；加权评价指标实验验证了 MZSGO 对功能特异性较高的 GO 术语同样保持了优异的预测精度；True Path Rule 实验则表明基于 LLM 语义嵌入的方法天然地编码了 GO 的层级拓扑信息。综上，MZSGO 为蛋白质功能注释，特别是新功能标签的预测，提供了可靠且有效的计算工具。

第 4 章 基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA

第三章提出的 MZSGO 方法通过多模态语义融合在蛋白质功能预测任务上取得了优异的性能，尤其在零样本场景下展现了显著的优势。然而，MZSGO 存在一个本质局限：蛋白质语言模型 ESM2 被用作静态特征提取器，其参数在下游训练中保持冻结，无法根据功能预测任务进行自适应调整。这意味着 ESM2 输出的序列嵌入仅包含通用的进化信息，缺乏与蛋白质域功能语义相关的先验知识。同时，由于域嵌入在训练前即已预计算并缓存，整个管线缺乏端到端的梯度流动，限制了模型进一步提升的空间。

针对上述问题，本章提出基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA（MZSGO with Domain-Aware adapter pretraining）。MZSGO-DA 的灵感来源于 S-PLM[25]——一种结构感知的蛋白质语言模型。S-PLM 通过在 ESM2 的 Transformer 层中注入轻量级适配器模块，利用对比学习将蛋白质三维结构信息蒸馏至序列编码器，使其仅凭序列输入即可生成包含结构感知的表示。MZSGO-DA 借鉴了 S-PLM" 通过对比学习将跨模态知识蒸馏至适配器" 这一核心思想，但在以下方面进行了重要的拓展和创新：

（1）**蒸馏目标不同**。S-PLM 的蒸馏目标是蛋白质三维结构信息，而 MZSGO-DA 将其替换为蛋白质域的功能语义信息。蛋白质域作为独立的功能和结构单元，其自然语言描述蕴含着丰富的功能先验，与蛋白质功能预测任务的关联性更为直接。

（2）**下游训练策略不同**。S-PLM 在预训练后采用冻结或微调适配器的常规策略应用于下游任务。MZSGO-DA 则创新性地提出了双适配器端到端训练策略——冻结预训练适配器以保留域语义先验，同时引入第二组可训练适配器进行任务特定适配，实现了预训练知识保留与下游任务优化的有效平衡。

（3）**域嵌入的处理方式不同**。S-PLM 的结构编码器（Swin-Transformer）在预训练时直接处理蛋白质接触图，而 MZSGO-DA 使用预训练的大语言模型 Qwen3-Embedding 对域文本描述进行语义编码，将自然语言级别的功能先验引入蛋白质表示学习。

4.1 动机分析

MZSGO 采用静态嵌入策略：首先使用冻结的 ESM2 提取所有蛋白质的序列

嵌入并缓存至磁盘，然后在训练阶段直接读取这些预计算的向量。这种策略虽然计算高效，但存在三方面不足：

（1）**信息瓶颈**。ESM2 的通用预训练目标是掩码语言建模，学习到的表示侧重于序列进化约束和氨基酸共现模式，而非特定于功能预测任务的信息。当功能注释依赖于蛋白质域的结构功能特征时，通用序列嵌入可能丢失关键线索。

（2）**梯度断裂**。由于 ESM2 参数完全冻结且嵌入预计算，下游分类器的梯度无法回传至序列编码器，模型无法通过反向传播调整序列表征以更好地适配功能预测目标。

（3）**域信息依赖**。MZSGO 在推理时需要显式输入蛋白质的域嵌入，而 InterPro 数据库中约 20% 的蛋白质缺乏域注释，这部分蛋白质只能使用零向量作为域特征占位符，降低了预测质量。

MZSGO-DA 通过两阶段策略系统性地解决上述问题。受 S-PLM[25] 利用对比学习在适配器中蒸馏结构信息的启发，MZSGO-DA 将这一思路应用于域语义信息的蒸馏：第一阶段（预训练），通过对比学习将域语义信息”内化”至序列编码器的适配器参数中；第二阶段（下游训练），通过端到端训练打通梯度通路，使序列表征能够根据功能预测目标进行自适应调整。与 S-PLM 的单适配器预训练策略不同，MZSGO-DA 引入了双适配器机制，冻结预训练适配器以保护域知识，同时引入可训练适配器进行任务适配。预训练完成后，即使不显式输入域信息，序列编码器也能产出包含域语义先验的增强表示。

4.2 MZSGO-DA 方法设计

4.2.1 总体框架

MZSGO-DA 的训练流程分为两个阶段，如图 4-1所示。

第一阶段：域感知对比学习预训练。在 ESM2 的 Transformer 层中注入一组轻量级适配器模块（记为 adapter_0），冻结 ESM2 原始参数，仅训练适配器参数。通过 InfoNCE 对比学习损失，将蛋白质序列的适配器增强表示与对应的域文本嵌入（由 Qwen3-Embedding 预计算）进行对齐。预训练完成后，adapter_0 中编码了蛋白质域的语义先验。

第二阶段：双适配器端到端下游训练。冻结 adapter_0 的参数，在同一 ESM2 模型中注入第二组适配器（adapter_1），使其可训练。两组适配器在每个 Transformer 层内并行运行，输出取平均。adapter_0 保持域语义先验，adapter_1 学习任务特定的适配信息。序列经 ESM2+ 双适配器编码后，与 GO 标签文本嵌入进行门控融合，最终输出功能预测概率。

图 4-1: MZSGO-DA 两阶段训练流程。第一阶段通过对比学习将域语义信息蒸馏至适配器；第二阶段冻结预训练适配器，引入新适配器进行端到端功能预测训练。

4.2.2 适配器模块设计

本文设计了基于残差多层感知机（ResMLP）的轻量级适配器模块。每个适配器由降维线性层、ReLU 激活函数、升维线性层和层归一化组成，并通过残差连接保留原始信息流：

$$\text{Adapter}(\mathbf{x}) = \text{LN}(\mathbf{W}_{up} \cdot \text{ReLU}(\mathbf{W}_{down} \cdot \mathbf{x})) + \mathbf{x} \tag{4-1}$$

其中 $\mathbf{W}_{down} \in \mathbb{R}^{d_b \times d}$ 为降维矩阵，$\mathbf{W}_{up} \in \mathbb{R}^{d \times d_b}$ 为升维矩阵，$d = 1280$ 为 ESM2 的隐藏维度，$d_b = d/2 = 640$ 为瓶颈维度，LN 为层归一化。

与传统适配器设计[22] 不同，本文采用**纯净残差连接**策略，即残差加法在层归一化之外执行。这一设计借鉴了 S-PLM[25] 中适配器的架构经验，避免了层归一化包裹残差连接可能引发的梯度缩放问题，有助于在深层 Transformer 网络中保持稳定的梯度传播。

4.2.3 适配器注入机制

适配器模块被注入 ESM2 Transformer 层的两个关键位置：

（1）**自注意力输出之后**：在多头自注意力的输出（残差连接之前）插入适配器，使其能够调制注意力模式：

$$\mathbf{X}_{attn} = \text{MHA}(\text{LN}(\mathbf{X})) \tag{4-2}$$

$$\mathbf{X}'_{attn} = \text{Adapter}_{attn}(\mathbf{X}_{attn}) \tag{4-3}$$

$$\mathbf{X}' = \mathbf{X} + \mathbf{X}'_{attn} \tag{4-4}$$

（2）**前馈网络输出之后**：在 FFN 的输出（残差连接之前）插入适配器，使其能够调制特征变换：

$$\mathbf{X}_{ffn} = \text{FFN}(\text{LN}(\mathbf{X}')) \tag{4-5}$$

$$\mathbf{X}'_{ffn} = \text{Adapter}_{ffn}(\mathbf{X}_{ffn}) \tag{4-6}$$

$$\mathbf{X}'' = \mathbf{X}' + \mathbf{X}'_{ffn} \tag{4-7}$$

因此，每个 Transformer 层包含两个适配器实例（分别用于注意力子层和 FFN 子层），一组适配器共包含 $2N_{layer}$ 个 ResMLP 模块。

本文采用**运行时动态注入**策略：不修改 ESM2 的源代码，而是在模型加载后通

过 Python 的动态属性替换机制，将原始的 TransformerLayer 替换为包含适配器的 AdapterTransformerLayer。该策略与 S-PLM[25] 中的适配器注入方式一致，使适配器模块以即插即用的方式与任何 ESM2 变体兼容。默认仅对 ESM2 最后 $N_{adapter} = 16$ 层（共 33 层）注入适配器，浅层保持原始参数不变以保留通用序列表示能力。

当存在多组适配器（如双适配器策略中的 adapter_0 和 adapter_1）时，各组适配器在同一层内并行计算，输出通过均匀加权取平均：

$$\mathbf{X}_{adapter} = \frac{1}{G}\sum_{g=1}^{G}\text{Adapter}^{(g)}(\mathbf{X}) \tag{4-8}$$

其中 G 为适配器组数（预训练时 $G = 1$，下游训练时 $G = 2$）。

4.2.4 域感知对比学习预训练

预训练阶段的目标是将蛋白质域的语义信息蒸馏至序列编码器的适配器参数中。

4.2.4.1 序列编码器

将蛋白质序列 P 输入注入 adapter_0 的 ESM2 模型，获得每个残基位置的上下文嵌入，通过平均池化（排除填充位和特殊 token）获得蛋白质级表示：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0}(P)) \in \mathbb{R}^{1280} \tag{4-9}$$

4.2.4.2 域嵌入

蛋白质域的文本嵌入 $\mathbf{h}_{dom} \in \mathbb{R}^{2560}$ 由 Qwen3-Embedding-4B 预计算并缓存，编码方式与第三章 MZSGO 相同。

4.2.4.3 投影头

为将序列表示和域嵌入映射至共享的对比空间，设计两个独立的投影头：

$$\mathbf{z}_{seq} = \text{ProjHead}_{seq}(\mathbf{h}_{seq}) \in \mathbb{R}^{d_p} \tag{4-10}$$

$$\mathbf{z}_{dom} = \text{ProjHead}_{dom}(\mathbf{h}_{dom}) \in \mathbb{R}^{d_p} \tag{4-11}$$

其中 $d_p = 256$ 为投影维度。每个投影头由两层 MLP 组成：

$$\text{ProjHead}(\mathbf{x}) = \text{LN}(\mathbf{W}_2 \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_1 \cdot \mathbf{x})))) \tag{4-12}$$

中间隐藏维度为 512。输出向量经 L2 归一化后用于计算余弦相似度。

4.2.4.4 InfoNCE 对比损失

给定一批 B 个蛋白质样本，每个样本 i 对应序列投影 $\mathbf{z}^i_{seq}$ 和域投影 $\mathbf{z}^i_{dom}$ 构成正样本对，同一批次中其他样本构成负样本对。采用双向 InfoNCE 损失进行优化：

$$\mathcal{L}_{seq\to dom} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\mathrm{sim}(\mathbf{z}^i_{seq},\mathbf{z}^i_{dom})/\tau)}{\sum_{j=1}^{B}\exp(\mathrm{sim}(\mathbf{z}^i_{seq},\mathbf{z}^j_{dom})/\tau)} \tag{4-13}$$

$$\mathcal{L}_{dom\to seq} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(\mathrm{sim}(\mathbf{z}^i_{dom},\mathbf{z}^i_{seq})/\tau)}{\sum_{j=1}^{B}\exp(\mathrm{sim}(\mathbf{z}^i_{dom},\mathbf{z}^j_{seq})/\tau)} \tag{4-14}$$

$$\mathcal{L}_{CL} = \frac{1}{2}(\mathcal{L}_{seq\to dom} + \mathcal{L}_{dom\to seq}) \tag{4-15}$$

其中 $\mathrm{sim}(\cdot,\cdot)$ 为余弦相似度，$\tau = 0.07$ 为温度超参数。

通过这种双向对比学习，adapter_0 被训练为能够将 ESM2 的序列表示调制至与域嵌入对齐的语义空间。预训练完成后，adapter_0 中的参数编码了将序列特征映射至域感知空间的变换，即使后续不提供域嵌入输入，ESM2+adapter_0 的输出也隐式地包含了域的功能语义信息。

4.2.5 双适配器端到端下游训练

预训练完成后，进入端到端的下游功能预测阶段。

4.2.5.1 双适配器策略

冻结 adapter_0 的所有参数，将预训练学到的域语义先验” 锁定”。在 ESM2 的同一组 Transformer 层中注入第二组适配器 adapter_1，随机初始化其参数。adapter_1 为可训练状态，负责学习功能预测任务特定的适配信息。

与 S-PLM[25] 在预训练后仅使用单组适配器进行下游任务不同，MZSGO-DA 的双适配器策略具有以下优势：

（1）**知识保留**：adapter_0 冻结后，预训练阶段通过对比学习学到的域-序列对齐知识不会在下游训练中被覆盖或遗忘。

（2）**任务适配**：adapter_1 提供了额外的可学习参数，使模型能够在保持域先验的同时适应特定的功能预测目标。

（3）**稳定性**：两组适配器的输出取平均，相当于一种集成效应，有助于稳定训练和提升泛化能力。

4.2.5.2 端到端序列编码

与 MZSGO 不同，MZSGO-DA 在下游训练时不使用预计算的静态嵌入，而是在每个训练迭代中实时运行 ESM2+ 双适配器前向传播。为节省显存，前向传播跳过 ESM2 的语言模型头（LM Head）和接触预测头（Contact Head），仅执行 Transformer 编码器部分：

$$\mathbf{h}_{seq} = \text{MeanPool}(\text{ESM2}_{adapter_0+adapter_1}(P)) \in \mathbb{R}^{1280} \tag{4-16}$$

4.2.5.3 特征投影与门控融合

MZSGO-DA 的下游分类架构简化为双模态融合：序列特征和 GO 标签文本嵌入。由于域语义信息已通过 adapter_0 内化至序列表示中，推理时不再需要显式输入域嵌入。

序列特征和 GO 标签嵌入分别经过投影后，输入双模态门控融合模块（GatedFusionModule2）。该模块与第三章的三模态版本类似，但仅处理两个输入：

$$\mathbf{h}'_{seq} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{seq}\mathbf{h}_{seq}))) \in \mathbb{R}^{512} \tag{4-17}$$

$$\mathbf{h}'_{label} = \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{label}\mathbf{E}_{label}))) \in \mathbb{R}^{512} \tag{4-18}$$

在训练阶段，同样对序列特征施加模态丢弃策略（丢弃率 $p = 0.15$），以增强模型对序列信息缺失场景下的鲁棒性。

门控融合模块计算自适应权重并生成融合表示：

$$\boldsymbol{\alpha} = \text{Softmax}(\mathbf{W}_{gate} \cdot \text{ReLU}(\text{LN}(\mathbf{W}_{ctx}[\hat{\mathbf{h}}'_{seq} \parallel \mathbf{h}'_{label}]))) \tag{4-19}$$

$$\mathbf{H}_{fused} = \alpha_1 \cdot \phi_{seq}(\hat{\mathbf{h}}'_{seq}) + \alpha_2 \cdot \phi_{label}(\mathbf{h}'_{label}) \tag{4-20}$$

其中 $\boldsymbol{\alpha} \in \mathbb{R}^2$ 为归一化的门控权重。

4.2.5.4 分类与损失函数

融合表示经过分类 MLP 生成逻辑值：

$$\hat{y} = \sigma(\mathbf{W}_{out} \cdot \text{Dropout}(\text{GELU}(\text{LN}(\mathbf{W}_{cls}\mathbf{H}_{fused})))) \tag{4-21}$$

其中分类头将 512 维融合特征压缩至 256 维，再投影至 1 维输出。

下游训练使用二分类交叉熵损失（BCEWithLogitsLoss）：

$$\mathcal{L}_{task} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(\hat{y}_i) + (1-y_i)\log(1-\hat{y}_i)] \tag{4-22}$$

下游阶段的可训练参数包括：adapter_1 的所有参数、特征投影层、门控融合模块和分类头。ESM2 的原始参数和 adapter_0 均保持冻结。

4.3 实验设置

4.3.1 数据集

MZSGO-DA 使用与第三章 MZSGO 相同的数据集，包括基于 CAFA5 和 Swiss-Prot 的训练集、标准测试集，以及通过时间演进方式构建的零样本测试集。数据集统计信息详见第三章表 3-1和表 3-2。

4.3.2 实现细节

4.3.2.1 预训练阶段

对比学习预训练基于 PyTorch[32] 分布式数据并行（DDP）框架实现，使用 6 块 NVIDIA GPU 进行训练。ESM2 选用 esm2_t33_650M_UR50D 变体（33 层 Transformer，隐藏维度 1280）。适配器注入最后 16 层，瓶颈维度 640。使用 AdamW[35] 优化器，学习率 1×10^{-4}，权重衰减 1×10^{-4}。训练采用余弦退火学习率调度，预热比例 0.1。每张 GPU 的批次大小为 8，梯度累积步数为 2，有效批次大小为 96。训练最多 50 个 epoch，使用早停策略（耐心值 5）防止过拟合。训练过程使用 FP16 混合精度加速，梯度裁剪阈值为 1.0。温度超参数 $\tau = 0.07$。

4.3.2.2 下游训练阶段

下游训练同样采用 DDP 框架和 6 块 GPU。加载预训练的 adapter_0 参数并冻结，初始化 adapter_1 并设为可训练。每张 GPU 的批次大小为 4（由于端到端前向传播 ESM2 需要更多显存），梯度累积步数为 4，有效批次大小仍为 96。学习率 1×10^{-4}，隐藏维度 512，分类 Dropout 率 0.3，特征丢弃率 0.15。训练 30 个 epoch，同样使用早停策略。

4.3.3 基线方法

除了第三章中列出的十种基线方法外，本章额外引入 MZSGO 作为直接对比基线，以评估端到端训练相对于静态嵌入方法的增益。同时将不使用预训练的单适配器端到端方法作为消融基线，记为 MZSGO-DA (w/o pretrain)。

4.3.4 评价指标

评价指标与第三章一致，包括有监督指标 $F_{\max}$ 和 AUPR，零样本指标 Unseen AUPR 和 Seen AUPR，以及综合评价指标调和均值 H。

4.4 实验结果与分析

4.4.1 与 MZSGO 的性能对比

表 4-1展示了 MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。

表 4-1: MZSGO-DA 与 MZSGO 在三个 GO 本体上的性能对比。Δ 表示 MZSGO-DA 相对于 MZSGO 的绝对提升。

本体	模型	Fmax↑	AUPR↑	Unseen AUPR↑	Seen AUPR↑	H↑
	MZSGO	0.5045	0.5008	0.2393	0.5021	0.3241
BP	MZSGO-DA	**0.5103**	**0.5076**	**0.2517**	**0.5092**	**0.3366**
	Δ	+0.0058	+0.0068	+0.0124	+0.0071	+0.0125
	MZSGO	0.7611	0.7337	0.4806	0.7380	0.5821
MF	MZSGO-DA	**0.7682**	**0.7421**	**0.4963**	**0.7460**	**0.5957**
	Δ	+0.0071	+0.0084	+0.0157	+0.0080	+0.0136
	MZSGO	0.7470	0.7726	0.5862	0.7733	0.6669
CC	MZSGO-DA	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**
	Δ	+0.0066	+0.0077	+0.0179	+0.0077	+0.0146

从实验结果可以观察到：

（1）**全面的性能提升**。MZSGO-DA 在三个 GO 本体的所有指标上均优于 MZSGO，验证了端到端训练策略和域感知适配器预训练的有效性。

（2）**零样本指标提升尤为显著**。在 Unseen AUPR 上，MZSGO-DA 在 BP、MF 和 CC 本体上分别获得 +0.0124、+0.0157 和 +0.0179 的提升，且调和均值 H 的提升幅度（+0.0125 至 +0.0146）一致超过有监督指标（Fmax 提升 +0.0058 至 +0.0071）。这表明域感知预训练通过将域语义信息内化至序列编码器，增强了模型对未见标签的泛化能力。

（3）**端到端训练的梯度优势**。MZSGO-DA 的有监督指标也获得了稳定提升，说明端到端训练使序列编码器能够根据功能预测目标进行微调，产出更具区分性的表示。

4.4.2 消融实验

为分析 MZSGO-DA 各组件的贡献，本文在 CC 本体上进行了系统的消融实验，结果如表 4-2所示。

表 4-2: MZSGO-DA 在 CC 本体上的消融实验结果。

变体	Fmax	AUPR	Unseen AUPR	Seen AUPR	H
预训练策略消融					
无预训练（随机初始化 $adapter_1$）	0.7421	0.7654	0.5713	0.7662	0.6561
单 adapter 端到端（无 $adapter_0$）	0.7448	0.7689	0.5790	0.7698	0.6620
适配器策略消融					
$adapter_0$ 不冻结（双 adapter 均可训练）	0.7502	0.7715	0.5684	0.7721	0.6568
仅 $adapter_0$（冻结，无 $adapter_1$）	0.7382	0.7598	0.5923	0.7604	0.6667
注入层数消融					
注入最后 8 层	0.7478	0.7735	0.5862	0.7742	0.6675
注入最后 24 层	0.7510	0.7768	0.5944	0.7774	0.6745
注入全部 33 层	0.7493	0.7751	0.5901	0.7758	0.6710
MZSGO-DA（注入最后 16 层）	**0.7536**	**0.7803**	**0.6041**	**0.7810**	**0.6815**

消融结果支持以下结论：

（1）**预训练的重要性**。去除预训练后（随机初始化 $adapter_1$ 直接端到端训练），H 从 0.6815 降至 0.6561，降幅达 0.0254。即使使用单 adapter 端到端训练也仅获得 0.6620 的 H 值，均显著低于完整的 MZSGO-DA，证实域感知对比学习预训练为下游任务提供了重要的初始化先验。

（2）**冻结 $adapter_0$ 的必要性**。当 $adapter_0$ 不冻结而是与 $adapter_1$ 联合训练时，有监督指标 Fmax 反而提升至 0.7502，但 Unseen AUPR 下降至 0.5684，H 降至 0.6568。这说明联合训练虽然增加了模型容量，但会导致预训练域知识被下游梯度覆盖，损害零样本泛化能力。冻结 $adapter_0$ 有效保护了预训练知识。

（3）**双适配器的协同效应**。仅使用冻结的 $adapter_0$（不引入 $adapter_1$）进行端到端预测，虽然 Unseen AUPR 较高（0.5923），但 Fmax（0.7382）和总体 AUPR（0.7598）均明显下降。这是因为冻结的 $adapter_0$ 仅学到了域-序列对齐的知识，缺乏功能预测任务的适配能力。双适配器策略通过 $adapter_1$ 提供了任务适配的灵活性，实现了域先验与任务目标的最优平衡。

（4）**注入层数的影响**。从 8 层增加到 16 层带来了显著的性能提升（H 从 0.6675 升至 0.6815），继续增加到 24 层或 33 层反而导致轻微下降。这表明浅层 Transformer 编码了通用的氨基酸表示模式，注入适配器可能干扰这些底层特征；而中高层对

功能信息的编码更为敏感，适配器注入能带来最大收益。16 层是表征能力与训练稳定性之间的最优折中。

4.4.3 预训练过程分析

为深入理解对比学习预训练的效果，本文监控了训练过程中正样本对相似度、负样本对相似度和相似度间隔（similarity gap）的变化。

随着训练的推进，正样本对（同一蛋白质的序列表示与域嵌入）的余弦相似度从初始的约 0.1 稳步上升至 0.7 以上，而负样本对（不同蛋白质的序列-域配对）的相似度维持在 0.05 以下。相似度间隔（正样本相似度减去负样本相似度均值）从约 0.05 增长至 0.65 以上，表明适配器成功地将序列表示调制至与域嵌入高度对齐的空间。

训练损失在约 15 个 epoch 后趋于收敛，早停机制在第 20 至 25 个 epoch 附近触发。过长的预训练可能导致过拟合至训练集中的蛋白质-域对应关系，早停策略有效防止了这一问题。

4.4.4 参数效率分析

表 4-3展示了 MZSGO-DA 中各组件的参数量统计。

表 4-3: MZSGO-DA 参数量统计。

组件	参数量	状态
ESM2 原始参数	~650M	冻结
adapter_0（16 层 ×2 个）	~53M	冻结
adapter_1（16 层 ×2 个）	~53M	可训练
特征投影与分类头	~2M	可训练
总计	~758M	—
可训练参数	~55M	7.3%

MZSGO-DA 的可训练参数仅占总参数的 7.3%，远低于全参数微调方案。这种参数高效的设计不仅降低了训练的计算和存储开销，还通过保持 ESM2 原始参数冻结有效防止了灾难性遗忘，确保蛋白质语言模型在通用序列建模方面的能力不受损害。

4.5 本章小结

本章提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-

DA。该方法受 S-PLM[25] 利用对比学习在适配器中蒸馏结构信息的启发，将蒸馏目标从三维结构信息拓展至蛋白质域的功能语义信息，其核心创新体现在三个方面：

（1）**域感知对比学习预训练**。通过 InfoNCE 对比学习将蛋白质域的语义信息蒸馏至 ESM2 内部的轻量级适配器模块，使序列编码器在不需要显式域输入的情况下即可产出携带域语义先验的增强表示。

（2）**双适配器端到端训练策略**。冻结预训练的 $adapter_0$ 以保留域知识，引入可训练的 $adapter_1$ 进行任务适配。两组适配器在 Transformer 层内并行运行，实现了预训练知识保留与下游任务适配的有效平衡。

（3）**端到端梯度通路**。打破了 MZSGO 中静态嵌入方法的梯度断裂问题，使下游损失信号能够回传至序列编码器，实现了从序列输入到功能预测的完整优化。

实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，验证了域感知适配器预训练和端到端训练策略的有效性。消融实验进一步证实了预训练、冻结策略和双适配器设计各自的必要性。MZSGO-DA 以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配，为蛋白质功能预测领域的预训练-微调范式提供了新的技术方案。

结 论

蛋白质功能预测是生物信息学领域的核心任务之一。随着高通量测序技术的飞速发展，蛋白质序列数据呈指数级增长，而经实验验证的功能注释比例极低，自动化功能预测方法的需求日益迫切。现有的深度学习方法通常将基因本体功能标签视为简单的分类标识符，忽略了蕴含于文本定义中的丰富语义信息，限制了模型对未见标签的泛化能力。本文围绕”多模态语义融合”与”预训练域感知适配”两个方向展开研究，提出了两个具有递进关系的蛋白质功能预测框架。

首先，本文提出了多模态零样本蛋白质功能注释方法 MZSGO。该方法将蛋白质功能预测重新定义为蛋白质-GO 匹配问题，利用蛋白质语言模型 ESM2 提取序列进化特征，利用大语言模型 Qwen3-Embedding 对蛋白质域描述和 GO 功能定义进行统一语义编码。设计了自适应门控融合模块实现逐样本动态的多模态特征整合，并引入非对称特征丢弃策略增强模型对模态缺失的鲁棒性。实验表明，MZSGO 在三个 GO 本体的有监督指标上均达到最优或极具竞争力的水平，在零样本场景下以压倒性优势超越所有现有方法。特别是在 CC 本体上，MZSGO 的调和均值 H 达到 0.6669，是亚军方法 ProtNote（0.3659）的近两倍，验证了多模态语义融合范式在零样本蛋白质功能预测中的有效性。

其次，本文提出了基于域感知适配器预训练的端到端蛋白质功能预测方法 MZSGO-DA。该方法针对 MZSGO 中静态嵌入策略的信息瓶颈和梯度断裂问题，设计了轻量级适配器模块注入蛋白质语言模型的 Transformer 层内部，通过 InfoNCE 对比学习预训练将蛋白质域的语义信息蒸馏至序列编码器。在下游阶段，采用双适配器策略——冻结预训练适配器保留域知识，引入新适配器进行任务适配——实现端到端训练。实验结果表明，MZSGO-DA 在三个 GO 本体上全面超越 MZSGO，尤其在零样本指标上提升显著，以仅 7.3% 的可训练参数比例实现了对大规模蛋白质语言模型的高效适配。

本文的主要贡献可以归纳为：（1）通过引入大语言模型构建域和标签的统一语义空间，实现了蛋白质功能预测从封闭标签集到开放标签集的范式转换，使模型具备零样本推理能力；（2）通过域感知对比学习预训练与双适配器端到端训练机制，在不改变蛋白质语言模型原始参数的前提下，高效地将多模态知识注入序列编码器。

尽管本文方法取得了显著的进展，但仍存在一些局限性和进一步改进的空间：

第一，本文使用预计算的静态域嵌入和 GO 标签嵌入，而非端到端地训练大

语言模型编码器。虽然这在当前硬件条件下是务实的选择，但未来随着计算资源的提升，联合训练蛋白质语言模型和文本编码器可能带来更深层次的跨模态对齐。

第二，本文的零样本评估虽然采用了严格的时间演进策略和序列同源性过滤，但零样本测试集的规模仍然有限，特别是 CC 本体仅有 17 个零样本测试蛋白质。未来需要在更大规模的零样本基准上验证方法的泛化能力。

第三，本文目前仅利用了序列和域文本两种模态，未充分利用蛋白质三维结构信息。结合 AlphaFold2 预测的结构特征和蛋白质-蛋白质相互作用网络信息，可能进一步提升功能预测精度。

第四，MZSGO-DA 的端到端训练虽然提升了性能，但显著增加了训练时间和显存消耗。探索更高效的参数高效微调策略（如 LoRA、Prefix Tuning 等）以进一步降低计算开销，是有价值的未来方向。

展望未来，蛋白质功能预测领域可能沿以下方向发展：一是构建更大规模的预训练数据集和更强大的蛋白质基础模型，为下游功能预测提供更丰富的表征；二是探索蛋白质功能预测与蛋白质设计的联合优化，实现从”理解功能”到”设计功能”的跨越；三是将零样本功能预测能力与基因组学、转录组学等多组学数据相结合，为系统生物学研究提供更全面的功能注释工具。

参考文献

[1] EISENBERG D，MARCOTTE E M，XENARIOS I，et al. Protein function in the post-genomic era [J]. Nature，2000，405（6788）：823-826.

[2] ASHBURNER M，BALL C A，BLAKE J A，et al. Gene ontology: tool for the unification of biology [J]. Nature genetics，2000，25（1）：25-29.

[3] GOEMAN J J，MANSMANN U. Multiple testing on the directed acyclic graph of gene ontology [J]. Bioinformatics，2008，24（4）：537-544.

[4] ANON. UniProt: the universal protein knowledgebase in 2025 [J]. Nucleic acids research，2025，53（D1）：D609-D617.

[5] FRIEDBERG I. Automated protein function prediction—the genomic challenge [J]. Briefings in bioinformatics，2006，7（3）：225-242.

[6] ALTSCHUL S F，GISH W，MILLER W，et al. Basic local alignment search tool [J]. Journal of molecular biology，1990，215（3）：403-410.

[7] BUCHFINK B，REUTER K，DROST H-G. Sensitive protein alignments at tree-of-life scale using DIAMOND [J]. Nature methods，2021，18（4）：366-368.

[8] KULMANOV M，HOEHNDORF R. DeepGOPlus: improved protein function prediction from sequence [J]. Bioinformatics，2020，36（2）：422-429.

[9] JUMPER J，EVANS R，PRITZEL A，et al. Highly accurate protein structure prediction with AlphaFold [J]. nature，2021，596（7873）：583-589.

[10] JIAO P，WANG B，WANG X，et al. Struct2GO: protein function prediction based on graph pooling algorithm and AlphaFold2 structure information [J]. Bioinformatics，2023，39（10）：btad637.

[11] BLUM M，ANDREEVA A，FLORENTINO L C，et al. InterPro: the protein sequence classification resource in 2025 [J]. Nucleic acids research，2025，53（D1）：D444-D456.

[12] KULMANOV M，HOEHNDORF R. DeepGOZero: improving protein function prediction from sequence and zero-shot learning based on ontology axioms [J]. Bioinformatics，2022，38（Supplement_1）：i238-i245.

[13] ZHOU N，JIANG Y，BERGQUIST T R，et al. The CAFA challenge reports improved protein function prediction and new functional annotations for hundreds of genes through experimental screens [J]. Genome biology，2019，20（1）：244.

[14] O'SHEA K，NASH R. An introduction to convolutional neural networks [J]. arXiv preprint arXiv:1511.08458，2015.

[15] LIN Z，AKIN H，RAO R，et al. Evolutionary-scale prediction of atomic-level protein structure with a language model [J]. Science, 2023, 379 (6637): 1123-1130.

[16] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in neural information processing systems，2017，30.

[17] KULMANOV M，GUZMÁN-VEGA F J，DUEK ROGGLI P，et al. Protein function prediction as approximate semantic entailment [J]. Nature Machine Intelligence，2024，6（2）：220-228.

[18] LI W，WANG B，DAI J，et al. Partial order relation–based gene ontology embedding improves protein function prediction [J]. Briefings in Bioinformatics, 2024，25（2）：bbae077.

[19] WANG B, GENG Y, CHENG X, et al. ProtGO: universal protein function prediction utilizing multi-modal gene ontology knowledge [J]. Bioinformatics, 2025, 41（7）：btaf390.

[20] WANG W，SHUAI Y，ZENG M，et al. DPFunc: accurately predicting protein function via deep learning with domain-guided structure information [J]. Nature communications，2025，16（1）：70.

[21] CHAR S，CORLEY N，ALAMDARI S，et al. ProtNote: a multimodal method for protein–function annotation [J]. Bioinformatics，2025，41（5）：btaf170.

[22] HOULSBY N，GIBER A，JASTRZEBSKI S，et al. Parameter-efficient transfer learning for NLP [C] // International conference on machine learning，2019：2790-2799.

[23] CHEN T，KORNBLITH S，NOROUZI M，et al. A simple framework for contrastive learning of visual representations [C] // International conference on machine learning，2020：1597-1607.

[24] OORD A V D，LI Y，VINYALS O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748，2018.

[25] WANG D，POURMIRZAEI M，ABBAS U L，et al. S-PLM: Structure-aware Protein Language Model via Contrastive Learning between Sequence and Structure [J]. Advanced Science，2025，12（5）：e2404212.

[26] ZHANG Y，LI M，LONG D，et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models [J]. arXiv preprint arXiv:2506.05176，2025.

[27] LUO R，SUN L，XIA Y，et al. BioGPT: generative pre-trained transformer for biomedical text generation and mining [J]. Briefings in bioinformatics，2022，23（6）：bbac409.

[28] CUI Y，JIA M，LIN T-Y，et al. Class-balanced loss based on effective number of samples [C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition，2019：9268-9277.

[29] HENDRYCKS D. Gaussian Error Linear Units (Gelus) [J]. arXiv preprint arXiv:1606.08415，2016.

[30] BOUTET E，LIEBERHERR D，TOGNOLLI M，et al. UniProtKB/Swiss-Prot: the manually annotated section of the UniProt KnowledgeBase [G] // Plant bioinformatics: methods and protocols. Springer，2007：89-112.

[31] BA J L，KIROS J R，HINTON G E. Layer normalization [J]. arXiv preprint arXiv:1607.06450，2016.

[32] PASZKE A，GROSS S，MASSA F，et al. Pytorch: An imperative style, high-performance deep learning library [J]. Advances in neural information processing systems，2019，32.

[33] KINGMA D P. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980，2014.

[34] NOTARO M，FRASCA M，PETRINI A，et al. HEMDAG: a family of modular and scalable hierarchical ensemble methods to improve Gene Ontology term prediction [J]. Bioinformatics，2021，37（23）：4526-4533.

[35] LOSHCHILOV I，HUTTER F. Decoupled weight decay regularization [C] // International conference on learning representations，2019.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

Boyue Cui, Beibei Wang, Xuan Wang, Junyi Li. ”MZSGO: Multimodal Zero-Shot Gene Ontology Annotation via Evolutionary Signals and Textual Semantics” 期刊 Bioinformatics (Oxford University Press) 在投。

（二）申请及已获得的专利

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于多模态预训练的蛋白质功能预测研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

时光荏苒，转眼间两年半的硕士研究生生涯已近尾声。在完成毕业论文之际，百感交集。回望来路，深知今日之成果绝非一人之力所能及——正是众多师长、亲友的无私支持与倾心相助，才让我得以坚定前行、顺利完成学业。在此，谨以最诚挚的心意，向所有曾给予我关怀与帮助的人致以深深的谢意。

首先，谨向我的导师李君一老师致以最诚挚的感谢。在攻读硕士学位期间，您不仅在学术研究上给予我系统而深入的指导，更在科研方法和学术写作方面耐心地培养了我的逻辑思维能力和独立研究能力。在论文选题、实验设计和论文撰写的每一个阶段，您始终认真细致地审阅我的工作，提出了大量富有针对性的建议和改进意见，使我能够不断完善研究方案并提升论文质量。您的严谨治学态度与无私付出令我受益匪浅。此外，在日常学习与生活中，您也给予我们充分的关怀与支持，为我顺利完成学业提供了重要保障。

其次，我要感谢我的同门。在科研探索的过程中，我们相互交流、共同进步，面对研究中的困难与挑战，彼此分享思路与经验。特别感谢师姐王贝贝在蛋白质功能预测领域的宝贵指导和经验分享，为我的研究工作提供了重要参考。与同门们共同讨论课题，使我在学术视野与研究能力上均受益良多，每一次交流都对我的研究工作产生了积极而深远的影响。

随后，我要特别感谢我的家人。在攻读硕士学位的这几年中，面对学业与科研带来的压力，是你们始终如一的理解、包容与鼓励，给予我坚持前行的力量。每一次电话中的关怀、每一次回家时温暖的陪伴，都让我深切感受到无言却深厚的爱与支持。正是你们在背后的默默付出，成为我顺利完成学业的重要支撑。

同时，我也衷心感谢我的朋友们。在求学与科研的过程中，你们的陪伴、理解与鼓励，为这段紧张而充实的时光增添了温度。无论是低谷时的倾听，还是前行中的相互支持，你们都让我在忙碌与压力之中保持信心与动力。

最后，我要衷心感谢哈尔滨工业大学。四年在哈尔滨本部、两年在深圳校区的学习经历，使我在学术视野与专业能力上都得到了系统而全面的培养。从专业课程的科学设置，使我得以扎实而深入地掌握相关理论与方法。学院的每一位老师都治学严谨、认真负责，其言传身教不仅传授了专业知识与研究方法，也深刻塑造了我严谨求实的学术态度。感谢学校和学院多年来的悉心培养，未来我将秉持在此形成的治学精神，继续努力，在各自岗位上践行哈工大的校训与精神。

衷心感谢老师的悉心教诲、同学的并肩前行、朋友的温暖陪伴以及家人的坚

定支持，使我得以顺利走过这段研究生时光。未来，我将带着这份感激与收获，继续前行。