硕士学位论文

（专业学位论文）

基于多模态网络表征学习的蛋白质功能预测研究

PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL NETWORK REPRESENTATION LEARNING

焦沛舜

哈尔滨工业大学

2023 年 12 月

中国知网 https://www.cnki.net

国内图书分类号：TP391.4　　学校代码：10213
国际图书分类号：004.8　　密级：公开

硕士学位论文

基于多模态网络表征学习的蛋白质功能预测研究

硕士研究生：焦沛舜
导　　师：李君一副教授
申请学位：专业硕士学位
类　　别：电子信息
所在单位：哈尔滨工业大学 (深圳)
答辩日期：2023 年 12 月
授予学位单位：哈尔滨工业大学

中国知网　https://www.cnki.net

Classified Index: TP391.4
U.D.C: 004.8

A dissertation submitted in partial fulfillment of
the requirements for the academic degree of
Master of Engineering

PROTEIN FUNCTION PREDICTION BASED ON MULTIMODAL NETWORK REPRESENTATION LEARNING

Candidate: Peishun Jiao
Supervisor: Junyi Li
Academic Degree Applied for: Master of Engineering
Specialty: Computer Science and Technology
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: December, 2023
Degree-Conferring-Institution: Harbin Institute of Technology

中国知网 https://www.cnki.net

摘 要

高通量测序技术的发展使得基因组学进入到了信息时代，大规模的基因组测序项目产生了大量的 DNA 序列数据，为研究生物体的基因组提供了详细的信息。后基因组时代强调对基因组数据的功能性解释，蛋白质功能预测是在这一背景下应运而生，它致力于解释基因产物的功能和相互作用。目前，蛋白质功能预测模型的研究主要聚焦在避免复杂特征工程的深度学习方法上，在蛋白质相互作用网络上通过图表征算法进行消息传播的方法在目前的主流模型中取得了较好的效果。但现有的模型大多是基于氨基酸序列信息提取蛋白质特征从而进行功能预测，然而蛋白质的功能是由其结构所决定，所以如何高效利用蛋白质结构数据进行功能预测仍然是值得探究的问题。

近年来，蛋白质结构预测领域有着飞快的发展，DeepMind 公司的 AlphaFold2 模型将蛋白质结构预测提升到原子级别。考虑到现有方法的局限性，本文构建了一种基于蛋白质结构和序列的蛋白质功能预测模型。首先为充分挖掘蛋白质结构信息，将蛋白质三维结构被转化成二维接触图并通过图表示学习进行氨基酸残基嵌入。随后，利用注意力网络的层次化图池化算法提取蛋白质结构网络特征并拼接通过蛋白质语言模型得到的序列特征作为蛋白质的完整表达用于下游功能标签的分类任务。本文的方法抛弃了蛋白质相互作用网络的信息，仅是以单个蛋白质信息的输人为主体，因此具有较好的通用性，在人类数据集上的实验结果中，本文提出的方法在多个性能指标中均取得最优的效果。

简单地将蛋白质多源特征拼接的方式未考虑到不同模态之间信息的交互与融合。受到视觉与语言多模态预训练模型的启发，本文构建了一个基于蛋白质序列结构-功能术语的多模态预训练模型，相比较之间不同模态特征直接拼接的方式通过预训练过程中不同模态间的交互获得远程联系从而构建完整的蛋白质表示，然后在下游微调任务中利用融合后的特征进行功能预测。同时考虑到蛋白质标签的层次关系，基于图注意力算法构建层次分类器，并通过后处理机制保证预测标签间父子结构的准确性。最后，选取一种乳糖操纵子抑制因子 2PE5-B 蛋白进行模型的可解释性分析，证明了模型的设计的合理性和预测的可靠性。

关键词：蛋白质功能预测; 蛋白质结构; 层次化图池化算法; 多模态预训练模型

中国知网 https://www.cnki.net

Abstract

The development of high-throughput sequencing technology has ushered genomics into the information age. Large-scale genome sequencing projects have generated vast amounts of DNA sequence data, providing detailed information for the thesis of organism genomes. In the post-genomic era, emphasis has shifted to the functional interpretation of genomic data. Protein function prediction has emerged in this context, aiming to elucidate the functions and interactions of gene products. Currently, research on protein function prediction models primarily focuses on deep learning approaches that avoid complex feature engineering. Methods based on graph representation learning on protein-protein interaction networks, utilizing message passing algorithms, have shown promising results in mainstream models. However, most current models are based on extracting protein features from amino acid sequence information. Since protein function is determined by its structure, efficiently utilizing protein structure data for function prediction remains an important area for exploration.

In recent years, the field of protein structure prediction has witnessed rapid development, with DeepMind's AlphaFold2 model elevating protein structure prediction to the atomic level. Considering the limitations of existing methods, this thesis constructs a protein function prediction model based on both protein structure and sequence information. To fully exploit protein structure information, the three-dimensional structure of proteins is transformed into a two-dimensional contact map, and amino acid residue embeddings are obtained through graph representation learning. Subsequently, hierarchical graph pooling algorithms based on attention networks are employed to extract protein structure network features. These features are concatenated with sequence features obtained through a protein language model to form a comprehensive representation of proteins for downstream functional label classification tasks. This approach abandons the use of protein-protein interaction network information, focusing mainly on the input of individual protein information, thereby demonstrating good generality. In experiments on human datasets, the proposed method achieves optimal performance across multiple evaluation metrics.

The simple concatenation of protein multi-source features does not take into account the interaction and fusion of information across different modalities. Inspired by multi-

中国知网 https://www.cnki.net

modal pretraining models in visual and language domains, this thesis establishes a multi-modal pretraining model based on protein sequence, structure, and functional terms. In contrast to directly concatenating features from different modalities, this approach leverages interactions between different modalities during the pretraining process to capture long-range dependencies and construct a comprehensive protein representation. The fused features are then used for downstream fine-tuning tasks, such as functional prediction. Additionally, considering the hierarchical relationships among protein labels, a hierarchical classifier is built based on graph attention algorithms. A post-processing mechanism is employed to ensure the accuracy of parent-child structures in predicted labels. Finally, interpretability analysis of the model is conducted using the example of lactose repressor protein 2PE5-B, demonstrating the rationality of the model design and the reliability of predictions.

Keywords: protein function prediction, protein structure, hierarchical graph pooling algprithm, multimodal pretraining model

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 课题背景及研究的目的和意义.....1
1.1.1 课题背景.....1
1.1.2 研究目的和意义.....2
1.2 国内外研究现状.....3
1.2.1 基于序列的蛋白质功能预测.....3
1.2.2 基于结构的蛋白质功能预测.....4
1.2.3 基于多源信息融合的蛋白质功能预测.....5
1.3 主要研究内容和文章的组织结构.....6
1.3.1 本文的主要研究内容.....6
1.3.2 本文的组织结构.....7
第 2 章 蛋白质功能预测的相关研究概述.....9
2.1 引言.....9
2.2 蛋白质功能预测问题定义.....9
2.3 图表示学习研究现状.....11
2.3.1 基于无监督学习的图嵌入方法.....11
2.3.2 基于监督学习的图神经网络方法.....12
2.3.3 基于图神经网络的图分类算法.....14
2.4 多模态预训练模型研究现状.....16
2.4.1 多模态预训练模型结构.....16
2.4.2 多模态预训练任务.....16
2.4.3 多模态预训练模型的发展以及在蛋白质领域的应用.....17
2.5 本章小结.....19
第 3 章 基于结构和图分类算法的蛋白质功能预测.....20
3.1 引言.....20
3.2 数据集的获取和预处理.....20
3.2.1 数据集的获取.....20
3.2.2 蛋白质序列特征的提取.....21
3.2.3 蛋白质接触图的构建.....22
3.2.4 氨基酸残积水平嵌入.....22
3.3 注意力机制层次化图分类模型建立.....23
3.3.1 图神经网络卷积层.....24
3.3.2 自注意力机制层次化图池化算法.....24
3.3.3 图读出层.....24

中国知网 https://www.cnki.net

3.4 实验和结果分析.....26
3.4.1 蛋白质功能预测评价指标.....26
3.4.2 对比实验结果与分析.....26
3.4.3 消融实验结果与分析.....29
3.4.4 模型参数敏感性分析.....30
3.5 本章小结.....32
第 4 章 基于多模态预训练的蛋白质功能预测模型.....33
4.1 引言.....33
4.2 序列-结构-功能蛋白质多模态预训练模型构建.....33
4.2.1 单流预训练模型构建.....34
4.2.2 预训练任务.....36
4.3 蛋白质功能标签的树状层次化分类与后处理机制.....36
4.3.1 基于图注意力网络的层次化分类算法.....37
4.3.2 后处理机制.....37
4.4 实验结果与分析.....38
4.4.1 基于预训练的蛋白质功能预测模型实验与结果分析.....38
4.4.2 层次化分类算法与后处理机制实验结果分析.....39
4.5 模型可解释性分析.....40
4.6 本章小结.....42
结论.....43
参考文献.....44

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 课题背景及研究的目的和意义

1.1.1 课题背景

2003 年，人类基因组计划完成了人类基因组的初步测序，生物科学家逐渐解开了基因和分子生物学之间的关系。随着时间的推移，研究者们开始更加关注基因组中基因的功能以及网络的调控，而不是仅仅关注基因的序列，从而走进了后基因组时代。该阶段更加强调对基因组中各个基因的功能进行系统性研究，包括基因的表达、调控、蛋白质的功能以及他们在细胞和生物水平上的相互作用。同时，对蛋白质的组成、结构和功能进行系统性研究，揭示蛋白质之间的相互作用和细胞中复杂信号的传导、调控和代谢网络也是当前研究的重点。与传统的基因组学研究不同，后基因组时代更加强调系统性的研究方法，通过整合多种生物学信息揭示生物体内复杂的调控网络。通过蛋白质组学的方法，研究者可以更全面了解细胞中蛋白质的组成和功能。这有助于揭示蛋白质相互作用网络，进而理解细胞信号传导、代谢途径等重要生物学过程，从而更好理解生命的本质。

蛋白质作为生物体内一类重要的大分子有机化合物，由氨基酸通过肽链连接而成。它们在生物体内具有多种功能，是细胞结构的主要组成部分之一，也是许多生物体内重要生命过程的关键参与者，在生物体内担任着多种重要角色，包括结构支持、运输分子、催化化学反应、免疫防御和传递信号等。例如，肌肉中的肌冻蛋白质使肌肉能够收缩，抗体是一种免疫系统产生的蛋白质，能够识别和抵御外来入侵的病原体。蛋白质功能的多样性是通过结构和序列的多样性体现的，不同的蛋白质通过其特定的结构和活性部位实现各种生物学功能。同时，蛋白质往往不是单独发挥作用，而是通过多个蛋白质相互配合形成蛋白质复合物实现更复杂的功能。因此在研究蛋白质功能的模型中结构、序列和相互作用网络是重要的数据源。总体来看，蛋白质和蛋白质之间的相互作用是维持生物体内各种功能的基础，同时研究蛋白质的功能，对理解生物学过程、药物研发和疾病诊断和治疗具有重要的现实意义。

高通量测序技术的快速发展导致了大量蛋白质序列数据的涌现，然而，相对于蛋白质序列的迅速增长，已知功能的标签数据相对较少，据统计目前已知功能的蛋白质数量不到 UniProt[1] 中搜集的 1.9 亿条蛋白质数据集的 1%，同时通过实

中国知网 https://www.cnki.net

验测定蛋白质功能的方法费时费力，这就为蛋白质功能预测任务提出了新的挑战。在这一背景下，蛋白质功能预测模型变得尤为重要，基于统计学计算的自动功能预测（Automatic Function Prediction, AFP）[2] 模型应运而生，通过从蛋白质的序列、结构和相互作用网络等多个维度获取信息自动注释蛋白质功能，为生物学研究和药物开发提供有力支持。

在蛋白质结构预测领域，AlphaFold2[3] 的出现掀起了一场革命。AlphaFold2 以其强大的深度学习架构和创新方法，成功将蛋白质的三维结构预测提升到原子级别，并在 2020 年的第 14 届 Critical Assessment of Struct Prediction（CASP14）中取得第一名的出色成绩。AlphaFold2 模型的意义不仅在于提高了结构预测的精度，同时也对功能预测提供了更加可靠的基础。蛋白质结构和功能密切相关，因此高质量的结构数据有助于准确预测蛋白质的功能特征，这对于解读基因组数据、研究疾病机制、进行药物研发等方面都具有深远的影响。综合来看，高通量测序技术和 AlphaFold2 模型的出现共同推动了蛋白质功能预测领域的发展，为深入解析蛋白质的结构和功能提供了新的视角和工具。

1.1.2 研究目的和意义

CAFA（Critical Assessment of Function Annotations）[4] 比赛是关于蛋白质功能预测的评估比赛，其目的在于推动蛋白质功能预测领域的研究，通过评估不同方法对蛋白质功能进行预测，促进该领域的发展。CAFA 比赛定期举办，提供了一个国际性的平台吸引世界各地研究人员参加。通过从 CAFA 比赛中取得优秀成绩的模型来看，蛋白质功能预测已经从基于统计学方法和机器学习方法的时代，逐渐过渡到基于深度学习方法的时代。传统机器学习的方法在特征提取方面较为麻烦，通常需要研究者具有较为深入的生物学背景。基于深度学习的算法可以避免复杂的特征工程，设计端到端的功能预测模型，并且具有较好的泛化性能，因此往往在比赛中能够展现出更优的性能。

同时，在比赛中基于蛋白质多源信息融合的模型往往更容易脱颖而出，蛋白质的序列、结构和相互作用网络分别从不同方面描述蛋白质的特征，因此综合多维度特征可以得到更加完整的蛋白质表达，有效提高功能预测任务的准确度。然而目前的信息融合更多的是停留在特征拼接的前期融合阶段，缺少了不同模态之间的交互过程。因此设计多模态数据融合的蛋白质表示模型，通过捕获不同模态之间的远程连接更加充分的挖掘不同模态之间的信息，得到完整的蛋白质表达仍然是当前需要研究的问题。同时，由于蛋白质结构数据的缺乏，前期的模型较少的利用蛋白质结构方面的信息。然而，蛋白质的结构和功能是密切相连的，随着

中国知网 https://www.cnki.net

AlpaFold2 带动的蛋白质结构预测的迅速发展，完整的蛋白质结构数据集能够为功能预测提供强有力的支撑。目前已经有多种基于结构信息的功能预测模型涌出，然而在该领域如何通过蛋白质的三维结构提取特征用于下游功能注释任务仍是目前需要解决问题的重点。

总体来看，构建高准确率的蛋白质功能预测模型目前仍然是具有挑战并且具有广阔前景的领域。针对于上述问题的分析，本文将从深度学习以及网络表征算法展开，首先探索如何高效的利用目前 AlphaFold2 提供的高精度蛋白质结构特征，然后在此基础上类比于视觉-文本的多模态预训练模型，探究如何设计蛋白质领域不同模态间融合的预训练模型，通过此预训练模型获得基于不同模态间融合的完整表达，从而增强蛋白质功能预测的精度。本文最终将构建一个多模态、高性能、可扩展、端到端的蛋白质功能预测模型，从而更好的弥补随着高通量测序技术迅速发展序列与蛋白质功能标签之前的缺口，为进一步深入理解生命活动、探索新药物和疫苗研发以及提高农作物产量等方面提供重要的信息和工具。

1.2 国内外研究现状

美国生物学家 Anfinsen 于 1961 年提出的分子生物学第二中心法则，分别对蛋白质的序列和三维结构如何影响蛋白质功能做了深入探讨，这一理论为日后通过计算预测蛋白质功能标签奠定了基础。根据其数据来源不同，蛋白质功能预测可以分为基于序列和基于结构两大类。同时蛋白质相互作用网络（PPI）在功能预测方面也发挥着重要的作用，通常认为蛋白质是通过和多个小分子物质如（DNA、RNA 等）或蛋白质结合发挥其功能，所以在 PPI 网络中相互作用的蛋白质通常会共享其功能。近年来，多模态领域有着较大的发展，如何将蛋白质的多源信息整合成较为完整的特征表示提升在下游分类任务中的效果成为目前较为热门的方向。

1.2.1 基于序列的蛋白质功能预测

通常来讲，氨基酸序列相似程度较高的蛋白质往往会有较多相同的功能，所以最初的研究往往是基于序列相似性展开的。基于自然语言处理领域算法的快速发展，部分学者基于序列信息通过蛋白质语言模型预处理得到蛋白质的结构域、家族等信息，并在下游功能标签注释任务中取得了较好的结果。

通过 BLAST[5] 等比对工具快速计算同源蛋白质之间的序列相似性预测功能标签是 CAFA 比赛的基线方法。2015 年，PANNZER[6] 模型横空出世取得第一届 CAFA 比赛的第一名，其主要通过多重序列比对的方法（Multiple Sequence Align-

中国知网 https://www.cnki.net

ment，MSA）评价蛋白质序列的相似性得分，然后通过 K 近邻算法作为分类器预测蛋白质标签。2016 年，Gong[7] 等人提出的 GoFDR 模型基于蛋白质的序列比对获得位置的异性打分矩阵（Position-Specific Scoring Matrix，PSSM），从而获得该氨基酸序列的同源保守型信息。2017 年，第三届 CAFA 比赛第一名 GOLabeler 模型[8]，首先通过同源蛋白质的序列比对可以获取该蛋白质家族和结构域等信息，然后根据不同的特征训练多个分类器并通过学习排序算法调整不同特征的权重。同年，Kulmanov[9] 等人提出的 DeepGO 模型，首次将深度学习领域的卷积神经网络应用到蛋白质功能预测领域，以氨基酸的序列作为输入提取的特征信息，并融合 Diamond[10] 提取的序列相似性特征构建端到端的功能预测模型。

1.2.2 基于结构的蛋白质功能预测

具有相似功能的蛋白质，其序列也可能有较大差别。结构决定功能是自然界中的普遍法则，蛋白质功能作为结构的自然延伸，由其结构域折叠成特定的、有序的三维构象所决定。2021 年，Gligorijević[11] 等人提出的 DeepFRI 模型通过从蛋白质结构中提取特征来预测蛋白质功能。2022 年，Lai[12] 等人基于注意力机制的图卷积神经网络提取蛋白质的结构特征，有效提高了功能预测的精度。尽管追求大规模、准确的蛋白质结构数据一直是对传统实验方法的挑战，由于这种数据获取的困难，使用蛋白质结构数据进行大规模预测一直面临诸多难题。这意味着目前在预测领域的方法受限，因为实验手段的限制阻碍了对蛋白质结构的广泛了解，从而影响了规模化的预测。

近年来，随着蛋白质结构预测取得了突破性的发展，通过 AlphaFold2 模型进行高精度蛋白质结构预测可以获得大量原子级别的蛋白质结构的三维坐标。该模型第一部分输入为一级氨基酸序列和同源物种的比对序列，第二部分的输入为已知相似序列的蛋白质三维结构模版。模型先将比对序列和配对模版分别进行嵌入表示，然后通过 Evoformer 神经网络实现进化关系的推理，并预测所有重原子（除氢以外的任何原子）的空间坐标和每个残基的置信度，预测结果会作为新的模版回收迭代到整个模型的预测过程中，重复三次后的输出作为最终预测结果。AlphaFold2 公开了其预测数据集，98.5% 的人类蛋白质被成功破译，这将对通过结构来预测蛋白质功能产生深远的影响。2023 年，Gu[13] 等人在 DeepFRI 的基础上提出了 HEAL 模型，其主要通过 AlphaFlod2 提供的蛋白质结构数据集进行数据增强，并在结构特征提取算法方面做了优化。

中国知网 https://www.cnki.net

1.2.3 基于多源信息融合的蛋白质功能预测

基于单一的信息源难以完整表达蛋白质的语义信息，今年来更多的学者开始将研究的重点放在如何融合蛋白质的多源信息从而更好的进行下游分类任务。蛋白质的序列和结构信息仅能够表达单个蛋白质的特征，但是蛋白质功能的表达往往是多的蛋白质之间的相互作用共同形成的。Schwikowski[14] 等的研究表明，半数以上的蛋白质在所在相互作用网络中的邻居有功能共享。蛋白质的序列、结构和相互作用等信息源可以看作蛋白质的不同模态信息，考虑将不同模态的信息融合可以得到更高维度的特征，从不同角度描述蛋白质得到蛋白质的完整表达，进而可以更好的提升下游功能预测任务的性能。目前有两个比较主流的蛋白质多源信息融合的方法：其一是直接将多个维度的特征直接拼接。比如，2019 年，You[15] 等人在 NetGO 的基础上加入了 PPI 网络的信息提出 NetGO 模型，成为当时最为先进的功能预测模型。2020 年，在 DeepGO 的基础上，Kulmanov[16] 等人提出了 DeepGOPlus 模型，通过图表示学习算法得到蛋白质节点在 PPI 网络中的嵌入表示并融合其序列特征，结合二者信息进行功能标签预测。2023 年，Wu[17] 等人提出的 CFAGO 模型分为两步，在上游通过多头注意力机制交叉融合蛋白质的 PPI 网络信息和生物学特征，在下游微调模型并做蛋白质功能预测任务。另一种融合的方式是通过图卷积神经网络（Graph Convolutional Network, GNN），将 PPI 网络作为图，结构或者序列信息作为节点的属性特征，利用 GNN 的消息聚合与传播机制，通过学习其多阶临域信息更新蛋白质的特征表示。2019 年，Zhou[18] 等人首次使用该方法提出 DeepGOA 模型，主要在功能标签网络中使用 GNN 算法在获得其功能标签语义信息的同时也包含了不同标签间的相互关系。同年，You[19] 等人提出的 DeepGraphGO 模型，将蛋白质语义模型预处理得到的特征嵌入 PPI 网络中，通过 GCN 学习不同蛋白质在网络中的相互关系。次年，在此基础上提出的 PSPGO 模型[20] 是一种基于蛋白质序列的多物种融合的蛋白质功能预测模型。2022 年，Xue[21] 等人提出了蛋白中多模态预训练模型，通过 Transformer 模型融合蛋白质序列、结构和功能标签信息得到蛋白质更为完整的表达，在下游多任务中均有较为优秀的表现。

总的来看，蛋白质功能预测问题已经从最初的单纯基于氨基酸序列或者结构的方法逐渐发展到基于多源信息融合的方式。同时，随着算力和算法的日益发展，越来越多的研究者开始探究如何利用深度学习等方法设计端到端标签注释模型。但是从目前的主流方法来看，仍然存在以下问题：

第一，早期的研究方法更多的是基于序列，虽然蛋白质的结构更加能够直接

中国知网 https://www.cnki.net

反应蛋白质功能，但是由于缺乏高精度的蛋白质三维结构相关研究难以展开。蛋白质的结构预测和功能预测一脉相承，2021 年，DeepMind 发布的 AlphaFold2 模型在 CASP14 比赛中取得令人瞩目的成绩，将蛋白质结构预测提升到原子级别，并公开了包括人类在内的 2.14 亿蛋白质高精度结构数据集。如何有效利用蛋白质结构数据集进行功能预测仍然是有待探究的问题。

第二，现有的基于 PPI 网络的模型通常会存在噪声，如果在 PPI 网络中进行 GNN 的消息传播通常会进一步放大噪声，并且具有深层的 GNN 网络可能会使所有节点趋近于相同的表示导致过度平滑问题。同时，现有的基于 PPI 的方法针对于新测序的蛋白质序列或者同源信息较少的蛋白质无法进行有效预测，使得模型通用型较差。

第三，现有的蛋白质多源信息融合的模型通常是简单的将多个特征简单的拼接或者基于学习排序模型分配不同的权重，这样的方式忽略了不同模态信息之间的远程联系。如何从不同模态间通过对比学习设计合理的蛋白质多模态预训练模型，获得更加完善的蛋白质表示，是本实验中所需要面临的挑战。

第四，蛋白质功能术语网络是树状结构，而目前现有的算法通常将功能标签预测问题看作多标签的二分类问题，从而忽视了不同标签之间的父子结构关系，同时也不能保证预测的正确性。所以如何设计基于层次结构的分类器仍是需要面对的问题。

1.3 主要研究内容和文章的组织结构

1.3.1 本文的主要研究内容

根据上述问题的总结和目前存在的难点，本文以蛋白质的序列和结构特征作为数据主体，围绕如何高效提取蛋白质结构特征、探究如何建立基于序列和结构的多模态预训练模型构建高效完善的蛋白质语义信息以及如何建立具有层次结构的分类器确保功能标签之间的父子关系的正确性等问题展开，在提升模型性能的前提下同时提升模型的通用性。具体来讲，本文的研究内容如下：

（1）蛋白质数据集的获取和预处理。鉴于目前多源信息融合的方式以成为主流的蛋白质功能预测的方法，本文主要使用蛋白质序列数据集、蛋白质结构数据集和蛋白质功能标签数据集进行实验，且以上数据集均为开源数据集。通过利用大规模数据的预训练模型，可以通过自监督的方法有效的提取蛋白质的序列特征。本文在比较多种较为主流的蛋白质语言模型后选取 SeqVec[22] 模型作为蛋白质序列特征编码器。同时，在预处理过程中通过无监督的图表示学习算法 Node2Vec[23]

中国知网 https://www.cnki.net

进行氨基酸特征的水平嵌入。

（2）基于结构和图分类算法的蛋白质功能预测。因为蛋白质结构数据的稀缺，现有的方法较少是针对结构来预测蛋白质功能的。在 DeepMind 公司公开 AlphaFold2 预测的 2.14 亿个原子级别的蛋白质三维结构数据集后，如何通过结构充分挖掘其特征用于蛋白质功能预测成为目前的热点。本文提出了一种基于注意力机制的层次化图池化算法，首先将通过计算氨基酸间的相对距离生成蛋白质接触图，并基于预训练中的氨基酸特征利用 GNN 算法进行消息的传播与聚合，通过多轮迭代得到该蛋白质的最终表示，最终将功能预测问题转化为图分类任务。完成上述模型构建工作后，本文进行了对比实验和消融实验验证方法的合理性并根据结果进行相关讨论。

（3）基于模态间融合的蛋白质预训练模型。基于多源信息的方式在一定程度上扩展了蛋白质的表示，在功能分类任务中取得了不错的效果。但目前的大多方法通常是将多源信息直接拼接而忽略了不同模态之间的远程联系。本文提出了一种蛋白质不同模态间融合的预训练模型，在上游 MLM（Masked Language Modeling）的预训练任务中，利用 Transformer 模型的自注意力机制处理输入序列的上下文信息，从而能够捕获到蛋白质序列、结构和功能注释之间长距离的语义依赖关系。上游的预训练通过充分挖掘不同模态间的相互关系，可以得到更完整的蛋白质表示，从而有助于提高下游功能预测任务的表现。最后，本文通过实验验证了上述模型的有效性，并根据对比实验和消融实验结果做出合理性分析与讨论。

1.3.2 本文的组织结构

本文主要通过四个章节来阐述，每个章节内容的总体概括如下所示：

第一章，首先以该课题的研究背景为出发点展开，然后通过介绍国内外的研究现状，总结了目前常见的三类主流方法并分析不同方法之间的优劣以及目前所做研究的局限性，并在此基础上提出了本文的研究内容，本章节最后总结了整体的组织结构。

第二章，首先具体介绍了蛋白质功能预测问题所涉及的内容，并对该问题做形式化抽象通过公式具体定义该问题。本文的实验主要在基于网络表征学习和多模态融合算法实现数据挖掘任务，因此本章接下来分别介绍了网络表征学习各个具体子问题的研究内容与现状，并介绍了多模态预训练模型的发展历程和其不同模型的具体原理。

第三章，主要介绍基于结构和图分类算法的蛋白质功能预测模型。本章节最开始详细介绍了实验所用数据集的获取，然后分别介绍了蛋白质序列和结构数据

中国知网 https://www.cnki.net

预处理的方法，最后提出基于注意力机制的层次化图池化算法提取蛋白质结构的完整表示用于下游分类任务。本章基于该模型与目前较为先进的模型做了相关对比实验以及消融实验，并根据实验数据对模型的优劣进行充分的分析。

第四章，主要围绕蛋白质多模态预训练模型展开，在第三章的基础上，通过蛋白质的序列、结构和功能标签注释等不同模态间的对比学习从而获得整个蛋白质的完整表达用于下功能预测任务。上游多模态预训练模型通过预训练任务可以更加充分的挖掘蛋白质的完整表示，同时有助于提高模型的泛化能力，缓解某个模态间数据稀疏问题。本章节最后通过实验验证了该预训练模型的有效性并进行相关理论分析。

中国知网 https://www.cnki.net

第 2 章 蛋白质功能预测的相关研究概述

2.1 引言

蛋白质是生物体内执行生命过程的关键分子，他们在细胞中承担了许多重要的功能，如催化化学反应、传递信号、提供结构支持等。同时蛋白质功能预测在医学研究、药物设计、基因编辑等领域具有广泛的应用。它有助于理解分子水平上的生物学过程，并为疾病治疗和药物开发提供重要的信息。但目前针对蛋白质功能预测问题仍然没有一个清晰的范式描述，因此在本章节中首先给出蛋白质功能预测问题的定义，然后分别介绍网络表征和多模态预训练模型的相关研究与原理，为之后的工作做铺垫。本章节的组织结构为：2.2 节将蛋白质功能预测问题转化为数学模型并给出具体定义；2.3 节介绍网络表征算法的分类、原理与相关研究现状；2.4 节介绍多模态预训练领域的发展以及在蛋白质领域的应用；2.5 节对本章内容进行总结。

2.2 蛋白质功能预测问题定义

在统计学的视角下，蛋白质功能术语预测问题可以转化为多标签的二元分类算法：假设已知一组数量为 n 的蛋白质节点为 $P = \{p_1, p_2, ..., p_3\}$，$T = \{t_1, t_2, ..., t_m\}$ 表示描述每一个蛋白质可能含有的 m 个功能术语标签的集合。蛋白质的特征通常包括序列、结构、PPI 网络等多个维度，因此这里用 $F = \{f_1, f_2, ..., f_k\}$ 来描述每一个蛋白质 k 个维度的特征。综上，一个完整的蛋白质数据集可以表示为：$D_l = \{(p_1, F_1, T_1), (p_2, F_2, T_2), ..., (p_n, F_n, T_n)\}$，其中 p_i 代表第 i 个蛋白质节点，F_i 代表该蛋白质的特征，其特征可以是单一信息源特征也可以是多源信息特征，T_i 代表该蛋白质的多个功能术语。根据上面数据的描述，该问题可以定义为：具有标注的完整蛋白质数据集 D_l 作为训练集，对一个输入蛋白质节点数据集 P 和特征数据集 F 输出为每个蛋白质节点的功能标签数据集 T 进行有监督训练，然后利用训练好的模型对未带标签蛋白质数据集（P，F）预测其功能标签 $\hat{T} \subseteq T$，使得：

$$\hat{T} = \arg\max_{P \subseteq T} \{Pr\,(P \mid p)\} \tag{2-1}$$

其中 $Pr\,(P \mid p)$ 是需要预测蛋白质 p 的功能集合为 P 的概率质量函数，通常模型的输出是每个功能术语标签的概率，通过设定的平均阈值能够找到该蛋白质功能

中国知网 https://www.cnki.net

标签的最大的子集合。

通常来讲，蛋白质有两种不同的功能注释词汇来描述，分别是功能目录（Functional Catalogue, FunCat）[24] 和基因本体（Gene Ontology, GO）[25] 功能注释方案，由于 GO 标签对不同种类的功能做了更为详细的分类，同时也是 CAFA 比赛中所使用的方式，所以本文采用 GO 标签注释蛋白质的功能并完成后续实验。在同一个类别之间的功能标签被组织称一个具有层次结构的树状图（有向无环图），节点由 GO 编号和具体功能描述组成，边表示不同术语之间的关系，主要包括 is-a、part-of、has-part 和 regulation 等关系。比如图 2-1，描述的是生物过程的结构图。在该图中的祖先结点的 ID 为 GO:0008150 对应的术语名称为 biological process（生物过程），其子节点组成父子关系（is-a）。同时由于生物学过程的功能具有多层次和交叉的特性，一个子节点可能会存在多个父节点。

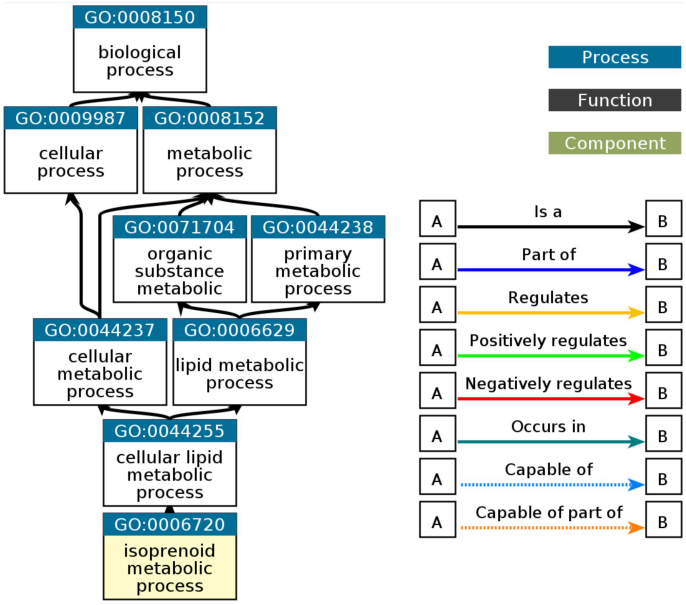

图 2-1 生物过程基因本体术语组织结构图

进一步来看，因为功能标签具有层次树状结构，所以蛋白质功能预测问题不只是多标签的二分类问题，因为在预测过程中不仅仅要考虑每个标签的概率，同时也需要考虑标签之间的相互关系，因此该预测任务可以预测某个蛋白质在所有 GO 标签组成的完整有向无环图 G 中的子图问题，子图中的节点集合即为该蛋白质的的功能标签 Q。

$$\hat{T} = \arg\max_{Q \subseteq G} \{Pr\,(Q \mid p)\} \tag{2-2}$$

这里 $Pr\,(Q \mid p)$ 得到的是子图中标签节点的后验概率分布。

中国知网 https://www.cnki.net

2.3 图表示学习研究现状

2.3.1 基于无监督学习的图嵌入方法

图嵌入学习是一种无监督学习方法，其主要目的是将图中的节点、边或整个图映射到低维度的向量，从而更好地捕捉图中节点之间的结构关系和相似性，为下游任务提供更加有效的输入。在该领域 Perozzi 等[26] 提出的 DeepWalk 算法首先采用随机游走算法通过递归遍历其相邻节点获得词向量，其随机游走长度可以通过调整参数来控制；然后借助自然语言处理领域 Word2Vec 算法的思想获得网络中节点的低维特征表示。Node2Vec 算法[23] 的思想与 DeepWalk 相同，但其可以根据参数动态调整随机游走的参数，从而同时获得广度优先和深度优先遍历序列，广度优先遍历可以更好的表达网络的同质性信息，而深度优先遍历可以更好的表达网络的结构信息，该图嵌入算法在同质性和结构性之间找到平衡。但是 DeepWalk 和 Node2Vec 算法在大型较为复杂的网络中可能无法提取高层次的信息，同时 Node2Vec 算法的训练需要耗费较多的计算资源和时间。在此基础上，提出了一种专门针对于大规模网络进行图嵌入学习的算法，LINE 算法[27] 更倾向于使用广度优先遍历算法通过最小化目标函数优化的方式来获取网络的低维表示。该方法是同时得到一阶和二阶相似性特征后并将其拼接作为最终表示。在一阶相似度中顶点之间的联合概率表达如下：

$$P_1(v_i, v_j) = \frac{1}{1 + \exp(-\boldsymbol{u}_i^{\mathrm{T}} \cdot \boldsymbol{u}_j)} \tag{2-3}$$

其中 $\boldsymbol{u}_i$ 和 $\boldsymbol{u}_j$ 分别是顶点 v_i 和 v_j 的低维向量表示。其目标函数表示式为：

$$O_1 = -\sum_{(i,j)\in E} w_{ij} \lg p_1(v_i, v_j) \tag{2-4}$$

在二阶相似度计算中，在顶点 v_i 已知的前提下，邻居 v_j 出现的概率为：

$$P_2(v_j|v_i) = \frac{\exp\left(\boldsymbol{u}'^{\mathrm{T}}_j \cdot \boldsymbol{u}_i\right)}{\sum_{k=1}^{|V|} \exp\left(\boldsymbol{u}'^{\mathrm{T}}_k \cdot \boldsymbol{u}_i\right)} \tag{2-5}$$

将 KL 散度作为距离度量指标，得到优化目标为：

$$O_2 = \sum_{i\in V} \lambda_i d(\widehat{p}_2(\cdot|v_i), p_2(\cdot|v_i)) \tag{2-6}$$

其中权重 λ_i 可以是节点 v_i 的度或者 PageRank 值等重要因子，并设 $\lambda_i = d_i$

LINE 算法总体上看是一种高效、灵活、准确的图嵌入算法，在处理大规模网络时有更好的效果，但是使用时需要注意算法的灵敏度以及参数的调整。

中国知网 https://www.cnki.net

上述介绍的方法都是基于近邻相似假设的，但在一些场景中不是近邻的顶点也会有很高的相似性，例如在图 2-2 中，u 和 v 两个节点虽然距离较远，但是他们的结构具有较高的相似性，即它们的度分别为 5 和 4，分别连接 3 和 2 个三角形。然而上述基于紧邻序列的方式无法感知此类节点的相似性。针对此问题，Leonardo 等人[28] 提出 Struct2Vec 算法从空间结构相似性的角度定义顶点相似度，从而更倾向于捕获网络中不同节点的位置结构特征。从整体上看，具有相同度的顶点是结构相似的，若各自邻接顶点仍然具有相同度数，那么他们相似度就更高。Struct2Vec 首次在图嵌入中引入了结构化信息和随机游走相结合的方式，更好的通过结构信息捕捉丰富的图拓扑结构，从而提高了在图结构中学习节点表示的性能，在下游节点分类和链接预测中有更好的表现。

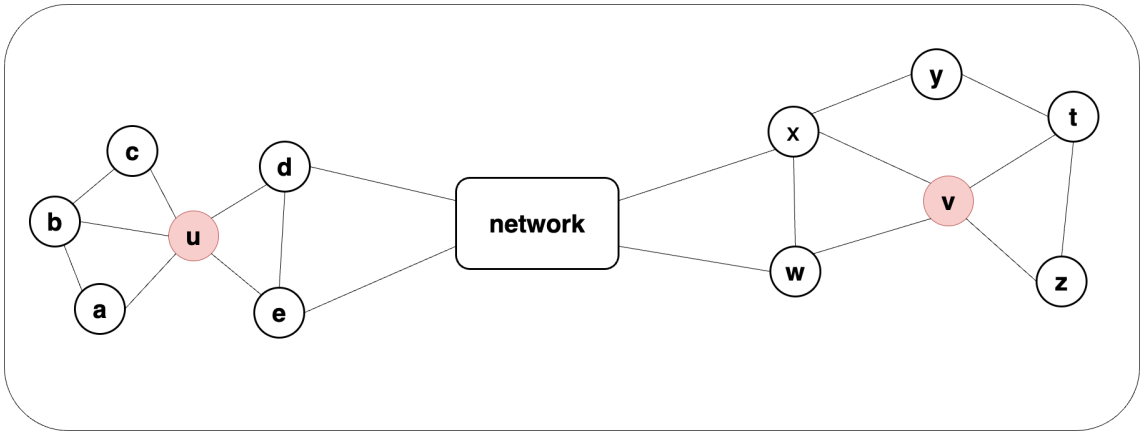

图 2-2 具有结构相似性节点的网络

2.3.2 基于监督学习的图神经网络方法

基于深度学习的图表示学习方法可以相比较与传统的图嵌入方式，可以解决浅层网络表示能力有限、处理非线性图结构和稀疏图等问题。目前图神经网络主要分为谱域和空域两种。在基于谱域的方法中，类比于卷积神经网络的思想，KipF 等[29] 提出了图卷积神经网络，通过定义图上的傅立叶变换和反变换实现网络的卷积操作。GCN 中单层的图卷积层是其核心函数，具体表示如下：

$$H^{(l+1)} = \sigma\left(\widetilde{\boldsymbol{D}}^{-1/2}\widetilde{\boldsymbol{A}}\widetilde{\boldsymbol{D}}^{-1/2}H^{(l)}\boldsymbol{W}^{(l)}\right) \tag{2-7}$$

其中，$\boldsymbol{A}$ 是无向图 G 添加节点自链接后的邻接矩阵，即 $\tilde{A} = A + I_N$，这里 A 表示无向图 G 的邻接矩阵，I_N 表示恒等矩阵；$\boldsymbol{D}$ 表示的是 $\boldsymbol{A}$ 的度矩阵，且 $\widetilde{\boldsymbol{D}}_{ii} = \sum_j \widetilde{\boldsymbol{A}}_{ij}$；$\boldsymbol{W}^{(l)}$ 代表第 l 层可学习的权重矩阵；$H^{(l)}$ 和 $H^{(l+1)}$ 分别第 l 层和第 l+1 层的特征矩阵。根据公式 2-7，GCN 中通常叠加多个卷积层从而学习多跳邻居信息，但通常会

中国知网 https://www.cnki.net

因为层数过多导致过拟合问题，同时 GCN 通常是基于内存的图神经网络算法，节点的聚合与更新需要全图的特征，由于内存限制通常无法处理较大规模的图。

Hamilton[30] 等提出的 GraphSAGE, 解决了上述 GCN 中的扩展性问题。该模型主要思想是采样和聚合，节点每次会选取固定数量和阶数的邻居信息更新其特征。并提出了均值和池化两种类型的聚合函数。

在空域的方法中，较为典型的是 Velickovic[31] 等人提出的图注意力网络（Graph Attention Network）模型。通常基于空域的方法，不再基于整图的邻接矩阵而是相连的两个节点之间的注意力分数进行消息的传播与聚合，其注意力系数表示为：

$$\alpha_{ij} = \frac{\exp\left(\mathrm{LeakyReLU}\left(\mathrm{a}^T[\mathrm{Wh}_i \| \mathrm{Wh}_j]\right)\right)}{\sum_{k\in N_i}\exp\left(\mathrm{LeakyReLU}\left(\mathrm{a}^T[\mathrm{Wh}_i \| \mathrm{Wh}_k]\right)\right)} \tag{2-8}$$

其中 α_{ij} 是节点 j 到 i 的注意力系数，N_i 表示节点 i 的邻居节点，W 是每一个节点上应用的线性变换权重矩阵，a 是权重向量。最后通过 softmax 归一化。由此可见 GAT 算法注意力系数的计算主要是基于直接相邻节点的信息，所以大规模图可以突破内存限制分批次的进行训练。

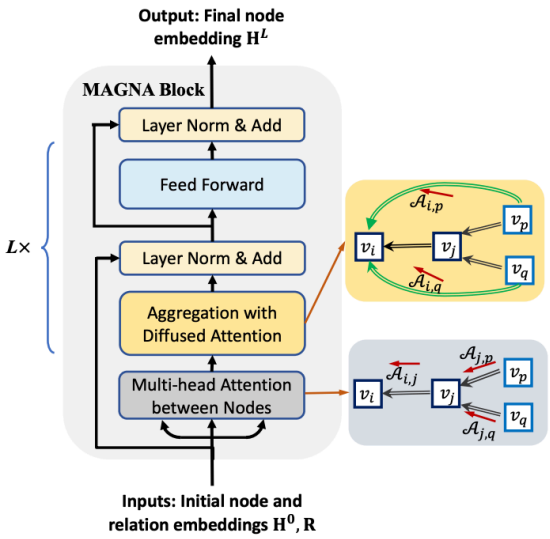

图 2-3 基于直接多跳的图注意力网络模型图[32]

虽然 GNN 通过 self-attention 机制已经取得的较好的效果，但目前的注意力机制仅仅只考虑到直接相连的邻居节点，若通过叠加多层网络的方式往往会带来过拟合问题，基于此 Wang[32] 等人提出的 Direct multi-hop Attention based Graph neural Network(DAGN) 算法在每层中通过注意力机制考虑远程节点的消息传播，其架构图如 2-3 所示，其采用了多头注意力机制，并且包含两层的前馈神经网络。基于多跳注意力聚合函数是本算法的主要创新点，其 1 跳直接邻居的注意力矩阵通过图

中国知网 https://www.cnki.net

扩散计算多跳邻居的注意力分数：

$$\mathcal{A} = \sum_{i=0}^{\infty} \theta_i A^i,\ where \sum_{i=0}^{\infty} \theta_i = 1 \tag{2-9}$$

其中 $\mathcal{A}$ 代表多跳注意力矩阵的聚合表达，A^i 代表第 i 阶邻居的注意力矩阵，θ_i 是注意力衰减因子，通过几何分布 $\theta_i = \alpha(1-\alpha)^i$ 计算并且满足 $\theta_i > \theta_{i+1}$，该方式使得远程邻居对应的权重在逐渐下降。该算法利用近似计算多跳注意力机制的方式将图注意力算法扩展到多阶邻居，在有效避免过拟合的前提下同时保证任务的复杂度仍然较低，并在多个任务中取的较好效果。

上述算法都是基于同构网络，2020 年 Hu[33] 等人提出了一种异构图神经网络模型 Heterogeneous Graph Transformer（HGT），并提出了一种面向大规模图训练的异构小批量图采样算法，可以对亿数量级别节点异构图建模。为了处理图的异构性，该算法将每条边的模型参数分解为三个矩阵相乘，其分解根据每条边的三元组 <初始节点类型，边类型，目标节点类型> 来定义，然后使用三元组对权重矩阵参数化，从而计算每条边的注意力值。在此分解基础上，HGT 的消息传播方式与 Transformer 较为相似，将目标节点映射为一个 Query 向量，源节点映射为一个 key 向量，随后计算两者的点积作为注意力值。与 Transformer 不同的是，在异构图中每个元关系对应一组不同的权重。同时，为了处理图数据的动态性，作者引入了相对时间编码（Relative Temporal Encoding），即根据不同的时间戳把初始图分割成若干个子图，将发生在不同时间的边放在一个图中。在计算两个节点相互之间的时间差，并对每一个时间差编码，作为初始节点特征的一部分，这样 HGT 在训练过程中可以学习出图中的时间依赖关系，同时发生在不同时间的节点也可以进行信息传递。

2.3.3 基于图神经网络的图分类算法

网络表征算法在下游任务中主要通过节点分类、整图分类以及链路预测表现，本节通过图分类算法展开。通常来讲，图分类算法有基于图相似性计算和图神经网络两种方式，随着图深度学习的不断发展，基于图神经网络的端到端预测方式不断提升预测效果的同时也避免的复杂的特征工程。基于图神经网络的图分类算法可以大致分为两个步骤：卷积和池化，将在下文中依次展开。

图卷积的目的主要是通过复杂的特征变化进行特征提取，最早期的方式是将非欧式图转化为二维结构，然后通过传统卷积神经网络（CNN）提取特征，其中 PSCN[34] 模型和 Ego-CNN[35] 模型均是利用图的结构信息通过 CNN 算法在节点上进行卷积，不同点在于 PSCN 模型的节点选择算法可以适应不同图的不同节点数

中国知网 https://www.cnki.net

量，因为多层卷积中可能因为上层选择算法中缺失的节点在下层中未能得到有效的表达，所以该算法只能有一个卷积层。而 Ego-CNN 模型在图初始化中抛弃了节点选择算法，通过将整图嵌入并给每个节点设置固定的邻居数量并拼接作为整图的初始化表达，随后可以基于该特征矩阵叠加多层的卷积，从而获得图的全局和局部关键信息。

2017 年，基于图结构的消息传递和聚合通用框架 Message Passing Neural Networks (MPNNs)[36] 提出后，目前主流的图分类方法方法基于 2.3.2 介绍的图卷积函数 GCN、GraphSAGE 和 GAT 等得到节点的特征映射，然后通过不同的图池化算法最终得到整个图的表示。图池化通常也叫做下采样，是通过图粗化过程从而达到减少图特征维度的效果。图池化一般会先通过分配矩阵选择聚合的邻居节点，然后通过最大池化（Max Pooling）、加和池化（Sum Pooling）或者均值池化（Mean Pooling）等方式聚合成为新的超节点。Ma[37] 等人提出的 EigenPool 模型是较为经典的图池化模型，通过谱池化的方式得到分配矩阵并基于该矩阵得到多个子图利用多组池化算子得到超节点表示。Wu[38] 等人认为网络中具有相同度的节点往往具有相似的图结构信息，基于此理论他们提出的 DEMO-Net 模型将相同度的节点在池化阶段通过拼接的方式组合称为超节点。不同于上述硬分配的方式，Amir[39] 等人提出的 DiffPool 通过具有记忆层的图神经网络学习到多个分配矩阵，并通过卷积层得到最终分配矩阵的表示用于池化。Lee[40] 等人创新性的提出的 SAGPool 是一种节点选择的基于自注意力机制的层次化图池化模型，模型图如下图 2-4 所示，通过卷积层得到每个节点的自注意力分数，基于 Top-K 算法选取下一层节点并将上层节点特征与该节点的自注意力分数点乘作为子图节点的表示。

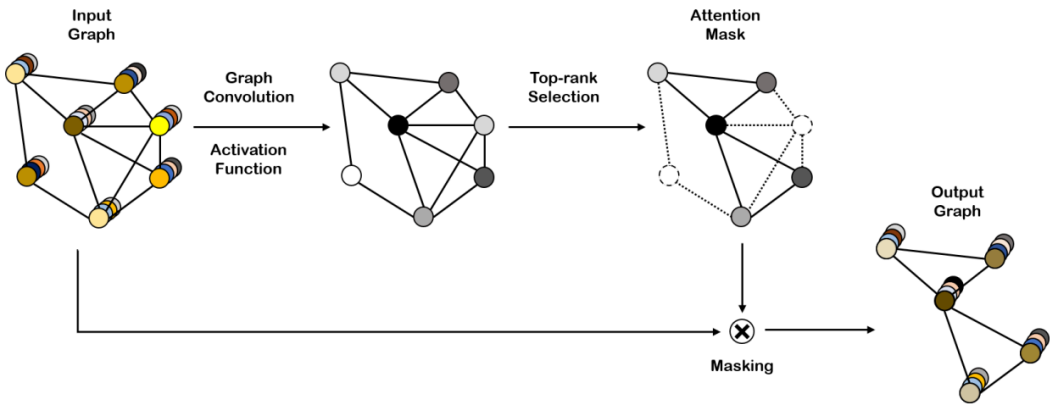

图 2-4 自注意力池化层示意图[40]

中国知网 https://www.cnki.net

2.4 多模态预训练模型研究现状

多模态数据是指针对同一个对象，从不同的领域或者角度进行描述，其中描述的每一个领域的数据可以看作一个模态。随着自监督和对比学习的不断发展，目前多模态预训练模型在视觉和语言信息融合方面已经发挥着重要作用。相比较于单模态的预训练，多模态预训练模型可以获得不同模态间的远程关联信息，从而充分挖掘被描述对象的特征。目前，多模态融合模型通过自监督或者对比学习预训练，然后在下游任务中微调已经成为多模态任务中较为主流的方式。大规模的预训练数据集使得预训练模型对特征挖掘更加敏感，下游微调模型以预训练模型为起点进行训练可以有效减少训练次数且模型获得了更好的泛化性。下文将从多模态预训练模型的结构、预训练任务以及目前较为经典的模型进行展开。

2.4.1 多模态预训练模型结构

目前来看，多模态预训练模型有两种主流架构：单流架构和双流架构。其共同点是最后都会通过 Transformer 进行模态间的融合并输出特征。单流架构是在早期将不同模态的信息拼接在一起，然后通过注意力机制完成模态间的交互。其好处是将单模态的特征提取和多模态之间的交互共享一套参数模型，大大减少了参数的数量，同时有效减少了模型训练的时间。然后单流架构的输入特征是较为原始，没有很好的学习到单模态的特征，双流架构首先会对不同模态分别进行编码，然后通过注意力机制完成跨模态之间的融合。双流架构通常比较灵活，通常会因为视觉特征信息较为重要而有较多的网络层。但双流架构增加模型的复杂性导致训练和推理成本的增加，同时需要更多的计算资源。

2.4.2 多模态预训练任务

（1）跨模态掩码语言建模任务（Cross-Modal Masked Language Modeling, MLM）：指对文本句子随机屏蔽一些词语，然后通过不同模态之间的信息交互推理出被屏蔽掉的词语内容，从而让不同模态之间的信息产生关联和上下文信息的依赖，并且做到跨模态之间信息的对齐。

（2）跨模态掩码区域预测任务（Cross-Modal Masked Region Prediction, MRP）：类比于 MLM 任务，掩码区域预测任务通过随机屏蔽视觉的部分信息，然后根据其他的图文特征信息预测。然后根据预测内容的不同，可以分为掩码区域分类（Masked Region Classification, MRC）和掩码区域特征回归（Masked Region Feature Regression, MRFR）两个方向。MRC 任务预测的是图像高层次的语义，相当于做物体的分类

中国知网 https://www.cnki.net

任务；而 MRFR 任务意在通过未被屏蔽区域的图文信息回归预测被屏蔽区域的原始特征信息。

（3）图像-文本匹配任务（Image-Text Matching, ITM）：该任务本质属于二分类任务，给定图像和文本对判断是否匹配。相比较与之前的任务，ITM 任务更多的是为模型提供在粗粒度上对齐的能力。

（4）图像文本对比学习任务（Image-Text Contrastive Learning）：通常会构造一组正负样本对。正样本对由相同的图像和文本组成，负样本对则由不同的图像和文本组成。模型要求使正样本对的表示在共享空间中更加接近，负样本对在这个空间中更加原理。其目标是通过对比学习让模型学习对比图像和文本的表达，从而使图像和文本在共享的表示空间中更加接近。

Kim 等人[41] 根据视觉和语言两种模态的表达能力与不同模态间在深层网络的交互程度，将多模态预训练模型分成了四类，如图 2-5 所示，图中 VE、TE 和 MI 分别代表 Visual Embedding、Text Embedding 和 Modality Interaction。

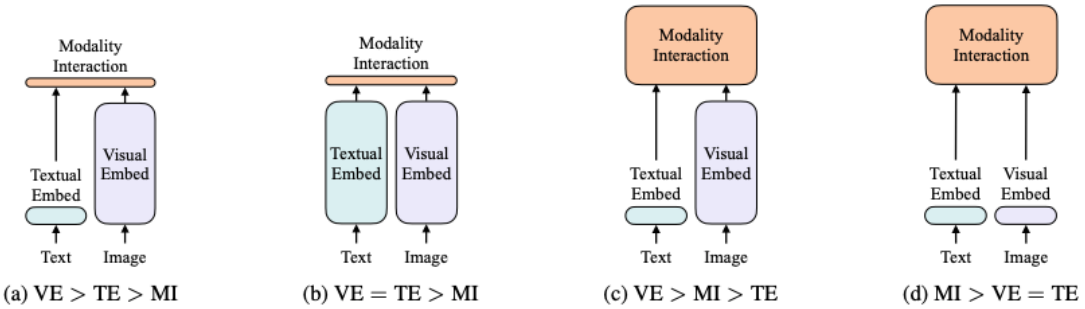

图 2-5 四类视觉和语言模型[41]

传统的多模态融合通常认为视觉特征发挥着较为重要的作用，所以会通过较多参数的目标检测提取器作为 Visual Embedding，在模态融合层通常只是通过简单的点积进行跨模态间的交互，如上图 2-5（a）所示。模态间融合的是否充分决定了多模态预训练模型的效果，如上图 2-5（c）所示，目前的主流模型通常将 Transformer Encorder 作为 Modality Interaction 层，利用其全局的注意力机制取得了较好的效果。受到 Visual transformer[42] 的影响，将图片划分成不同 token 然后可以像类似于编码文本的方式进行 Visual Embedding，大大降低了计算的复杂度，该模型如上图 2-5（d）所示。

2.4.3 多模态预训练模型的发展以及在蛋白质领域的应用

2021 年，OpenAI 提出的 CLIP[43] 模型采用对比学习的方法，联合训练图像和文本编码器将不同模态的特征映射到共享的表示空间，通过最大化真实图文向量

中国知网 https://www.cnki.net

的余弦相似度最小化不匹配图文向量的余弦相似度进行 zero-shot 学习。但 CLIP 在大规模数据集上训练可能需要耗费较大的时间和计算开销。同年提出的 ViLT 模型[41] 认为在多模态领域视觉模块的特征往往更加重要同时也要注重两种模态在深层网络中是否有交互。同时也创新的提出在 MLM 任务中屏蔽所有文本中的词语往往能够使得模态间更好的交互，在下游视觉问答（Visual Question Answering, VQA）等任务中有较好的效果。ALBEF 模型[44] 主要的贡献点在模态融合前对齐和动量蒸馏算法。通过在单模态编码器的特征上引入中间的 ITC（Intra-Task Contrastive）损失，将图像和文本特征对齐使多模态编码器更容易的进行跨模态学习。同时为了解决脏数据提出动态蒸馏算法，在训练时通过模型参数的移动平均保留一个动量版本模型，使用动量模型生成伪标签作为额外的监督信号。VLMo[45] 引入 MoME Transformer，即每个块包含特定模态的处理模块和一个共享自注意力层。其中 MoME Transformer 共包含三个模态模块：图像编码的视觉模块、文本编码的语言模块和图文融合模块。并提出分阶段的预训练策略，首先使用图像数据预训练视觉模块和自注意力层，然后使用文本预料训练语言模块，最后将训练好的模型作为初始化进行融合模块的训练。然而以上模型在下游 VL（Vsion and Language）任务中表现不佳，针对此 2022 年提出的 BLIP 是[46] 更适用于下游任务的新模型结构，并引入了从网络噪声数据中进行学习的新方法。通过高效的多任务预训练和灵活的迁移学习的新模型结构–多模态混合编码器-解码器结构（Multimodal mixture of Encoder-Decoder，MED），联合三个预训练任务：ITC、ITM 和 MLM 进行训练，在下游多个 VL 任务中均取得了最优的效果。2022 年，VLMo 相同的团队提出了 BEIT-3 模型[47]，其主要的改进点是相比于传统的多个预训练任务，BEIT-3 模型仅使用一个预训练任务 mask-then-predict 训练一个通用的多模态基础模型。在预训练过程中，按比例随机遮掩文本特征或者图像分片，训练模型来恢复遮掩特征，不仅能够学习到特征表示，同时还能够学到不同模态之间的对齐，同时仅仅一个预训练任务使模型有更好的扩展性。

类比于图像和文本的多模态预训练任务，Xue 等人[21] 提出了蛋白质多领域的序列-结构-功能多模态预训练模型 S2F。其蛋白质序列的编码通过蛋白质语言模型嵌入，蛋白质结构则通过拓扑片编码提取特征，蛋白质的功能标签通过 One-Hot 编码。通过单流结构的 Transformer 模型进行不同模态间的融合，通过上游的对齐和补全任务学习到完整的蛋白质表示，在下游蛋白质功能预测和蛋白质相互作用网络预测中均取得了较好的效果。

中国知网 https://www.cnki.net

2.5 本章小结

本章首先介绍了对蛋白质功能术语预测做了数学定义，然后通过介绍功能标签-基本本体 GO 标签的概念以及其层次结构的组成对该问题的输出做了进一步限制，阐述了本文主要解决问题的内容。随后主要围绕网络表征算法和多模态预训练模型展开。针对于网络表征算法，分别介绍了基于无监督学习的图嵌入方法、基于监督学习的图神经网络方法和基于图神经网络的图分类算法。在后续实验中，蛋白质三维结构中氨基酸节点的表示则是通过图嵌入算法来实现，而蛋白质节点的整图分类需要通过图神经网络进行消息传播与聚合。在多模态领域，首先介绍了多模态预训练模型结构的分类和常见的训练任务，随后本文梳理了近年来较为经典的多模态预训练模型，为之后的研究做好了铺垫。

中国知网 https://www.cnki.net

第 3 章 基于结构和图分类算法的蛋白质功能预测

3.1 引言

近年来，蛋白质结构预测取得重大突破，DeepMind 团队开发的 AlphaFold2 模型在 CASP14 中取得优异成绩，该模型可以预测原子级别的蛋白质结构。目前，利用深度学习的方法自动注释蛋白质功能标签的模型通常基于蛋白质序列提取特征并与蛋白质相互作用网络结合的方法取得了较好的效果，但对于不在蛋白质相互作用网络中的新序列，此类模型无法进行有效预测。同时在自然界中结构决定功能是普遍的法则，AlphaFold2 预测了并开源了包括人类在内的 2.14 亿蛋白质结构，因此本章节主要介绍如何通过充分挖掘蛋白质结构信息预测蛋白质功能展开。具体来讲，本章节提出了一种基于注意力机制的层次化图池化方法，将每个蛋白质的结构看作网络通过池化算法充分挖掘结构与功能的联系。

本章节的组织结构如下：3.2 节介绍数据集的获取来源以及蛋白质序列和蛋白质结构三维原子坐标的预处理过程；3.3 节介绍注意力机制层次化图池化算法的构建；3.4 节介绍了实验评价指标，并展示了对比和消融实验结果并进行合理性的分析；3.5 节是本章节的总结。

3.2 数据集的获取和预处理

3.2.1 数据集的获取

本实验中，首先从 EMBL-EBI 数据库获取人类通过 AlphaFold2 预测的蛋白质结构数据，其中人类数据集包括 23391 个蛋白质结构。随后在目前已有的 50 多万蛋白质功能标签中提取通过实验获取的注释，即证据代码（Evidence Code）为‘IDA’，‘IPI’，‘EXP’，‘IGI’，‘IMP’，‘IEP’，‘IC’或‘TA’的注释，最终筛选出 20395 条关于人类蛋白质的功能注释。同时，在基因本体官方网站可以获取最新的蛋白质功能注释标签，即基因本体数据。将所有标签梳理为 BPO、CCO、MFO 三大类，然后根据各个标签之间的关系构建层次树状图。值得注意的是，某些标签因出现频率较低会增大后期实验部分的噪声，因此将标签阈值设置为 50，即将人类蛋白质的所有功能标签中出现频率少于 50 次的标签过滤。补全并过滤处理后 BPO、MFO、CCO 标签数分别为为 809、273、298。同时，为了展示数据的复杂性与严谨性，随后计算了过滤后三个分支所包含的功能术语占总标签的百分比，如

中国知网 https://www.cnki.net

下表所示：

表 3-1 不同分支 GO 标签数量

分支	过滤后 GO 标签数量	真实 GO 标签数量	百分比
BPO	809	3208	25.23%
MFO	273	1810	15.08%
CCO	298	1879	15.87%

每种蛋白质可能和一个或者多个 GO 标签术语相关联，事实上这对于评估数据的复杂性和任务预测的潜在挑战至关重要。本文提供了原数据中 BPO、MFO 和 CCO 分支中所有人类蛋白质对应的 GO 术语，并绘制直方图展示不同蛋白质的 GO 标签数量，如下图 3-1 所示。

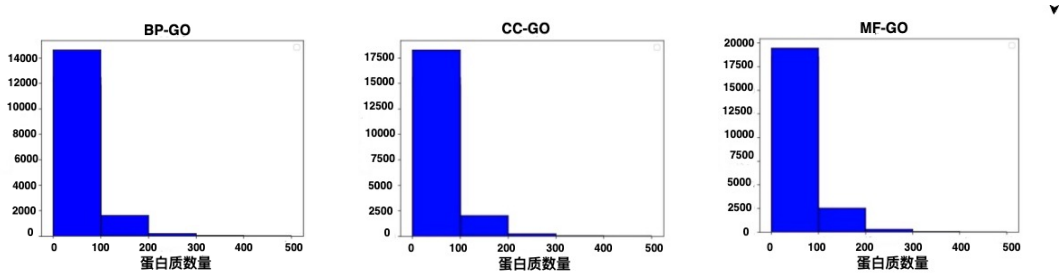

(a) BP 分支蛋白质关联标签 (b) CC 分支蛋白质关联标签 (c) MF 分支蛋白质关联标签

图 3-1 三个分支下蛋白质关联标签数量分布直方图

3.2.2 蛋白质序列特征的提取

在自然语言处理领域，随着 Bert[48] 和 XLNet[49] 等大规模预训练模型的提出推动了近年来该领域的蓬勃发展。在生物学领域，将蛋白质序列看作语句可以自然的应用 NLP 相关算法提取氨基酸序列的特征，目前在该领域已有多种蛋白质序列的大规模分布式语言模型出现，其中 SeqVec（Sequence Vector）模型应用较为广泛。SeqVec 是一种用于表示蛋白质序列的深度学习模型，该模型通过大规模的无监督预训练，将蛋白质序列映射到固定维度的向量表示，通过捕获序列中的关键特征学习蛋白质的序列表示。具体来讲，SeqVec 模型利用 CharCNN[50] 算法提取氨基酸的局部特征，然后使用两层双向长短期记忆网络（BiLSTM）构建语言模型，通过平均聚合字段特征和语言模型来获取单个氨基酸特征，即对于第 k 个氨基酸，其表示为：

$$\mathbf{SeqVec}_k = x_k^{LM} + h_{k,1}^{LM} + h_{k,2}^{LM} \tag{3-1}$$

中国知网 https://www.cnki.net

$$h_{k,j}^{LM} = \left[\overrightarrow{h}_{k,j}^{LM}; \overleftarrow{h}_{k,j}^{LM}\right] \tag{3-2}$$

其中 x_k^{LM} 是 CharCNN 层输出的上下文无关的 1024 维字符特征，$\overrightarrow{h}_{k,j}^{LM}$、$\overleftarrow{h}_{k,j}^{LM}$ 分别表示第 j 层前向和后向 LSTM 层输出的 512 维向量，这两个输出向量通过拼接构成 1024 维特征作为第 j 层 BiLSTM 模型的输出。最后，SeqVec 模型将残基级别特征拼接成 $\mathbf{1024} \times \mathbf{N}$ 的矩阵，并通过主成分分析或平均聚合等方法将该矩阵降维生成 $\mathbf{1024} \times \mathbf{N}$ 维单条蛋白质序列的特征向量。在具体实现上，该模型首先使用 UniRef50 数据库中大约 33M 条序列进行预训练。然后将人类蛋白质序列作为输入，对于其每一条蛋白质序列，可以得到一个 $\mathbf{1024} \times \mathbf{N}$ 的特征向量作为蛋白质序列特征，在后续模型中结合其结构特征用于下游蛋白质功能预测。

3.2.3 蛋白质接触图的构建

蛋白质结构与功能有着紧密的联系，为了更好的通过蛋白质的结构信息推断蛋白质相关功能，将蛋白质三维结构转化为二维的蛋白质接触图，通过构建蛋白质结构网络聚合其相邻残基的信息，最终获得蛋白质结构特征。具体实现上，通过 AlphaFold2 可以得到蛋白质结构的三维原子坐标，进而可以计算氨基酸残基中 $C\alpha$ 原子两两之间的相对距离。如果两者之间的相对距离小于 10 Å，则认为这两个残基之间有边直接相连。根据此方法可以建立蛋白质接触图。

3.2.4 氨基酸残积水平嵌入

在蛋白质结构网络中的每个节点就是氨基酸残基，为了获得节点的特征，最直观的方法是用 one-hot 编码 26 个不同的氨基酸，但是该方法未能捕获到相同氨基酸在不同蛋白质网络中的位置信息。因此采用图表示学习方法学习节点在蛋白质网络中的结构信息。图表示学习将离散非欧式空间中的节点嵌入得到连续低维欧式空间中，在现有的网络表示学习方法中，DeepWalk[26] 是最具有代表性的算法之一，其将 word2vec[51] 思想扩展到图数据，认为相邻节点具有相似的嵌入向量。DeepWalk 使用随机游走算法提取节点邻域信息，通过随机抽样策略选择邻居节点。Node2vec[23] 在此基础上进行优化，该算法通过偏随机游走的方式获取图中节点的近邻序列，即若当前顶点为 x_1，其下一跳邻居节点 x_2 访问的概率被赋予一种偏向性，其概率表达为：

$$P(c_i = x_2 \mid c_{i-1} = x_1) = \begin{cases} \dfrac{\pi_{x_1 x_2}}{Z} & (x_1, x_2) \in E \\ 0 & (x_1, x_2) \notin E \end{cases} \tag{3-3}$$

中国知网 https://www.cnki.net

其中是 $\pi_{x_1x_2}$ 顶点 x_1 和顶点 x_2 之间的未标准化概率，Z 是标准化常数。Node2vec 引入两个超参数 p 和 q 来调节漫步策略，假设当前随机游走经过 (x_1,x_2) 到达顶点 v，设 $\pi_{x_1x_2}=\alpha_{pq}(x_1,x_2)\cdot w_{x_1x_2}$，$w_{x_1x_2}$ 是顶点 x_1 和 x_2 之间的边的权重。

$$\alpha_{pq}(x_1,x_2)=\begin{cases}\dfrac{1}{p} & d_{x_1x_2}=0\\ 1 & d_{x_1x_2}=1\\ \dfrac{1}{q} & d_{x_1x_2}=2\end{cases} \tag{3-4}$$

其中 $d_{x_1x_2}$ 为顶点 x_1 和顶点 x_2 之间的最小路径长度。在具体的实现方面，本实验是基于腾讯开源分布式机器学习平台 Spark-On-Angel[52]，利用 Spark 提供的高效的数据存储、更新、共享服务进行实现 Node2vec 算法进行图计算。在输入的蛋白质中，其氨基酸残基个数均在 1500 以下，所以在 Node2vec 中选择游走的长度为 30，p 设置为 0.8，q 设置为 1.2，结合每个残基的 one-hot 编码，最终针对蛋白质中每个残基生成 1x56 维度的特征向量。

3.3 注意力机制层次化图分类模型建立

本章节实现的蛋白质功能预测模型，其理论依据是结构或序列相似的蛋白质可能具有相似的功能。因为同一蛋白质可能具有多种功能，所以该模型本质是实现多标签分类任务。本文采用基于自注意力的图池化机制，将上述获取的蛋白质接触图与氨基酸残基特征作为输入，通过图卷积与层次池化提取蛋白质结构特征，并融合上述序列特征作为下游蛋白质功能预测多标签分类器的输入。

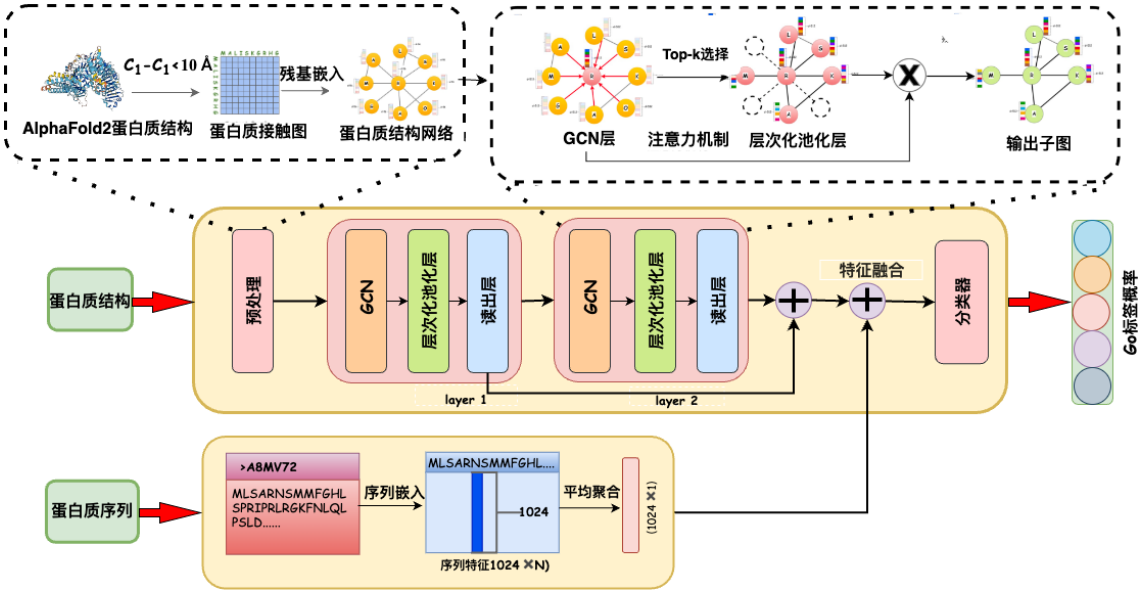

图 3-2 基于结构和图分类算法的蛋白质功能预测模型图

中国知网 https://www.cnki.net

3.3.1 图神经网络卷积层

在该阶段，将蛋白质的接触图作为邻接矩阵，氨基酸残基特征作为图中节点特征，通过图卷积在结构与结构相近的残基之间传播其特征。探索了几种较为广泛使用的图卷积函数，其中包括 Kipf Welling graph convolutional layer（GraphConv）[29]、Chebyshev spectral graph convolutions（ChebConv）[53]、SAmple and aggreaGatE convolutions（SAGEConv）[54] 和 Graph Attention（GAT）[31]，比较了不同图卷积方法对结果的影响，通过实验表明两层的 GraphConv 模型取得了最好的表现。在每一层中，通过邻居消息传播与聚合得到新的隐含表示：

$$h^{(1+1)} = \sigma\left(\widetilde{\mathcal{D}}^{-\frac{1}{2}} A \widetilde{\mathcal{D}}^{-\frac{1}{2}} h^{(l)} \Theta\right) \tag{3-5}$$

其中 $h^{(l)}$ 代表第 l 层节点的表示，$\Theta \in \mathbf{R}^{\mathbf{F}\times\mathbf{F}'}$ 是可学习的卷积权重，$\widetilde{\mathcal{D}} \in \mathbf{R}^{\mathbf{N}\times\mathbf{N}'}$ 是的度矩阵，$A \in \mathbf{R}^{\mathbf{N}\times\mathbf{N}'}$ 是具有自连接的邻接矩阵。

3.3.2 自注意力机制层次化图池化算法

自注意力机制近年来被广泛应用于深度学习模型中并取得良好效果，该机制使得模型更多的关注重要的特征。Junhyun Lee[40] 等人将自注意力机制引入图池化模型中，通过叠加卷积层并将输出特征转化为一维得到各个节点的重要性得分。然后采用 Cangea 等人[55] 提出的节点选择算法，保留部分输入图的节点和边并生成新的子图作为下一层的输入。其中池化比是决定保留节点数量的参数，基于自注意力卷积层得到的各节点重要性得分来选择下一层节点。在模型的应用中采用两头注意力机制分别得到每个节点的两个重要性得分并求均值最为最后得分，在实验中该方法有效提高了模型的性能。

$$\text{idx} = \text{Top} - \text{Rank}(\mathbb{Z}, [\text{kN}]) \quad \mathbb{Z}_{\text{mask}} = \mathbb{Z}_{\text{idx}} \tag{3-6}$$

$$X_{\text{out}} = X' \odot \mathbb{Z}_{\text{mask}} \quad A_{\text{out}} = A_{\text{idx,idx}} \tag{3-7}$$

其中 X' 是保留节点的原始特征，X_{out} 是保留节点的生成特征，$\mathbb{Z}_{\text{mask}}$ 是保留节点对应的重要性得分，A_{out} 是保留节点生成子图的邻接矩阵。

3.3.3 图读出层

Xu K[56] 等人在论文中证明，在图分类领域中，相较于 mean-pooling 与 max-pooling，sum-pooling 显示出更好的效果，在 sum-pooling 中将图中所有节点特征求和，可以学习全部的标签进而可以提取更多的信息。在层次池化模型中，采用将

中国知网 https://www.cnki.net

sum-pooling 拼接 max-pooling 的方式提取该层的图特征，最终将多层的图特征求和作为该蛋白质的结构特征。每层图池化公式如下：

$$S = \frac{1}{N}\sum_{i=1}^{N} X_i || \max X_i \tag{3-8}$$

其中 N 为该层中节点的个数，X_i 代表第 i 个节点的特征，|| 代表特征拼接。

蛋白质功能预测模型整体流程如下面伪代码 3-1 所示，输入由蛋白质结构网络即蛋白质接触图、预训练得到的氨基酸残基特征和蛋白质序列特征组成，在 K 层图池化算法中，每层有两个GCN叠加，第一层GCN聚合邻居信息得到下一层网络中节点的特征 H^{i+1}，第二层 GCN 输出 1 维的特征值作为节点重要性得分 $Score^i$，由Top-Rank算法选择节点组成子图。该层的输出值由各个节点特征值 H^{i+1} 和其重要性得分相乘并由公式 3-8 计算得到读出值 $Readout^i$。最终叠加 K 层读出值并拼接序列特征，由多层感知机算法进行线性变换得到每个标签出现的概率 $labels$。

算法 3-1 注意力机制层次化图分类算法伪代码

算法 3-1 注意力机制层次化图分类算法伪代码

Input: 蛋白质结构网络 $G(V, E)$
氨基酸残基特征 $F = \left\{f_v, \forall v \in V\right\}$
蛋白质序列特征 S
层次化迭代层数 K

Output: 蛋白质功能标签概率 $labels$

```
h_v ← f_v 获取节点特征
final_readout ← None
for l in K do
    H^{l+1} ← GCN_Layer1(G^l, H^l)
    Score^l ← GCN_Layer2(G^l, H^l)
    Readout^l ← H^{l+1} * Score^l
    G^{l+1} = Top-Rank(G^i, Score^i)
    final_readout ← final_readout+Readout^l
end
f_con = Concatente(final_readout, S)
labels = MLP(f_con)
return labels;
```


中国知网 https://www.cnki.net

3.4 实验和结果分析

3.4.1 蛋白质功能预测评价指标

本实验中选取了 AUC，AUPR，Fmax 这 3 种参数来评价蛋白质功能标签注释模型的性能[57]。

1. AUC（Area Under the Curve）参数表示 ROC（Receiver Operating Characterstic Curve）曲线下的面积，其取值范围通常在 0 到 1 之间，越接近于 1 代表模型的分类能力较好。在衡量不平衡类别的分类问题时，AUC 通常具有更好的鲁棒性。

2. AUPR（Area Under the Precision-Recall Curve）是通过计算 Precision-Recall 曲线下的面积获得，其主要用于度量分类模型在不同分类阈值下的性能。其值范围通常也在 0 到 1 之间，0 代表随机，1 代表完美性能。同样，AUPR 对于正负样本分布不均匀的情况有更好的鲁棒性，并且能够更好的关注正例样本分类时的表现。

3. Fmax 综合考虑模型的精准率和召回率，对于给定的阈值，测试集上的平均精准率（pr）、平均召回率（rc）以及 Fmax 定义如下：

$$\mathrm{pr}(\tau) = \frac{1}{\mathrm{m}(\tau)} \sum_{\mathrm{i}=1}^{\mathrm{m}(\tau)} \mathrm{pr_i}(\tau) \tag{3-9}$$

$$\mathrm{rc}(\tau) = \frac{1}{\mathrm{n}} \sum_{\mathrm{i}=1}^{\mathrm{n}} \mathrm{rc_i}(\tau) \tag{3-10}$$

$$\mathrm{Fmax}(\tau) = \max_{\tau \in [0,1]} \{\frac{2 \cdot \mathrm{pr}(\tau) \cdot \mathrm{rc}(\tau)}{\mathrm{pr}(\tau) + \mathrm{rc}(\tau)}\} \tag{3-11}$$

其中，$\mathrm{m}(\tau)$ 指的是至少有一个功能标签的预测概率大于或等于阈值 (τ) 的蛋白质个数，n 指测试集中的蛋白质总数。$\mathrm{pr_i}(\tau)$ 与 $\mathrm{rc_i}(\tau)$ 指第个蛋白质在阈值下的预测精准率和召回率，其定义分别为：

$$\mathrm{pr_i}(\tau) = \frac{|\mathrm{T} \cap \mathrm{P_i}(\tau)|}{|\mathrm{P_i}(\tau)|} \tag{3-12}$$

$$\mathrm{rc_i}(\tau) = \frac{|\mathrm{T} \cap \mathrm{P_i}(\tau)|}{|\mathrm{T}|} \tag{3-13}$$

其中，T 代表功能标签集合，$\mathrm{P_i}(\tau)$ 指阈值下第个蛋白质的预测标签集合。

3.4.2 对比实验结果与分析

为了验证本文中模型的性能，在人类蛋白质数据集中，通过使用三个不同的模型来预测三个分支的功能进行实验。并与目前主流的模型进行比较，其中包括

中国知网 https://www.cnki.net

Naïve[58]、BLAST[5]、DeepGO[9] 和 DeepGOA[18] 以及 DeepFRI[11] 和 GAT-GO[12]。Naïve 和 BLAST 是流行的基线方法。Naïve 算法主要依据统计学算法中已知功能标签出现的概率对新蛋白质进行功能预测。BLAST 是一种基于序列相似性比对的方式，通过在已知数据库中进行大量序列比对，找到序列局部相似性生成功能打分矩阵进行预测。DeepGO 是最早的深度学习模型之一，它使用序列数据和 PPI 相互作用网络数据，基于层次分类器对蛋白质进行注释。DeepGOA 创新引入 GCN 获取 GO 中的知识指导预测，在人类和玉米的蛋白质数据集上取得了良好的效果。DeepFRI 通过将蛋白质三维结构转化为接触图并利用 GCN 提取结构特征进行蛋白质功能预测。GAT-GO 在 DeepFRI 的基础上将聚合函数 GCN 改为 GAT，并通过实验验证取得较好结果。将在 F-max、AUC 和 AUPR 标准下，将本文中的模型与其他算法进行比较。

表 3-2 人类蛋白质数据上的对比实验结果

Model	BPO			CCO			MFO		
	Fmax	AUC	AUPR	Fmax	AUC	AUPR	Fmax	AUC	AUPR
Naïve	0.344	0.500	0.566	0.551	0.487	0.377	0.326	0.499	0.528
BLAST	0.339	0.577	0.489	0.441	0.563	0.269	0.411	0.623	0.461
DeepGO	0.327	0.639	0.571	0.589	0.695	0.448	0.404	0.760	0.625
DeepGOA	0.385	0.698	0.622	0.629	0.757	0.500	0.477	0.820	0.710
DeepFRI	0.425	0.732	0.635	0.624	0.779	0.641	0.542	0.881	0.763
GAT-GO	0.462	0.586	0.512	0.647	0.831	0.681	0.633	0.912	0.776
Struct2GO	**0.475**	**0.870**	**0.652**	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**

从表 3-2 可以看出，与其他主流模型相比，本文中的模型的预测性能在多个指标上均有明显的提高，这在一定程度上得益于本文针对与蛋白质数据集的处理与模型的设计，通过 AlphaFold2 提供的数据集充分挖掘蛋白质结构信息并结合序列特征的方法，有效提高了蛋白质功能注释模型的性能。同时，在所有的分支中，MFO 分支取得较好的预测结果，反之 BPO 分支预测的准确率普遍较低，这可能与不同分支的标签数目有关，往往较少的标签数更容易取得较高的准确率。同时，在上表中可以观察到相比较与 AUC 和 AUPR 的值，Fmax 的值明显略低。在蛋白质功能预测中，一些功能标签可能比其他功能标签少，导致数据不平衡，在这种情况下 AUC 和 AUPR 的值往往高于 Fmax。并且 AUC 和 AUPR 是综合指标，而 Fmax 只是一个点估计，因此较高的 AUPR 或者 AUC 值可能表明该模型在多个阈值上表现相对较好。为了获得所有 GO 术语的性能指标以对模型性能提供更加公平的评价，获得了 MFO、CCO 和 BPO 测试集中所有 GO 标签的性能指标，并绘制直方图如图 3-3 所示。

中国知网 https://www.cnki.net

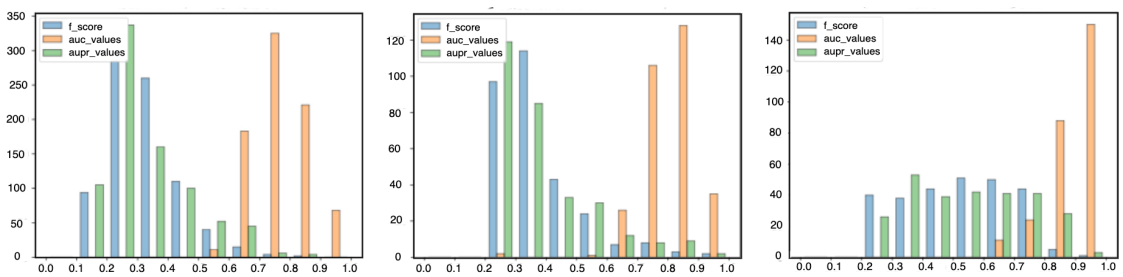

(a) BP 分支签概率分布　(b) CC 分支标签概率分布　(c) MF 分支标签概率分布

图 3-3 三个分支下蛋白质标签在测试集中预测概率分布直方图

接下来，分别比较模型中各个组成部分的不同变体，通过实验验证目前本文中的模型在各个变体中取得最好的效果。在通过蛋白质接触图提取结构特征时，分别用 GraphConv、ChebConv、GATConv、SAGEConv 四种不同的聚合函数进行实验，通过实验结果可以看出，聚合函数的选取对模型精确度没有较大影响，但 GraphConv 往往在各项数据取得较好的结果。接下来分别比较 SumPool、AvgPool、MaxPool 在图读出时对模型性能的影响，正如 Xu K[56] 所阐述的 SumPool 方法可以积累到更多的特征，在区分图结构的任务中往往可以取得较好的效果。在本模型中，层次图池化的效果要明显好于全局图池化，可能是在类似于蛋白质接触图这种具有大量节点的数据中，层次图池化能够有效地从大规模图中提取有用的信息。最后，在基于自注意力机制进行层次化池化时，比较了单层与双层自注意力层的效果，实验结果可以看出，多头注意力层可以学习到更多有效信息往往在实验中有较好表现。

表 3-3 模型不同模块对比实验

Model	BPO			CCO			MFO		
	Fmax	AUC	AUPR	Fmax	AUC	AUPR	Fmax	AUC	AUPR
GraphConv	**0.475**	**0.870**	**0.652**	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**
ChebConv	0.465	0.868	0.745	0.637	0.938	0.719	0.665	0.952	0.695
GATConv	0.457	0.869	0.749	0.623	0.931	0.703	0.678	0.953	0.705
SAGEConv	0.457	0.869	0.749	0.623	0.931	0.703	0.678	0.953	0.705
SumPool	**0.475**	**0.870**	0.652	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**
AvgPool	0.358	0.786	0.627	0.544	0.890	0.686	0.404	0.838	0.503
MaxPool	0.457	0.864	**0.731**	0.633	0.936	0.720	0.667	0.953	0.696
Hierarchical	**0.475**	**0.870**	**0.652**	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**
Global	0.364	0.789	0.613	0.542	0.890	0.683	0.402	0.838	0.601
2_layer_attention	**0.475**	**0.870**	**0.652**	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**
1_layer_attention	0.456	0.867	0.745	0.629	0.935	0.728	0.634	0.942	0.672

随后，针对几种不同蛋白质接触图生成方式进行对比实验。在前文的模型中

中国知网 https://www.cnki.net

采用计算氨基酸残基 $C\alpha$ 原子之间相对距离的方式将蛋白质三维坐标转换为二维表示，为了提高本文模型实验的严谨性，接下来将和另外两种不同的蛋白质接触图方式进行对比实验：1）ANY-ANY：如果氨基酸残基中任何一个原子与另一个氨基酸中的原子之间的距离小于 10Å 就认为存在直接相连的边。2）NBR：如果他们 Rosetta 相邻原子之间的距离小于氨基酸相邻半径的和，则认为存在直接相连的边。在 MF-GO 注释的蛋白质数据集上对三种不同方法进行训练，实验结果如图 3-4 所示。

根据实验数据，可以观察发现：1）使用 ANY-ANY 方法的结果最差，可能是该计算方式会标记许多错误的接触从而产生较大的误差，同时该方式的计算和时间开销也较大。2）NBR 方法略好于 CA-CA 的方式，可能是因为该方法考虑了氨基酸之间侧链之间的关系。然而考虑到实验的计算性能和内存开销，以及在预处理过程中只是粗略地获得蛋白质的二维结构以及进行后续的特征提取，所以在本文的实验中仍然采用 CA-CA 方法。

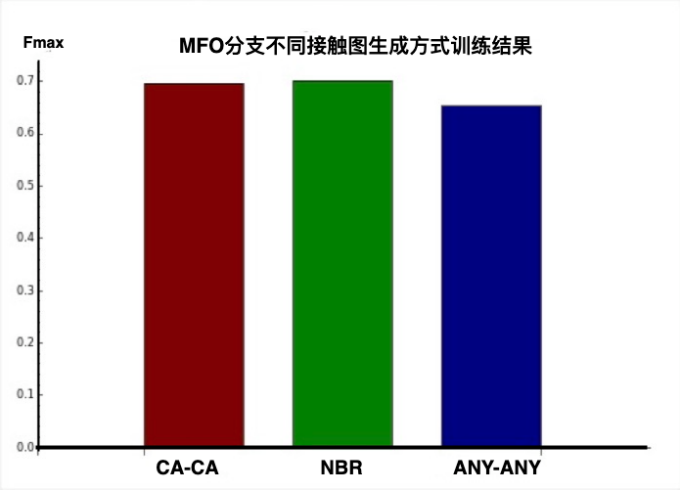

图 3-4 MF 分支上采用不同接触图方式训练的对比实验结果

3.4.3 消融实验结果与分析

在本节中进行消融实验，以比较本模型中每个组件对性能改进的贡献。依次删除蛋白质的结构特征、蛋白质序列特征、氨基酸 one-hot 编码和氨基酸结构特征，然后比较其余模型的性能，实验数据如表 3-4 所示。通过实验数据可以看出，去掉任何一个组件都会导致模型性能的损失，充分证明了本文中模型的各个组件都是有效的。在消融实验中，当移除掉 GCN 通过 AlphaFold2 提取的蛋白质结构特征后，导致模型性能下降最大。因此可以看出蛋白质的结构与功能有较强关联。其次可以看到，在分别移除氨基酸的 one-hot 编码和利用 Node2vec 提取氨基酸特征

中国知网 https://www.cnki.net

后，对模型性能均有较小影响。可以认为氨基酸的 one-hot 编码代表语意信息，而基于 Node2vec 从蛋白质接触图中提取的为氨基酸的结构特征，两者相互结合可以使得本文中的模型更为充分的挖掘蛋白质的结构特征。

表 3-4 人类蛋白质数据上的消融实验结果

Model	BPO			CCO			MFO		
	Fmax	AUC	AUPR	Fmax	AUC	AUPR	Fmax	AUC	AUPR
Without Structure	0.361	0.788	0.427	0.544	0.886	0.680	0.422	0.863	0.634
Without One-hot	0.438	0.854	0.609	0.625	0.934	0.727	0.648	0.947	0.752
Without Node2vec	0.430	0.850	0.602	0.584	0.925	0.714	0.636	0.946	0.694
Without Sequence	0.429	0.851	0.595	0.579	0.924	0.705	0.594	0.945	0.707
Our Model	**0.475**	**0.870**	**0.652**	**0.653**	**0.938**	**0.735**	**0.696**	**0.967**	**0.782**

3.4.4 模型参数敏感性分析

在本节中，分别分析参数 Dropout、Learning Rate、Pooling Ratio 和 conv Number 对模型的影响。采取控制变量的方法，每次只改变一个参数进行多次对比实验，通过观察训练后模型的性能，分析该参数对模型的实际影响以选取最优参数值。超参数对比实验的范围如表所示。

表 3-5 不同超参数的选取范围

超参数	范围
Dropout	0.3, 0.35, 0.4, 0.45, 0.5
Learning Rate	0.1, 0.01, 0.001, 0.0001
Pool Ratio	0.25, 0.5, 0.75
Conv Number	1, 2, 3, 4

Dropout 主要影响模型的鲁棒性，在深度网络中使用 Dropout 可以减少过拟合，从而提高模型的泛化能力。从表中的实验，结果不难发现不同的 Dropout 对模型的性能影响较小，其中当 Dropout 为 0.3 时，模型取得了略好的性能，同时为了加速模型的收敛速度，选择较为保守的 Dropout 值，即 0.3。

Learning Rate 主要影响模型的收敛性。从图中的实验结果中，观察到当 Learning Rate 为 0.01 时模型的分类性能最差，这说明学习率过高可能导致损失函数在一定范围内来回摆动，最终阻碍模型收敛到最佳参数。随着学习率的不断递减，模型的性能逐渐提高，但同时意味着需要更多的训练批次才能收敛到最优值。最终考虑训练时间与模型的平衡，将 Learning Rate 设置为 0.0001。

中国知网 https://www.cnki.net

Conv Number 代表在层次化池化过程中，每次需要的卷积层数。当 Conv Number 为 1 时，意味着只能学习到直接邻居的特征，随着 Conv number 的增大意味着图中的节点能够学习到更多间接邻居的特征，但同时也会导致模型过拟合问题的产生。实验结果表明不同的 Conv Number 模型性能只有略微差别，当 Conv Number 为 2 时模型取得最优效果。

Pool Ratio 代表在层次化过程中，下一层生成的子图中节点的个数占原图的比例即池化比，若 Pool Ratio 为 1 则退化为全局池化。在比较图中的实验结果，发现当 Pool Ratio 为 0.75 时模型效果较好。当 Pool Ratio 降到 0.25 时模型性能有了较大下降，可能是因为子图中节点个数减少幅度过大会影响模型的泛化能力，故将 Pool Ratio 的值设置为 0.75。

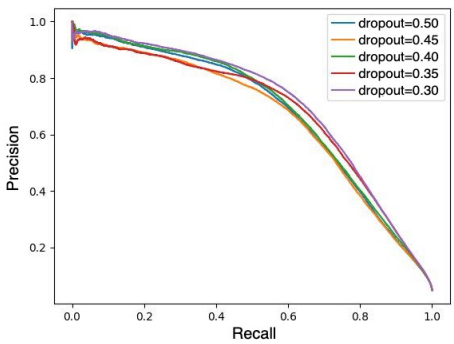

(a) 不同 Dropout 下的 pr 曲线

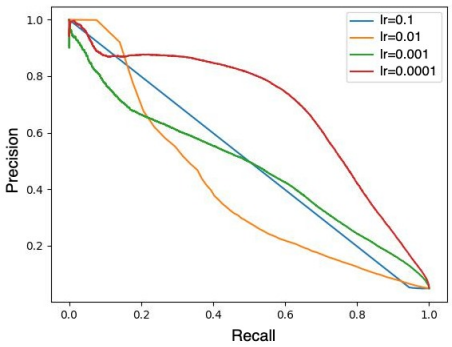

(b) 不同 Learning Rate 下的 pr 曲线

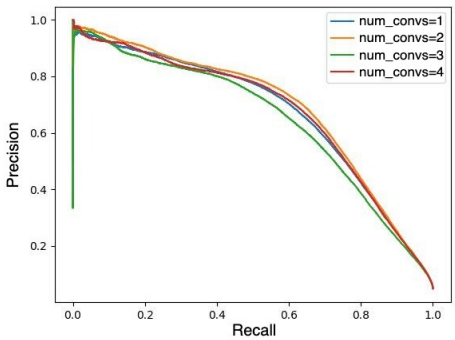

(c) 不同 Conv Number 下的 pr 曲线

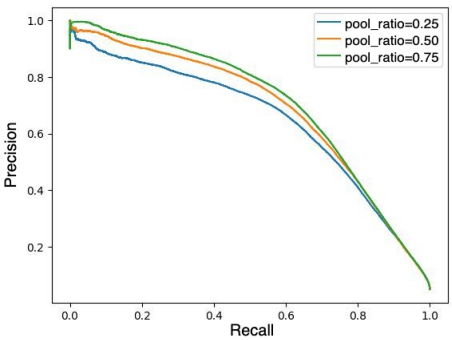

(d) 不同 Pool Ratio 下的 pr 曲线

图 3-5 模型敏感性参数分析实验结果图

中国知网 https://www.cnki.net

3.5 本章小结

在本文中，提出了一个强大的端到端的图深度学习模型，基于蛋白质的结构与序列有效快速的注释蛋白质功能。具体来说，采用基于自注意力机制的图池化模型，通过 AlphaFold2 预测结果提取结构特征，并融合了 Seqvec 提取的序列特征训练蛋白质功能分类器。AlphaFold2 提供的蛋白质结构数据为功能预测提供了强有力的支持，可以使得摒弃之前工作中蛋白质相互作用网络的束缚，有效的提高模型的通用型。同时，与传统利用实验方式获取的的蛋白质结构数据集进行功能标签注释的方法相比，AlphaFold2 提供了充足的高分辨率结构信息，使得本文中的模型可以感知更多的同源信息，有效提高了预测的准确率。在对比实验中表明，本模型在多个指标上都达到了最先进性能，充分证明了结构信息对蛋白质功能预测的有效支持。

中国知网 https://www.cnki.net

第 4 章 基于多模态预训练的蛋白质功能预测模型

4.1 引言

上一章基于蛋白质的结构和序列信息构建基于层次化图池化算法的蛋白质功能预测模型，但上述模型仅仅将提取到的蛋白质序列和结构特征通过拼接的方式输入到分类器，未真正考虑不同模态之间信息的交互对下游分类任务带来的优势。同时，在之前模型中将蛋白质功能预测问题看作多标签的二分类问题，但蛋白质的功能标签实际是按照层次化树型结构组织的，其中每一个蛋白质的功能标签相当于一棵子树结构，这意味着不同标签之前可能存在一定的关系，但是基于多标签的二分类模型将不同功能术语看作单独的个体，割裂了不同标签之间的关系。鉴于以上问题，本章节在之前模型的基础上提出了基于多模态预训练的蛋白质功能预测模型。本章节的组织结构如下：4.2 节介绍多模态预训练模型的构建以及相应预训练任务；4.3 节介绍树状层次化分类算法的实现以及预测过程中的后处理机制；4.4 节进行消融实验对模型进行合理性验证并根据实验结果展开相应讨论；4.5 节进行模型预测的案例分析；4.6 节对本章进行总结。

4.2 序列-结构-功能蛋白质多模态预训练模型构建

在蛋白质表示领域中，目前主流的模型是基于序列信息的蛋白质预训练模型，基于序列的预训练模型通常称为蛋白质语言模型，可以简单描述为：将由氨基酸序列组成的蛋白质看成句子，其中每一个氨基酸代表一个单词，然后通过自然语言处理等深度学习的方式转化为特征向量用于不同的下游任务。随着高通量测序技术的发展从而获得了较为完善的蛋白质序列数据集，蛋白质序列信息本质上是文本信息，因此许多研究者将自然语言处理中的类似 Bert[48] 和 XLNet[49] 等大规模预训练模型推广到蛋白质表示中来，通过无监督的深度学习模型能够对文本自动的提取特征信息从而避免了复杂的特征工程。较为经典的是 ProtVec[59] 模型，其核心思想是基于 Word2Vec[51] 将氨基酸序列按照三个一组分割为子串，然后通过 skip-gram 算法训练得到子串的特征表示进而拼接为整个蛋白质的表达。基于 ELMo[60] 的 SeqVec[22] 模型则是通过双向长短记忆网络提取氨基酸在序列中的上下文信息。2021 年，Elnaggar 等[61] 提出的 ProtTrans 模型是基于 Transformer 提取蛋白质特征的语言模型。上述基于序列的蛋白质语言模型在蛋白质表达方面均取

中国知网 https://www.cnki.net

得了不错的效果，目前已广泛应用到蛋白质的二级结构预测、蛋白质的功能预测以及蛋白质相互作用预测等多个下游任务中。但仅仅依赖序列单一模态无法充分挖掘蛋白质三级结构中的特征，随着蛋白质结构预测的迅猛发展目前已经有较为完善的结构数据集。因此，本章节提出了一个蛋白质多模态预训练模型，从不同维度提取蛋白质的特征并充分挖掘蛋白质不同模态之间的相互联系，从而获得蛋白质的完整表示。

4.2.1 单流预训练模型构建

受到视觉与语言的多模态融合预训练模型的启发，本章节主要围绕构造蛋白质预训练模型展开，其模型图如 4-1 所示。通过蛋白质序列、结构以及功能标签数据集在基于 Transformer 算法的基础上构建单流预训练模型。

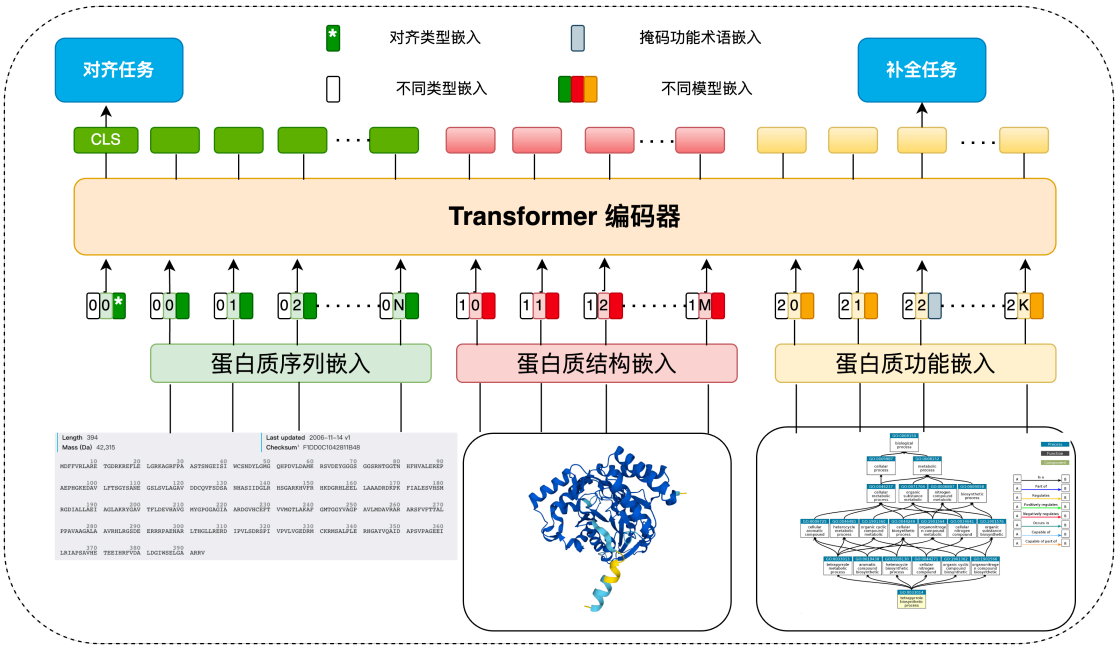

图 4-1 蛋白质序列-结构-功能术语多模态预训练模型图

（1）蛋白质序列表示：和第三章中的蛋白质序列特征提取一致，这里任然采用 SeqVec 的方式将蛋白质序列表示为 $\mathbf{1} \times \mathbf{1024}$ 特征，但在预训练任务中为了能够更好区分不同模态特征，本模型在每个模态中加入了类别信息用来加以区分。同时增加了位置信息使得融合特征可以更好的处理多模态的输入以及捕获不同模态之间的对应关系。序列特征的表示如下：

$$\mathbf{f}_i^{\text{seq}} = \mathbf{t}_i^{\text{seq}} + \mathbf{p}_i^{\text{seq}} + \mathbf{seq}_{\text{i}}, \quad i = 1, \ldots, N \tag{4-1}$$

中国知网 https://www.cnki.net

其中，$\mathbf{t}_i^{\text{seq}}$ 代表类别信息，0 代表是序列模态；$\mathbf{p}_i^{\text{seq}}$ 代表位置信息；$\mathbf{seq}_{\text{i}}$ 是原始蛋白质序列中某一氨基酸表示特征。

在 Transformer 架构中，通常会在输入序列的开头添加一个特殊的 CLS 标记，并使用它的输出作为整个序列的汇总表示。这个 CLS 标记的输出包含整体输入序列的语义信息，类似于对整个输入进行汇总的全局特征。在多模态场景中，CLS 特征可能被设计为汇总整个图像和文本输入的信息，提供一个全局的、跨模态的表示。在本文的预训练模型中，在序列特征的头部添加 CLS 标记用于后续对齐任务的特征输入。

（2）蛋白质结构表示：这里同样按照第三章中提出的基于自注意力的层次化图池化算法提取蛋白质结构特征，将三维蛋白质位置信息转化为二维接触图，将氨基酸残基组成的每个蛋白质网络看成一个小图通过图卷积神经网络进行消息传播与聚合进行图池化算法从而得到基于结构的蛋白质嵌入。同序列类似，多模态结构特征中同样加入了类别和位置信息，其表示为：

$$\mathbf{f}_i^{\text{struct}} = \mathbf{t}_i^{\text{struct}} + \mathbf{p}_i^{\text{struct}} + \mathbf{struct}_{\text{i}}, \quad i = 1, \ldots, M \tag{4-2}$$

其中 $\mathbf{t}_i^{\text{struct}}$ 代表类别信息，1 代表结构模态；$\mathbf{p}_i^{\text{struct}}$ 代表位置信息；$\mathbf{struct}_{\text{i}}$ 代表蛋白质原始的结构特征。

（3）蛋白质功能术语表示：预训练模型为了得到蛋白质的完整表示，因此本模型加入了蛋白质功能术语的特征。蛋白质的功能术语类似文本信息，形式上可以表示为由不同术语组成的句子。但由于在预训练模型中提取到的蛋白质表示是为了下游蛋白质功能预测任务，因此这里仅使用独热编码来表示功能术语信息，同时加入了位置和类别特征。其单个蛋白质的功能术语特征表示如下：

$$\mathbf{f}_i^{\text{func}} = \mathbf{t}_i^{\text{func}} + \mathbf{p}_i^{\text{func}} + \mathbf{func}_{\text{i}}, \quad i = 1, \ldots, K \tag{4-3}$$

其中，$\mathbf{t}_i^{\text{func}}$ 代表类别信息，2 代表功能术语模态；$\mathbf{p}_i^{\text{func}}$ 代表位置信息；$\mathbf{func}_{\text{i}}$ 代表该蛋白质某个功能术语的独热编码。

随后，将蛋白质序列、结构和功能术语表示前期融合作为 Transformer 编码器的输入，然后通过 6 层的自注意力机制和前馈神经网络将三个模态特征嵌入到统一的高维空间中，并在每一层中通过注意力机制对不同位置的特征进行加权组合，使其可以捕捉输入序列中全局和局部的关系进而从原始数据中提取出更高级别抽象的语义。Transformer 编码器的表达如下：

$$\begin{aligned}&\mathbf{o}_{\text{CLS}}, \mathbf{o}_1^{\text{seq}}, \ldots, \mathbf{o}_N^{\text{seq}}, \mathbf{o}_1^{\text{struct}}, \ldots, \mathbf{o}_M^{\text{struct}}, \mathbf{o}_1^{\text{fun}}, \ldots, \mathbf{o}_K^{\text{fun}} \\ &= \text{Transformer}\left(\mathbf{f}_{\text{CLS}}, \mathbf{f}_1^{\text{seq}}, \ldots, \mathbf{f}_N^{\text{seq}}, \mathbf{f}_1^{\text{struct}}, \ldots, \mathbf{f}_M^{\text{struct}}, \mathbf{f}_1^{\text{fun}}, \ldots, \mathbf{f}_K^{\text{fun}}\right)\end{aligned} \tag{4-4}$$

中国知网 https://www.cnki.net

4.2.2 预训练任务

受到视觉与语言的多模态预训练中图像-文本匹配任务（Image-Text Matching，ITM）和跨模态掩码语言建模任务（Cross-Modal Masked Language Modeling, MLM）的启发，本文的蛋白质预训练模型同样设计了匹配和掩码补全任务。

(1) 蛋白质序列-结构-功能术语匹配任务：如图 4-1 模型图所示，在序列的头部增加的 CLS 特征由不同的随机值作为输入，在 6 层 Transformer 编码器中可以学习到不同模态之间的全局特征，故可以将输出的 CLS 特征看作蛋白质不同模态融合后的总体特征表示。在预训练中的匹配任务中相当于用 CLS 特征做二分类任务，其中若原始标签为 0 代表蛋白质序列、结构和功能不匹配，原始标签为 1 代表三者匹配。

(2) 蛋白质功能术语补全任务：蛋白质的每个功能术语可以看作为一个单词，因此一个蛋白质完整的功能术语描述可以看作一条完整的句子。类比与跨模态掩码语言建模任务，在该任务中随机以 15% 的概率隐藏蛋白质的功能术语，通过不同模态间的信息交互完成缺失标签的补全任务。

本文中的蛋白质预训练是一个多任务学习模型，将按照多任务联合损失的策略计算损失函数，即将所有损失函数通过求和联合在一起，可以促进模型在不同任务之间共享信息，学习到数据更加通用的特征提高模型的表达能力。同时，提高模型的泛化能力防止过拟合现象。以上两个任务的联合损失函数如下：

$$\mathcal{L} = \mathcal{L}_{\text{ce}}(y_{\text{cls}}, \text{MLP}(\mathbf{o}_{\text{CLS}})) + \sum_{i \in \text{Masked}} \mathcal{L}_{\text{ce}}(y_i^{\text{seq}}, \text{MLP}(\mathbf{o}_i^{\text{seq}})) \tag{4-5}$$

其中，$\mathcal{L}_{\text{ce}}$ 代表交叉熵损失函数，y_{cls} 是 0-1 二分类标签代表不同模态间是否匹配，y_i^{seq} 代表需要补全的蛋白质功能术语标签。

4.3 蛋白质功能标签的树状层次化分类与后处理机制

正如 2.2 节介绍的，蛋白质的功能标签 GO 术语是通过有向无环图的形式组织的，不同术语之前存在一定的关系。在第三种章模型分类器模块的设计中，仅将功能自动注释模型看作多个标签的二分类，最终的预测节点可能会存在子节点的功能术语存在而父节点因较低的概率被预测为不存在的错误情况，这种方法在一定程度了割裂了不同标签之间的联系。基于此问题，本章节在第三种的基础上增加了层次化分类算法在分类器中通过图神经网络的消息传播与聚合方式根据蛋白质层次结构关系更新其节点信息，同时在推理预测过程中增加了后处理机制保证预测的准确性。

中国知网 https://www.cnki.net

4.3.1 基于图注意力网络的层次化分类算法

原始数据中的标签往往是较高层次的蛋白质功能术语，为了获得完整的功能标签，在预处理阶段需要根据真实路径进行补全，从而得到一个有向无环图的树状结构。同时，为了降低标签的稀疏性会根据一定阈值对标签进行过滤，最终得到的是之前有向无环图的子图。第三章中仅仅保留了 BPO、MFO、CCO 三个分支中的功能标签，即子图中的节点。在本章中，为了进行层次化的预测，所以需要同时保留图中所有节点的属性和图结构。

在层次化的分类器设计中，首先通过叠加多个线性层和多个非线性激活函数的多层感知机模块，将最终输出隐含空间的高维特征转化为和最终标签维度一致的特征，其表示为：

$$\hat{\mathbf{Y}} = \sigma\left(\mathbf{H}^{(L)}\mathbf{W}^{(L+1)} + \mathbf{b}^{(L+1)}\right). \tag{4-6}$$

其中，$\mathbf{W}^{(L+1)}$ 是输出层的转换矩阵，$\mathbf{b}^{(L+1)}$ 是偏置向量，σ 是 sigmoid 激活函数。预测得到的输出特征 $\hat{\mathbf{Y}}$ 代表每个标签可能出现的概率。

随后，在保留的功能术语的图结构中叠加 2 层图注意力网络（GAT）层。图中的节点即该分支中包含的功能术语，节点的特征为上述得到的预测该节点出现的概率。在一层 GAT 网络中，节点 p 和节点 q 之间的注意力值计算方式如下：

$$\alpha_{pq} = \mathrm{Softmax}\left(\mathrm{LeakyReLU}\left(\mathbf{a}^T[\mathbf{Wh}_p||\mathbf{Wh}_q]\right)\right) \tag{4-7}$$

其中，$\mathbf{a}$ 和 $\mathbf{W}$ 是可学习的权重，LeakyReLU 是非线性激活函数，Softmax 为最大值归一化函数。通过公式 4-6 得到基于注意力的蛋白质功能术语网络 N_P^*，图注意力机制的消息传播函数如下：

$$\mathbf{H}^{(l)} = \sigma\left(N_P^*\mathbf{H}^{(l-1)}\mathbf{W}_P^{(l)} + \mathbf{H}^{(l-1)}\right) \tag{4-8}$$

其中，$\mathbf{W}_P^{(l)}$ 是蛋白质功能术语网络的第 l 层的特征变换矩阵，σ 非是线性激活函数，$\mathbf{H}^{(l-1)}$ 是上一层的输入，即多层感知机模块得到的各个标签的概率特征，$\mathbf{H}^{(l)}$ 是该图卷积层的输出。

4.3.2 后处理机制

为保证预测结果的准确性，在本模型预测推理阶段增加后处理模块。在通过注意力网络得到各个功能术语的预测概率，然后按照一定阈值对功能标签进行二分类。为保证在更高层次中的父节点预测不存在而其子节点存在的情况，在预测阶段的最终输出层，会从具有每个功能标签的叶子结点开始不断向上迭代直到祖

中国知网 https://www.cnki.net

先节点，该方式保证了其与子节点具有关系的父节点或者祖先节点功能标签的存在。

算法 4-1 后处理算法伪代码

算法 4-1 后处理算法伪代码

Input: 标签网络 $label_network = (V, E)$, 初始标签嵌入 $labels$

Output: 更新后的标签嵌入 $labels$

```
edges ← E 获取图中的所有边
child ←V1 获取子节点
parent ← V2 获取父节点
(child, parent) 代表图中一条边
for (child, parent) in edges do
    if labels[child] > labels[parent] then
        labels[parent] ←labels[child]
    end
end
return labels
```

4.4 实验结果与分析

4.4.1 基于预训练的蛋白质功能预测模型实验与结果分析

在 4.2 节中构建的蛋白质多模态预训练模型输出的完整的蛋白质表达，利用多模态交互后丰富的信息可以在下游的蛋白质功能预测任务中取得更好的效果。在本节实验中，仍然在人类蛋白质数据集上从 BPO、MFO 和 CCO 三个分支构建三个不同的模型用来评估蛋白质功能预测模型的效果。在具体实验设计中，分为蛋白质预训练模型和下游功能预测微调任务。在蛋白质预训练模型中其输入分别为氨基酸序列、蛋白质三维结构图和蛋白质功能标签，分别通过蛋白质语言模型提取氨基酸序列特征、层次化图池化算法提取蛋白质三维结构特征和独热编码蛋白质功能标签，利用 Transformer 编码器将融合后输出层的特征值进行蛋白质序列-结构-功能术语匹配任务和蛋白质功能术语补全任务的自监督预训练任务，然后利用上游训练好的模型在下游蛋白质功能预测任务中进行微调。其输入为氨基酸序列和蛋白质三维结构图，特征编码和融合同预训练模型一致并将 Transformer 编码器的输出层传送到分类器中进行功能标签预测。在训练过程中，多模态预训练模型

中国知网 https://www.cnki.net

和下游功能预测模型共享一套超参数，其中学习速率设置为 5e-4，随机失活值设置为 0.45，批处理大小设置为 16，然后首先在预训练任务中进行 100 轮训练，随后在预训练已有的参数模型上继续进行 10 轮下游任务训练。在这里，将基于预训练的蛋白质功能预测模型与本文第三章中构建的模型进行对比实验，实验结果如图所示。

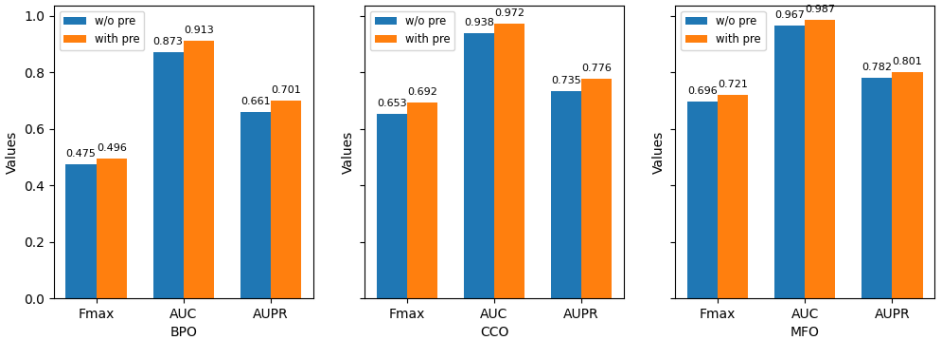

图 4-2 预训练蛋白质功能预测模型对比实验结果图

在上图 4-2 中，模型的评判指标同第三章一样，依然通过 Fmax、AUC、AUPR 三个维度的指标对模型进行多维度评测。综合来看，基于预训练的两阶段蛋白质功能预测模型在三个不同分支中的性能指标均好于本文第三章中提出的模型，可见蛋白质多模态预训练模型在学习蛋白质的完整表示方面具有一定的优势，其模态融合阶段通过对比学习或者不同模态间的远程联系，对下游蛋白质功能预测任务性能有较大提高。同时，预训练模型具有较好的泛化性能，下游任务可以基于预训练模型较快的收敛从而在较少的训练轮次中达到较好的效果。同时，根据上图可以观察到，在三个分支的不同模型中均存在 Fmax 值低于 AUC 和 AUPR 的情况，在计算 Fmax 的值时，本文将阈值作为一个超参数，通过 0.01 的步长迭代的计算 Fmax 的最大值，在大多数情况下阈值最终选择在 0.3-0.4 之间，这表明 Fmax 是一个点估计，而 AUC 和 AUPR 是综合性指标，具有较高的值说明该模型在大范围的多个阈值下均有较好的性能。同时，在蛋白质功能预测问题中，会存在一些功能标签较为罕见导致数据不平衡。在这种情况下，AUC 和 AUPR 的值也往往比 Fmax 高。

4.4.2 层次化分类算法与后处理机制实验结果分析

考虑到功能术语之间的树状关系，本节实验模型在之前的基础上，分别在训练过程中添加图注意力网络层用于学习不同标签之前的层次关系和在预测过程中添加后处理层保证预测结果的正确性。然后和之前实验流程一样，分别在 BPO、

中国知网 https://www.cnki.net

MFO、CCO 三个分支中将数据集按照 8:1:1 的比例分成训练集、验证集和测试集，然后在下图中比较了是否带有层次化分类算法和后处理机制模型的不同表现。

表 4-1 层次化分类算法与后处理机制对比实验结果

Model	BPO			CCO			MFO		
	Fmax	AUC	AUPR	Fmax	AUC	AUPR	Fmax	AUC	AUPR
Modified Model	**0.481**	**0.873**	**0.661**	**0.658**	**0.942**	**0.763**	**0.701**	**0.969**	**0.796**
Previous Model	0.475	0.870	0.652	0.653	0.938	0.735	0.696	0.967	0.782

根据上述实验结果，可以明显的看出通过在标签内构建网络，利用图注意力算法进行消息聚合与传播学习得到不同标签之前的层次关系有助于进一步提升预测的准确性，同时，在测试集中通过后处理算法避免了因父节点预测概率低于阈值不存在而子节点存在的情况发生，进一步提高了预测的准确性。

4.5 模型可解释性分析

Grad-CAM（Gradient-weighted Class Activation Mapping）[62] 是一种用于解释深度学习模型预测的可视化技术，主要利用目标类别的梯度信息来加权输入图像上的特征图，通过这种方式，Grad-CAM 生成一个热力图，用于指示模型在预测时关注区域的不同重要程度，它可以突出显示模型做出判断的重要部分。Grad-CAM 的优点是不需要重新训练或改变模型的架构，并且具有很高的计算效率。在蛋白质功能预测领域中可以利用 Grad-CAM 的算法分析不同氨基酸残基对蛋白质功能的影响权重，从而找出和蛋白质功能较为相关的氨基酸残基。在本文的模型中，选择图神经网络的最后一个卷积层作为特征映射，然后通过求导的方式计算输出层不同特征对标签预测的贡献值，其表达如下公式：

$$\mathbf{W}_{i,j}^{l} = \frac{\partial \mathbf{y}^{l}}{\partial \mathbf{F}_{i,j}} \tag{4-9}$$

其中，$\mathbf{F} \in \mathbb{R}^{L \times D}$ 代表最后一个卷积层的输出，L 代表卷积层的长度，D 代表输出隐藏层的维度。$\mathbf{W}^{l}$ 代表特征映射对预测函数 l 的重要性得分，通过对每个氨基酸残基的贡献求和得到。随后，对最后一个卷积层的所有特征进行加权求和，得到残差空间中特定函数的热图：

$$\mathbf{CAM}_{i}^{l} = \mathrm{Re}LU\left(\frac{\sum_{j=1}^{D} \mathbf{W}_{i,j}^{l} \cdot \mathbf{F}_{i,j}}{D}\right) \tag{4-10}$$

本文选取了 2PE5-B 蛋白质的 GO:0003677（DNA-binding）进行案例分析。2PE5-B 蛋白质是一种乳糖操纵子抑制因子 Lacl，它能够与 DNA 结合，并通过

中国知网 https://www.cnki.net

这种结合来调控基因表达。2PE5-B 蛋白质结合到操纵子的 DNA 序列上时，这个 DNA 序列通常位于乳糖代谢相关的基因群上游区域。在没有乳糖的情况下，它以一种构象结合到乳糖操纵子区域，阻止附近的基因转录。当细菌环境存在乳糖时，乳糖分子会和该蛋白质结合导致其构象发生变化，从而使其无法有效的结合到相关 DNA 上，解除了对基因的抑制。这时相关基因可以被 RNA 聚合酶复制，启动乳糖的代谢功能。2PE5-B 蛋白质的完整氨基酸序列如下：

KPVTLYDVAEYAGVSYQTVSRVVNQASHVSAKTREKVEAAMAELNYIPNRVAQQLAGKQ
LLLIGVATSSLALHAPSQIVAAIKSRADQLGASVVVSMVERSGVEACKAAVHNLLAQRV
SGLIINYPLDDQDAIAVEAACTNVPALFLDVSDQTPINSIIFSHEDGTRLGVEHLVALG
HQQIALLAGPLSSVSARLRLAGWHKYLTRNQIQPIAEREGDWSAMSGFQQTMQMLNEGI
VPTAMLVANDQMALGAMRAITESGLRVGADISVVGYDDTEDSSCYIPPLTTIKQDFRLG
QTSVDRLLQLSQGQAVKGNQLLPVSLVKRKTTLA

在蛋白质功能预测模型的输出中发现 2PE5-B 蛋白质的 MFO 分支中存在 GO:0003677 标签。该标签是分子功能标签，其具体描述为：DNA Binding，表明蛋白质在分子水平上存在与 DNA 结合的功能，同时可能存在调控基因表达，催化 DNA 反应等功能。为了探究在本文中模型预测时，该蛋白质的各个氨基酸残基对 GO:000367 标签所起到的不同作用，根据上述 Grad-GAM 算法得到该蛋白质在功能预测过程中，不同的氨基酸残基特征对该标签预测的影响权重分布，并生成对应序列热图，如下图 4-3 所示。

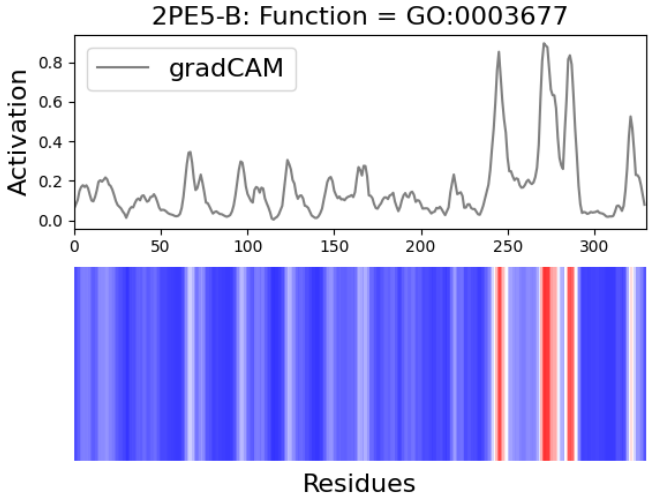

图 4-3 2PE5-B 蛋白质热图分布

然后将热图中氨基酸残基的分布值映射到蛋白质的三维结构中，如下图 4-4 所

中国知网 https://www.cnki.net

示。其中蓝色代表该氨基酸残基对 GO:000367 标签预测的重要程度较低，而红色代表重要程度较高。通过观察图 4-4 可以看出，在 DNA 周围的氨基酸残基表现出强烈的信号，即大多呈现红色区域，可见他们对 GO:000367（DNA-Binding）标签的预测起到关键作用。该结果直观的解释了本文提出的基于结构和序列数据的方式预测蛋白质功能的可靠性。

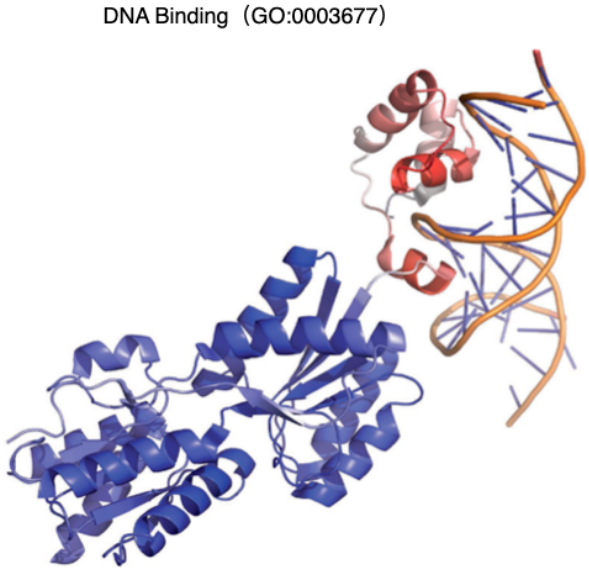

图 4-4 2PE5-B 蛋白质与 DNA 相互作用结构图

4.6 本章小结

本章在第三章功能预测模型的基础上构建了蛋白质多模态预训练模型，通过预训练过程中不同模态的交互获得远程关系构建完整的蛋白质表示，在下游功能预测任务中性能有较为明显的提升。同时，考虑到蛋白质术语之间的网状关系，在第三章多标签二分类模型的基础上串联图注意力层，将通过聚合功能标签网络中邻居特征更新最终的标签构建层次分类器从而更好的感知标签之间的父子关系。为进一步保证预测的准确性，在预测过程中的后处理机制通过从叶子节点开始进行不断迭代，保证了预测结果中父子关系的严谨性。最后，基于 Grad-CAM 算法对本文构建的蛋白质功能预测模型进行可解释性分析，通过生成的热图分析得到不同氨基酸残基对功能标签的重要程度，并将特征值映射到蛋白质三维结构中可以发现预测过程中起关键作用的氨基酸残基在空间上恰好与小分子如 DNA 直接相互作用从而发挥功能，证明了本文构建的功能预测模型的合理性。

中国知网 https://www.cnki.net

结 论

在后基因组时代，蛋白质序列与结构正在不断被完善，然而现有经过实验注释的蛋白质功能标签不足 1%。目前的主流模型主要聚焦在利用深度学习算法挖掘蛋白质不同模态的信息进行功能预测，通常会存在蛋白质结构数据利用率不高、不同数据源的信息未充分融合的缺点。针对此问题，本文结合 AlphaFold2 提供的蛋白质结构数据集，利用网络表征算法和预训练机制构建蛋白质功能预测模型，取得研究成果如下部分：

（1）本文将蛋白质三维结构转化二维接触图，并通过图表示学习算法得到氨基酸残基的网络结构特征，融合独热编码得到的语义特征作为蛋白质结构网络中每个氨基酸节点的表示，利于后续基于图池化算法的蛋白质结构特征的提取。

（2）针对无法高效利用蛋白质结构信息的问题，本文将蛋白质接触图和氨基酸特征表示作为输入，利用注意力机制的层次化图池化算法充分挖掘蛋白质的结构表达，并将其输出拼接通过蛋白质语言模型编码的序列信息作为该该蛋白质的完整表达，通过多层感知机算法在下游中进行多标签分类。目前基于蛋白质相互作用网络信息的模型通常取得了较好效果，相比较于此类模型，本文的模型以单个蛋白质的序列和结构为主体输入，因此具有较好的可扩展性与通用性，在人类蛋白质数据集的实验中多个指标均取得最优效果，其中与目前最为先进的基于结构的模型 GAT-GO 比较在 MFO 分支中的 Fmax、AUC 分别提升 9.0% 和 6.1%

(3) 考虑到蛋白质不同模态之间信息的交互与融合，本文基于蛋白质序列、结构和功能术语信息构建单流 Transformer 的多模态预训练模型，通过设计不同模态之间的匹配任务和蛋白质功能术语的补全任务，使得不同模态之间信息得到充分的交互，从而挖掘蛋白质更加完整的表达。通过与本文第三章模型对比实验可知，具有预训练算法的功能预测模型通常具有更高的准确率。同时，蛋白质预训练模型也为蛋白质相互作用网络预测、蛋白质结构预测等提供了良好的拓展性。

本文创新性的结合蛋白质的结构和多模态预训练提出的功能预测模型取得了不错的效果，但任存在下列可以改进的问题：首先，本文的实验主要是基于人类蛋白质数据集，探究多物种的蛋白质功能预测模型可以更加有效的提升模型的泛化能力和通用性；其次，本文提出的模型未能充分利用蛋白质相互作用网络的有效信息，在今后的模型的设计中可以考虑加入蛋白质相互作用网络以及结构相似性网络等进一步扩展蛋白质的完整表达从而提升模型的预测精度。

中国知网 https://www.cnki.net

参考文献

[1] BATEMAN A, MARTIN M J, ORCHARD S, et al. Uniprot: the universal protein knowledgebase in 2023[J]. Nucleic Acids Research, 2022, 51(1).

[2] MAKRODIMITRIS S, VAN HAM R C, REINDERS M J. Automatic gene function prediction in the 2020’s[J]. Genes, 2020, 11(11): 1264.

[3] JUMPER J, EVANS R, PRITZEL A, et al. Highly accurate protein structure prediction with alphafold[J]. Nature, 2021, 596(7873): 583-589.

[4] GILLIS J, PAVLIDIS P. Characterizing the state of the art in the computational assignment of gene function: lessons from the first critical assessment of functional annotation (cafa)[J]. BMC bioinformatics, 2013, 14(3): 1-12.

[5] ALTSCHUL S F, GISH W, MILLER W, et al. Basic local alignment search tool [J]. Journal of molecular biology, 1990, 215(3): 403-410.

[6] KOSKINEN P, TÖRÖNEN P, NOKSO-KOIVISTO J, et al. Pannzer: high-throughput functional annotation of uncharacterized proteins in an error-prone environment[J]. Bioinformatics, 2015, 31(10): 1544-1552.

[7] GONG Q, NING W, TIAN W. Gofdr: a sequence alignment based method for predicting protein functions[J]. Methods, 2016, 93: 3-14.

[8] YOU R, ZHANG Z, XIONG Y, et al. Golabeler: improving sequence-based large-scale protein function prediction by learning to rank[J]. Bioinformatics, 2018, 34 (14): 2465-2473.

[9] KULMANOV M, KHAN M A, HOEHNDORF R. Deepgo: predicting protein functions from sequence and interactions using a deep ontology-aware classifier [J]. Bioinformatics, 2018, 34(4): 660-668.

[10] BONDY-DENOMY J, PAWLUK A, MAXWELL K L, et al. Bacteriophage genes that inactivate the crispr/cas bacterial immune system[J]. Nature, 2013, 493 (7432): 429-432.

[11] GLIGORIJEVIĆ V, RENFREW P D, KOSCIOLEK T, et al. Structure-based protein function prediction using graph convolutional networks[J]. Nature communications, 2021, 12(1): 3168.

中国知网 https://www.cnki.net

[12] LAI B, XU J. Accurate protein function prediction via graph attention networks with predicted structure information[J]. Briefings in Bioinformatics, 2022, 23(1): bbab502.

[13] GU Z, LUO X, CHEN J, et al. Hierarchical graph transformer with contrastive learning for protein function prediction[J]. Bioinformatics, 2023, 39(7): btad410.

[14] SCHWIKOWSKI B, UETZ P, FIELDS S. A network of protein–protein interactions in yeast[J]. Nature biotechnology, 2000, 18(12): 1257-1261.

[15] YOU R, YAO S, XIONG Y, et al. Netgo: improving large-scale protein function prediction with massive network information[J]. Nucleic acids research, 2019, 47 (W1): W379-W387.

[16] KULMANOV M, HOEHNDORF R. Deepgoplus: improved protein function prediction from sequence[J]. Bioinformatics, 2020, 36(2): 422-429.

[17] WU Z, GUO M, JIN X, et al. Cfago: cross-fusion of network and attributes based on attention mechanism for protein function prediction[J]. Bioinformatics, 2023, 39(3): btad123.

[18] ZHOU G, WANG J, ZHANG X, et al. Deepgoa: predicting gene ontology annotations of proteins via graph convolutional network[C]//2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM). IEEE, 2019: 1836-1841.

[19] YOU R, YAO S, MAMITSUKA H, et al. Deepgraphgo: graph neural network for large-scale, multispecies protein function prediction[J]. Bioinformatics, 2021, 37 (1): i262-i271.

[20] WU K, WANG L, LIU B, et al. Pspgo: cross-species heterogeneous network propagation for protein function prediction[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2022, 27(10): 324-330.

[21] XUE Y, LIU Z, FANG X, et al. Multimodal pre-training model for sequence-based prediction of protein-protein interaction[C]//Machine Learning in Computational Biology. PMLR, 2022: 34-46.

[22] HEINZINGER M, ELNAGGAR A, WANG Y, et al. Modeling aspects of the language of life through transfer-learning protein sequences[J]. BMC bioinformatics, 2019, 20(1): 1-17.

[23] GROVER A, LESKOVEC J. node2vec: Scalable feature learning for networks [C]//Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.

中国知网 https://www.cnki.net

[24] RUEPP A, ZOLLNER A, MAIER D, et al. The funcat, a functional annotation scheme for systematic classification of proteins from whole genomes[J]. Nucleic acids research, 2004, 32(18): 5539-5545.

[25] ASHBURNER M, BALL C A, BLAKE J A, et al. Gene ontology: tool for the unification of biology[J]. Nature genetics, 2000, 25(1): 25-29.

[26] PEROZZI B, AL-RFOU R, SKIENA S. Deepwalk: Online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining. 2014: 701-710.

[27] TANG J, QU M, WANG M, et al. Line: Large-scale information network embedding[C]//Proceedings of the 24th international conference on world wide web. 2015: 1067-1077.

[28] RIBEIRO L F, SAVERESE P H, FIGUEIREDO D R. struc2vec: Learning node representations from structural identity[C]//Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2017: 385-394.

[29] JIANG B, ZHANG Z, LIN D, et al. Semi-supervised learning with graph learning-convolutional networks[M]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 11313-11320.

[30] HAMILTON W, YING Z, LESKOVEC J. Inductive representation learning on large graphs[J]. Advances in neural information processing systems, 2017, 30(3).

[31] VELICKOVIC P, CUCURULL G, CASANOVA A, et al. Graph attention networks [J]. stat, 2017, 1050(20): 548-550.

[32] XUE H, SUN X K, SUN W X. Multi-hop hierarchical graph neural networks [M]//2020 IEEE International Conference on Big Data and Smart Computing (BigComp): volume 18. IEEE, 2020: 82-89.

[33] HU Z, DONG Y, WANG K, et al. Heterogeneous graph transformer[C]// Proceedings of the web conference 2020. 2020: 2704-2710.

[34] NIEPERT M, AHMED M, KUTZKOV K. Learning convolutional neural networks for graphs[C]//International conference on machine learning. PMLR, 2016: 2014-2023.

[35] TZENG R C, WU S H. Distributed, egocentric representations of graphs for detecting critical structures[C]//International Conference on Machine Learning. PMLR, 2019: 6354-6362.

中国知网 https://www.cnki.net

[36] GILMER J, SCHOENHOLZ S S, RILEY P F, et al. Neural message passing for quantum chemistry[C]//International conference on machine learning. PMLR, 2017: 1263-1272.

[37] MA Y, WANG S, AGGARWAL C C, et al. Graph convolutional networks with eigenpooling[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 723-731.

[38] WU J, HE J, XU J. Net: Degree-specific graph neural networks for node and graph classification[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 406-415.

[39] YING Z, YOU J, MORRIS C, et al. Hierarchical graph representation learning with differentiable pooling[J]. Advances in neural information processing systems, 2018, 31(83).

[40] LEE J, LEE I, KANG J. Self-attention graph pooling[C]//International conference on machine learning. PMLR, 2019: 3734-3743.

[41] KIM W, SON B, KIM I. Vilt: Vision-and-language transformer without convolution or region supervision[C]//International Conference on Machine Learning. PMLR, 2021: 5583-5594.

[42] WU B, XU C, DAI X, et al. Visual transformers: Token-based image representation and processing for computer vision[A]. 2020.

[43] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.

[44] LI J, SELVARAJU R, GOTMARE A, et al. Align before fuse: Vision and language representation learning with momentum distillation[J]. Advances in neural information processing systems, 2021, 34(31): 9694-9705.

[45] BAO H, WANG W, DONG L, et al. Vlmo: Unified vision-language pre-training with mixture-of-modality-experts[J]. Advances in Neural Information Processing Systems, 2022, 35(17): 32897-32912.

[46] LI J, LI D, XIONG C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//International Conference on Machine Learning. PMLR, 2022: 12888-12900.

中国知网 https://www.cnki.net

[47] WANG W, BAO H, DONG L, et al. Image as a foreign language: Beit pretraining for vision and vision-language tasks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 19175-19186.

[48] KENTON J D M W C, TOUTANOVA L K. Bert: Pre-training of deep bidirectional transformers for language understanding[M]//Proceedings of naacL-HLT: volume 11. 2019: 2-8.

[49] YANG Z, DAI Z, YANG Y, et al. Xlnet: Generalized autoregressive pretraining for language understanding[J]. Advances in neural information processing systems, 2019, 32(11).

[50] ZHANG X, ZHAO J, LECUN Y. Character-level convolutional networks for text classification[J]. Advances in neural information processing systems, 2015, 28 (34).

[51] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space[A]. 2013.

[52] YUT L, ZHANG C, SHAO Y, et al. Lda* a robust and large-scale topic modeling system[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1406-1417.

[53] DEFFERRARD M, BRESSON X, VANDERGHEYNST P. Convolutional neural networks on graphs with fast localized spectral filtering[J]. Advances in neural information processing systems, 2016, 29(13).

[54] WU F, SOUZA A, ZHANG T, et al. Simplifying graph convolutional networks [C]//International conference on machine learning. PMLR, 2019: 6861-6871.

[55] CANGEA C, VELIČKOVIĆ P, JOVANOVIĆ N, et al. Towards sparse hierarchical graph classifiers[A]. 2018.

[56] XU K, HU W, LESKOVEC J, et al. How powerful are graph neural networks? [A]. 2018.

[57] 张晓帅. 基于 PPI 网络的蛋白质功能预测研究[D]. 哈尔滨工业大学, 2021.

[58] ZHOU N, JIANG Y, BERGQUIST T R, et al. The cafa challenge reports improved protein function prediction and new functional annotations for hundreds of genes through experimental screens[J]. Genome biology, 2019, 20(1): 1-23.

[59] ASGARI E, MOFRAD M R. Continuous distributed representation of biological sequences for deep proteomics and genomics[J]. PloS one, 2015, 10(11): 141-157.

中国知网 https://www.cnki.net

[60] SARZYNSKA-WAWER J, WAWER A, PAWLAK A, et al. Detecting formal thought disorder by deep contextualized word representations[J]. Psychiatry Research, 2021, 304(16): 114-135.

[61] ELNAGGAR A, HEINZINGER M, DALLAGO C, et al. Prottrans: Toward understanding the language of life through self-supervised learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(10): 7112-7127.

[62] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 618-626.

中国知网 https://www.cnki.net