目 录

第 1 章 课题的来源及研究的背景和意义 1
1.1 课题的来源 1
1.2 课题研究的背景和意义 1
第 2 章 国内外研究现状及分析 3
2.1 国内外研究现状 3
2.2 国内外文献综述及简析 3
2.2.1 蛋白质功能预测研究现状 3
2.2.2 多模态预训练蛋白质功能预测研究现状 7
2.2.3 扩散模型分类器研究现状 8
2.2.4 蛋白质功能预测领域研究进展总结 10
第 3 章 主要研究内容及研究方案 11
3.1 研究内容 11
3.2 研究方案 11
3.2.1 获取并整合数据集 11
3.2.2 构建双分支 VAE 预训练框架 12
3.2.3 构建扩散模型网络 15
3.2.4 扩散模型上的类条件分类器 16
3.2.5 优化多标签分类器及模型评估 18
第 4 章 预期目标 19
4.1 预期目标 19
第 5 章 已完成的研究工作及进度安排 20
5.1 已完成的研究工作 20
5.2 进度安排 21
第 6 章 已具备的研究条件和所需条件及经费 22
6.1 实验室条件和经费保障 22
6.2 所需条件及经费 22
第 7 章 预计困难及解决方案 23
7.1 预计困难与技术难点 23
7.2 解决方案 23
参考文献 24

第 1 章 课题的来源及研究的背景和意义

1.1 课题的来源

蛋白质是生物系统的组成部分，要了解生物系统及其在分子尺度上的行为，就必须了解蛋白质的功能。蛋白质功能预测对于理解细胞内和细胞外生物学过程以及揭示蛋白质多样性与进化之间的关系具有重要意义。此外，蛋白质功能预测在阐明基因功能、理解基因调控网络和指导未表征蛋白质的功能注释方面起着至关重要的作用[1]。蛋白质功能的准确预测通过促进靶向特定蛋白质的药物的产生来支持药物发现和开发，从而提高治疗效果。在个性化医疗中，了解蛋白质功能的个体差异对于评估疾病风险和设计个性化治疗策略至关重要。总之，蛋白质功能预测是推动生命科学和医学进步的重要工具，对人类健康和可持续发展具有重要意义。

在生物数据收集技术趋于成熟的今天，人们通过高通量测序和蛋白质组质谱分析技术测定的蛋白质组相关数据呈指数级增长。然而，基于生物实验确定蛋白质功能的方法耗时耗力，并且对设备、资金等方面的要求苛刻，远远不能适应当下日益增长的标注需求。全球最权威的蛋白质数据库 UniProt[2] 中只有不到 1% 的蛋白质经过实验标注了功能，即便对于研究较广泛的人类蛋白质组已知的 2 万多个蛋白质而言，也有 2/3 蛋白质是完全未经实验标注或者功能标签不全的[3]，亟需进一步标注。在这样的时代背景之下，使用计算手段自动标注蛋白质功能的方法应运而生，其相比传统的实验标注方法更加方便高效、预测成本低、扩展性强且应用范围广，因此逐渐成为蛋白质功能标注领域的研究热点。

1.2 课题研究的背景和意义

蛋白质序列中的氨基酸残基通过一系列复杂的空间转化过程形成独特的三维结构，这种结构在生物学功能中起着至关重要的作用。蛋白质的三维结构不仅赋予了其独特的物理化学性质，还通过非共价相互作用形成蛋白质-蛋白质相互作用（Protein-Protein Interaction，PPI）网络。这些网络是细胞中生命活动的核心调控机制，参与了几乎所有的生物过程。例如 PPI 网络可以通过组装成蛋白质复合物，形成特定的分子机器，来执行复杂的生物学功能。然而，值得注意的是并非所有蛋白质都需要通过形成复合物来实现其功能，有些蛋白质能够独立地执行其功能，这使得蛋白质功能的多样性和复杂性更加显著。

在蛋白质研究领域，遵循“序列-结构-功能”的范式，即通过蛋白质的氨基酸序列推测其三维结构，再通过结构推测其生物功能。目前，蛋白质功能的注释和分类主要依赖于基因本体论（Gene Ontology，GO）系统。GO 系统是一个标准化的框架，涵盖了三大本体论：生物过程本体论（Biological Process Ontology，BPO）、分子功能本体论（Molecular Function Ontology，MFO）和细胞组分本体论（Cellular Component Ontology，CCO）。GO 系统目前包含超过 50,000 个类目，这些类目之间并非独立存在，而是通过正式定义的关系相互连接和影响。因此，在预测蛋白质功能时，必须考虑这些类目之间的复杂关系。尽管 GO 系统为蛋白质功能的注释提供了全面的框架，仍有许多 GO 类目由于缺乏足够的实验注释数据而难以准确预测。事实上，在 GO 系统的 20,000 多个类目中，有超过一半的类目仅有极少数的蛋白质被实验注释为具有该功能，甚至一些类目完全没有注释数据。这些稀缺注释类别通常是高度特异的，具有较高的信息量，对生物学研究和应用具有重要意义。由于数据稀缺，传统的机器学习模型在这些类别上的预测表现往往较差，随着越来越多的新蛋白质被发现，如何准确预测这些新蛋白质的功能成为了蛋白质研究领域的一个重大挑战。

在这种背景下，基于多模态预训练的方法为解决这一问题提供了一种创新的解决方案[4]。多模态预训练方法旨在通过整合来自蛋白质的不同数据类型，包括序列、结构、以及可能的功能注释等来训练预测模型，能够更全面地捕捉蛋白质的复杂性。相较于传统的依赖大量标注数据的方法，多模态预训练不仅可以处理标注数据稀缺的问题，还能提高模型对新蛋白质功能的预测精度。本研究的目的在于开发和验证一种基于多模态预训练的蛋白质功能预测模型，通过这一模型，不仅能够有效地预测那些未标注蛋白质的功能，还能够扩展现有的蛋白质功能预测方法的应用范围，提升其准确性和广泛性。这将有助于推动生命科学的进步，为疾病治疗和药物开发等应用领域提供强有力的科学基础。

第 2 章 国内外研究现状及分析

2.1 国内外研究现状

CAFA（Critical Assessment of Function Annotation）[5] 挑战是一项在生物信息学领域极具挑战性的竞赛，其目的是评估并推动蛋白质功能预测方法的发展。这项挑战由国际生物信息学研究社区组织，并吸引了来自世界各地的研究人员参与。简而言之，CAFA 组织者提供大量的蛋白质序列，参与者需要使用他们的计算方法来预测这些蛋白质的功能，并将这些预测与实际的注释进行比较，以评估计算方法的准确性。CAFA 挑战为研究人员提供了一个平台，让他们能够评估和比较各自的蛋白质功能预测计算方法。此外，CAFA 挑战已成为生物信息学领域的一项重要竞赛，在这里，研究人员可以了解各种现有功能预测算法的优点和缺点，并促进蛋白质功能预测方法的发展。

基于多模态预训练的蛋白质功能预测是一种前沿的深度学习方法，它通过整合来自蛋白质的不同数据源，例如序列、结构和已知的功能标注来训练模型。这种方法不依赖于大量的直接训练数据，而是通过挖掘和融合多种类型的生物数据来预测蛋白质的功能。模型通过学习这些不同模态的内在联系，构建一个能够从输入特征（如氨基酸序列和三维结构）映射到其功能属性的框架。在多模态预训练中，关键的挑战是如何有效地整合来自不同数据源的信息，并捕获这些数据之间的复杂关系。

2.2 国内外文献综述及简析

2.2.1 蛋白质功能预测研究现状

在过去几十年里，国内外学者提出了许多计算方法来预测蛋白质的功能。这些方法可以根据它们所利用的信息类型分为三大类：基于序列的方法、基于 3D 结构的方法、基于混合信息的方法。需要注意的是，这些分类并非严格区分，它们之间存在重叠和相关性，例如一些基于结构的计算方法也会利用序列信息来预测蛋白质的功能。

(1) 基于蛋白质序列的方法

基于序列的方法主要针对蛋白质序列，通过提取与功能相关的潜在特征来预测蛋白质的功能。这些方法更深入地研究氨基酸序列中包含的信息，并试图捕捉与嵌入其中的蛋白质功能相关的细微特征。

BLAST[6] 是一种广泛使用的工具，用于搜索数据库，寻找与目标蛋白相似的序列，从而推断目标蛋白的潜在功能。然而单纯依靠序列比对工具预测蛋白质功能的准确性不高，因此许多方法已经开始结合神经网络。结合卷积神经网络的预测结果，DeepGOPlus[7] 通过搜索已知功能的相似蛋白来提高预测精度。与之前的模型 DeepGO[8] 相比，DeepGOPlus 在去除 PPI 特征的同时提高了预测性能。此外它克服了序列长度的限制，用单热编码取代了氨基酸三元组嵌入层。HiFun[9] 从蛋白质可以表示为一种语言的想法中获得灵感，使用 BLOSUM62 矩阵[10] 和 FastText 嵌入蛋白质序列。基于 BLOSUM62 矩阵的向量被馈送到卷积层以提取潜在特征，而基于 FastText 嵌入的矩阵被馈送到由卷积神经网络 (CNN) 和具有自关注架构的双向长短期记忆 (BiLSTM)[11] 组成的架构中。从 CNN 中提取的特征向量被传递到 BiLSTM 的两个隐藏层，这两个隐藏层利用前后的上下文信息来增强特征表示。此外，HiFun 对 BiLSTM 层的输出执行自关注机制，以估计氨基酸的重要性。

这些方法仅利用蛋白质序列进行蛋白质功能预测，在发现新蛋白质的功能方面发挥着重要作用。通过研究实验表明，依赖于蛋白质序列的方法可以显著提高功能类别中 MFO 的预测。然而许多蛋白质在功能上相似，但在序列上不同，这可能导致对序列相似性低的蛋白质的预测性能较差。

(2) 基于蛋白质结构的方法

基于三维结构的方法侧重于蛋白质的结构特征，蛋白质结构经常被翻译成接触图，从中捕获与功能密切相关的特征。在这些方法中，蛋白质序列经常被用作输入特征之一，对于功能主要受结构特征影响的蛋白质，基于三维结构的方法具有更明显的优势。

DeepFRI[12] 将图卷积网络 (GCN) 作为其核心技术，首先利用蛋白质家族数据库 (Pfam)[13] 中的序列对具有长短期记忆的语言模型 (LSTM-LM)[14] 进行预训练，提取序列的残差特征；其次它将蛋白质结构转化为接触图，两者都用作 GCN 的输入。LSTM-LM 从序列中学习的特征和 GCN 从接触图中学习的特征显著提高了蛋白质功能预测的性能。HEAL[15] 与 DeepFRI 进行了比较，作者首先使用蛋白质数据库 (Protein Data Bank, PDB) 中的蛋白质训练模型 heal-PDB，该模型的性能与 DeepFRI 相当。通过加入 AlphaFold2[16] 预测的蛋白质结构，HEAL 的性能得到了显著提高。HEAL 首先基于序列节点特征和接触图为每个蛋白质构建图，并将其输入到由消息传递神经网络和分层图转换器组成的架构中，然后使用监督学习和比较学习来优化网络。Struct2GO[17] 同时接受序列和结构信息作为输入，利用 SeqVec 模型[18] 提取序列特征，利用基于自关注机制的分层图池化模型从 AlphaFold2 预测的结构中提取特征。为了最大限度地利用结构信息，Struct2GO 采用 Node2vec[19]

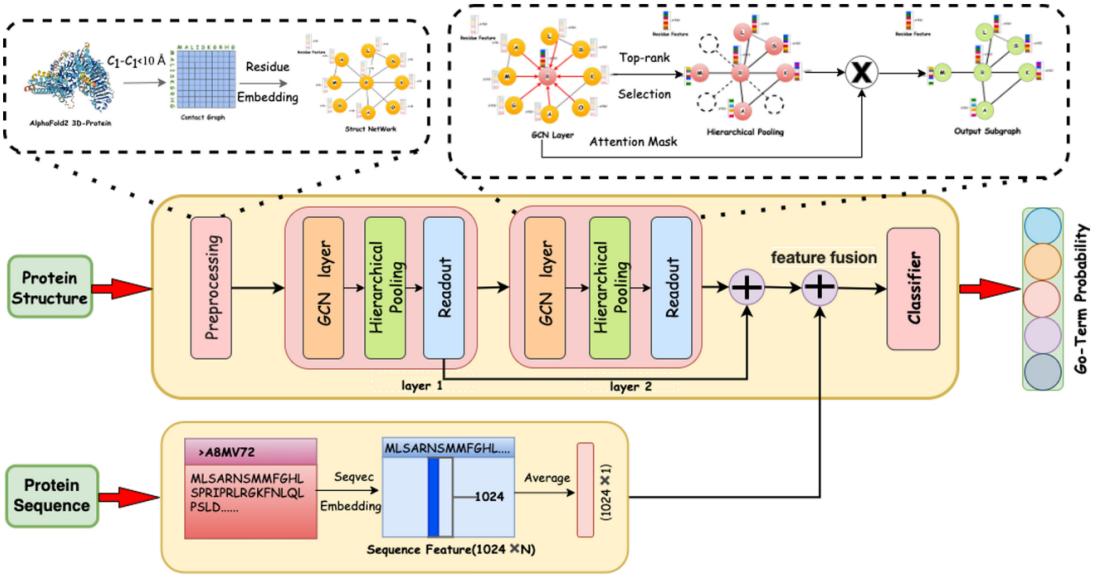

图 2-1 Struct2GO 模型图[17]

算法在蛋白质结构网络中生成氨基酸级嵌入。这些嵌入被用作图池模型的初始节点特征。与实验确定的蛋白质结构相比，AlphaFold2 提供了丰富的高分辨率结构信息，显著提高了模型预测精度。

这些方法将蛋白质结构与蛋白质序列结合起来，大大提高了蛋白质功能预测的准确性。对于高相似性的蛋白质，仅使用序列特征很难区分细微的功能差异，结合结构特征可以帮助克服这一问题。这种方法的缺点是它们只关注蛋白质的结构特征，而忽略了蛋白质之间的相互作用。

（3）基于混合信息的方法

基于混合信息的方法强调各种信息类型的组合，如蛋白质序列、蛋白质结构、PPI 网络或 InterPro 特征等的整合方法。CAFA 挑战表明，有效整合不同的信息类型可以真正提高蛋白质功能预测的准确性，目前混合信息是该领域发展的主要趋势。

DeepGraphGO[20] 是一种基于多物种图神经网络的方法。首先利用 InterProScan[21] 工具生成蛋白质的 InterPro 特征向量，并结合 PPI 网络将 InterPro 特征向量作为网络中的节点特征，然后通过多个图卷积层捕获网络中的高阶信息。此外，DeepGraphGO 的优势在于它采用了多物种策略，利用所有物种的蛋白质数据来训练单个模型，不仅节省了时间和计算资源，而且提高了模型的泛化能力。DeepGOZero[22] 使用 InterPro 的二进制特征作为输入，并通过两个多层感知器（MLP）层生成稠密特征。最显著的是 DeepGOZero 可以利用基因本体（GO) 形式公理通过零样本学习来预测新功能，这些 GO 形式公理通过 EL Embedding[23] 表示为 n 球体的类嵌入到几何模型的向量关系中来表示本体语义。DeepGOZero 将模型理

论与神经网络结合起来预测蛋白质功能，具体来说它计算预测结果和标签之间的二进制交叉熵损失，然后通过 EL Embedding 指定的本体公理派生的损失来优化它们。此外 DeepGOZero 还整合了同源蛋白的相似性信息，以进一步增强预测性能。DeepGO-SE[24] 对 DeepGOZero 进行了一系列改进, 它通过使用预训练的大型蛋白质语言模型结合神经符号模型来预测蛋白质序列的功能，该神经符号模型将功能预测视为近似语义蕴涵。作者使用 ESM2[25] 蛋白质语言模型来生成单个蛋白质的表示，与 DeepGOZero 类似，将 ESM2 嵌入投射到由 GO 公理生成的嵌入空间（EL Embeddings）中。与 DeepGOZero 不同的是，作者使用这些世界模型来执行“语义蕴涵”：当且仅当在所有使理论 T 为真的世界模型中，陈述 φ 也为真时，φ 才由理论 T 蕴涵 ($T \vDash \varphi$)[26]。利用这种近似语义蕴涵的形式，作者展示了 GO 扩展版本中的公理可以增强分子功能的预测。此外作者通过整合有关有机体蛋白质相互作用网络改进了复杂生物过程和细胞成分的预测。

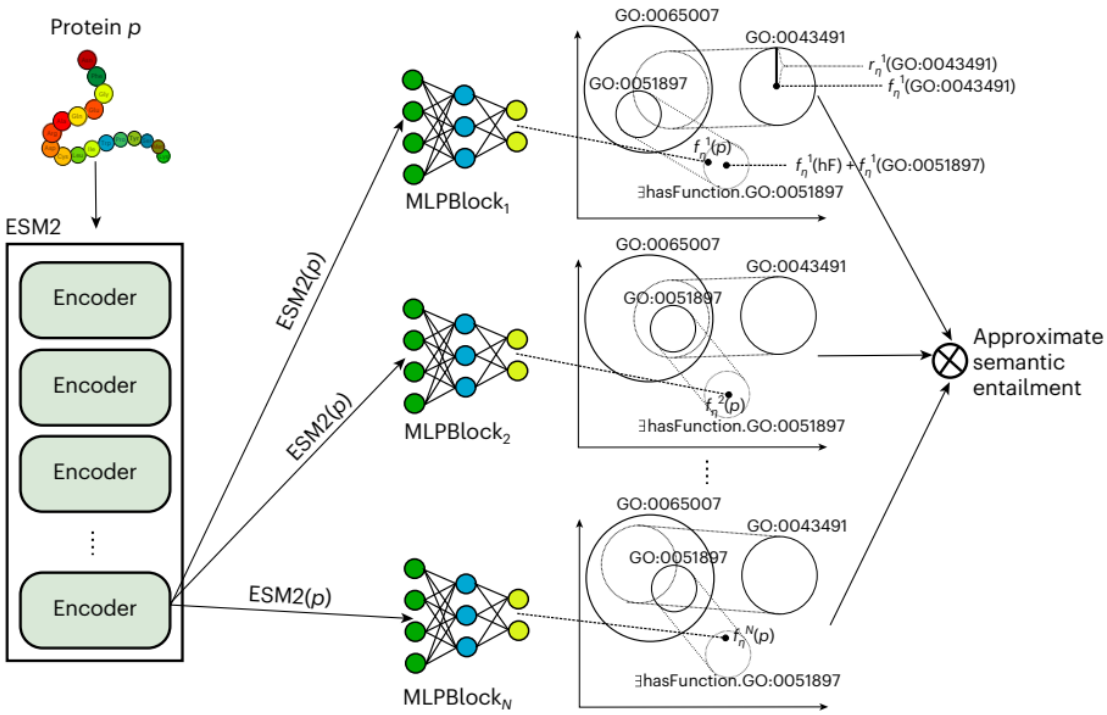

图 2-2 DeepGO-SE 模型图[24]

这些方法通过有效地融合来自多个来源的信息，从多个方面捕捉蛋白质的多样性特征，从而提高功能预测的性能。然而融合来自不同数据源的信息通常需要更复杂的算法或技术来提取特征，特别是在大规模数据集上，这可能导致计算资源和时间的消耗增加。此外，一些蛋白质可能缺乏某些特征的来源信息，导致缺乏这些蛋白质的全面融合信息，因此正确处理缺失数据是此类方法的主要挑战。

2.2.2 多模态预训练蛋白质功能预测研究现状

多模态预训练技术通过整合多种生物信息数据，如蛋白质序列、结构和已有的功能标注，克服了传统单一数据源预训练模型在自动功能预测（AFP）领域的局限性。这种方法的核心优势在于能够利用来自不同生物学模态的信息，提高预测未标注或罕见功能的准确性。在多模态预训练中，模型不仅学习从序列或结构直接推断功能的能力，还能通过整合这些不同模态的信息来获得更深层次的生物学见解。

CFAGO[27] 基于多头注意机制在两个阶段交叉融合 PPI 网络和蛋白质属性[28]。第一步是预训练，其中使用自编码器来学习 PPI 网络和蛋白质属性中的隐藏特征，自动编码器具有忽略数据中的噪声的能力。第二步是微调，将预训练好的编码器与两层全连接神经网络相结合，预测蛋白质功能。消融实验表明，与注意机制相比，预训练对成绩提高的作用更大。

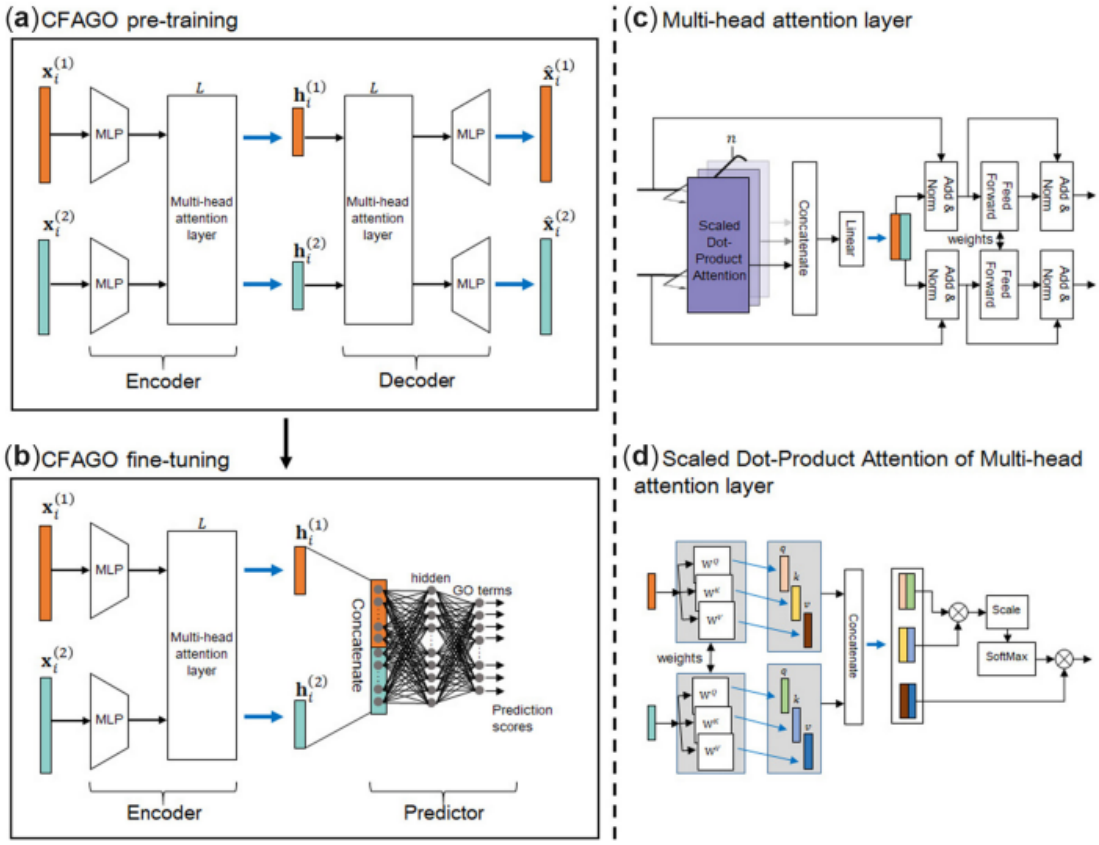

图 2-3 CFAGO 模型图[27]

MASSA[29] 构建了一个新型深度学习框架，用于整合蛋白质序列、结构和功能注释的多模态数据。MASSA 通过设计与蛋白质生物学理解相符的特定任务预训

练目标，在多任务学习过程中提取详细的蛋白质域特征，从而在蛋白质属性、蛋白质-蛋白质相互作用和蛋白质-配体相互作用等各种下游任务中增强性能。研究表明，该框架在特定下游任务中实现了最先进的结果，并引入了一种新的基于最优传输的度量来量化从预训练模型到不同下游任务的转移性，有效地展示了整合多种类型蛋白质数据的优势，为计算生物学和生物信息学的发展提供了新的视角。

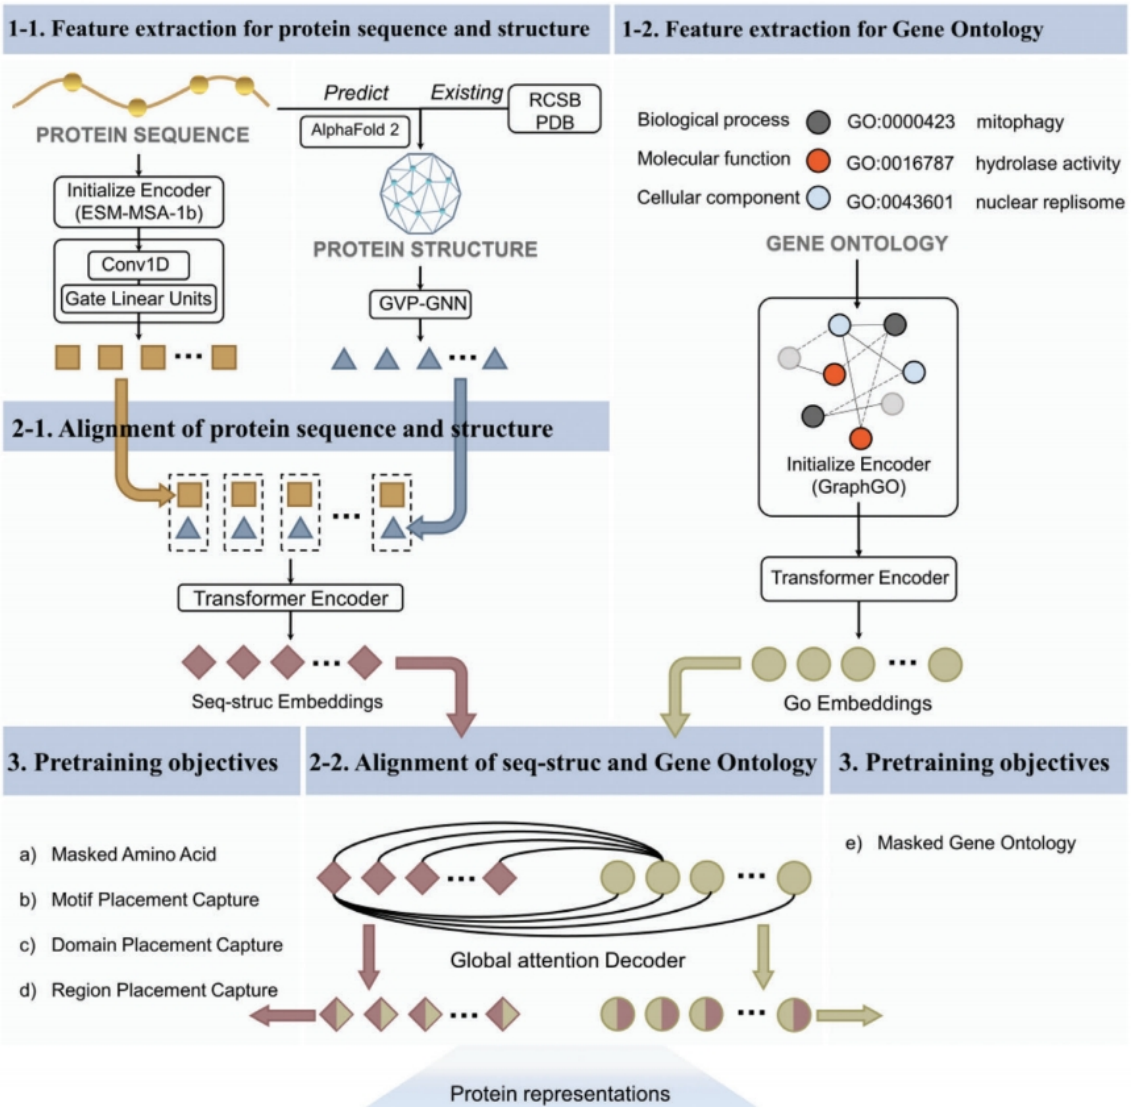

图 2-4 MASSA 模型图[29]

2.2.3 扩散模型分类器研究现状

最近大规模的文本到图像扩散模型显著提升了基于文本生成图像的能力，这些模型可以根据各种提示生成逼真的图像，并表现出强大的组合泛化能力。虽然到目前为止，大多数使用案例都集中在图像生成上，但扩散模型还可以提供条件

密度估计，这对于图像生成之外的任务也很有用。国内外已有不少学者利用扩散模型进行零样本分类，并取得了不错的性能结果。

Kevin Clark 与 Priyank Jaini[30] 提出文本到图像的扩散模型是零样本分类器，其关键思想是利用扩散模型的能力，在给定标签的文本描述的情况下，将带有噪声的图像去噪，作为该标签可能性的代理。模型以原始图像 x_0 作为输入，生成一个加噪的图像 x_t，这是通过在扩散模型中加入噪声来实现的。使用不同的标签提示（如“Cat”、“Horse”、“Frog”等），扩散模型条件化这些标签提示，以去噪输入图像。在每个时间步 t 上，扩散模型输出与这些标签相关的去噪图像，对每个标签提示在不同时间步的去噪图像计算得分，通过计算得分最小的标签来确定最终的分类结果。

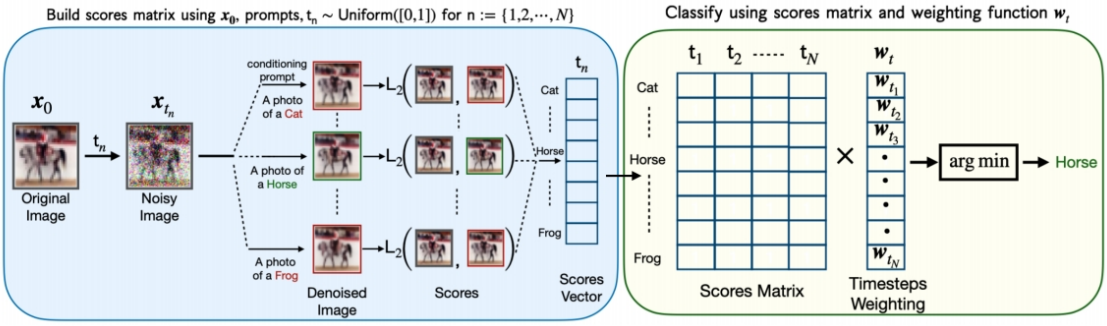

图 2-5 使用扩散模型进行零样本分类模型图[30]

Alexander Li 等人[31] 证明了大规模文本到图像扩散模型 (如 Stable diffusion[32]) 的密度估计可以用于执行零样本分类，而无需任何额外的训练。其中输入图像被加噪后，通过扩散模型和文本条件来去噪，并计算每个条件下的损失，最终模型选择那个最能准确预测噪声的条件（即损失最小的条件）作为分类结果。输入的文本条件 c 是与类别相关的描述（如 a photo of a [class name]），这是模型用来指导分类的提示。模型的分类目标是找到最佳的文本条件 c，使得在所有时间步 t 中，模型预测的噪声 $\hat{\epsilon}$ 最接近实际添加的噪声 ϵ。Chen 等人[33] 提出了鲁棒扩散分类器 (Robust diffusion Classifier, RDC)，这是一种由预训练的扩散模型构建的生成分类器，具有对抗鲁棒性。RDC 首先最大化给定输入的数据似然，然后使用扩散模型通过贝叶斯定理估计的条件似然来预测优化后输入的类概率。具体过程为给定输入图像 x，首先通过一个扩散模型对其进行处理，通过迭代优化来最大化图像的似然估计。这个过程涉及到多个时间步 t 的迭代，从而使优化后的图像 x_t 更符合扩散模型的概率分布。优化目标是最小化噪声预测误差（即扩散损失），这个误差在每个时间步 t 上进行平均。然后对优化后的图像 x_t 使用扩散模型再次进行处理，以估计每个类别 y 的条件对数似然 $\log p_\theta(x \mid y_k)$。通过贝叶斯定理，计算每个类别的概率 $p(y \mid x)$，并最终选择具有最大概率的类别作为预测结果。

2.2.4 蛋白质功能预测领域研究进展总结

综上所述，蛋白质功能预测领域在国内外取得了显著进展，主要包括基于序列、结构以及多模态信息的方法。CAFA 挑战作为评估和推动蛋白质功能预测的重要平台，显示了不同方法的优势和不足。基于序列的方法通过捕捉氨基酸序列中的特征实现预测，但在处理序列相似性低的蛋白质时存在局限。基于结构的方法通过分析蛋白质的三维特征来提高预测准确性，特别是在结合图神经网络时取得了优异的性能。然而，基于接触图提取结构特征的方法在计算资源上面临诸多限制。多模态预训练技术通过整合序列、结构和蛋白质功能注释等多种数据来源，进一步提升了模型的准确性和泛化能力，但也面临数据融合复杂性和计算资源需求增加的问题。此外，扩散模型在零样本分类中的应用展示了其在蛋白质功能预测领域的潜力。本课题将继续探索这些方法的优化和扩展，特别是在高维和复杂数据的处理上，进一步提升蛋白质功能预测的性能和应用范围。

第 3 章 主要研究内容及研究方案

3.1 研究内容

基于多模态预训练的蛋白质功能预测研究旨在通过结合深度学习和多种生物信息数据来源（如序列数据、结构数据和功能标注），提高预测精度，尤其是在未见功能标签上的预测能力。利用如 AlphaFold2 等结构预测工具的突破，以及其他相关生物信息技术的进展，本研究将探索如何有效地整合这些多模态数据来增强蛋白质功能的预测效果。研究的具体内容包括：

（1）设计并实现一个双分支 VAE[34] 预训练模型，用于同时编码蛋白质的序列和结构特征。序列和结构分别通过独立的编码器分支进行处理，并通过预训练提取出通用低维蛋白质特征表示。

（2）在 VAE 生成的蛋白质特征表示基础上，使用扩散模型进行 GO 标签的分类。扩散模型的优势在于它能够处理未见过的功能标签，通过生成过程估计各个类别的条件概率。

（3）在包含未见功能标签的测试集上对模型进行评估，验证其蛋白质功能预测能力。通过与其他传统方法（如基于序列相似性的方法）的对比实验，展示该模型在处理稀有功能标签上的优势。

3.2 研究方案

3.2.1 获取并整合数据集

本课题的研究内容涉及到蛋白质的序列、结构和功能标签三种数据，其中序列来自 UniProt 数据库[35]，结构来自 AlphaFold 数据库[16]，功能标签集合来自基因本体注释（GOA）数据库[36]。UniProt 是一个广泛使用的蛋白质数据库，包括各种重要部分,UniProt 版本 2024_01 包含超过 2.5 亿个序列记录。UniProt 手动管理和审查条目的部分被称为 UniProtKB/Swiss-Prot[3]，包含约 570 000 个序列。未经审查的部分被称为 UniProtKB/TrEMBL，包含约 2.49 亿个序列。根据 CAFA，不具实验性注释的蛋白质的注释是电子化的（证据代码：IEA），可能包含潜在的错误，为了保证模型的泛化性，我们在 UniProtKB/Swiss-Prot 中选择了不具实验性注释的 508245 个蛋白质进行预训练。带有证据代码（EXP、IDA、IPI、IMP、IGI、IEP、TAS 和 IC）的注释被认为是实验性的，为了确保实验结果的准确性和可靠性，我们选

择了带有实验证据代码的 60121 个蛋白质在下游预测中进行微调。并使用 GO[37] 的分层结构传播注释。

AlphaFold 是 DeepMind 和 EMBL-EBI 共同开发的高精度蛋白质结构预测数据库，在 v2.0 版本中，它包含超过 2 亿个条目，包括 48 种关键生物的蛋白质组，提供了广泛的 UniProt 覆盖范围。对于数据库中未包含的蛋白质结构，可以使用源代码（https：//github.com/google-deepmind/alphafold/）进行结构预测。为保证不同数据的蛋白质节点之间的映射对齐，本课题还下载了 Uniprot 映射到 AlphaFold 的映射文件。

基因本体注释（GOA）为 UniProt 知识库（UniProtKB）中的蛋白质提供高质量的 GO 注释。GOA 采用两种不同的 GO 注释方法：电子和手动[38]。目前 GOA 标注总数超过 13.77 亿条，其中电子 GO 标注约 13.72 亿条，人工 GO 标注仅约 590 万条。具体而言，GOA 数据库中超过 99% 的 GO 注释是通过电子注释方法进行的。GOA 数据库中有不同来源的功能注释信息，为了 GO 标签的真实可靠，本课题筛选了具有实验验证和专家手工收集的功能注释。

表 3-1 时间流数据集划分方法

数据集	划分依据
训练集	2021 年 1 月之前就具有实验注释的蛋白质
验证集	2021 年 1 月至 2022 年 12 月期间首次获得实验注释的蛋白质
测试集	2023 年 1 月至 2024 年 7 月期间首次获得实验注释的蛋白质

下游数据集划分共包含依据时间流划分和基于序列相似性聚类的两种策略，依据时间流划分数据集的方法如表 3-1 所示。为了验证本课题所提出的方法对于序列同源相似性低的蛋白质功能标签的预测能力，还对原始蛋白质数据进行了基于序列相似性的初始聚类步骤。为了确保所得簇之间的独特性，任何两个簇之间的序列相似性被限制为最大 30%，随后分别按照 18：1：1 的比例划分训练集、验证集和测试集。

3.2.2 构建双分支 VAE 预训练框架

国内外学者已经在蛋白质序列的低维表示上做了很多研究工作，有近两年兴起预训练语言模型的方法，例如 esm3[39]、SaProt[40]、ProGen[41] 等；有较老的 CNN[42]、LSTM[43] 等方法；还有类似 InterProScan[21] 等工具，这些方法已经能够提取到序列特征的关键信息，如蛋白质家族、结构域、结合位点等。本课题计划采用与当前蛋白质语言模型类似的模块对序列进行编码提取有效信息。

随着 AlphaFold2[44] 的巨大突破，越来越多的蛋白质能用来进行蛋白质功能预测，为了方便蛋白质结构的表示，出现了接触图的概念，基于接触图的方法能够简化蛋白质结构的初步表示，便于进一步通过深度学习提取蛋白质的结构特征产生低维表示，但通常是计算昂贵的。点云是一种常用的 3D 数据格式，在包括计算机视觉、自动驾驶和机器人技术在内的许多领域都取得了巨大成功[45]。点云可以表示为一组无序的 3D 点 $\{P_i \mid i = 1, \ldots, n\}$，其中所有点都是齐次的，并且每个点 P_i 是其 (x, y, z) 坐标的向量。与接触图和蛋白质图相比，点云具有在不牺牲计算效率的情况下保留原子几何信息的优点。与无序且同质的原始点云相比，我们计划采用的蛋白质点云由从其原始结构中提取的有序和异质点组成，具体来说每个点对应于氨基酸的 α 碳原子。除了每个点的 3D 坐标 (x, y, z) 之外，每个点所属的残基类型 R 以及该残基在长度为 L 的蛋白质序列中的位置 P 也被附加为点特征。蛋白质点云中每个点的定义为：$[x, y, z, R, P]$，$R \in$ (G, A, V, L, I, S, T, C, M, D, E, N, Q, R, K, F, Y, W, P, H)，$P \in (1, 2, 3, \ldots, L)$。

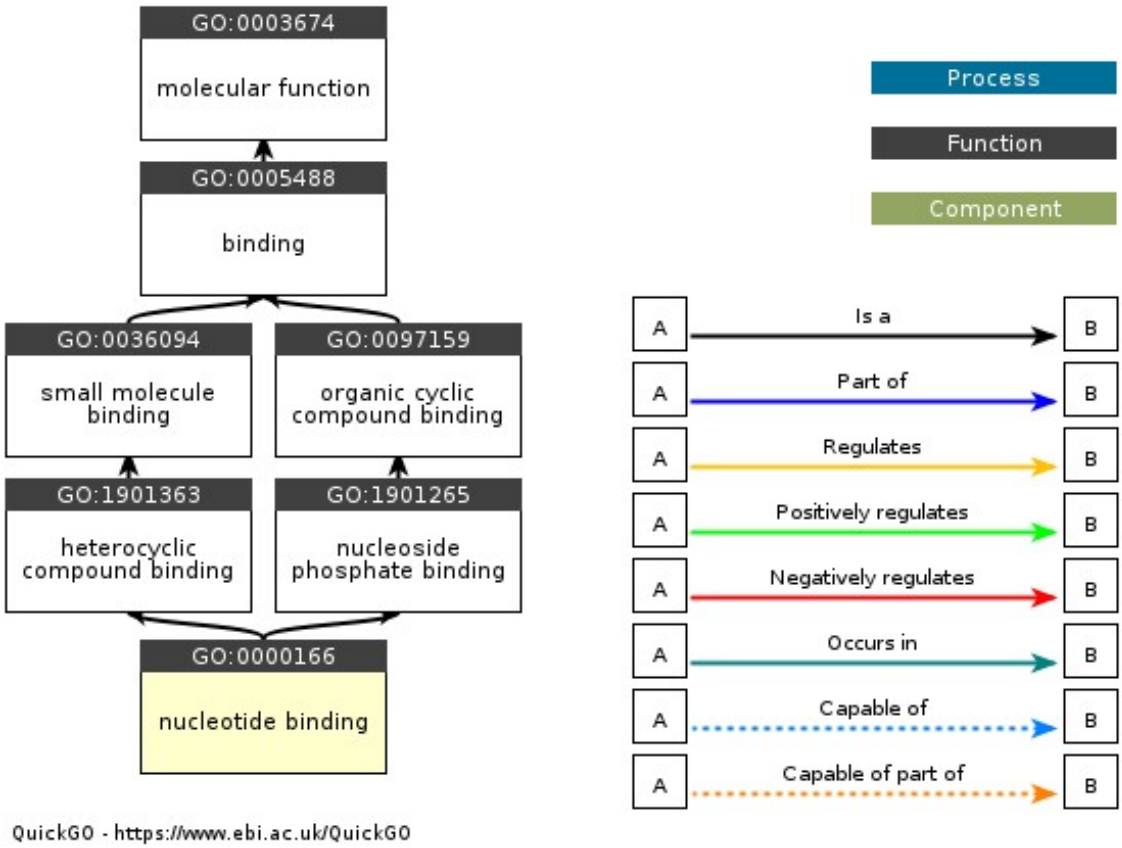

图 3-1 GO 树状结构示例[46]

功能标签，即 GO 标签，它们之间并不是独立或者简单集合的关系，而是一种树状结构关系，如图 3-1 所示。所有的 GO 标签都在这个树状结构的基因本体库中。

基因本体库不重叠地分为三个分支[47]：细胞组分（Cellular Component，CC），单个的基因产物或多个基因产物的复合物在分子水平上的活动；分子功能（Molecular Function，MF），基因产物在执行功能时所处的细胞结构位置；生物过程（Biological Process，BP），通过多种分子活动完成的生物学过程。在每个子系统内，所有的节点形成了有向无环图。并且，GO 子节点与父节点之间存在着“is a”和“part of”关系，这意味着如果一个蛋白质拥有某个 GO 节点表示的功能，那么也拥有该 GO 节点的父节点表示的功能。基于 GO 的这种真正路径规则，GO 标签在进行嵌入之前，还需要向上传播进行标签补全，否则会产生标签不一致等问题。之后对每一个蛋白质的标签集合编码，利用深度学习产生合适的嵌入表示作为扩散模型的类条件输入。

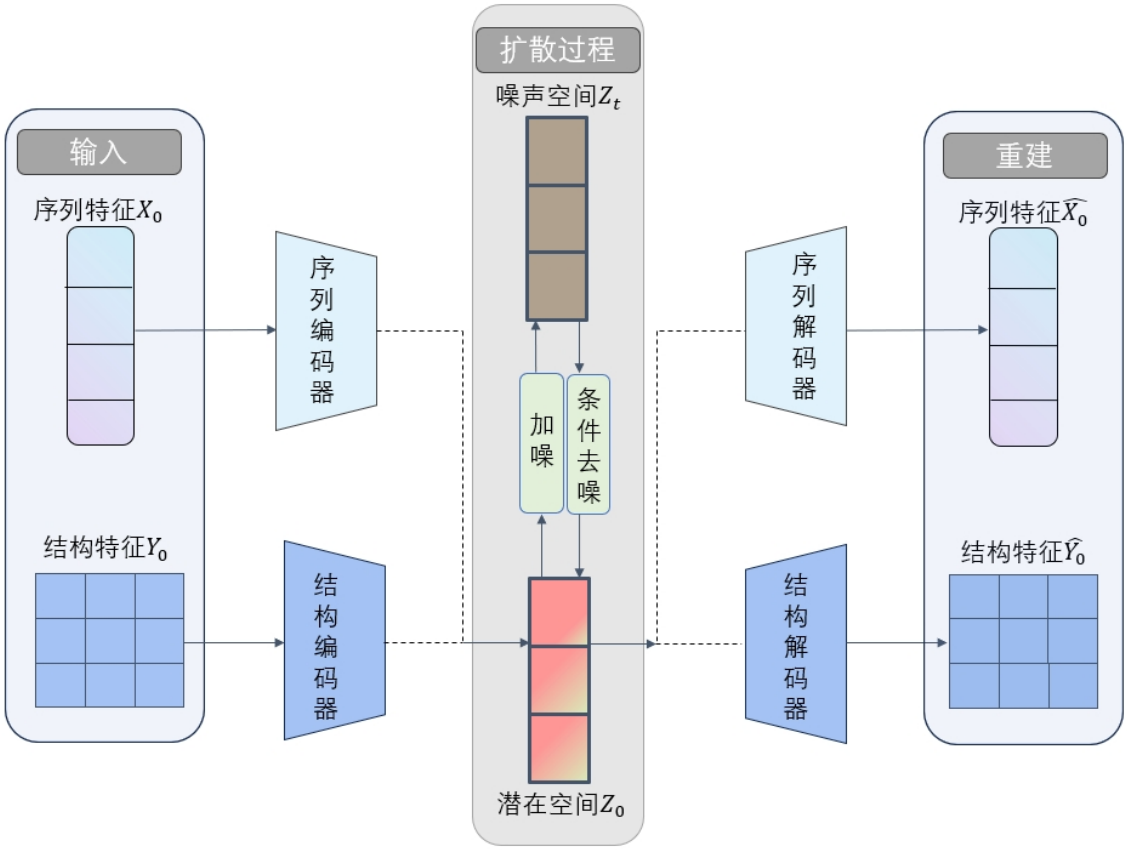

图 3-2 双分支 VAE 预训练框架示意图

本课题计划采用一种创新的双分支编码器-解码器变分自编码器（VAE）预训练架构，旨在同时处理和学习来自蛋白质序列、结构与功能注释的信息，双分支 VAE 预训练的模型架构如图 3-2 所示。这一架构通过分别对序列上下文和结构上下文进行编码，将两个不同模态的特征有效地整合并映射到统一的潜在向量空间中，进一步采用加噪与类条件去噪扩散过程对融合功能注释的向量分布进行学习，

最后分别根据交叉熵（CE）损失与 Chamfer 距离（CD）损失评估网络性能重建蛋白质序列与结构。该预训练旨在增强对蛋白质数据通用表示的学习能力，提高其在复杂生物数据中的泛化能力，为下游的功能预测和其他生物信息学处理任务提供强大的数据支持。

3.2.3 构建扩散模型网络

本课题计划构建一个扩散模型网络，旨在提高蛋白质功能预测的准确性和泛化能力，输入为蛋白质序列和结构的潜在空间特征。扩散模型是一类具有特定马尔可夫链结构的生成模型，本课题计划采用离散时间扩散模型的设计思想[48]。从一个干净的样本 z_0 开始，固定的前向过程 $q(z_t|z_{t-1})$ 添加高斯噪声，而学习到的反向过程 $p_\theta(z_{t-1}|z_t, c)$ 尝试对输入去噪，可选地基于一个变量 c 进行条件化。在我们的设置中，z 是蛋白质的潜在空间表示，而 c 代表一个低维的蛋白质 GO 功能标签嵌入。扩散模型定义 z_0 的条件概率为[49]：

$$p_\theta(z_0|c) = \int p(z_T) \prod_{t=1}^{T} p_\theta(z_{t-1}|z_t, c)\, dz_{1:T} \tag{3-1}$$

其中 $p(z_T)$ 通常固定为 $\mathcal{N}(0, \mathbf{I})$。由于直接最大化 $p_\theta(z_0)$ 涉及积分运算，难以实现，因此扩散模型通过最小化对数似然的变分下界（ELBO[50]）进行训练：

$$\log p_\theta(z_0|c) \geq \mathbb{E}_q \left[\log \frac{p_\theta(z_{0:T}, c)}{q(z_{1:T}|z_0)} \right] \tag{3-2}$$

扩散模型将 $p_\theta(z_{t-1}|z_t, c)$ 参数化为高斯分布，并训练一个神经网络，将带噪声的输入 z_t 映射到用于计算 $p_\theta(z_{t-1}|z_t, c)$ 均值的值。每个带噪声的样本 $z_t = \sqrt{\bar{\alpha}_t} z + \sqrt{1 - \bar{\alpha}_t}\epsilon$ 可以表示为一个干净输入 z 和高斯噪声 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 的加权组合，扩散模型通常会学习一个网络 $\epsilon_\theta(z_t, c)$ 来估计添加的噪声[51]。使用这种参数化，ELBO 可以写为：

$$-\mathbb{E}_\epsilon \left[\sum_{t=2}^{T} w_t \|\epsilon - \epsilon_\theta(z_t, c)\|^2 - \log p_\theta(z_0|z_1, c) \right] + C \tag{3-3}$$

其中 C 是一个不依赖于 c 的常数项。由于 T 很大且 $\log p_\theta(z_0|z_1, c)$ 通常较小，因此选择忽略这一项。研究发现发现去掉 w_t 可以改善样本质量指标[52]，于是 ELBO 的最终表达式为：

$$-\mathbb{E}_{t,\epsilon} \left[\|\epsilon - \epsilon_\theta(z_t, c)\|^2 \right] + C \tag{3-4}$$

扩散模型通过其生成过程学习数据的底层分布，而不仅仅是记忆训练数据中的特定模式。这种学习方式使模型能够更好地泛化到未见过的蛋白质序列或结构，

特别是那些在训练集中没有直接功能标签的蛋白质。本课题设计的扩散模型可以用于多种蛋白质功能预测任务，尤其是在新物种蛋白质功能注释、稀有功能标签发现等领域具有重要应用前景。通过将序列和结构特征有机结合，本课题为蛋白质功能预测提供了一种创新的解决方案，具有广泛的生物学和医学研究意义。

3.2.4 扩散模型上的类条件分类器

近年来，基于条件生成模型的分类方法在图像零样本分类方面展现出巨大潜力，本课题中使用扩散模型进行蛋白质功能预测的框架如图 3-3 所示。模型输入序列特征 X_0 和结构特征 Y_0 ，分别通过序列编码器和结构编码器进行处理，得到潜在空间表示 Z_0 和结构特征表示。在此基础上将 Z_0 添加噪声后生成噪声空间表示 Z_t，接下来将 Z_t 输入到扩散模块中，该模块结合 GO 标签条件 c 进行键值查询操作，从而完成特征的扩散处理。通过这种方法，即使对于未见过的类别，也能通过标签条件 c 提供的语义信息进行准确分类。最后通过最小化采样噪声 ϵ_θ 和添加噪声 ϵ 之间的损失函数，实现分类目标。该框架通过一系列编码、噪声添加、扩散处理步骤，最终精确预测输入数据的类别。

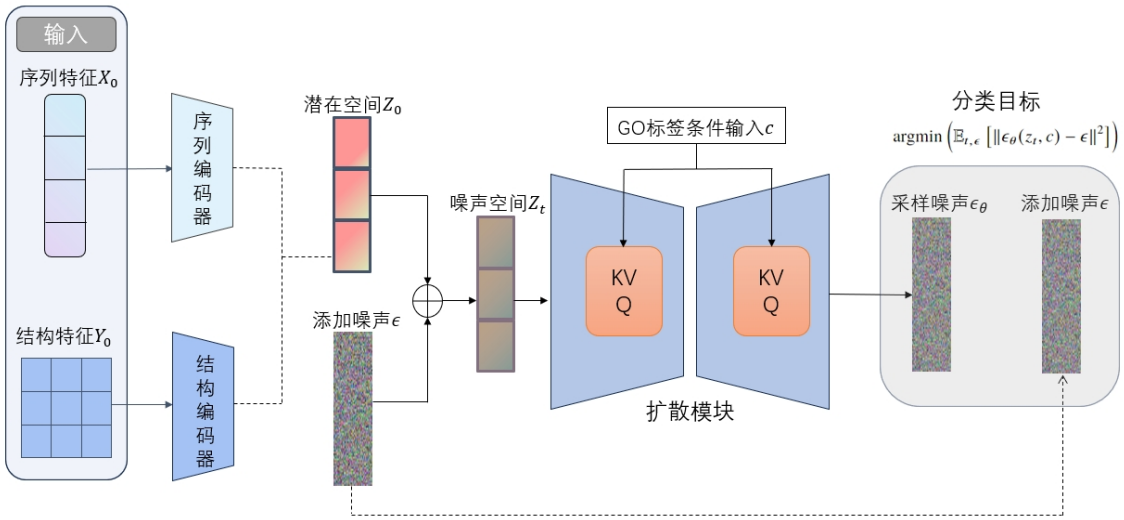

图 3-3 扩散分类器预测蛋白质功能框架示意图

具体而言，通过贝叶斯定理，利用模型预测结果和标签先验 $p(c)$，我们可以实现对给定输入 z 的条件概率 $p_\theta(c_i \mid z)$ 的计算，对于标签集合 $\{c_i\}$，条件概率的计算公式如下：

$$p_\theta(c_i \mid z) = \frac{p(c_i)p_\theta(z \mid c_i)}{\sum_j p(c_j)p_\theta(z \mid c_j)} \tag{3-5}$$

在假设标签的先验分布为均匀分布（即 $p(c_i) = \frac{1}{N}$）的情况下，所有 $p(c)$ 项

可以相互抵消。对于扩散模型来说，直接计算 $p_\theta(z \mid c)$ 是不可行的。因此我们使用变分下界（ELBO）来代替 $\log p_\theta(z \mid c)$，并结合以下公式来获得给定标签集合 $\{c_i\}_{i=1}^N$ 的后验分布[53]：

$$p_\theta(c_i \mid z) = \frac{\exp\left(-\mathbb{E}_{t,\epsilon}\left[\|\epsilon - \epsilon_\theta(\mathbf{z}_t, c_i)\|^2\right]\right)}{\sum_j \exp\left(-\mathbb{E}_{t,\epsilon}\left[\|\epsilon - \epsilon_\theta(\mathbf{z}_t, c_j)\|^2\right]\right)} \tag{3-6}$$

为了计算每个期望的无偏蒙特卡洛估计[54]，我们通过采样 N 对 (t_i, ϵ_i)，其中 $t_i \sim [1, 1000]$ 且 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$，并计算以下公式：

$$\frac{1}{N}\sum_{i=1}^{N}\left\|\epsilon_i - \epsilon_\theta\left(\sqrt{\bar{\alpha}_{t_i}}\mathbf{z} + \sqrt{1-\bar{\alpha}_{t_i}}\epsilon_i, c_j\right)\right\|^2 \tag{3-7}$$

通过将此公式代入上述后验分布的公式中，我们可以从条件扩散模型中提取分类器。扩散分类器是一种强大的、无需超参数调整的方法，可以从预训练的扩散模型中提取分类器，而无需进行额外的训练。扩散分类器可以用于从文本到图像模型（如 Stable Diffusion[32]）中提取零样本分类器，或者从类条件扩散模型（如 DiT[55]）中提取标准分类器。总之，本课题旨在利用扩散分类器这一创新方法，通过结合蛋白质序列和结构特征，实现更精确的蛋白质功能预测，推动蛋白质功能注释的零样本预测研究。

算法 3-1 基于扩散模型的蛋白质功能分类器

输入： 蛋白质潜在空间表示 z, 蛋白质功能标签 $\{c_i\}_{i=1}^n$，每个输入的采样次数 T

输出： 预测的功能标签 $Selectlabels$

```
初始化 Labels[c_i] = list() 对每个 c_i
for j = 1, ..., T do
    从 [1, 1000] 中采样 t；ε ~ N(0, I)
    计算 z_t = √ᾱ_t z + √(1 − ᾱ_t) ε
    for 条件功能标签 c_k ∈ {c_i}_{i=1}^n do
        将 ||ε − ε_θ(x_t, c_k)||^2 加入到 Labels[c_k] 中
    end for
end for
对每个 c_i 计算功能标签平均误差：MeanLabels[c_i] = mean(Labels[c_i])
选择误差低于阈值的标签：
SelectedLabels = {c_i | MeanLabels[c_i] < threshold}
return Selectlabels
```

3.2.5 优化多标签分类器及模型评估

蛋白质功能预测是一个典型的多标签学习问题，与传统的分类问题相比较主要有标签之间相互依赖和标签数量不确定两个问题，对于前者，本课题使用真正路径规则在获取标签嵌入时解决；对于后者，关键是要设计并优化合适的多标签分类算法。本课题采用基于机器学习的多标签学习算法整合前述提取出的蛋白质节点表示，构建蛋白质功能预测模型。

为了从不同角度评估不同方法的预测准确性，我们选择了两种不同的度量标准，包括 F-max 分数（Fmax）和精确率-召回率曲线下面积（AUPR）。Fmax[56] 是一种蛋白质中心的度量标准，在 CAFA 挑战赛[57] 和许多蛋白质功能预测研究中使用，其取值范围为 0 到 1，其中 1 表示模型的最佳性能，0 表示最差性能。其定义如下：

$$\mathrm{Fmax} = \max_{\tau}\left(\frac{2 \times \mathrm{pr}(\tau) \times \mathrm{rc}(\tau)}{\mathrm{pr}(\tau) + \mathrm{rc}(\tau)}\right) \tag{3-8}$$

$\mathrm{pr}(\tau)$ 和 $\mathrm{rc}(\tau)$ 分别是阈值 τ 下的精确率和召回率，其定义如下：

$$\mathrm{pr}(\tau) = \frac{1}{m(\tau)} \sum_{i=1}^{m(\tau)} \frac{|P_i(\tau) \cap T_i|}{|P_i(\tau)|} \tag{3-9}$$

$$\mathrm{rc}(\tau) = \frac{1}{n} \sum_{i=1}^{n} \frac{|P_i(\tau) \cap T_i|}{|T_i|} \tag{3-10}$$

其中 f 是一个 GO 类，$P_i(\tau)$ 是蛋白质 i 在阈值 τ 下的预测注释集合，T_i 是该蛋白质的真实注释集合，$m(\tau)$ 是我们为至少一个类进行预测的蛋白质数量，n 是蛋白质的总数。

此外 AUPR 是一种在许多蛋白质功能预测研究中使用的功能中心度量标准，它也是评估预测结果中类别不平衡时的合理指标[58]。AUPR 和 AUROC 都是非常通用的分类评价标准。然而，由于 AUROC 在分类不平衡的情况下可能不够敏感，因为它考虑了真阳性率和假阳性率之间的平衡，这可能会受到大量负类样本的影响。相反 AUPR 更好地反映了分类器在预测正例时的性能，即它更能够惩罚假阳性[59]。AUPR 的取值范围也为 0 到 1，1 表示模型的最佳性能，0 表示最差性能。

第 4 章 预期目标

4.1 预期目标

本课题的预期目标是基于多模态预训练的方法，成功实现蛋白质功能的准确预测，特别是在面对稀有功能标签和新发现的蛋白质时。通过利用蛋白质序列和结构特征，结合扩散模型与标签类条件分类器，我们期望能够提升蛋白质功能预测的精度和鲁棒性。主要的成果和目标可分为以下几点：

（1）针对蛋白质序列和结构数据的特点进行数据预处理，利用双分支变分自编码器（VAE）预训练并学习出适用于下游蛋白质功能预测的有效潜在空间表示。

（2）构建扩散模型，包括噪声添加和去噪两个过程，首先通过逐步添加高斯噪声模拟蛋白质数据的扩散，然后利用神经网络根据特定条件功能标签从噪声中恢复原始蛋白质表示。

（3）设计并实现基于扩散模型的标签类条件分类器，能够在无标签或稀有标签的数据条件下，精确预测蛋白质的功能。

（4）优化分类器使得其能够有效进行多标签分类，并在各种复杂条件下提供稳定的蛋白质功能预测结果，特别是针对序列同源相似性低的蛋白质。

（5）将上述研究工作整理成论文，争取以第一作者身份在 JCR 一区期刊上发表一篇具有影响力的学术论文。

第 5 章 已完成的研究工作及进度安排

5.1 已完成的研究工作

目前为止，本课题已经完成了蛋白质功能预测研究及多模态预训练与扩散模型进行零样本分类的理论学习，成功获取并整理了相关数据集。按照研究内容所述，上游数据集拟选择 UniProt 版本 2024_01 手动管理和审查条目的部分 UniProtKB/Swiss-Prot 中不具实验性注释的 508245 个蛋白质进行大规模数据预训练。下游数据集的构建采用了两种策略：一种是依据时间流划分数据集，另一种是基于序列相似性进行聚类划分。前者确保训练集与测试集中的蛋白质数据无冗余，而后者则确保了不同蛋白质序列间的区分度，从而充分保证了模型在不同条件下的泛用性。这两种策略在处理大规模数据时能够有效提高模型的稳定性和准确性，确保研究结果的可靠性。下表展示了根据不同规则生成的下游数据集的详细统计信息。

表 5-1 根据不同规则生成的下游数据集统计信息

数据集	统计数据	BPO	CCO	MFO	全部
时间流划分数据集	训练集	47,830	42,891	31,756	57,254
	验证集	777	717	684	1,432
	测试集	1,070	898	408	1,435
	GO 标签	19,717	2,506	6,095	28,318
序列相似性划分数据集	训练集	44,827	40,235	29,745	54,302
	验证集	2,378	2,091	1,510	2,823
	测试集	2,472	2,180	1,593	2,996
	GO 标签	19,450	2,515	5,914	27,879

此外，本课题还复现了蛋白质功能预测近年来的经典论文，包括结合多模态学习框架用于蛋白质表示，通过学习蛋白质的序列、结构和功能注释数据来进行多任务学习，其目的在于提高蛋白质相关下游任务的性能，并通过新的空间度量方法量化表示的转移性的 MASSA 模型[29]；学习结构域与 GO 之间的关联，构建功能一致的结构域表示，从而有效地进行蛋白质功能预测的 Domain-PFP 模型[60]；基于 DeepFRI 数据集，加入层次图注意力的 HEAL 模型[15]；基于自注意力图池化算法，利用 AlphaFold2 提供的结构信息来增强模型预测的准确性和通用性的

Struct2GO[17] 模型；使用编码器-解码器架构进行预训练，然后进行微调以学习更有效的蛋白质表示的 CFAGO 模型[27]；结合预训练的大型语言模型和神经符号模型，利用基因本体（GO）中的公理进行预测的 DeepGO-SE 模型[24]。

5.2 进度安排

本课题的研究时间为 2023 年 9 月开始至 2025 年 12 月份进行答辩，根据以往项目经验，结合个人的学习和科研攻关能力，为本课题研究计划，制定以下的研究进度安排：

（1）2023 年 9 月至 2024 年 8 月：已完成相关理论学习，经典论文复现，获取并整理数据集。

（2）2024 年 9 月至 2024 年 12 月：构建双分支变分自编码器（VAE）预训练架构并设计扩散模型，包括向前噪声添加过程、通过逐步去除高斯噪声恢复蛋白质数据的扩散过程，通过预训练学习出适用于下游多标签分类任务的有效潜在空间表示，

（3）2025 年 1 月至 2025 年 3 月：设计并实现基于扩散模型的标签类条件分类器，能够处理无标签或稀有标签数据。

（4）2025 年 3 月至 2025 年 5 月：进行对比实验，准备中期答辩。

（5）2025 年 6 月至 2025 年 8 月：继续优化多标签分类器，确保其在各种复杂条件下的预测结果的稳定性和准确性。

（6）2025 年 9 月至 2025 年 11 月：完成论文以及相关材料的撰写，准备答辩。

第 6 章 已具备的研究条件和所需条件及经费

6.1 实验室条件和经费保障

实验室目前已经有两台服务器，分别是 Dell EMC PowerEdge R740 和 Nettrix X640 G40 机架式服务器。Dell EMC PowerEdge R740 具有 2 个物理 CPU，型号为 Intel(R) Xeon(R) Silver 4114 CPU @ 2.20GHz，一共拥有 40 个逻辑核心。运行内存为 250GB，硬盘空间为 3TB。配备 2 张 Tesla P40 显卡，单张显存容量 24GB。Nettrix X640 G40 具有 2 个物理 CPU，型号为 Intel(R) Xeon(R) Platinum 8358 CPU @ 2.60GHz，一共拥有 128 个逻辑核心。运行内存为 500GB，硬盘空间为 7TB。配备 8 张 NVIDIA RTX A6000 显卡，单张显存容量 48GB。以上设备可以充分保障本课题的科研需求。

6.2 所需条件及经费

目前实验室提供的研究条件充分，经费充足，开展今后的课题研究仅使用现有的服务器作为研究平台即可，并不需要采购其他设备。

第 7 章 预计困难及解决方案

7.1 预计困难与技术难点

（1）课题涉及的数据量大，且具有高维、高噪声的特性，这使得模型不仅在数据预处理上面临着一些困难，而且在抗噪能力和处理大规模数据的能力上有较高的要求，怎样将蛋白质序列和结构数据转换为统一潜在空间分布也是本研究的一个重难点。

（2）扩散模型的设计包括噪声添加和去噪两个过程，在模拟蛋白质数据的扩散过程时，需要精准地实现高斯噪声的逐步添加，并通过神经网络恢复原始蛋白质表示。优化扩散分类器以实现有效的多标签分类，特别是在低蛋白质序列同源相似性的条件下，能够提供稳定的预测结果，是一个重要的技术挑战。

（3）通过 3D 点云表征蛋白质结构数据并进行多模态生物数据预训练，与利用扩散模型等生成方法进行分类是近两年才兴起的发展方向，可参考的论文和方法有限，这使得本课题在研究时面临着一些阻力。

(4) 在分类类别数量庞大的情况下，计算每个类别的得分通常需要进行多次采样，这将导致计算成本的显著增加。如何设计一种有效的算法和网络框架以降低计算复杂度，已成为该领域目前面临的主要挑战之一。

7.2 解决方案

（1）针对数据集的问题，设计改进的变分自编码器预训练架构，例如引入自注意力机制，增强潜在空间表示的表达能力，确保其能捕捉蛋白质数据的关键特征。

（2）为了提高进展速度和效率，本课题将一边进行实验一边吸收已经提出的蛋白质功能预测领域的相关方法，针对不同算法的问题尝试改进和优化，争取探索最有效的算法来进行研究。

（3）持续阅读大量相关论文，紧跟学术前沿动态，不断尝试最新的多模态预训练方法，拓展科研思路。

参考文献

[1] EISENBERG D，MARCOTTE E M，XENARIOS I，et al. Protein function in the post-genomic era [J]. Nature，2000，405（6788）：823-826.

[2] ANON. UniProt: the universal protein knowledgebase in 2021 [J]. Nucleic acids research，2021，49（D1）：D480-D489.

[3] BOUTET E，LIEBERHERR D，TOGNOLLI M，et al. UniProtKB/Swiss-Prot, the manually annotated section of the UniProt KnowledgeBase: how to use the entry view [J]. Plant bioinformatics: methods and protocols，2016：23-54.

[4] WANG X, CHEN G, QIAN G, et al. Large-scale multi-modal pre-trained models: A comprehensive survey [J]. Machine Intelligence Research，2023，20（4）：447-482.

[5] ZHOU N，JIANG Y，BERGQUIST T R，et al. The CAFA challenge reports improved protein function prediction and new functional annotations for hundreds of genes through experimental screens [J]. Genome biology，2019，20：1-23.

[6] ALTSCHUL S F，GISH W，MILLER W，et al. Basic local alignment search tool [J]. Journal of molecular biology，1990，215（3）：403-410.

[7] KULMANOV M，HOEHNDORF R. DeepGOPlus: improved protein function prediction from sequence [J]. Bioinformatics，2020，36（2）：422-429.

[8] KULMANOV M，KHAN M A，HOEHNDORF R. DeepGO: predicting protein functions from sequence and interactions using a deep ontology-aware classifier [J]. Bioinformatics，2018，34（4）：660-668.

[9] WU J，QING H，OUYANG J，et al. HiFun: homology independent protein function prediction by a novel protein-language self-attention model [J]. Briefings in Bioinformatics，2023，24（5）：bbad311.

[10] SONG D, CHEN J, CHEN G, et al. Parameterized BLOSUM matrices for protein alignment [J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics，2014，12（3）：686-694.

[11] XU G，MENG Y，QIU X，et al. Sentiment analysis of comment texts based on BiLSTM [J]. Ieee Access，2019，7：51522-51532.

[12] GLIGORIJEVIĆ V, RENFREW P D, KOSCIOLEK T, et al. Structure-based protein function prediction using graph convolutional networks [J]. Nature communications，2021，12（1）：3168.

[13] MISTRY J, CHUGURANSKY S, WILLIAMS L, et al. Pfam: The protein families database in 2021 [J]. Nucleic acids research, 2021, 49(D1): D412-D419.

[14] GRAVES A, GRAVES A. Long short-term memory [J]. Supervised sequence labelling with recurrent neural networks, 2012: 37-45.

[15] GU Z, LUO X, CHEN J, et al. Hierarchical graph transformer with contrastive learning for protein function prediction [J]. Bioinformatics, 2023, 39(7): btad410.

[16] VARADI M, ANYANGO S, DESHPANDE M, et al. AlphaFold Protein Structure Database: massively expanding the structural coverage of protein-sequence space with high-accuracy models [J]. Nucleic acids research, 2022, 50(D1): D439-D444.

[17] JIAO P, WANG B, WANG X, et al. Struct2GO: protein function prediction based on graph pooling algorithm and AlphaFold2 structure information [J]. Bioinformatics, 2023, 39(10): btad637.

[18] HEINZINGER M, ELNAGGAR A, WANG Y, et al. Modeling aspects of the language of life through transfer-learning protein sequences [J]. BMC bioinformatics, 2019, 20: 1-17.

[19] GROVER A, LESKOVEC J. node2vec: Scalable feature learning for networks [C] // Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining, [S.l.], 2016: 855-864.

[20] YOU R, YAO S, MAMITSUKA H, et al. DeepGraphGO: graph neural network for large-scale, multispecies protein function prediction [J]. Bioinformatics, 2021, 37(Supplement_1): i262-i271.

[21] JONES P, BINNS D, CHANG H-Y, et al. InterProScan 5: genome-scale protein function classification [J]. Bioinformatics, 2014, 30(9): 1236-1240.

[22] KULMANOV M, HOEHNDORF R. DeepGOZero: improving protein function prediction from sequence and zero-shot learning based on ontology axioms [J]. Bioinformatics, 2022, 38(Supplement_1): i238-i245.

[23] KULMANOV M, LIU-WEI W, YAN Y, et al. El embeddings: Geometric construction of models for the description logic el++ [J]. arXiv preprint arXiv:1902.10499, 2019.

[24] KULMANOV M, GUZMÁN-VEGA F J, DUEK ROGGLI P, et al. Protein function prediction as approximate semantic entailment [J]. Nature Machine Intelligence, 2024, 6(2): 220-228.

[25] LIN Z，AKIN H，RAO R，et al. Evolutionary-scale prediction of atomic-level protein structure with a language model [J]. Science, 2023, 379(6637): 1123-1130.

[26] ZADEH L A. The concept of a linguistic variable and its application to approximate reasoning—I [J]. Information sciences，1975，8（3）：199-249.

[27] WU Z，GUO M，JIN X，et al. CFAGO: cross-fusion of network and attributes based on attention mechanism for protein function prediction [J]. Bioinformatics，2023，39（3）：btad123.

[28] VASWANI A. Attention is all you need [J]. arXiv preprint arXiv:1706.03762，2017.

[29] HU F，HU Y，ZHANG W，et al. A multimodal protein representation framework for quantifying transferability across biochemical downstream tasks [J]. Advanced Science，2023，10（22）：2301223.

[30] CLARK K，JAINI P. Text-to-image diffusion models are zero shot classifiers [J]. Advances in Neural Information Processing Systems，2024，36.

[31] LI A C，PRABHUDESAI M，DUGGAL S，et al. Your diffusion model is secretly a zero-shot classifier [C] // Proceedings of the IEEE/CVF International Conference on Computer Vision，[S.l.]，2023：2206-2217.

[32] ROMBACH R，BLATTMANN A，LORENZ D，et al. High-resolution image synthesis with latent diffusion models [C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition，[S.l.]，2022：10684-10695.

[33] CHEN H，DONG Y，WANG Z，et al. Robust classification via a single diffusion model [J]. arXiv preprint arXiv:2305.15241，2023.

[34] KINGMA D P. Auto-encoding variational bayes [J]. arXiv preprint arXiv:1312.6114，2013.

[35] ANON. UniProt: the universal protein knowledgebase in 2023 [J]. Nucleic acids research，2023，51（D1）：D523-D531.

[36] HUNTLEY R P，SAWFORD T，MUTOWO-MEULLENET P，et al. The GOA database: gene ontology annotation updates for 2015 [J]. Nucleic acids research，2015，43（D1）：D1057-D1063.

[37] ASHBURNER M，BALL C A，BLAKE J A，et al. Gene ontology: tool for the unification of biology [J]. Nature genetics，2000，25（1）：25-29.

[38] BARRELL D, DIMMER E, HUNTLEY R P, et al. The GOA database in 2009—an integrated Gene Ontology Annotation resource [J]. Nucleic acids research, 2009, 37 (suppl_1): D396-D403.

[39] HAYES T, RAO R, AKIN H, et al. Simulating 500 million years of evolution with a language model [J]. bioRxiv, 2024: 2024-07.

[40] SU J, HAN C, ZHOU Y, et al. Saprot: Protein language modeling with structure-aware vocabulary [J]. bioRxiv, 2023: 2023-10.

[41] MADANI A, MCCANN B, NAIK N, et al. Progen: Language modeling for protein generation [J]. arXiv preprint arXiv:2004.03497, 2020.

[42] LI Z, LIU F, YANG W, et al. A survey of convolutional neural networks: analysis, applications, and prospects [J]. IEEE transactions on neural networks and learning systems, 2021, 33 (12): 6999-7019.

[43] YU Y, SI X, HU C, et al. A review of recurrent neural networks: LSTM cells and network architectures [J]. Neural computation, 2019, 31 (7): 1235-1270.

[44] BRYANT P, POZZATI G, ELOFSSON A. Improved prediction of protein-protein interactions using AlphaFold2 [J]. Nature communications, 2022, 13 (1): 1265.

[45] GUO Y, WANG H, HU Q, et al. Deep learning for 3d point clouds: A survey [J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43 (12): 4338-4364.

[46] BINNS D, DIMMER E, HUNTLEY R, et al. QuickGO: a web-based tool for Gene Ontology searching [J]. Bioinformatics, 2009, 25 (22): 3045-3046.

[47] CONSORTIUM G O. The Gene Ontology (GO) database and informatics resource [J]. Nucleic acids research, 2004, 32 (suppl_1): D258-D261.

[48] HOOGEBOOM E, NIELSEN D, JAINI P, et al. Argmax flows and multinomial diffusion: Learning categorical distributions [J]. Advances in Neural Information Processing Systems, 2021, 34: 12454-12465.

[49] KINGMA D, SALIMANS T, POOLE B, et al. Variational diffusion models [J]. Advances in neural information processing systems, 2021, 34: 21696-21707.

[50] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations [J]. arXiv preprint arXiv:2011.13456, 2020.

[51] SOHL-DICKSTEIN J，WEISS E，MAHESWARANATHAN N，et al. Deep unsupervised learning using nonequilibrium thermodynamics [C] //International conference on machine learning，[S.l.]，2015：2256-2265.

[52] HO J，JAIN A，ABBEEL P. Denoising diffusion probabilistic models [J]. Advances in neural information processing systems，2020，33：6840-6851.

[53] SONG Y，ERMON S. Generative modeling by estimating gradients of the data distribution [J]. Advances in neural information processing systems，2019，32.

[54] DOUCET A，PITT M K，DELIGIANNIDIS G，et al. Efficient implementation of Markov chain Monte Carlo when using an unbiased likelihood estimator [J]. Biometrika，2015，102（2）：295-313.

[55] PEEBLES W，XIE S. Scalable diffusion models with transformers [C] //Proceedings of the IEEE/CVF International Conference on Computer Vision，[S.l.]，2023：4195-4205.

[56] CLARK W T，RADIVOJAC P. Information-theoretic evaluation of predicted ontological annotations [J]. Bioinformatics，2013，29（13）：i53-i61.

[57] RADIVOJAC P，CLARK W T，ORON T R，et al. A large-scale evaluation of computational protein function prediction [J]. Nature methods，2013，10（3）：221-227.

[58] DAVIS J，GOADRICH M. The relationship between Precision-Recall and ROC curves [C] //Proceedings of the 23rd international conference on Machine learning，[S.l.]，2006：233-240.

[59] SONG F V，SU J，HUANG S，et al. DeepSS2GO: protein function prediction from secondary structure [J]. Briefings in Bioinformatics，2024，25（3）：bbae196.

[60] IBTEHAZ N，KAGAYA Y，KIHARA D. Domain-PFP allows protein function prediction using function-aware domain embedding representations [J]. Communications Biology，2023，6（1）：1103.