硕士学位论文

（专业学位论文）

基于图神经网络的多行为去噪推荐方法研究

RESEARCH ON MULTI-BEHAVIOR DENOISING RECOMMENDATION METHOD BASED ON GRAPH NEURAL NETWORKS

樊红雨

哈尔滨工业大学

2026 年 1 月

国内图书分类号：TM301.2　　学校代码：10213
国际图书分类号：62-5　　密级：公开

硕士学位论文

基于图神经网络的多行为去噪推荐方法研究

硕士研究生：樊红雨

导　　师：马江虹副教授

申请学位：专业硕士

类　　别：计算机技术

所在单位：哈尔滨工业大学（深圳）

答辩日期：2026 年 01 月

授予学位单位：哈尔滨工业大学

Classified Index: TM301.2
U.D.C: 62-5

Dissertation for the Master Degree

RESEARCH ON MULTI-BEHAVIOR DENOISING RECOMMENDATION METHOD BASED ON GRAPH NEURAL NETWORKS

Candidate: Hongyu Fan
Supervisor: Associate Prof. Jianghong Ma
Academic Degree Applied for: Master of Engineering
Specialty: Electronic and Information Engineering
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: January, 2026
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

随着用户交互行为类型的日益丰富，推荐系统在多行为场景下面临严重的噪声干扰与偏好混叠问题。用户在电商或内容平台上的点击、收藏、加购、购买等行为虽然能够反映潜在兴趣，但其中包含的随机、误触或弱相关交互会削弱模型对真实偏好的刻画能力。此外，传统多行为推荐多依赖协同信号，缺乏模态语义信息的辅助，难以在复杂语义环境下准确识别噪声行为。针对上述问题，本文围绕“多行为协同去噪”与“多模态语义引导去噪”两个方向展开研究，提出了两个具有互补性的去噪推荐模型。

首先，提出多行为推荐系统中的噪声识别与偏好提取模型，面向多行为推荐中的噪声干扰问题。该模型从行为间与行为内两个层面建模用户偏好关系，设计了行为加权机制与自监督约束，从多行为图结构中自动识别并抑制噪声交互的影响。同时，引入噪声感知的偏好提取模块，使模型在保留高质量辅助行为信号的同时，消除弱相关或不可靠的交互，从而获得更精确的偏好表示。

其次，为进一步扩展至多模态多行为场景，提出基于大模型语义引导的多模态多行为去噪推荐方法。该方法引入大型视觉语言模型提取物品的图像与文本语义表示，通过模态语义相似度实现硬去噪，去除语义不一致的辅助交互；在图神经网络框架中，设计语义感知注意力机制以实现软去噪，自适应调整邻居节点的信息权重，从而聚焦于语义一致的高质量交互。此外，提出跨图对比学习模块，在语义增强图与去噪图之间建立一致性约束，实现模态语义信息向结构空间的有效迁移。

本文的创新性体现在结合协同信号建模与多模态语义理解技术，提出两种创新方法以解决多行为推荐场景中的噪声干扰与真实偏好识别问题。一方面，从协同信息建模与去噪机制两方面入手，设计了基于行为内与行为间双层结构的噪声感知偏好提取模型，实现对真实偏好与噪声交互的有效区分，提升了多行为推荐的精确性与鲁棒性；另一方面，利用大型视觉语言模型的语义理解能力与多模态特征融合机制，构建多模态多行为去噪推荐框架，通过语义一致性约束实现软、硬去噪的协同优化，从视觉与文本模态中挖掘跨模态真实偏好信号，为复杂交互场景下的鲁棒推荐提供了新的思路与方法。

关键词：推荐系统；图神经网络；去噪推荐；多行为推荐

Abstract

With the increasing diversity of user interaction behaviors, recommender systems in multi-behavior scenarios face significant challenges of noise interference and preference entanglement. User actions on e-commerce or content platforms—such as clicks, favorites, add-to-cart, and purchases—can reflect potential interests, yet they often include random, accidental, or weakly related interactions that obscure true user preferences. Moreover, traditional multi-behavior recommendation methods primarily rely on collaborative signals, lacking semantic guidance from multimodal information, which limits their ability to identify noisy behaviors in complex semantic environments.

To address these issues, this thesis investigates two complementary directions: collaborative denoising and multimodal semantic-guided denoising, and proposes two novel denoising recommendation models.

First, a Noise-aware Inter- and Intra-behavior Preference Extraction model (NIPER) is proposed to address noise interference in multi-behavior recommendation. This model captures user preference relationships at both inter-behavior and intra-behavior levels, and introduces a behavior-weighted mechanism together with a self-supervised constraint to automatically identify and suppress noisy interactions in the multi-behavior graph. Furthermore, a noise-aware preference extraction module is designed to preserve high-quality auxiliary behavioral signals while filtering out weakly relevant or unreliable interactions, thus yielding more accurate user preference representations.

Second, to further extend the denoising framework to multimodal multi-behavior scenarios, a large-model semantic-guided multimodal denoising recommendation framework is proposed. This method leverages large vision-language models to extract semantic representations from both textual and visual modalities of items. Based on cross-modal semantic similarity, a hard-denoising mechanism removes inconsistent auxiliary interactions. Within the graph neural network (GNN) architecture, a semantic-aware attention mechanism is introduced to achieve soft denoising by adaptively adjusting neighbor weights, thereby emphasizing semantically consistent and informative interactions. In addition, a cross-graph contrastive learning module establishes consistency constraints between the denoised graph and the semantic-augmented graph, enabling effective transfer of semantic information into the structural representation space.

The main contributions of this thesis are as follows: (1) A collaborative denoising

method that distinguishes true preferences from noisy interactions through a dual-level (inter- and intra-behavior) preference extraction framework, enhancing the accuracy and robustness of multi-behavior recommendation; (2) A multimodal semantic-guided denoising framework that integrates large vision-language models and attention-based message passing, achieving synergistic optimization of hard and soft denoising via semantic consistency constraints. This design effectively captures cross-modal preference signals from textual and visual modalities, providing a new perspective and methodology for robust recommendation in complex multi-behavior and multimodal environments.

Keywords: recommender system, graph neural network, denoising recommendation, multi-behavior recommendation

目 录

摘 要 I
ABSTRACT II
第 1 章 绪论 1
1.1 本文背景及研究的目的和意义 1
1.2 国内外相关研究概述 2
1.2.1 基于图神经网络的推荐算法研究现状 2
1.2.2 基于图神经网络的多行为推荐研究现状 3
1.2.3 去噪推荐算法研究现状 5
1.2.4 多模态与大模型驱动的推荐研究现状 6
1.2.5 研究概述小结 8
1.3 本文的主要研究内容及章节安排 9
1.3.1 主要研究内容 9
1.3.2 论文组织结构 10
1.3.3 论文整体研究框架 11
第 2 章 图神经网络与对比学习相关理论概述 12
2.1 引言 12
2.2 图神经网络相关原理及理论知识 12
2.2.1 图神经网络的基本流程 12
2.2.2 典型图神经网络模型 13
2.3 对比学习相关原理及理论知识 16
2.4 本章小结 17
第 3 章 噪声感知与偏好提取的多行为推荐方法 18
3.1 引言 18
3.2 问题定义及方法概述 19
3.2.1 问题定义 19
3.2.2 算法实现概述 20
3.3 行为间与行为内加权去噪模块 21
3.4 偏好感知的表征增强模块 24
3.5 模型训练 26
3.6 实验与讨论 27

3.6.1 评价指标 27
3.6.2 数据集信息 27
3.6.3 实验设置 28
3.6.4 总体实验效果 28
3.6.5 消融实验 29
3.6.6 参数实验 30
3.6.7 案例研究 31
3.7 本章小结 33
第 4 章 噪声感知与偏好提取的多模态多行为推荐方法 34
4.1 引言 34
4.2 问题定义及方法概述 35
4.2.1 问题定义 35
4.2.2 方法概述 36
4.3 多模态辅助偏好建模 37
4.4 语义感知注意力的软去噪消息传递 40
4.5 模态感知图增强与对比学习 41
4.6 模型训练 42
4.7 实验与讨论 43
4.7.1 评价指标 43
4.7.2 数据集信息 43
4.7.3 实验设置 44
4.7.4 总体实验效果 44
4.7.5 消融实验 45
4.7.6 参数实验 46
4.7.7 案例研究 47
4.8 本章小结 48
结 论 50
参考文献 52
攻读硕士学位期间取得创新性成果 56
哈尔滨工业大学学位论文原创性声明和使用权限 57
致 谢 58

第 1 章 绪论

1.1 本文背景及研究的目的和意义

近年来，随着互联网的快速发展和数据规模的急剧膨胀，现实世界的信息量呈现出指数级增长的趋势。用户在享受信息便利的同时，也面临着“信息过载”的问题，即如何在海量数据中高效地筛选出符合个人兴趣和需求的内容，已成为当前研究和产业界的核心挑战之一。推荐系统（Recommender System, RS）正是在这一背景下应运而生，它通过分析用户与物品之间的历史交互关系来学习用户与物品的表示，从而为用户提供个性化的内容推荐[1–3]。推荐系统如今已成为互联网产品的重要组成部分，被广泛应用于视频播放平台（如 YouTube、抖音）、音乐平台（如 QQ 音乐、网易云音乐）以及电子商务平台（如淘宝、拼多多、京东）等，在为用户提供更好体验的同时，也为企业带来了显著的商业收益。

推荐系统的发展大致经历了从基于相似度的协同过滤（Collaborative Filtering, CF)[4]，到基于深度学习的表示学习方法[3]，再到近年来基于图神经网络（Graph Neural Network, GNN)[2] 的阶段。协同过滤通过度量用户或物品间的相似性实现推荐，而深度学习方法利用神经网络提升了特征表示能力。近年来，GNN 被广泛应用于推荐系统中，能够在用户–物品二部图上建模高阶关系，通过消息传递机制（message passing）捕捉潜在的交互模式，从而显著提升推荐性能。

然而，现有的大多数图神经网络推荐方法仅基于用户的单一目标行为（如购买）进行建模[5–7]，这种简化假设在实际应用中存在显著局限性。在真实的互联网场景中，用户往往会对同一物品产生多种行为[8,9]，例如浏览、收藏、加购、购买等，这些行为不仅反映了用户对物品的不同兴趣强度，也蕴含了更丰富的意图语义。为了解决数据稀疏问题并使推荐模型更贴近实际场景，研究者提出了多行为推荐系统（Multi-Behavior Recommendation, MBR），通过引入辅助行为来扩充目标行为的交互，从而在一定程度上提升了模型的表达能力与泛化性能。

但与此同时，引入辅助行为虽然能够丰富交互信号，但同时也带来了新的挑战。由于辅助行为的获取成本远低于目标行为，这些交互中不可避免地包含大量噪声行为，即与用户真实兴趣不一致或无效的交互信息。如果直接将这些噪声数据用于建模，可能会干扰模型学习用户的真实偏好，导致推荐结果的准确性下降。因此，如何在多行为推荐中有效识别并抑制噪声行为的影响，成为该领域亟待解决的重要问题。

针对目前多行为推荐去噪研究的不足，本文拟提出一种基于图神经网络的多

行为去噪推荐模型，通过在多行为图结构中引入噪声建模与关系加权机制，实现对多源行为的联合学习与鲁棒推荐。该研究有助于提升推荐系统在复杂行为场景下的准确性与鲁棒性，并为多行为数据的统一建模与泛化能力提升提供新的思路，对推动推荐系统在真实环境中的稳定性与应用效果具有重要意义。

1.2 国内外相关研究概述

1.2.1 基于图神经网络的推荐算法研究现状

近年来，图神经网络凭借其在处理图结构化数据方面的强大建模能力，已成为推荐系统领域的重要研究方向。推荐系统的核心任务是基于用户的历史行为预测其未来的兴趣偏好，而用户与物品之间的交互关系可以自然地建模为图结构，这使得 GNN 在该场景中展现出独特优势。

GNN 能够在用户–物品二部图上建模高阶交互关系[10]。其中，用户和物品分别作为节点，交互行为作为边，通过消息传递与聚合机制，模型能够捕获潜在的关系模式，从而学习到更具表达力的用户与物品表示。此外，GNN 还可进一步融合外部信息，例如用户的社交关系[11] 和物品的知识图谱[12]，以构建统一的表示学习框架，更全面地刻画推荐系统中的异构数据特征。

2019 年，Wang 等人提出 NGCF 模型[7]，首次将协同过滤信号引入图神经网络的消息传递过程中。模型通过多层邻居信息聚合捕获用户与物品之间的高阶关系，从而学习到更加丰富的特征表示。然而，由于引入非线性变换和多层传播，NGCF 的计算复杂度较高，并容易出现过度平滑（over-smoothing）问题。

2020 年，He 等人提出 LightGCN 模型[5]，在结构上对 NGCF 进行了简化。该模型去除了非线性激活函数和特征变换，仅保留邻居聚合与层间加权操作。通过多层传播与加权融合，LightGCN 在显著降低计算复杂度的同时，仍能保持优异的推荐性能，证明了简洁的图卷积结构在推荐任务中的有效性。

随着研究的深入，学者们开始关注如何进一步提升 GNN 模型的泛化能力与鲁棒性。2021 年，Wu 等人提出 SGL 模型[13]，引入自监督对比学习机制，通过对用户–物品图进行数据增强，生成不同视角的图表示，并最小化同一节点在不同视角下的嵌入差异，从而提升模型的泛化性能。2022 年，Liu 等人提出 SimGCL 模型[14]，在 SGL 的基础上去除了复杂的数据增强操作，通过在节点嵌入中添加噪声扰动实现对比学习，以更简洁的结构获得了与 SGL 相当甚至更优的推荐效果。这些研究表明，自监督与对比学习方法能够有效增强图神经网络在推荐任务中的稳定性与泛化能力，为后续研究提供了新的方向。

综上，基于图神经网络的推荐研究已取得显著进展，但在多行为建模方面仍存在不足。为进一步挖掘用户偏好的多层次特征，研究者开始探索基于图神经网络的多行为推荐方法，这将在下一节中详细介绍。

1.2.2 基于图神经网络的多行为推荐研究现状

传统的推荐模型通常仅利用单一类型的用户-物品交互行为进行建模，因此容易面临数据稀疏和冷启动等问题。多行为推荐通过引入多种用户-物品交互类型（例如浏览、收藏、加入购物车等），为缓解上述问题提供了有效的解决思路[15–18]。在多行为场景中，如何实现辅助行为（如浏览、收藏、加购）与目标行为（如购买）之间的有效信息融合，一直是学术界关注的研究重点。相关研究主要聚焦于探索不同行为之间的语义关联与交互机制，以提升目标行为的预测性能。图 1-1 展示了多行为推荐中典型的多种行为数据形式及其对应的推荐目标。

图 1-1: 多行为推荐的数据形式[2]

2020 年，Jin 等人[19] 为区分不同行为的强度并融合多行为的语义信息，提出 MBGCN 模型。该方法基于多种行为数据构建统一的异构图结构，在用户-物品二部图上学习各类行为的交互贡献，并在物品-物品共同交互图上建模不同行为之间的语义相关性。模型通过在统一图中实现多层消息传递，使不同类型的行为信号能够相互补充，从而提升用户表示的准确性。最终，MBGCN 通过聚合行为贡献和语义得分生成预测结果。该模型为多行为数据的图融合提供了新的思路，但在处理噪声行为和建模行为间依赖方面仍存在局限。

2021 年，Xia 等人[20] 指出，不同类型的用户-物品交互之间存在复杂的依赖关系，且用户行为模式差异显著。例如，一些用户仅在购买意图明确时才会收藏商

品，而另一些用户可能频繁收藏但很少购买。为解决该问题，作者提出 MB-GMN 模型，引入元学习框架提取跨行为知识。具体而言，MB-GMN 将不同行为视为不同的任务，通过元网络在训练过程中动态调整图神经网络的参数，以实现行为间的知识迁移。该方法不仅捕捉了多行为之间的依赖关系，还使模型在面对新的行为模式时具有更强的适应性。然而，模型的训练复杂度较高，对参数初始化和任务划分的敏感性较强。

2022 年，Gu 等人[9] 认为早期多行为推荐研究过于强调行为差异，而忽视了行为间的潜在共性。为此，作者提出 S-MBRec 模型，通过自监督学习捕捉目标行为与辅助行为之间的嵌入共性，从而缓解监督信号稀疏的问题。该模型在训练阶段构建正负样本对，通过最大化目标行为与辅助行为嵌入的一致性，提升模型对高质量信号的利用率。S-MBRec 有效减少了辅助行为冗余，提高了模型的鲁棒性，但在面对噪声较多的辅助行为时，仍缺乏显式的噪声识别机制。

2023 年，Cheng 等人[21] 观察到多行为在实际应用中通常具有顺序性（如点击 → 加购 → 购买），不同行为之间存在潜在的因果依赖。基于此，作者提出 Cascading GCN 模型，设计了级联结构以显式建模行为间的层次关系。该模型将前一行为学习到的嵌入通过特征转换操作输入到下一行为的图卷积层中，从而在嵌入传播过程中保留行为依赖信息。通过这种方式，模型能够更准确地刻画用户兴趣的动态演化过程。该方法在行为序列建模方面具有较好的解释性，但对行为顺序的依赖较强，难以适应多样化的非线性行为模式。

2024 年，Zhang 等人[22] 指出，以往多数多行为推荐方法将每种行为独立建模并分别训练，导致多行为信息融合不足。为此，提出 POGCN 模型，定义不同行为之间的偏序关系，并将行为组合建模为加权边，以构建统一的加权图结构。通过在该偏序图上进行图卷积操作，模型能够在保持行为层次差异的同时，实现全局的行为融合。POGCN 在捕捉行为语义结构方面取得良好效果，但仍未充分考虑各类行为间的信噪差异。

同年，Zhang 等人[23] 提出 DPT 模型，以预训练的方式对辅助行为中的交互进行去噪。该模型首先在多个单行为图上学习初始嵌入，通过计算交互得分来评估行为质量，并在训练阶段过滤得分较低的噪声交互。随后，模型在清洗后的交互数据上进行联合训练，从而获得更高质量的行为表示。DPT 在一定程度上缓解了噪声干扰问题，但其去噪操作独立于多行为关联结构，且未能区分不同行为的噪声比例差异，因此仍存在改进空间。

虽然多行为推荐已取得显著进展，但现有研究大多关注于如何将多种行为信息进行融合，而较少考虑辅助行为中潜在的噪声问题。在实际场景中，诸如点击、

浏览、收藏等辅助行为通常成本较低、随意性较强，往往不能准确反映用户的真实兴趣或购买意图，从而引入大量噪声。尽管 DPT 模型[23] 尝试对辅助行为进行去噪，但其仍沿用单行为推荐中的独立去噪思路，未能充分建模多种行为之间的关联差异。事实上，不同行为对用户偏好的反映程度并不相同，其噪声比例也应具有差异。因此，如何在多行为推荐中有效识别并抑制噪声行为，成为当前研究亟待解决的问题，也促使去噪推荐逐渐成为新的研究方向。

1.2.3 去噪推荐算法研究现状

推荐系统主要依赖于隐式反馈（Implicit Feedback）来学习用户偏好。隐式反馈指用户在与系统交互过程中无需明确表达意图，系统根据用户的行为（如点击、浏览、收藏等）推断其兴趣偏好。与显式反馈（如评分或评论）相比，隐式反馈更易获取且更符合用户的真实行为特征。然而，在实际场景中，隐式反馈往往包含大量噪声样本，如误点击、随机浏览或非兴趣驱动的交互，这些噪声会干扰模型对用户真实偏好的学习，导致推荐性能下降。因此，如何识别并抑制噪声反馈，成为推荐系统研究中的重要问题[24]。

2021 年，Wang 等人[25] 通过分析常规推荐模型的训练过程，发现噪声反馈通常在早期训练阶段表现出较大的损失值。据此提出 ADT 模型，在训练过程中根据每条隐式交互的损失值自适应地剔除潜在噪声交互。模型设计了两种策略：一是直接截断高损失样本，二是对高损失样本进行加权调整，从而动态降低噪声样本对整体优化的影响。该方法首次提出基于训练信号的自适应去噪思路，为后续工作提供了重要启发。

2022 年，Tian 等人[26] 指出，现有去噪方法在图神经网络推荐中往往忽略了噪声交互在邻域聚合中的传播效应。即使节点自身的噪声被部分消除，来自邻居的全局噪声仍可能干扰表示学习。此外，过度去噪还可能造成数据稀疏性加剧。为此，作者提出了图去噪模块与多样性保持模块：前者通过筛选更可靠的交互关系来优化图结构学习，后者通过联合去噪数据与多样性增强数据学习用户偏好，以平衡准确性与多样性。

2023 年，Fan 等人[6] 指出用户与物品的交互频次差异显著：交互稀疏的节点存在信息不足，而交互密集的节点则可能包含噪声。若仅依赖用户–物品矩阵而忽略用户–用户及物品–物品相关性，聚合范围也会受限。为此，提出 GraphDA 模型，通过在原始交互图上进行预训练以获得节点嵌入，再结合 Top-K 采样进行双向增强：对稀疏节点进行数据扩充，对高频节点执行去噪处理。该方法在缓解数据不平衡与噪声干扰方面均取得了良好效果。

2024 年，He 等人[27] 指出基于损失值的噪声识别方法（如 ADT）存在局限：损失与噪声之间的关联性并非总是稳定，困难样本可能与噪声样本同时被误判，从而造成信息丢失。针对这一问题，作者提出 DCF 模型，通过扩展观察区间并聚合多个训练迭代中的损失值，来稳定样本评估结果。与传统的直接丢弃噪声样本不同，DCF 将被标记的噪声样本重新标注并引入训练，使模型在保持鲁棒性的同时避免了训练样本的浪费。

2024 年，Zhang 等人提出 DeMBR 模型[28]。该模型采用双层去噪机制：硬去噪通过计算多行为下用户与物品嵌入相似度并剔除低得分交互；软去噪利用语义引导机制，以强表达行为（如购买）指导弱表达行为（如点击）消除噪声。该方法有效提升了多行为推荐性能，但依赖固定行为强度假设，缺乏自适应噪声建模能力。

综上所述，现有去噪推荐研究主要聚焦于单行为隐式反馈场景下的噪声识别与抑制，通过损失监测、自适应加权或图结构重构等手段提升模型鲁棒性。然而，在多行为推荐系统中，辅助行为（如浏览、收藏、加购）普遍存在噪声，而相关研究仍较为匮乏。当前方法往往假设所有辅助行为的噪声分布一致，忽略了不同行为在用户偏好反映上的差异性。针对这一问题，本文将从“多行为去噪”的角度出发，探索在图神经网络框架下识别并抑制辅助行为噪声的新方法，以更准确地刻画用户真实兴趣并提升多行为推荐性能。

1.2.4 多模态与大模型驱动的推荐研究现状

(1) 多模态推荐研究现状

近年来，研究者开始探索在推荐系统中融合多模态信息，以更全面地理解用户兴趣与物品语义。多模态推荐通过结合文本、图像、音频等内容特征，能够在冷启动与稀疏交互场景下显著提升模型性能。然而，现有多模态推荐方法普遍存在两个主要不足：一是多数模型仅在特征层面进行模态信息的简单融合，未能充分建模不同模态之间的交互与互补关系；二是模态特征中常存在噪声（如图像背景干扰或文本冗余描述），若未加以抑制，可能会削弱模型对用户真实偏好的刻画精度。

2021 年，Zhang 等人提出 LATTICE 模型[29]，指出多模态推荐中除用户-物品交互关系外，还存在基于模态内容的隐式物品-物品关联。该方法为每种模态（如图像、文本）构建物品-物品图，并将各模态图聚合为统一的潜在结构图，在此基础上进行图卷积传播以学习高阶语义关系。该模型有效融合了模态内容与协同信号，但未显式建模不同模态间的相关性，同时忽视了模态特征中潜在的噪声干扰。

2023 年，Zhou 等人进一步提出 FREEDOM 模型[30]，在 LATTICE 的基础上优化了多模态图的鲁棒性与效率。该模型通过冻结物品-物品图以减少训练开销，并

对用户-物品图进行剪枝与去噪，从而抑制交互噪声带来的影响。尽管 FREEDOM 在模型稳定性与性能上表现出色，但仍未考虑不同模态之间的互补关系，也未对模态内部的噪声特征进行显式建模与抑制。

2024 年，Mo 等人提出 MGNM 模型[31]，旨在解决多模态推荐中图神经网络层叠带来的特征冗余与模态噪声问题。该模型从局部与全局两个层面进行建模：在局部交互阶段，引入动态去冗余损失，通过特征矩阵与系数矩阵的乘积约束减少多层传播造成的特征冗余；在全局交互阶段，为每种模态设计模态引导特征去噪模块，以消除与用户偏好无关的模态噪声并捕获模态内部复杂关系。

总体而言，现有多模态推荐研究在提升模型表达能力和缓解数据稀疏方面取得了显著进展。然而，大多数方法仍主要关注模态内部特征的融合，而缺乏对不同模态间交互与语义互补关系的系统建模。同时，模态特征本身往往存在噪声与冗余信息，若未有效抑制，可能导致推荐结果偏离用户真实偏好。这些局限性为后续将大模型（LLMs）引入推荐系统以实现跨模态语义理解与知识增强提供了新的研究方向。

(2) 大模型结合推荐研究现状

近年来，大语言模型（Large Language Models, LLMs）在自然语言处理领域展现出强大的语义理解与推理能力，推动了推荐系统研究的新方向。LLM 在推荐系统中的应用主要集中于特征工程阶段，利用其开放世界知识与逻辑推理能力对原始数据进行后加工与数据增强，以生成语义更丰富的特征或样本，缓解数据稀疏与冷启动问题。然而，现有多模态推荐方法往往忽视模态之间的关联性与模态内部的噪声特征，导致特征融合效果受限。为此，本文引入大语言模型作为语义引导模块，通过深层语义建模与关系补全来显式建模模态间关联，并削弱模态内部噪声，从而实现跨模态信息的语义对齐与高质量特征融合，提升推荐系统的鲁棒性与语义表达能力。

2024 年，Wei 等人提出了 LLMRec 模型[32]，该方法充分利用 LLM 在知识建模与逻辑推理方面的强大能力，从自然语言视角对推荐图进行增强，以缓解推荐系统中普遍存在的数据稀疏与低质量侧信息问题。具体而言，LLMRec 设计了三种基于 LLM 的图增强策略：强化用户-物品交互边以丰富隐式反馈信号、增强物品节点的语义理解以提升内容表示能力，以及构建基于自然语言的用户画像以改进个性化建模。

2024 年，Xu 等人[33] 针对兴趣点推荐中数据稀疏的问题，引入了多模态内容信息（如文本与图像）以增强模型的语义表达能力。该方法采用统一的预训练模型，从不同模态中提取对应的语义特征，从而缓解了模态间的语义不一致问题。具

体而言，MMPOI 首先利用预训练的图文生成模型 BLIP2[?] 将图像内容转化为文本描述，再通过统一的预训练语言模型 Sentence-BERT[?] 提取各模态的语义表示，实现视觉与文本模态语义空间的对齐与融合。

2025 年，Wang 等人提出了 LLaRD 模型[34]，指出现有推荐系统去噪方法主要依赖外部知识或交互数据学习策略，但前者受限于知识可用性，后者往往依赖固定假设，难以准确识别复杂场景下的噪声。为此，LLaRD 利用大型语言模型（LLM）的知识与推理能力，引入语言先验以提升去噪效果。该模型首先通过 LLM 从观测数据中提取语义与偏好知识，然后结合链式思维 CoT 推理挖掘用户–物品关系，从而识别并过滤无关或错误交互。

总体来看，近年来大语言模型（LLMs）在推荐系统中的引入，为缓解数据稀疏、语义不一致及噪声干扰等长期难题提供了新的思路。相关研究表明，LLM 不仅能够利用其开放世界知识和推理能力丰富用户与物品的语义表示，还能在多模态融合与交互建模中发挥语义引导作用。

1.2.5 研究概述小结

在多行为推荐系统中，现有研究主要聚焦于利用多种用户交互行为（如点击、加购、收藏和购买）来缓解数据稀疏问题并提升推荐精度。然而，尽管多行为建模显著改善了用户偏好的捕获能力，现有方法在噪声识别与偏好提取方面仍存在若干不足与挑战：

(a) **辅助行为噪声问题**：辅助行为虽能提供额外的用户偏好线索，但其中包含大量与真实兴趣无关的交互，例如偶然点击或临时操作。这些噪声会在图传播过程中被放大，导致模型学习到的用户偏好偏离真实分布。目前大多方法仍将不同辅助行为视为等价信号，缺乏对行为强度差异与行为内相关性的细粒度建模。

(b) **行为间依赖关系建模不足**：多行为推荐往往将辅助行为直接与目标行为进行融合，却忽略了行为间的层次与依赖结构。例如，加购行为对购买的促进作用远强于点击行为，若未能显式区分不同行为的影响强度，容易引入跨行为噪声并造成信息混淆。

(c) **模态特征噪声与异构性问题**：随着多模态推荐的兴起，视觉、文本等模态特征被广泛用于丰富物品表示。然而，不同模态间存在显著的语义空间差异，而单一模态内部也常含有噪声或冗余信息。若缺乏有效的模态对齐与噪声抑制机制，模态融合反而可能削弱推荐的语义一致性。

(d) **语义层面真实偏好提取不足**：当前大多数方法仅依赖结构化交互数据进行建模，忽视了从语义层面理解与提炼用户真实偏好的可能性。由于交互行为背后潜藏着复杂的语义意图，单纯依赖协同信号难以全面刻画用户兴趣。

综上，现有研究在多行为推荐的去噪建模中仍存在结构层与语义层的双重瓶颈。为此，本文分别从**协同信号层面与语义层面**提出系统性改进：第一，设计基于协同信号的**跨行为与行为内加权去噪机制**，结合对比学习以区分真实偏好与辅助噪声；第二，引入**大语言模型（LLM）生成的模态语义信息**，通过模态引导的**硬去噪与软去噪策略**实现跨模态语义对齐与噪声抑制，并进一步通过模态驱动的对比学习增强语义一致性，从而实现多层次、可解释的多行为去噪推荐。

1.3 本文的主要研究内容及章节安排

1.3.1 主要研究内容

在信息过载与多样化交互行为日益增长的时代背景下，推荐系统正逐步从单一行为建模迈向多行为融合的深度语义理解阶段。多行为推荐系统通过融合点击、收藏、加购、购买等多种用户交互行为，有效缓解了数据稀疏问题。然而，辅助行为中普遍存在的噪声与行为间复杂的依赖关系，使得模型难以准确识别用户的真实偏好。此外，随着多模态内容的引入，模态内部的噪声与模态间的语义差异进一步加剧了推荐的不稳定性。针对上述挑战，本文以“基于图神经网络的多行为去噪推荐方法”为核心研究目标，从协同信号层面与语义建模层面展开系统研究，提出两种创新性框架，实现了多源信息融合下的多层次去噪推荐。

首先，针对辅助行为中存在的大量噪声问题，本文设计了**噪声感知与偏好提取的多行为推荐方法**。该方法以用户—物品多行为交互图为基础，通过行为间与行为内加权机制，分别从全局行为强度与局部相似交互两个层面识别噪声交互。跨行为加权模块利用因果推断方法估计各行为对目标行为的影响强度，从而为不同行为分配合理权重；行为内加权模块则依据相似用户的共同交互模式动态调整权重，以保留高可信度的偏好信号。在此基础上，提出了权重引导的去噪机制，通过设定噪声阈值自适应地过滤低权重交互，构建高质量多行为图。随后，引入偏好感知的对比学习策略，在跨行为与行为内两个层面通过正负样本构造强化用户嵌入一致性，从而实现了对用户真实偏好的高精度捕获与表达。

其次，考虑到多模态信息在描述用户偏好与物品语义中的重要作用，本文提出了**噪声感知与偏好提取的多模态多行为推荐方法**。该方法利用大语言模型在知识理解与语义推理方面的优势，通过生成用户与物品的模态描述文本，实现跨模态特征的语义对齐与扩展。随后，在模型层面引入两种互补的去噪机制：硬去噪阶段基于模态相似度计算删除显著偏离真实语义的交互；软去噪阶段在图神经网络的消息传播过程中引入模态引导的注意力机制，动态抑制语义噪声传播。为进

一步提升语义一致性，本文利用模态生成的嵌入构造正负样本对，开展模态对比学习，在特征层面强化用户与物品的语义匹配关系，实现了语义驱动的去噪与偏好增强。

综上所述，本文的研究工作从“协同信号层面”与“语义建模层面”双向出发，构建了一个层次化的多行为去噪推荐体系。前者通过行为强度建模与对比学习实现结构级噪声抑制，后者依托大语言模型实现模态语义层的噪声识别与语义补全。两者相辅相成，不仅显著提升了推荐系统的鲁棒性与泛化能力，也为多行为、多模态场景下的去噪推荐提供了新的理论与方法支撑。

1.3.2 论文组织结构

本论文的整体结构安排如下：

第一章为绪论。首先介绍多行为推荐系统的研究背景与现实意义，阐述推荐系统在多样化用户交互场景下所面临的核心问题，如噪声交互、数据稀疏及模态差异等。随后，对国内外在多行为推荐、去噪推荐、多模态推荐以及大语言模型辅助推荐等领域的研究现状进行系统梳理，分析现有方法的优势与不足，并明确本文的研究目标与创新点。最后，对论文的总体结构进行概述，为后续章节的展开奠定理论与逻辑基础。

第二章为相关技术概述。主要介绍支撑本文研究的基础理论与关键技术，包括图神经网络在推荐系统中的建模原理、消息传递机制及其在多行为场景下的应用。同时，对多行为推荐的基本框架与噪声建模思路进行阐述，并简要介绍大语言模型在语义理解与知识生成方面的核心机制，为后续模型设计及语义引导去噪方法提供必要的技术支撑。

第三章提出噪声感知与偏好提取的多行为推荐方法。针对辅助行为中普遍存在的噪声问题，构建了跨行为与行为内加权去噪模块，通过因果推断建模行为强度与相似交互关系，从多层次识别并过滤异常交互。同时，引入偏好感知的跨行为与行为内对比学习机制，以多视角强化用户与物品的嵌入一致性与语义表达能力，从而有效缓解噪声干扰与数据稀疏问题，提升推荐结果的准确性与稳定性。

第四章提出噪声感知与偏好提取的多模态多行为推荐方法。该方法充分利用 LLM 的语义理解与逻辑推理能力，为用户与物品生成文本化的模态描述，实现跨模态语义空间的对齐。在此基础上，通过模态相似度计算实现硬去噪，并在图神经网络中引入注意力机制以实现软去噪，从而削弱模态噪声并保留关键偏好特征。进一步地，结合模态对比学习策略，增强不同模态间的语义一致性与特征互补性，实现高质量特征融合与鲁棒推荐效果。

1.3.3 论文整体研究框架

本研究针对多行为推荐系统在多样化用户交互场景中普遍面临的噪声干扰、数据稀疏及模态差异等问题，构建了以图神经网络为核心的多层次去噪与语义增强推荐框架。研究主要聚焦以下三个核心问题：首先，针对多行为数据中存在的大量噪声交互，提出跨行为与行为内加权去噪算法，通过因果推断估计行为强度，结合用户间相似性建模生成加权交互图，以有效区分真实偏好与噪声交互，从而提升推荐的准确性与稳定性；其次，为解决辅助行为与目标行为之间的偏好差异问题，构建偏好感知的自监督对比学习机制，在行为内与行为间两个层面进行表征增强，强化用户与物品嵌入的一致性；最后，引入大语言模型生成的语义特征，通过文本化模态描述与语义对齐机制，建模多模态信息间的关系。基于模态相似性实现硬去噪，并在图神经网络中通过注意力机制完成软去噪，进一步提升模型的鲁棒性与语义表达能力。论文通过理论创新与语义融合，形成从多行为噪声识别、偏好表征增强到多模态语义引导去噪的系统性研究框架，为多行为推荐系统中的噪声建模与语义增强提供了新的范式，并在多个公开数据集上验证了其有效性与可扩展性。

在本研究中，第三章提出的**噪声感知与偏好提取的多行为推荐方法**，以及第四章提出的**噪声感知与偏好提取的多模态多行为推荐方法**，从不同层面为多行为推荐系统中的噪声抑制与偏好建模提供了解决方案。

第三章聚焦于多行为数据的结构与信号建模，通过构建跨行为与行为内加权去噪模块，结合因果推断与自监督对比学习，识别辅助行为中的噪声并提取真实偏好信号，形成纯净且高质量的交互表示。第四章则在此基础上引入大语言模型，通过语义生成与关系推理，扩展推荐系统的模态维度。该方法利用 LLM 生成的语义描述实现跨模态特征对齐，并在图神经网络中融合模态注意力机制，实现多模态层面的硬、软联合去噪，从而进一步提升推荐的语义解释性与泛化能力。

需要指出的是，第四章的研究在方法设计上继承并扩展了第三章的成果。第三章为多行为去噪奠定了结构性与因果性基础，而第四章则在此框架上通过引入语言语义与多模态信息实现更高层次的语义增强。两章在研究目标上相互独立、在技术逻辑上相互衔接，分别从行为信号与语义特征两个维度推进多行为推荐的去噪与增强研究。

从推荐流程的视角来看，第三章与第四章可视为并行互补的两条路径：前者侧重于基于交互结构的信号净化与偏好提取，后者则着眼于语义层面的知识建模与特征融合。两者共同构成完整的多行为去噪与语义引导推荐框架，为实现高精度、高鲁棒性的推荐提供了系统性解决思路与技术支撑。

第 2 章 图神经网络与对比学习相关理论概述

2.1 引言

随着互联网平台的快速发展，用户与内容之间的交互数据呈指数级增长，如何在海量信息中为用户提供个性化推荐已成为智能信息系统的重要研究方向。传统的推荐算法（如协同过滤与矩阵分解）在建模用户—物品关系方面取得了良好效果，但由于忽略了交互数据的复杂结构与高阶关联，其表达能力和泛化性能仍存在不足。近年来，图神经网络凭借其在非欧几里得结构化数据上的建模优势[2]，被广泛引入推荐系统中，用于捕获用户与物品之间的高阶连接与潜在语义关系，从而显著提升了推荐的准确性与表示能力。

然而，仅依靠监督信号进行训练的推荐模型在实际应用中仍面临诸多挑战。首先，用户行为数据往往存在噪声、稀疏和偏置等问题[35,36]，导致模型学习到的用户表示与真实偏好存在偏差。其次，推荐系统中的多行为交互和多模态内容信息进一步增加了建模难度，使得模型难以充分利用潜在的结构信号与语义信息。为此，对比学习（Contrastive Learning, CL）被引入推荐系统，作为一种自监督学习范式，通过构造正负样本对在无标签条件下优化表示分布，从而提升模型在噪声环境下的鲁棒性与泛化能力。

综上所述，图神经网络与对比学习的结合为推荐系统的研究提供了新的发展方向：前者关注用户—物品关系的结构化建模，后者强调表示空间的一致性约束与自监督优化。二者相辅相成，不仅能够增强推荐模型的表示能力，还能有效缓解数据噪声与稀疏问题。本章将系统梳理与本研究密切相关的理论基础，包括图神经网络的核心原理及其在推荐系统中的典型应用，以及对比学习的基本思想与在推荐场景下的改进策略，为后续章节的模型设计与算法实现奠定理论支撑。

2.2 图神经网络相关原理及理论知识

2.2.1 图神经网络的基本流程

图神经网络是一类能够在图结构数据上直接进行学习的深度模型。其核心思想是通过消息传递（Message Passing）机制，使节点在嵌入空间中综合自身特征与邻居节点的信息，从而生成具有结构感知与关系表达能力的节点表示。

在一个典型的 GNN 层中，节点特征的更新通常包含两个阶段：

1. **消息传递**：每个节点从其邻居节点接收并聚合信息。对于节点 v，其邻居集合记为 $\mathcal{N}(v)$。在第 l 层中，消息传递过程可表示为：

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v)} M^{(l)} \left(\mathbf{h}_v^{(l-1)}, \mathbf{h}_u^{(l-1)}, \mathbf{e}_{uv} \right), \tag{2-1}$$

其中，$M^{(l)}(\cdot)$ 为消息函数，用于根据节点与边特征计算邻居信息的加权表示，并完成消息的聚合。

2. **节点更新**：节点结合自身上一层的表示与聚合后的消息向量，更新当前层的表示：

$$\mathbf{h}_v^{(l)} = U^{(l)} \left(\mathbf{h}_v^{(l-1)}, \mathbf{m}_v^{(l)} \right), \tag{2-2}$$

其中，$U^{(l)}(\cdot)$ 为更新函数，可采用非线性变换（如 MLP、GRU 或残差结构）以捕获复杂的邻域依赖关系。

通过堆叠多层消息传递与更新操作，GNN 能够逐步捕获高阶邻居的结构信息，实现节点间的深层语义关联建模。在此框架下，众多具有代表性的模型相继被提出，其中部分方法已被广泛应用于推荐系统场景。接下来，本文将介绍几种在推荐算法领域中具有代表性的图神经网络模型及其核心思想。

2.2.2 典型图神经网络模型

（1）图卷积网络

图卷积网络（Graph Convolutional Network, GCN）[37] 是最早提出的基于谱域卷积思想的图神经网络之一，其核心目标是将传统卷积神经网络（CNN）的局部特征提取能力扩展至非欧式的图结构数据中。GCN 的关键思想在于：每个节点不仅依赖自身特征进行表征学习，还通过邻接关系接收邻居节点的信息，实现跨节点的特征传播与全局平滑。其计算过程可归纳为典型的两步形式：**消息传递**与 **节点更新**。

- **消息传递**：节点通过邻接矩阵实现特征的聚合与传播。对于节点 v，其邻居集合为 $\mathcal{N}(v)$，消息传递过程可形式化为：

$$\mathbf{m}_v^{(l)} = \sum_{u \in \mathcal{N}(v) \cup \{v\}} \frac{1}{\sqrt{d_u d_v}} \mathbf{W}^{(l)} \mathbf{h}_u^{(l-1)}, \tag{2-3}$$

其中，$\mathbf{W}^{(l)}$ 为第 l 层的可学习线性变换参数，d_u 与 d_v 分别为节点 u 与 v 的度。该式中的对称归一化因子 $\frac{1}{\sqrt{d_u d_v}}$ 可有效抑制高连接度节点在聚合过程中的主导效应，从而实现稳定的信息传播。

• **节点更新**：节点将聚合后的邻域信息 $\mathbf{m}_v^{(l)}$ 经过非线性变换，更新为新的特征表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\mathbf{m}_v^{(l)}\right), \tag{2-4}$$

其中 $\sigma(\cdot)$ 表示非线性激活函数（如 ReLU）。通过多层堆叠，GCN 能够递归地传播信息，使每个节点在高层表征中融入高阶邻居的结构语义特征。

在矩阵形式下，GCN 的整体更新规则可写为：

$$\mathbf{H}^{(l+1)} = \sigma\left(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}}\mathbf{H}^{(l)}\mathbf{W}^{(l)}\right), \tag{2-5}$$

其中，$\widetilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ 表示加入自连接的邻接矩阵，$\widetilde{\mathbf{D}}$ 为其对应的度矩阵。该更新过程等价于在图拉普拉斯谱域上进行卷积操作，因此 GCN 可视为对图信号进行低通滤波的平滑算子。GCN 以其参数高效、结构简洁的特点成为后续多种图神经网络（如 GraphSAGE、GAT、LightGCN 等）的理论基础。

（2）图采样聚合网络

GraphSAGE（Graph Sample and Aggregate）[38] 是一种支持大规模图上归纳式学习的图神经网络模型。与 GCN 依赖全图邻接矩阵计算不同，GraphSAGE 通过采样机制与可学习聚合函数实现了高效的局部邻域特征传播，能够在动态变化或未见过的新节点上进行推理。其核心流程可概括为两步：消息传递与节点更新。

• **消息传递**：对于每个节点 v，GraphSAGE 首先从其邻居集合 $\mathcal{N}(v)$ 中随机采样固定数量的邻居，以控制计算复杂度。然后，通过可学习的聚合函数（如均值聚合、LSTM 聚合或池化聚合）将邻居节点的特征表示汇总：

$$\mathbf{m}_v^{(l)} = \mathrm{AGGREGATE}\left(\{\mathbf{h}_u^{(l-1)} \mid u \in \mathrm{Sample}(\mathcal{N}(v))\}\right), \tag{2-6}$$

其中，Sample$(\cdot)$ 表示随机采样操作。该聚合机制使得模型能够在保持表达能力的同时显著降低计算与存储开销，从而适应大规模工业级图数据。

• **节点更新**：节点将自身特征与聚合后的邻居信息进行拼接，通过线性变换与非线性激活生成新的节点表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\mathbf{W}^{(l)} \cdot \mathrm{CONCAT}\left(\mathbf{h}_v^{(l-1)}, \mathbf{m}_v^{(l)}\right)\right), \tag{2-7}$$

其中，$\mathbf{W}^{(l)}$ 为可学习参数矩阵，$\sigma(\cdot)$ 为激活函数。这种更新方式既保留了节点自身的语义信息，又融合了邻域特征，使得 GraphSAGE 在异质节点和稀疏场景中具备更强的泛化能力。

通过分层采样与聚合，GraphSAGE 支持在训练阶段仅访问部分图结构，并在推理阶段对新增节点进行嵌入生成（inductive inference），因而广泛应用于推荐系统、社交网络与知识图谱等大规模动态图场景。

（3）图注意力网络

图注意力网络（Graph Attention Network, GAT）[39] 在消息传递框架中引入了注意力机制，以自适应地分配邻居节点的重要性权重，从而克服了传统 GCN 中均匀聚合的局限性。GAT 不再依赖预定义的归一化矩阵，而是通过可学习的注意力参数在局部邻域内动态调整信息流强度。其核心流程同样可分为两步：**消息传递**与**节点更新**。

- **消息传递**：对于每个节点 v，首先通过线性变换矩阵 $\mathbf{W}$ 将节点特征映射到新的表示空间：

$$\mathbf{h}'_v = \mathbf{W}\mathbf{h}_v. \tag{2-8}$$

然后，通过注意力机制计算节点 v 与邻居节点 $u \in \mathcal{N}(v)$ 之间的关联强度：

$$e_{uv} = \mathrm{LeakyReLU}\left(\mathbf{a}^\top [\mathbf{h}'_u \| \mathbf{h}'_v]\right), \tag{2-9}$$

并使用 softmax 函数对所有邻居的注意力得分进行归一化：

$$\alpha_{uv} = \frac{\exp(e_{uv})}{\sum_{k \in \mathcal{N}(v)} \exp(e_{kv})}, \tag{2-10}$$

其中，$\mathbf{a}$ 为可学习的注意力向量，$\|$ 表示向量拼接操作。该机制允许节点对语义上更相关的邻居分配更高权重，从而提升消息传播的针对性。

- **节点更新**：节点基于注意力权重对邻居特征进行加权聚合，形成更新后的表示：

$$\mathbf{h}_v^{(l)} = \sigma\left(\sum_{u \in \mathcal{N}(v)} \alpha_{uv} \mathbf{h}'_u\right), \tag{2-11}$$

其中，$\sigma(\cdot)$ 表示非线性激活函数。为了增强模型的表达能力，GAT 通常采用多头注意力机制（Multi-Head Attention），即并行计算多个注意力通道并对其结果进行拼接或平均，从而捕获不同语义视角下的邻域特征相关性。

通过注意力机制的引入，GAT 实现了节点间关系的自适应建模，不再依赖图结构的固定拓扑权重，在异质图、社交网络及多模态推荐任务中展现出优越的特征选择与语义过滤能力。

（4）LightGCN 模型

LightGCN（Light Graph Convolution Network）[5] 是一种专为推荐系统设计的轻量级图神经网络模型，其核心思想是对传统 GCN 结构进行简化，仅保留最关键的

邻居特征聚合过程，去除了非线性激活与特征变换等操作，从而在保持模型表达能力的同时显著提升训练与推理效率。其整体流程可分为两个阶段：消息传递与节点更新。

• **消息传递**：LightGCN 不再引入额外的线性变换矩阵或激活函数，而是直接基于对称归一化的邻接矩阵传播节点特征。对于第 l 层传播，节点特征的更新公式为：

$$\mathbf{E}^{(l+1)} = \mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}}\mathbf{E}^{(l)}, \tag{2-12}$$

其中，$\mathbf{A}$ 为用户-物品二部图的邻接矩阵，$\mathbf{D}$ 为其度矩阵。该归一化传播机制确保了不同度节点之间的平衡，使得每个节点能够稳定地吸收邻居的嵌入信息，从而实现高效的信息扩散与结构平滑。

• **节点更新**：为充分利用多层传播过程中不同阶邻居所包含的协同信息，LightGCN 将所有层的节点表示进行加权融合，形成最终的节点嵌入：

$$\mathbf{e}_u = \sum_{l=0}^{L} \alpha_l \mathbf{e}_u^{(l)}, \quad \mathbf{e}_i = \sum_{l=0}^{L} \alpha_l \mathbf{e}_i^{(l)}, \tag{2-13}$$

其中，α_l 为第 l 层的权重系数，通常设为均值或按经验衰减分配。这种跨层融合方式有效整合了不同阶邻居的结构特征，使模型在保持轻量化的同时依然具备捕获高阶协同信号的能力。

通过去除非必要的非线性变换与参数矩阵，LightGCN 显著减少了计算与存储开销，同时在多行为推荐、社交推荐等任务中仍能保持强大的表示能力，因此成为近年来推荐系统研究中的核心基线模型。

2.3 对比学习相关原理及理论知识

对比学习（Contrastive Learning）是一种基于相似性约束的自监督表示学习方法，其核心思想是通过构建正负样本对（Positive/Negative Pairs）来学习高质量的特征表示，使语义相似的样本在嵌入空间中靠近，而语义无关的样本彼此远离。相比传统的监督学习依赖人工标签的方式，对比学习能够从无标注数据中挖掘潜在结构信息，显著提升模型的泛化能力和鲁棒性。

早期的对比学习思想可追溯至互信息最大化（Mutual Information Maximization）方法，其目标在于通过最大化不同视图之间的互信息来捕获共享语义特征。此类方法包括 Deep InfoMax[40] 和 CPC（Contrastive Predictive Coding）[41] 等。随着大规模无监督表示学习的发展，SimCLR[42]、MoCo[43] 和 BYOL[44] 等方法进一步推动了对比学习在计算机视觉和推荐系统中的广泛应用。

对比学习的一般流程可分为三个阶段：样本构建、相似度度量与目标优化。

1. **样本构建**：模型首先需要从原始样本中生成具有语义关联的多视图表示。对于给定样本 x，通过两种不同的数据增强或视角变换（如裁剪、遮挡、掩码或行为扰动）生成两个相关视图 (x_i, x_j)，称为正样本对。来自其他样本的数据 (x_i, x_k) 被视为负样本对。这种设计使得模型在无监督条件下能够自动学习到“语义一致性”，即同一实体的不同观测在嵌入空间中应保持接近。

2. **相似度度量**：为量化样本对在表示空间中的关系，常用的相似度度量为余弦相似度：

$$\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i^\top \mathbf{z}_j}{\|\mathbf{z}_i\| \, \|\mathbf{z}_j\|}, \tag{2-14}$$

其中，$\mathbf{z}_i$ 与 $\mathbf{z}_j$ 分别表示样本经过编码器 $f_\theta(\cdot)$ 后的特征表示。余弦相似度通过角度关系刻画样本间的相对语义距离，保证了尺度不变性和数值稳定性。

3. **目标优化**：对比学习的核心目标是最大化正样本对的相似度并最小化负样本对的相似度。最常用的优化目标是 InfoNCE 损失函数[41]：

$$\mathcal{L}_{\mathrm{InfoNCE}} = -\log \frac{\exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{N} \exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}, \tag{2-15}$$

其中，τ 为温度系数，用于调整相似度分布的平滑程度，N 表示候选样本数量。该损失通过软最大化机制强化正样本对的区分性，并在嵌入空间中形成自然的簇结构（Cluster Structure）。

从信息论角度来看，InfoNCE 可被视为互信息的下界估计，其优化过程等价于最大化样本视图间共享信息的期望。这种思想被称为互信息最大化原理（Mutual Information Maximization Principle），能够有效减少特征冗余并提升表达能力。此外，Wang 与 Isola[45] 提出了对比学习的两个关键理论目标：（1）**对齐性（Alignment）**——正样本对在嵌入空间中的距离应尽可能接近；（2）**均匀性（Uniformity）**——所有样本在单位超球面上应均匀分布，以避免塌陷（Collapse）问题。对比学习的目标可视为在这两种约束之间取得平衡，从而在保持判别性的同时维持表示多样性。

2.4 本章小结

本章主要介绍了图神经网络与对比学习的相关理论基础。在图神经网络部分，首先阐述了 GNN 的一般工作流程，包括消息构造与聚合机制，并重点介绍了若干具有代表性的模型（如 GCN、GraphSAGE、GAT 与 LightGCN），以说明不同结构在特征传播与表示学习上的差异与优势。在对比学习部分，本章系统总结了其核心思想、基本流程与典型优化目标（如 InfoNCE 损失），并分析了其在特征对齐与表示均匀性方面的理论依据。

第 3 章 噪声感知与偏好提取的多行为推荐方法

3.1 引言

随着互联网平台中用户行为的多样化，**多行为推荐系统**逐渐成为解决推荐系统中**数据稀疏**和**冷启动**问题的有效工具。传统的推荐算法通常依赖单一类型的用户行为（如购买行为）来推测用户的偏好，这种方法在面对数据稀疏或冷启动时会遇到显著挑战。为了解决这些问题，多行为推荐系统通过引入辅助行为（例如点击、浏览、收藏等）来增强对用户兴趣的理解，从而提高推荐精度。然而，在实际应用中，辅助行为往往含有大量噪声信息，例如误点击、无意浏览或无效收藏等，这些噪声交互可能严重干扰对用户真实偏好的识别。

尽管近年来针对多行为推荐的研究不断深入，已有的一些工作主要集中在**行为信息融合**和**行为关系建模**上，但大多数方法忽视了辅助行为中的噪声问题。现有的多行为推荐算法通常假设所有辅助行为均为有效信息，未能有效区分低质量的噪声行为与真实的用户兴趣。此外，传统的去噪方法多集中在单一行为场景中，忽略了多行为场景下**行为间的关联性**，以及如何利用高质量辅助行为增强目标行为的表达能力。

针对上述挑战，本文提出了一种新颖的框架——**噪声感知与偏好提取的多行为推荐方法（Noise Identification and Preference Extraction in Multi-Behavior Recommender System, NIPER）**。该框架由两个主要模块组成，旨在有效识别并去除辅助行为中的噪声，同时增强辅助行为与目标行为之间的互补信息，提升推荐精度和系统的鲁棒性。

首先，**跨行为与行为内加权去噪模块**旨在识别不同用户行为对偏好的影响差异，为每种行为分配不同的权重。在此基础上，本文采用跨行为与行为内信息融合的策略，区分噪声交互与有效交互。通过去除低权重的噪声交互，显著提升了对用户真实偏好的学习效果。

其次，**基于偏好信息的表征增强模块**采用自监督学习策略增强辅助行为与目标行为之间的信息传递。通过生成正负样本对促进目标行为的学习，并匹配用户和物品的相似交互嵌入，进一步增强了行为间的一致性与准确性。该方法不仅缓解了目标行为数据稀疏问题，还揭示了用户在不同交互场景下的潜在兴趣偏好。

本文的主要贡献如下：

1. 本文提出了一个能够有效识别多行为推荐系统中噪声并提取真实偏好的框架，为多行为推荐的去噪研究提供了新的视角。

2. 本文提出了一种新的跨行为与行为内加权去噪模块，通过引入加权机制，有效识别并去除辅助行为中的噪声，提升了模型对真实用户偏好的学习能力。

3. 本文设计了一种创新的自监督学习方法，利用辅助行为数据中的真实偏好补充目标行为，从而缓解目标行为数据稀疏问题，并揭示用户与物品之间的相似交互模式。

综上所述，本研究不仅提升了多行为推荐系统的准确性和鲁棒性，也为推荐系统中的去噪问题提供了新的思路。实验结果表明，NIPER 在多个公开数据集上显著优于现有的多行为推荐方法，展现出优越的性能与泛化能力。

3.2 问题定义及方法概述

3.2.1 问题定义

在本研究中，定义用户集合为 $U = \{u_1, u_2, ..., u_{|U|}\}$，物品集合为 $I = \{i_1, i_2, ..., i_{|I|}\}$，其中 $|U|$ 和 $|I|$ 分别表示用户和物品的数量。符号 B 表示行为类型的集合。

在数据集中，将购买行为设定为**目标行为**，而其他行为（如浏览、加购、收藏等）设定为**辅助行为**，并用 K 表示行为类别的总数。

构建的用户-物品交互图记为 $G^R = (V, E^R)$，其中 $V = U \cup I$ 表示图中所有用户与物品节点的集合，边集 E^R 表示观测到的交互关系。在包含 K 种行为的多行为场景下，整体交互图 G^R 可划分为 K 个行为子图：$G_1^R, G_2^R, ..., G_K^R$。

给定用户与物品之间的交互矩阵集合 R，其中 $R_k \in \mathbb{R}^{|U|\times|I|}$ 表示第 k 种行为下的交互矩阵。若 $R_{ui}^k = 1$，则表示用户 u 在行为 k 下与物品 i 发生过交互，此时在行为图 G_k^R 中存在一条连接用户 u 与物品 i 的边；若 $R_{ui}^k = 0$，则表示用户 u 在该行为下未与物品 i 交互。

为了进一步挖掘用户与物品之间潜在的相似偏好信息，构建了**用户同构图** G^U 和**物品同构图** G^I，以捕捉用户-用户及物品-物品之间的共享交互关系。在构建过程中，遍历各行为下的用户-物品交互记录；若一对用户 (u, v) 或一对物品 (i, j) 在目标行为（购买行为）下存在共同交互，则在图 G^U 中连接 u 与 v，并在图 G^I 中连接 i 与 j。

多行为推荐任务的形式化定义如下：

- **输入**：用户在 K 种行为下的交互图集合 $\{G_1^R, G_2^R, ..., G_K^R\}$；
- **输出**：一个推荐模型，用于预测用户 u 在第 K 种行为（即目标行为）下与物品 i 发生交互的概率。

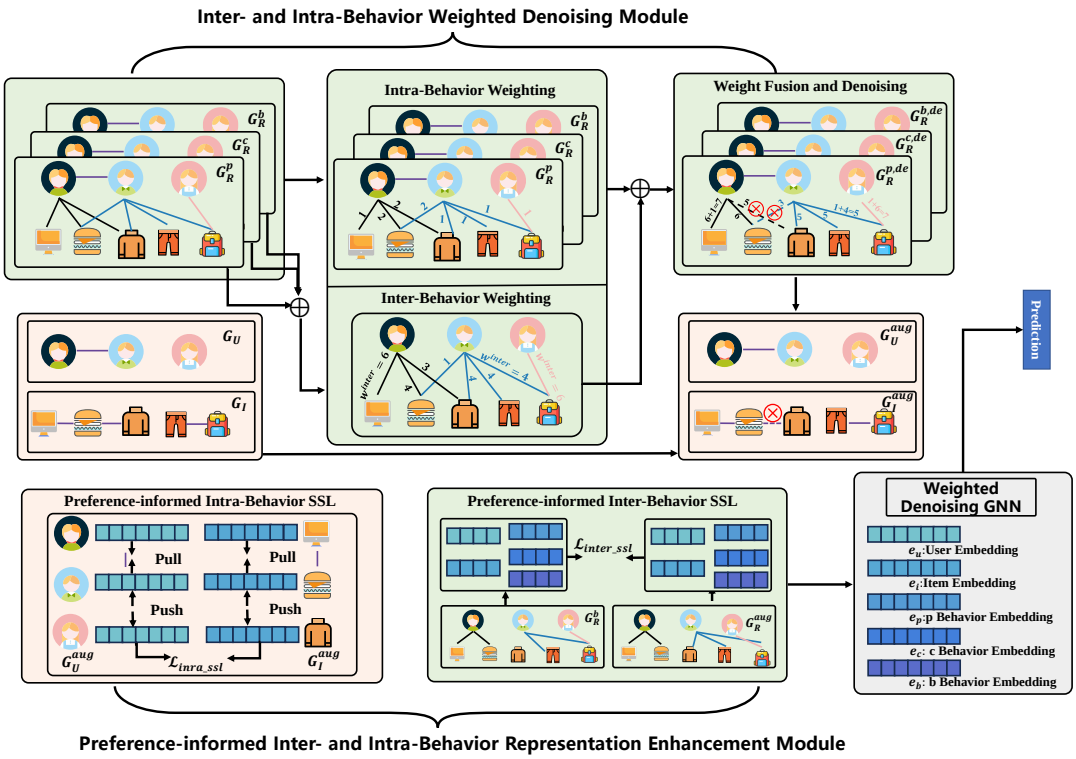

图 3-1: NIPER 整体框架示意图

3.2.2 算法实现概述

为有效解决多行为推荐算法中的噪声干扰问题，本文提出了**噪声感知与偏好提取的多行为推荐方法**（NIPER: Noise Identification and Preference Extraction in Multi-Behavior Recommender System）。图 3-1 展示了 NIPER 的整体结构，该模型主要由两个关键模块组成：**(i) 行为间与行为内加权去噪模块（Inter- and Intra-Behavior Weighted Denoising Module）**与 **(ii) 偏好感知的表征增强模块（Preference-informed Representation Enhancement Module）**。

1. **行为间与行为内加权去噪模块**旨在识别并减轻辅助行为中的噪声交互，通过跨行为与行为内加权机制提升多行为信号的可靠性。该模块包含三个子模块：**基于行为强度的行为间加权模块**、**基于共同交互的行为内加权模块**以及**去噪模块**。其中，基于行为强度的行为间加权模块用于刻画不同行为类型在用户偏好表达中的固有强度差异。例如，在电商场景中，购买行为通常较加购行为更能体现真实兴趣，而加购行为的偏好强度又高于单纯的浏览行为。基于共同交互的行为内加权模块则用于建模具有相似兴趣的用户之间的交互影响。若多个用户在某些物品上表现出一致的交互行为，则这些行为更可能反映其真实偏好，从而获得更高的权重。通过上述两类加权机制的协同作用，可构建出带有权重的多行为交互图。随

后，去噪模块根据权重分布剔除低置信度的辅助行为交互，从而生成经过降噪处理且保留关键信息的高质量多行为图，有效减弱噪声对推荐结果的负面影响。

2. **偏好感知的表征增强模块**旨在从辅助行为中提取高置信度的真实偏好，以缓解目标行为数据的稀疏性。该模块包括两部分：**偏好感知的行为间对比学习**与**偏好感知的行为内对比学习**。前者利用在去噪阶段保留的高权重辅助交互，对目标行为交互图进行增强与补充。通过对比增强前后目标行为的嵌入表示，挖掘用户在多行为数据中的潜在偏好，从而提升整体推荐性能。后者依据用户与用户、物品与物品之间的相似交互偏好，对其嵌入进行区分与优化，强化具有相似兴趣实体间的表示一致性，进一步提升模型的表达能力与泛化性。

3.3 行为间与行为内加权去噪模块

在多行为推荐系统中，传统方法通常将用户行为划分为辅助行为与目标行为[8,9,19,20,23,35]。然而，这种二元划分忽略了不同辅助行为在表达用户兴趣偏好方面的重要性差异。例如，*加入购物车*行为相较于*浏览页面*更能反映用户的潜在购买意图。若不加区分地处理所有辅助行为，可能导致关键行为信号被削弱，从而降低推荐精度。

为定量刻画不同行为类型在购买转化中的作用，本文将点击与加购行为的影响建模为一个**因果推断问题**[?]，并采用**潜在结果框架**（Potential Outcomes Framework）[? ?] 进行建模。对于每个用户 i，设 $T \in \{1, 2\}$ 表示行为类型，其中 $T = 1$ 表示点击行为，$T = 2$ 表示加购行为；$Y \in \{0, 1\}$ 表示用户是否完成购买；X 表示用户的行为特征，包括点击次数、加购次数及总交互次数。

个体化处理效应（Individual Treatment Effect, ITE）定义为：

$$\tau_i = \mathbb{E}[Y_i(2) - Y_i(1) \mid X_i], \tag{3-1}$$

其中 $Y_i(t)$ 表示用户 i 在行为类型 $T = t$ 下的潜在购买结果。由于实际数据中每个样本仅能观测到一个处理结果，因此需通过因果推断方法进行估计。

本文采用**因果森林模型（Causal Forest）**对 τ_i 进行估计。该模型是一种基于随机森林的非参数方法，能够在高维协变量空间中捕捉异质性处理效应。训练完成后，模型根据用户特征 X_i 计算估计的处理效应：

$$\tau_i = \hat{\mathbb{E}}[Y_i \mid T = 2, X_i] - \hat{\mathbb{E}}[Y_i \mid T = 1, X_i]. \tag{3-2}$$

若 $\tau_i > 0$，说明对用户 i 而言，加购行为相较点击行为更能促进购买转化；反之则表示点击行为更具影响力。该效应可用于刻画不同行为的相对重要性。

为进一步量化各行为的强度，本文依据用户级处理效应 τ_i 构建行为权重。将其映射为点击与加购行为的响应权重如下：

$$w_{\text{cart},i} = \frac{\exp(\tau_i)}{\exp(\tau_i) + 1}, \quad w_{\text{click},i} = 1 - w_{\text{cart},i}. \tag{3-3}$$

上述形式保证了权重的平滑性与归一性，能够有效反映用户在两种行为间的相对偏好强度。

基于用户级权重，定义加购行为的全局强度指标为：

$$\rho^{\text{cart}} = \frac{1}{N}\sum_{i=1}^{N} w_{\text{cart},i}, \tag{3-4}$$

相应地，点击行为的全局强度可表示为 $\rho^{\text{click}} = 1 - \rho^{\text{cart}}$。上述强度值用于衡量不同行为在全局范围内对购买转化的平均促进作用。作为最终目标行为，购买行为直接反映用户的真实转化，因此其强度设为常数：

$$\rho^{\text{buy}} = 1. \tag{3-5}$$

基于计算得到的各行为强度值，本文构建了全局加权的跨行为交互图 $\boldsymbol{G_{inter}}$，其邻接矩阵 $\boldsymbol{w^{inter}} \in \mathbb{R}^{|U|\times|I|}$ 定义为：

$$w_{ui}^{inter} = \sum_{k=1}^{K} \rho^k \cdot R_{ui}^k. \tag{3-6}$$

该公式将多种行为的贡献进行加权融合，从而更全面地刻画用户的真实偏好与意图。如图 3-2 所示，若用户 u_1 在浏览、加购与购买三种行为中均与物品 i_1 发生交互，则其全局权重为：

$$w_{u_1 i_1}^{inter} = w^{pv} \times 1 + w^{cart} \times 1 + w^{buy} \times 1 = 6. \tag{3-7}$$

若用户 u_1 仅在浏览与购买行为中与物品 i_2 交互，则权重计算为：

$$w_{u_1 i_2}^{inter} = w^{pv} \times 1 + w^{cart} \times 0 + w^{buy} \times 1 = 4. \tag{3-8}$$

通过上述建模过程，跨行为加权机制能够有效捕捉不同行为类型对用户偏好的贡献，为后续去噪与特征学习奠定基础。

基于共现交互的行为内加权：除了考虑不同行为类型在偏好表达中的强度差异外，用户在同一行为下的交互偏好同样蕴含着重要信息。这些偏好能够反映交互行为的相对重要性，并在相似用户之间体现出一定的一致性。基于此，本文引入**共现交互机制**，以量化具有相似兴趣的用户在同一行为下的共同交互强度。

具体而言，若相似用户在相同行为下频繁与同一物品交互，则该交互更可能

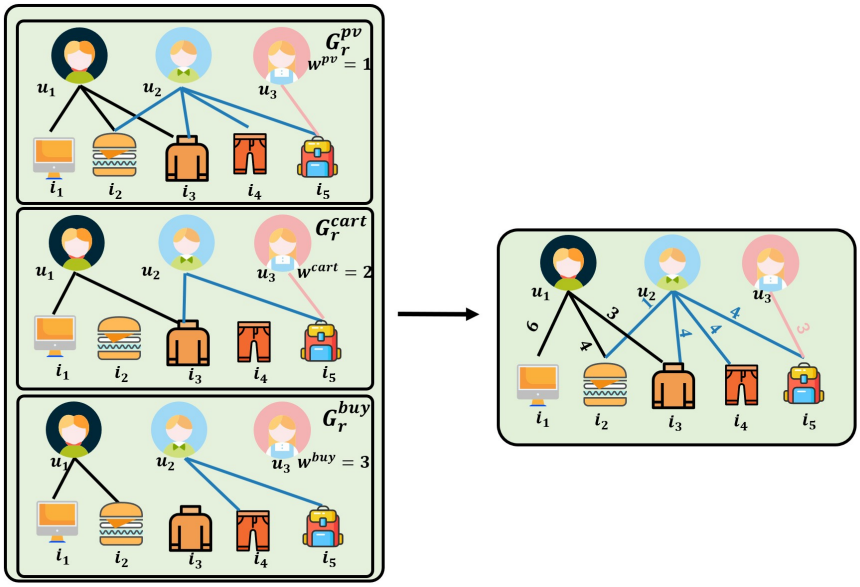

图 3-2: 一个生成带有权重的行为间全局交互图的例子

代表真实偏好。为刻画这一关系，结合用户相似性交互图 $\boldsymbol{G_U}$ 与用户–物品交互图 $\boldsymbol{G_R}$，定义用户 u 在行为 k 下与物品 i 的行为内权重如下：

$$w_{ui}^{\text{intra},k} = \left(1 + \sum_{v \in V_u} R_{vi}^k\right) \cdot R_{ui}^k, \tag{3-9}$$

其中，V_u 表示与用户 u 相似的用户集合。该定义综合了用户相似性与共同交互频率，从而能够更全面地量化行为内交互的重要性。

为统一不同层次的权重信息，本文提出一种**行为内与行为间权重融合框架**。其中，行为内权重用于刻画单一行为下用户–物品交互的重要性，而跨行为权重用于建模不同行为类型间的关联性。两者的融合能够在全局层面上平衡行为差异与局部特征，从而更准确地反映用户的真实偏好。

在融合过程中，为避免权重尺度差异导致偏移，首先采用最小–最大归一化对行为内权重进行标准化。最终得到的融合权重矩阵 $\boldsymbol{w}^{\boldsymbol{com},\boldsymbol{k}} \in \mathbb{R}^{|\mathcal{U}|\times|\mathcal{I}|}$ 定义如下：

$$w_{ui}^{\text{com},k} = \alpha w_{ui}^{\text{intra},k} + (1-\alpha) w_{ui}^{\text{inter}}, \tag{3-10}$$

其中，k 表示行为类型，α 为平衡系数，用于控制行为内权重与跨行为权重的贡献比例。

权重引导的去噪模块：该模块旨在进一步去除辅助行为中噪声交互的影响。具体而言，仅对辅助行为中权重较低的交互进行过滤，而目标行为保持不变。设每个辅助行为的融合权重为 $w_{ui}^{\text{com},k}$，并根据超参数 β_{low} 及行为强度 ρ^k 自适应确定去噪阈值，则去噪后的交互矩阵定义为：

$$R_{ui}^{\mathrm{de},k} = w_{ui}^{\mathrm{com},k} \cdot \mathbb{I}\left(\frac{w_{ui}^{\mathrm{com},k}}{\max(\mathbf{w}^{\mathrm{com},\mathbf{k}})} < \frac{\beta_{\mathrm{low}}}{\rho^k}\right), \tag{3-11}$$

其中，$\mathbb{I}(\cdot)$ 表示指示函数。该机制确保仅去除低权重的辅助行为交互，而目标行为矩阵 $\boldsymbol{R}^{\mathrm{de},\boldsymbol{K}}$ 保持不变，直接令 $\boldsymbol{R}^{\mathrm{de},\boldsymbol{K}} = \boldsymbol{w}^{\mathrm{com},\boldsymbol{K}}$。最终，对于每个辅助行为 k，去噪后的矩阵 $\boldsymbol{R}^{\mathrm{de},\boldsymbol{k}}$ 保留了高置信度的交互信息，并作为相应去噪多行为图的邻接矩阵。该过程使得用户-物品交互关系能够被更准确、鲁棒地建模。

在得到多行为去噪加权交互矩阵 $\boldsymbol{R}^{\boldsymbol{de},\boldsymbol{k}}$ 后，采用带有消息传递机制的图神经网络（GNN）对用户和物品进行表示学习。具体而言，本文以 GHCF（Graph-based Hybrid Collaborative Filtering）[8] 作为主干网络。GHCF 是一种针对多行为推荐任务设计的图神经网络结构，能够联合嵌入图中节点（用户与物品）及多种行为关系的表示，并显式捕获跨行为的高阶协同信号。

与原始 GHCF 在节点表示学习中对同一行为下的邻居进行等权聚合不同，本文在消息传播过程中引入了基于去噪权重的加权机制，使模型能够根据交互置信度动态调整邻居节点的重要性。其消息传播公式定义如下：

$$\mathbf{e}_{u,k}^{(l+1)} = \mathrm{LeakyReLU}\left(\mathbf{W}^{(l)} \cdot \mathrm{mean}\left\{\mathbf{e}_{i,k}^{(l)} \odot \mathbf{e}_k^{(l)} : i \in N_{u,k}\right\}\right), \tag{3-12}$$

其中，$\mathbf{e}_{u,k}^{(l+1)}$ 表示在第 $(l+1)$ 层传播后，用户 u 在行为类型 k 下的嵌入表示；$N_{u,k}$ 为用户 u 在行为 k 下的邻居物品集合；$\mathbf{W}^{(l)}$ 为第 l 层的特征变换矩阵；$\odot$ 表示逐元素乘积操作；$\mathbf{e}_k^{(l)}$ 为第 l 层行为类型 k 的全局嵌入向量，用于调节不同行为语义间的表示差异。

行为类型嵌入 $\mathbf{e}_k^{(l)}$ 在各层间通过以下线性变换进行更新：

$$\mathbf{e}_k^{(l+1)} = \mathbf{W}_b^{(l)} \mathbf{e}_k^{(l)}, \tag{3-13}$$

其中，$\mathbf{W}_b^{(l)}$ 为层特定的行为类型转换矩阵，用于捕获多行为之间的语义迁移关系。

经过多层消息传播后，模型最终得到用户嵌入 $\mathbf{E_u}$、物品嵌入 $\mathbf{E_i}$ 以及行为类型嵌入 $\mathbf{E_k}$（其中 $k \in \mathcal{B}$），为后续的偏好建模与预测提供高质量的表示基础。

3.4 偏好感知的表征增强模块

偏好感知的行为间对比学习：为缓解目标行为中的数据稀疏问题，本文利用辅助行为中高权重的交互信息对目标行为进行增强，从而构建更具代表性的交互视图。该方法通过将辅助行为中反映用户真实偏好的交互迁移至目标行为的表示空间，有效提升了目标行为的表达能力与鲁棒性。

具体而言，首先将所有辅助行为的去噪加权交互矩阵进行融合，定义如下：

$$\boldsymbol{R}^{all} = \sum_{k=1}^{K-1} \boldsymbol{R}^{de,k}, \tag{3-14}$$

其中，$\boldsymbol{R}^{all}$ 表示合并后的多行为交互矩阵。为控制注入目标行为的辅助数据规模，引入阈值超参数 β_{high}，从辅助行为中筛选出高置信度的交互样本，得到高权重交互矩阵：

$$R_{ui}^{\text{high}} = R_{ui}^{\text{all}} \cdot \mathbb{I}\left(\frac{R_{ui}^{\text{all}}}{\max(\mathbf{R}^{\text{all}})} \geq 1 - \beta_{\text{high}}\right), \tag{3-15}$$

其中，$\mathbb{I}(\cdot)$ 为指示函数。将高权重矩阵 $\boldsymbol{R}^{high}$ 与目标行为的去噪矩阵 $\boldsymbol{R}^{de,K}$ 合并后，得到增强后的目标行为视图：

$$\boldsymbol{R}^{aug} = \boldsymbol{R}^{high} + \boldsymbol{R}^{de,K}. \tag{3-16}$$

该矩阵 $\boldsymbol{R}^{aug}$ 作为增强图 $\boldsymbol{G}_{\boldsymbol{R}}^{aug}$ 的邻接矩阵，用于刻画用户与物品之间的强化交互关系。

上述过程生成了目标行为的两个视图：原始视图与增强视图。分别对两者进行编码后，得到节点表示 $\boldsymbol{e}_u^{\text{ori}}$ 与 $\boldsymbol{e}_u^{\text{aug}}$。节点级的正样本对定义为：

$$\left\{(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_u^{\text{aug}}) \mid u \in \mathcal{U}\right\},$$

而负样本对为：

$$\left\{(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_v^{\text{aug}}) \mid u, v \in \mathcal{U}, u \neq v\right\}.$$

在用户侧，优化目标采用 InfoNCE 损失定义如下：

$$\mathcal{L}_{\text{inter,user}} = \sum_{u \in \mathcal{U}} -\log\left(\frac{\exp\left(\phi(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_u^{\text{aug}})/\tau\right)}{\sum_{v \in \mathcal{U}} \exp\left(\phi(\boldsymbol{e}_u^{\text{ori}}, \boldsymbol{e}_v^{\text{aug}})/\tau\right)}\right), \tag{3-17}$$

其中，τ 为温度系数，$\phi(\cdot)$ 表示内积运算。物品侧的损失函数可按相同方式计算，最终跨行为对比学习的总体损失为：

$$\mathcal{L}_{\text{inter}} = \mathcal{L}_{\text{inter,user}} + \mathcal{L}_{\text{inter,item}}. \tag{3-18}$$

偏好感知的行为内对比学习：在多行为推荐中，具有相似交互模式的用户往往在偏好特征上表现出一致性，因此其嵌入表示也应保持高度相似。为此，本文引入了行为内对比学习机制，通过最大化相似用户嵌入之间的一致性，强化同偏好用户在表示空间中的聚合性，从而提升模型对用户真实偏好的刻画能力。

具体而言，基于增强后的交互矩阵 $\boldsymbol{R}^{aug}$，重新定义用户真实偏好相似性图 $\boldsymbol{G}_{\boldsymbol{U}}^{aug}$ 与物品真实偏好相似性图 $\boldsymbol{G}_{\boldsymbol{I}}^{aug}$。若用户 u 与 v（或物品 i 与 j）在 $\boldsymbol{R}^{aug}$ 中存

在相同交互，则在用户图 $\boldsymbol{G}_{\boldsymbol{U}}^{\boldsymbol{aug}}$ 中建立 u 与 v 的连接，在物品图 $\boldsymbol{G}_{\boldsymbol{I}}^{\boldsymbol{aug}}$ 中建立 i 与 j 的连接。由此可以刻画用户（或物品）间的交互一致性关系。

基于上述图结构，将具有相似交互模式的用户视为正样本对 (u, u^{+})，行为差异较大的用户视为负样本对 (u, u^{-})。通过最大化正样本对之间的嵌入一致性并最小化负样本对之间的相似度，实现对用户嵌入空间的对比优化。设 $\boldsymbol{e}_u$ 表示用户 u 的嵌入向量，行为内对比学习的目标函数定义如下：

$$\mathcal{L}_{\text{intra,user}} = \sum_{u \in \mathcal{U}} -\log\left(\frac{\exp\left(\phi(\boldsymbol{e}_u, \boldsymbol{e}_{u^{+}})/\tau\right)}{\sum_{u^{-} \in \mathcal{U}} \exp\left(\phi(\boldsymbol{e}_u, \boldsymbol{e}_{u^{-}})/\tau\right)}\right), \tag{3-19}$$

其中，u^{+} 表示与用户 u 在图 $\boldsymbol{G}_{\boldsymbol{U}}^{\boldsymbol{aug}}$ 中相连的节点，u^{-} 表示未与 u 相连的节点；τ 为温度超参数，$\phi(\cdot)$ 表示内积相似度函数。物品侧的损失函数定义方式与用户侧相同，行为内对比学习的总目标为：

$$\mathcal{L}_{\text{intra}} = \mathcal{L}_{\text{intra,user}} + \mathcal{L}_{\text{intra,item}}. \tag{3-20}$$

3.5 模型训练

为实现稳定高效的模型训练，本文采用一种非采样推荐目标函数[46]，其在准确性与效率上均优于传统的贝叶斯个性化排序（Bayesian Personalized Ranking, BPR）损失。对于给定的用户批次 B 和物品集合 $\mathcal{I}$，在行为 k 下的非采样推荐损失定义为：

$$\mathcal{L}_{\text{rec}}^{k} = \sum_{u \in B} \sum_{i \in I_u^{k+}} \left[\left(c_i^{k+} - c_i^{k-}\right)\left(\hat{x}_{u,i}^{k}\right)^2 - 2c_i^{k+}\hat{x}_{u,i}^{k}\right], \tag{3-21}$$

其中，$\hat{x}_{u,i}^{k}$ 表示用户 u 在行为 k 下对物品 i 的预测交互概率；I_u^{k+} 表示用户 u 在行为 k 下已发生交互的物品集合；c_i^{k+} 和 c_i^{k-} 为超参数，用于控制正负样本权重。

整体推荐任务的优化目标为各行为损失的加权和，其中 λ_k 为各行为的平衡系数：

$$\mathcal{L}_{\text{rec}} = \sum_{k=1}^{K} \lambda_k \mathcal{L}_{\text{rec}}^{k}. \tag{3-22}$$

此外，本文在训练中引入自监督对比学习损失，以进一步提升嵌入表示的判别性与鲁棒性。最终的联合优化目标定义为：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \mu(\mathcal{L}_{\text{inter}} + \mathcal{L}_{\text{intra}}), \tag{3-23}$$

其中，μ 为控制自监督学习强度的超参数。

训练完成后，目标行为下用户 u 对未交互物品 v 的交互概率计算如下：

$$\hat{y}_{uv}^{(k)} = \boldsymbol{e}_u^\top \cdot \mathrm{diag}(\boldsymbol{e}_K) \cdot \boldsymbol{e}_v, \tag{3-24}$$

其中，$\boldsymbol{e}_u$ 与 $\boldsymbol{e}_v$ 分别表示用户与物品的嵌入，K 表示目标行为类型，$\mathrm{diag}(\boldsymbol{e}_K)$ 为由目标行为嵌入构成的对角矩阵。

3.6 实验与讨论

3.6.1 评价指标

为了全面评估各模型在 Top-K 推荐任务下的性能，本文选取了两个常用指标：召回率（Recall）和归一化折损累计增益（Normalized Discounted Cumulative Gain, NDCG）。对于测试集中的每个用户，模型首先对所有候选物品进行排序，并根据排序结果计算以下指标。

$$\mathrm{Recall@K} = \frac{|R^K(u) \cap T(u)|}{|T(u)|}, \tag{3-25}$$

$$\mathrm{NDCG@K} = \frac{1}{|U|} \sum_{u \in U} \frac{\sum_{k=1}^{K} \frac{\mathbb{I}\left(R_k^K(u) \in T(u)\right)}{\log_2(k+1)}}{\sum_{k=1}^{K} \frac{1}{\log_2(k+1)}}, \tag{3-26}$$

其中，$R^K(u)$ 表示模型为用户 u 推荐的 Top-K 个物品集合，$T(u)$ 表示测试集中用户 u 实际交互（或点击）的物品集合，$R_k^K(u)$ 表示推荐列表中第 k 个物品。$\mathbb{I}(\cdot)$ 为指示函数，当 $R_k^K(u) \in T(u)$ 时取 1，否则为 0。

Recall@K 反映模型能否成功推荐出用户真实感兴趣的物品，而 NDCG@K 则进一步关注这些物品在推荐列表中的排序位置。前者强调**推荐覆盖率**，后者衡量**推荐排序质量**。二者结合使用，可综合评估模型在多行为去噪推荐任务中的整体表现。

3.6.2 数据集信息

本研究选用了学术界广泛使用的三个多行为推荐数据集——Beibei、Taobao 和

表 3-1: 数据集的统计信息

数据集	#User	#Item	#View	#Cart	#Favorite	#Buy
Beibei	21,716	7,977	2,412,586	642,622	–	282,860
Taobao	48,749	39,493	1,548,162	193,747	–	211,022
Tmall	31,882	31,232	1,223,372	293,544	253,619	135,980

Tmall，以评估所提出算法在不同场景下的有效性。这些数据集均包含用户与物品之间的多种交互行为（如浏览、收藏、加购与购买），能够充分反映用户在不同阶段的兴趣变化。所有数据集中均不包含显式反馈信息，仅记录用户的交互行为，因此非常适合用于基于隐式反馈的多行为去噪推荐研究。各数据集的详细统计信息见表 3-1。

3.6.3 实验设置

实验在 PyTorch 框架下实现，优化器采用 Adam，学习率设为 0.001，批量大小为 256，嵌入维度为 64。为防止模型过拟合，在训练过程中设置嵌入丢弃率（embedding dropout rate）为 0.3，边丢弃率（edge dropout rate）为 0.1。非采样损失（non-sampling loss）中的负样本权重在 $\{0.1, 0.01\}$ 中选择；对比学习的温度系数 τ 从 $\{0.2, 0.4\}$ 中选取。

3.6.4 总体实验效果

为验证所提出模型的有效性，本文选取了三类具有代表性的当前最先进推荐模型作为对比基线：

1. **单行为推荐模型（Single-Behavior Recommendation Models）**：此类模型仅利用目标行为进行训练，包括 NGCF[7] 与 LightGCN[5]。此外，为评估将多种行为直接整合为单一行为的影响，构建了融合所有行为数据的单行为版本，分别记为 NGCF_{all} 与 $\text{LightGCN}_{\text{all}}$。

2. **去噪推荐模型（Denoising Recommendation Models）**：包括面向单行为推荐的去噪方法 GraphDA[6]，以及面向多行为推荐的去噪方法 DPT[23]。

3. **多行为推荐模型（Multi-Behavior Recommendation Models）**：包括 S-MBRec[9]、GHCF[8]、MBSSL[35] 与 POGCN[22]。

表 3-2 展示了 NIPER 与各类基线模型的实验结果，其中最佳与次优结果分别以加粗和下划线标注。综合结果表明，所提出方法在多项指标上均显著优于现有方法，具体分析如下：

1. **NIPER 模型整体性能最优。** NIPER 在 Recall 与 NDCG 等主要指标上均超越所有基线模型。这一性能提升主要源于两点：（1）跨行为与行为内加权去噪机制有效识别并削弱了辅助行为中的噪声干扰；（2）偏好感知的表示增强模块在跨行为与行为内层面提升了嵌入的表达能力，使辅助行为中蕴含的真实偏好得以有效迁移至目标行为表示中。

2. **多行为建模显著优于单行为建模**。多行为推荐模型在三种数据集上均表现出优于单行为模型的效果，说明充分建模行为间关系能够更准确地反映用户的潜在偏好。同时，将所有行为简单合并为单一行为（NGCF_{all}、$\text{LightGCN}_{\text{all}}$）虽略有提升，但仍显著落后于多行为建模方法。

3. **辅助行为包含有价值偏好信息但同时存在噪声**。在 Beibei 与 Taobao 数据集中，将辅助行为纳入建模能提升推荐性能，说明辅助行为中确实包含真实偏好信号。然而在 Tmall 数据集中，该策略反而导致性能下降，表明该数据集的辅助行为中噪声比例更高，直接合并行为可能放大噪声影响。

4. **NIPER 在去噪性能方面优于现有方法**。与 GraphDA（单行为去噪）和 DPT（独立行为去噪）相比，NIPER 在考虑行为依赖关系的同时实现多行为联合去噪，并结合自监督学习增强表示鲁棒性，从而在多行为场景下展现出更优的性能。

表 3-2: NIPER 在三个数据集上的实验结果 (Beibei, Taobao, Tmall)

Model	Beibei				Taobao				Tmall			
	R@5	R@10	N@5	N@10	R@5	R@10	N@5	N@10	R@5	R@10	N@5	N@10
NGCF[7]	0.0185	0.0348	0.0108	0.0161	0.0203	0.0291	0.0141	0.0169	0.0219	0.0329	0.0146	0.0182
NGCF_{all}[7]	0.0316	0.0487	0.0194	0.0261	0.0254	0.0348	0.0193	0.0205	0.0024	0.0053	0.0021	0.0029
LightGCN[5]	0.0230	0.0419	0.0141	0.0202	0.0300	0.0412	0.0211	0.0247	0.0363	0.0524	0.0251	0.0303
LightGCN_{all}[5]	0.0349	0.0583	0.0222	0.0297	0.0377	0.0433	0.0284	0.0284	0.0036	0.0060	0.0023	0.0030
GraphDA[6]	0.0384	0.0603	0.0253	0.0312	0.0318	0.0468	0.0214	0.0253	0.0153	0.0204	0.0098	0.0143
DPT[23]	0.1009	0.1621	0.0545	0.0793	0.0484	0.1025	0.0375	0.0571	0.0573	0.0934	0.0353	0.0448
S-MBRec[9]	0.0981	0.1697	0.0613	0.0872	0.0673	0.0814	0.0348	0.0446	0.0503	0.0639	0.0301	0.0397
GHCF[8]	0.1227	0.1897	0.0783	0.1000	0.0534	0.0807	0.0361	0.0449	0.0462	0.0763	0.0287	0.0384
MBSSL[35]	0.1034	0.1734	0.0652	0.0899	0.0688	0.1022	0.0465	0.0567	0.0507	0.0838	0.0313	0.0419
POGCN[22]	0.0854	0.1548	0.0621	0.0801	0.0519	0.0841	0.0351	0.0423	0.0458	0.0741	0.0214	0.0386
NIPER	**0.1632**	**0.2372**	**0.1053**	**0.1292**	**0.0812**	**0.1084**	**0.0576**	**0.0664**	**0.0884**	**0.1216**	**0.0585**	**0.0693**

3.6.5 消融实验

为验证所提出模型中各个设计模块的有效性与必要性，本节进行了系统的消融实验。具体地，设计了以下六个模型变体：

1. **w/o Inter-Weighting**：移除跨行为加权机制，仅保留行为内权重进行去噪；
2. **w/o Causal Inference**：去除基于因果推断的行为强度估计，采用人工设定的固定值作为行为强度，其中 $\rho^{click} = 1$，$\rho^{cart} = \rho^{collect} = 2$，$\rho^{buy} = 3$；
3. **w/o Intra-Weighting**：移除行为内加权机制，仅依赖跨行为权重进行去噪；
4. **w/o Denoising**：完全取消去噪模块，直接利用原始多行为交互图进行建模；
5. **w/o $\text{SSL}_{\text{inter}}$**：移除偏好增强模块中的跨行为自监督学习部分；
6. **w/o $\text{SSL}_{\text{intra}}$**：移除偏好增强模块中的行为内自监督学习部分。

消融实验结果如表 3-3 所示。由于篇幅限制，本文重点报告 Beibei 与 Taobao 数据集上的 Recall@5 结果，其他数据集上亦观察到相似趋势。结果分析如下：

1. **加权机制的重要性**。跨行为与行为内加权机制的结合能够有效整合多视角信息，对不同交互的重要性进行精细区分。当任意一项加权机制被移除时（如 w/o Inter-Weighting 或 w/o Intra-Weighting），模型性能均出现明显下降，表明该双层加权策略对于识别噪声交互与保持有效信号均至关重要。

2. **去噪模块的必要性**。将完整模型与 w/o Denoising 变体对比可发现，去噪模块在显著提升模型精度方面起关键作用。若直接使用未经筛选的原始交互，辅助行为中的噪声信号会误导用户偏好建模，导致推荐结果偏差。因此，去噪阶段对于提升推荐系统的鲁棒性和准确性具有重要意义。

3. **自监督学习增强的有效性**。当移除自监督学习组件（w/o SSL_{inter} 或 w/o SSL_{intra}）后，模型性能均明显下降。这表明跨行为自监督学习（inter-SSL）通过高权重辅助行为增强目标行为表示，而行为内自监督学习（intra-SSL）有助于强化相似用户与物品之间的嵌入一致性。二者协同作用显著提升了模型的表征能力与泛化性能。

表 3-3: 消融实验结果

DataSet	Beibei		Taobao		Tmall	
Metric	Recall@5	NDCG@5	Recall@5	NDCG@5	Recall@5	NDCG@5
w/o Inter-Weighting	0.1243	0.0783	0.0704	0.0487	0.0611	0.0397
w/o Casual Inference	0.1325	0.0.0835	0.0806	0.0524	0.0691	0.0429
w/o Intra-Weighting	0.1232	0.0746	0.0720	0.0472	0.0601	0.0383
w/o Denoising	0.1198	0.0758	0.0603	0.0406	0.0493	0.0318
w/o SSL_{inter}	0.1154	0.0775	0.0618	0.0454	0.0576	0.0381
w/o SSL_{intra}	0.1163	0.0769	0.0605	0.0438	0.0549	0.0375
NIPER	**0.1632**	**0.1053**	**0.0812**	**0.0576**	**0.0884**	**0.0585**

3.6.6 参数实验

为探究模型关键超参数对整体性能的影响，本文从噪声移除比例 β_{low}、目标行为增强比例 β_{high} 以及行为权重平衡系数 α 三个方面进行了系统实验分析。图 3-3 展示了各参数变化对模型性能的影响趋势与差异。

1. **去噪比例 β_{low} 的影响**：如图 3-3(a) 所示，不同数据集在最优去噪比例上的差异反映了其噪声水平的不同。随着去噪比例的提高，模型性能呈现“先升后降”的趋势。这一现象可归因于以下两点：（i）在较低的去噪比例下，适度去除噪声交互有助于减少无关信息的干扰；（ii）当比例过高时，部分有效交互被误删，导致模型无法充分学习用户的真实偏好，从而造成性能下降。

2. **辅助行为增强比例 β_{high} 的影响**：增强比例 β_{high} 控制辅助行为对目标行为的补充程度。如图 3-3(b) 所示，随着 β_{high} 的增大，模型性能初期逐步提升，但在超过最优值后出现下降。这表明，适量引入辅助行为能够有效传递真实偏好信息，而过高的增强比例则会引入噪声或无效信号，反而削弱推荐效果。因此，合理设定 β_{high} 对于充分利用辅助行为、提升模型准确性至关重要。

3. **平衡系数 α 的影响**：参数 α 用于平衡行为间权重与行为内权重的重要性。如图 3-3(c) 所示，当 α 取值过小或过大时，模型会分别过度依赖跨行为或行为内权重，从而造成性能下降。虽然不同数据集的最优 α 值略有差异，但整体趋势表明，在两类权重间保持适当平衡能够使模型获得最佳表现。

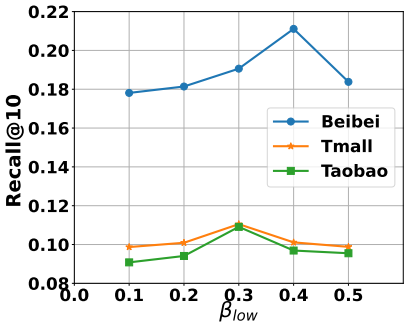

(a) 去噪比例 β_{low}

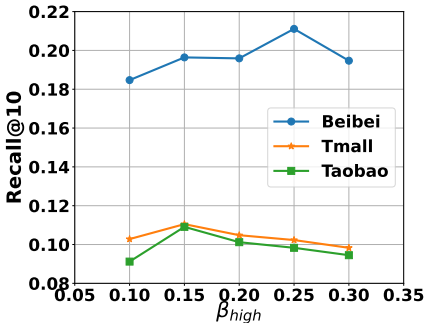

(b) 辅助行为增强比例 β_{high}

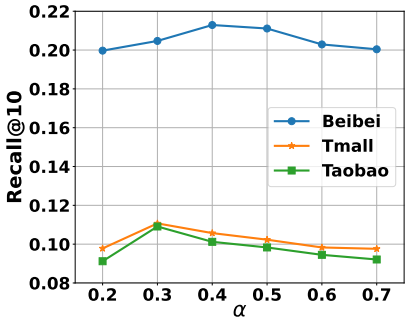

(c) 平衡系数 α

图 3-3: 超参数实验

3.6.7 案例研究

(1) 去噪模块有效性分析

为进一步验证所提出去噪模块的通用性与可迁移性，本节将 NIPER 的跨行为与行为内加权去噪模块集成至三种当前最先进的多行为推荐模型中——GHCF[8]、MBSSL[35] 和 POGCN[22]，以评估其对不同框架的性能提升效果。实验采用 Recall@10 与 NDCG@10 两项指标，对集成去噪模块前后的性能差异进行对比分析，从而量化该模块在提升推荐精度方面的贡献。

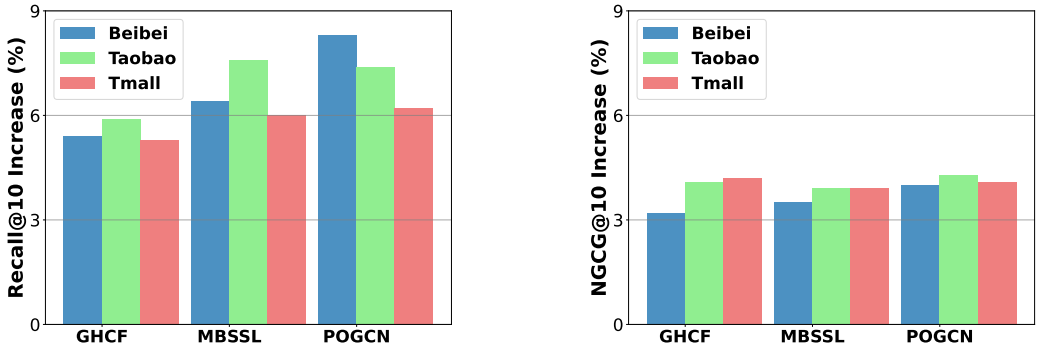

(a) Recall@10 提升效果　　(b) NDCG@10 提升效果

图 3-4: 在不同模型中集成 NIPER 去噪模块后的性能增益

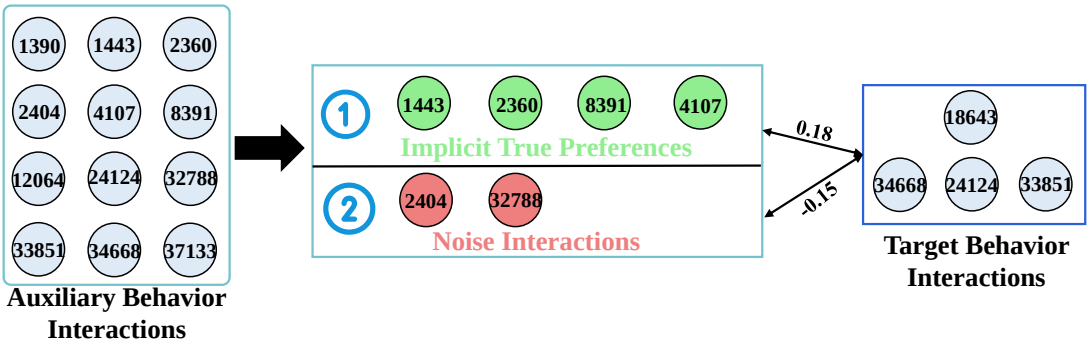

图 3-5: 辅助行为与目标行为相似性案例分析

如图 3-4 所示，在 Beibei、Taobao 和 Tmall 数据集上，三种基线模型在 Recall@10 与 NDCG@10 指标上均取得显著提升。该结果表明，NIPER 的去噪机制能够有效降低多行为交互中的噪声干扰，同时具备良好的通用性与可扩展性，可作为提升现有多行为推荐框架性能的独立模块。

(2) 去噪模块的局部效果分析

为进一步验证 NIPER 在辅助行为分类中的有效性，本节从局部视角对其进行分析。我们选取 Taobao 数据集中的一位典型用户作为研究对象，该用户在辅助行为下与 12 个物品发生过交互。依据模型在最优参数设置下的权重分布，我们根据去噪阈值 β_{low} 和增强阈值 β_{high} 对该用户的辅助行为进行了分类。其中，权重低于 β_{low} 的交互被视为噪声样本，而权重高于 $(1-\beta_{high})$ 的交互则被认为更能反映用户的真实偏好。随后，我们计算辅助行为交互与用户实际购买物品之间的余弦相似度，以验证分类结果的合理性。

分析：如图 3-5 所示，辅助行为中被识别为真实偏好的高权重交互，其与目标行为（购买行为）物品的相似度显著高于被识别为噪声的交互。这表明，NIPER 能够精准地区分噪声与真实偏好，在去除无效交互的同时，有效保留对用户真实兴趣具有代表性的交互信息，从而提升模型的整体推荐性能。

3.7 本章小结

本章提出了一种新颖的多行为推荐框架——NIPER（Noise Identification and Preference Extraction in Multi-Behavior Recommender System），用于解决多行为推荐系统中噪声交互与真实偏好提取的核心问题。与以往方法普遍将所有辅助行为数据直接融合到目标行为模型中不同，NIPER 能够区分辅助行为中的噪声与真实偏好。其中，跨行为与行为内加权去噪模块通过为多行为交互分配权重，有效削弱了噪声交互的影响，确保无关或偶然的行为被过滤；基于偏好的表征增强模块则利用自监督学习机制，从辅助行为中提取真实偏好信息，从而增强模型的表达能力。在多个公开数据集上的广泛实验结果表明，NIPER 在推荐精度上显著优于现有最先进方法，验证了该框架在提升多行为推荐系统鲁棒性与准确性方面的有效性。

第 4 章 噪声感知与偏好提取的多模态多行为推荐方法

4.1 引言

随着推荐系统在电商、短视频与内容分发等场景中的广泛应用，用户行为数据呈现出多样化和复杂化的特征。不同类型的用户行为（如点击、收藏、购买等）蕴含了用户多层次的兴趣线索，为建模个性化偏好提供了丰富的信息来源。然而，当前的推荐系统在建模用户偏好时仍面临两大核心挑战：其一，多行为交互数据中普遍存在噪声，例如误点击、无效浏览等行为并不能准确反映用户的真实兴趣；其二，现有方法主要依赖用户-物品的协同信号，忽视了物品本身的多模态语义内容（如文本描述和图像特征），从而限制了模型在兴趣表达不充分或行为多样性较高场景下的建模能力。

近年来，针对多行为推荐问题的研究逐渐深入，已有工作主要集中在行为关系建模和行为融合策略上，通过在不同层次上捕获多行为间的关联性来提升推荐效果。然而，这些方法普遍存在两方面的不足：一方面，它们通常假设辅助行为均为有效信号，未能充分考虑行为数据中的噪声问题，导致模型可能受到误导性交互的干扰；另一方面，尽管多模态信息（如图像和文本）能够为用户偏好提供语义补充，但现有研究往往将其作为静态特征使用，缺乏与多行为信号的深度融合，难以实现语义层面的偏好理解与去噪。

为解决上述问题，本文提出了一种**噪声感知与偏好提取的多模态多行为推荐方法**。该方法在传统多行为推荐框架的基础上，引入文本与图像等多模态特征，并借助大语言模型的知识建模与语义推理能力，实现多模态内容与多行为协同信号的深度融合。模型的总体目标是在抑制噪声交互的同时，增强多源语义的融合与真实偏好的刻画，从而提升推荐系统的鲁棒性与语义表达能力。

首先，**多模态辅助偏好建模模块**利用大语言模型对物品的文本与图像内容进行语义建模，生成高质量的多模态摘要，以提升内容表达的丰富度与可区分性。随后，结合用户-物品的多行为交互记录，计算交互强度与模态语义一致性，从内容层面辅助识别噪声交互，提取用户的真实偏好意图。

其次，**语义感知的图消息传递模块**在图神经网络的表示学习过程中，将多行为权重与模态特征嵌入共同融入消息传播机制，实现结构信号与语义信号的联合建模。通过动态调整邻居聚合权重，模型在表示传播过程中兼顾交互强度与内容语义相似性，从而生成更加稳健且可解释的用户与物品表示。

最后，**模态感知图增强的对比学习模块**旨在统一结构与语义空间中的表示分

布。该模块基于生成的用户偏好摘要与物品语义摘要构建语义增强图，并与协同交互图共同参与表示学习。通过跨图对比学习机制，对齐同一用户-物品对在不同图下的嵌入表示，从而提升模型的一致性与泛化性能。

本文的主要贡献如下：

1. 提出了一种融合大语言模型语义建模能力的多模态多行为去噪推荐框架，实现了多行为信号与多模态特征的深度协同建模，为噪声识别与偏好提取提供了新的思路。

2. 设计了语义感知的图消息传递机制，将多行为权重与模态特征共同嵌入图神经网络中，实现结构与语义信号的动态融合，显著提升了模型的鲁棒性与可解释性。

3. 引入模态感知图增强的对比学习策略，通过跨图对齐结构空间与语义空间的用户-物品表示，有效提高了模型的泛化性能与多模态语义一致性。

综上所述，本文提出的多模态多行为推荐方法通过引入大语言模型实现了从“协同信号驱动”到“语义理解驱动”的范式转变，既有效缓解了多行为数据中的噪声干扰，又提升了多模态特征在偏好建模中的融合质量与解释性，为多源信息融合的智能推荐提供了一种具有语义鲁棒性的解决思路。

4.2 问题定义及方法概述

4.2.1 问题定义

在本研究中，设用户集合为 $\mathcal{U} = \{u_1, u_2, \ldots, u_{|\mathcal{U}|}\}$，物品集合为 $\mathcal{I} = \{i_1, i_2, \ldots, i_{|\mathcal{I}|}\}$。定义用户-物品交互图为

$$G^R = (V, E^R), \tag{4-1}$$

其中，节点集合 $V = \mathcal{U} \cup \mathcal{I}$ 表示所有用户与物品节点，边集合 E^R 表示观测到的用户-物品交互关系。在多行为场景下，用户可能与同一物品发生多种类型的交互（如浏览、加购、购买等）。因此，整体交互图 G^R 可以划分为 K 个行为子图：

$$G^R = \{G_1^R, G_2^R, \ldots, G_K^R\}, \tag{4-2}$$

其中，G_k^R 表示第 k 种行为对应的子图。

为便于建模，定义交互矩阵集合 $\{R_1, R_2, \ldots, R_K\}$，其中

$$R_k \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|} \tag{4-3}$$

表示行为 k 下的用户-物品交互矩阵。若

$$R_{ui}^{k} = 1, \tag{4-4}$$

则表示用户 u 在行为 k 下与物品 i 发生过交互，对应地，在行为图 G_k^R 中存在一条连接用户 u 与物品 i 的边；若

$$R_{ui}^{k} = 0, \tag{4-5}$$

则表示该交互未发生。

在推荐任务中，模型旨在学习一个预测函数 $\widehat{y}_{ui}$，用于刻画用户 u 对物品 i 的偏好强度：

$$\widehat{y}_{ui} = f(u, i \mid \Theta), \tag{4-6}$$

其中 $f(\cdot)$ 表示推荐模型，Θ 为模型参数。根据预测得分对物品集合 $\mathcal{I}$ 进行排序，可为用户 u 生成推荐列表 R_u，即排名最高的 Top-K 个物品：

$$R_u = \text{Top-}K(\widehat{y}_{ui},\ i \in \mathcal{I}). \tag{4-7}$$

综上，多行为推荐任务的形式化定义如下：

- **输入**：用户在 K 种行为下的交互图集合 $\{G_1^R, G_2^R, \ldots, G_K^R\}$；
- **输出**：一个推荐模型，用于预测用户 u 在第 K 种行为（即目标行为）下与物品 i 发生交互的概率 $\widehat{y}_{ui}$。

4.2.2 方法概述

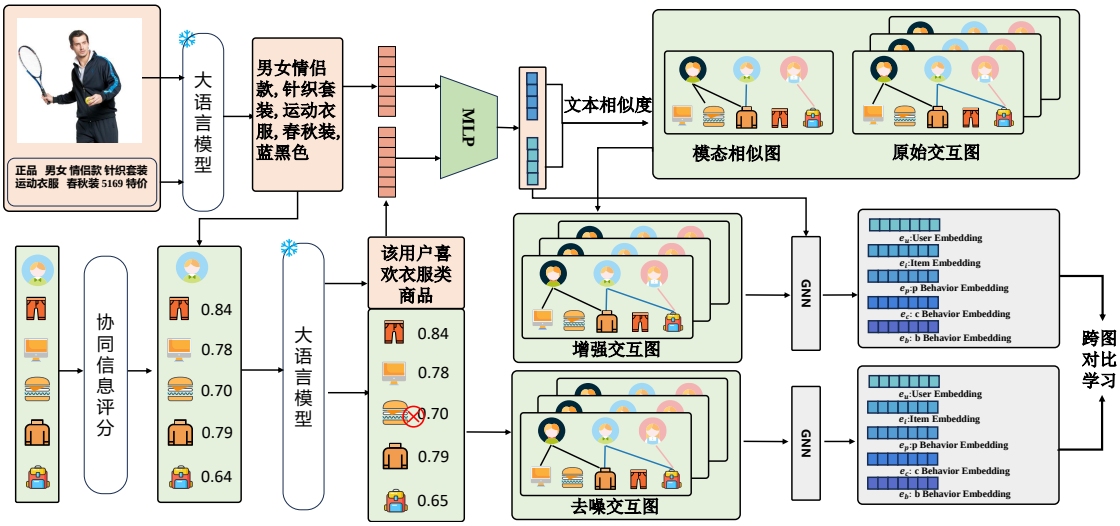

图 4-1: 噪声感知与偏好提取的多模态多行为推荐方法整体框架示意图

本研究聚焦于多模态多行为推荐系统中的噪声干扰与鲁棒表示建模问题，提

出了一种统一的多模态多行为去噪推荐框架。该方法融合了大语言模型的语义生成能力、多模态内容理解、图神经网络的结构建模优势以及对比学习的判别特性，以实现高质量、可解释且鲁棒的用户-物品表示学习。整体框架由以下三个核心模块组成：

1. **多模态辅助偏好建模模块**：为获得语义丰富且具备判别力的特征表示，本文首先利用 LLM 对多模态内容进行语义对齐。具体而言，物品侧基于图像与文本模态信息，通过 LLM 生成内容一致的语义文本描述，并将不同模态特征映射至共享语义空间，从而实现模态间的对齐与融合。随后，利用生成的模态嵌入计算用户-物品交互的语义相似度，根据相似度阈值执行**硬去噪**，以剔除显著偏离用户真实兴趣的异常交互行为。

2. **语义感知的图消息传递模块**：为联合建模交互结构与模态语义信息，本文设计了一种语义感知的消息传递机制。在邻居聚合过程中，引入基于模态相似度的注意力加权策略，使图神经网络在传播阶段重点聚合语义一致性更高的邻居节点；在特征更新阶段，融合交互嵌入、行为类型嵌入与模态语义嵌入，从而捕获多源特征间的互补关系，提升用户与物品表示的表达能力。

3. **模态感知图增强与对比学习模块**：为弥补原始交互图中潜在的偏好缺失，本文基于多模态语义关系构建语义增强图 $\mathcal{G}_{\text{aug}}$，并将其与去噪后的协同交互图共同用于表示学习。通过引入图级对比学习策略，对两种视角下的节点表示进行对齐，使模型能够在结构空间与语义空间之间实现一致性约束与知识迁移，从而有效提升推荐的鲁棒性与泛化性能。

4.3 多模态辅助偏好建模

多模态输入与文本摘要生成：本研究的输入数据包括物品侧的图像与标题文本，以及用户侧的多行为交互记录。物品侧数据通常存在语义噪声：图像中可能包含广告、水印或背景干扰元素，而文本标题多由商家编写，常含有营销性修辞或冗余关键词，难以准确反映商品的核心属性。为实现多模态内容的统一理解与语义浓缩表达，物品的图像与文本标题被共同输入至多模态大语言模型（LLM），通过设计提示词（prompt），在视觉与文本的协同语义空间中生成高质量的物品摘要文本。

在提示设计中，输入由“任务指令部分”和“数据输入部分”组成。

- **任务指令部分（Instruction）**：用于明确模型生成目标。例如：

你是一名电商领域的专家，请根据以下商品的图像和文本信息，生成一句简洁的摘要，用以准确描述该商品的核心功能、用途或适用人群。

- **数据输入部分（Input）**：包含商品主图和文本信息，例如：

图像：< 上传的商品主图 >
文本：这是一款夏季新款男士运动鞋，轻便透气，适合跑步及日常出行。

多模态大语言模型在接收上述输入后，将联合理解图像与文本两种模态的信息，并输出一段高语义浓度的商品摘要。例如："轻质透气的男士跑步鞋，适合日常通勤与运动。"该摘要被记作物品的语义描述 s_i，用于后续的用户偏好建模与图结构构建。

用户偏好摘要生成机制：在获得所有物品的模态摘要后，结合用户的多行为交互记录生成用户的偏好摘要文本。对于每个用户，将其交互过的物品摘要文本、行为类型（如点击、加购、收藏、购买）以及交互评分一并输入 LLM。交互评分来源于前一工作 NIPER 所提出的基于因果推断的协同加权机制，该机制通过跨行为与行为内的加权计算，为每条用户-物品交互分配一个反映交互可靠性与强度的权重分值，从而量化不同交互行为的重要性。

为了引导 LLM 理解行为强度与语义内容之间的关系，从而生成能够反映稳定兴趣偏好的文本摘要，设计的 prompt 模板如下所示：

- **任务说明（Instruction）**：

你是一位推荐系统助手。用户与物品之间的交互行为具有不同强度，例如"购买"通常表示较强兴趣，而"点击"可能仅代表短暂关注。请根据用户的历史交互记录，总结其主要兴趣偏好。

- **数据输入（Input）**：包括交互行为类型、物品摘要文本以及协同评分，例如：

用户 ID：u1234
交互物品列表：
[1] 行为：购买；摘要：轻质透气的跑步鞋；评分：0.92
[2] 行为：点击；摘要：女士时尚手提包；评分：0.23
[3] 行为：加购；摘要：运动功能手表，适合日常锻炼；评分：0.87
...

LLM 在理解交互强度、协同评分与模态语义的关系后，生成概括性的用户偏好摘要文本 s_u，如"偏好运动休闲类商品，特别关注轻便跑鞋与户外装备"。在此基础上，利用生成的用户偏好文本与物品模态摘要文本构建统一的语义表示空间，以支持后续基于模态相似度的硬去噪机制。

语义嵌入与基于相似度的硬去噪：为获得用户与物品的语义表示，将用户的偏好摘要文本 s_u 与物品的模态摘要文本 s_i 输入预训练语言模型 BERT，分别提取高维语义向量：

$$\mathbf{h}_u = \mathrm{BERT}(s_u), \quad \mathbf{h}_i = \mathrm{BERT}(s_i). \tag{4-8}$$

随后，使用多层感知机（MLP）对上述语义向量进行投影与降维，得到最终的模态语义嵌入：

$$\widetilde{\mathbf{e}}_u = \mathrm{MLP}(\mathbf{h}_u), \quad \widetilde{\mathbf{e}}_i = \mathrm{MLP}(\mathbf{h}_i). \tag{4-9}$$

由于预训练语言模型生成的语义向量通常维度较高（如 768 维或更高），若直接与图神经网络（GNN）的结构表示结合将导致参数量与计算开销显著增加，并且在特征融合时会造成尺度不一致问题。因此，MLP 模块不仅承担降维作用，更通过可学习的非线性映射实现语义空间的重构与特征尺度的统一，使得文本语义嵌入能够无缝对接后续 GNN 的结构化特征学习过程。

为避免投影过程中出现语义漂移并保持降维前后的语义一致性，引入余弦一致性正则项以约束 MLP 输出向量与原始 BERT 表示在方向上的一致性：

$$\mathcal{L}_{\text{align}} = 1 - \frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} \frac{\mathbf{h}_x^\top \widetilde{\mathbf{e}}_x}{\|\mathbf{h}_x\| \, \|\widetilde{\mathbf{e}}_x\|}, \tag{4-10}$$

其中 $\mathcal{X}$ 表示用户与物品节点的联合集合。该正则项通过最大化投影前后语义表示的方向一致性，保持了 BERT 表征的语义结构特征，同时避免了复杂的 softmax 与 KL 散度计算带来的数值不稳定。

在得到模态语义嵌入后，为识别辅助行为中的潜在噪声交互，计算用户嵌入与其交互物品嵌入之间的模态语义相似度：

$$s_{ui} = \frac{\widetilde{\mathbf{e}}_u^\top \widetilde{\mathbf{e}}_i}{\|\widetilde{\mathbf{e}}_u\| \, \|\widetilde{\mathbf{e}}_i\|}. \tag{4-11}$$

对每位用户的相似度得分进行 softmax 归一化：

$$\tilde{s}_{ui} = \frac{\exp(s_{ui}/\tau)}{\sum_{j \in \mathcal{I}_u} \exp(s_{uj}/\tau)}, \tag{4-12}$$

其中 τ 为温度系数。根据归一化后的相似度分布，设置阈值 δ，仅保留 $\tilde{s}ui \geq \delta$ 的交互边作为有效样本，对低于阈值的辅助行为交互视为硬噪声予以删除。购买行为由于其高置信度被始终保留。最终得到去噪后的多行为交互图：

$$\mathcal{G}_{\text{denoised}} = \mathcal{G}^R \setminus \{(u, i, b) \mid b \in \mathcal{B}_{\text{aux}}, \tilde{s}_{ui} < \delta\}. \tag{4-13}$$

通过上述语义建模与硬去噪流程，BERT 实现了跨模态语义空间的统一编码，MLP 进一步完成语义压缩与特征对齐，为后续 GNN 的消息传递提供兼容输入。基于模态相似度的去噪机制则有效剔除了语义不一致或低相关的辅助交互，在保留关键偏好信号的同时显著提升了交互图的纯净度与推荐模型的鲁棒性。

4.4 语义感知注意力的软去噪消息传递

在获得去噪后的加权交互图 $\boldsymbol{G}_{\mathbf{denoised},k}$ 后，为进一步缓解残余噪声干扰并提升表示的语义一致性，本文引入带有语义引导的消息传递机制，实现基于注意力的软去噪（soft denoising）。该过程以图神经网络为核心，在 GHCF[8] 框架基础上，通过引入 Query–Key–Value（QKV）注意力机制，动态调整邻居节点在信息聚合中的权重，从而抑制低语义相关的邻居贡献，强化与用户兴趣一致的高相关邻居信号。

不同于原始 GHCF 在各行为子图中对同类邻居进行等权聚合的方式，本研究根据用户与邻居物品在语义空间中的相似度自适应地分配聚合权重，使消息传递过程具备噪声感知能力。在第 l 层传播中，首先将用户与物品的模态语义嵌入 $\widetilde{\mathbf{e}}_u$ 与 $\widetilde{\mathbf{e}}_v$ 分别映射为 Query 与 Key 表示，而 Value 向量来自邻居节点的交互嵌入 $\mathbf{e}_v^{(l)}$：

$$\mathbf{q}_u = \mathbf{W}_Q^{(l)}\widetilde{\mathbf{e}}_u, \quad \mathbf{k}_v = \mathbf{W}_K^{(l)}\widetilde{\mathbf{e}}_v, \quad \mathbf{v}_v^{(l)} = \mathbf{W}_V^{(l)}\mathbf{e}_v^{(l)}, \tag{4-14}$$

其中，$\mathbf{W}_Q^{(l)}$、$\mathbf{W}_K^{(l)}$ 和 $\mathbf{W}_V^{(l)}$ 为第 l 层的可学习参数矩阵。

随后，用户 u 与其邻居物品 $v \in N_{u,k}$ 的注意力权重基于语义相关性计算得到：

$$\alpha_{uv,k}^{(l)} = \mathrm{softmax}\left(\frac{\mathbf{q}_u^\top \mathbf{k}_v}{\sqrt{d}}\right)_{v \in N_{u,k}}, \tag{4-15}$$

其中 d 为嵌入维度。该权重反映了邻居节点在语义空间中与用户兴趣的一致程度，高相似度邻居在聚合中获得更大权重，而语义不一致的噪声邻居则被自然削弱，从而实现了隐式的软去噪。

基于注意力权重，对邻居节点的特征进行加权聚合，得到用户 u 在行为 k 下的更新表示：

$$\mathbf{e}_{u,k}^{(l+1)} = \mathrm{LeakyReLU}\left(\mathbf{W}^{(l)} \sum_{v \in N_{u,k}} \alpha_{uv,k}^{(l)} \left(\mathbf{v}_v^{(l)} \odot \mathbf{e}_k^{(l+1)}\right)\right), \tag{4-16}$$

其中，$\odot$ 表示逐元素乘，$\mathbf{e}_k^{(l+1)}$ 为行为类型的嵌入，$\mathbf{W}^{(l)}$ 为特征变换矩阵。

为了进一步建模行为类型间的差异性，对每种行为类型嵌入进行线性变换：

$$\mathbf{e}_k^{(l+1)} = \mathbf{W}_b^{(l)}\mathbf{e}_k, \tag{4-17}$$

其中 $\mathbf{W}_b^{(l)}$ 为行为特征映射矩阵。最终，经过多层传播后，可分别得到用户嵌入 E_u、物品嵌入 E_v 和行为类型嵌入 E_k，其中 $k \in \mathcal{B}$ 为行为集合。

该语义感知注意力机制通过在消息传递过程中显式建模用户与邻居间的语义相关性，实现了对残余噪声的软抑制（soft denoising），使模型能够在多模态多行为场景下学习到更加鲁棒且语义一致的用户与物品表示。

4.5 模态感知图增强与对比学习

语义增强图构建：为缓解原始交互图中真实偏好边的缺失问题，并进一步发挥模态语义在推荐任务中的补充作用，构建了基于模态一致性的语义增强图 $\mathcal{G}_{\text{aug}}$。该图以辅助行为图（即 G_k^R，$k = 1, \ldots, K-1$）为基础，通过筛选语义一致性较高的用户–物品交互对来补充目标行为图 G_K^R，从而在保持协同结构的同时引入内容层面的关联信息。

具体而言，基于用户与物品的模态语义嵌入 $\widetilde{\mathbf{e}}_u$ 与 $\widetilde{\mathbf{e}}_v$，采用余弦相似度衡量二者的语义相关性：

$$\text{sim}(u, v) = \frac{\widetilde{\mathbf{e}}_u^\top \widetilde{\mathbf{e}}_v}{\|\widetilde{\mathbf{e}}_u\| \, \|\widetilde{\mathbf{e}}_v\|}. \tag{4-18}$$

当 $\text{sim}(u, v)$ 超过设定阈值 β 时，认为该辅助行为交互在语义上可能反映了用户的真实兴趣意图，因此将其纳入语义增强图：

$$\mathcal{G}_{\text{sim}} = \left\{(u, v) \mid \exists k \in \{1, \ldots, K-1\},\ (u, v) \in G_k^R,\ \text{sim}(u, v) > \beta\right\}. \tag{4-19}$$

最终，语义增强图 $\mathcal{G}_{\text{sim}}$ 被并入目标行为图，形成增强后的目标行为图：

$$\widetilde{G}_K^R = G_K^R \cup \mathcal{G}_{\text{sim}}, \tag{4-20}$$

并将其与原始辅助行为图集合共同记为 $\mathcal{G}_{\text{aug}}$。该增强策略通过引入高置信度的模态语义边补充协同图的结构信息，有效提升了目标行为图对用户真实兴趣的刻画能力。

跨图表示对比学习：为进一步实现语义增强图 $\mathcal{G}_{\text{aug}}$ 与去噪图 $\mathcal{G}_{\text{denoised}}$ 之间的知识迁移与偏好一致性建模，引入了跨图对比学习（cross-graph contrastive learning）策略。该机制利用模态信息生成正负样本对，从语义视角对齐两图中的节点表示，促进语义信息的高效传递。

具体而言，将两张图分别输入图神经网络（GNN），得到用户与物品在两种图结构下的嵌入表示：

$$\mathbf{e}_u, \mathbf{e}_v = \text{GNN}(\mathcal{G}_{\text{denoised}}), \quad \mathbf{e}_u^{\text{aug}}, \mathbf{e}_v^{\text{aug}} = \text{GNN}(\mathcal{G}_{\text{aug}}). \tag{4-21}$$

其中，$\mathbf{e}_u$ 与 $\mathbf{e}_v$ 分别为去噪图中用户与物品的嵌入，$\mathbf{e}_u^{\text{aug}}$ 与 $\mathbf{e}_v^{\text{aug}}$ 则来自语义增强图。

为强化两种图视角下的语义一致性，对同一节点在两图中的嵌入施加对比学习约束。以用户为例，对比学习损失定义为：

$$\mathcal{L}_{\text{contrast}}^{(u)} = -\log \frac{\exp\left(\cos(\mathbf{e}_u, \mathbf{e}_u^{\text{aug}})/\tau\right)}{\sum\limits_{u' \in \mathcal{U}} \exp\left(\cos(\mathbf{e}_u, \mathbf{e}_{u'}^{\text{aug}})/\tau\right)}, \tag{4-22}$$

其中 τ 为温度系数，$\cos(\cdot)$ 表示余弦相似度。同理，物品端的对比损失为：

$$\mathcal{L}_{\text{contrast}}^{(v)} = -\log \frac{\exp\left(\cos(\mathbf{e}_v, \mathbf{e}_v^{\text{aug}})/\tau\right)}{\sum_{v' \in \mathcal{I}} \exp\left(\cos(\mathbf{e}_v, \mathbf{e}_{v'}^{\text{aug}})/\tau\right)}. \tag{4-23}$$

最终的跨图对比学习目标定义为：

$$\mathcal{L}_{\text{contrast}} = \mathcal{L}_{\text{contrast}}^{(u)} + \mathcal{L}_{\text{contrast}}^{(v)}. \tag{4-24}$$

该模块利用模态信息构建正负样本对，将语义增强图中的高质量语义关系显式传递至去噪图的节点表示中，从而在结构空间与语义空间间实现信息对齐，显著提升用户与物品嵌入的鲁棒性与泛化能力。

4.6 模型训练

为实现多模态多行为场景下的稳定训练与鲁棒优化，模型的最终目标函数综合考虑了推荐精度、语义一致性与跨图表示对齐三方面因素。

首先，推荐损失仍采用与第一部分 NIPER 相同的非采样优化形式，用于直接回归用户-物品交互概率，避免负采样引入的噪声误差。对于特定用户批次 B 与整个物品集合 $\mathcal{I}$，行为 k 下的非采样推荐损失定义为：

$$\mathcal{L}_{\text{rec}}^{k} = \sum_{u \in B} \sum_{i \in I_u^{k+}} \left[\left(c_i^{k+} - c_i^{k-}\right) \left(\hat{x}_{u,i}^{k}\right)^2 - 2c_i^{k+} \hat{x}_{u,i}^{k} \right], \tag{4-25}$$

其中，$\hat{x}_{u,i}^{k}$ 表示用户 u 在行为 k 下对物品 i 的预测偏好值，I_u^{k+} 为正交互集合，c_i^{k+} 与 c_i^{k-} 为经验超参数。

整体推荐损失为各行为损失的加权和：

$$\mathcal{L}_{\text{rec}} = \sum_{k=1}^{K} \lambda_k \mathcal{L}_{\text{rec}}^{k}, \tag{4-26}$$

其中 λ_k 表示第 k 种行为的权重。

其次，为实现语义增强图与去噪图之间的信息传递与偏好一致性，引入跨图对比学习损失：

$$\mathcal{L}_{\text{contrast}} = \mathcal{L}_{\text{contrast}}^{(u)} + \mathcal{L}_{\text{contrast}}^{(v)}, \tag{4-27}$$

其中用户端与物品端的对比损失定义为：

$$\mathcal{L}_{\text{contrast}}^{(u)} = -\log \frac{\exp\left(\cos(\mathbf{e}_u, \mathbf{e}_u^{\text{aug}})/\tau\right)}{\sum_{u' \in \mathcal{U}} \exp\left(\cos(\mathbf{e}_u, \mathbf{e}_{u'}^{\text{aug}})/\tau\right)}, \quad \mathcal{L}_{\text{contrast}}^{(v)} = -\log \frac{\exp\left(\cos(\mathbf{e}_v, \mathbf{e}_v^{\text{aug}})/\tau\right)}{\sum_{v' \in \mathcal{I}} \exp\left(\cos(\mathbf{e}_v, \mathbf{e}_{v'}^{\text{aug}})/\tau\right)}. \tag{4-28}$$

此外，为防止 MLP 降维造成的语义漂移，引入余弦一致性正则项，用以保持 BERT 原始表征与投影后嵌入的语义方向一致：

$$\mathcal{L}_{\text{align}} = 1 - \frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} \frac{\mathbf{h}_x^\top \widetilde{\mathbf{e}}_x}{\|\mathbf{h}_x\| \, \|\widetilde{\mathbf{e}}_x\|}, \tag{4-29}$$

其中 $\mathcal{X}$ 为用户与物品节点的集合。

最终的联合优化目标定义为：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \mu \, \mathcal{L}_{\text{contrast}} + \gamma \, \mathcal{L}_{\text{align}}, \tag{4-30}$$

其中，μ 与 γ 分别为对比学习与语义一致性正则项的权重系数。

在优化完成后，用户 u 对物品 v 的目标行为预测概率为：

$$\hat{y}_{uv}^{(k)} = \mathbf{e}_u^\top \cdot \text{diag}(\mathbf{e}_k) \cdot \mathbf{e}_v, \tag{4-31}$$

其中 $\mathbf{e}_u$、$\mathbf{e}_v$ 分别为用户与物品嵌入，$\mathbf{e}_k$ 为目标行为类型的嵌入向量，$\text{diag}(\mathbf{e}_k)$ 表示以 $\mathbf{e}_k$ 为对角元素的对角矩阵。

该联合目标在优化过程中同时约束了结构信号、模态语义与跨图一致性，从而实现了鲁棒、稳健的多模态多行为去噪推荐建模。

4.7 实验与讨论

4.7.1 评价指标

为全面评估模型的推荐性能，本文采用命中率（Hit Ratio，HR）与归一化折损累计增益（Normalized Discounted Cumulative Gain，NDCG）作为主要评价指标，其计算方式与第三章相同。其中，HR 用于衡量模型在前 K 个推荐结果中命中目标物品的比例，反映模型的召回能力；NDCG 则综合考虑目标物品在推荐列表中的排名位置，更能体现推荐结果的排序合理性与相关性。

4.7.2 数据集信息

由于第三章所使用的数据集仅包含用户与物品在多种行为下的交互信息（如点击、加购、购买等），缺乏文本与图像等模态特征，无法支撑多模态场景下的去噪与偏好建模研究。为进一步扩展模型至多模态多行为推荐任务，本章基于 Tmall 平台的原始数据重新构建了一个多模态多行为推荐数据集——**Tmall-Rec**①。该数据集在保留用户-物品多行为交互关系的基础上，补充了物品侧的文本描述与图像

① https://tianchi.aliyun.com/dataset/140281

信息，使得模型能够同时利用协同交互信号与多模态内容特征进行联合建模，从而更深入地探索用户真实偏好识别与噪声过滤机制。表 4-1 展示了该数据集的统计信息。

表 4-1: Tmall-Rec 数据集的统计信息

数据集	#User	#Item	#View	#Cart	#Buy
Tmall-Rec	8,302	30,316	496,615	60,798	43,172

4.7.3 实验设置

实验基于 PyTorch 实现，优化器采用 Adam，学习率设为 0.001，批量大小为 256。图神经网络（GNN）的嵌入维度为 64；为缓解过拟合，训练中使用嵌入丢弃率 0.3 与边丢弃率 0.1。非采样推荐目标的负样本权重固定为 0.01。对比学习的温度系数 τ 在区间 $[0.1, 0.5]$ 内网格搜索。文本语义编码器采用 Sentence-BERT，其输出维度为 768；随后通过一个 MLP 投影到 64 维以与 GNN 表示空间对齐并降低计算开销。多模态摘要与语义对齐由 Qwen-2.5-VL 完成，输入为物品图像与标题以及用户的多行为交互信息。

4.7.4 总体实验效果

表 4-2: Tmall-Rec 数据集上各模型的性能比较结果

Model	Tmall-Rec			
	Recall@5	Recall@10	NDCG@5	NDCG@10
LightGCN[5]	0.0823	0.2049	0.0742	0.1598
FREEDOM[30]	0.1874	0.3412	0.1438	0.2487
GHCF[8]	0.3117	0.4079	0.2274	0.2585
DPT[23]	0.3571	0.4762	0.2745	0.3017
MBSSL[35]	0.3934	0.5063	0.2932	0.3298
Ours	**0.5234**	**0.6241**	**0.4012**	**0.4338**

为验证所提多模态多行为去噪推荐算法的有效性，与三类具有代表性的推荐模型进行了系统对比，具体如下：

1. **单行为推荐模型（Single-Behavior Recommendation Models）**：仅基于目标行为进行建模，用于评估多行为协同建模带来的性能提升。代表方法包括经典协同过滤模型 LightGCN[5]，以及融合模态特征的单行为多模态推荐模型 FREEDOM[30]。

2. **去噪推荐模型（Denoising Recommendation Models）**：通过建模噪声特征以提升推荐鲁棒性，选取面向多行为场景的代表性方法 DPT[23] 进行对比。

3. **多行为推荐模型（Multi-Behavior Recommendation Models）**：显式建模多种用户行为间的相关性，以增强目标行为的预测能力。代表方法包括 GHCF[8] 与基于自监督机制的 MBSSL[35]。

表 4-2 展示了多模态多行为去噪推荐算法与三类基线模型在 Tmall-Rec 数据集上的综合性能比较结果。所有模型均采用在验证集上表现最优的超参数配置进行评估，以确保结果的公平性。

从整体结果来看，所提算法在 Recall@K 与 NDCG@K 等主要指标上均取得了显著提升，表现出更优的推荐准确性与排序能力。其中，在 Recall@10 和 NDCG@10 上，较当前表现最优的多行为模型 MBSSL 分别提升约 12% 与 10%，在各评价指标上均保持领先。

从模型结构角度分析，传统单行为模型（如 LightGCN）由于未考虑多行为信号之间的关联，仅能学习目标行为层面的偏好模式，整体性能较低。加入模态特征的 FREEDOM 在一定程度上提升了内容表达能力，但其缺乏对多行为协同关系与噪声交互的建模，仍存在语义偏差与过拟合问题。多行为推荐方法 GHCF 与 MBSSL 能够捕获行为间的关联性，从而在多源交互数据上获得更优表现，但其对多模态内容的利用较为有限，且在存在噪声干扰的场景中表现下降。

相比之下，所提算法在两方面实现了显著优势：（1）通过引入大模型生成的模态语义摘要，有效弥补了协同信号中缺失的内容信息，使模型能够在语义空间中对齐用户与物品的真实偏好关系；（2）结合基于模态相似度的硬去噪机制与语义感知的软去噪聚合策略，显著降低了辅助行为中随机性与非兴趣驱动交互的干扰，确保图结构中保留的信息更加纯净。

综合来看，该算法在多模态融合与噪声抑制两方面均展现出较高的鲁棒性与表达能力，验证了在复杂交互场景下引入模态语义信息与分层去噪机制的必要性与有效性。

4.7.5 消融实验

为验证所提出模型中各个设计模块的有效性与必要性，本节进行了系统的消融实验。具体地，设计了以下四个模型变体：

1. **GNN only**：仅保留基础的 GHCF 网络结构，对多行为交互进行建模，不引入任何模态或去噪模块；

2. **w/o 硬去噪**：移除基于多模态信息的硬去噪模块，保留语义感知消息传递与对比学习；

3. **w/o 软去噪**：移除语义感知注意力机制，使用与 GHCF 相同的均值聚合方式进行消息传递；

4. **w/o SSL**：移除模态感知图增强与跨图对比学习模块，仅保留去噪与基本 GNN 表示学习；

消融实验结果如表 4-3 所示。结果分析如下：

1. **基础 GNN 的性能对比**。与完整模型相比，仅使用 GHCF 结构（**GNN only**）的性能显著较低，说明单纯依赖协同信号难以充分建模用户的真实偏好。这验证了引入多模态语义与去噪机制对于提升表示质量与缓解交互噪声具有重要意义。

2. **硬去噪机制的重要性**。移除硬去噪模块后，模型性能显著下降，表明多模态信息在识别和剔除非真实交互方面发挥了关键作用。硬去噪模块通过计算用户与物品在语义空间中的模态相似度，有效过滤了语义不一致或低相关的辅助行为交互，从而降低了噪声干扰。当该机制被移除时，噪声交互被直接用于训练，导致表示学习受污染，用户偏好建模的准确性显著下降。

3. **软去噪模块的必要性**。替换语义感知注意力为均值聚合后，模型在所有评估指标上均出现明显退化，表明软去噪机制在信息传播过程中的自适应调节能力至关重要。基于语义相似度的注意力权重能够动态调整邻居节点的影响力，使模型在特征聚合时更关注语义一致性高的交互关系，从而提升用户与物品表示的判别性与稳定性。

4. **对比学习的有效性**。移除跨图对比学习模块后，模型泛化性能明显下降，验证了该模块在语义增强图与去噪图之间建立一致性约束的作用。对比学习通过在两个视角下对齐节点表示，促进了语义信息向结构空间的有效迁移，从而在保持表达一致性的同时增强了模型的鲁棒性。

表 4-3: 消融实验结果（Tmall-Rec 数据集）

Model	Tmall-Rec			
	Recall@5	Recall@10	NDCG@5	NDCG@10
GNN only	0.2902	0.3857	0.2098	0.2405
w/o 硬去噪	0.4386	0.5337	0.3157	0.3444
w/o 软去噪	0.4628	0.5835	0.3321	0.3695
w/o SSL	0.4409	0.5748	0.3279	0.3528
Ours	**0.5234**	**0.6241**	**0.4012**	**0.4338**

4.7.6 参数实验

为系统分析模型关键超参数对整体性能的影响，本节从三个方面展开实验研

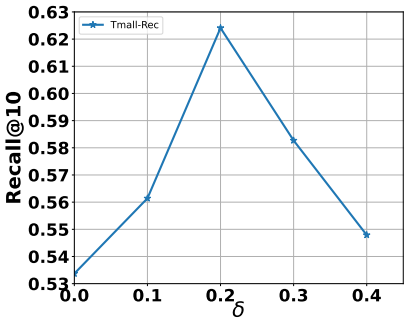

(a) 硬噪声阈值 δ

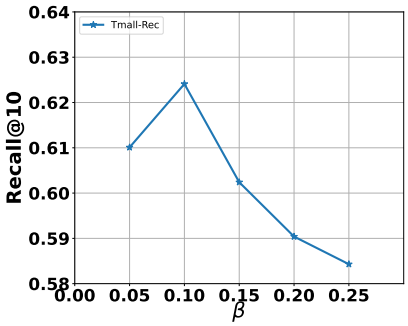

(b) 语义增强阈值 β

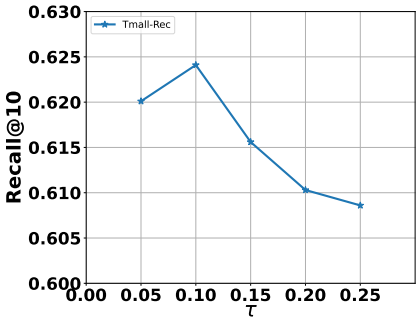

(c) 对比学习温度系数 τ

图 4-2: 超参数实验

究：硬噪声阈值 δ、语义增强阈值 β 以及对比学习温度系数 τ。图 4-2 展示了不同参数取值下模型在主要指标上的性能变化趋势。

1. **硬噪声阈值 δ 的影响**：该参数用于控制硬去噪阶段中交互样本的过滤强度。当阈值较低时，模型可能保留部分噪声样本，导致表示学习受到干扰；而当阈值过高时，真实但罕见的偏好交互可能被误删，造成信息损失。实验结果表明，适中的阈值能在噪声抑制与信息保留之间取得良好平衡，从而实现最优性能。

2. **语义增强阈值 β 的影响**：语义增强阈值决定了辅助行为交互是否可被纳入语义增强图中。较低的阈值会引入更多低相关的辅助样本，降低图结构的纯度；较高的阈值则导致增强边数量不足，语义补充效果减弱。实验结果显示，适当提升 β 能有效强化语义一致性，提升模型在高阶兴趣建模中的表现。

3. **对比学习温度系数 τ 的影响**：温度系数调节了对比学习中正负样本分布的平滑程度。当 τ 过大时，样本差异被弱化，导致对比约束不足；当 τ 过小时，梯度过于尖锐，模型训练不稳定。结果表明，适中的温度系数能兼顾表示区分性与优化稳定性，从而提升跨图对齐效果。

4.7.7 案例研究

为验证本文提出的大模型模态增强方法在区分视觉相似但语义不同商品时的

特征类型	相似度
视觉特征（Vision-only）	0.57
原始文本特征（Original Text）	0.41
LLM 增强文本特征（LLM-Enhanced Text）	**0.32**

图 4-3: 红色豆浆机与红色图书样本对在不同特征表征下的语义相似度。

有效性，本节选取两张在视觉上高度相似、背景一致的商品图片（红色豆浆机与红色图书）构建案例对。两张图片在颜色、光照与构图上几乎一致，低层视觉特征高度相似，难以通过视觉表征区分。

实验对比了三种不同表征方式的相似度。如图 4-3 所示，视觉特征的相似度最高（0.57），表明传统视觉模型主要受颜色与外观影响；原始文本表征的相似度下降至 0.41，反映了文本语义对类别差异的初步区分；而本文提出的 LLM 增强文本方法进一步将相似度降低至 0.32，说明通过大语言模型生成的结构化语义描述（包含品类、功能、品牌等关键槽位信息），能够显著强化语义可分性，减少视觉共性带来的混淆。

4.8 本章小结

本章针对多模态多行为推荐场景中噪声干扰与鲁棒表示建模的问题，提出了一种融合大语言模型语义理解能力与图神经网络结构建模优势的统一去噪推荐框架。不同于传统多行为推荐方法仅依赖协同信号进行建模，本文方法充分利用多模态内容与语义信息，能够在多源信号下实现对用户真实偏好的精准建模。

其中，多模态辅助偏好建模模块利用大语言模型生成语义摘要与相似度分布，通过硬去噪机制有效过滤低相关交互；语义感知的图消息传递模块引入软去噪策略，自适应地聚合语义一致性更高的邻居节点，提升表示的稳定性与鲁棒性；模

态感知图增强与对比学习模块则通过跨图一致性约束实现结构空间与语义空间的协同优化，进一步增强了模型的泛化性能。

在多模态多行为数据集上的实验结果表明，所提出的框架在 Recall 与 NDCG 等指标上显著优于现有主流方法。进一步的消融实验验证了硬去噪、软去噪与对比学习模块的有效性，证明该方法能够在融合多源模态信息、抑制交互噪声与提升推荐性能方面取得显著优势。

结 论

随着推荐系统在各类互联网平台中的广泛应用，用户交互数据的多样化与复杂性不断提升，传统的单行为建模方式已难以充分刻画用户的真实偏好特征。多行为与多模态信息的引入为推荐系统带来了新的机遇，也带来了噪声干扰、语义偏移及鲁棒建模等新的挑战。本文围绕多行为与多模态推荐场景下的噪声抑制与偏好建模问题展开研究，提出了两种创新性的去噪推荐框架。

首先，提出了一种新颖的多行为推荐框架——NIPER，用于解决多行为推荐系统中噪声交互与真实偏好提取的核心问题。与以往方法普遍将所有辅助行为数据直接融合到目标行为模型中不同，NIPER 能够区分辅助行为中的噪声与真实偏好。其中，行为间与行为内加权去噪模块通过为多行为交互分配权重，有效削弱了噪声交互的影响，确保无关或偶然的行为被过滤；基于偏好的表征增强模块则利用自监督学习机制，从辅助行为中提取真实偏好信息，从而增强模型的表达能力。广泛的实验结果表明，NIPER 在推荐精度与鲁棒性方面均显著优于现有最先进方法，验证了该框架在多行为推荐任务中的有效性。

接着，本文针对多模态多行为推荐场景中的噪声干扰与鲁棒表示建模问题，提出了一种融合大语言模型（LLM）语义理解能力与图神经网络（GNN）结构建模优势的统一去噪推荐框架。该方法通过多模态内容辅助、语义引导消息传递与跨图对比学习三方面的设计，实现了多源信号下用户真实偏好的精准建模。首先，在多模态辅助偏好建模阶段，引入多模态大语言模型生成物品的语义摘要文本，并结合多行为交互生成用户偏好摘要，从而在语义层面实现跨模态对齐；随后，通过模态语义嵌入计算用户与物品相似度分布，设计硬去噪机制以识别并剔除低相关交互，显著提升交互图的纯净度。其次，在软去噪模块中，构建语义感知注意力机制，引导 GNN 在消息传递过程中自适应地聚合语义相关性更高的邻居节点，从而降低噪声扩散并增强表示的鲁棒性。最后，通过模态感知图增强与跨图对比学习模块，引入语义增强图以补充协同图中的偏好缺失信息，并在跨图约束下实现多视角表示一致性。实验结果表明，该模型在多个指标上均显著优于主流基线模型，验证了所提框架在融合多源模态信息、抑制交互噪声与提升推荐精度方面的优势。

研究仍然存在一些不足。本文提出的多行为与多模态去噪推荐方法在泛化性与可扩展性方面仍有进一步提升空间。首先，模型整体结构较为复杂，包含多层去噪与语义对齐模块，虽然能够有效提升推荐性能，但也带来了较高的计算开销与参数规模，在大规模推荐场景下的训练效率与推理速度仍需优化。最后，本文

的实验主要基于公开数据集，缺乏在真实工业环境中的在线验证与用户反馈分析。未来的研究将探索基于因果推理的噪声建模与多模态语义对齐机制，结合任务自适应与轻量化建模策略，进一步提升模型的泛化性、可扩展性与稳健性，为多行为多模态推荐系统的发展提供更加通用且高效的解决方案。

参考文献

[1] 刘建国，周涛，汪秉宏. 个性化推荐系统的研究进展 [J]. 自然科学进展，2009，19（01）：1-15.

[2] GAO C，WANG X，HE X，et al. Graph neural networks for recommender system [C] //Proceedings of the fifteenth ACM international conference on web search and data mining，2022：1623-1625.

[3] ZHOU H, XIONG F, CHEN H. A comprehensive survey of recommender systems based on deep learning [J]. Applied Sciences，2023，13（20）：11378.

[4] ALJUNID M F，MANJAIAH D，HOOSHMAND M K，et al. A collaborative filtering recommender systems: Survey [J]. Neurocomputing，2025，617：128718.

[5] HE X，DENG K，WANG X，et al. Lightgcn: Simplifying and powering graph convolution network for recommendation [C] //Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval，2020：639-648.

[6] FAN Z, XU K, DONG Z, et al. Graph collaborative signals denoising and augmentation for recommendation [C] //Proceedings of the 46th international ACM SIGIR conference on research and development in information retrieval，2023：2037-2041.

[7] WANG X，HE X，WANG M，et al. Neural graph collaborative filtering [C] //Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval，2019：165-174.

[8] CHEN C, MA W, ZHANG M, et al. Graph heterogeneous multi-relational recommendation [C] //Proceedings of the AAAI conference on artificial intelligence：Vol 35，2021：3958-3966.

[9] GU S, WANG X, SHI C, et al. Self-supervised Graph Neural Networks for Multi-behavior Recommendation. [C] //IJCAI，2022：2052-2058.

[10] YING R，HE R，CHEN K，et al. Graph convolutional neural networks for web-scale recommender systems [C] //Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining，2018：974-983.

[11] WU L, SUN P, FU Y, et al. A neural influence diffusion model for social recommendation [C] // Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval, 2019: 235-244.

[12] WANG H, ZHANG F, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation [C] // The world wide web conference, 2019: 2000-2010.

[13] WU J, WANG X, FENG F, et al. Self-supervised graph learning for recommendation [C] // Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval, 2021: 726-735.

[14] LIU C, YU C, GUI N, et al. SimGCL: graph contrastive learning by finding homophily in heterophily [J]. Knowledge and Information Systems, 2024, 66 (3): 2089-2114.

[15] 严明时，程志勇，孙静，et al. 基于两阶段学习的多行为推荐 [J/OL]. 软件学报，2024，35（05）：2446-2465. http://dx.doi.org/10.13328/j.cnki.jos.006897.

[16] 党伟超，宋楚君，高改梅，et al. 基于级联残差图卷积网络的多行为推荐 [J]. 计算机应用，2024：1-13.

[17] 李建国，马文杰，程俊伟，et al. 基于图注意力网络的多行为推荐算法 [J]. 华南师范大学学报 (自然科学版)，2023，55（04）：72-80.

[18] 陆佳炜，李端倪，王策策，et al. 基于超图卷积神经网络的多行为感知服务推荐方法 [J]. 浙江大学学报 (工学版)，2023，57（10）：1977-1986.

[19] JIN B, GAO C, HE X, et al. Multi-behavior recommendation with graph convolutional networks [C] // Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval, 2020: 659-668.

[20] XIA L, XU Y, HUANG C, et al. Graph meta network for multi-behavior recommendation [C] // Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval, 2021: 757-766.

[21] CHENG Z, HAN S, LIU F, et al. Multi-behavior recommendation with cascading graph convolution networks [C] // Proceedings of the ACM Web Conference 2023, 2023: 1181-1189.

[22] ZHANG Y, BEI Y, CHEN H, et al. Multi-Behavior Collaborative Filtering with Partial Order Graph Convolutional Networks [C] // Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2024: 6257-6268.

[23] ZHANG C，CHEN R，ZHAO X，et al. Denoising and prompt-tuning for multi-behavior recommendation [C] //Proceedings of the ACM Web Conference 2023，2023：1355-1363.

[24] 王魁，姚迅，杨捷. 基于样本选择的自学习去噪鲁棒模型 [J]. 计算机应用，2024，44（S1）：77-82.

[25] WANG W，FENG F，HE X，et al. Denoising implicit feedback for recommendation [C] //Proceedings of the 14th ACM international conference on web search and data mining，2021：373-381.

[26] TIAN C，XIE Y，LI Y，et al. Learning to denoise unreliable interactions for graph collaborative filtering [C] //Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval，2022：122-132.

[27] HE Z，WANG Y，YANG Y，et al. Double Correction Framework for Denoising Recommendation [C] //Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining，2024：1062-1072.

[28] ZHANG S，CHU H，LI J，et al. DeMBR: Denoising Model with Memory Pruning and Semantic Guidance for Multi-Behavior Recommendation [C] //Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining，2025：521-529.

[29] ZHANG J，ZHU Y，LIU Q，et al. Mining latent structures for multimedia recommendation [C] //Proceedings of the 29th ACM international conference on multimedia，2021：3872-3880.

[30] ZHOU X，SHEN Z. A tale of two graphs: Freezing and denoising graph structures for multimodal recommendation [C] //Proceedings of the 31st ACM international conference on multimedia，2023：935-943.

[31] MO F，XIAO L，SONG Q，et al. Multimodal graph neural network for recommendation with dynamic de-redundancy and modality-guided feature de-noisy [J]. arXiv preprint arXiv:2411.01561，2024.

[32] WEI W，REN X，TANG J，et al. Llmrec: Large language models with graph augmentation for recommendation [C] //Proceedings of the 17th ACM international conference on web search and data mining，2024：806-815.

[33] XU Y，CONG G，ZHU L，et al. MMPOI: A Multi-Modal Content-Aware Framework for POI Recommendations [C] //Proceedings of the ACM on Web Conference，Singapore，2024：3454-3463.

[34] WANG S，ZHENG Z，SUI Y，et al. Unleashing the Power of Large Language Model for Denoising Recommendation [C] // Proceedings of the ACM on Web Conference 2025，2025：252-263.
[35] XU J, WANG C, WU C, et al. Multi-behavior self-supervised learning for recommendation [C] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval，2023：496-505.
[36] WEI W，HUANG C，XIA L，et al. Contrastive meta learning with behavior multiplicity for recommendation [C] // Proceedings of the fifteenth ACM international conference on web search and data mining，2022：1120-1128.
[37] KIPF T. Semi-supervised classification with graph convolutional networks [J]. arXiv preprint arXiv:1609.02907，2016.
[38] HAMILTON W，YING Z，LESKOVEC J. Inductive representation learning on large graphs [J]. Advances in neural information processing systems，2017，30.
[39] VELICKOVIC P，CUCURULL G，CASANOVA A，et al. Graph Attention Networks [C] // 6th International Conference on Learning Representations，Vancouver, BC, Canada，2018：1024-1045.
[40] BACHMAN P，HJELM R D，BUCHWALTER W. Learning representations by maximizing mutual information across views [J]. Advances in neural information processing systems，2019，32.
[41] OORD A V D，LI Y，VINYALS O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748，2018.
[42] CHEN T，KORNBLITH S，NOROUZI M，et al. A simple framework for contrastive learning of visual representations [C] // International conference on machine learning，2020：1597-1607.
[43] HE K，FAN H，WU Y，et al. Momentum contrast for unsupervised visual representation learning [C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition，2020：9729-9738.
[44] GRILL J-B，STRUB F，ALTCHÉ F，et al. Bootstrap your own latent-a new approach to self-supervised learning [J]. Advances in neural information processing systems，2020，33：21271-21284.
[45] WANG T，ISOLA P. Understanding contrastive representation learning through alignment and uniformity on the hypersphere [C] // International conference on machine learning，2020：9929-9939.
[46] CHEN C，ZHANG M，ZHANG Y，et al. Efficient heterogeneous collaborative filtering without negative sampling for recommendation [C] // Proceedings of the AAAI conference on artificial intelligence：Vol 34，2020：19-26.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

（二）申请及已获得的专利

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于图神经网络的多行为去噪推荐方法研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢